UVOD U VJEROJATNOST I STATISTIKU

Skripta za kolegij Statistika
(2. godina dodiplomskog studija)

Darko Brborović

2024
Sveučilište Jurja Dobrile u Puli

Sadržaj

1 Alati **5**
- 1.1 R i LaTeX . . . 5
- 1.2 Osnovno o R-u . . . 6
- 1.3 Podaci u R-u . . . 7
  - 1.3.1 Funkcija `c()` i vektori . . . 9
  - 1.3.2 Pristup elementima vektora . . . 9
  - 1.3.3 Još neki načini stvaranja vektora: funkcije `rep()` i `seq()` . . . 10
  - 1.3.4 Nenumerički vektori, još neke funkcije . . . 11
  - 1.3.5 Funkcija `which()` . . . 12
  - 1.3.6 Funkcija `typeof()` . . . 14
  - 1.3.7 Matrice . . . 14
  - 1.3.8 Liste i `data frame`ovi . . . 16
- 1.4 Učitavanje i snimanje podataka u R-u . . . 18

2 Opisna statistika **22**
- 2.1 Frekvencija i relativna frekvencija podataka . . . 23
  - 2.1.1 Kvalitativni podaci . . . 24
  - 2.1.2 Tablice u R-u . . . 25
  - 2.1.3 Kvantitativni podaci . . . 27
- 2.2 Mjere središnjeg okupljanja podataka - aritmetička sredina, medijan, mod 28
  - 2.2.1 Izračun aritmetičke sredine, medijana i moda u R-u . . . 30
- 2.3 Mjere raspršenosti podataka - raspon, varijanca i standardna devijacija . . . 31
- 2.4 Percentili i kvartili . . . 36
- 2.5 Osnovna analiza i grafički prikaz podataka u R-u . . . 37
- 2.6 Koeficijent korelacije . . . 46
- 2.7 Primjeri osnovne analize podataka . . . 50
- 2.8 Sažetak poglavlja . . . 69
- 2.9 Zadaci . . . 70
  - 2.9.1 Rješenja zadataka . . . 70

3 Osnove kombinatorike i naivna definicija vjerojatnosti **73**
- 3.1 Skupovi . . . 73
  - 3.1.1 Skupovne operacije . . . 76
  - 3.1.2 Vennovi dijagrami . . . 82
  - 3.1.3 Broj elemenata skupa; kardinalni broj . . . 86
  - 3.1.4 Kartezijev produkt skupova . . . 93
- 3.2 Skup elementarnih događaja i naivna definicija vjerojatnosti . . . 96
- 3.3 Osnovne metode prebrojavanja; kombinatorika . . . 101
  - 3.3.1 Prebrojavanje skupova u kojima je poredak važan, permutacije . . . 104
  - 3.3.2 Prebrojavanje skupova u kojima poredak nije važan, kombinacije . . . 109
  - 3.3.3 Kuglice i kutije . . . 111

3.3.4 Binomni koeficijenti . . . 116
3.4 Primjeri računanja vjerojatnosti naivnom definicijom vjerojatnosti . . . 118
3.5 Primjena R-a za izračun vjerojatnosti . . . 124
3.6 Sažetak poglavlja . . . 128
3.7 Zadaci . . . 131
3.7.1 Rješenja zadataka . . . 133

4 Vjerojatnost 140
4.1 Definicija vjerojatnosti i osnovna svojstva . . . 140
4.2 Primjeri vjerojatnosti i vjerojatnosnih prostora . . . 146
4.3 Nezavisnost . . . 150
4.4 Nezavisno izvođenje slučajnih eksperimenata - produktna vjerojatnost . . . 153
4.5 Uvjetna vjerojatnost . . . 159
4.5.1 Uvjetna vjerojatnost je vjerojatnost . . . 165
4.5.2 Bayesova formula i formula potpune vjerojatnosti . . . 166
4.6 Primjena R-a za računanje (uvjetnih) vjerojatnosti . . . 172
4.7 Sažetak poglavlja . . . 177
4.8 Zadaci . . . 179
4.8.1 Rješenja zadataka . . . 181

5 Slučajne varijable i njihove razdiobe 194
5.1 Slučajne varijable . . . 194
5.2 Diskretne slučajne varijable . . . 202
5.2.1 Razdioba diskretnih slučajnih varijabli . . . 203
5.2.2 Funkcije distribucije . . . 207
5.2.3 Neke poznatije diskretne razdiobe . . . 212
5.2.3.1 Diskretna uniformna razdioba . . . 213
5.2.3.2 Bernoullijeva slučajna varijabla . . . 214
5.2.3.3 Binomna razdioba . . . 214
5.2.3.4 Geometrijska razdioba . . . 218
5.2.3.5 Hipergeometrijska razdioba . . . 219
5.2.3.6 Poissonova razdioba . . . 220
5.2.4 Nezavisne slučajne varijable . . . 221
5.3 Integrali . . . 227
5.3.1 Određeni i neodređeni integrali . . . 228
5.3.2 Računanje integrala . . . 233
5.3.3 Nepravi integral . . . 237
5.4 Neprekidne slučajne varijable . . . 239
5.4.1 Neke poznatije razdiobe neprekidnih slučajnih varijabli . . . 243
5.4.1.1 Normalna razdioba . . . 243
5.4.1.2 Eksponencijalna razdioba . . . 251
5.4.1.3 Uniformna razdioba . . . 253
5.4.1.4 Paretova razdioba . . . 258
5.4.2 Nezavisne neprekidne slučajne varijable . . . 261
5.5 Razdiobe u R-u . . . 264
5.6 Sažetak poglavlja . . . 267
5.7 Zadaci . . . 273
5.7.1 Rješenja zadataka . . . 277

6 Matematičko očekivanje i granični teoremi **294**
6.1 Matematičko očekivanje . . . 294
6.1.1 Osnovna svojstva matematičkog očekivanja . . . 297
6.1.2 Varijanca . . . 302
6.1.3 Očekivanje, indikatori i vjerojatnost . . . 309
6.1.4 Viši momenti i još neka obilježja slučajnih varijabli . . . 314
6.1.5 Kovarijanca i korelacija slučajnih varijabli . . . 321
6.2 Granični teoremi . . . 329
6.2.1 Nejednakosti . . . 329
6.2.2 Zakoni velikih brojeva . . . 333
6.2.3 Centralni granični teorem . . . 338
6.3 Primjeri u R-u . . . 347
6.4 Sažetak poglavlja . . . 350
6.5 Zadaci . . . 354
6.5.1 Rješenja zadataka . . . 356

7 Osnove statističkog zaključivanja **364**
7.1 Procjenitelji . . . 364
7.1.1 Uzorak . . . 365
7.1.2 Statistike i procjenitelji . . . 367
7.1.3 Svojstva $\bar{X}_n$ i S_n^2 za uzorke iz normalne razdiobe . . . 371
7.1.4 Empirijske funkcije distribucije . . . 373
7.2 Testiranje statističkih hipoteza . . . 376
7.2.1 Očekivanje uzorka iz normalne distribucije s poznatom varijancom 378
7.2.2 t-test . . . 385
7.3 Upareni podaci - korelacija i regresija . . . 391
7.4 Sažetak poglavlja . . . 396
7.5 Zadaci . . . 399
7.5.1 Rješenja zadataka . . . 400

Literatura **407**

Uvod

Ova skripta napravljena je za potrebe kolegija Statistika koji se predaje na drugoj godini dodiplomskih studija Informatike, Računarstva i Proizvodnog strojarstva na Sveučilištu Jurja Dobrile u Puli. Kolegij u osnovi obuhvaća gradivo koje se često predaje u formi kolegija Uvod u vjerojatnost i statistiku. Ideja kolegija je da se uvedu osnovne statističke metode kroz jezik vjerojatnosti. Takav pristup uvođenju statistike je danas uobičajen i ne treba posebno obrazlaganje.

S obzirom da se kolegij predaje na drugoj godini dodiplomskog studija te se ne predaje na studiju matematike, teorija vjerojatnosti je predstavljena bez teorije mjere. Takav odabir materijala donekle utječe na sadržaj kolegija, kao i na literaturu na koju se skripta oslanja. Naime, na hrvatskom jeziku je (i dalje) najpotpunija knjiga o vjerojatnosti ona Nikole Sarape [10], ali je njen obuhvat daleko iznad razine koja je potrebna za uvođenje osnovnih pojmova vjerojatnosti i statistike. Stoga je odabir referentne literature prilagođen razini općenitosti na kojoj se kolegij predaje. Neke od knjiga koje je autor češće koristio u pripremi ove skripte su Blitzstein, Hwang: Introduction to Probability [3] i Ross: Introduction to Probability and Statistics for Engineers and Scientists [11] na engleskom te knjiga Benšić, Šuvak: Uvod u vjerojatnost i statistiku [2] i skripta Basrak: Statistika [1] na hrvatskom jeziku. Kao reference povremeno koristimo i knjige Feller: An Introduction to Probability Theory and Its Applications [6] te Wasserman: All of statistics [15], kao i neke druge koje su navedene unutar teksta skripte.

Darko Brborović

Poglavlje 1

Alati

1.1 R i LaTeX

U ovoj skripti se koristi programski jezik R koji je prilagođen statističkim primjenama, ali je i potpuno funkcionalan programski jezik. Jasna alternativa R-u je Python te ćemo kasnije dati i primjere korištenja Pythona za analizu podataka. Inače, vodi se dosta velika debata o tome da li je R ili Python pogodniji za tzv. "data science", a neka razmišljanja o tome mogu se naći na https://www.datacamp.com/blog/python-vs-r-for-data-science-whats-the-difference

Najjednostavniji način korištenja R-a je putem integriranog okruženja koje pruža RStudio. Riječ je o open source alatima. Snaga R-a leži u podršci (akademske i korisničke) zajednice pa se najnovije statističke i vjerojatnosne metode vrlo brzo implementiraju u R-u. Napomena: R je moguće koristiti i bez RStudia u "terminalskom" obliku, ali RStudio značajno olakšava upotrebu.

Više o R-u može se naći na https://www.r-project.org/. Na toj poveznici možete naći velik broj raznih uputstava, knjiga, dokumenata - pogledajte odjeljak Documentation na Home page i, na primjer, kratku "karticu referenci" u R-u na stranici https://cran.r-project.org/doc/contrib/refcard.pdf.

Više o RStudiu može se naći na https://www.rstudio.com/, a dosta materijala koje objavljuje R zajednica može se naći na https://www.r-bloggers.com/. Dosta problema se komentira na https://stackexchange.com/ ili na https://github.com/ (nisu vezani samo uz R).

Neke knjige o R-u (besplatne):
https://cran.r-project.org/doc/contrib/Paradis-rdebuts_en.pdf
https://web.itu.edu.tr/~tokerem/The_Book_of_R.pdf
i još više na https://r-dir.com/learn/e-books.html.

U ovom poglavlju ćemo prikazati osnovne tipove podataka i funkcije koje će nam trebati da počnemo koristiti R.

Ova skripta je pisana u Latexu. LaTeXje sustav za pripremu dokumenata, a punu snagu pokazuje u znanstvenim dokumentima s velikim brojem formula (ali je i više od toga). Na primjer, formula

$$\frac{d}{dx}\left(\int_0^x f(t)dt\right)=f(x)$$

se u LaTeX-u zapisuje kao

```
\frac{d}{dx}\left( \int_{0}^{x} f(t)dt\right)=f(x).
```

Još jedan primjer niza složenih simbola

$$(\Omega_n, \mathcal{F}_n, P_n) = ([0,1]^n, \mathcal{B}([0,1]^n), \lambda^n)$$

koji se u LaTeX-u zapisuje kao:

```
(\Omega_n, \mathcal{F}_n, P_n)=([0,1]^n,\mathcal{B}([0,1]^n),\lambda^n).
```

Više o LaTeX-u može se naći na https://www.latex-project.org/. Riječ je o besplatnom alatu, kao što je to i editor za LaTeX pod nazivom TeXstudio (vidi https://www.texstudio.org/).

Skripta je pisana u LaTeX-u s time da je korišteno Sweave okruženje u RStudiju kako bi se R kod mogao i izvršavati u samom dokumentu.

1.2 Osnovno o R-u

R može služiti kao običan kalkulator. Na primjer, kada otvorite R konzolu (to možete napraviti i u RStudiju) i upišete

```
> 2+3
```

dobit ćete rezultat

```
[1] 5
```

U R-u su implementirane i brojne matematičke funkcije pa tako, na primjer,

```
> sin(0.5)^2+ cos(0.5)^2
```

daje rezultat

```
[1] 1
```

Zanimljivo je da R, u nekim tipičnim situacijama, može raditi s izrazima koji u osnovi konvergiraju u beskonačnost (mogli bi reći da su jednaki ∞ ili $-\infty$). Tako nam operacija `1/0` daje vrijednost `Inf`, ali R zna da je

```
> exp(-Inf)
```

zapravo

```
[1] 0
```

Naravno, postoje izrazi čija vrijednost nije definirana pa će tako `Inf-Inf` dati vrijednost `NaN` ("not a number"*"). Da li treba napominjati da R prepoznaje i π:

```
> print(pi, digits=10)
```

```
[1] 3.141592654
```

Gornji primjer pokazuje da se funkcijom `print` mogu ispisati vrijednosti varijabli (ili konstante π u ovom slučaju). Kao i puno drugih funkcija u R-u tako i `print` ima dodatne opcije, a među njima je i broj znamenki koje želimo prikazati. U gornjem primjeru je to 10 znamenki. R u osnovi ima dobru `help` funkciju pa pomoću `help(print)` možete dobiti više detalja o argumentima funkcije `print` kao i neke osnovne primjere. Naravno, isto je dostupno i za druge funkcije u R-u.

Iako R može služiti kao kalkulator jasno je da se njegov potencijal, kao i kod drugih programskih jezika, može iskoristiti uvođenjem varijabli. Dodjeljivanje vrijednosti varijablama obavlja se pomoću `<-` pa tako varijabli x možemo dodijeliti vrijednost $\pi + 1$ na sljedeći način

```
> x<-pi+1
> print(x)

[1] 4.141593
```

Jasno, vrijednost varijable x je $4,141593$.

1.3 Podaci u R-u

Svi objektu u R-u imaju dva osnovna opisna svojstva: `mode` i `length` (s pripadnim istoimenim funkcijama). Postoje četiri osnovna tipa podataka koji mogu biti elementi objekata u R-u, a koje opisuje `mode`: `logical`, `numeric`, `complex` i `character`. Dosta je samorazumljivo što svaki od osnovnih tipova podataka znači, ali pogledajmo nekoliko primjera. Definirajmo najprije nekoliko varijabli:

```
> num1<-2
> num2<-2.5
> kompl<-num1+2i
```

Funkcijom `mode()` ispitujemo osnovni tip gore definiranih varijabli. Dobijemo

```
> mode(num1); mode(num2); mode(kompl)

[1] "numeric"

[1] "numeric"

[1] "complex"
```

Uočimo da funkcija `mode` ne razlikuje cjelobrojne od necjelobrojnih brojeva (vidjet ćemo malo kasnije da postoje i klase podataka). Znakovne varijable (`character`) definiramo tako da pod navodnicima napišemo niz znakova koje želimo pridružiti nekoj varijabli. Na primjer

```
> rijec<-"abc"
> print(rijec); mode(rijec)

[1] "abc"

[1] "character"
```

Kao i drugim jezicima, logičke vrijednosti se dobivaju, recimo, usporedbom vrijednosti varijabli poput

```
> mode(num1>num2)

[1] "logical"
```

pri čemu je vrijednost izraza `num1>num2` neistinita jer 2 nije veći od 2.5

```
> num1>num2

[1] FALSE
```

Jasno, mogu se i eksplicitno definirati logičke varijable

```
> log1<-T
> log2<-TRUE
> log3<-F
> mode(log1)

[1] "logical"

> mode(log2)

[1] "logical"

> mode(log3)

[1] "logical"
```

Zanimljivo je da se logičke varijable mogu i zbrajati, što nije sukladno logičkim pravilima, pa tako dobijemo

```
> print(log1+log2)

[1] 2
```

To je moguće jer se vrijednosti `TRUE` i `FALSE` spremaju kao 1 i 0. Naravno, u R-u su definirani i "pravi" logički operatori pa se logičko `ILI` označava s `|` (uspravna crta), logičko `I` s `&`, a logička negacija s `!`. Za prije definirane logičke varijable imamo

```
> print(log1 | log3)

[1] TRUE

> print(log1 & log3)

[1] FALSE

> print(!log1)

[1] FALSE
```

Uočimo da je duljina svih varijabli koje smo do sada susreli jednaka 1 što se lagano provjeri funkcijom `length()`. Varijable, i općenito objekti, čija je duljina veća od 1 mogu se dobiti na različite načine, a jedan od najpopularniji je korištenjem funkcije `c` u R-u. Njome dobivamo vektore. Na primjer,

```
> vekt<-c(num1, num2)
> mode(vekt)

[1] "numeric"

> length(vekt)

[1] 2
```

Vrijednost varijable `vekt` je dvodimenzionalni numerički vektor s elementima 2 i 2.5. R će nam to predstaviti kao

```
[1] 2.0 2.5
```

Vektori su samo jedan od tipova podataka, mogli bi reći i struktura podataka, u R-u. Njihov `mode` (osnovni tip) može biti bilo koji od prije navedenih osnovnih tipova podataka, a isti je slučaj i s poljima (`array`) i matricama (`matrix`). U slučaju ta tri tipa podataka treba uočiti da se oni mogu sastojati samo od istog osnosvnog tipa podataka (dakle, ili samo `numeric` ili samo `character` itd.), dok su tipovi podataka koji podržavaju mješovite osnovne tipove podataka liste (`list`) i `data frame`. Pogledajmo neke primjere.

1.3.1 Funkcija `c()` i vektori

Osnovne podatke o funkciji `c` u R-u, kao što smo već prije napomenuli, možete naći tako da napišete `help(c)`. Ukoliko koristite RStudio, u desnom prozoru će vam se otvoriti prozor s opisom funkcije, njezinim argumentima i nekim osnovnim primjerima. Ta se funkcija često koriti kako bi se brzo napravili neki vektori poput

```
> prviv<-c(2,2,2,2)
> drugiv<-c(1:8)
```

Elementi tih vetora su, redom,

```
[1] 2 2 2 2
```

```
[1] 1 2 3 4 5 6 7 8
```

Prvi vektor je duljine 4, dok je drugi duljine 8. Uočimo da smo za vektor `drugiv` iskoristili mogućnost koju nam pruža R da generiramo sve elemente između `n` i `m` navođenjem naredbe `n:m`. To se može iskoristiti čak i kada je `m` veći od `n`. Na primjer, `treciv<-c(8:5)` kreira vektor duljine 4, čiji su elementi

```
[1] 8 7 6 5
```

Operacije s vektorima, odnosno funkcije koje djeluju na vektore, se u R-u izvršavaju tako da se primjenjuju na elemente vektora. Na primjer,

```
> zbrojv<-prviv + treciv
> zbrojv
```

```
[1] 10  9  8  7
```

```
> incrv<-drugiv+1
> incrv
```

```
[1] 2 3 4 5 6 7 8 9
```

```
> reciprv<-1/prviv
> reciprv
```

```
[1] 0.5 0.5 0.5 0.5
```

Uočimo da će R zbrojiti i vektore koji nisu jednake duljine i to tako da "reciklira" kraći vektor, odnosno da nakon kraja kraćeg vektora započne novi niz elemenata tog vetora. Tako tako će zbroj vektora `drugiv` i `treciv` dati rezultat

```
[1]  9  9  9  9 13 13 13 13
```

1.3.2 Pristup elementima vektora

Elementima vektora se pristupa tako da se nakon imena vektora navede mjesto u vektoru kojemu želimo pristupiti u uglatim zagradama. Na primjer, treći element vektora `drugiv` je broj tri, kojemu pristupamo na sljedeći način

```
> drugiv[3]
```

```
[1] 3
```

Slično, prvom elementu vektora `treciv`, koje je jednak 8, pristupamo na sljedeći način

```
> treciv[1]

[1] 8
```

Pristup elementima vektora nije ograničen samo na navođenje pojedinačnih članova. Naime, može se pristupiti i nekim uzastopnim članovima koristeći već navedenu mogućnost korištenja `n:m`. Tako možemo dobiti zadnja četiri elementa vektora `drugiv` navodeći `drugiv[5:8]` da dobijemo

```
[1] 5 6 7 8
```

Korištenjem funkcije `c` može se pristupiti, na primjer, samo trećem i petom elementu vektora `drugiv`:

```
> print(drugiv[c(3,5)])

[1] 3 5
```

Uočimo da je u gornjem primjeru poredak važan jer će nam `drugiv[c(5,3)]` kao rezultat dati

```
[1] 5 3
```

Može se koristiti i negativna vrijednost indeksa pri čemu R prepoznaje da na taj način želimo ukloniti element vektora čiji smo indeks naveli. Na primjer, ukoliko želimo ukloniti treći člana vektora `drugiv` napisat ćemo `drugiv[-3]` i kao rezultat ćemo dobiti

```
[1] 1 2 4 5 6 7 8
```

Ni tu nije kraj s mogućnošću izdvajanja elemenata vektora (a zapravo i drugih složenijih tipova podataka u R-u). Naime, u R-u je lagao izdvojiti sve elemente vektora koji su veći, jednaki, različiti i slično od neke vrijednosti. Na primjer, sve elemente vektora `treciv` koji su veći ili jednaki od 6 dobivamo tako da u uglatim zagradama navedemo uvjet `treciv>=6`. Dobivamo

```
> treciv[treciv>=6]

[1] 8 7 6
```

To nije naročito korisno kod malih vektora, ali je jasno da je kod velikih vektora, ili drugih struktura podataka, korisno na brz način izdvojiti elelmente koji zadovoljavaju neki uvjet.

1.3.3 Još neki načini stvaranja vektora: funkcije `rep()` i `seq()`

Vidjeli smo da je jedan način za kreiranje vektora korištenje funkcije `c`. Numeričke vektore je moguće stvoriti i korištenjem funkcija `rep()` i `seq()`. Funkcija `rep` samo ponavlja zadanu vrijednost određeni broj puta. Tako smo vektor `prviv` mogli napraviti i ovako

```
> prviv2<-rep(2, times=4)
> prviv2

[1] 2 2 2 2
```

Funkcija `seq` generira niz brojeva od `n` do `m` s time da je moguće definirati i korak za koji se mijenja sljedeći član. Tako, na primjer, možemo generirati prvih 5 parnih brojeva

```
> par5<-seq(2, 10, by=2)
> par5

[1]  2  4  6  8 10
```

ili brojeve između 0 i 1 razmaknute za 0,1

```
> niz01<-seq(0, 1, by=0.1)
> niz01

 [1] 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
```

Kao i kod drugih funkcija, moguće su još neke opcije za funkciju `seq`. Na primjer, možemo zadati i koliko vrijednosti želimo da niz sadrži između brojeva `n` i `m`. Konkretno, ako želimo između 0 i 9 ubaciti 6 brojeva (uključujući nulu i devetku) možemo upotrijebiti parametar 'length.out'

```
> niz09<-seq(0, 9, length.out=6)
> niz09

[1] 0.0 1.8 3.6 5.4 7.2 9.0
```

1.3.4 Nenumerički vektori, još neke funkcije

Naravno, vektori mogu biti i drugog tipa od `numeric`, a za njihovo kreiranje opet možemo iskoristiti funkciju `c` kao što se vidi niže

```
> ime<-c("Iva", "Ana", "Marko")
> ime

[1] "Iva"   "Ana"   "Marko"

> mode(ime)

[1] "character"

> length(ime)

[1] 3
```

Opet, elementima vektora `ime` pristupamo tako da navedeno u uglatim zagradama element vektora kojem želimo pristupiti. Stoga će nam `ime[1]` vratiti vrijednost

```
[1] "Iva"
```

Ako želimo dodati jedan element već postojećem vektoru to možemo napraviti funkcijom `append()`. Na primjer, vektoru `ime` možemo dodati ime Ivica na sljedeći način

```
> ime2<-append(ime, "Ivica")
> print(ime2)

[1] "Iva"   "Ana"   "Marko" "Ivica"
```

Uočimo da smo to mogli napraviti i korištenjem funkcije `c`

```
> ime3<-c(ime, "Ivica")
> print(ime3)

[1] "Iva"   "Ana"   "Marko" "Ivica"
```

ali nam funkcija `append` omogućava veću fleksibilnost. Naime, njenim korištenjem možemo dodati novi element u postojeći vektor iza željenog elementa. Tako u vektor `ime` možemo dodati element na drugo mjesto

```
> ime2<-append(ime, "Ivica", after=1)
> print(ime2)

[1] "Iva"   "Ivica" "Ana"   "Marko"
```

Korištenje funkcije `append` nije ograničeno na vektore koji sadrže znakove (`character`). Tako u vektor `prviv` možemo dodati broj 5 na treće mjesto

```
> cetvrtiv<-append(prviv, 5, after=2)
> print(cetvrtiv)

[1] 2 2 5 2 2
```

Ovo je kratki pregled osnovnih funkcionalnosti R-a pa na ovom mjestu nećemo previše širiti temu manipuliranja s vektorima, ali ćemo napomenuti da se na vektore mogu primijeniti i neke skupovne funkcije. Tako, na primjer, funkcija `intersect()` daje zajedničke elemente dva vektora, dok funkcija `setdiff()` daje elemente jednog vektora koji nisu u drugom. Tako imamo

```
> print(intersect(ime, ime2))

[1] "Iva"   "Ana"   "Marko"

> print(setdiff(ime2, ime))

[1] "Ivica"

> print(setdiff(drugiv, treciv))

[1] 1 2 3 4
```

1.3.5 Funkcija `which()`

U R-u je, naravno, moguće odrediti na kojim se mjestima unutar vektora nalaze elementi koji zadovoljavaju određeni uvjet i to korištenjem funkcije `which()`. Tako ćemo saznati na kojim se mjestima vektora `treciv` nalaze elementi koji su veći ili jednaki od 6 na sljedeći način

```
> which(treciv>=6)

[1] 1 2 3
```

Uočite da je argument funkcije `which` vektor s logičkim vrijednostima. To lagano provjerimo

```
> treciv>=6
```

```
[1]  TRUE  TRUE  TRUE FALSE
```

Funkcija `which` ima i dvije ekstenzije `which.min` i `which.max`. Tako možemo odrediti najmanji element vektora `treciv` kao i mjesto na kojem se element s najmanjom vrijednosti nalazi, odnosno njegov indeks:

```
> min(treciv)

[1] 5

> which.min(treciv)

[1] 4
```

Kombinacijom pristupa elementima vektora te korištenjem funkcije `which` možemo odrediti, na primjer, koji su sve elementi vektora `ime` različiti od imena Iva (koristimo operator `!=`) te koji je indeks (na kojem se mjestu nalazi) element vektora `ime` koji sadrži ime Marko. Provjera jednakosti dvaju objekata obavlja se korištenjem operatora `==`. Imamo

```
> ime[ime!="Iva"]

[1] "Ana"   "Marko"

> which(ime=="Marko")

[1] 3
```

Vrijedi još napomenuti da se elementima vektora mogu dati i nazivi. Na primjer, elemente vektora `ime` možemo nazvati prvi, drugi i treći na sljedeći način:

```
> names(ime)=c("prvi", "drugi", "treci")
```

pa se prilikom ispisa elemenata vektora `ime` dobiva

```
   prvi   drugi   treci
  "Iva"   "Ana" "Marko"
```

Sada se, primjerice, drugom elementu vektora `ime` može pristupiti preko njegovog indeksa

```
> ime[2]

drugi
"Ana"
```

ili preko imena

```
> ime["drugi"]

drugi
"Ana"
```

Primjer 1.3.1. U R-u se operator koji kao rezultat daje ostatak pri dijeljenju dva cijela broja označava s %%. Kako bismo našli sve elemente vektora `drugiv` koji su parni?

Rješenje tog problema se, naravno, oslanja na činjenicu da je ostatak pri dijeljenju parnih brojeva s 2 jednak nuli. Stoga možemo provjeriti koji od elemenata vektora `drugiv` imaju ostatak pri dijeljenju s 2 jednak nuli. Prema prijašnjim napomenama imamo

```
> drugiv[drugiv%% 2==0]

[1] 2 4 6 8
```

Kako biste našli mjesta u vektoru `drugiv` na kojima se nalaze neparni brojevi? (Iskoristite funkciju `which`.) □

1.3.6 Funkcija `typeof()`

Prije u tekstu smo naveli da funkcija `mode` kao vrijednost daje jedan od osnovnih tipova podatka, među kojima je i `numeric`. Naravno, R razlikuje cjelobrojne od realnih brojeva. Funkcija `typeof` kao vrijednost vraća način na koji R pohranjuje određeni objekt. Ukoliko se iza broja stavi 'L', R će taj broj prepoznati kao cjelobrojni. Tako za varijable

```
> cjel<-42L
> doubt<-42
> real<-12.65
```

možemo lagano provjeriti da je njihov `mode` zapravo `numeric`, ali je

```
> typeof(cjel)

[1] "integer"

> typeof(doubt)

[1] "double"

> typeof(real)

[1] "double"
```

Drugi način da se broj pohrani kao cjelobrojni je da se koristi funkcija `as.integer`. Tako imamo

```
> cjel2<-as.integer(12)
> typeof(cjel2)

[1] "integer"
```

Vrijednosti funkcije `typeof` su raznovrsne, a potpuniji popis se može naći u R dokumentaciji na, na primjer, https://www.rdocumentation.org/packages/base/versions/3.6.2/topics/typeof.

Bez želje za zbunjivanjem napomenut ćemo da u R-u postoji i funkcija `class()` koja je fleksibilnija od funkcije `mode`, a važna je karakteristika R-a, o kojoj nećemo ovdje govoriti, da korisnik sam može definirati vrijednost funkcije `class`. Zainteresirani čitatelj može naći više detalja u R dokumentaciji koju smo već spominjali.

1.3.7 Matrice

Matrice u R-u tipično možemo kreirati funkcijom `matrix` kao što je navedeno u donjem primjeru

```
> A<-matrix(c(1:6), nrow=2, ncol=3, byrow=TRUE)
```

Tako dobijemo matricu

```
     [,1] [,2] [,3]
[1,]    1    2    3
[2,]    4    5    6
```

Argumenti funkcije `matrix` su `nrow`, odnosno broj redaka i `ncol`, odnosno broj stupaca te, jasno, sami elementi matrice (u ovom slučaju brojevi od 1 do 6). U gornjem primjeru je definirano `byrow=TRUE` što znači da se matrica "puni" po recima. Ukoliko izostavimo taj argument R će koristiti predefiniranu vrijednost `byrow=FALSE` što će uzrokovati "punjenje" matrice po stupcima. U tom slučaju dobivamo matricu

```
     [,1] [,2] [,3]
[1,]    1    3    5
[2,]    2    4    6
```

S obzirom da su matrice dvodimenzionalni objekti, njihovim elementima pristupamo tako da navedemo u uglatim zagradama mjesto u retku i stupcu na kojoj se element nalazi. Tako ćemo dobiti da se na trećem mjestu u prvom retku nalazi element 3 jer je

```
> A[1,3]

[1] 3
```

Uočimo da možemo pristupiti i cijelom prvom retku

```
> A[1,]

[1] 1 2 3
```

ili cijelom trećem stupcu

```
> A[,3]

[1] 3 6
```

Kao i kod vektora, možemo pristupati elementima matrice i na složenije načine. Tako drugi i treći stupac možemo izdvojiti s `A[ ,c(2,3)]` i dobiti

```
     [,1] [,2]
[1,]    2    3
[2,]    5    6
```

ili pak možemo izdvojiti sve elemente matrice `A` koji su veći ili jednaki od 3 pomoću `A[A>=3]`. Dobivamo

```
[1] 4 5 3 6
```

Kada primijenim funkciju `mode` na varijablu `A` dobit ćemo vrijednost `numeric`. S druge strane imamo

```
> typeof(A)

[1] "integer"

> class(A)

[1] "matrix" "array"
```

Možemo uočiti da su matrice zapravo specijalni slučajevi tipa podataka `array`, koji mogu imati više od dvije dimenzije (dakle, ne samo stupce i retke, nego i dodatne "smjerove"). Kako svaki objekt u R-u, kao što smo rekli na početku, ima duljinu vidimo da primjenom funkcije `length(A)` dobivamo vrijednost 6. Jasno, kod matrica je relevantna i dimenzija matrice, u matematičkom smislu, pa možemo provjeriti da je dimenzija od `A` jednaka

```
> dim(A)

[1] 2 3
```

S obzirom da R prema osnovnim postavkama obavlja sve operacije na razini elemenata dodavanjem broja matrici, na primjer, zapravo dodajemo broj svakom elementu matrice. Tako će nam operacija `A+2` rezultirati matricom

```
     [,1] [,2] [,3]
[1,]    3    4    5
[2,]    6    7    8
```

dok će operacija `A*3` dati matricu

```
     [,1] [,2] [,3]
[1,]    3    6    9
[2,]   12   15   18
```

Naravno, R podržava i "obično" množenje matrica pomoću operatora `%*%` pa će tako umnožak matrice `A` i transponirane matrice od `A`, koju izračunamo pomoću `t(A)`, dati novu matricu koja je jednak produktu te dvije matrice

```
> A%*%t(A)
```

```
     [,1] [,2]
[1,]   14   32
[2,]   32   77
```

Podsjetite se računa s matricama ako imate dvojbe oko dimenzije produkta te dvije matrice ili njenih elemenata koje, za vježbu, možete izračunati "na ruke".

1.3.8 Liste i `data frameovi`

Liste su vrlo općeniti tipovi podataka u R-u koje se mogu sastojati od raznih podataka sastavljenih od osnovnih tipova podataka. Na primjer, uz već prije definirane varijable, definiramo i jednu logičku

```
> logi<-c(T,T,F,F,T)
```

Formirajmo za početak listu

```
> lista<-c(treciv, ime)
```

koju R prikazuje kao

```
                                  prvi   drugi   treci
    "8"     "7"     "6"     "5"   "Iva"   "Ana" "Marko"
```

Ukoliko želimo maknuti nazive vektora `ime` dovoljno je učiniti sljedeće

```
> names(lista)=c()
> lista
```

```
[1] "8"     "7"     "6"     "5"     "Iva"   "Ana"   "Marko"
```

Sada tu listu možemo proširiti s vektorom `logi` da dobijemo

```
> lista<-c(lista, logi)
> lista
```

```
 [1] "8"     "7"     "6"     "5"     "Iva"   "Ana"   "Marko" "TRUE"  "TRUE"
[10] "FALSE" "FALSE" "TRUE"
```

Liste su u osnovi liste vektora (vektor vektora) različite duljine. Ukoliko definiramo listu u kojoj svi vektori imaju istu duljinu dobivamo `data frame` s kojima ćemo uglavnom raditi. Data frameovi se zapravo koriste za pohranu tabličnih podataka. Kao primjer možemo uzeti već postojeći vektor `ime`, ukloniti nazive elemenata i napraviti novi `dob`

```
> dob<-c(21,25,22)
```

te definirati data frame `pod`

```
> names(ime)<-c()
> pod<-data.frame(ime, dob)
```

Tako dobivamo

```
    ime dob
1   Iva  21
2   Ana  25
3 Marko  22
```

Varijabla `pod` je tipa `data frame`, a R je u osnovi tretira kao listu što vidimo pomoću

```
> class(pod)

[1] "data.frame"

> typeof(pod)

[1] "list"
```

Možemo uočiti da nam gornji podaci nisu previše informativni, ali zato možemo iskoristiti funkciju `str()` koja će dati detaljniji opis interne strukture objekata u R-u pa tako i našeg `pod`. Imamo

```
> str(pod)

'data.frame':        3 obs. of  2 variables:
 $ ime: chr  "Iva" "Ana" "Marko"
 $ dob: num  21 25 22
```

Data frameove možemo lagano proširivati. Tako u `pod` možemo dodati i visinu svake od osoba čija su imena navedena u vektoru `ime`

```
> vis<-c(165, 172, 180)
```

te dobiti

```
> pod<-data.frame(pod, vis)
> pod

    ime dob vis
1   Iva  21 165
2   Ana  25 172
3 Marko  22 180
```

Pomoću `str` možemo provjeriti novu strukturu tako dobivenog data framea

```
'data.frame':        3 obs. of  3 variables:
 $ ime: chr  "Iva" "Ana" "Marko"
 $ dob: num  21 25 22
 $ vis: num  165 172 180
```

Uočimo da su data frameovi dvodimenzionalni objekti, a pristup njihovim elementima je sličan kao kod matrica. Na primjer, prvom retku data framea pod možemo pristupiti na sljedeći način

```
> pod[1,]

  ime dob vis
1 Iva  21 165
```

dok trećem stupcu možemo pristupiti ovako

```
> pod[,3]

[1] 165 172 180
```

Mala specifičnost data frameova je ta da se stupcima može pristupiti tako da nakon imena data framea stavimo znak $ te naziv stupca kojemu želimo pristupiti. Tako možemo pristupiti trećem stupcu i na sljedeći način

```
> pod$vis

[1] 165 172 180
```

Vratit ćemo se kasnije data frameovima, a za sada ćemo završiti s ovim pregledom tipova podataka u R-u.

1.4 Učitavanje i snimanje podataka u R-u

R učitava i snima podatke (datoteke) u tzv. radnom direktoriju (working directory). Ukoliko niste sigurni koji je trenutno definiran radni direktorij to možete provjeriti funkcijom `getwd()`, dok promjenu radnog direktorija obavljamo funkcijom `setwd()`. Na primjer,

```
> setwd("C:/Sveuciliste-Pula/Skripta")
```

Sada je "C:\Sveuciliste-Pula\Skripta" radni direktorij (uočite da u R kodu trebate staviti znak /, a ne \). To možemo i provjeriti

```
> getwd()

[1] "C:/Sveuciliste-Pula/Skripta"
```

R ima velik broj načina učitavanja različitih formata datoteka, odnosno podataka. Tako je moguće čitati Excel fileove poput ovoga na slici

Za učitavanje Excel datoteka možemo upotrijebiti funkciju `read.xlsx`. Uočimo da ona zahtjeva učitavanje nekoliko R paketa, ali R će nas upozoriti na to prilikom izvršavanja dijela koda koji koristi tu funkciju. Naravno, možemo U R terminal upisati `help("read.xlsx")` i saznati detalje o toj funkciji. U ovom slučaju nam trebaju sljedeći R paketi

Ime	Tezina	Visina
A	60	165
B	80	180
C	85	175
D	84	184
E	62	168
F	65	175
G	86	184
H	86	192
I	95	182
J	78	178
K	70	175
L	68	170

Slika 1.1: Primjer Excel filea čije ćemo podatke učitati u R.

```
> library("rJava")
> library("xlsx")
> library("xlsxjars")
```

Uočimo da su ti paketi već bili instalirani na ovom računalu, a da nisu bili instalirani iskoristili bi funkciju `install.packages("package-name")`. Sada ćemo varijabli `podaci` pridružiti sadržaj Excel filea BMI u kojem su snimljeni gore prikazani podaci.

```
> podaci<-read.xlsx("BMI.xlsx", sheetName="Prva", header=T, endRow=13)
```

Funkcija `read.xlsx` učitava podatke kao `data frame` u što se možemo uvjeriti pomoću `class(podaci)`. Više podataka o varijabli podaci možemo dobiti pomoću `str(podaci)`. Konkretno, dobivamo sljedeći opis podataka

```
'data.frame':        12 obs. of  3 variables:
 $ Ime   : chr  "A" "B" "C" "D" ...
 $ Tezina: num  60 80 85 84 62 65 86 86 95 78 ...
 $ Visina: num  165 180 175 184 168 175 184 192 182 178 ...
```

Naravno, možemo pogledati i same podatke

```
> podaci
```

```
   Ime Tezina Visina
1    A     60    165
2    B     80    180
3    C     85    175
4    D     84    184
5    E     62    168
6    F     65    175
7    G     86    184
8    H     86    192
9    I     95    182
10   J     78    178
11   K     70    175
12   L     68    170
```

Vidimo da data frame `podaci` sadrži 3 niza (vektora) s po 12 podataka u svakome. Argument `header=T` u funkciji `read.xlsx` je učitao i nazive vektora. To nam je korisno jer sada možemo preko tih imena pristupiti pojedinim stupcima podataka koje smo učitali iz dane Excelice. Na primjer, podatke o visini dobijemo na sljedeći način

```
> podaci$Visina

 [1] 165 180 175 184 168 175 184 192 182 178 175 170
```

Uočimo da je `podaci$Visina` vektor. Kao što smo već vidjeli, pojedinačnim podacima tog vektora pristupamo tako da u uglatim zagradama napišemo mjesto (indeks) kojem želimo pristupiti. Tako možemo provjeriti koji se podatak nalazi na trećem mjestu vektora `Visina` ili na petom mjestu vektora `Ime`. Dobivamo

```
> podaci$Visina[3]

[1] 175

> podaci$Ime[5]

[1] "E"
```

Kako opet radimo s vektorima možemo pimijeniti sve što smo prije naučili o vektorima. Tako možemo izdvojiti koje su sve osobe manje ili jednake 180 cm po visini

```
> podaci$Visina[podaci$Visina<=180]

[1] 165 180 175 168 175 178 175 170
```

odrediti koliko ih ima

```
> length(podaci$Visina[podaci$Visina<=180])

[1] 8
```

ili na kojim se mjestima (u kojim redovima) nalaze

```
> which(podaci$Visina<=180)

[1]  1  2  3  5  6 10 11 12
```

S obzirom da naša varijabla `podaci` sadrži podatke o težini i visini određenih osoba, možemo odrediti njihove BMI-jeve, odnosno indekse tjelesne mase. Oni se računaju tako da se težina osobe podijeli s kvadratom visine osoba izraženim u metrima. Definirajmo novi vektor koji će sadržavati podatke o BMI-ju svake od osoba

```
> BMI<-podaci$Tezina/(podaci$Visina/100)^2
```

a zatim proširimo data frame podaci s tim vektorom

```
> podaci<-data.frame(podaci, BMI)
```

Sada data frame `podaci` sadržava četiri vektora duline 12, kao što se i sami možemo uvjeriti

```
   Ime Tezina Visina      BMI
1    A     60    165 22.03857
2    B     80    180 24.69136
3    C     85    175 27.75510
4    D     84    184 24.81096
5    E     62    168 21.96712
6    F     65    175 21.22449
7    G     86    184 25.40170
8    H     86    192 23.32899
9    I     95    182 28.68011
10   J     78    178 24.61810
11   K     70    175 22.85714
12   L     68    170 23.52941
```

Ukoliko želimo za kasnije pohraniti podatke, to možemo opet napraviti tako da ih snimimo u Excel tablicu i to funkcijom `write.xlsx`

```
> write.xlsx(podaci, "BMI2.xlsx", sheetName="Druga", col.names = TRUE)
```

Mogli smo podatke snimiti i u prvi file BMI, ali postoji mogućnost da bi "pregazili" prethodno postojeće podatke pa smo prikazali način da se podaci snime u jednu drugu Excel tablicu. Naravno, R može čitati i razne druge formate datoteka, poput `.csv` i to funkcijom `read.csv`, ali i HTML tablice. Učitavanje podataka u raznim formatima je tema za sebe, a nama će biti dovoljne osnovne funkcije kako bismo učitali podatke koji će nam trebati u nastavku.

Poglavlje 2

Opisna statistika

Opisna statistika, često se naziva i **deskriptivnom statistikom**, je dio statistike koji se bavi organizacijom određenih (prikupljenih) podataka i njihovim sažetim opisom numeričkim i grafičkim metodama, odnosno prikazima. Podatke dobivamo mjerenjem ili bilježenjem nekih svojstava jedinki koji čine populaciju. U terminima skupova, jedinke su elementi nekog većeg skupa (populacije). Primjeri populacija mogu biti svi ljudi na Zemlji ili sve zvijezde u Svemiru. Često su populacije o kojima želimo nešto reći ili zaključiti prevelike da bismo mogli analizirati sve jedinke. Stoga je uobičajeno odabrati neki manji podskup populacije i na njemu obaviti određena mjerenja ili opažanja. Taj manji podskup populacije se u statistici zove **uzorak**. Mjerenjima koje obavljamo na uzorcima, ili nekim drugim opažanjima uzorka, dobivamo podatke.

U okviru dijela statistike (kao znanosti) koji nazivamo opisnom statistikom pokušavamo analizirati i prezentirati podatke koje prikupljamo. Velik dio statistike bavi se **statističkim zaključivanjem** (eng. *statistical inference*) kojim pokušavamo izvesti određene zaključke o cijeloj populaciji na osnovi podataka koje smo dobili analizom uzorka iz te populacije. Da bi se razvila teorija statističkog zaključivanja potrebno je najprije uvesti koncepte iz teorije vjerojatnosti, što ćemo učiniti u kasnijim poglavljima. Vidjet ćemo da se podaci koje prikupljamo mogu smatrati realizacijama nekih (slučajnih) varijabli. U tom smislu se i sama mjerenja, odnosno opažanja o uzorku populacije koji promatramo, nazivaju varijable.

Podaci, odnosno varijable, koje analiziramo mogu biti različitog tipa, ali najčešće su to numerički i znakovni podaci. U statističkim terminima se govori o **kvantitativnim** i **kvalitativnim** (kategorijalnim) podacima, odnosno varijablama. Primjeri kvantitativnih podataka su visina, težina, broj bodova na ispitu, temperatura mora i slično, dok su primjeri kvalitativnih podataka spol, boja očiju, model automobila i tako dalje. Kvantitativne varijable (podatke) možemo dodatno podijeliti na diskretne i neprekidne. Diskretne varijable su one koji imaju jasno određen skup moguDćih vrijednosti koji je konačan ili prebrojiv.[1] Primjeri takvih podataka bi bili broj riba na određenom području, broj sunčanih dana u godini u nekom gradu ili broj neispravnih proizvoda (iz nekog većeg skupa proizvoda). Neprekidne varijable mogu imati skup vrijednosti koji je neprebrojiv, odnosno takav da se preciznijim mjerenjima uzorka mogu dobiti dodatne informacije o uzorku. Primjeri su visina ljudi (možemo ju mjeriti u centimetrima, milimetrima,...), temperatura mora ili brzina kretanja nekog tijela. Numeričke podatke koji su realizacije nekih varijabli, a s obzirom na skup mogućih vrijednosti tih varijabli, možemo zvati diskretnim i neprekidnim podacima.

Ponekad autori znaju razlikovati i **ordinalne** podatke, to jest one kod kojih postoji uređaj (zna se koji je podatak veći, a koji je manji). Primjer takvih podataka bi bio

[1] U sljedećem poglavlju ćemo se malo detaljnije osvrnuti na pojmove prebrojivog i neprebrojivog skupa.

stupanj obrazovanja (NSS, SSS, VSS,...). Naravno, velik broj prikupljenih podatka je zapravo složenog tipa, odnosno sastoji se od podataka različitog tipa. Tipična reprezentacija takvih podatka u R-u se obavlja putem data frameova (ponekad se nazivaju podatkovnim okvirima).

Važan dio statistike se tiče i procesa prikupljanja podataka, odnosno **dizajna eksperimenta (pokusa)** kojim prikupljamo podatke (eng. *experimental design*). O tome u ovoj skripti nećemo previše govoriti. Napomenimo da je jedna od središnjih tema u dizajnu procesa prikupljanja podataka reprezentativnost uzorka. Naime, da bismo mogli analizom značajki nekog uzorka donijeti zaključke o cijeloj populaciji, želimo da nam odabrani uzorak iz populacije dobro reprezentira značajke cijele populacije, odnosno da je reprezentativan. Zanimljivo je da se slučajnim odabirom uzorka iz populacije dobivaju u velikoj mjeri reprezentativni uzorci.

O čemu se tu govori? Recimo da želimo izračunati prosječnu visinu ljudi na Zemlji. Naravno, nije ideja da izmjerimo visinu svakog čovjeka, nego da odaberemo uzorak iz populacije svih ljudi i onda izmjerimo njihovu visinu. Nadamo se da bi tako dobiveni broj mogao biti blizak prosječnoj visini cijele populacije (zašto bi to mogla biti istina je predmet statističkog zaključivanja). No da bi to moglo biti tako, odabrani uzorak ljudi treba biti reprezentativan za cijelu populaciju ljudi. Jasno je da uzorci ljudi iz, na primjer, Nizozemske ili iz jugoistočne Azije nisu reprezentativni za cijelu populaciju ljudi i da će odabir takvih uzoraka utjecati na dobivene rezultate mjerenja te na lošiju procjenu prosječne visine cijele populacije ljudi.

Ima još dosta problema vezanih uz dizajn eksperimenta (pokusa) kojim se prikupljaju podaci, ali to nam nije tema od središnjeg interesa u ovoj skripti pa ju nećemo detaljnije obrađivati.

2.1 Frekvencija i relativna frekvencija podataka

Za osnovni prikaz podataka u statistici se koriste **tablice frekvencija**, odnosno relativnih frekvencija, kao i odgovarajući grafovi. Malo preciznije, neka je

$$x_1, x_2, \ldots, x_n, \quad n \in \mathbb{N}$$

neki niz podataka. Među njima može biti i podataka s istim vrijednostima (naravno, mogu biti i svi različiti). Označimo s

$$y_1, y_2, \ldots y_k, \quad k \in \mathbb{N},\ k \leq n$$

sve različite vrijednosti niza podataka (x_i). Tada broj pojavljivanja podatka y_i, $i \in \{1, 2, \ldots, k\}$, nazivamo **frekvencijom podatka** y_i i označavamo s f_i. Dakle, uz definiciju

$$f_i - \text{broj pojavljivanja (frekvencija) vrijednosti } y_i,\ i \in \{1, 2, \ldots, k\}.$$

možemo formirati tablicu u kojoj se uz vrijednosti podataka y_i nalazi i njihova frekvencija f_i. Takva tablica se naziva tablica frekvencija.

Često je značajno izračunati i udio pojavljivanja pojedine vrijednosti u ukupnom broju podatka koji se promatra. Tada definiramo niz vrijednosti (manjih ili jednakih od 1)

$$f_i' = f_i/n - \text{relativna frekvencija vrijednosti } y_i,\ i \in \{1, 2, \ldots, k\}.$$

Opet se može sastaviti tablica u kojoj se uz vrijednosti podataka y_i nalazi i njihova **relativna frekvencija** f_i'. Takva tablica se naziva tablica relativnih frekvencija. Uobičajeno se podaci iz takvih tablica prikazuju histogramima, odnosno stupčastim grafovima, iako se mogu koristiti i drugi tipovi grafova. U nastavku navodimo nekoliko primjera da razjasnimo pojmove koje smo upravo uveli.

2.1.1 Kvalitativni podaci

U tablici 2.1 su prikupljeni podaci o krvnoj grupi za deset osoba različitog spola.

Ime (ID)	Spol	Krvna grupa
ID1	Ž	A
ID2	M	0
ID3	M	B
ID4	Ž	0
ID5	Ž	0
ID6	M	A
ID7	M	AB
ID8	Ž	0
ID9	M	A
ID10	Ž	A

Tablica 2.1: Podaci o spolu i krvnoj grupi za deset osoba

U prvom stupcu su samo navedene identifikacijske oznake za svaku osobu, u drugom spol, a u trećem određena krvna grupa. Ako zanemarimo identifikacijske oznake vidimo da zapravo imamo dva niza podataka (o spolu i krvnoj grupi). Osnovna pitanja koja si možemo postaviti su ona u kojima se pitamo koliko je žena među ispitanicima ili koliko njih ima krvnu grupu nula (univerzalni davatelji) i tome slično. Naravno, ovo je jednostavan primjer u kojem imamo kratke nizove podataka pa su odgovori očiti, ali princip bi bio isti i da imamo podatke za 10.000 ljudi.

Kako bi dobili osnovnu sintezu promatranih podataka formirat ćemo tablice frekvencija po spolu i po krvnoj grupi za osobe za koje su prikupljeni gore prezentirani podaci. Jasno, prema prije uvedenim oznakama je $n = 10$, a $k = 2$ kod podataka o spolu jer su različite vrijednosti spola ispitanika samo $y_1 = \text{M}$ i $y_2 = \check{\text{Z}}$. Slično, kod podataka o krvnoj grupi imamo četiri moguće različite vrijednosti ($y_1 = 0$, $y_2 = \text{A}$, $y_3 = \text{B}$ i $y_4 = \text{AB}$) pa je $k = 4$. U skladu s definicijom tablica frekvencija za podatke o spolu dobivamo $f_1 = 5$ i $f_2 = 5$, odnosno tablicu frekvencija Na sličan način formiramo i tablicu frekvencija za

Spol	frekvencija
M	5
Ž	5

Tablica 2.2: Tablica frekvencija za podatke o spolu

podatke o krvnoj grupi: vidimo da se krvna grupa 0 pojavljuje 4 puta pa je $f_1 = 4$, krvna grupa A se pojavljuje također 4 puta pa je $f_2 = 4$, krvna grupa B se pojavljuje jednom pa je $f_3 = 1$, a isto tako je $f_4 = 1$ jer se krvna grupa AB pojavljuje jednom. Imamo tablicu frekvencija Ukoliko sve navedene frekvencije podijelimo s n, odnosno 10, dobijemo

Krvna grupa	frekvencija
0	4
A	4
B	1
AB	1

Tablica 2.3: Tablica frekvencija za podatke o krvnoj grupi

tablicu relativnih frekvencija. Na primjer, imamo sljedeću tablicu relativnih frekvencija pojavljivanja krvnih grupa za deset osoba za koje smo dobili inicijalne podatke

Krvna grupa	**relativna frekvencija**
0	$0.4 = 4/10$ (40%)
A	$0.4 = 4/10$ (40%)
B	$0.1 = 1/10$ (10%)
AB	$0.1 = 1/10$ (10%)

Tablica 2.4: Tablica relativnih frekvencija za podatke o krvnoj grupi

2.1.2 Tablice u R-u

Pogledajmo kako bismo u R-u napravili iste te tablice te prikazali podatke grafički. Tablicu s originalno dobvenim podacima prevedimo u R `data frame` koji ćemo nazvati `krgrupa`. Tako dobijemo

```
> Spol<-c("Ž", "M", "M", "Ž", "Ž", "M", "M", "Ž", "M", "Ž")
> Krvna_grupa<-c("A", "0", "B", "0", "0", "A", "AB", "0", "A", "A")
> krgrupa<-data.frame(Spol, Krvna_grupa)
> krgrupa

   Spol Krvna_grupa
1     Ž           A
2     M           0
3     M           B
4     Ž           0
5     Ž           0
6     M           A
7     M          AB
8     Ž           0
9     M           A
10    Ž           A
```

Uočimo da smo izostavili prvi stupac gornje tablice. R ima ugrađenu funkciju `table()` koja za dane podatke izradi tablicu u kojoj je prikazan broj pojavljivanja vrijednosti pojedine varijable. Tako će nam `table(krgrupa$Spol)` pobrojati broj muškaraca i žena u podacima koje promatramo, odnosno frekvenciju pojavljivanja vrijednosti podataka "M" i "Ž" u svim podacima koji su nam na raspolaganju.

```
> table(krgrupa$Spol)

M Ž
5 5
```

Na sličan način možemo prikazati i frekvenciju pojavljivanja pojedine krvne grupe među osobama za koje su nam dostavljeni podaci

```
> table(krgrupa$Krvna_grupa)

 0  A AB  B
 4  4  1  1
```

Kako su nam podaci spremljeni u data frame možemo dobiti i zajednički tablični pregled danih podataka po spolu i krvnoj grupi

```
> table(krgrupa)

    Krvna_grupa
Spol 0 A AB B
   M 1 2  1 1
   Ž 3 2  0 0
```

Tablicu relativnih frekvencija za krvne grupe dobivamo tako da frekvenciju pojavljivanja pojedine krvne grupe podijelimo s brojem dostupnih podatka. Mogli bismo definirati novu varijablu

```
> relk<-krgrupa$Krvna_grupa/nrow(krgrupa)
```

pa onda na nju primijeniti funkciju `table`, ali možemo i jednostavnije

```
> table(krgrupa$Krvna_grupa)/nrow(krgrupa)

  0   A  AB   B
0.4 0.4 0.1 0.1
```

Opet smo iskoristili svojstvo R-a da bez dodatnih uputa primjenjuje operacije na pojedinačne elemente objekta s kojim radimo. U ovom slučaju tablice.

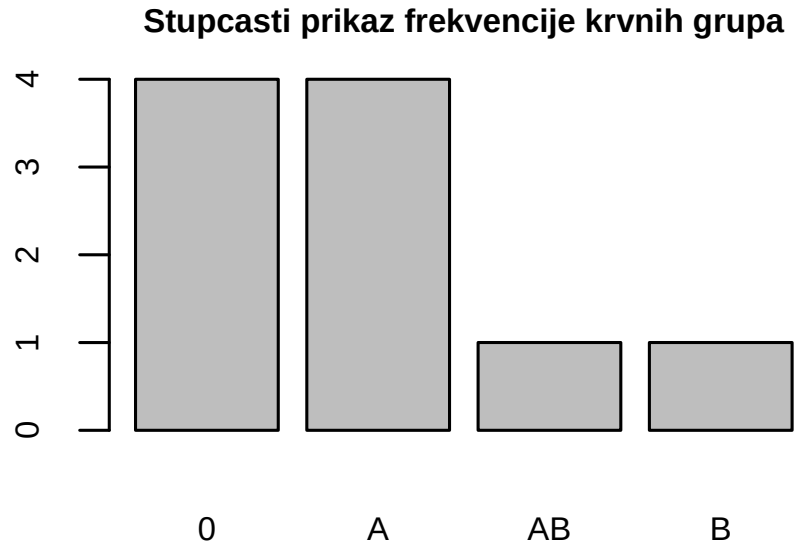
Uočimo da R u svojoj osnovnoj verziji ispisuje tablice horizontalno. Ponekad ih je preglednije ispisati vertikalno. Kao i za mnoge druge stvari, postoje paketi koji mogu poboljšati tablični prikaz. Tako se učitavanjem paketa `plyr` i upotrebom funkcije `count` može postići vertikalni ispis

```
> library("plyr")
> count(krgrupa, "Krvna_grupa")

  Krvna_grupa freq
1           0    4
2           A    4
3          AB    1
4           B    1
```

Postoje i drugi paketi, poput `epiDisplay`, koji omogućavaju dodatnu prilagodbu tabličnog prikaza. Napokon, korištenjem R-ove osnovne funkcije `barplot()` tablični podaci se mogu i vizualizirati. Tako tablicu frekvencija za krve grupe možemo grafički prikazati stupčastim grafom, kao na donjoj slici. Kao i druge funkcije za grafički prikaz podataka funkcija `barplot` ima cijeli niz argumenata kojima se mogu kontrolirati parametri slike koju prikazujemo. U slučaju stupčastog grafa koji prikazujemo malo smo smanjili veličinu fonta uz osi grafa te dodali naslov grafa "Stupčasti prikaz frekvencije krvnih grupa".

```
> par(mar=c(2,2,2,1))
> barplot(table(krgrupa$Krvna_grupa),
+         main= "Stupcasti prikaz frekvencije krvnih grupa",
+         cex.axis=0.7, cex.names=0.7, cex.main=0.7)
```



Više o ovakvim tipovima grafova i mogućnostima njihove prilagodbe reći ćemo malo kasnije kada ćemo analizirati kvantitativne podatke, a tada ćemo uglavnom korisiti funkciju `hist`.

Mala napomena: ponekada se osim tablice relativnih frekvencija prikazuje i tablica kumulativnih relativnih frekvencija (vidjet ćemo u poglavlju o slučajnim varijablama zašto je to relevantno). Takve tablice je jednostavno kreirati jer možemo iskoristiti još jednu od osnovnih R-ovih funkcija `cumsum` koja izračunava kumulativnu sumu danih elemenata. Da ne bude zabune, ako imamo brojeve 1, 3 i 5 onda je kumulativna suma prva dva broja 4, dok je kumulativna suma sva tri broja 9. Primjer tablice kumulativnih relativnih frekvencija za krvne grupe (prema prijašnjim podacima) je naveden niže

```
> cumsum(table(krgrupa$Krvna_grupa)/nrow(krgrupa))

  0   A  AB   B
0.4 0.8 0.9 1.0
```

Takva tablica nam govori da je 40% ispitanika imalo krvnu grupu 0, 80% ispitanika je imalo krvnu grupu 0 ili A te je 90% ispitanika imalo jednu od krvnih grupa 0, A ili B.

2.1.3 Kvantitativni podaci

Pogledajmo podatke o visini, težini i indeksu tjelesne mase koje smo vidjeli na kraju prošlog poglavlja. Učitat ćemo ih korištenjem funkcije `read.xlsx` i spremiti u varijablu `kvant`

```
> library("rJava")
> library("xlsx")
> library("xlsxjars")
> kvant<-read.xlsx("BMI2.xlsx", sheetName="Druga", header=T, endRow=13)
```

Podsjetimo se o kojim je podacima riječ

```
> kvant

   NA. Ime Tezina Visina      BMI
1    1   A     60    165 22.03857
2    2   B     80    180 24.69136
```

```
3    3   C     85    175 27.75510
4    4   D     84    184 24.81096
5    5   E     62    168 21.96712
6    6   F     65    175 21.22449
7    7   G     86    184 25.40170
8    8   H     86    192 23.32899
9    9   I     95    182 28.68011
10  10   J     78    178 24.61810
11  11   K     70    175 22.85714
12  12   L     68    170 23.52941
```

Vidmo da je prva kolona zapravo višak, a pri tome je i bez imena. Možemo je izbrisati tako da varijabli kvant pridružimo sve vrijednosti osim onih iz prve kolone: `kvant<-kvant[,c(2,3,4,5)]`. Provjerimo kojeg su tipa preostali podaci.

```
> str(kvant)

'data.frame':        12 obs. of  4 variables:
 $ Ime   : chr  "A" "B" "C" "D" ...
 $ Tezina: num  60 80 85 84 62 65 86 86 95 78 ...
 $ Visina: num  165 180 175 184 168 175 184 192 182 178 ...
 $ BMI   : num  22 24.7 27.8 24.8 22 ...
```

Kao i u slučaju kvalitativnih podataka lagano možemo napraviti tablice frekvencija, na primjer, pojavljivanja pojedine visine među osobama čije smo podatke dobili

```
> table(kvant$Visina)

165 168 170 175 178 180 182 184 192
  1   1   1   3   1   1   1   2   1
```

Jasno, najviše pojavljivanja ima visina 175, ali to u ovom slučaju nije toliko zanimljivo. Za kvantitativne podatke imamo niz dodatnih informacija koje nam mogu biti od koristi prilikom analize podataka, odnosno sažimanja informacija o njima. Prije svega, to su **mjere središnjeg okupljanja** (središnje tendencije) i **raspršenosti** podataka. Vratit ćemo se BMI podacima kada definiramo navedene pojmove.

2.2 Mjere središnjeg okupljanja podataka - aritmetička sredina, medijan, mod

Neka je zadan neki niz kvantitativnih (numeričkih) podataka $x_1, x_2, \ldots, x_n$, $n \in \mathbf{N}$. Kao što znamo tada se **aritmetička sredina** tih podataka, u oznaci $\bar{x}$ ili $\bar{x}_n$, računa kao

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Ponekad se za aritmetičku sredinu koristi i izraz **srednja vrijednost**. U engleskoj literaturi, u kontekstu statistike, najčešće ćemo naići na naziv *mean* ili *sample mean* za aritmetičku sredinu podataka. Riječ *sample* prevodimo kao uzorak. Radi se o tome da se $x_1, \ldots x_n$ mogu smatrati uzorkom (podskupom) podataka dobivenih iz neke šire populacije $x_1, \ldots x_N$, $N > n$. S druge strane, na njih možemo gledati kao na realizacije neke slučajne varijable pa ti brojevi mogu predstavljati uzorak iz neke razdiobe, odnosno distribucije (ova rečenica će biti jasna kada se uvedemo u teoriju vjerojatnosti; za sada

je možete ignorirati, ali zapamtite da je ovo razlog zašto se koristi baš aritmetička sredina podataka, a ne geometrijska ili neka druga sredina podataka). Radi potpunosti, izračunajmo aritmetičku sredinu podataka

$$24, 5, 9, 12, 22, 2, 89, 4, 13.$$

Sada je $x_1 = 24$, $x_2 = 5$ i tako dalje do $x_9 = 13$. Prema formuli za aritmetičku sredinu dobivamo

$$\bar{x} = \frac{24 + 5 + 9 + 12 + 22 + 2 + 89 + 4 + 13}{8} = 20$$

Aritmetička sredina podataka se jednostavno izračuna i za podatke koji su linearno transformirani. Na primjer, ukoliko je

$$y_i = a \cdot x_i + b, \quad i = 1, \ldots, n, \ a, b \in \mathbb{R}$$

transformirani niz podataka onda je $\bar{y} = a\bar{x} + b$ jer je

$$\bar{y} = \sum_{i=1}^{n} (ax_i + b) = a \sum_{i=1}^{n} x_i + b = a\bar{x} + b. \tag{2.1}$$

Sljedeća mjera središnjeg okupljanja podataka je **medijan** ili **središnja vrijednost** podataka. Medijan je jednak središnjem podatku (po veličini) u nizu podataka koji promatramo. On se jednostavno odredi ukoliko su podaci sortirani po veličini.

Konkretno, prijašnji niz podataka $24, 5, 9, 12, 22, 2, 89, 4, 13$ najprije sortirajmo da dobijemo $2, 4, 5, 9, 12, 13, 22, 24, 89$. Sada se lagano vidi da je središnji podatak, dakle medijan, broj 12. Uočimo da smo imali niz s neparnim brojem podataka pa je bio točno jedan podatak za koji je preostala polovica brojeva bila manja, odnosno veća od njega.

Općenito, ukoliko je broj podataka n neparan, onda je nakon sortiranja podataka po veličini medijan jednak podatku koji se nalazi na mjestu $(n + 1)/2$. Ukoliko niz podatka koji promatramo ima paran broj elemenata n, onda se medijan računa kao srednja vrijednost dva središnja podatka, odnosno kao aritmetička sredina podataka koji se nalaze na mjestima $n/2$ i $n/2 + 1$ u sortiranom nizu podataka. Dakle, ukoliko nam je zadan **sortirani** niz brojeva $x_1, x_2, \ldots, x_n$, $n \in \mathbf{N}$, onda medijan možemo zapisati u obliku funkcije

$$\text{medijan}(x_1, x_2, \ldots, x_n) = \begin{cases} x_{(n+1)/2} & , \text{ n neparan} \\ (x_{n/2} + x_{n/2+1})/2 & , \text{ n paran} \end{cases}$$

Zadnja mjera središnjeg okupljanja podataka je **mod**. Ukoliko su opet podaci koje promatramo označeni s $x_1, \ldots, x_n$, onda je mod tih podataka jednak vrijednosti koja se najčešće pojavljuje među vrijednostima x_i. Ukoliko se niti jedna vrijednost ne pojavljuje više od jednom, onda moda jednostavno nema. Takva je situacija s prije promatranim nizom podataka $24, 5, 9, 12, 22, 2, 89, 4, 13$. Ukoliko promatramo niz podataka $2, 4, 5, 5, 7, 9, 12$, onda je mod tih podataka jednak 5 (vrijednost 5 se najčešće pojavljuje). Koliki su medijan i aritmetička sredina?

Vrijednost moda ne mora biti jedinstvena (samo jedan broj). Naime, u podacima $2, 3, 3, 4, 5, 7, 7, 10$ se vrijednosti 3 i 7 pojavljuju najviše (po dva puta) pa su modovi 3 i 7. Takav niz podataka se naziva **multimodalnim**. Niz podataka u kojem je vrijednost podatka koji se najviše pojavljuje jedinstvena naziva se **unimodalnim**.

Jasno je da mod nije naročita mjera sredine podataka jer on može biti jednak i prvom ili zadnjem elementu niza sortiranih podataka. U praksi se mod ne koristi često.

2.2.1 Izračun aritmetičke sredine, medijana i moda u R-u

U R-u je implementirana funkcija `mean()` koja računa aritmetičku sredinu. Za gornji primjer tako imamo

```
> x<-c(24,5,9,12,22,2,89,4,13)
> mean(x)

[1] 20
```

Kao što je dobro poznato, na izračun aritmetičke sredine dosta utječu vrijednosti niza podataka koje značajno odstupaju od drugih vrijednosti, dakle granične ili ekstremne vrijednosti (na engleskom *outliers*). U ovom konkretnom primjeru, ukoliko maknemo iz niza podataka vrijednost 89 aritmetička sredina se smanji na $11,375$. U R-u imamo

```
> x<-x[!x==89]
> mean(x)

[1] 11.375
```

U R-u je implementirana i funkcija `median()` koja izračunava medijan nekog skupa podataka. U slučaju niza podatka koji smo inicijalno spremili u varijablu `x` imamo

```
> median(c(24,5,9,12,22,2,89,4,13))

[1] 12
```

dok je medijan istoga niza s izbačenom vrijednosti 89 jednak

```
> median(x)

[1] 10.5
```

Ovo je konzistentno s prije definiranom vrijednosti medijana u slučaju parnog broja podataka jer su sada dva središnja podatka 9 i 12, a njihova je srednja vrijednost jednaka $10,5$ (artimetička sredina od 9 i 12). Kao što vidimo, a to vrijedi i općenitije, vrijednost medijana se manje mijenja ukoliko se izbace granične (ekstremne) vrijednosti. To je u nekim situacijama vrlo relevantno. Na primjer, kada se govori o (neto) plaćama u Hrvatskoj često se spominje prosječna plaća (koja se računa kao artitmetička sredina svih plaća u Hrvatskoj). Na nju dosta utječu najveće plaće, a one u osnovi malo toga govore o općoj situaciju u Hrvatskoj, rastu ili padu životnog standarda i slično. S druge strane, medijalna plaća se uvijek refereira na srednju isplaćenu plaću (polovica ljudi ima plaću manju od te, a polovica veću) i njeno povećanje ukazuje na opći porast plaća u Hrvatskoj. Za informaciju, u ožujku 2023. godine je prosječna (neto) plaća u Hrvatskoj iznosila 1.130 eura dok je medijalna (neto) plaća iznosila 946 eura.

U R-u funkcija mod nije implementirana u osnovnom paketu funkcija. Naravno, mod vektora numeričkih podataka se može naći na različite načine. Na primjer, formirajmo vektor `nuz`

```
> nuz<-c(1,2,3,3,4,5,6,6,7,8,8,9)
```

Vidimo da taj vektor (niz brojeva) ima tri moda: 3, 6 i 8. Jedna ideja je da formiramo tablicu frekvencija pridruženu vektoru `nuz` i ispitamo kojim su vrijednostima u tablici (to su imena tablice) pridružene najveće frekvencije (najveća učestalost pojavljivanja, odnosno mod). U osnovi to možemo napraviti primjenom donjeg koda

```
> names(table(nuz))[table(nuz)==max(table(nuz))]
```

Mali je problem to što su imena elemenata tablice podaci tipa `character`, ali to se može riješiti tako da se pretvore u `numeric` korištenjem funkcije `as.numeric()`. Sljedeći kod pokazuje koji se rezultat dobije.

```
> as.numeric(names(table(nuz))[table(nuz)==max(table(nuz))])

[1] 3 6 8
```

Ukoliko ima dvojbe o tome što smo napravili možemo pogledati osnovnu tablicu

```
> table(nuz)

nuz
1 2 3 4 5 6 7 8 9
1 1 2 1 1 2 1 2 1
```

kao i nazive elemenata tablice

```
> names(table(nuz))

[1] "1" "2" "3" "4" "5" "6" "7" "8" "9"
```

Na ovom mjestu je prikladno spomenuti kako se u R-u definiraju **korisnički definirane funkcije**. U donjem kodu je definirana jednostavna funkcija `Mod()`. Stavili smo veliko početno slovo M da se razlikuje od predefinirane R-ove funkcije `mode`. Ona ima jedan argument, a izvršava gore opisan dio koda koji pronalazi mod numeričkog vektora.

```
> Mod <- function(x) {
+   as.numeric(names(table(x))[table(x)==max(table(x))])
+ }
```

Tako definiranu funkciju primijenimo na vektor `nuz`

```
> Mod(nuz)

[1] 3 6 8
```

Uočimo da R pridjeljuje `mode` i tako definiranoj funkciji

```
> mode(Mod(nuz))

[1] "numeric"
```

2.3 Mjere raspršenosti podataka - raspon, varijanca i standardna devijacija

Vidjeli smo u prošlom poglavlju koje su mjere središnjeg okupljanja podataka. One opisuju neku srednju ili tipičnu vrijednost podataka koje promatramo. Ponekad se takve mjere zovu lokacijskima. Ipak, one same nisu dovoljne da malo preciznije opišu podatke koje proučavamo. Naime, osim srednjih ili tipičnih vrijednosti podataka, važna je karakteristika (numeričkih) podataka i njihova raspršenost (disperzija), razmak između njih i slične karakteristike. Da bismo jasnije uočili u čemu je problem pogledajmo dva niza podataka:

$$8, 9, 9, 10, 10, 10, 10, 11, 11, 12$$

i

$$1, 2, 5, 8, 10, 10, 12, 15, 18, 19$$

Prvi niz podataka je prilično koncentriran - podaci su grupirani vrlo blizu vrijednosti 10. Drugi niz podataka je dosta raspršen, odnosno podaci su rastegnuti u dosta većem rasponu. Ipak, izračunom mjera središnjeg grupiranja podataka ne uočavamo razliku među podacima. Naime, i artimetička sredina podataka i medijan i mod su u oba slučaja jednaki 10. To lagano provjerimo i u R-u

```
> uski<-c(8,9,9,10,10,10, 10,11,11,12)
> siroki<-c(1,2 , 5, 8 ,10, 10, 12, 15, 18,19)
> mean(uski); mean(siroki)

[1] 10

[1] 10

> median(uski); median(siroki)

[1] 10

[1] 10

> Mod(uski); Mod(siroki)

[1] 10

[1] 10
```

Kako su podaci očito različitog karaktera jasno je da nam trebaju još neke mjere koje će nam pomoći da razlikujemo podatke prema njihovoj raspršenosti oko središnjih vrijednosti. Prva takva mjera je **raspon** podataka (eng. *range*). Za niz podataka $x_1, x_2, \ldots, x_n$, $n \in \mathbb{N}$, definiramo njihov raspon kao razliku maksimuma i minimuma tih podataka, odnosno

$$\text{raspon}\{x_1, \ldots, x_n\} = \max\{x_1, \ldots, x_n\} - \min\{x_1, \ldots, x_n\}.$$

Za prvi niz podataka lagano vidimo da je njegov raspon 4, dok je raspon drugog niza podataka 18. Za razliku od mjera središnjeg okupljanja podataka, vidimo da raspon jasno razlikuje ta dva niza podataka. Jedan je prilično koncentriran, dok je drugi donekle raspršen.

Sljedeća mjera raspršenosti podataka je **varijanca** (eng. *variance*). Ukoliko opet imamo niz podataka $x_1, x_2, \ldots, x_n$, $n \in \mathbb{N}$, njihovu varijancu (preciznije, uzoračku varijancu), u oznaci s^2 ili s_n^2, definiramo kao

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2, \tag{2.2}$$

gdje je $\bar{x}$, kao i prije, artimetička sredina podataka. Varijancu podataka možemo interpetirati kao kvadratno odstupanje podataka od njihove srednje vrijednosti (normalizirano s $n-1$). Za ilustraciju, izračunajmo varijancu drugog niza podataka uvedenog u ovom poglavlju. Prema gornjoj formuli imamo

$$s^2 = \frac{1}{9}\big[(1-10)^2 + (2-10)^2 + (5-10)^2 + (8-10)^2 + (10-10)^2 + (10-10)^2 + (12-10)^2 + (15-10)^2 + (18-10)^2 + (19-10)^2\big] = 38,6667$$

To lagano provjerimo u R-u korištenjem funkcije `var()`

```
> var(siroki)

[1] 38.66667
```

Za prvi niz podataka dobijemo varijancu

```
> var(uski)

[1] 1.333333
```

što nam, kao i u slučaju raspona, jasno ukazuje na različitost ta dva niza podataka.

Uz varijancu podataka je usko vezana i **standardana devijacija** podataka (eng. *standard deviation*) koju definiramo kao kvadratni korijen od varijance. Uz prirodnu oznaku za standardnu devijaciju s ili s_n, prema tome imamo

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}. \tag{2.3}$$

Iako se standardna devijacija može izračunati i iz varijance (uzimanjem drugog korijena), R ima posebnu funkciju `sd()` koja izračunava standardnu devijaciju. Nizovi podataka koje smo uveli u ovom poglavlju imaju sljedeće standardne devijacije

```
> sd(uski)

[1] 1.154701
```

i

```
> sd(siroki)

[1] 6.218253
```

Postoje još neke mjere raspršenosti podataka, poput tzv. **interkvartilnog raspona**, koji je jednak razlici između trećeg i prvog kvartila, odnosno 75%-tnog percentila i 25%-tnog percentila, no da bi precizno definirali takve pojmove najprije moramo vidjeti što su percentili nizova podataka (uzoraka). Ni tu nije kraj mjerama disperzije podatka. Na primjer, jedna mjera koja uzima u obzir i aritmetičku sredinu podatka i standardnu devijaciju je **koeficijent varijacije**, u oznaci cv ili cv_n, koji je jednak kvocijentu standardne devijacije i artimetičke sredine podatka, odnosno

$$cv_n = \frac{s_n}{\bar{x}_n}.$$

Koeficijent varijacije se ponekad (rijetko) naziva i relativnom standardnom devijacijom jer dovodi u odnos standardnu devijaciju i srednju vrijednost podatka. Koeficijent varijacije omogućava usporedbu podataka sa značajno različitim standardnim devijacijama i očekivanjima, s time da se koristi za nenegativne brojeve. Kada je to relevantno? Pogledajmo sljedeći primjer.

Primjer 2.3.1. U financijama se često rizik ulaganja opisuje standardnom devijacijom povrata (recimo godišnjih) koje ostvaruju određeni tipovi ulaganja, odnosno ulaganja u određena klase imovine. Tako, na primjer, ulaganje u obveznice može ostvariti sljedeće godišnje povrate $1,2\%, 2,5\%, -1,4\%, 3,8\%, 0,2\%$, dok ulaganje u dionice može ostvariti sljedeće godišnje povrate $3,5\%, 6,2\%, 12,8\%, -8,5\%, 3,6\%$ (brojevi su ilustrativni). Tada je aritmetička sredina povrata koji su ostvareni na obveznicama jednaka $1,26\%$,

dok je aritmetička sredina povrata koji su ostvareni na dionicama jednaka $3,52\%$ (provjerite to u R-u; uočite da je $1,2\% = 0,012$). Ako bismo smatrali ostvarene povrate reprezentativnima za općenite povrate na tržištima kapitala mogli bimo jasno zaključiti da je bolje ulaganje, ostvaruje veće povrate, ono u dionice.

S druge strane, standardna devijacija povrata ostvarenih ulaganjem u obveznice je približno jednaka 2%, dok je standardna devijacija povrata koji su ostvareni ulaganjem u dionice približno jednaka $7,71\%$. To nam indicira da je ulaganje u dionice rizičnije (ostvaruje veće raspršenje povrata) pa bi prema tome mogli zaključiti da je bolje ulaganje u obveznice.

Prema tome, u ovisnosti o kriteriju odabira možemo se odlučiti za ulaganje u obveznice ili dionice, ali bi htjeli imati neku veličinu koja uključuje obje mjere ostvarenih povrata. U takvoj situaciji nam može pomoći pogledati neke druge mjere podataka, a jedna od njih, ne i jedina[2], je koeficijent varijacije. Lagano se vidi da je koeficijent varijacije za obveznice (povrate koje ostvaruju obveznice) jednak $1,587$, dok je kod dionica on jednak $2,19$ (uočite da koeficijent varijacije nema mjerne jedinice). To možemo interpretirati tako da konstatiramo da je kod dionica veća ne samo standardna devijacija, nego i relativna standardna devijacija pa bi mogli zaključiti da su one "objektivno" rizičnije od obveznica. To bi nas moglo uputiti da je ulaganje u obveznice povoljnije. Treba napomenuti da ima i drugih razmatranja prilikom ulaganja na tržištima kapitala, puput vremenskog roka ulaganja, tolerancije na rizik ulagača i slično, pa gore navedenu malu statističku analizu zaista treba smatrati samo ilustrativnom. Ipak, vidimo da se uvedenim kvantitativnim mjerama podataka mogu izvoditi analize koje mogu biti korisne. □

Napomena 2.3.2 (Varijanca linearno transformiranih podataka)**.** Uzmimo niz kvantitativnih podataka $x_1, x_2, \ldots, x_n$, $n \in \mathbf{N}$, te ih linearno transformirajmo odnosno definirajmo novi niz podataka $y_1, y_2, \ldots, y_n$, gdje je

$$y_i = a \cdot x_i + b, \quad i = 1, \ldots, n, \ a, b \in \mathbb{R}.$$

U relaciji (2.1) smo vidjeli da se aritmetička sredina linearno transformiranih podataka izračuna jednostavno tako da se aritmetička sredina osnovnog niza podataka pomnoži s a te se tako dobivenom produktu doda b. Iskoristimo sada činjenicu da je $\bar{y} = a\bar{x} + b$ kako bi izračunali

$$\sum_{i=1}^{n}(y_i - \bar{y})^2 = \sum_{i=1}^{n}(ax_i + b - (a\bar{x} + b))^2 = a^2 \sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Stoga, ako sa s_x^2 označimo varijancu niza podataka $(x_i) = (x_1, \ldots, x_n)$, a sa s_y^2 označimo varijancu niza podataka $(y_i) = (y_1, \ldots, y_n)$ vidimo da vrijedi

$$s_y^2 = a^2 s_x^2. \tag{2.4}$$

Uočite da se b uopće ne pojavljuje u formuli (2.4). □

Formula (2.4) nam omogućava da već izračunate vrijednosti varijance (ili standardne devijacije) iskoristimo za izračun varijance linearno transformiranih podataka. Na primjer, pomnožimo sve brojeve u vektoru `siroki` s 13 i oduzmimo 100 od svakoga broja. Dakle, krenemo od niza brojeva $x_1 = 1, x_2 = 2, x_3 = 5, x_4 = 8, x_5 = 10, x_6 = 10, x_7 = 12, x_8 = 15, x_9 = 18, x_{10} = 19$ te formiramo novi niz brojeva

$$y_i = 13x_i - 100, \ i = 1, 2, \ldots, 10$$

pri čemu je $a = 13$, a $b = -100$. Jasno, novodobiveni brojevi y_i su

[2] U financijama je zapravo uobičajeno koristiti recipročnu vrijednost koeficijenta varijacije koja se naziva Sharpovim omjerom.

```
> 13*siroki-100

 [1] -87 -74 -35   4  30  30  56  95 134 147
```

Sada možemo izračunati (recimo u R-u) varijancu tih brojeva

```
> var(13*siroki-100)

[1] 6534.667
```

ali možemo i iskoristiti formulu (2.4) da preskočimo cijeli taj postupak. Naime, jer je varijanca niza brojeva $(1, 2, 5, 8, 10, 10, 12, 15, 18, 19)$ jednaka $38,6667$ prema (2.4) je varijanca linearno transformiranih brojeva $(y_1, y_2, \ldots, y_{10})$ jednaka

$$13^2 \cdot 38,6667 = 6534,67.$$

Napomena 2.3.3 (Još jedna formula za varijancu)**.** Prilikom izračuna varijance često se koristi i sljedeći jednostavni algebarski izraz

$$\sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2. \tag{2.5}$$

U njegovu istinitost se lagano uvjerimo jer imamo

$$\begin{aligned}\sum_{i=1}^{n}(x_i - \bar{x})^2 &= \sum_{i=1}^{n}(x_i^2 - 2x_i\bar{x} + \bar{x}^2)\\ &= \sum_{i=1}^{n} x_i^2 - 2\bar{x}\sum_{i=1}^{n} x_i + \sum_{i=1}^{n}\bar{x}^2\\ &= \sum_{i=1}^{n} x_i^2 - 2\bar{x}n\frac{1}{n}\sum_{i=1}^{n} x_i + n\bar{x}^2\\ &= \sum_{i=1}^{n} x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2.\end{aligned}$$

□

Napomena 2.3.4 (Zanimljiva svojstva aritmetičke sredine i medijana)**.** Osim što imaju dosta jasnu interpretaciju u kontekstu analize podataka, aritmetička sredina podataka i medijan imaju još jednu interpretaciju koja je zanimljiva u kontekstu definicija mjera raspršenosti podataka. Naime, ako je $x_1, \ldots, x_n$, $n \in \mathbb{N}$, neki niz podataka, onda se možemo zapitati koji broj z minimizira sljedeći izraz (zbroj kvadrata razlika vrijednosti podataka i z)

$$(x_1 - z)^2 + \cdots + (x_n - z)^2 = \sum_{i=1}^{n}(x_i - z)^2. \tag{2.6}$$

Iz analize znamo da se ekstremi funkcije računaju tako da se derivacija funkcije izjednači s nulom pa se nađu nultočke koje su onda potencijalne točke ekstrema. Ukoliko je druga derivacija funkcije u nekoj od točaka esktrema pozitivna dobijemo točku minimuma.

Definirajmo stoga funkciju

$$f(z) = \sum_{i=1}^{n}(x_i - z)^2,\ z \in \mathbb{R}$$

i izračunajmo joj derivaciju (po z). Iskoristimo činjenicu da je derivacija zbroja jednaka zbroju derivacija te formulu za derivaciju složenih funkcija da dobijemo

$$f'(z) = -2\sum_{i=1}^{n}(x_i - z) = -2(\sum_{i=1}^{n} x_i - nz).$$

Izjednačimo $f'(z)$ s nulom i podijelimo jednakost s -2 da bi dobili točku ekstrema

$$z = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Kako je $f''(z) = 2n > 0$ zaključujemo da je riječ o točki minimuma. Dakle, za $z = \bar{x}_n$ će izraz u (2.6) postizati minimum za proizvoljno odabrani niz brojeva $x_1, \ldots, x_n$. No, kada pogledamo definiciju varijance shvaćamo da je varijanca brojeva definirana upravo tako da je jednaka minimalnoj vrijednosti zbroja kvadratnih ostupanja niza brojeva $x_1, \ldots, x_n$ od nekog realnog broja z.

Slično se možemo zapitati koji broj m minimizira sljedeći izraz (zbroj apsolutnih vrijednosti razlika vrijednosti podataka i m)

$$|x_1 - m| + \cdots + |x_n - m|.$$

Ukoliko je m jednak medijanu podataka gornji izraz će postići minimalnu vrijednost. Ova se činjenica može dokazati kao i prije navedena tvrdnja za aritmetičku sredinu, ali treba koristiti poopćenje derivacije te funkciju sign(z) koja je jednaka 1 za pozitivne brojeve i -1 za negativne. Alternativno se ta tvrdnja može dokazati i elementarnim računom, ali sam dokaz nam na ovom mjestu nije važan pa možemo samo zapamtiti da aritmetička sredina i medijan imaju dodatnu matematičku interpretaciju. □

2.4 Percentili i kvartili

Neka je p realan broj, $p \in [0, 1]$. Tada je $100p$ **percentil** nekog niza podatka jednak onoj vrijednosti među podacima za koju je $100p$ posto podataka manje ili jednako od nje, a $100(1-p)$ posto podataka je veće ili jednako od nje. Ako dva podatka zadovoljavaju taj uvjet, onda je $100p$ percentil jednak aritmetičkoj sredini ta dva podatka.

Da bi se odredili percentili podataka potrebno je sortirati podatke u rastući poredak. Pretpostavimo da imamo n podataka, $n \in \mathbb{N}$. Prema gornjoj definiciji, da bi se odredio $100p$ percentil tih podatka treba utvrditi koji je od podataka takav da je barem np vrijednosti podataka manje ili jednako od njega i da je barem $n(1-p)$ podataka veće ili jednako od njega.

U osnovi su moguća dva slučaja prilikom određivanja $100p$ percentila. Pokažimo na dva primjera koje su moguće situacije. Kao prvi primjer uzmimo sljedeći niz već sortiranih $n = 16$ podataka

$$1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16$$

Pretpostavimo da je $p = 0,8$, odnosno da želimo izračunati 80%-tni percentil. Tada je $np = 12,8$ i, naravno, $n(1-p) = 3.2$. Za 80%-tni percentil tada treba vrijediti da je $12,8$ podataka manje ili jednako njemu, a $3,2$ podatka je veće ili jednako njemu. Jasno je da trinaesti element sortiranog niza podataka, ovdje je to baš broj 13, zadovoljava taj uvjet pa je 80%-tni percentil upravo broj 13.

Za sljedeći primjer odaberimo niz podataka

$$1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20$$

i odredimo njegov 90%-tni percentil. Sada je $np = 18$, dok je $n(1-p) = 2$. U ovom slučaju i osamnaesti i devetnaesti član niza, dakle brojevi 18 i 19, zadovoljavaju uvjet da je osamnaest podataka manje ili jednako njima te su dva podatka veća ili jednaka njima. U tom slučaju je 90%-tni percentil jednak aritmetičkoj sredini ta dva podatka, odnosno jednak je $18,5$.

Tradicionalno neki od percentila imaju posebna imena i značenje. Tako se 25%-tni percentil naziva prvim **kvartilom**, 50%-tni percentil se naziva drugim kvartilom, a 75%-tni percentil se naziva trećim kvartilom. Uočimo da je drugi kvartil zapravo medijan. Razlika između trećeg i prvog kvartila se naziva **interkvartilnim rasponom** (eng. *interquartile range*) i još je jedna od mjera raspršenja podataka koja se koristi u praksi.

Napomena 2.4.1 (Uređajne statistike)**.** Neka je $x_1, x_2, \ldots, x_n$, $n \in \mathbf{N}$, neki niz numeričkih podataka (brojeva). Ukoliko uredimo te podatke po veličini dobijemo niz

$$x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}.$$

Taj niz podataka se naziva **uređajnom statistikom** (kasnije ćemo malo formalnije definirati pojam statistike u smislu funkcije uzorka). Sada neke prije uvedene pojmove možemo formalno opisati uređajnim statistikama.

Naime, jasno je da je minimum podataka jednak $x_{(1)}$, dok je maksimum podataka jednak $x_{(n)}$. Naravno, tada je raspon podataka jednak

$$\text{raspon}\{x_1, \ldots, x_n\} = x_{(n)} - x_{(1)}.$$

Slično se i medijan može prikazati pomoću uređajnih statistika

$$\text{medijan}(x_1, x_2, \ldots, x_n) = \begin{cases} x_{(\frac{n+1}{2})} & \text{, n neparan} \\ (x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)})/2 & \text{, n paran} \end{cases}$$

Uočite da smo i prije medijan prikazali u ovako kompaktnom zapisu, ali smo sada upotrijebili zapis pomoću uređajnih statistika koje se često pojavljuju u statistici. □

U vjerojatnosti i statistici se često koristi i izraz **kvantili** (eng. *quantiles*) koji je usko vezan uz pojmove percentila i kvartila (oni se svi mogu smatrati posebnim slučajevima kvantila). Kvantili se definiraju pomoću vjerojatnosnih funkcija distribucije. Kako njih još uvijek nismo uveli nećemo na ovom mjestu ulaziti u definiciju kvantila, ali ostavljamo ovu napomenu da ne bi došlo do zabune prilikom proučavanja literature. Kako se kvantili mogu definirati za nizove brojeva možete pogledati u [1], odjeljak 2.4.

2.5 Osnovna analiza i grafički prikaz podataka u R-u

Vratimo se sada primjeru s indeksom tjelesne mase (BMI). Podaci su spremljeni u data frame `kvant`, a imena stupaca (vektora koji čine taj data frame) su `Ime`, `Tezina`, `Visina` i `BMI`. Opremljeni novim znanjem sada lagano možemo izračunati neke osnovne kvantitativne mjere danih podatka. Tako za težinu osoba čije podatke podatke imamo izračunamo aritmetičku sredinu, medijan, standardnu devijaciju i raspon

```
> mean(kvant$Tezina); median(kvant$Tezina); sd(kvant$Tezina);

[1] 76.58333

[1] 79
```

```
[1] 11.26102
```

```
> range(kvant$Tezina)
```

```
[1] 60 95
```

Uočimo da R ima funkciju `range()` koja kao vrijednost vraća najmanju i najveću vrijednost koju postižu promatrani podaci. Naravno, raspon podataka, u prije definiranom smislu, je jednak razlici ta dva broja, odnosno 35.

Kako je R u osnovi programski jezik napisan za statističku analizu, R ima ugrađenu funkciju `summary()` koja sažeto prikazuje neke osnove statistike o podacima

```
> summary(kvant$Tezina)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  60.00   67.25   79.00   76.58   85.25   95.00
```

Vidimo da se na popisu osnovnih statistika o podacima nalaze minimum i maksimum, aritmetička sredina (*mean*) te kvartili podataka. Ista funkcija se može primijeniti i na cijeli data frame `kvant`

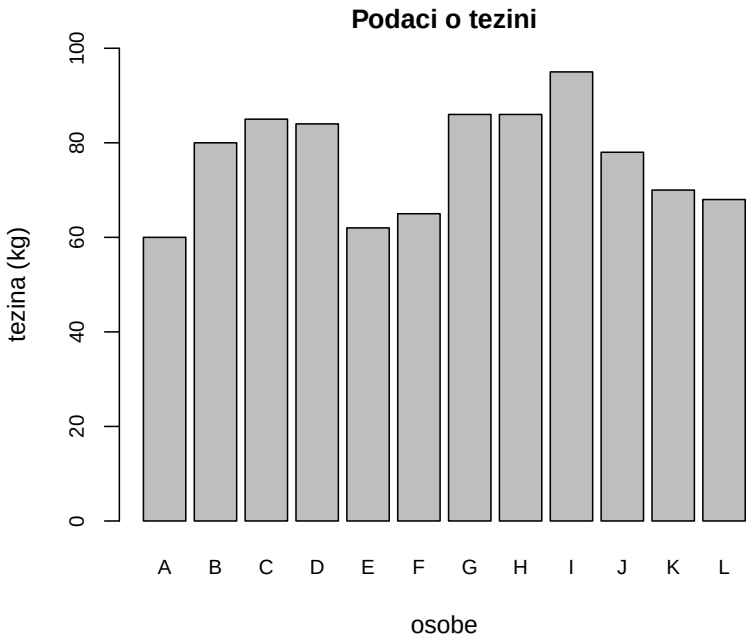
```
> summary(kvant)
```

```
     Ime                Tezina          Visina          BMI
 Length:12          Min.   :60.00   Min.   :165.0   Min.   :21.22
 Class :character   1st Qu.:67.25   1st Qu.:173.8   1st Qu.:22.65
 Mode  :character   Median :79.00   Median :176.5   Median :24.07
                    Mean   :76.58   Mean   :177.3   Mean   :24.24
                    3rd Qu.:85.25   3rd Qu.:182.5   3rd Qu.:24.96
                    Max.   :95.00   Max.   :192.0   Max.   :28.68
```

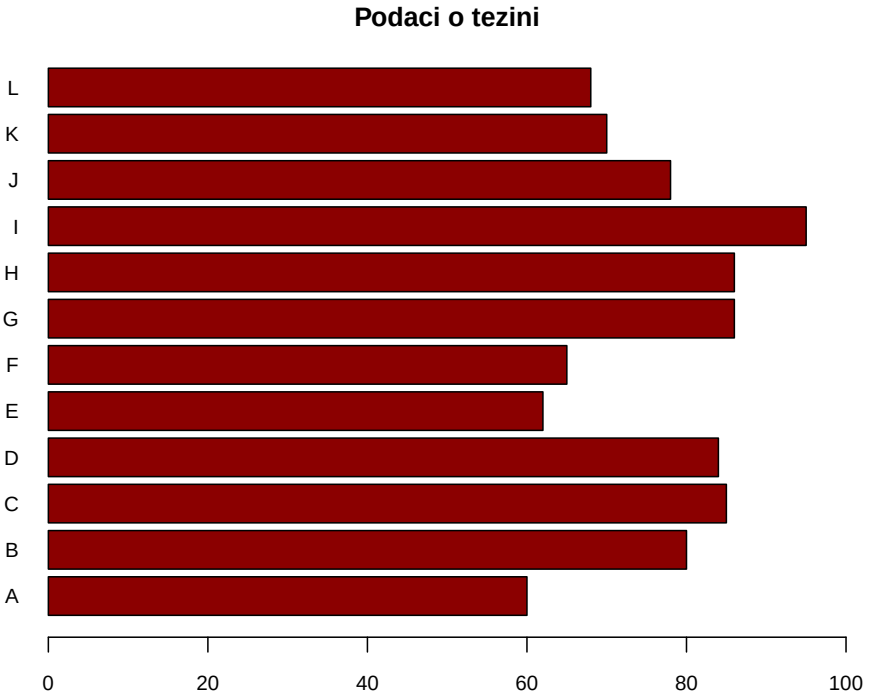
Sada vidimo osnovni sažetak kvantitativnih karakteristika za sve numeričke vektore od kojih se sastoji data frame `kvant`. Ovo je često najbrži i najlakši način da steknemo uvid u neke podatke koje želimo bolje upoznati ili ih dodatno proučiti. Jasno, vektor `Ime` je znakovnog tipa pa `summary()` za njega samo utvrđuje doljinu i tip podataka.

Da bi dodatno razumijeli podatke možemo se poslužiti i grafičkim prikazom. Opet koristimo stupčasti graf. Za razliku od prijašnjeg stupčastog grafa koji smo prikazali, kod gornjeg grafa smo definirali dodatne parametre. Tako smo funkciji `barplot` eksplicitno naveli određivanjem parametra `names.arg` da kao oznake na x-osi koristi imena osoba, naveli raspon podatka koji će se prikazati na y-osi, dodali smo ime grafa te smo imenovali x i y os (pomoću `xlab` i `ylab`). Dodatno je smanjen font (veličina) oznaka uz x i y os pomoću parametara `cex.axis` i `cex.labels`. Oni su postavljeni na vrijednost manju od 1 što indicira smanjenje, a vrijednosti veće od 1 povećanje veličine oznaka uz osi grafa. Postoji još cijeli niz parametara koji se mogu mijenjati, a cjelovitiji popis parametara može se naći tako da se u R konzoli utipka `help("barplot")`, kao što smo već višekratno napomenuli. Također, koristili smo funkciju `par` da prilagodimo margine oko grafa koji generira R. Na primjer, s `par(mar=c(4,4,2,1))` smo odredili margine oko samog grafa, a s `par(oma=c(1,2,2,1))` margine oko slike grafa (vanjske margine).

```
> par(mar=c(4,4,2,1), oma=c(1,2,2,1))
> barplot(kvant$Tezina, names.arg = kvant$Ime , ylim= c(0,100),
+         main="Podaci o tezini" , xlab="osobe", ylab="tezina (kg)",
+         cex.axis=0.8, cex.names=0.8, cex.main=1.1)
```



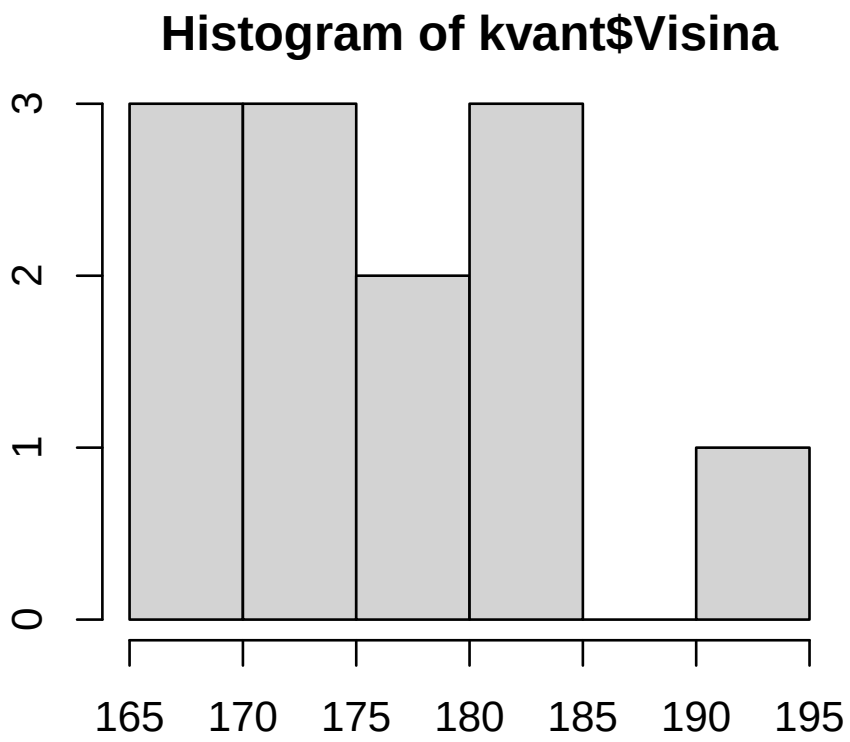
Kao primjer korištenja dodatnih parametara dajemo još jedan graf u kojem je iskorišten horizontalni prikaz (parametar `horiz=TRUE`), stupci su obojani tamno crvenom bojom te je sačuvan naziv grafa. Također, promijenili smo i orijentaciju oznaka uz y os (parametar `las=1`).



Kao što smo već vidjeli, odmah na početku potpoglavlja 2.1.3, tablični prikaz kvantitativnih podataka nije uvijek previše informativan, a dodatno je kompliciran za podatke koji su realizacije neprekidnih varijabli pa su često njihove vrijednosti necijeli brojevi. Za njihov prikaz je uobičajeno formirati intervale te prikazati broj podataka u pojedinom intervalu. Da bi se grafički prezentirali takvi podaci uobičajeno je koristiti **histograme**. Oni su, dakle, grafički analogon tabličnog prikaza frekvencije podataka koji su realiza-

cije neprekidnih varijabli, ali i velikog broja podataka koji su diskretnog tipa. U R-u se histogrami generiraju funkcijom `hist()`. Pogledajmo histogram Visine u podacima `kvant`

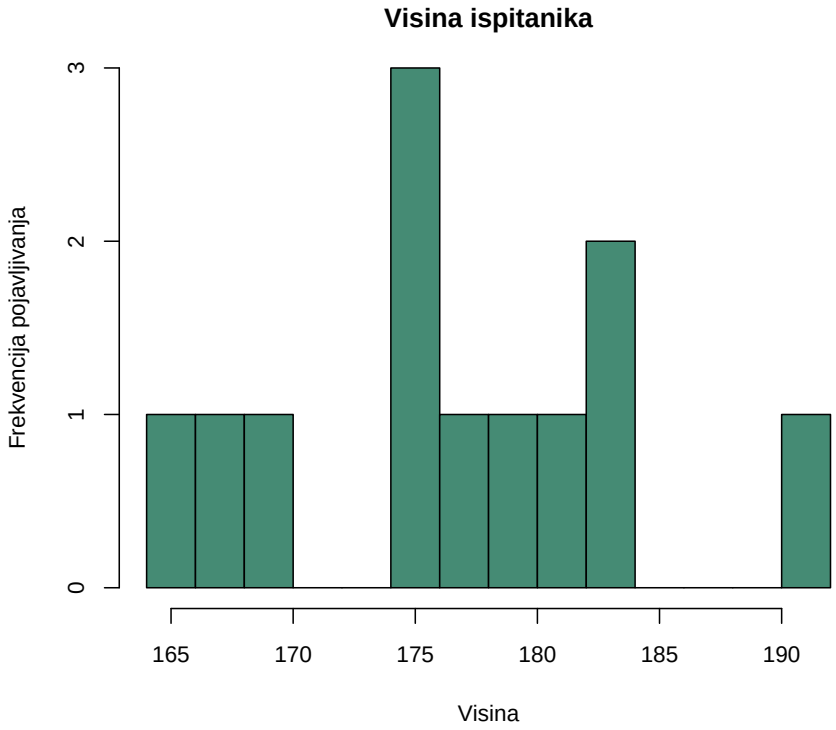
```
> par(mar=c(2,2,2,1))
> hist(kvant$Visina)
```



Histogram prikazuje broj podataka u pojedinom segmentu unutar ukupnog raspona podataka koje proučavamo. Na prethodnom grafu je R sam podijelio x os u segmente duljine 5. Svaki stupac označava broj osoba čija se visina nalazi u jednom od naznačenih segmenata. Uočimo da je vrijednost 170 dodana u segment $165 - 170$. Kao i kod barplota, možemo mijenjati razne parametre histograma.

Na primjer, na sljedećem grafu smo prikazanom histogramu, koji koristi iste podatke kao i prethodni, dodali naslov, imena podataka na osima, smanjili font na osima, povećali ga u naslovu te smo sami definirali broj kategorija za prikaz podataka i to tako da smo stavili da je on jednak broju podataka u vektoru `kvant$Visina`. Broj kategorija na histogramu možemo mjenjati parametrom `breaks`. Dodatno smo obojali stupiće histograma u akvamarin plavu boju (jednu od velikog broja njih definiranih u R-u - pogledajte više o bojama u R-u na https://r-charts.com/colors/).

```
> par(mar=c(4,4,2,1))
> h<-hist(kvant$Visina,
+      main="Visina ispitanika", xlab= "Visina",
+      ylab="Frekvencija pojavljivanja",
+      breaks = length(kvant$Visina),
+      cex.axis=0.9, cex.main=1.1, cex.lab=0.9,
+      col="aquamarine4")
```



Na ovom mjestu je važno uočiti sljedeće: iako je histogram izgledom sličan stupčastom grafu, osovna je razlika da se histogramom prikazuju samo numerički podaci. Dodatno, podaci koje prikazujemo histogramom se grupiraju u intervale koji uključuju sve vrijednosti koje se nalaze između granica intervala. Ti se intervali ponekad nazivaju i **razredima**. Tako se, na primjer, kod histograma koji prikazuje vrijednosti od `kvant$Visina` u intervalu $[165, 170]$ nalaze tri podatka (visine tri osobe), kao i u intervalu $(170, 175]$. Taj histogram prikazuje frekvencije pojavljivanja podataka u određenom intervalu. Ti intervali, odnosno razredi, mogu biti i drugačije definirani pa je tako jedan razred na tom histogramu mogao biti i $[165, 170)$. Mi smo koristili R-ovu definiciju razreda.

Kod prikaza podataka na drugom histogramu (u kojem smo stupiće obojali u akvamarin) u kodu smo varijabli `h` pridružili sam histogram (koji je nacrtan). Možemo pogledati od čega se uopće sastoji histogram u R-u

```
> h

$breaks
 [1] 164 166 168 170 172 174 176 178 180 182 184 186 188 190 192

$counts
 [1] 1 1 1 0 0 3 1 1 1 2 0 0 0 1

$density
 [1] 0.04166667 0.04166667 0.04166667 0.00000000 0.00000000 0.12500000
 [7] 0.04166667 0.04166667 0.04166667 0.08333333 0.00000000 0.00000000
[13] 0.00000000 0.04166667

$mids
 [1] 165 167 169 171 173 175 177 179 181 183 185 187 189 191

$xname
[1] "kvant$Visina"
```

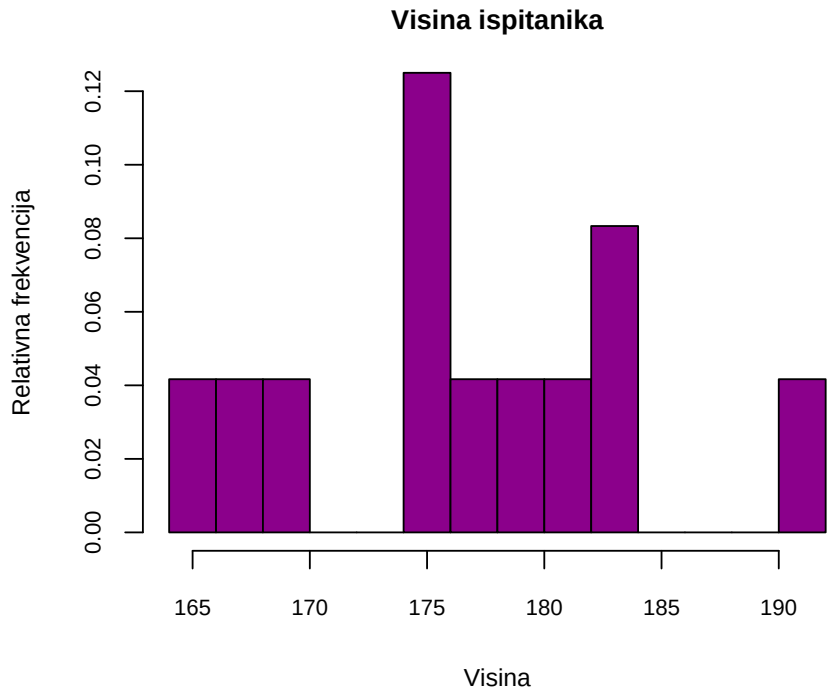
```
$equidist
[1] TRUE

attr(,"class")
[1] "histogram"
```

Većina od 6 ispisanih polja je samorazumljiva, a podaci o granicama razreda (intervala u kojima su grupirani podaci) su sadržani u vektoru `$breaks`. Vidimo da su u ovom slučaju podaci grupirani u razrede $[164, 166]$, $(166, 168]$, $(168, 179]$ i tako dalje. Pažljiviji čitatelj će uočiti da je R svrstao podatke u 14, a ne 12 razreda (koliko je duljina vektora `kvant$Visina`). To je napravio kako bi podaci bili pregledno prikazani jer da je formirao 12 intervala jednake duljine širina svakog intervala bi bila $(192 - 165)/12 = 2.25$ (165 je najmanji promatrani podatak, a 192 najveći), a ovako je širina svakog intervala 14. Uočimo da su sve visine koje smo promatrali cijeli brojevi, ali je jasno da smo mogli raditi i s brojevima oblika $175,3$ cm ili $182,65$ cm pa bi oni bili ubrojeni u odgovarajuće razrede koje je R formirao.

Svakako vrijedi skrenuti pažnju na vektor `$density` koji R-u omogućava da napravi histogram relativnih frekvencija (kasnije ćemo vidjeti što to znači u kontekstu vjerojatnosti). Imamo

```
> par(mar=c(4,4,2,1))
> hist(kvant$Visina, main="Visina ispitanika", xlab= "Visina",
+      ylab="Relativna frekvencija", breaks = length(kvant$Visina),
+      cex.axis=0.75, cex.main=0.9, cex.lab=0.8, col="darkmagenta",
+      probability = TRUE)
```

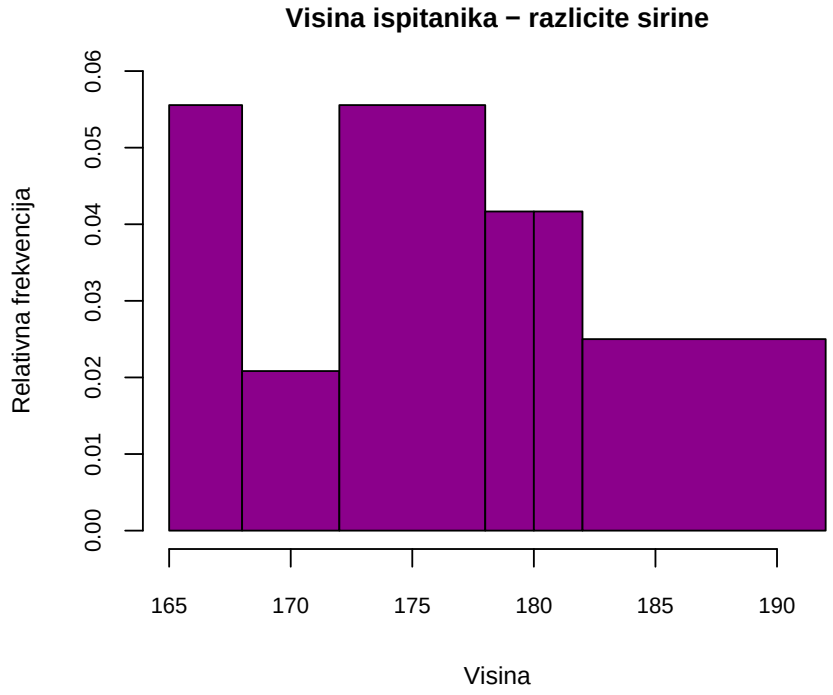


Prethodni graf zahtjeva malo objašnjenje. Prije svega, isti bi se graf dobio da smo umjesto `probability=TRUE` stavili `freq=FALSE` (predefinirana vrijednost parametra `freq` je `TRUE`). Nadalje, kada se zbroji umnožak svih širina stupića s njihovim visinama dobije se vrijednost jedan. Dakle, takve grafove treba interpretirati ne samo "čitajući" vrijednosti s y osi, nego uzimajući u obzir i širinu stupića. Kako se računaju vrijednosti vektora

`$density`? Tako da se relativne frekvencije pojedinog razreda podijele sa širinom intervala koji predstavlja taj razred. Primjerice, u intervalu $[164, 166]$ imamo jedan podatak, njegova je relativna frekvencija jednaka $1/12$ (podsjetite se definicije relativnih frekvencija) i tu relativnu frekvenciju trebamo podijeliti sa širinom intervala $[164, 166]$ koja je jednaka 2. Tako dobivamo broj $1/24 = 0,04166667$. Slično je i za ostale vrijednosti.

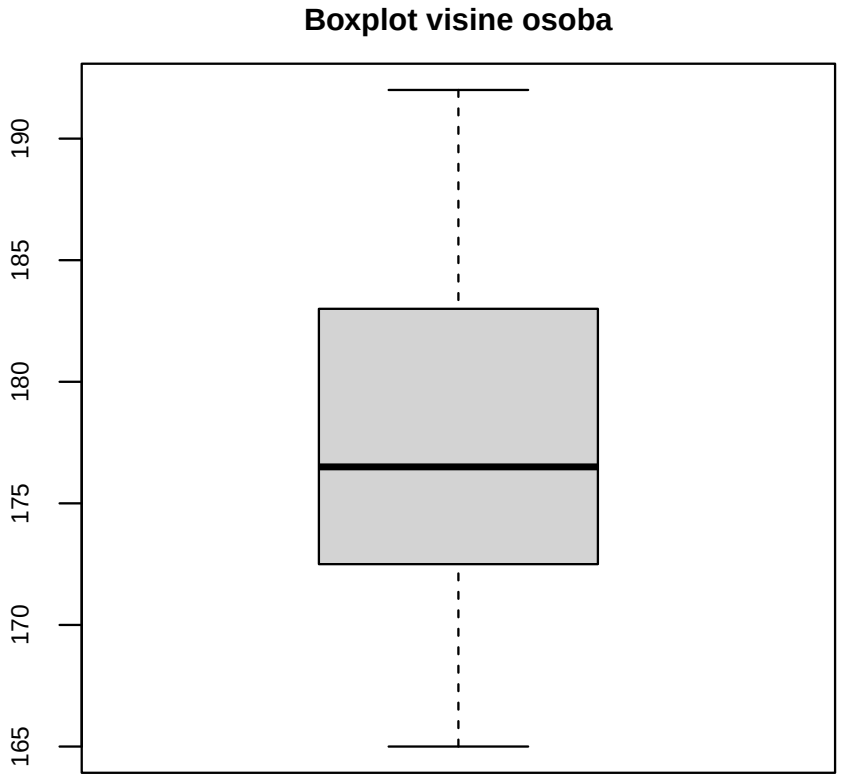
Jasno, razredi koje prikazujemo histogramom ne moraju svi imati jednaku širinu. Primjer je histogram prikazan na donjem grafu. Na njemu smo sami definirali vrijednosti parametra `breaks` i to tako da smo mu vrijednosti definirali vektorom koji ima 7 elemenata: `c(165,168,172,178,180,182,192)`. U ovom primjeru takav graf nije previše koristan, ali ukoliko u nekom području vrijednosti imamo velik broj podataka korisno je podijeliti ga na manje dijelove. Vidjet ćemo to kasnije kod nekih primjera.

```
> par(mar=c(4,4,2,1))
> hist(kvant$Visina, main="Visina ispitanika - razlicite sirine",
+      xlab= "Visina", ylab="Relativna frekvencija",
+      ylim=c(0,0.06),
+      cex.axis=0.75, cex.main=0.9, cex.lab=0.8,
+      breaks = c(165, 168,  172, 178, 180, 182, 192),
+      col="darkmagenta", probability = TRUE)
```



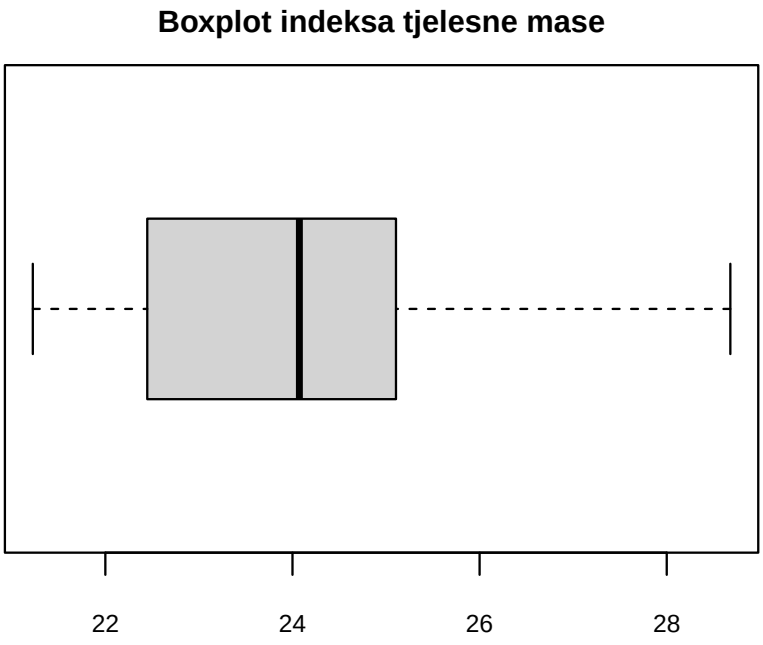
Završit ćemo ovaj kratki pregled grafičkog prikaza podataka još jednim tipom grafa, tako zvanim boxplotom (funkcija u R-u je `boxplot()`). Boxplot se na engleskom naziva i *box and whiskers* dijagramom, a možemo to prevesti i kao pravokutni dijagram. On nam je dosta koristan u kontekstu analize grupiranja podataka, njihovog raspona i identificiranja ekstremnih vrijednosti (outliera).

```
> par(mar=c(2,2,2,1))
> boxplot(kvant$Visina, cex.axis=0.7, cex.main=0.8,
+         main="Boxplot visine osoba")
```



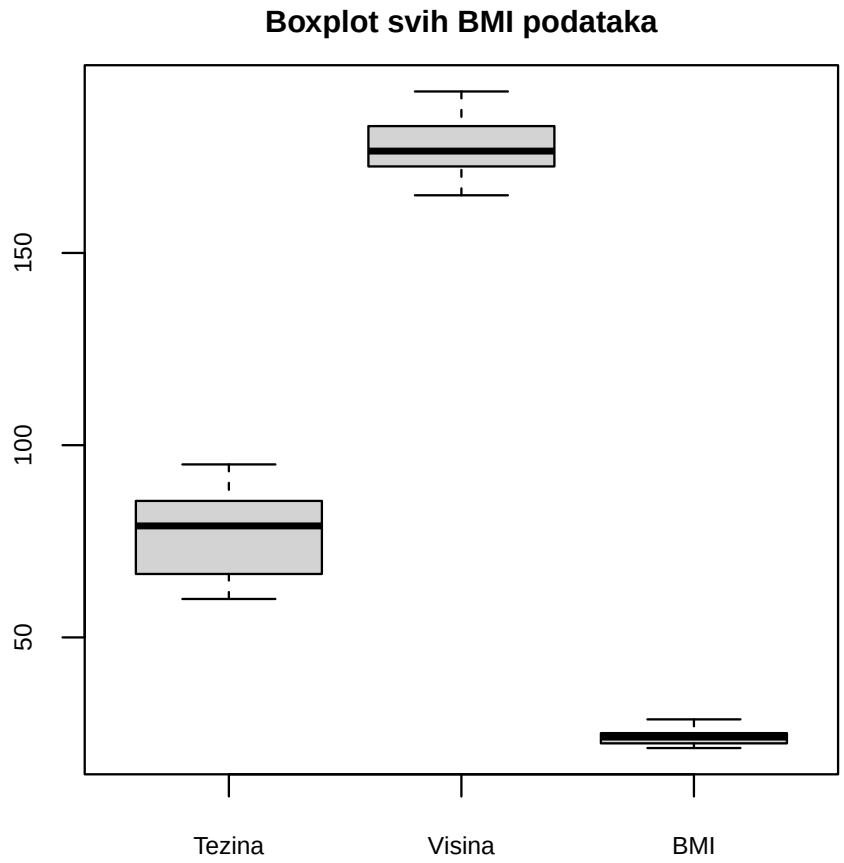
Na grafu možemo uočiti razne podatke: podebljana crta u sredini predstavlja medijan, a sivi pravokutnik na slici je s donje i gornje strane omeđen, redom, prvim i trećim kvartilom. Horizontalnim crtama su naznačene najmanja i najveća vrijednost podataka koje analiziramo. Na grafu bi kružićima bili označeni i ekstremni podaci (outlieri), pri čemu se ekstremnim podacima smatraju oni koji su od 1. i 3. kvartila udaljeni za više od $1,5 \cdot IQR$, gdje je IQR interkvantilni razmak.

Na donjem grafu je prikazan boxplot indeksa tjelesne mase položen horizontalno (postavili smo vrijednost parametra `horizontal` na `TRUE`)



R nam omogućava da na jednom grafu prikazažemo boxplotove za sva tri vektora numeričkih podataka koje sadrži `kvant`.

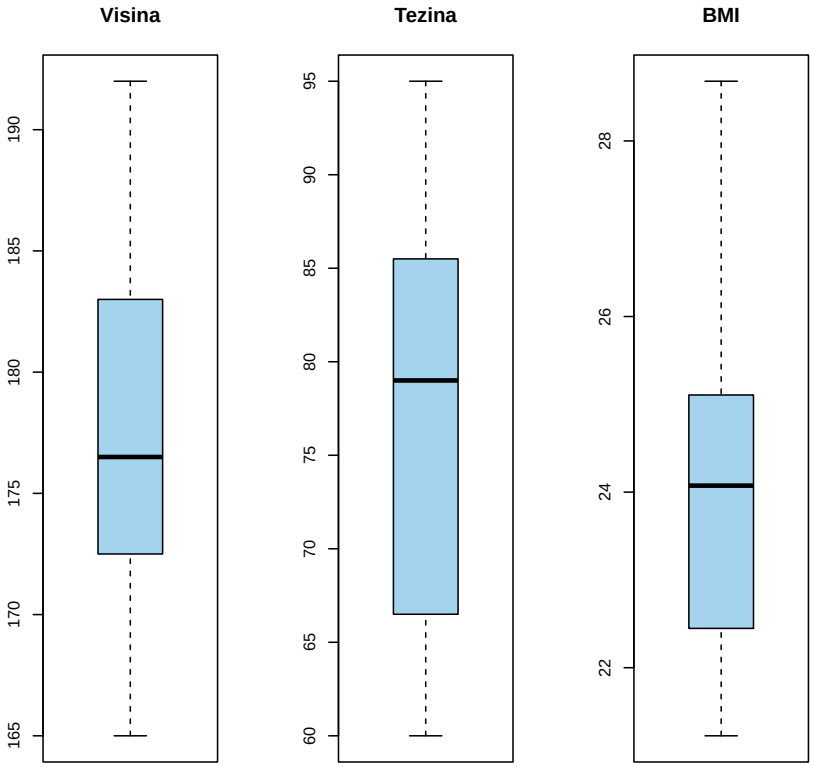
```
> par(mar=c(2,2,2,1))
> boxplot(kvant[, c(2,3,4)],
+         main="Boxplot svih BMI podataka",
+         cex.axis=0.7,cex.main=0.8)
```



Kao što vidimo, problem zajedničkog prikaza zajedničkih boxplotova na istom grafu je u tome što su podaci na različitim skalama pa takav graf ne pokazuje puno. Vidimo da se rasponi podataka skoro pa nerazlučivi, a to je poanta prikaza podataka pomoću boxplota.

Alternativno, a bitno informativnije, možemo prikazati sva tri boxplota jedan do drugoga da dobijemo pregledan prikaz podataka koje proučavamo. Takav prikaz je dan na sljedećoj slici. Naravno, sada trebamo uočiti da su skale na kojima su prikazani podaci na svakom od tri grafa različite, ali je jasno kako su podaci raspoređeni (distribuirani) u okviru svojih skala. Radi demonstracije korištenja parametara prikazanih grafova smo stupiće na svakom od njih obojali u svijetlo plavu boju (ta se zove `"lightskyblue2"` u R-ovoj paleti boja).

```
> par(mfrow = c(1, 3))
> boxplot(kvant$Visina, main="Visina", col="lightskyblue2");
> boxplot(kvant$Tezina, main="Tezina", col="lightskyblue2");
> boxplot(kvant$BMI, main="BMI", col="lightskyblue2")
```



2.6 Koeficijent korelacije

Ukoliko imamo niz dvodimenzionalnih kvantitativnih podataka, (x_i, y_i), $i = 1, 2, \ldots, n$, $n \in \mathbb{N}$, onda se često postavlja pitanje o međuodnosu podataka x_i i y_i. Tako se možemo pitati da li su podaci iz ta dva niza podataka istovremeno veliki ili mali. U osnovi želimo ispitati da li postoji neka povezanost među podacima koje promatramo.

Jedna od najčešćih mjera međuovisnosti podataka je **korelacija** koju mjerimo **koeficijentom korelacije**, u oznaci $\rho_{x,y} = \rho$ ili r. Uz prije uvedene oznake $\bar{x}$ i s_x za očekivanje i standardnu devijaciju niza x_i, koeficijent korelacije definiramo kao

$$\rho = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{(n-1)s_x s_y} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}. \tag{2.7}$$

Koeficijent korelacije ima sljedeća osnovna svojstva:

i) $-1 \leq \rho \leq 1$,

ii) Za $a, b \in \mathbb{R}$, $a > 0$, i $y_i = ax_i + b$ vrijedi $\rho = 1$,

iii) Za $a, b \in \mathbb{R}$, $a < 0$, i $y_i = ax_i + b$ vrijedi $\rho = -1$,

iv) $\rho_{x,y} = \rho_{y,x}$ (simetričnost).

U osnovi se jednostavno pokaže da vrijede sva navedena svojstva koeficijenta korelacije. Tako za dokaz prvog svojstva uočimo da je

$$\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s_x} - \frac{y_i - \bar{y}}{s_y}\right)^2 \geq 0. \tag{2.8}$$

Dodatno, sjetimo se definicije varijance s_x^2 da bi dobili

$$\sum_{i=1}^{n} \frac{(x_i - \bar{x})^2}{s_x^2} = \frac{1}{s_x^2} \sum_{i=1}^{n} (x_i - \bar{x})^2 = \frac{n-1}{\sum_{k=1}^{n} (x_k - \bar{x})^2} \sum_{i=1}^{n} (x_i - \bar{x})^2 = n - 1.$$

Kvadriranjem izraza u (2.8) dobivamo

$$\sum_{i=1}^{n} \frac{(x_i - \bar{x})^2}{s_x^2} - 2 \sum_{i=1}^{n} \frac{(x_i - \bar{x})(y_i - \bar{y})}{s_x s_y} + \sum_{i=1}^{n} \frac{(y_i - \bar{y})^2}{s_y^2} = n - 1 - 2(n-1)\rho + n - 1.$$

Iz (2.8) slijedi da je

$$2(n-1)\rho \leq 2(n-1)$$

pa je jasno da je $\rho \leq 1$. Da bi pokazali da je i $\rho \geq -1$ krenemo od izraza

$$\sum_{i=1}^{n} \Big(\frac{x_i - \bar{x}}{s_x} + \frac{\bar{y} - y_i}{s_y} \Big)^2 \geq 0$$

i zaključujemo analogno.

Slično se vidi da vrijedi i svojstvo (ii). Naime, iz svojstava varijance, odnosno standardne devijacije (vidi (2.4)) znamo da je

$$s_y = a s_x.$$

Kako je dodatno $\bar{y} = a\bar{x} + b$ dobivamo

$$\rho = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(a x_i + b - a\bar{x} - b)}{(n-1) s_x a s_x} = \frac{1}{s_x^2} \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2 = 1.$$

Analogno pokažemo da vrijedi svojstvo (iii) pri čemu uočimo da je $s_x = -a s_y$ (varijanca i standardna devijacija ne mogu biti negativne).

Primjer 2.6.1. Nađimo korelaciju između nizova brojeva $-2, 0, 2, 4, 4$ i $2, 2, 3, 4, 4$.

U skladu s gore uvedenim oznakama imamo $x_1 = -2, x_2 = 0, x_3 = 2, x_4 = 4, x_5 = 4$ i $y_1 = 2, y_2 = 2, y_3 = 3, y_4 = 4, y_5 = 4$. Da bi izračunali korelaciju ta dva niza podataka trebamo izračunati aritmetičke sredine i standardne devijacije oba niza podataka. U skladu s prethodnim definicijama vidimo da je $\bar{x} = 1,6$ i $\bar{y} = 3$. Slično izračunamo $s_x = 2,607681$ i $s_y = 1$ (provjerite te izračune za vježbu). Prema definiciji koeficijenta korelacije u (2.7) imamo

$$\begin{aligned} \rho &= \frac{1}{4 \cdot 2,607681} \big((-2 - 1,6)(2 - 3) + (0 - 1,6)(2 - 3) + (2 - 1,6)(3 - 3) \\ &\quad + (4 - 1,6)(4 - 3) + (4 - 1,6)(4 - 3) \big) \\ &= \frac{1}{10,430724} (3,6 + 1,6 + 2,4 + 2,4) \\ &= \frac{10}{10,430724} = 0,9587. \end{aligned}$$

Dobivena korelacija $0,9587$ je dosta visoka pa možemo reći da su podaci visoko (pozitivno) korelirani. Općenito ne postoje stroga kvantitativna pravila koja bi određivala kada su podaci značajno ili slabo korelirani, ali možemo reći da vrijednosti korelacije veće od $0,75 - 0,8$ indiciraju dosta visoku (pozitivnu) povezanost podataka, dok vrijednosti korelacije manje od $-0,75$ ili $-0,8$ indiciraju dosta visoku (negativnu) povezanost podataka. Koeficijent korelacije koji je manji, po apsolutnoj vrijednosti, od $0,3$ ukazuju na nekoreliranost podataka, odnosno na njihovu nisku razinu međusobne povezanosti. Jasno, za $\rho = 1$ su podaci savršeno pozitivno korelirani, za $\rho = -1$ su savršeno negativno korelirani, dok su za $\rho = 0$ nekorelirani. U praksi se ovakve vrijednosti koeficijenta korelacije rijetko pojavljuju. □

Važno upozorenje: korelacija mjeri međuovisnost podataka, ali ne i njihovu kauzalnost (uzročno-posljedičnu vezu). Visoka korelacija ne znači da je uzrok nekog svojstva (pojave) onaj za koji je izmerena visoka korelacija. Često se može naći neki treći faktor koji može objasniti zajedničko "gibanje" promatranih nizova podataka koji su visoko korelirani. Na primjer, ako mjerimo brzinu okretanja lopatica neke vjetroturbine i brzine vjetra uočit ćemo da su te dvije veličine (nizovi izmjerenih podataka) visoko korelirane. Jasno, iz toga nećemo zaključiti da brzo okretanje lopatica uzrokuje veću brzinu vjetra, iako je korelacija visoka. Ovo je jednostavan primjer u kojem znamo da postoji upravo suprotna kauzalna veza, ali ukazuje na problem zaključivanja korištenjem korelacije.

U R-u je implementirana funkcija `cor()`) koja računa korelaciju dva niza brojeva. Možemo provjeriti izračun iz Primjera 2.6.1. Imamo

```
> xv<-c(-2,0,2,4,4); yv<-c(2,2,3,4,4)
> cor(xv, yv)

[1] 0.9587062
```

Za dodatnu ilustraciju uzmimo podatke BMI Prisjetimo se da smo imali zadana tri niza kvantitativnih podataka: težinu

```
> kvant$Tezina

 [1] 60 80 85 84 62 65 86 86 95 78 70 68
```

visinu

```
> kvant$Visina

 [1] 165 180 175 184 168 175 184 192 182 178 175 170
```

i indeks tjelesne mase

```
> options(width=75)
> kvant$BMI

 [1] 22.03857 24.69136 27.75510 24.81096 21.96712 21.22449 25.40170
 [8] 23.32899 28.68011 24.61810 22.85714 23.52941
```

Možemo se zapitati da li su, na primjer, visina i BMI nekako povezani. Izračunajmo njihovu korelaciju

```
> cor(kvant$Visina, kvant$BMI)

[1] 0.3990429
```

Vidimo da je dobivena vrijednost korelacije približno jednaka $0,4$. Za usporedbu izračunajmo korelaciju između težine i visine

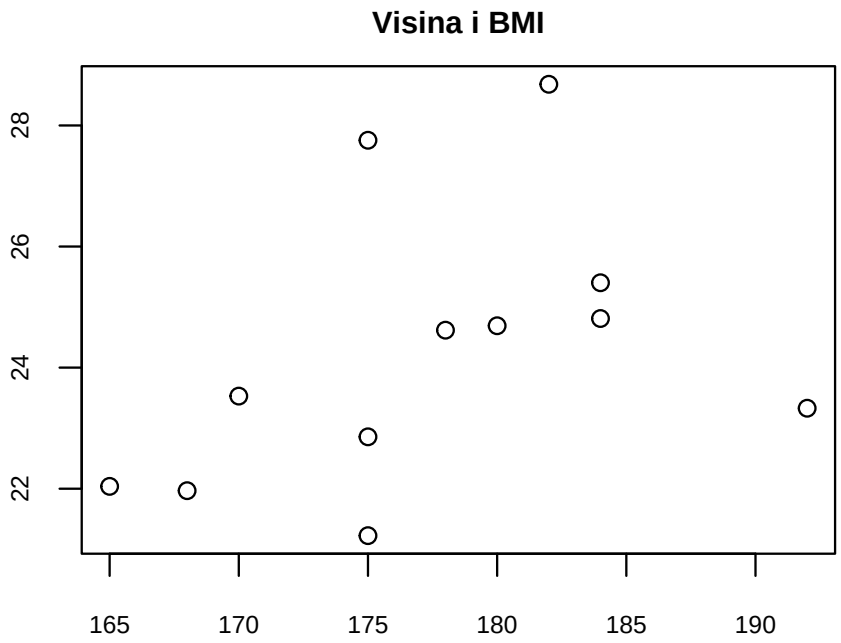
```
> cor(kvant$Visina, kvant$Tezina)

[1] 0.8160658
```

U ovom slučaju je korelacija dosta veća i iznosi $0,816$. Veća vrijednost korelacije (koeficijenta korelacije) indicira veću povezanost, međuovisnost, promatranih nizova podataka. Uočavamo da su težina i visina dosta povezanije (pozitivno koreliranije) od visine i BMI-a. Zaključili bi, barem prema promatranom uzorku podataka, da je jača veza između težine i visine, nego između visine i BMI-a.

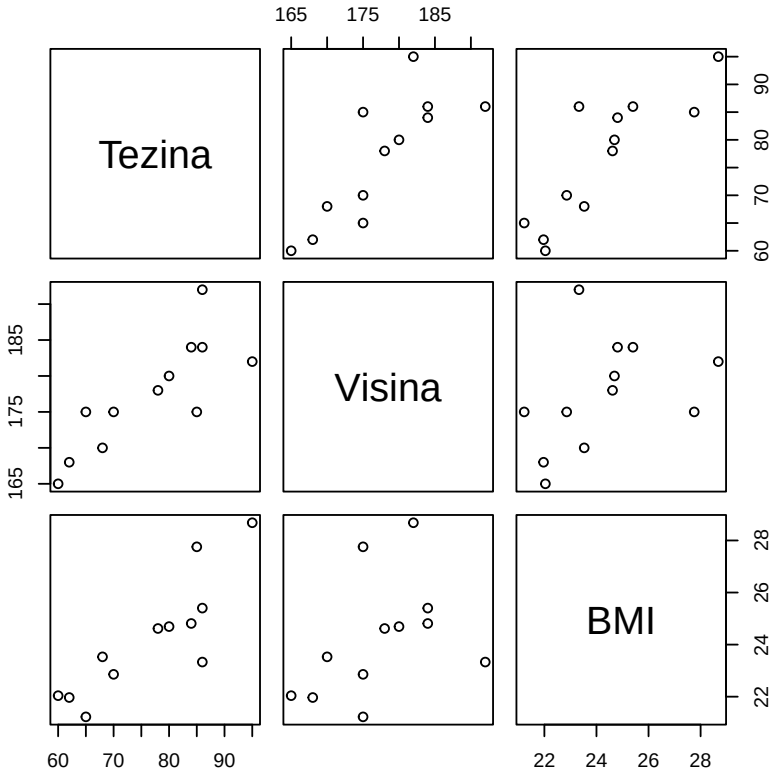
Ukoliko želimo vizualno utvrditi povezanost podataka najčešće se upotrebljava tzv. scatterplot, odnosno dijagram raspršenosti, koji u R-u dobivamo "običnom" funkcijom `plot()`). Tako za visinu i BMI dobivamo sljedeći prikaz

```
> par(mar=c(2,2,2,1))
> plot(kvant$Visina, kvant$BMI, main="Visina i BMI",
+      cex.axis=0.7, cex.main=0.8)
```



R omogućava da se svi takvi grafovi za neke kvantitativne nizove iscrtaju na istom grafu i to korištenjem funkcije `pairs()`. Tako za visinu, težinu i BMI možemo dobiti sljedeći skup grafova

```
> pairs(kvant[, c(3,4,5)])
```



S gornje slike bi mogli naslutiti da su Tezina i BMI dosta povezani. To nam potvrđuje izračun njihovog koeficijenta korelacije

```
> cor(kvant$BMI, kvant$Tezina)

[1] 0.8546543
```

Vizualno, pozitivno visoko korelirane podatke možemo prepoznati tako da uočimo da podaci približno leže na pravcu kojemu je koeficijent smjera pozitivan. Slično je za negativno visoko korelirane podatke, s time da je koeficijent smjera pravca na kojem leže podaci negativan. Ukoliko su podaci raštrkani korelacija će biti mala, odnosno bliska nuli. Vratit ćemo se na izračun korelacije malo kasnije kada ćemo promotriti još neke primjere podataka.

2.7 Primjeri osnovne analize podataka

U ovom odjeljku ćemo pogledati nekoliko skupova podataka i vidjeti što možemo reći o njima koristeći se pojmovima i alatima koje smo uveli u ovom poglavlju. Dodatno ćemo upoznati još neke R-ove funkcije koje su korisne za manipulaciju i obradu podataka.

Primjer 2.7.1 (Skok u vis)**.** Učitat ćemo podatke o rezultatima koje su postigli juniori u Hrvatskoj u atletskoj disciplini skok u dalj u 2022. godini. Podaci su spremljeni u Excel tablici "Skok-u-dalj", a vrijednost te tablice ćemo pridružiti varijabli `dalj`, koja će biti data frame

```
> dalj<-read.xlsx("Skok-u-dalj.xlsx",sheetName ="Skok-u-vis",header=F)
> dalj
```

	X1	X2	X3	X4	X5	X6
1	7.51	Roko	F	2005-02-11	Zagreb	2022-09-03
2	7.24	Vito	K	2005-05-03	Zagreb	2022-05-21
3	6.85	David	P	2007-03-05	Varaždin	2022-06-19
4	6.64	Toma	B	2007-05-06	Split	2022-04-30
5	6.60	Filip	S	2003-03-31	Zagreb	2022-05-21
6	6.37	Domagoj	B	2005-08-20	Rijeka	2022-05-10
7	6.35	Zvonimir	T	2003-09-03	Leibnitz	2022-05-28
8	6.07	Karlo	M	2003-12-27	Rijeka	2022-06-08
9	5.99	Marko	T	2006-08-17	Ljubljana	2022-06-27
10	5.96	Frano	P	2007-03-16	Varaždin	2022-05-07
11	5.91	Emilio	P	2007-05-06	Varaždin	2022-05-07
12	5.91	Lovro	R	2004-05-15	Zagreb	2022-09-17
13	5.90	Mihael	P	2007-02-21	Zagreb	2022-07-09
14	5.90	Daniel	S	2006-12-12	Split	2022-08-27
15	5.85	Luka	P	2005-05-12	Rijeka	2022-05-10
16	5.85	Andrej	B	2003-08-05	Zagreb	2022-09-24
17	5.82	David	D	2005-08-03	Zadar	2022-05-22
18	5.77	Filip	P	2003-09-19	Zagreb	2022-06-12
19	5.77	Gabriel	B	2008-02-06	Zagreb	2022-09-14
20	5.72	Karlo	B	2005-02-25	Rijeka	2022-06-08
21	5.72	Bernard	B	2004-03-11	Osijek	2022-08-25
22	5.54	Matej	M	2004-01-21	Zagreb	2022-09-24
23	5.51	Borna	C	2007-04-11	Karlovac	2022-05-22
24	5.51	Luka	K	2007-07-28	Split	2022-08-27

```
25 5.51     Leon  S 2006-09-26    Zagreb 2022-09-24
26 5.50    Tomas  J 2007-07-15  Varaždin 2022-06-19
27 5.49     Ivan  P 2008-02-04    Rijeka 2022-06-08
28 5.46    Lovro  S 2007-04-28    Zagreb 2022-09-17
29 5.44      Noa  L 2007-08-09    Zagreb 2022-09-14
30 5.42      Noa  S 2009-03-10    Zagreb 2022-09-14
```

Vidimo da stupci (u kojima su sadržani podaci različitih tipova) nemaju imena, odnosno imaju automatski pridružena imena od strane R-a. Iako bi mogli nastaviti raditi i s takvim data frameom, pridružit ćemo stupcima neka prirodna imena

```
> names(dalj)<-c("daljina","ime","prezime","rodjenje","klub","dat_skok")
```

Pogledajmo od čega se sastoji data frame `dalj`. Sjetimo se, u tu svrhu je praktično iskoristiti funkciju `str`.

```
> str(dalj)
```

```
'data.frame':        30 obs. of  6 variables:
 $ daljina : num  7.51 7.24 6.85 6.64 6.6 6.37 6.35 6.07 5.99 5.96 ...
 $ ime     : chr  "Roko" "Vito" "David" "Toma" ...
 $ prezime : chr  "F" "K " "P" "B" ...
 $ rodjenje: Date, format: "2005-02-11" "2005-05-03" ...
 $ klub    : chr  "Zagreb" "Zagreb" "Varaždin" "Split" ...
 $ dat_skok: Date, format: "2022-09-03" "2022-05-21" ...
```

Uočimo da imamo samo jedan numerički vektor te da imamo ukupno 30 podataka (30 redaka). Stupci `rodjenje` i `dat_skok` su tipa datum, što znači da su se mogu urediti. Tako, na primjer, možemo sortirati stupac `rodjenje`

```
> sort(dalj$rodjenje)
```

```
 [1] "2003-03-31" "2003-08-05" "2003-09-03" "2003-09-19" "2003-12-27"
 [6] "2004-01-21" "2004-03-11" "2004-05-15" "2005-02-11" "2005-02-25"
[11] "2005-05-03" "2005-05-12" "2005-08-03" "2005-08-20" "2006-08-17"
[16] "2006-09-26" "2006-12-12" "2007-02-21" "2007-03-05" "2007-03-16"
[21] "2007-04-11" "2007-04-28" "2007-05-06" "2007-05-06" "2007-07-15"
[26] "2007-07-28" "2007-08-09" "2008-02-04" "2008-02-06" "2009-03-10"
```

Pokušajmo sada iskoristiti prije naučeno da se bolje upoznamo s podacima koje smo dobili. Za početak pogledajmo `summary`. Kao što smo već istaknuli, funkcija `summary` će za nenumeričke podatke dati samo opis tipa podataka i njihov broj. Za numeričke podatke ćemo dobiti srednju i središnju vrijednost (aritmetičku sredinu i medijan), raspon podataka te kvartile.

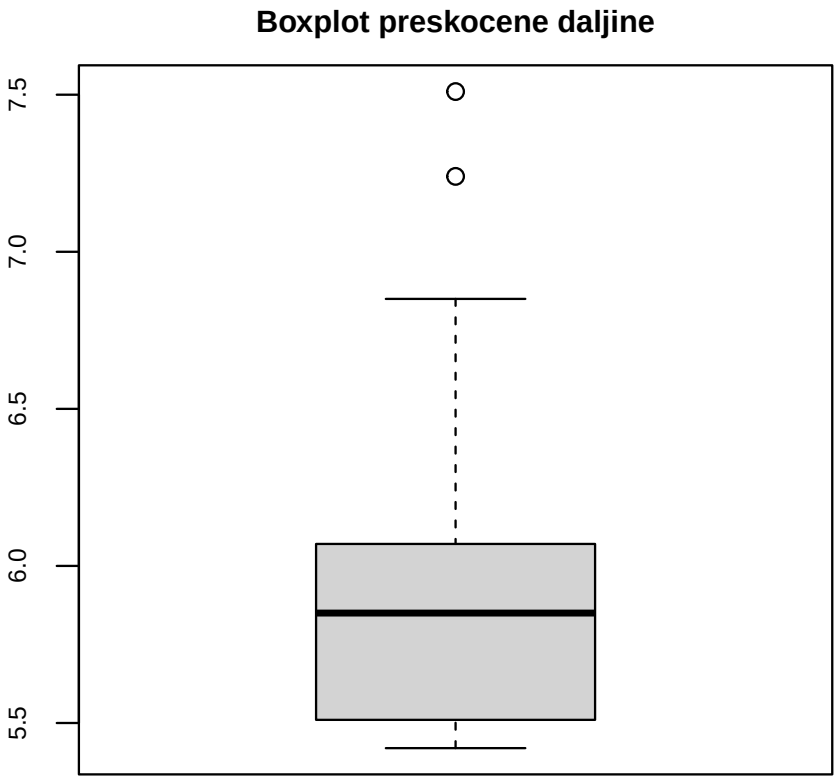
```
> summary(dalj)
```

```
    daljina          ime              prezime
 Min.   :5.420   Length:30          Length:30
 1st Qu.:5.518   Class :character   Class :character
 Median :5.850   Mode  :character   Mode  :character
 Mean   :5.969
 3rd Qu.:6.050
 Max.   :7.510
```

```
    rodjenje              klub              dat_skok
 Min.   :2003-03-31   Length:30          Min.   :2022-04-30
 1st Qu.:2004-07-22   Class :character   1st Qu.:2022-05-22
 Median :2006-09-06   Mode  :character   Median :2022-06-19
 Mean   :2006-01-27                      Mean   :2022-07-10
 3rd Qu.:2007-05-04                      3rd Qu.:2022-09-11
 Max.   :2009-03-10                      Max.   :2022-09-24
```

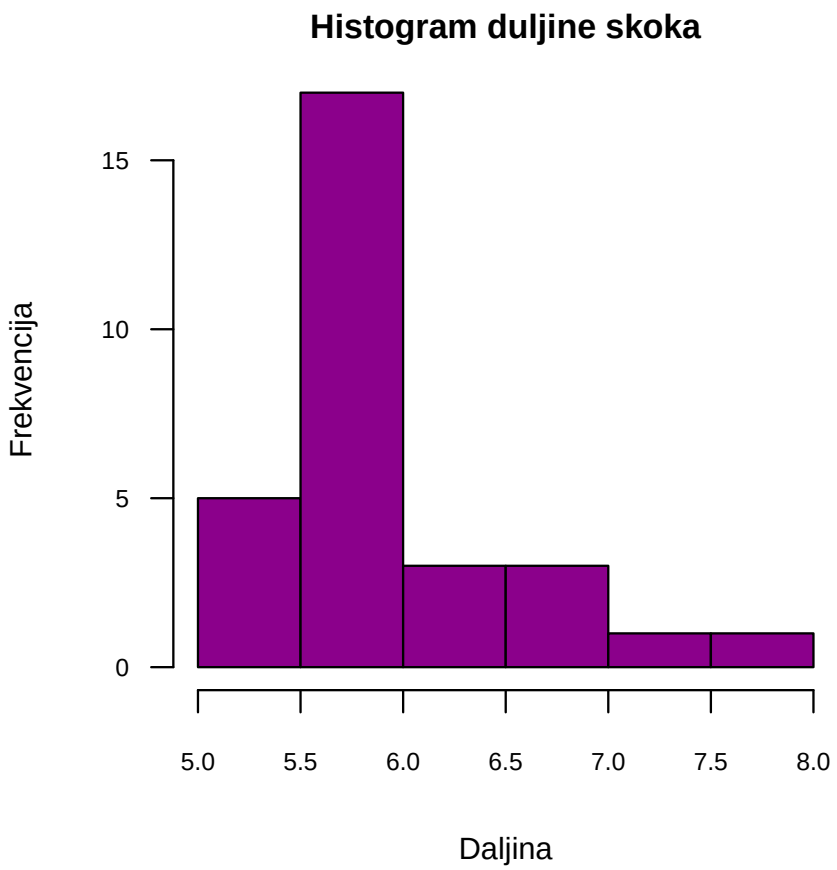
Vidimo da je kod daljine skoka prosječna daljina skoka veća od medijana, što indicira da ima podataka koji značajno odstupaju od prosjeka (aritmetičke sredine). Uočimo da je maksimum vektora `daljina` dosta veći od trećeg kvartila što nam inidicira da neki od podataka o daljini skoka dosta odstupaju od većine podataka. Naravno, opet imamo mali broj podataka pa se u to možemo i sami uvjeriti (dva su skoka preko 7 metara).

Provjerimo to boxplotom. Kao što možemo vidjeti sada su se iznad gornje horizontalne crte, koja označava maksimum podataka bez outliera, nalaze dva kružića koja označavaju outliere. Također, vidimo da je većina podataka grupirana između $5,5$ i 6 metara. Preciznije, velik broj podataka se nalazi između prvog i trećeg kvartila koji su jednaki, kao što smo vidjeli korištenjem funkcije `summary`, $5,518$ odnosno $6,05$ metara.

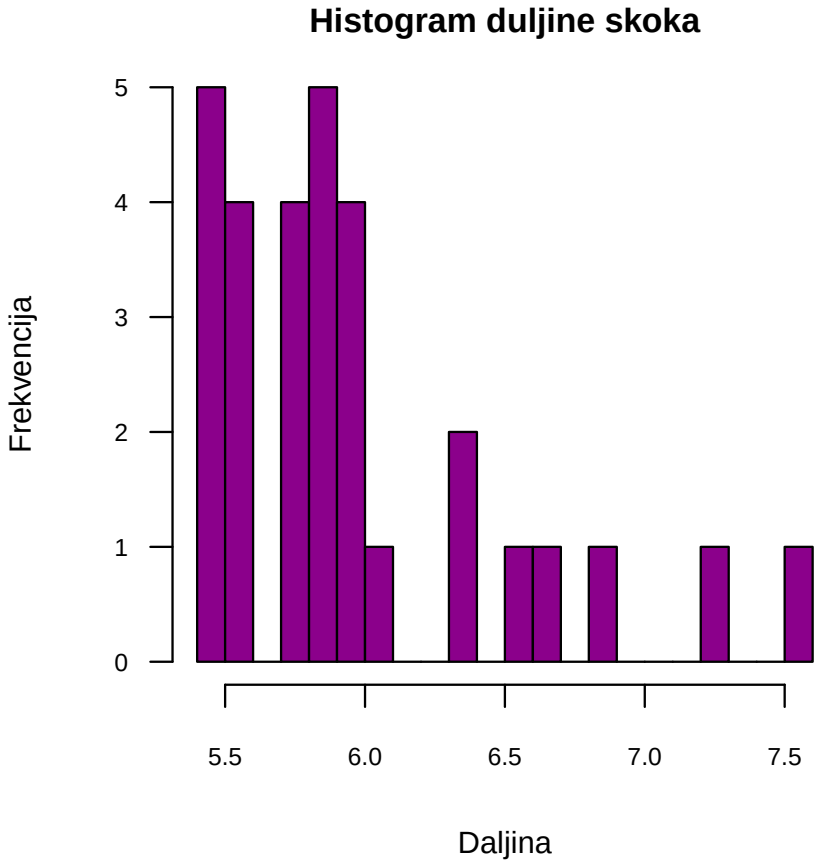


Slično zaključujemo ukoliko pogledamo histogram podataka. Na njemu jasno vidimo da je velik broj podataka (duljina skoka) grupiran u razredu histograma $(5.5, 6]$.

```
> par(mar=c(4,4,2,1))
> hist(dalj$daljina, main="Histogram duljine skoka", xlab= "Daljina",
+      ylab="Frekvencija",  las=1,
+      cex.axis=0.7, cex.lab=0.8, cex.main=0.9,
+      col="darkmagenta")
```



Možemo malo profiniti histogram, odnosno prikazati više stupića, ali zaključak ostaje isti (stavili smo `breaks = 15`)



Još jedna od mogućnosti za analizu podataka je da ih grupiramo po nekom kriteriju i onda analiziramo. U tu svrhu nam može poslužiti R funkcija `by()`. Pogledajmo primjer u kojem prikazujemo sažetak analize podataka o duljini skoka, ali grupiranima po klubovima navedenim u orginalnoj tablici.

```
> by(dalj$daljina, dalj["klub"], summary)

klub: Karlovac
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   5.51    5.51    5.51    5.51    5.51    5.51
------------------------------------------------------------
klub: Leibnitz
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   6.35    6.35    6.35    6.35    6.35    6.35
------------------------------------------------------------
klub: Ljubljana
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   5.99    5.99    5.99    5.99    5.99    5.99
------------------------------------------------------------
klub: Osijek
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   5.72    5.72    5.72    5.72    5.72    5.72
------------------------------------------------------------
klub: Rijeka
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   5.49    5.72    5.85    5.90    6.07    6.37
------------------------------------------------------------
klub: Split
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  5.510   5.705   5.900   6.017   6.270   6.640
------------------------------------------------------------
klub: Varaždin
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  5.500   5.808   5.935   6.055   6.183   6.850
------------------------------------------------------------
klub: Zadar
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   5.82    5.82    5.82    5.82    5.82    5.82
------------------------------------------------------------
klub: Zagreb
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  5.420   5.510   5.770   5.994   5.910   7.510
```

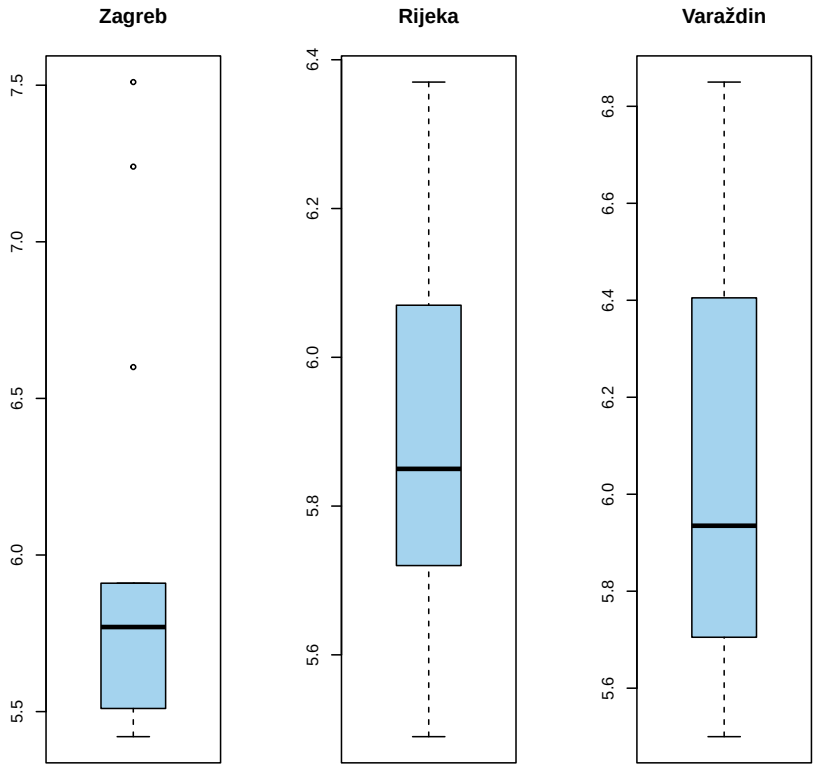
U osnovi funkcija `by` primjenjuje funkciju `summary` (navedenoj na kraju gornjeg koda) na vektor `dalj$daljina` kojega grupiramo prema vrijednostima vektora `klub`. Uvidom u dobivene podatke vidimo da većina nije prezanimljiva (ne sadrži dovoljno podataka). Recimo da nas malo preciznije zanima izanalizirati podatke za natjecatelje iz Zagreba, Rijeke, i Varaždina te da za njih želimo nacrtati boxplotove. To možemo napraviti na više načina, a jedan je naveden u sljedećem R kodu.

Najprije izdvojimo natjecatelje iz Zagreba, Rijeke, i Varaždina

```
> dalj.zg<-dalj[dalj[,"klub"]=="Zagreb",]
> dalj.ri<-dalj[dalj[,"klub"]=="Rijeka",]
> dalj.vz<-dalj[dalj[,"klub"]=="Varaždin",]
```

a zatim nacrtamo tražene grafove

```
> par(mfrow = c(1, 3))
> boxplot(dalj.zg$daljina, main="Zagreb", col="lightskyblue2");
> boxplot(dalj.ri$daljina, main="Rijeka", col="lightskyblue2");
> boxplot(dalj.vz$daljina, main="Varaždin", col="lightskyblue2")
```



Boxplotovi za Rijeku i Varaždin su, recimo, očekivani, dok je onaj za Zagreb koncentriran na prilično malim daljinama s tri značajne ekstremne vrijednosti (outliera). Mogli bi se pitati koji je razlog tome, ali uočimo da je najviše natjecatelja iz Zagreba, što možemo provjeriti

```
> nrow(dalj.zg)

[1] 13

> nrow(dalj.ri)

[1] 5

> nrow(dalj.vz)

[1] 4
```

Stoga se čini razumnim pretpostaviti da je veći broj natjecatelja zapravo smanjio prosječne rezultate. Vidimo da su ostvareni maksimumi čak i najveći za Zagreb, odnosno bez dva značajna outliera bi zapravo imali slične histograme za sva tri grada.

Može nas također zanimati da li godina rođenja, među juniorima za koje su prikupljeni podaci, utječe na ostvarene rezultate. Da bi lakše manipulirali datumima dodat ćemo još jednu kolonu u naš data frame `dalj` u kojem će biti navedena samo godina rođenja i to kao numerički podatak

```
> dalj$godina <- as.numeric(format(dalj$rodjenje, "%Y"))
```

Sada opet možemo dobiti sažetak podataka grupiranih po godinama rođenja, koristeći se prije uvedenom funkcijom `by` (vrijedi napomenuti da R ima i funkciju `aggregate()` koja omogućava slične operacije).

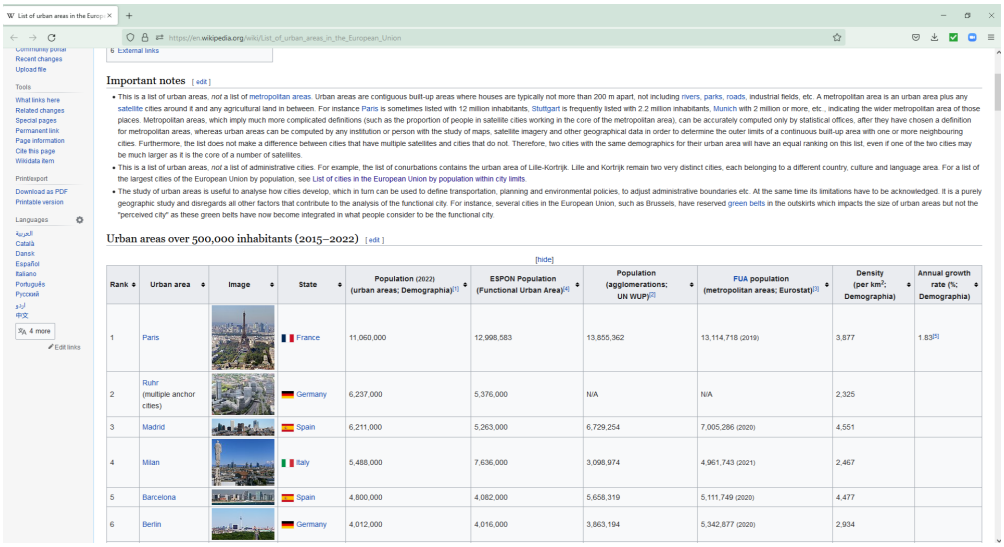
```
> by(dalj$daljina, dalj["godina"], summary)

godina: 2003
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  5.770   5.850   6.070   6.128   6.350   6.600
------------------------------------------------------------
godina: 2004
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  5.540   5.630   5.720   5.723   5.815   5.910
------------------------------------------------------------
godina: 2005
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  5.720   5.827   6.110   6.418   7.022   7.510
------------------------------------------------------------
godina: 2006
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  5.510   5.705   5.900   5.800   5.945   5.990
------------------------------------------------------------
godina: 2007
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  5.440   5.503   5.705   5.868   5.947   6.850
------------------------------------------------------------
godina: 2008
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   5.49    5.56    5.63    5.63    5.70    5.77
------------------------------------------------------------
godina: 2009
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   5.42    5.42    5.42    5.42    5.42    5.42
```

□

Primjer 2.7.2 (Najveći gradovi (urbana područja) u EU)**.** U prijašnjim primjerima smo uglavnom učitavali podatke iz Excel tablica (slično je s .csv datotekama). Na taj način možemo pristupiti različitim podatacima jer, na primjer, službene nacionalne ili EU statističke mrežne stranice pružaju mogućnost snimanja podataka u Excel tablicama. S druge strane ćemo često na mrežnim stranicama naći neke zanimljive podatke koji nisu odmah dostupni u pogodnom formatu za analizu u R-u (ili nekom drugom jeziku). Tipičan primjer predstavljaju stranice Wikipedije koje sadrže pregršt zanimljivih i vrijednih podataka, najčešće prezentiranih u obliku tablica. Tako na adresi
https://en.wikipedia.org/wiki/List_of_urban_areas_in_the_European_Union
možemo pronaći popis urbanih područja u EU koja imaju više od 500.000 stanovnika.

Pretpostavimo da nas zanimaju podaci iz tablice i da ih želimo učitati u R. Postoji više načina na koji to možemo učiniti, a u nastavku primjera ćemo pokazati kako to napraviti koristeći se skupom R paketa pod nazivom `Tidyverse`. U `Tidyverse`-u se nalaze R paketi koji su dizajnirani za tzv. *data science*, odnosno za suvremenu obradu podataka. Riječ je o relativno novom skupu paketa koji koriste donekle različitu sintaksu



Important notes [edit]

- This is a list of urban areas, *not* a list of metropolitan areas. Urban areas are contiguous built-up areas where houses are typically not more than 200 m apart, not including rivers, parks, roads, industrial fields, etc. A metropolitan area is an urban area plus any satellite cities around it and any agricultural land in between. For instance Paris is sometimes listed with 12 million inhabitants, Stuttgart is frequently listed with 2.2 million inhabitants, Munich with 2 million or more, etc., indicating the wider metropolitan area of those places. Metropolitan areas, which imply much more complicated definitions (such as the proportion of people in satellite cities working in the core of the metropolitan area), can be accurately computed only by statistical offices, after they have chosen a definition for metropolitan areas, whereas urban areas can be computed by any institution or person with the study of maps, satellite imagery and other geographical data in order to determine the outer limits of a continuous built-up area with one or more neighbouring cities. Furthermore, the list does not make a difference between cities that have multiple satellites and cities that do not. Therefore, two cities with the same demographics for their urban area will have an equal ranking on this list, even if one of the two cities may be much larger as it is the core of a number of satellites.
- This is a list of urban areas, *not* a list of administrative cities. For example, the list of conurbations contains the urban area of Lille-Kortrijk. Lille and Kortrijk remain two very distinct cities, each belonging to a different country, culture and language area. For a list of the largest cities of the European Union by population, see List of cities in the European Union by population within city limits.
- The study of urban areas is useful to analyse how cities develop, which in turn can be used to define transportation, planning and environmental policies, to adjust administrative boundaries etc. At the same time its limitations have to be acknowledged. It is a purely geographic study and disregards all other factors that contribute to the analysis of the functional city. For instance, several cities in the European Union, such as Brussels, have reserved green belts in the outskirts which impacts the size of urban areas but not the "perceived city" as these green belts have now become integrated in what people consider to be the functional city.

Urban areas over 500,000 inhabitants (2015–2022) [edit]

[hide]

Rank	Urban area	Image	State	Population (2022) (urban areas; Demographia)[1]	ESPON Population (Functional Urban Area)[4]	Population (agglomerations; UN WUP)[2]	FUA population (metropolitan areas; Eurostat)[3]	Density (per km²; Demographia)	Annual growth rate (%; Demographia)
1	Paris		France	11,060,000	12,998,583	13,855,362	13,114,718 (2019)	3,877	1.83[5]
2	Ruhr (multiple anchor cities)		Germany	6,237,000	5,376,000	N/A	N/A	2,325	
3	Madrid		Spain	6,211,000	5,263,000	6,729,254	7,005,286 (2020)	4,551	
4	Milan		Italy	5,488,000	7,636,000	3,098,974	4,961,743 (2021)	2,467	
5	Barcelona		Spain	4,800,000	4,082,000	5,658,319	5,111,749 (2020)	4,477	
6	Berlin		Germany	4,012,000	4,016,000	3,863,194	5,342,877 (2020)	2,934	

Slika 2.1: Tablica s najvećim urbanim područjima u EU na Wikipediji

od standardnog R-a (to je relativna mana) i koji omogućavaju fleksibilno baratanje s raznim podacima (to je, naravno, prednost). Za neke osnovne informacije o `Tidyverse` posjetite mrežnu stranicu https://www.tidyverse.org/ ili stranicu R dokumentacije https://www.rdocumentation.org/packages/tidyverse/versions/2.0.0.

Jedan od paketa u `tidyverse` je paket `magrittr` koji u R uvodi tzv. "pipe" operator `%>%`. Taj operator prosljeđuje vrijednost koja se nalazi ispred njega u funkciju/izraz koji se nalazi iza njega. Uz iste oznake kao u prošlom primjeru, osnovne podatke o vektoru `dalj$daljina` možemo dobiti upotrebom funkcije `summary`

```
> summary(dalj$daljina)

   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  5.420   5.518   5.850   5.969   6.050   7.510
```

ali možemo i upotrijebiti operator `%>%` da dobijemo isti rezultat

```
> library("magrittr")
> dalj$daljina  %>% summary

   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  5.420   5.518   5.850   5.969   6.050   7.510
```

Unutar `Tidyverse`-a se nalazi paket `rvest` koji sadrži funkciju `read_html()` . Inače, R sadrži i druge funkcije za manipulaciju mrežnim podacima, poput `readLines()` ili `htmlParse()` u `XML` paketu. Više informacija o tome se može naći i na CRAN Task View: Web Technologies and Services na adresi https://cran.rstudio.org/web/views/WebTechnologies.html. Možete pogledati i blog o pristojnom *scrapanju* tablica na Wikipediji https://ivelasq.rbind.io/blog/politely-scraping/.

Iskoristit ćemo funkciju `read_html` da bi pročitali sadržaj stranice https://en.wikipedia.org/wiki/List_of_urban_areas_in_the_European_Union. Iskoristit ćemo operator pipe `%>%` da izdvojimo sve tablice na toj stranici te ćemo ih ispuniti podacima. Rezultat spremamo u varijablu `eu` da ne bi automatski dobili ispis svih tablica na stranici. S obzirom da je adresa s koje skidamo podatke dosta dugačka, ispis R koda ne bi stao u jedan red. Stoga smo iskoristili funkciju `paste0()` koja zaista samo spaja dva niza znakova. Uočite da smo to napravili samo radi preglednijeg prikaza.

```
> library(rvest)
> wikistr<-"https://en.wikipedia.org/wiki/"
> listurban<-"List_of_urban_areas_in_the_European_Union"
>  eu<-read_html(paste0(wikistr,listurban))%>%
+    html_nodes(css = "table")%>% html_table(fill = T)
```

Varijabla `eu` je lista koja sadrži 13 elemenata.

```
> typeof(eu)

[1] "list"

> length(eu)

[1] 14
```

Ispisom elemenata vidimo da je tablica koju želimo zapravo prvi element liste. Izdvojit ćemo samo nju. Cijeli elementi liste se izdvajaju dvostrukim uglatim zagradama.

```
> eu<-eu[[1]]
```

Ispišite sami listu `eu` da vidite od čega se sastoji. U osnovi nas zanima drugi, četvrti i peti stupac liste, a možemo uključiti i deveti (gustoća naseljenosti). Dodatno, pretvorit ćemo listu u data frame da možemo lakše baratati podacima. Definirajmo novu varijablu `eu_cities` (iako nije nužno) te pogledajmo funkcijom `str` od čega se sastoji novonastali data frame (upotrijebili smo neke parametre funkcije `str` radi ispravnog prikaza unutar PDF dokumenta)

```
> eu_cities<-as.data.frame(eu[, c(2,4,5,9)])
> str(eu_cities, width=73, strict.width="cut")

'data.frame':        70 obs. of  4 variables:
 $ Urban area                                        : chr  "Paris" "Ruhr"..
 $ State                                             : chr  "France" "Ger"..
 $ Population (2022) (urban areas; Demographia)[1]: chr  "14,800,000[5"..
 $ Density(per km2; Demographia)                     : chr  "3,877" "2,32"..
```

Vidimo da svi vektori od `eu_cities` imaju imena, ali su malo nezgrapna pa ćemo ih zamijeniti. Dodatno, dva numerička vektora koji nas zanimaju su tipa `character` pa ćemo ih konvertirati u `numeric`. S obzirom da su ti brojevi zapisani sa zarezima trebat ćemo ih prethodno "izbrisati". To možemo napraviti R funkcijom `gsub()` koja znak koji navedemo zamijeni sljedećim znakom koji navedemo (sve u navodnicima). Ovdje zarez mijenjamo s praznom riječi (znakom).

```
> names(eu_cities)=c("Grad", "Drzava", "BrojSt", "Gustoca")
> eu_cities$BrojSt<-as.numeric(gsub(",","",eu_cities$BrojSt))
> eu_cities$Gustoca<-as.numeric(gsub(",","",eu_cities$Gustoca))
> str(eu_cities, vec.len=3)

'data.frame':        70 obs. of  4 variables:
 $ Grad   : chr  "Paris" "Ruhr(multiple anchor cities)" "Madrid" ...
 $ Drzava : chr  "France" "Germany" "Spain" ...
 $ BrojSt : num  NA 6237000 6211000 5488000 ...
 $ Gustoca: num  3877 2325 4551 2467 ...
```

Možemo uočiti da se i Zagreb nalazi na listi gradova koje smo izdvojili i to na 58. mjestu popisa najvećih urbanih područja u EU.

```
> eu_cities[58,]

     Grad  Drzava BrojSt Gustoca
58 Zagreb Croatia 630000    3379
```

Također, možemo prikazati i 10 gradova, odnosno urbanih područja, u EU koja imaju najveću gustoću naseljenosti. U tu svrhu prvo trebamo sortirati `eu_cities` po gustoći naseljenosti, dakle po stupcu `eu_cities$Gustoca` i to u padajućem redosljedu. To možemo napraviti funkcijom `order()` na sljedeći način:
`eu_cities[order(eu_cities$Gustoca, decreasing = TRUE),]`.
Nakon toga iskoristimo funkciju `head()` koja vraća početak objekta koji promatramo (funkcija `tail` vraća završetak objekta). Imamo

```
> head(eu_cities[order(eu_cities$Gustoca, decreasing = TRUE),], 10)

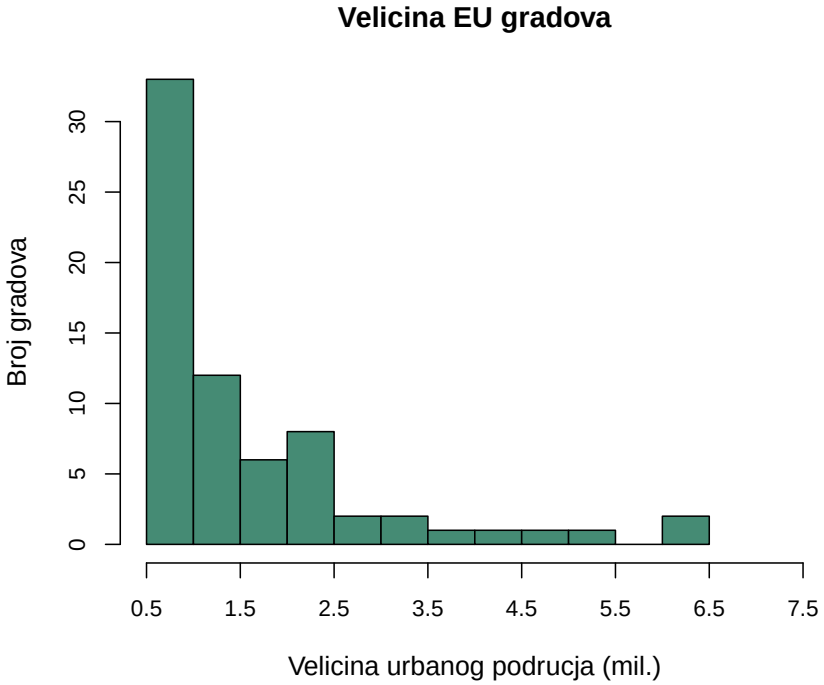
           Grad   Drzava  BrojSt Gustoca
67        Genoa    Italy  540000    6950
22       Vienna  Austria 1890000    5614
8        Athens   Greece 3450000    5290
46       Bilbao    Spain  775000    5250
51       Málaga    Spain  686000    5094
69   Santa Cruz    Spain  506000    4652
38 Sofia-Pernik Bulgaria 1428000    4571
3        Madrid    Spain 6211000    4551
23    Bucharest  Romania 1862000    4522
5     Barcelona    Spain 4800000    4477
```

Mogli smo dobiti isti rezultat i na druge načine. Na primjer, jedan konzervativan način bi bio

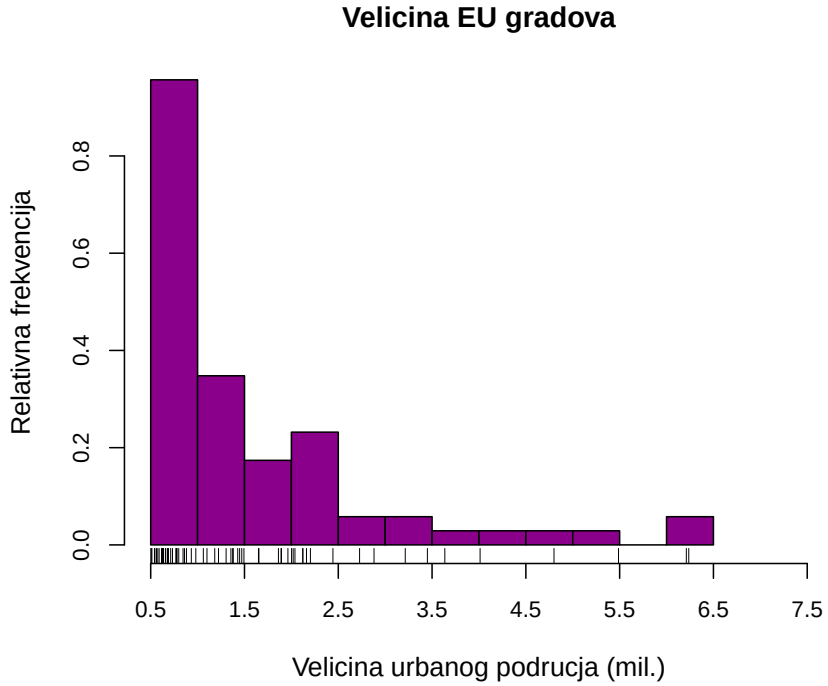
```
> eu_sort_gust<-eu_cities[order(eu_cities$Gustoca, decreasing = TRUE),]
> eu_sort_gust[1:10,]
```

U osnovi sada možemo napraviti analize poput onih iz prethodnih primjera. Na primjer, možemo pogledati histogram frekvencija veličine gradova. Uočite da smo izdvojili opis x-osi korištenjem funkcije `axis`. Njen prvi argument određuje na koju stranicu grafa dodajemo dodatne oznake (1 određuje x-os, 2 y-os, a moguće je s 3 i 4 nanijeti oznake i iznad te s desne strane grafa). Oznake na x osi smo nanijeli korištenjem funkcije `seq` s kojom smo se susreli u prvom poglavlju.

```
> par(mar=c(5,4,3,2))
> hist(eu_cities$BrojSt/1000000, main="Velicina EU gradova",
+      xlab= "Velicina urbanog podrucja (mil.)",  breaks=11,
+      xlim=c(0.5, 7.5), xaxt="n", ylab="Broj gradova",
+      cex.main=1.2, cex.lab=1.1, cex.axis=0.9, col="aquamarine4")
> axis(1, at=seq(0.5, 7.5, by=1), labels= seq(0.5, 7.5, by=1),
+      cex.axis=0.9)
```



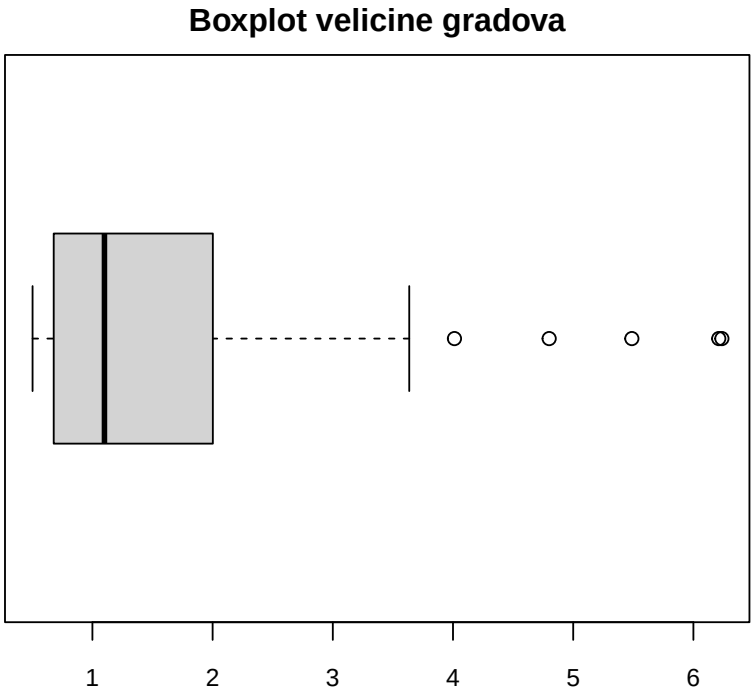
Na sličan način možemo napraviti i histogram relativnih frekvencija. Na dno grafa smo dodali 1-dimenzionalni graf podataka sadržanih u vektoru `eu_cities$BrojSt` koji smo podijelili s milion. Za to smo iskoristili funkciju `rug()`. To je korisno da se dodatno vizualizira koncentracija varijable koju analiziramo, odnosno prikazujemo.



Naravno, korisno je pogledati i boxplot. Kao što smo već uočili, najveći broj podataka je oko 600.000 pa imamo dosta outliera, odnosno gradova (urbanih područja) u kojima živi više od 4 miliona ljudi. S druge strane, gotovo polovina promatranih gradova ima manje od milion stanovnika.

```
> par(mar=c(2,2,2,2))
```

```
> boxplot(eu_cities$BrojSt/1000000, main="Boxplot velicine gradova",
+         cex.axis=0.8, cex.main=1.1, horizontal=TRUE)
```



U Primjeru 2.7.1 smo upoznali funkciju `by` kojom možemo selektirati podatke iz nekog data framea. Slično možemo napraviti i funkcijom `aggregate()`, kao što pokazuje donji primjer.

```
> aggregate(eu_cities$BrojSt, by= list(eu_cities$Drzava), FUN=sum)
```

```
            Group.1        x
1           Austria  1890000
2           Belgium  3264000
3          Bulgaria  1428000
4           Croatia   630000
5    Czech Republic  1183000
6           Denmark  1649000
7           Finland  1223000
8            France       NA
9  France,  Belgium  1304000
10          Germany 24237000
11           Greece  4331000
12          Hungary  2443000
13          Ireland  2123000
14            Italy 17310000
15           Latvia   615000
16        Lithuania   545000
17      Netherlands  5267000
18           Poland  7463000
19         Portugal  4082000
20          Romania  1862000
21            Spain 17300000
22           Sweden  2750000
```

Argument funkcije `aggregate()` `by` određuje kojim ćemo podacima grupirati prvonavedene, a argumentom `FUN` određujemo kou ćemo funkciju primijeniti na tako grupirane (agregirane) podatke. Donji kod daje potpuno istu vrijednost funkcije `aggregate`

```
> aggregate(BrojSt ~ Drzava, data= eu_cities, FUN=sum)
```

Njegova je prednost to što kao imena stupaca čuva prvobitno definirana imena stupaca u data frameu `eu_cities` (isprobajte). Tip podataka koji generira funkcija `aggregate` je opet data frame. To nam omogućava da primijenimo `aggregate` s različitim funkcijama, spojimo dobivene data frameove, a onda ih još i sortiramo po gustoći stanovnika. Primjer toga smo prikazali u donjem kodu. Uočimo da smo odabrali samo prvih 20 najvećih gradova. Isti bi se rezultat dobio da se promijeni drugo ime u `df2` s `names(df2)<-c("Drzava", "Gustoca")` (inače bi imali iste nazive kolona i u `df1` i u `df2`), a zatim se primjeni funkcija `merge` kao `merge(df1, df2, by = "Drzava")` te se sortiranje obavi na isti način.

```
> df1<-aggregate(BrojSt ~ Drzava, data= eu_cities, FUN=sum,
+                subset = c(1:20))
> df2<-aggregate(BrojSt ~ Drzava, data= eu_cities, FUN=length,
+                subset =c(1:20))
> df<-cbind.data.frame(df1, df2[, 2])
> names(df)<-c("Drzava", "Stanovnici", "Broj_gradova")
> df[order(df$Broj_gradova, decreasing=TRUE),]
```

```
        Drzava Stanovnici Broj_gradova
2      Germany   18469000            6
6        Italy   12338000            3
10       Spain   11011000            2
1      Belgium    2203000            1
3       Greece    3450000            1
4      Hungary    2443000            1
5      Ireland    2123000            1
7  Netherlands    2881000            1
8       Poland    1963000            1
9     Portugal    2727000            1
11      Sweden    2121000            1
```

Isti se rezultat može napraviti na još nekoliko načina. Ukoliko želimo iskoristiti operator `%>%` trebamo prvo učitati paket `dplyr` a zatim izvršiti sljedeći kod

```
> group_by(eu_cities[1:20,],Drzava) %>%
+   mutate(Stanovnici=sum(BrojSt), Broj_gradova = n() ) %>%
+    summarise(across(c(Broj_gradova, Stanovnici), unique)) %>%
+     arrange(desc(Broj_gradova))
```

```
# A tibble: 12 × 3
   Drzava      Broj_gradova Stanovnici
   <chr>              <int>      <dbl>
 1 Germany                6   18469000
 2 Italy                  3   12338000
 3 Spain                  2   11011000
 4 Belgium                1    2203000
 5 France                 1         NA
 6 Greece                 1    3450000
```

```
 7 Hungary                1    2443000
 8 Ireland                1    2123000
 9 Netherlands            1    2881000
10 Poland                 1    1963000
11 Portugal               1    2727000
12 Sweden                 1    2121000
```

Još jedno rješenje s istim rezultatom se dobije korištenjem tablica

```
> library(data.table)
> dtdf<-setDT(eu_cities[1:20,])[,list(Broj_gradova=.N,
+                 Stanovnici    =sum(BrojSt)), by=Drzava]
> dtdf[order(dtdf$Broj_gradova, decreasing=TRUE),]
```

```
         Drzava Broj_gradova Stanovnici
 1:     Germany            6   18469000
 2:       Italy            3   12338000
 3:       Spain            2   11011000
 4:      France            1         NA
 5:      Greece            1    3450000
 6: Netherlands            1    2881000
 7:    Portugal            1    2727000
 8:     Hungary            1    2443000
 9:     Belgium            1    2203000
10:     Ireland            1    2123000
11:      Sweden            1    2121000
12:      Poland            1    1963000
```

Kao što vidimo, u R-u se dosta problema/zadataka može riješiti na više načina. Teško je reći koji je od njih najbolji, ali prvo rješenje je blisko općenitim definicijama i manipulacijama tipovima podataka u R-u, dok je zadnje vrlo specifično vezano uz manipulacije tablicama u R-u. U smislu razvoja i približavanja R-a strukturiranom programiranju drugo prikazano rješenje bi se moglo preferirati. Autoru je najbliskije prvo prikazano rješenje. □

Primjer 2.7.3 (Podaci u R paketima)**.** Velik broj R paketa dolazi s raznim podacima koji su vrlo korisni za usavršavanje vještina potrebnih za baratanje podacima, odnosno analizu podataka. Popis skupova podataka koji se nalaze u pojedinom paketu može se pogledati naredbom `data(package="ime_paketa")`. Tako se, na primjer, u R-ovom paketu `datasets` nalazi skup podataka `faithful` koji sadrži podatke o erupcijama gejzira Old Faithful koji se nalazi u američkom Nacionalnom parku Yellowstone. Taj gejzir je poznat po relativno pravilnim erupcijama koje se događaju svakih 40 minuta do dva sata. U skupu podataka `faithful` nalaze se dvije kolone s 272 podatka. U prvoj koloni je navedeno vrijeme trajanja erupcije, a u drugoj vrijeme do sljedeće erupcije (u minutama). Ime prvog stupca je `eruptions`, a ime drugog stupca je `waiting`. S obzirom na broj redaka, nećemo isprintati sve elemente tog skupa podataka, nego ćemo odmah pogledati njihovu strukturu, sažetak podataka i boxplotove.

```
> library("datasets")
> str(faithful)
```

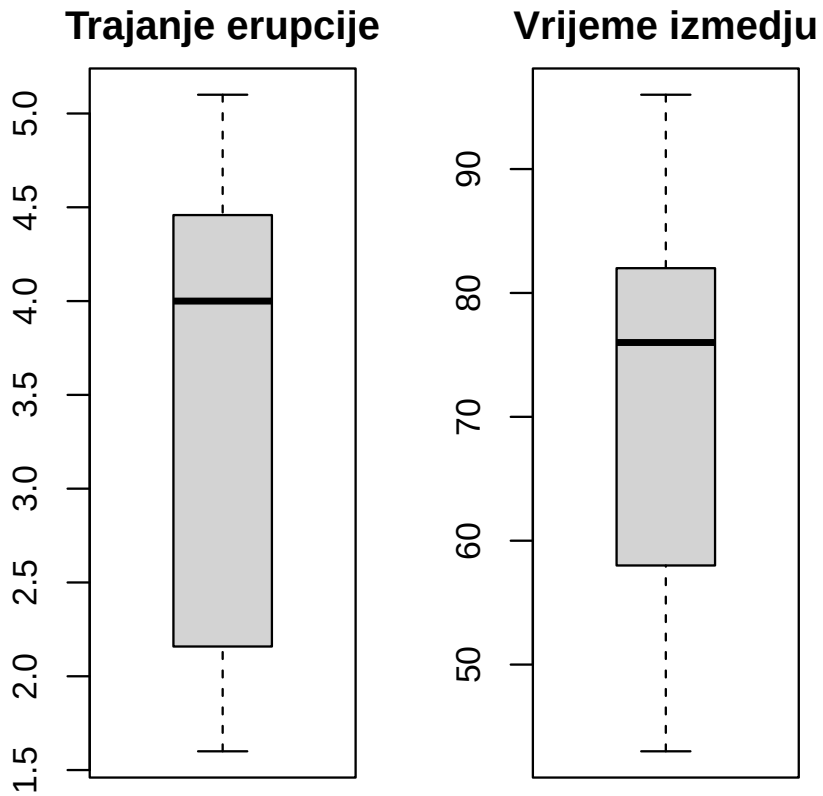
```
'data.frame':        272 obs. of  2 variables:
 $ eruptions: num  3.6 1.8 3.33 2.28 4.53 ...
 $ waiting  : num  79 54 74 62 85 55 88 85 51 85 ...
```

```
> summary(faithful)

   eruptions        waiting
 Min.   :1.600   Min.   :43.0
 1st Qu.:2.163   1st Qu.:58.0
 Median :4.000   Median :76.0
 Mean   :3.488   Mean   :70.9
 3rd Qu.:4.454   3rd Qu.:82.0
 Max.   :5.100   Max.   :96.0
```

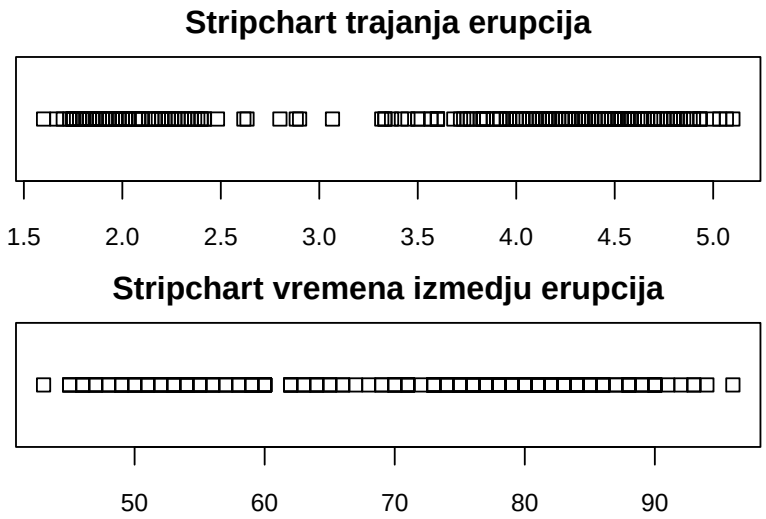
Vidimo da je prosjek podataka manji od medijana pa zaključujemo da oba niza podataka sadrže udaljenije male podatke od medijana u odnosu na veće podatke (dulje trajanje erupcija, odnosno razmak između njih).

```
> par(mfrow = c(1, 2),mar=c(2,2,2,2))
> boxplot(faithful$eruptions, main="Trajanje erupcije",
+         cex.main=1.1, cex.axis=0.9)
> boxplot(faithful$waiting, main="Vrijeme izmedju",
+         cex.main=1.1, cex.axis=0.9)
```



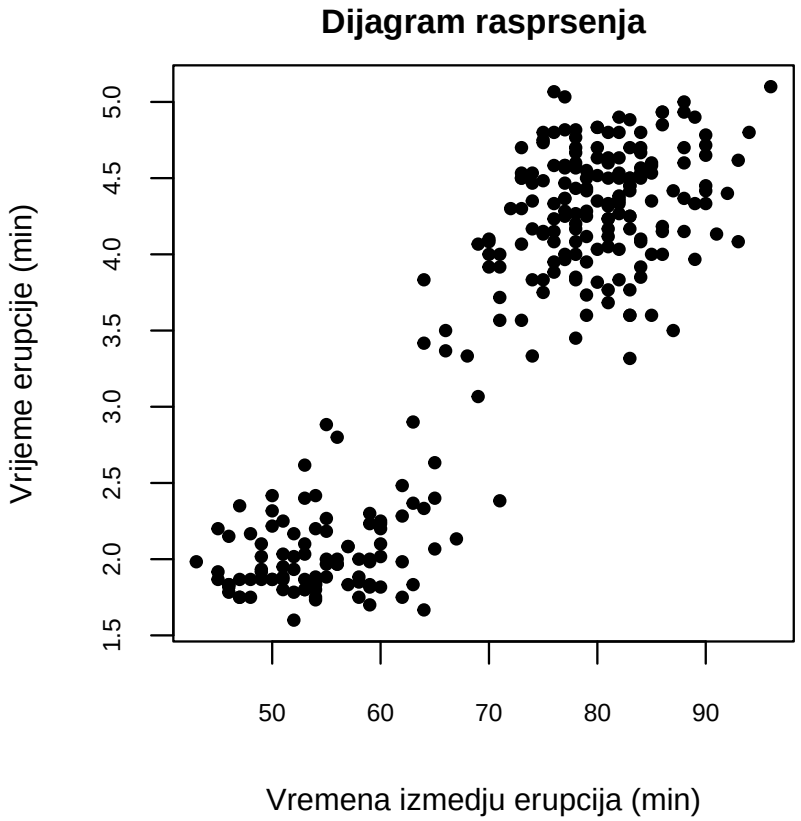
Možemo pogledati i jednodimenzionalne grafove za obje komponente podataka sadržanih u `faithful`

```
> par(mfrow = c(2, 1), mar=c(2,2,2,2))
> stripchart(faithful$eruptions, jitter=TRUE, cex.axis=0.8,
+            main="Stripchart trajanja erupcija",cex.main=1.1)
> stripchart(faithful$waiting, jitter=TRUE, cex.axis=0.8,
+            main="Stripchart vremena izmedju erupcija", cex.main=1.1)
```



Stripchart je još jedan tip grafova u R-u. Pogledajmo dijagram raspršenja (scatterplot) podataka

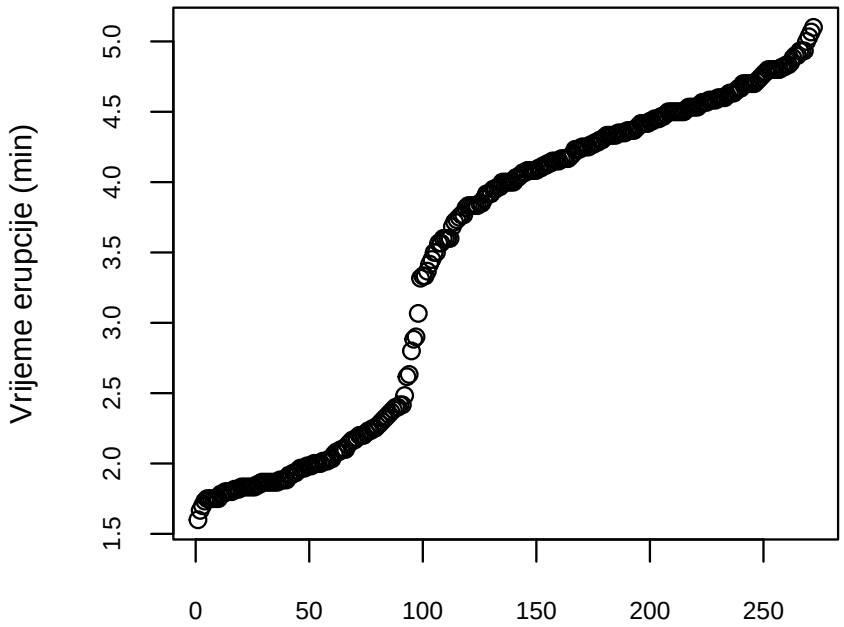
```
> par(mar=c(5,4,2,2))
> plot(faithful$waiting, faithful$eruptions, pch=20, cex.lab=0.8,
+      xlab="Vremena izmedju erupcija (min)", cex.axis=0.7,
+      ylab="Vrijeme erupcije (min)", main="Dijagram rasprsenja", cex.main=0.9)
```



Instruktivno je i poredati podatke po veličini i zatim grafički prikazati podatke funkcijom `plot`. Na x osi je naveden redni broj sortiranih podataka. Na taj način dobivamo sljedeći graf

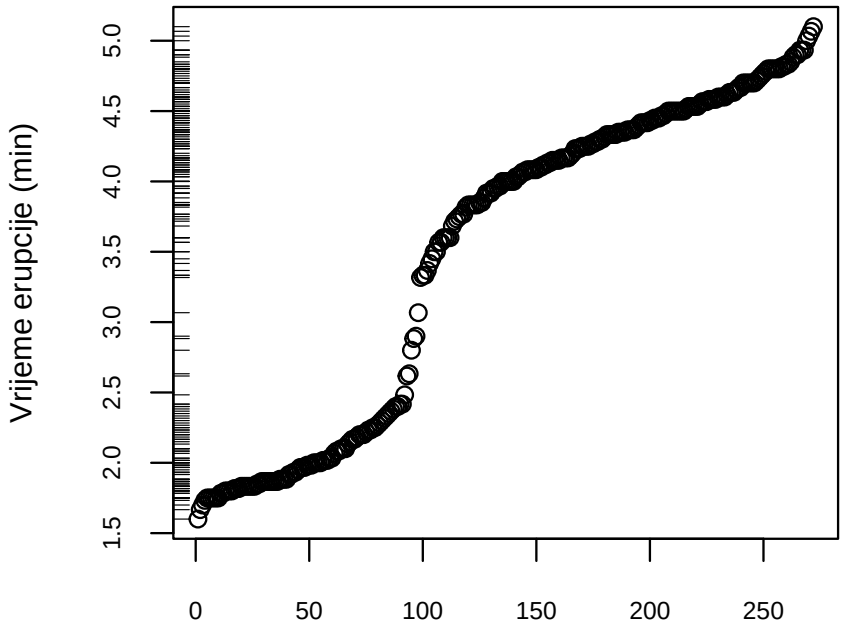
```
> par(mar=c(2,4,1,1))
```

```
> plot( sort( faithful$eruptions), pch=1, cex.axis=0.7,
+       ylab="Vrijeme erupcije (min)", cex.lab=0.8)
```



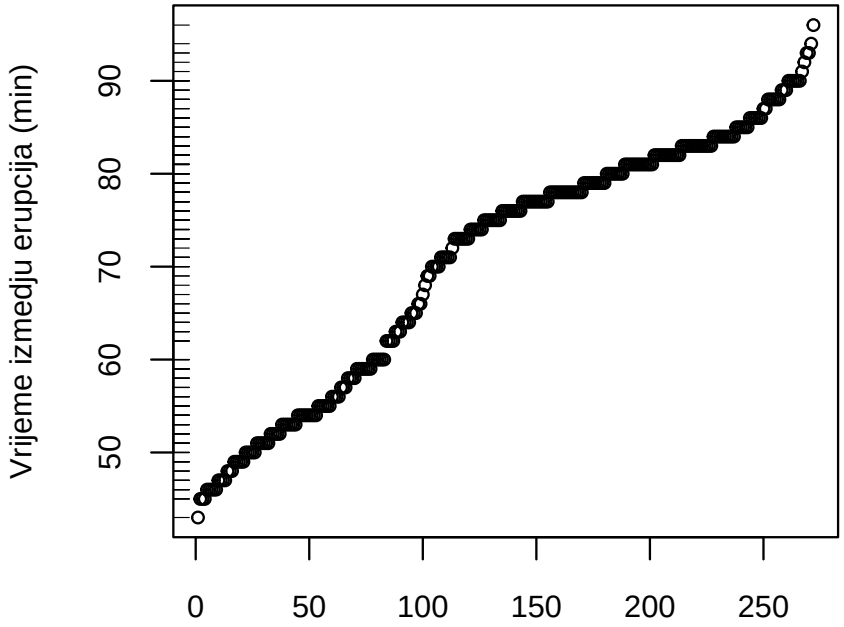
Dodajmo i `rug` s kojim smo se već susreli kod histograma relativne frekvencije veličine EU gradova. Prvo to napravimo za vremena trajanja erupcija,

```
> par(mar=c(2,4,1,1))
> plot( sort( faithful$eruptions), pch=1, cex.axis=0.7,
+       ylab="Vrijeme erupcije (min)", cex.lab=0.8)
> rug(faithful$eruptions, side=2)
```



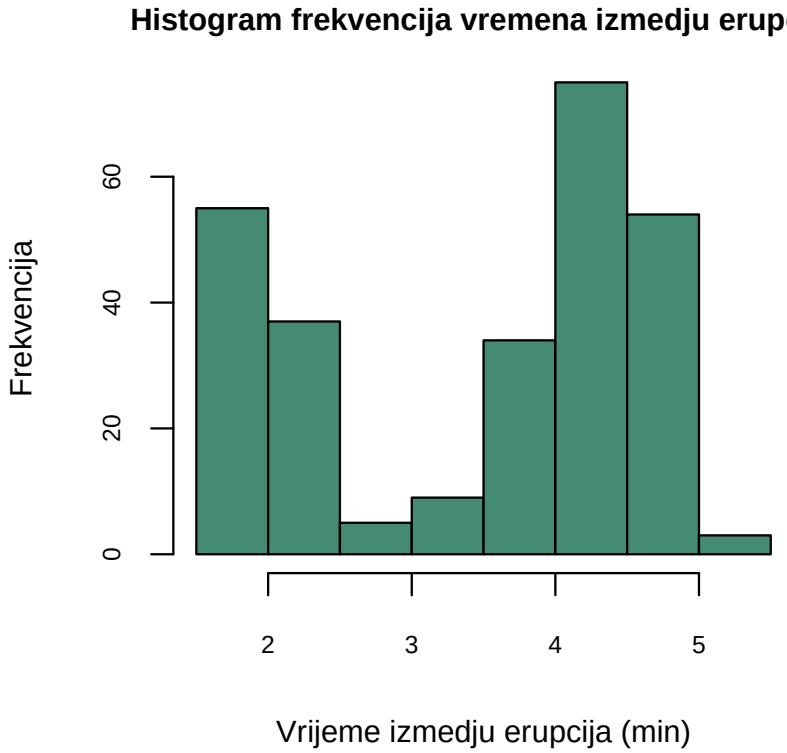
a zatim i za vremena između erupcija.

```
> par(mar=c(2,4,1,1))
> plot( sort( faithful$waiting), pch=1, cex=0.7, cex.axis=0.8,
+       ylab="Vrijeme izmedju erupcija (min)", cex.lab=0.8)
> rug(faithful$waiting, side=2)
```



Možemo uočiti da su vremena trajanja erupcija zapravo grupirana u dvije grupe manjih i većih podataka. Isto bi nam trebao potvrditi i histogram

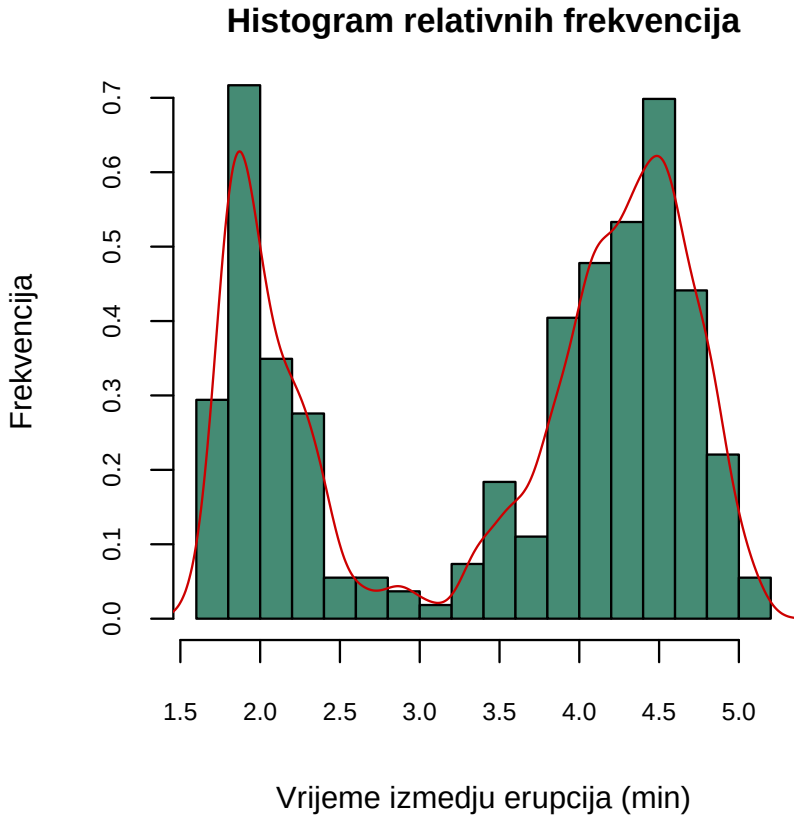
```
> par(mar=c(4,4,2,2))
> hist(faithful$eruptions, xlab="Vrijeme izmedju erupcija (min)",
+      main="Histogram frekvencija vremena izmedju erupcija",
+      cex.axis=0.7, cex.main=0.8, cex.lab=0.8, ylab="Frekvencija",
+      col = "aquamarine4")
```



Na sljedećem grafu prikazujemo histogram relativnih frekvencija vremena trajanja erupcija gejzira Old faithful. Na graf smo dodali i crvenu liniju koja predstavlja neprekidnu verziju grafa relativnih frekvencija. Kasnije ćemo detaljnije razmotriti o kakvoj se

liniji radi i koji je njen značaj (to bi bila aproksimacija funkcije gustoće slučajne varijable čije su realizacije predstavljene podacima o vremenu trajanja erupcija gejzira).

```
> par(mar=c(5,4,2,2))
> hist(faithful$eruptions, main="Histogram relativnih frekvencija",
+      breaks=20, probability= TRUE, cex.axis=0.7, cex.main=0.9,
+      xlab="Vrijeme izmedju erupcija (min)", cex.lab=0.8,
+      ylab="Frekvencija", col = "aquamarine4")
> points(density(faithful$eruptions, bw=.1), type='l', col='red3', lwd=1)
```



Gledajući pojedinačne pravokutnike na gornjem histogramu, recimo drugi, možemo provjeriti da je njegova visina (pogledajte `density` vektor histograma) jednaka $0,71691$. S druge strane, maksimum tih podataka je $5,1$, dok je minimum $1,6$. Dakle, širina jednog pravokutnika je $(5,1-1,6)/20 = 0,175$. Stoga je površina tog pravokutnika jednaka $0,12546$. Zbroj svih tako dobivenih površina je jednak 1, kao što smo već ranije istaknuli (pogledajte Primjer 2.7.1).

Završit ćemo ovu malu analizu podataka `faithful` analizom koreliranosti podataka o trajanju erupcija i vremena između njih. Prije prikazani dijagram raspršenja indicira dosta veliku povezanost tih podataka. Isto potvrđuje i izračun korelacije jer dobivamo dosta veliku vrijedost, kao što možemo vidjeti niže.

```
> cor(faithful$waiting, faithful$eruptions)

[1] 0.9008112
```

□

2.8 Sažetak poglavlja

Neka je

$$x_1, x_2, \ldots, x_n, \quad n \in \mathbb{N}$$

neki niz podataka. OznaD imo s

$$y_1, y_2, \ldots y_k, \quad k \in \mathbb{N},\ k \leq n$$

sve različite vrijednosti niza podataka (x_i). Tada broj pojavljivanja podatka y_i, $i \in \{1, 2, \ldots, k\}$, nazivamo **frekvencijom podatka** y_i i označavamo s f_i. Uz definiciju

$$f_i - \text{broj pojavljivanja (frekvencija) vrijednosti } y_i,\ i \in \{1, 2, \ldots, k\}.$$

možemo formirati tablicu u kojoj se uz vrijednosti podataka y_i nalazi i njihova frekvencija f_i. Takva tablica se naziva tablica frekvencija.

Dodatno možemo definirati niz vrijednosti (manjih ili jednakih od 1)

$$f_i' = f_i/n - \text{relativna frekvencija vrijednosti } y_i,\ i \in \{1, 2, \ldots, k\}.$$

Opet se može sastaviti tablica u kojoj se uz vrijednosti podataka y_i nalazi i njihova **relativna frekvencija** f_i'. Takva tablica se naziva tablica relativnih frekvencija.

Aritmetička sredina podataka $x_1, x_2, \ldots, x_n$, $n \in \mathbb{N}$, u oznaci $\bar{x}$ ili $\bar{x}_n$, računa se kao

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Medijan je jednak središnjem podatku (po veličini) u nizu podataka $x_1, x_2, \ldots, x_n$.
Mod je podatak u nizu $x_1, x_2, \ldots, x_n$ koji se najčešće pojavljuje.

Varijancu niza podataka $x_1, x_2, \ldots, x_n$, u oznaci s^2, s_x^2 ili s_n^2, definiramo kao

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2,$$

gdje je $\bar{x}$, kao i prije, artimetička sredina podataka.
Standardna devijacija je drugi korijen (pozitivni) od varijance.

Neka je p realan broj, $p \in [0, 1]$. Tada je $100p$ **percentil** nekog niza podatka jednak onoj vrijednosti među podacima za koju je $100p$ posto podataka manje ili jednako od nje, a $100(1-p)$ posto podataka je veće ili jednako od nje. Ako dva podatka zadovoljavaju taj uvjet, onda je $100p$ percentil jednak aritmetičkoj sredini ta dva podatka.

25%-tni percentil naziva prvim **kvartilom**, 50%-tni percentil se naziva drugim kvartilom, a 75%-tni percentil se naziva trećim kvartilom. Drugi kvartil je medijan. Razlika između trećeg i prvog kvartila se naziva **interkvartilnim rasponom**.

Zadan je niz dvodimenzionalnih kvantitativnih podataka, (x_i, y_i), $i = 1, 2, \ldots, n$, $n \in \mathbb{N}$. Jedna od najčešćih mjera međuovisnosti podataka je **korelacija** koju mjerimo **koeficijentom korelacije**, u oznaci $\rho_{x,y} = \rho$ ili r. Koeficijent korelacije definiramo kao

$$\rho = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{(n-1)s_x s_y} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}.$$

Koeficijent korelacije ima sljedeća osnovna svojstva:

i) $-1 \leq \rho \leq 1$,

ii) Za $a, b \in \mathbb{R}$, $a > 0$, i $y_i = ax_i + b$ vrijedi $\rho = 1$,

iii) Za $a, b \in \mathbb{R}$, $a < 0$, i $y_i = ax_i + b$ vrijedi $\rho = -1$,

iv) $\rho_{x,y} = \rho_{y,x}$ (simetričnost).

2.9 Zadaci

Zadatak 2.9.1. *Zadan je niz brojeva* $1, 0, 1, 2, 5, 4, 0, 1, 2, 5$. *Nađite mod i* 70%*-tni percentil za te brojeve.*

Zadatak 2.9.2. *Zadan je niz brojeva* $5, -1, 0, 4, 2$. *Nađite srednju vrijednost i varijancu tih brojeva.*

Zadatak 2.9.3. *Nađite aritmetičku sredinu i standardnu devijaciju sljedećeg niza brojeva:* $4, -3, 1, 0, -2$.

Zadatak 2.9.4. *Zadan je niz brojeva* $4, 2, 1, 0, 1, 3, 2, 9$. *Nađite srednju vrijednost i medijan tih brojeva. Da li promjenom jednog od tih brojeva (podataka) možete izjednačiti srednju vrijednost i medijan? Obrazložite.*

Zadatak 2.9.5. *Nađite korelaciju između nizova brojeva* $-1, 0, 1, 2, 3$ *i* $2, 3, 3, 4, 2$.

Zadatak 2.9.6. *Nađite korelaciju između nizova brojeva* $0, 1, 2, 3$ *i* $-1, 0, 0, 2$.

Zadatak 2.9.7. *Nađite medijan i* 25%*-tni percentil brojeva* $2, 4, 1, 2, 5, 4, 0, -1, 2, 5$.

Zadatak 2.9.8. *Nađite mod i* 80%*-tni percentil brojeva* $-2, 4, 1, 2, 4, 5, 0, -3, 2, 6, -1$.

Zadatak 2.9.9. *Nađite mod i* 75%*-tni percentil brojeva* $2, 4, -1, 2, 5, 3, 0, -1, 2, 5$.

Zadatak 2.9.10. *Dobili smo podatke o prodanim modelima automobila u nekom auto salonu u prošlom tjednu (podaci su poredani po kronološkom redu prodaje): Le, Le, Ib, Al, Ib, Le, Al, Le, Cu, Ib, Cu, Cu. Napravite tablicu frekvencija i relativnih frekvencija za modele prodanih automobila u danom auto salonu.*

Zadatak 2.9.11. *Dok sjedite u kafiću i čekate prijatelja da dođe na kavu, zabavljate se i gledate na televiziji rezultate druge finske nogometne lige. Da ne gubite vrijeme odlučite zabilježiti, radi vježbe za kolokvij iz Statistike, ostvarene rezultate (pobjeda domaćina, neriješeno, poraz domaćina). Zabilježili ste sljedeće rezultate: neriješeno, pobjeda, pobjeda, neriješeno, poraz, pobjeda, poraz, neriješeno, pobjeda. Napravite tablicu frekvencija i relativnih frekvencija ostvarenih rezultata koje ste zabilježili.*

Zadatak 2.9.12. *Na jednom malom graničnom prelazu u Hrvatskoj bilježe se zemlje iz kojih su ušli pojedini automobili. U jednom danu su zabilježeni ulasci iz sljedećih država: SLO, I, SLO, A, A, I, H, D, SLO, I, H, D, D, SLO, I. Napravite tablicu frekvencija i relativnih frekvencija ulazaka automobila iz pojedinih država u promatranom danu.*

2.9.1 Rješenja zadataka

Rješenje 1 (Zadatak 2.9.1)**.** Sortirajmo zadanih 10 brojeva: $0, 0, 1, 1, 1, 2, 2, 4, 5, 5$. Da nađemo 70%-tni percentil trebamo odrediti podatak (mogu biti dva) za koji je $10 \cdot 0,7 = 7$ članova niza manje ili jednako od njega i $10 \cdot (1 - 0,7) = 3$ veće ili jednako od njega. Jasno je da broj 4 zadovoljava te uvjete pa je 70%-tni percentil danog niza brojeva jednak 4. Uočimo, da se tražilo da izračunamo medijan (središnji podatak), onda bi dva broja zadovoljavala uvjet da je pola podataka manje ili jednako od tog broja i pola podatka je veće ili jednako od tog broja. To su brojevi 1 i 2. U tom slučaju je medijan (a tako bi bilo i za neke percentile ili kvartile) jednak zbroju tih brojeva podijeljan s dva, odnosno medijan je jednak $1,5$. Mod smo definirali kao najčešći podatak koji se pojavljuje u nizu brojeva. Ovdje je to 1 pa je mod tog niza jednak 1. Sjetimo se, može biti i više brojeva u nizu koji se pojavljuju više od jednom pa načelno govoreći može biti i više modova u nizu brojeva.

Rješenje 2 (Zadatak 2.9.2)**.** Pogledajmo formule za aritmetičku sredinu i varijancu i uvrstimo dane brojeve. Ispada da je aritmetička sredina (srednja vrijednost) tih brojeva jednaka 2, dok je varijanca jednaka $6,5$. Prisjetimo se da je standardna devijacija samo drugi korijen iz varijance (ovdje je jednaka $2,54951$), a još smo definirali i raspon podataka kao razliku najvećeg i najmanjeg podatka. Ovje je raspon podataka jednak $5-(-1)=6$.

Rješenje 3 (Zadatak 2.9.3)**.** Prema formulama za aritmetičku sredinu i standardnu devijaciju (drugi korijen od varijance) je aritmetička sredina jednaka 0, a standardna devijacija $2,7386$.

Rješenje 4 (Zadatak 2.9.4)**.** Srednja vrijednost podataka (aritmetička sredina) je jednaka $2,75$, dok je medijan (središnja vrijednost) jednak 2. Rekli smo da tzv. outlieri najviše utječu na razliku aritmetičke sredine i medijana, a ovje je to broj 9. Stoga se čini da se njegovom zamjenom s drugim brojem najlakše može smanjiti aritmetička sredina promatranog niza brojeva. Zaista, ako 9 zamijenimo s 3 dobijemo novi niz podataka $4,2,1,0,1,3,2,3$ čiji su i medijan i aritmetička sredina jednaki 2.

Rješenje 5 (Zadatak 2.9.5)**.** Prema formuli za korelaciju je korelacija ta dva niza podataka jednaka $0,189$. To nije velika korelacija. Rekli smo da vrijednosti korelacije blizu 1 ili -1 upućuju na značajnu koreliranost podataka.

Rješenje 6 (Zadatak 2.9.6)**.** Prema formuli za korelaciju je korelacija ta dva niza podataka jednaka $0,923$. To je dosta velika korelacija. Rekli smo da vrijednosti korelacije blizu 1 ili -1 upućuju na značajnu koreliranost podataka.

Rješenje 7 (Zadatak 2.9.7)**.** Sortiramo zadani niz brojeva

```
[1] -1  0  1  2  2  2  4  4  5  5
```

Niz ima $n=10$ članova. 25%-tni percentil tog niza je broj (ili brojevi) za koji je $n\cdot 0,25=2,5$ članova niza manje ili jednako od tog broja, a $n\cdot(1-0,25)=7,5$ članova niza je veće ili jednako od tog broja. Broj 1 zadovoljava taj uvjet pa je 25%-tni percentil brojeva jednak 1. Medijan je 50%-tni percentil pa je u ovom slučaju on jednak broju 2. Dakle, rješenje je 2 i 1.

Rješenje 8 (Zadatak 2.9.8)**.** Sortirajmo niz brojeva

```
[1] -3 -2 -1  0  1  2  2  4  4  5  6
```

Imamo niz od 11 brojeva ($n=11$) i tražimo član (članove) niza za koji je $n\cdot 0,8=8,8$ članova niza manje ili jednako od tog člana i $n\cdot(1-0,8)=2,2$ članova niza veće ili jednako od tog člana. Stoga je 80%-tni percentil danog niza brojeva jednak 4. Mod je vrijednost koja se najčešće pojavljuje u nizu brojeva, a ovdje imamo dvije takve vrijednosti: 2 i 4. To su modovi (niz je multimodalan).

Rješenje 9 (Zadatak 2.9.9)**.** Sortirajmo zadane brojeve: $-1,-1,0,2,2,2,3,4,5,5$. Vrijednost koja se najviše puta ponavlja je 2. To je mod. Da nađemo 75%-tni percentil trebamo odrediti podatak (mogu biti dva) za koji je $10\cdot 0,75=7,5$ članova niza manje ili jednako od njega i $10\cdot(1-0,75)=2,5$ veće ili jednako od njega. U osnovi samo broj 4 zadovoljava oba uvjeta pa je on jednak 75%-tnom percentilu.

Rješenje 10 (Zadatak 2.9.10)**.** Tablica frekvencija prikazuje učestalost pojavljivanja pojedinog podatka (u ovom slučaju marke automobila). Stoga za podatke o prodaji iz zadatka imamo

```
prodaja_modela
Al Cu Ib Le
 2  3  3  4
```

Tablica relativnih frekvencija prikazuje relativnu učestalost pojavljivanja pojedinog podatka među svim podacima. Drugim riječima, elementi tablice relativnih frekvencija su brojevi iz tablice frekvencija podijeljeni s ukupnim brojem podataka koje promatramo (koji su nam dani). Stoga dobivamo sljedeću tablicu relativnih frekvencija za gornje podatke o prodaji

```
relativna_prodaja_modela
       Al        Cu        Ib        Le
0.1666667 0.2500000 0.2500000 0.3333333
```

Rješenje 11 (Zadatak 2.9.11). Tablica frekvencija prikazuje učestalost pojavljivanja pojedinog podatka (u ovom slučaju ishoda nogometnih utakmica). Stoga za podatke o prodaji iz zadatka imamo (uvedimo skraćenice pob za pobjedu, ner za neriješeno i por za poraz)

```
> ishodi_utakmica<-c("ner", "pob", "pob", "ner", "por",
+                    "pob", "por", "ner", "pob")
> table(ishodi_utakmica)

ishodi_utakmica
ner pob por
  3   4   2
```

Tablica relativnih frekvencija prikazuje relativnu učestalost pojavljivanja pojedinog podatka među svim podacima. Drugim riječima, elementi tablice relativnih frekvencija su brojevi iz tablice frekvencija podijeljeni s ukupnim brojem podataka koje promatramo (koji su nam dani). Stoga dobivamo sljedeću tablicu relativnih frekvencija za gornje podatke o ishodu utakmica

```
> relativna_ishodi_utakmica<-c("ner", "pob", "pob", "ner", "por",
+                              "pob", "por", "ner", "pob")
> rel_verzija<-table(relativna_ishodi_utakmica)/length((ishodi_utakmica))
> rel_verzija

relativna_ishodi_utakmica
      ner       pob       por
0.3333333 0.4444444 0.2222222
```

Rješenje 12 (Zadatak 2.9.12). Tablica frekvencija

```
drzave
  A   D   H   I SLO
  2   3   2   4   4
```

a tablica relativnih frekvencija je

```
relativno_drzave
        A         D         H         I       SLO
0.1333333 0.2000000 0.1333333 0.2666667 0.2666667
```

Poglavlje 3

Osnove kombinatorike i naivna definicija vjerojatnosti

Teorija vjerojatnosti se bavi matematičkim modeliranjem slučajnih događaja ili pojava. Slučajnost se može shvatiti kao antipod determinizma, odnosno slučajnima se smatraju one pojave koje se ne mogu deterministički opisati (poput djelovanja gravitacije, na primjer) ili za njih jednostavno nemamo dovoljno informacija koje bi omogućile determinističke izračune. S druge strane se slučajnost ili neizvjesnost ishoda javlja kod gotovo svih događaja ili procesa koje želimo opisati ili modelirati pa se tako i greške mjerenja nekih osnovnih fizikalnih značajki mogu smatrati slučajnima, odnosno mogu se modelirati na taj način.

U najjednostavnijoj formi se slučajnost javlja kod bacanja novčića ili igraće kockice. Naime, ukoliko bacamo (simetričan) novčić načelno ne znamo da li će pasti pismo ili glava. Dakle, ishod bacanja je nepoznat, odnosno slučajan. Usprkos tome što ne možemo sa sigurnošću odrediti ishod pojedinačnog bacanja novčića, možemo dosta toga reći o vjerojatnostima raznih ishoda, poput vjerojatnosti da će na novčiću pasti glava u 5 uzastopnih bacanja.

U žargonu teorije vjerojatnosti se radnje ili pojave koje rezultiraju nepoznatim ishodima (ali poznatim mogućnostima ishoda) nazivaju **slučajnim eksperimentima**. Tako su bacanje novčića ili kockice slučajni eksperimenti, ali i kašnjenje vlaka može biti slučajni eksperiment, kao i životni vijek pojedine osobe. Pokazuje se da je osnovni korak u izgradnji teorije vjerojatnosti definicija skupa svih mogućih ishoda pojedinog slučajnog eksperimenta. Taj se skup naziva **prostorom elementarnih događaja** (eng. *sample space*) i praktički se uvijek uznačava s Ω. Elementi tog skupa se, sukladno oznaci samoga skupa, označavaju s ω.

Matematički gledano je teorija vjerojatnosti zasnovana na skupovima pa ćemo započeti ovo poglavlje s kratkim ponavljanjem osnovnih definicija i svojstava skupova.

3.1 Skupovi

Skup je jedan od osnovnih objekata u matematici, poput točke ili pravca u geometriji, za čije značenje pretpostavljamo da je svima poznato i razumljivo. Da bismo se ipak mogli donekle orjentirati dajemo sljedeću "definiciju" pojma skupa. To je tako zvana Cantorova naivna definicija pojma skupa. Postoji i aksiomatska teorija skupova koja se sustavnije bavi građenjem skupova, ali se njome nećemo baviti u ovoj skripti.

Definicija 3.1.1. Skup je objedinjenje neke množine različitih elemenata. Članove skupa nazivamo elementima skupa.

Mogli smo u gornjoj definiciji koristiti i formulaciju poput "Skup je kolekcija različitih elemenata", ali je jasno da smo u oba slučaja prebacili teret značenja pojma skupa na pojmove objedinjenje, množina ili kolekcija, a time si nismo pomogli jer je njih jednako teško definirati. No, za svakodnevni život matematike te male distinkcije među pojmovima nisu previše značajne pa niti mi ne moramo o tome previše brinuti.

U matematici je uobičajeno skupove označavati velikim slovima poput S, T, U, V ili A, B, C, D i slično. Kao i inače u matematici, skupove možemo i indeksirati pa ih možemo označavati sa S_1, S_2, S_3 i na slične načine. Elemente skupova označavamo malim slovima. Tako ćemo činjenicu da je s element skupa S označavati sa

$$s \in S,$$

a ukoliko neki t nije element skupa S pisat ćemo

$$t \notin S.$$

Uobičajeni način zadavanja skupova je nabrajanjem njihovih elemenata unutar vitičastih zagrada pri čemu su elementi skupa odvojeni zarezom.

Primjer 3.1.2. Neka je sa S označen skup koji se sastoji od brojeva 1 i 2. Nećemo raditi razlikovanje između oznake za skup i samoga skupa pa ćemo reći da je S skup koji sadrži brojeve 1 i 2, a to ćemo zapisivati kao $S = \{1, 2\}$. U skladu s gore uvedenom oznakom za elemente skupa jasno je da je $1 \in S$ i $2 \in S$. □

Iako definicija skupa koju smo naveli nije formalna ipak se iz nje nešto od svojstava skupova može iščitati. Naime, u njoj se navodi da skup čine različiti elementi pa zapravo možemo zaključiti da se pojavljivanje istih elemenata u navođenju elemenata skupa može ignorirati. Također, poredak elemenata prilikom navođenja elemenata skupa nije važan. Dakle, elemente skupa možemo pisati proizvoljnim poretkom i svi će oni činiti isti skup.

Primjer 3.1.3. Uzimo $S = \{1, 2\}$ kao u prethodnom primjeru. Kao što smo rekli S možemo zapisati i kao $S = \{2, 1\}$ jer poredak kojim navodime elemente skupa nije važan. Također, smatrat ćemo da su skupovi $\{1, 2\}$, $\{1, 1, 2\}$ i $\{2, 1, 2\}$ svi isti jer jednake elemente skupa možemo ignorirati, odnosno smatrati da se isti element pojavljuje samo jednom.

Napomenimo da se "skupovi" kod kojih se u nabrajanju elemenata oni (elementi) mogu ponavljati nazivaju multiskupovima. Primjeri multiskupova bi bili $T = \{1, 1, 2, 2, 3, 3\}$ ili $U = \{1, 2, 2, 3, 3, 3\}$. Kao multiskupovi T i U ne bi bili jednaki dok su kao skupovi oni jednaki skupu $\{1, 2, 3\}$. □

Skupovi, naravno, ne moraju sadržavati samo brojeve ili neke druge matematičke objekte. U sljedećim primjerima navodimo neke drugačije primjere skupova.

Primjer 3.1.4. S G označimo skup gradova u RH koji imaju više od 50.000 stanovnika. Tada je $G = \{$ Zagreb, Split, Rijeka, Osijek, Zadar, Slavonski Brod, Pula$\}$. Naravno, koristeći se prijašnjim oznakama možemo pisati Osijek $\in G$ ili Pula $\in G$, a Karlovac $\notin G$. □

Primjer 3.1.5. Ukoliko sa D označimo skup svih dana u tjednu, onda je $D = \{$ ponedjeljak, utorak, srijeda, četvrtak, petak, subota, nedjelja $\}$. □

Primjer 3.1.6. Sa Z označimo skup svih znamenki u dekadskom sustavu. Znamo da je $Z = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$. Skup svih binarnih znamenki B je nešto manji jer je $B = \{0, 1\}$. □

Skupove mogu sačinjavati i sve kovanice koje se koriste u nekoj državi, svi kamenčići koji su u nekoj vrećici (ili na nekoj plaži), sve zvijezde u svemiru i tako dalje.

Iako je nabrajanje svih elemenata skupa u vitičastim zagradama vrlo zgodan način predstavljanja skupova on nije uvijek primijenjiv. Naime, postoje skupovi koji nisu konačni i čije elemente ne možemo predstaviti na taj način. U školovanju smo se susreli s takvim skupovima. Na primjer, znamo da je kružnica skup svih točaka ravnine koje su jednako udaljene od jedne točke - središta kružnice. Takve skupove ne možemo opisati nabrajanjem svih njegovih elemenata, ali ih ipak možemo vrlo elegantno zapisati.

Naime, u matematici je uobičajeno zadavati skupove nekim svojstvom. Takvu notaciju ćemo i ovdje preuzeti pa ćemo pisati $S = \{s \mid P(s)\}$, a to će značiti da je S skup svih onih s-ova za koje vrijedi svojstvo P. Notaciju $S = \{s \mid P(s)\}$ čitamo kao "S je skup svih s za koje vrijedi P od s". Pogledajmo nekoliko skupova koji se zadaju na taj način.

Primjer 3.1.7. Skup G iz primjera 3.1.4 možemo zapisati koristeći se upravo opisanom notacijom. Tako je $G = \{g \mid \text{broj stanovnika od } g \geq 50.000\}$, gdje je s g označen proizvoljan grad u Hrvatskoj. Približivši se još više govornom jezikom možemo pisati i $G = \{$ gradovi u RH $\mid$ broj stanovnika grada $\geq 50.000\}$.

Na sličan način je vidimo da je skup $V = \{$ građani RH $\mid$ visina građana ≥ 190 cm $\}$ skup svih stanovnika Hrvatske koji su veći ili jednaki od 190 cm.

Napokon, podsjetimo se kako bismo predstavili kružnicu L sa središtem u ishodištu neke ravnine i radijusom 5. Tada je $K = \{(x, y) \mid x^2 + y^2 = 25\}$, gdje su (x, y) točke iz promatrane ravnine. Radi potpunosti možemo se prisjetiti da se krug sa središtem u istoj točki i s radijusom od 5 cm može zapisati kao $K = \{(x, y) \mid x^2 + y^2 \leq 25\}$, dok bi krug istog radijusa, ali sa središtem u točki $(2, 3)$ zapisali kao $K_2 = \{(x, y) \mid (x-2)^2 + (y-3)^2 \leq 25\}$. □

Napomena 3.1.8. Nekoliko skupova u matematici imaju poseban značaj pa su za njih rezervirane i posebne oznake koje su svima prepoznatljive. Prvi takav skup je skup prirodnih brojeva koji označavamo sa $\mathbb{N}$. Kako su prirodni brojevi 0, 1, 2, 3, i tako dalje možemo pisati i $\mathbb{N} = \{0, 1, 2, 3, 4, ...\}$. Vidimo da je ovo primjer beskonačnog skupa kojem ne možemo nabrojati sve elemente, ali ipak svi znamo koji su njegovi elementi. Na ovom mjestu vrijedi napomenuti da se često sa $\mathbb{N}$ označavaju prirodni brojevi koji ne sadržavaju nulu, a onda se sa $\mathbb{N}_0$ označava skup svih prirodnih brojeva koji sadrži i nulu.

Sljedeći značajan skup koji ima rezerviranu posebnu oznaku je skup svih cijelih brojeva koji označavamo sa $\mathbb{Z}$. U cijele brojeve ubrajamo sve prirodne brojeve te sve negativne brojeve. Možemo pisati i $\mathbb{Z} = \{..., -3, -2, -1, 0, 1, 2, 3, ...\}$.

S $\mathbb{Q}$ ćemo označavati skup svih racionalnih brojeva. Racionalni brojevi su oni koji se mogu prikazati u obliku razlomka, pri čemu uzimamo u obzir i razlomke s negativnim predznakom. Formalno bi mogli zapisati i $\mathbb{Q} = \{\frac{m}{n} \mid m \in \mathbb{Z}, n \in \mathbb{N}, n \neq 0\}$. Dakle, $\mathbb{Q}$ se sastoji od svih razlomaka u kojima je brojnik neki cijeli broj, a nazivnik prirodni broj različit od nule. Uočimo da prikaz racionalnih brojeva nije jedinstven jer su, na primjer, 1/2, 2/4 i 4/8 isti brojevi, ali to nije problem u gonjem prikazu skupa $\mathbb{Q}$ jer smo rekli da se pojavljivanje istih elemenata u prikazu skupa može ignorirati. Vidimo da smo skup $\mathbb{Q}$ zapisali samo u obliku $S = \{s \mid P(s)\}$ jer je teško pobrojati njegove elemente na drugi način.

Napokon, sa $\mathbb{R}$ ćemo označavati skup svih realnih brojeva. On sadrži racionalne i iracionalne brojeve. Malo ga je teže zapisati u prije navedenom obliku, a mogli bi reći da ga sačinjavaju svi brojevi koji se mogu prikazati u obliku broja s decimalnim zarezom,

odnosno decimalnom točkom, pri čemu broj znamenaka s lijeve i desne strane decimalnog zareza može biti proizvoljno velik. Ovo nam ne govori previše o strukturi realnih brojeva, a na ovom mjestu nećemo ulaziti dublje u mogućnost boljeg definiranja realnih brojeva.

Osim ovih osnovnih skupova za koje smo rezervirali posebne oznake imamo i neke varijacije istih. Tako se sa $\mathbb{Z}^+$ ili $\mathbb{R}^+$ označavaju skup svih cijelih brojeva većih od nule ili skup svih realnih brojeva većih od nule. Ponekad ćemo koristiti i takve oznake ili ćemo napomenuti drugačije. □

3.1.1 Skupovne operacije

Nakon što smo uveli pojam skupa i razmotrili načine prikaza skupova možemo razmisliti na koje načine možemo uspoređivati skupove i koje se operacije mogu izvoditi na skupovima.

Ukoliko su zadana dva proizvoljna skupa osnovno pitanje koje si možemo postaviti je da li su oni jednaki. Stoga najprije dajemo definiciju jednakosti skupova.

Definicija 3.1.9 (Jednakost skupova)**.** Neka su S i T dva skupa. Oni su jednaki ako sadrže iste elemente, odnosno ako je svaki element skupa S ujedno i element skupa T i obratno: ako je svaki element skupa T ujedno i element skupa S.

Nema puno nepoznanica u gornjoj definiciji i ona je intuitivno jasna. Naime, kako su skupovi definirani svojim elementima razumno je reći i da su dva skupa jednaka ako su im jednaki svi elementi. Naravno, provjera jednakosti dva skupa u praksi može biti vrlo složena, a vremenom ćemo se u to i uvjeriti. Za sada pogledajmo neke osnovne primjere.

Primjer 3.1.10. Neka je $S_1 = \{x \mid x \in \mathbb{Z} \text{ i } x^2 = x\}$, a $S_2 = \{0, 1\}$. Kako su 0 i 1 jedina rješenja jednadžbe $x^2 = x$ vidimo da su u S_1 oni cijeli brojevi koji su zapravo jednaki 0 ili 1. Dakle, $S_1 = S_2$.

Slično možemo vidjeti i da su skupovi $T_1 = \{x \mid x \in \mathbb{N} \text{ i } x^2 - 5x + 6 = 0\}$ i $T_2 = \{2, 3\}$ jednaki.

Sukladno napomeni o jednakosti skupova bez obzira na poredak elemenata vidimo da su i skupovi $U_1 = \{1, 3, 5, 7\}$ i $U_2 = \{5, 3, 7, 1\}$ jednaki. □

Definiranje pojma jednakosti skupova samo je prvi korak u algebraizaciji teorije skupova. Naime, ako na skupove gledamo kao na matematičke objekte prirodno se nameće poriv da ih pokušamo uspoređivati, "zbrajati", "množiti" i slično. U nastavku teksta dajemo definicije osnovnih operacija sa skupovima.

Definicija 3.1.11 (Podskup skupa)**.** Neka su S i T dva skupa. Ako je svaki element skupa S ujedno i element skupa T, onda je S **podskup od** T. Oznaka za podskup je $S \subset T$. Ukoliko je S podskup skupa T i T sadrži barem jedan element koji nije u S, onda kažemo da je S **pravi podskup** skupa T. U oznaci $S \subsetneq T$.

Gornja definicija nam kaže da je $S \subset T$ ako je zadovoljeno da je za proizvoljni element $s \in S$ nužno i $s \in T$. Uočimo: ako $S \subset T$ i $T \subset S$, onda je $S = T$. Vrijedi i obratno: ako je $S = T$, onda je $S \subset T$ i $T \subset S$

Iz mnogih razloga se u matematici često uvode nul elementi ili jedinični elementi. U zbrajanju je to 0. Znamo da za sve brojeve x vrijedi $x+0 = x$. I u teoriji skupova se uvodi jedan poseban skup, a to je **prazan skup**. Oznaka za prazan skup je $\emptyset$. Prazan skup ne sadrži niti jedan element. Možemo ga prikazati kao $\emptyset = \{\}$ ili kao $\emptyset = \{x \mid x \neq x\}$. Uočimo da je prazan skup podskup svakog skupa.

Primjer 3.1.12. Neka je $S = \{a, b, c\}$ i $T = \{a, b, c, d\}$. Tada je $S \subset T$ prema gornjoj definiciji. Naime, elementi od S su a, b i c i vidimo da su svi ti elementi ujedno i elementi skupa T pa je $S \subset T$. Prema definiciji praznog skupa je jasno da je $\emptyset \subset S$ i $\emptyset \subset T$.

S druge strane, skup $U = \{a, b, c, e\}$ nije podskup od T, pišemo $S \not\subseteq T$, jer jedan element skupa U nije ujedno i element skupa T. Naravno, to je $e \in U$. □

Iako se može činiti da nema nepoznanica vezanih uz jednakost skupova, odnosno podskupove skupova, treba pripaziti na jednu činjenicu. Naime, i skupovi mogu biti elementi skupova pa se skupovi mogu sastojati od drugih skupova. Primjerice, uzmimo broj 1 i formirajmo skup

$$A = \{1, \{1\}\}.$$

Na popisu elemenata skupa A (unutar vanjskih vitičastih zarada, odvojeni zarezima) vidimo dva elementa skupa A: broj 1 i skup $\{1\}$ koji sadrži broj jedan. Dakle, skup A ima dva elementa, odnosno

$$1 \in A, \quad \{1\} \in A.$$

Uočite

$$1 \neq \{1\},$$

ali

$$1 \in \{1\}.$$

Ukoliko konzistentno primjenjujemo definicije koje smo naveli, i koje ćemo navesti u nastavku, ne bi trebalo biti dvojbe oko pojma elementa skupa i podskupa skupa, ali ipak dajemo jedan primjer da ne bi bilo nedoumica.

Primjer 3.1.13 (Podskupovi skupa)**.** Uzmimo skup $S = \{a, b, c\}$ i razmislimo koji su svi elementi skupa S, odnosno podskupovi od S.

Što se tiče elemenata skupa S, tu ne bi trebalo biti nedoumica jer su elementi skupa navedeni unutar vitičastih zagrada i odvojeni zarezima. Dakle, svi elementi skupa S su a, b i c.

Kakva je situacija s podskupovima skupa S? Tražimo skupove čiji će elementi ujedno biti i elementi skupa S. Jedan, trivijalan, takav skup je prazni skup pa je svakako $\emptyset \subset S$. Nadalje, jednočlani skupovi koji sadrže elemente skupa S su također podskupovi od S. Dakle,

$$\{a\} \subset S, \quad \{b\} \subset S, \quad \{c\} \subset S.$$

Nadamo se da je jasno da vrijede gornja svojstva. Primjerice, a je jedini element skupa $\{a\}$, ali a nalazimo i na popisu elemenata skupa S pa su svi elementi skupa $\{a\}$ (a to je samo a) ujedno i elementi skupa S. Po definiciji podskupa to znači da je $\{a\} \subset S$. Nadamo se da je jasno da $\{a\} \notin S$ (jer $\{a\}$ ne nalazimo na popisu elemenata od S).

Navedeni jednočlani skupovi nisu jedini podskupovi od S. Naime, i dvočlani skupovi $\{a, b\}$, $\{a, c\}$ i $\{b, c\}$ su također podskupovi od S. To se opet jednostavno provjeri jer su, na primjer, b i c jedini elementi skupa $\{b, c\}$, a ujedno su i elementi od S pa je $\{b, c\} \subset S$. Istom logikom zaključujemo da je i $S \subset S$. Vratit ćemo se malo kasnije na podskupove skupa, ali ovaj primjer pokazuje kako se oni grade. □

Na operaciju "biti podskup", koju zovemo i **skupovnom inkluzijom**, možemo gledati kao na relaciju definiranu na skupovima. Ona ima svojstva poput relacije $\leq$ na skupu brojeva. Posebno, skupovna inkluzija je **tranzitivna relacija**. Osnovna svojstva skupovne inkluzije saželi smo u sljedećoj propoziciji.

Propozicija 3.1.14. *Neka su A, B i C skupovi. Za skupovnu inkluziju vrijede svojstva*

i) $\emptyset \subset A$, *za svaki skup* A,

ii) $A \subset B$ *i* $B \subset A$ *ako i samo ako* $A = B$,

iii) Ako je $A \subset B$ *i* $B \subset C$, *onda je* $A \subset C$. *(tranzitivnost)*

Lako se vidi da vrijede sva svojstva navedena u propoziciji. Na primjer, svojstvo *iii)* pokažemo na sljedeći način: neka je x proizvoljan element iz skupa A (ako A nema niti jednog elementa, onda *iii)* trivijalno vrijedi zbog *i)*). Jer je $A \subset B$, onda je $x \in B$, a jer je $B \subset C$, onda je i $x \in C$. Dakle, za proizvoljni element x iz skupa A smo pokazali da je ujedno i u skupu C, a to znači da je $A \subset C$.

Napomena 3.1.15. Uočimo da svojstvo navedeno u *ii)* sadrži formulaciju ako i samo ako. Ona podrazumijeva dvije implikacije:

- ako je $A \subset B$ i $B \subset A$, onda je $A = B$ i
- ako je $A = B$, onda je $A \subset B$ i $B \subset A$.

Takve se formulacije često koriste u matematici i dosta su cijenjene jer nam govore da su neke dvije formule (logički) ekvivalentne pa se bilo koja od njih može koristiti u ovisnosti o kontekstu u kojem je jedna od njih korisnija/pogodnija. Često se umjesto formulacije "ako i samo ako" koristi skraćena "akko". Na engleskom je slična situacija: formulacija "if and only if" se često krati s "iff". □

Skupovna inkluzija se može, naravno, primijeniti i na beskonačne skupove. Kao što je dobro znano vrijedi

$$\mathbb{N} \subsetneq \mathbb{Z} \subsetneq \mathbb{Q} \subsetneq \mathbb{R}.$$

U skupu realnih brojeva $\mathbb{R}$ se standardno koriste oznake za intervale ili segmente realnih brojeva (možemo ih vizualizirati kao podskupove brojevnog pravca).

Četiri su osnovna tipa intervala realnih brojeva koji se međusobno razlikuju samo prema tome da li uključuju neku rubnu točku ili ne. Tako za $a, b \in \mathbb{R}$ dva realna broja, $a < b$ imamo sljedeće intervale (s lijeve strane su oznake, a s desne definicije tih skupova):

$$(a, b) = \{x \in \mathbb{R} \mid a < x < b\}$$

$$(a, b] = \{x \in \mathbb{R} \mid a < x \leq b\}$$

$$[a, b) = \{x \in \mathbb{R} \mid a \leq x < b\}$$

$$[a, b] = \{x \in \mathbb{R} \mid a \leq x \leq b\}$$

Vidimo da je, na primjer, (a, b) skup svih realnih brojeva koji su veći od a, a manji od b. Tako je $(2, 5)$ skup svih realnih brojeva koji su veći od 2, a manji od 5. Interval $[a, b]$ se često naziva i **segmentom**. Ponekad se gornje oznake koriste i slučajevima u kojima je a ili b beskonačan (oznaka za beskonačnost je $+\infty$ ili $-\infty$ za minus beskonačno). Tako je $(-\infty, b) = \{x \in \mathbb{R} \mid -\infty < x < b\}$, uz dosta jasne varijacije (poput $[a, \infty)$).

Definicija 3.1.16 (Unija skupova)**.** Neka su S i T skupovi. **Unija skupova** S i T je skup koji sadrži točno one elemente koji su elementi skupa S ili elementi skupa T. Oznaka za uniju skupova S i T je $S \cup T$.

Dakle, unija dva skupa je opet skup i to takav u kojem su sadržani svi elementi skupa S i svi elementi skupa T. Neki se elementi mogu i ponavljati (ukoliko su sadržani i u S i u T), ali već znamo da kod skupova možemo ignorirati elemente koji se ponavljaju, odnosno uzeti ih u obzir samo jednom.

Primjer 3.1.17. Neka su zadani skupovi $N = \{1, 3, 5, 7, 9\}$ i $P = \{0, 2, 4, 6, 8\}$. Tada je skup $Z = N \cup P = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$ jer unija skupova N i P sadrži sve elemente skupa N i skupa P. Skup Z je skup znamenki u dekadskom sustavu. □

Primjer 3.1.18. Pogledajmo sljedeće skupove. Neka je SH = { Zagorje, Podravina, Slavonija, Zagreb, Kordum i Banija, Gorski Kotar } i JH = { Istra, Rijeka, Kvarner, Lika, Dalmacija }. Tada je unija skupova SH i JH skup RH, odnosno skup hrvatskih regija (vjerojatno nepotpun, ali ovdje ipak samo dajemo primjere unije skupova). Dakle, $RH = SH \cup JH$. □

Primjer 3.1.19. Zadani su skupovi $S_1 = \{1, 2, 3\}$ i $S_2 = \{2, 3, 4\}$. Tada je unija ta dva skupa skup S, pri čemu je $S = S_1 \cup S_2 = \{1, 2, 3, 4\}$. □

Primjer 3.1.20. Ukoliko je skup S sadržan u skupu T, onda je $S \cup T = T$. Tako je, na primjer, $\mathbb{N} \cup \mathbb{Q} = \mathbb{Q}$. □

Pogledajmo neka **svojstva unije skupova**. S, T i V su proizvoljni neprazni skupovi. U zagradi je naveden naziv pojedinog svojstva.

1. $S \cup S = S$ (idempotentnost unije)
2. $S \cup T = T \cup S$ (komutativnost unije)
3. $(S \cup T) \cup V = S \cup (T \cup V)$ (asocijativnost unije)
4. $S \cup \emptyset = S$ ($\emptyset$ je neutralni element za uniju)
5. $S \cup T = T$ ako i samo ako je $S \subset T$

Sva ova svojstva se mogu lagano dokazati, ali u ovom poglavlju nam je cilj upoznati (podsjetiti se) osnovna svojstva skupova pa se nećemo time nećemo baviti. Dodatno, većina tih svojstava se lagano "dokaže" Vennovim dijagramima na koje ćemo se podsjetiti malo kasnije. Na ovom mjestu možemo napomenuti da nam asocijativnost unije omogućava da pojam unije skupova lagano proširimo na konačno mnogo skupova.

Definicija 3.1.21 (Unija konačno mnogo skupova)**.** Neka su $S_1, S_2, \ldots, S_n$ proizvoljni skupovi (n njih), pri čemu je n neki prirodan broj veći ili jednak 2. Tada je unija tih skupova skup $S = S_1 \cup S_2 \cup \ldots \cup S_n$ koji sadrži sve elemente koji su u bilo kojem od skupova $S_1, S_2, \ldots, S_n$. Oznaka za konačnu uniju skupova $S_1, S_2, \ldots, S_n$ je

$$S = \bigcup_{i=1}^{n} S_i. \tag{3.1}$$

Vidimo da se pojam unije konačno mnogo skupova podudara sa pojmom unije dva skupa koji smo prije definirali. Također, pojam unije skupova se može proširiti i na beskonačnu uniju skupova.

Definicija 3.1.22 (Unija beskonačno mnogo skupova)**.** Neka je $S_1, S_2, S_3, \ldots$ proizvoljan niz od beskonačno mnogo skupova. Tada je unija tih skupova skup S koji sadrži sve elemente koji su u bilo kojem od skupova $S_1, S_2, S_3, \ldots$. Za beskonačnu uniju skupova koristimo sljedeće oznake

$$S = \bigcup_{i=1}^{\infty} S_i = \bigcup_{i \in \mathbb{N}} S_i.$$

Unija konačno mnogo skupova je poseban slučaj unije beskonačno mnogo skupova (stavimo $\emptyset = S_{n+1} = S_{n+2} = \ldots$). Sljedeća skupovna operacija koju definiramo je presjek skupova.

Definicija 3.1.23 (Presjek skupova)**.** Neka su S i T skupovi. **Presjek skupova** S i T je skup koji sadrži točno one elemente skupova S i T koji su sadržani u oba skupa. Oznaka za presjek skupova S i T je $S \cap T$.

Dakle, presjek dva skupa je opet skup i to takav koji sadrži samo one elemente koji se nalaze i u skupu S i u skupu T. Pogledajmo neke primjere.

Primjer 3.1.24. Zadani su skupovi $S = \{1, 2, 3\}$ i $T = \{2, 3, 4\}$. Prema definiciji presjek skupova je skup koji sadrži sve elemente koji se nalaze i u skupu S i u skupu T, odnosno $S \cap T = \{2, 3\}$. □

Primjer 3.1.25. Kao što smo već napomenuli, u matematici se često skupovi zadaju tako da se navode svojstva koja moraju zadovoljiti elementi tog skupa. Tako, na primjer, možemo definirati skup $E = \{n \in \mathbb{N} \mid n \leq 10 \text{ i } n \text{ neparan broj}\}$. Skup E sačinjavaju oni prirodni projevi koji su manji ili jednaki 10 te su neparni. Formalno govoreći, skup E (i druge slične skupove koje zadajemo nabrajanjem nekih svojstava) možemo zapisati kao presjek skupova. Definirajmo skup $D = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10\}$ koji sadrži sve prirodne brojeve manje od 10 te skup $N = \{1, 3, 5, 7, 9, 11, \ldots\}$ koji sadrži sve neparne prirodne brojeve. Tada se skup E može zapisati kao presjek skupova D i N, odnosno $E = D \cap N$. Na kraju ovog primjera napomenimo još samo to da je se skupovi poput P uobičajemo zapisuju na najkraći mogući način pa se različita svojstva razdvajaju samo zarezom, odnosno uobičajeno pišemo $P = \{n \in \mathbb{N} \mid n \leq 10,\ n \text{ neparan broj}\}$. □

Pogledajmo neka **svojstva presjeka skupova**. Neka su S, T i V proizvoljni neprazni skupovi. U zagradi je naveden naziv pojedinog svojstva (vidjet ćemo da se ponavlja terminologija koju smo naveli kod svojstava unije skupova).

1. $S \cap S = S$ (idempotentnost presjeka)
2. $S \cap T = T \cap S$ (komutativnost presjeka)
3. $(S \cap T) \cap V = S \cap (T \cap V)$ (asocijativnost presjeka)
4. $S \cap \emptyset = \emptyset$, ($\emptyset$ je nul element za operaciju presjeka)
5. $S \cap T = T$ ako i samo ako je $T \subset S$.

Kao i u slučaju unije skupova možemo napomenuti da nam asocijativnost presjeka omogućava da pojam presjeka skupova lagano proširimo na konačno ili beskonačno mnogo skupova.

Definicija 3.1.26 (Presjek konačno mnogo skupova)**.** Neka su $S_1, S_2, \ldots, S_n$ proizvoljni skupovi (n njih), pri čemu je n neki prirodan broj veći ili jednak 2. Tada je presjek tih skupova skup $S = S_1 \cap S_2 \cap \ldots \cap S_n$ koji sadrži sve elemente koji su **svim** skupovima $S_1, S_2, \ldots, S_n$. Oznaka za konačan presjek skupova je

$$S = \bigcap_{i=1}^{n} S_i.$$

Definicija 3.1.27 (Presjek beskonačno mnogo skupova)**.** Neka je $S_1, S_2, S_3, \ldots$ proizvoljan niz od beskonačno mnogo skupova. Tada je presjek tih skupova skup S koji sadrži sve elemente koji su u **svim** skupovima $S_1, S_2, S_3, \ldots$. Za presjek beskonačno mnogo-skupova koristimo oznake

$$S = \bigcap_{i=1}^{\infty} S_i = \bigcap_{i \in \mathbb{N}} S_i.$$

Napomena 3.1.28 (Disjunktni skupovi)**.** Ako su S i T skupovi i vrijedi $S \cap T = \emptyset$, kažemo da su S i T **disjunktni** skupovi. Pojam disjunktnosti se često koristi u matematici pogotovo u slučaju kada se neki skup može prikazati kao disjunktna unija nekih drugih skupova, odnosno kao unija nekih drugih skupova koji su disjunktni.

Skupovi $S = \{1, 2, 3\}$ i $T = \{2, 3, 4\}$ nisu dijunktni jer je $S \cap T = \{2, 3\}$. S druge strane su skupovi $S = \{1, 2, 3\}$ i $V = \{5, 6, 7\}$ disjunktni jer je $S \cap V = \emptyset$. Kao primjer jednog jednostavnog rubnog slučaja možemo uočiti da skupovi $[1, 2]$ i $[2, 5)$ nisu disjunktni jer im je u presjeku broj 2, odnosno $[1, 2] \cap [2, 5) = \{2\}$. □

Mogu se uočiti neke sličnosti $\cup$ i $\cap$ sa $+$ i $\cdot$ kod brojeva, kao što se može vidjeti iz nekih od svojstava unije i presjeka. Ipak, treba biti oprezan jer analogija ne vrijedi u potpunosti. Niže navodimo neke veze između unije i presjeka skupova te analogne formule koje bi vrijedile kod zbrajanja i množenja brojeva.

1. $S \cup (T \cap V) = (S \cup T) \cap (S \cup V)$ (distributivnost unije prema presjeku; kod brojeva bi to bilo $(a + bc) = (a + b)(a + c)$, što općenito ne vrijedi)
2. $S \cap (T \cup V) = (S \cap T) \cup (S \cap V)$ (distributivnost presjeka prema uniji; kod brojeva bi to bilo $a(b + c) = ab + ac$, što je istina)
3. $(S \cap T) \cup T = T$, $(S \cup T) \cap T = T$

Osim osnovnih operacija na skupovima možemo uvesti još neke operacije koje se često koriste. Prva od njih je komplement skupa.

Definicija 3.1.29 (Komplement skupa)**.** Neka su A i S proizvoljni neprazni skupovi, s time da je $A \subset S$. **Komplement skupa** A (u odnosu na S) je skup koji sadrži točno one elemente skupa S koji nisu elementi skupa A (dakle, jesu u S, ali nisu u A). Oznaka za komplement skupa A je A^c, a ponekad se koristi i $\bar{A}$.

Primjer 3.1.30. Neka je $A = \{1, 3, 5, 7, 9\} \subset S = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$. Tada je komplement skupa A skup $A^c = \{0, 2, 4, 6, 8\}$, odnosno skup parnih znamenki. □

Neka je $A = \mathbb{Q}$, a $S = \mathbb{R}$. Tada je A^c jednak skupu iracionalnih brojeva (tako se iracionalni brojevi i definiraju: to su realni brojevi koji nisu racionalni).

Komplement skupa može biti i kompliciraniji skup. Na primjer, za $A = (1, 2) \subset \mathbb{R}$ je $A^c = (-\infty, 1] \cup [2, \infty)$. □

Za komplement skupova vrijede sljedeće korisne i često korištene formule koje nazivamo **De Morganovim pravilima**. Ako su $A, B \subset S$, onda je

$$(A \cup B)^c = A^c \cap B^c \quad \text{i} \tag{3.2}$$

$$(A \cap B)^c = A^c \cup B^c \tag{3.3}$$

De Morganova pravila vrijede i za konačne unije i presjeke. Tako za konačno mnogo skupova $A_1, A_2, \ldots, A_n$ vrijedi

$$(A_1 \cup A_2 \cup \ldots \cup A_n)^c = A_1^c \cap A_2^c \cap \ldots \cap A_n^c \quad \text{i} \quad (A_1 \cap A_2 \cap \ldots \cap A_n)^c = A_1^c \cup A_2^c \cup \ldots \cup A_n^c$$

Definicija 3.1.31 (Razlika skupova)**.** Neka su S i T proizvoljni neprazni skupovi. **Razlika skupova** S i T je skup koji sadrži točno one elemente skupa S koji nisu elementi skupa T (dakle, jesu u S, ali nisu u T). Oznaka za razliku skupova S i T je $S \setminus T$.

Primjer 3.1.32. Zadani su skupovi $S = \{1, 2, 3\}$ i $T = \{2, 3\}$. Razlika skupova S i T je skup $S \setminus T = \{1\}$. U njemu je samo jedan element jer po definiciji razlike skupova iz skupa S trebamo maknuti sve one elemente koji su u S, ali se nalaze i u T, a u ovom slučaju su to brojevi 2 i 3. Stoga u razlici $S \setminus T$ ostaje samo broj 1. □

Primjer 3.1.33. Uzmimo skupove prirodnih i cijelih brojeva $\mathbb{N}$ i $\mathbb{Z}$. Tada razlika skupova $\mathbb{Z}$ i $\mathbb{N}$ sadrži sve cijele brojeve koji nisu prirodni, a to su zapravo negativni cijeli brojevi i nula (ukoliko ju ne uključimo u $\mathbb{N}$). Dakle, $\mathbb{Z} \setminus \mathbb{N} = \{0, -1, -2, -3, \ldots\}$. Obratna razlika skupova $\mathbb{N} \setminus \mathbb{Z}$ sadrži sve prirodne brojeve koji nisu cijeli. Takvih nema pa je $\mathbb{N} \setminus \mathbb{Z} = \emptyset$. □

Primjer 3.1.34. Zadani su skupovi $S = \{4, 2, 7, 5, 0\}$, $T = \{0, 6, 9, 2\}$ i $V = \{4, 7\}$. Lagano vidimo da je tada $S \setminus T = \{4, 5, 7\}$ i $S \setminus V = \{0, 2, 5\}$. Kako su T i V disjunktni skupovi, odnosno nemaju zajedničkih elemenata, u razlici $T \setminus V$ se nalaze svi elementi iz T koji nisu u V, a to su svi elementi iz T. Dakle, $T \setminus V = T = \{0, 2, 6, 9\}$. □

U nastavku navodimo neka svojstva **razlike skupova**. Neka su S, T i V proizvoljni neprazni skupovi. Tada je:

1. $S \setminus \emptyset = S$
2. $(S \setminus T) \cup (S \cap T) = S$
3. $(S \cup T) \setminus T = S \setminus T$
4. $(S \setminus T) \cup (S \cap T) \cup (T \setminus S) = S \cup T$
5. $(S \setminus T) \setminus V = S \setminus (T \cup V)$
6. $S \setminus (T \setminus V) = (S \setminus T) \cup (S \cap V)$

Pogledajmo kako bismo dokazali da vrijedi svojstvo $(S \setminus T) \cup (S \cap T) = S$. U osnovi, skupovne jednakosti dokazujemo tako da dokažemo dvije skupovne inkluzije (sjetite se svojstva *ii*) u Propoziciji 3.1.14). U ovom slučaju to znači da želimo dokazati $(S \setminus T) \cup (S \cap T) \subset S$ i $S \subset (S \setminus T) \cup (S \cap T)$. Skupovne inkluzije pak dokazujemo tako da uzmemo proizvoljan element skupa s lijeve strane relacije podskupa skupova i dokažemo da je on nužno i element skupa s desne strane iste relacije.

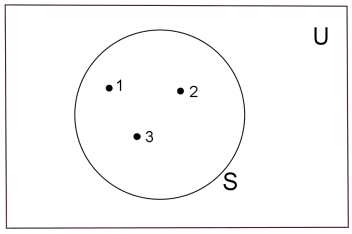
Dakle da bi dokazali da je $(S \setminus T) \cup (S \cap T) \subset S$ uzmemo proizvoljan element s takav da je $s \in (S \setminus T) \cup (S \cap T)$. To znači da je s element od S ali ne i od T ili je s element i od S i od T. To će biti zadovoljeno ako i samo ako je $s \in S$. Slično pokažemo da vrijedi i obratna skupovna inkluzija.

Iako na sličan način možemo dokazati i ostala upravo navedena svojstva skupovne razlike, ipak za neke od tih jednakosti nije odmah očito zašto vrijede. Srećom, kod takvih, relativno jednostavnih, skupovnih jednakosti imamo na raspolaganju i malu pomoć koju nam pružaju tako zvani Vennovi dijagrami. Riječ je o grafičkoj metodi koja je dovoljno pouzdana da se njenim korištenjem možemo s razumnom sigurnošću uvjeriti da vrijedi neka skupovna jednakost.

3.1.2 Vennovi dijagrami

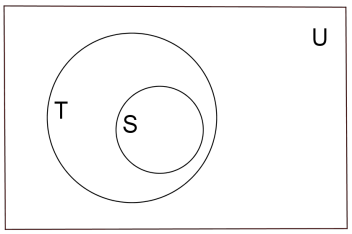
U Vennovim dijagramima uvodimo univerzalni skup U koji sadrži sve elemente koje promatramo. Skup U je na neki način prirodno okruženje skupa kojega promatramo, odnosno njegovih elemenata. Skupove prikazujemo krugovima ili nekim drugim sličnim zatvorenim krivuljama poput elipse. Pogledajmo primjer koji će nam pomoći u razjašnjavanju prikaza skupova pomoću Vennovih dijagrama.

Primjer 3.1.35. Pogledajmo kako bismo prikazali skup $S = \{1, 2, 3\}$ pomoću Vennovih dijagrama. U tom slučaju U može biti skup prirodnih brojeva pa je prikaz skupa S kao na slici

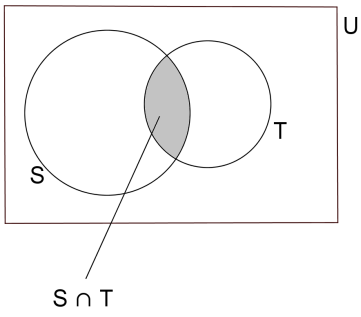


Važno je uočiti da nam ovdje nije važna geometrija skupova koje prikazujemo (veličina, središte kruga i slično), nego samo relativan odnos skupa i njegovih elemenata ili odnos nekog skupa s drugim skupovima, kao što ćemo uskoro vidjeti. □

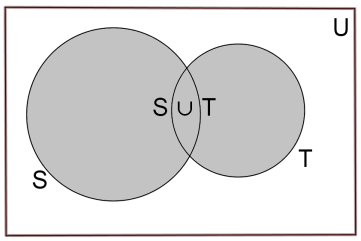
Ukoliko želimo prikazati samo odnos među skupovima ne moramo navoditi elemente skupova. Tako za skupove S i T činjenicu da je skup S sadržan u skupu T, odnosno da vrijedi $S \subset T$ priazujemo sljedećim Vennovim dijagramom. Napominjemo da će navedeni prikaz vrijediti u vrlom općenitim situacijama, a upravo to ćemo i koristiti kada ćemo neke stvari dokazivati (uvjeravati se) Vennovim dijagramima. Također, univerzalni skup U neće uvijek biti isti, nego će ovisiti o karakteru skupova koje promatramo. Preciznu definiciju univerzalnog skupa ne možemo dati između ostaloga i zato što ne postoji objekt koji bi obuhvaćao sve skupove (skup svih skupova). Vidjet ćemo da sve to nije naročito važno u korištenju Vennovih dijagrama jer je riječ o vrlo pragmatičnoj metodi, ali ipak treba biti svjestan njenih ograničenja.



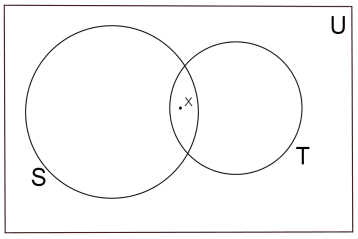
Pogledajmo sada kako bismo prikazali druge odnose među skupovima. Presjek skupova prikazujemo kao (osjenčani dio je presjek):



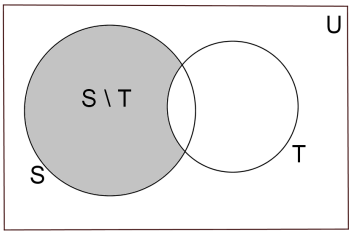
Ponovimo da sam crtež koji prikazuje skupove S i T nije važan u geometrijskom smislu. Dakle, nije važno da li je skup T nacrtan tako da je manji ili veći od skupa S. Ono što je relevantno je činjenica da se dva skupa mogu sjeći (dijeliti zajedničke elemente) i da to prikazujemo na dijagramu. Naravno, kao poseban slučaj se pojavljuje i onaj u kojem je presjek skupova prazan skup, ali to je uključeno u svim razmatranjima. Analogni prikaz unije skupova je dan sa:



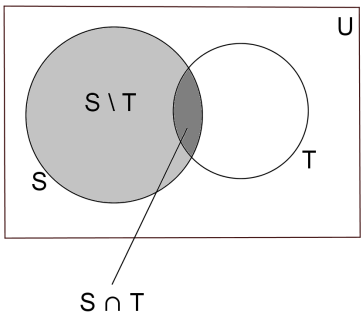
Naravno, ako je $x \in S \cap T$ to možemo prikazati kao:



Uz pomoć Vennovih dijagrama lakše možemo "vidjeti" svojstva razlike $S \setminus T$.

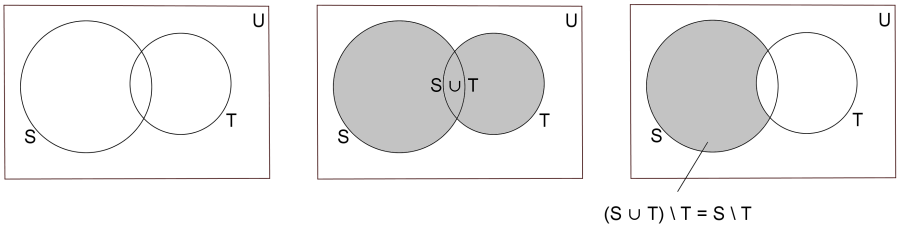


Pogledajmo kako izgleda skup $(S \setminus T) \cup (S \cap T)$ prikazan Vennovim dijagramima:



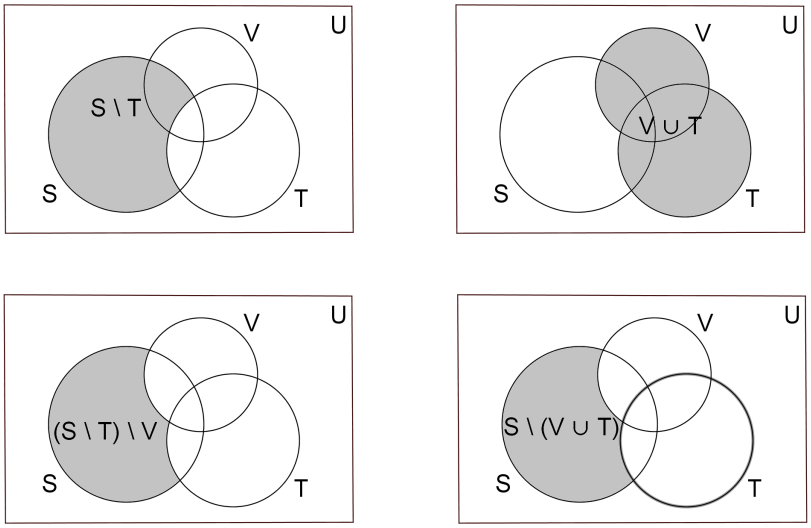
Koristeći se gornjim dijagramom jasnije nam je (zornije to vidimo) zašto je $(S \setminus T) \cup (S \cap T) = S$. Naime, vidimo da je unija dva osjenčana područja (to su $(S \setminus T)$ i $(S \cap T)$) jednaka skupu S.

Na sličan način možemo provjeriti da je $(S \cup T) \setminus T = S \setminus T$:



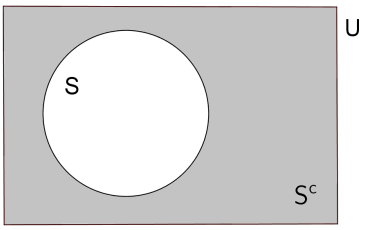
Za vježbu možete provjeriti kako bi se pokazalo da je $(S\setminus T)\cup(S\cap T)\cup(T\setminus S) = S\cup T$. Uočimo da je na taj način skup $S \cup T$ prikazan kao unija tri disjunktna skupa.

Pokažimo, korištenjem Vennovih dijagrama, da vrijedi skupovna jednakost $(S \setminus T) \setminus V = S \setminus (T \cup V)$:



Na sličan način možemo provjeriti da vrijedi $S \setminus (T \setminus V) = (S \setminus T) \cup (S \cap V)$.

U kontekstu korištenja Vennovih dijagrama možemo uvijek definirati i komplement skupa S jer su skupovi koje prikazujemo "uronjeni" u skup U. Grafički bi komplement skupa S prikazali kao:

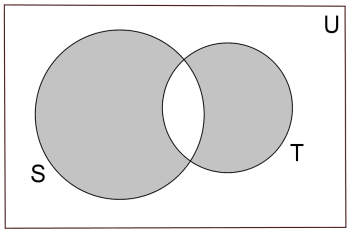


Jasno je da vrijedi: $S \cup S^c = U$ te $\emptyset^c = U$.

Još jedna skupovna operacija koju možemo uvesti je **simetrična razlika skupova**. Ona je definirana kao

$$S\triangle T = (S \setminus T) \cup (T \setminus S).$$

Oznaka za simetričnu razliku skupova je $S\triangle T$. Ime joj dolazi od činjenice da je sastavljena od unije dvije razlike skupova te da je komutativna (simetrična). Vennovim dijagramima simetričnu razliku prikazujemo kao:



Neka svojstva simetrične razlike su navedena u nastavku. Možemo uočiti da je simetrična razlika, za razliku od obične razlike skupova, komutativna i asocijativna operacija.

1. $S \triangle S = \emptyset$
2. $S \triangle \emptyset = S$
3. $S \triangle T = T \triangle S$ (komutativnost)
4. $(S \triangle T) \triangle V = S \triangle (T \triangle V)$ (asocijativnost)

3.1.3 Broj elemenata skupa; kardinalni broj

Vratimo se na početak naših razmatranja o skupovima. Vidjeli smo da elementi skupova mogu biti i drugi skupovi. Jedan poseban skup koji se može pridružiti svakom skupu S je skup svih podskupova od S. Oznaka za skup svih podskupova skupa S je $\mathcal{P}(S)$. Skup $\mathcal{P}(S)$ se još naziva i **partititivni skup** od S (engl. *power set*).

Najjednostavniji skup koji nam pada na pamet je prazan skup $\emptyset$. Njegov partitivni skup je skup $\mathcal{P}(S) = \{\emptyset\}$ jer je jedini podskup praznog skupa on sam. Dakle, partitivni skup od $\emptyset$ je jednočlan.

Ako skup S ima jedan element, recimo $S = \{1\}$, onda su svi podskupovi od S prazan skup $\emptyset$ i sam skup S. Dakle, u tom slučaju partitivni skup ima dva elementa, odnosno $\mathcal{P}(S) = \{\emptyset, \{1\}\}$.

Ako je $S = \{1, 2\}$, onda je $\mathcal{P}(S) = \{\emptyset, \{1\}, \{2\}, \{1, 2\}\}$ pa partitivni skup ima 4 elementa. u Primjeru 3.1.13 smo vidjeli da partitivni skup tročlanog skupa ima 8 elemenata. Lagano se provjeri da partitivni skup četveročlanog skupa ima 16 elemenata. Vidimo pravilnost.

Može se pokazati, matematičkom indukcijom, da za skup S s n elemenata, $n \in \mathbb{N}$, njegov partitivni skup $\mathcal{P}(S)$ ima 2^n elemenata. Uočimo da je paritivni skup najveći skup koji sadrži skupove koje čine elementi polaznog skupa S jer partitivni skup sadrži sve podskupove skupa S.

Vidmo da za konačne skupove možemo prilično lagano računati broj elemenata partitivnog skupa. No, što je s beskonačnim skupovima? Da li i za njih vrijede takva svojstva? Da li su sve beskonačnosti jednake? Na ta pitanja ne možemo dati odgovor alatima i pojmovima koje smo do sada uveli. No, ako malo "zakompliciramo" definiciju broja elemenata skupa vidjet ćemo da nam se otvaraju novi vidici vezani uz razlikovanje beskonačnosti.

Za početak uočimo da je osnovna mjera sličnosti koju možemo uvesti na skupovima vezana uz broj njihovih elemenata. Iako su, na primjer, skupovi $S = \{a, b, c\}$ i $T = \{1, 2, 3\}$ različiti (jer ne sadrže iste elemente) ipak su donekle slični jer imaju isti broj elemenata. Takvo razmatranje nas vodi na pojam kardinalnog broja skupa.

Definicija 3.1.36 (Kardinalni broj)**.** Neka je S neki skup. **Kardinalni broj** skupa S (kardinalitet skupa) je broj elemenata skupa S. Oznaka za kardinalni broj skupa je $|S|$. Ponekad se upotrebljava i oznaka $card(S)$.

Primjer 3.1.37. Neka je skup $S = \{a, b, c\}$. Tada je broj elementa skupa S jednak 3, odnosno $|S| = 3$, a $|\mathcal{P}(S)| = 2^3 = 8$.

Pogledajmo skup $T = \{\{a, b\}, \{c, d, e\}, \{f\}\}$. Pitamo se koji je broj elemenata skupa T. Kako su elementi skupa T skupovi $\{a, b\}$, $\{c, d, e\}$ i $\{f\}$ prema definiciji kardinalnog broja slijedi da je kardinalni broj skupa T jednak 3, odnosno $|T| = 3$.

Naravno, skupovi ne moraju biti zadani popisom svih elemenata, nego i navođenjem svojstava koje elementi skupa trebaju zadovoljavati. Tako možemo zadati skup $V = \{n \in \mathbb{N} \mid n < 12 \text{ i } n > 5\}$. Ovo je jednostavan primjer jer je zapravo $V = \{6, 7, 8, 9, 10, 11\}$ pa je $|V| = 6$. □

Skupovi ne moraju biti jednostavnih poput onih u prethodnom primjeru, a ne moraju biti niti konačni (sadržavati konačan broj elemenata). Problem određivanja kardinalnog broja skupa javlja se kod beskonačnih skupova. Kako oni nemaju konačan broj elemenata nije jasno koji im točno broj elemenata, odnosno koji im je kardinalni broj. Mogli bi se zapitati koji je uopće problem s beskonačnim skupovima. Čuveni matematičar David Hilbert osmislio je primjer s hotelom s beskonačno mnogo soba kako bi pokazao specifičnosti beskonačnih skupova (brojeva).

Ukoliko su u hotelu s konačno mnogo soba sve sobe popunjene i u hotel dolazi novi gost jednostavno ne postoji način da novi gost dobije sobu bez da neki prethodni gost ode iz hotela. U hotelu s beskonačno mnogo soba situacija je malo drugačija. Pretpostavimo da su sobe u takvom hotelu označene s $1, 2, 3$ i tako dalje te da su sve popunjene. Novi gost dolazi u hotel i traži sobu, a recepcioner mu je izdaje. Kako? Jedan od načina je da gost iz prve sobe ode u drugu sobu, gost iz druge sobe u treću, gost iz treće sobe u četvrtu i tako dalje. Naravno, u tom slučaju prva soba ostaje slobodna i u nju može ući novi gost. Na taj način svi prethodni gosti ostaju u hotelu (proizvoljni gost iz sobe $n \in \mathbb{N}$ ide u sobu $n+1$), a novom gostu je izdana soba broj 1.

Dakle, beskonačni skupovi imaju neke bitno drugačije karakteristike od konačnih skupova. Nije problem u tome da proizvoljno odredimo broj elemenata nekog beskonačnog skupa poput skupa prirodnih brojeva. Naime, možemo po definiciji staviti da je $|\mathbb{N}| = \aleph_0$, gdje se simbol $\aleph_0$ čita kao "alef nula". No, onda se nameće pitanje da li svi beskonačni skupovi imaju kardinalni broj $\aleph_0$? Odgovor je negativan, a da bi to razumijeli trebamo preciznije definirati kada dva skupa imaju jednak kardinalni broj.

Za početak probajmo malo razmisliti što znači da dva skupa imaju isti broj elemenata. Na neki način to znači da se elementi jednog od takva dva skupa mogu prebrojati elementima drugoga skupa i obratno. U osnovi to znači da postoji bijekcija između ta dva skupa. Ta bijekcija svakom elementu prvog skupa pridružuje jedan (i samo jedan) element drugog skupa te su time obuhvaćeni svi elementi drugoga skupa (to je definicija bijekcije iskazana riječima). Jasno je da postojanje bijekcije između dva konačna skupa zapravo implicira da skupovi imaju isti broj elemenata, odnosno isti kardinalni broj. Tu ideju ćemo pokušati primijeniti i na beskonačne skupove pa ćemo vidjeti da li ćemo moći reći nešto više o njima. Prije svega pogledajmo jedan primjer s konačnim skupovima.

Primjer 3.1.38. Pogledajmo skupove $S = \{1, 2, 3, 4, 5, 6\}$ i $T = \{a, b, c, d, e, f\}$. Oba skupa imaju po 6 elemenata pa im je i kardinalni broj jednak. Također, lagano je definirati bijekciju f sa S na T i to tako da je $f(1) = a$, $f(2) = b$, $f(3) = c$, $f(4) = d$, $f(5) = e$, $f(6) = f$. Naravno, postojanje takve bijekcije je zasnovano na činjenici da skupovi imaju jednak broje elmenata.

Da smo umjesto T uzeli skup $U = \{a, b, c, d, e\}$ bijekcija između S i U ne bi postojala (barem dva elementa iz S bi se morala preslikati u isti element skupa U). Naravno, u tom slučaju S i U nemaju isti broj elemenata što je konzistentno s činjenicom da među njima ne postoji bijekcija. □

Prethodna razmatranja nas vode do sljedeće definicije.

Definicija 3.1.39 (Skupovi s istim kardinalnim brojem)**.** Neka su S i T dva proizvoljna skupa (konačna ili beskonačna). S i T imaju **isti kardinalni broj** ako postoji bijekcija između S i T. Tada pišemo $|S| = |T|$.

Napomena 3.1.40 (Bijekcija)**.** Iako bi svi trebali biti upoznati s pojmom bijekcije, prisjetimo se njene definicije. Funkcija $f : D \to K$ je **bijekcija** ukoliko je injekcija i surjekcija. Skupovi D i K se zovu **domena** i **kodomena**.

Slika funkcije f je skup $\mathcal{I}m(f) = \mathcal{R}(f) = \{f(x) : x \in D\} \subset K$. Drugim riječima, $y \in K$ je u $\mathcal{I}m(f)$ ako i samo ako postoji barem jedan $x \in D$ takav da je $y = f(x)$.

Vidimo da je slika funkcije podskup kodomene, i to onaj podskup u kojem se nalaze svi elementi kodomene koji su preslikani iz nekog elementa domene. Poseban, a važan, slučaj je onaj u kojem se slika funkcije i kodomena podudaraju. Tada imamo:
funkcija $f : D \to K$ je **surjekcija** ako je $\mathcal{I}m(f) = K$. Ako je funkcija f surjekcija kažemo da f preslikava D "**na** K" (umjesto: f preslikava D "u K").

Funkcija $f : D \to K$ je **injekcija** ako iz $f(x) = f(y)$ slijedi $x = y$. Drugim riječima, svi elementi slike funkcije f su preslikani iz različitih elemenata domene. Ponekad se kaže da funkcija razlikuje elemente domene. Kako i inače funkcija f svakom elementu domene pridružuje samo jedan element kodomene, odnosno slike funkcije, uočavamo da kod injektivnih funkcija za svaki element iz slike funkcije f možemo reći kojem je elementu domene pridružen. Ako malo razmislimo, to zapravo znači da je dobro definirana i funkcija koje elementima kodomene pridružuje elemente domene iz kojih su oni preslikani funkcijom f. Tu novu funkciju zovemo inverznom funkcijom i označavamo sa f^{-1}.

Zaključujemo, funkcija koja je bijekcija svim elementima domene pridružuje različite elemente kodomene te se slika funkcije f i kodomena podudaraju. Bijekcije su vrlo cijenjene funkcije u matematici, pogotovo u kombinaciji s još nekim svojstvima koja čuvaju, na primjer, geometriju domene u kodomeni.

Surjektivnost funkcije se zapravo lako može "popraviti". Na primjer, $g : \mathbb{R} \to \mathbb{R}$ definirana s $g(x) = x^2$ nije surjekcija ali to postaje ako stavimo da joj je kodomena jednaka $[0, \infty)$. S druge strane, injektivnost nije uvijek lagano "popraviti". Ipak, iako g nije injekcija jer, na primjer, $g(-1) = g(1) = 1$, možemo promijeniti domenu da ona to postane. ukoliko stavimo da je domena jednaka $[0, \infty)$ kvadratna funkcije g postaje injekcija. Dakle, $g : [0, \infty) \to [0, \infty)$ takva da je $g(x) = x^2$ je bijekcija, a njena inverzna funkcija je $h(x) = \sqrt{x}$. Osnovni primjeri bijekcija su linearna funkcija ($g(x) = ax + b$, $a, b \in \mathbb{R}$), zatim potencije s neparnim eksponentom, ali i eksponencijalna i logaritamska funkcija. □

Primjer 3.1.41. Neka je $S = \{$pon, uto, sri, čet, pet, sub, ned $\}$ skup dana u tjednu, a $T = \{1, 2, 3, 4, 5, 6, 7\}$. Bijekcija između S i T je dana preslikavanjem f koje svakom danu u tjednu pridružuje njegov redni broj (s time da možemo reći da je prvi dan u tjednu ponedjeljak). Zbog postojanja bijekcije između S i T imamo da je $|S| = |T| = 7$. □

Još jednoim smo se uvjerili da je kod konačnih skupova lagano naći bijekcije ukoliko skupovi imaju jednak broj elemenata i obratno: ako među skupovima postoji bijekcija lagano je vidjeti da imaju jednak broj elemenata. Što je s beskonačnim skupovima?

Kod beskonačnih skupova postoje razne začudne situacije. Tako funkcija može preslikavati beskonačni skup na svoj pravi podskup i biti bijekcija, što je nezamislivo kod skupova s konačno mnogo elemenata. Na primjer, za funkciju $f : (1, +\infty) \to (1, 2)$ definiranu s

$$f(x) = 1 + \frac{1}{x}$$

lagano pokažemo da je bijekcija sa skupa $(1, +\infty)$ na skup $(1, 2)$, koji je pravi podskup od $(1, +\infty)$. Iako je skup $(1, 2)$ pravi podskup od $(1, +\infty)$ postojanje bijekcije među tim skupovima indicira da ti skupovi imaju jednak kardinalni broj, odnosno jednak broj elemenata.

Takvih primjera imamo još. Pogledajmo sljedeća tri jednostavna primjera

Primjer 3.1.42. Pogledajmo sljedeća dva beskonačna skupa: skup prirodnih brojeva $\mathbb{N} = \{0, 1, 2, 3, 4, 5, 6, 7, ...\}$ i skup $P = \{0, 2, 4, 6, 8, 10, 12, 14...\}$ svih parnih prirodnih brojeva (možemo pisati i $P = \{n \in \mathbb{N} \mid n$ paran$\}$).

Definirajmo funkciju $f : \mathbb{N} \to P$ sa $f(n) = 2n$. Ta funkcija je bijekcija. Surjekcija je jer se bilo koji parni broj može prikazati kao umnožak $2 \cdot n$, gdje je n neki prirodni broj. Na

primjer, $2 \cdot 0 = 0 \in P$, $2 \cdot 1 = 2 \in P$, $2 \cdot 2 = 4 \in P$ i tako dalje. Po definiciji to znači da je funkcija f surjekcija. Injektivnost provjeravamo tako da pretpostavimo da za neke $n, m \in \mathbb{N}$ vrijedi $f(n) = f(m)$. To znači da je $2n = 2m$, a iz toga nužno proizlazi da je $n = m$, što je i trebalo provjeriti prema definiciji injektivnosti. Zbog postojanja bijekcije između $\mathbb{N}$ i P iz definicije 3.1.39 zaključujemo da je $|P| = |\mathbb{N}| = \aleph_0$. Dakle, kardinalni broj skupa $\mathbb{N}$ i skupa prirodnih parnih brojeva je jednak (kardinalnim brojem skupa ta dva skupa ne možemo razlikovati). Drugim riječima, postoji jednak broj prirodnih brojeva i prirodnih parnih brojeva, iako je skup parnih prirodnih brojeva pravi podskup od $\mathbb{N}$. □

Primjer 3.1.43. Po uzoru na prethodni primjer probajmo izračunati koji je kardinalni broj od $\mathbb{Z}$, odnosno kardinalni broj skupa cijelih brojeva. Uz standardne oznake za prirodne brojeve $\mathbb{N}$ i cijele brojeve $\mathbb{Z}$ definirajmo funkciju $f : \mathbb{N} \to \mathbb{Z}$ sa

$$f(n) = \begin{cases} \dfrac{n}{2} & \text{, n paran} \\ -\dfrac{n+1}{2} & \text{, n neparan.} \end{cases}$$

Dakle, funkcija f prirodnim brojevima pridružuje njihovu polovicu ako su parni, odnosno $-(n+1)/2$ ako su neparni. Konkretno, za $n = 2$ je $f(2) = 1$, dok je za $n = 3$, $f(3) = -(3+1)/2 = -2$.[1] Ta funkcija je bijekcija. To se prilično lagano provjeri, s time da treba razlikovati slučajeve parnih i neparnih brojeva iz $\mathbb{N}$. U svakom slučaju, pronašli smo jednu bijekciju između skupova $\mathbb{N}$ i $\mathbb{Z}$. Prema tome, opet možemo zaključiti da je $|\mathbb{Z}| = |\mathbb{N}| = \aleph_0$. □

Na prvi pogled se čini da skup $\mathbb{Z}$ ima više elemenata od $\mathbb{N}$ (ili P iz prethodnog primjera), ali vidimo da oni imaju isti broj elemenata prema definiciji kardinalnog broja skupa. Uočimo da skup P i $\mathbb{Z}$ također imaju jednak broj elemenata jer postoji bijekcija sa $\mathbb{Z}$ na $\mathbb{N}$ i bijekcija sa $\mathbb{N}$ na P pa je kompozicija te dvije bijekcije opet bijekcija i to sa $\mathbb{Z}$ na P.

Mogli bi pomisliti da su brojevi u $\mathbb{Z}$ i $\mathbb{N}$ bili prilično "bliski" pa da zbog toga nisu promijenili kardinalitet skupa. Da li se nešto mijenja ako gledamo skupove u kojima su brojevi "udaljeniji"? Pogledajmo sljedeći primjer.

Primjer 3.1.44. Pogledajmo skupove $\mathbb{N} = \{0, 1, 2, 3, 4, 5, 6, ...\}$ i skup potencija broja 2 koji je jednak $S = \{1, 2, 4, 8, 16, 32, 64, 128...\}$ (možemo pisati i $\{n \in \mathbb{N} \mid n \text{ je potencija broja } 2\}$).

Definirajmo funkciju $f : \mathbb{N} \to S$ sa $f(n) = 2^n$. Opet lagano provjerimo da je to bijekcija. Iz same definicije skupa S je jasno da je f surjekcija, a injektivnost se lagano vidi prema definiciji. Stoga je, opet, $|S| = |\mathbb{N}| = \aleph_0$. □

Sada već možemo postati malo sumnjičavi. Da li iz prethodnih primjera možemo naslutiti da svi beskonačni skupovi imaju isti kardinalni broj? Da li postoji samo jedna vrsta beskonačnosti pa je zapravo pojam kardinalnog broja skupa beskoristan jer uopće ne razlikuje beskonačne skupove?

Vidjet ćemo da je odgovor na prethodna pitanja negativan, a u tu svrhu ćemo se usredotočiti na pojam partitivnog skupa. Vidjeli smo da za sve skupove s konačno mnogo elemenata vrijedi da je $|S| < |\mathcal{P}(S)|$. Preciznije, ukoliko je $|S| = n$, onda je $|\mathcal{P}(S)| = 2^n$.

Općenito se može dokazati da vrijedi sljedeći teorem. Dokaz tog teorema u osnovnom slučaju je dan u Napomeni 3.1.46.

[1] Čitatelj i sam može provjeriti vrijednosti funkcije f za druge izbore broja n, ali je za intuiciju važno uočiti kako f djeluje na nekoliko prvih prirodnih brojeva. Imamo sljedeća pridruživanja po funkciji f: $0 \mapsto 0$, $1 \mapsto -1$, $2 \mapsto 1$, $3 \mapsto -2$, $4 \mapsto 2$ i tako dalje.

Teorem 3.1.45 (Cantorov teorem)**.** *Svaki je skup strogo manji od svog partitativnog skupa, mjereno kardinalnim brojem skupa. Drugim riječima, za svaki skup S vrijedi $|S| < |\mathcal{P}(S)|$.*

Iz Cantorovog teorema zapravo zaključujemo da je $|\mathbb{N}| < |\mathcal{P}(\mathbb{N})|$. Dakle, postoje različite vrste beskonačnosti, odnosno nisu svi beskonačni skupovi jednako veliki. Naravno, možemo se nadalje zapitati koliko različitih beskonačnosti postoji. Jedan način da to saznamo je da nastavimo primjenu Cantorovog teorema na partitivne skupove partitivnih skupova. Tako dobivamo da je

$$|\mathcal{P}(\mathbb{N})| < |\mathcal{P}(\mathcal{P}(\mathbb{N}))|$$
$$|\mathcal{P}(\mathcal{P}(\mathbb{N}))| < |\mathcal{P}(\mathcal{P}(\mathcal{P}(\mathbb{N})))|$$
$$\dots$$

Ponavljajući upravo opisani postupak u nedogled dobivamo sve veće i veće skupove, u smislu njihovog kardinalnog broja. Na taj način vidimo da zapravo postoji beskonačno mnogo beskonačnosti.

Vratimo se na osnovnu situaciju od koje smo krenuli. Vidjeli smo da je prvi beskonačni kardinalni broj pridružen skupu prirodnih brojeva (kao i skupu cijelih i racionalnih brojeva) i uveli smo oznaku $|\mathbb{N}| = \aleph_0$. Iz Cantorovog teorema znamo da je partitivni skup prirodnih brojeva kardinalno veći od skupa prirodnih brojeva. Također, Cantorovim argumentom[2] se pokazuje da je kardinalni broj skupa realnih brojeva strogo veći od kardinalnog broja skupa prirodnih brojeva. Dakle, realnih brojeva ima bitno više od prirodnih brojeva. Ujedno, skup prirodnih i realnih brojeva su osnovni primjeri beskonačnih skupova čiji su kardinalni brojevi različiti. Naravno, puno je dodatnih takvih primjera (poput skupa svih funkcija sa $\mathbb{N}$ u $\mathbb{N}$), ali su $\mathbb{N}$ i $\mathbb{R}$ primjeri skupova o kojima imamo najveću intuiciju i za koje su gotovo svi čuli u toku svog obrazovanja pa ih to izdvaja nad ostalima.

Ono što trebamo zapamtiti je da skupovi $\mathbb{N}$ i $\mathbb{R}$ imaju različite kardinalne brojeve. Za skupove koji imaju jednak broje elemenata kao i $\mathbb{N}$ (a to su i $\mathbb{Z}$ i $\mathbb{Q}$, ali i $\mathbb{N}^n$, $n \in \mathbb{N}$) kažemo da su **prebrojivi**. Skupovi koji nisu prebrojivi su **neprebrojivi**.. Takvi su $\mathbb{R}$, ali i $(a, b) \subset \mathbb{R}$, $a, b \in \mathbb{R}$ ili $\mathbb{R}^n$, $n \in \mathbb{N}$. Ponekad se kardinalni broj skupa $\mathbb{R}$ označava sa $\mathfrak{c}$ (kontinuum).

Sljedeće dvije napomene nam neće trebati u nastavku, ali ih zainteresirani čitatelj može pročitati.

Napomena 3.1.46 (Cantorov dijagonalni argument)**.** Uzmimo skup S s beskonačno mnogo elemenata i pretpostavimo da je $|S| = |\mathcal{P}(\mathcal{S})|$. Prema definiciji kardinalnog broja to znači da postoji bijekcija $f : S \to \mathcal{P}(S)$. Označimo elemente skupa S sa $S = \{s_1, s_2, s_3, s_4, s_5, \dots\}$. Moguća bijekcija f između S i $\mathcal{P}(S)$ bi svakom elementu iz domene S pridružila neki element iz kodomene $\mathcal{P}(S)$. Drugim riječima, ta bijekcija bi svakom elementu skupa S pridružila neki podskup od S (jer su to elementi od $\mathcal{P}(S)$). Ne znamo točno kako ta bijekcija f izgleda, ali bi ona općenito bila pridruživanje sljedećeg oblika:
$s_1 \to \{s_1, s_2, s_4, ...\}$
$s_2 \to \{s_1, s_3, s_4, ...\}$
$s_3 \to \{s_4, ...\}$
$s_4 \to \{s_1, s_5, ...\}$
$s_5 \to \{s_1, s_2, s_3, s_4, s_5...\}$
$\dots$

[2] pogledajte Napomenu 3.1.46 da vidite o kakvom se argumentu tu radi

Na taj način svakom elementu iz S pridružimo element iz $\mathcal{P}(\mathcal{S})$ čime definiramo funkciju f. Naravno, tako je navedena samo jedna takva funkcija, ali je dosta jasno da proizvoljna moguća bijekcija izgleda poput gore navedene. Moguće su varijacije u početnim elementima pridruženih podskupova od S i u njihovom poretku pa tako možda prvi element skupa koji je pridružen elementu s_1 nije baš s_1, nego s_{346}, ali radi jednostavnosti zapisa pretpostavimo da je ta proizvoljna bijekcija poput navedene (vidjet ćete uskoro da nam za argumentaciju koju ćemo dati to nije presudno).

Formirajmo sada matricu u kojoj će u recima biti navedeni najprije elementi skupa S, a nakon toga će biti navedene nule ili jedninice, u ovisnosti o tome da li je pojedini element skupa S sadržan u skupu koji je pridružen tom elementu. Recimo, elementu s_1 će pripadati redak oblika $1,1,0,1,0$ jer $s_1 \in f(s_1)$, $s_2 \in f(s_1)$, $s_3 \notin f(s_1)$, $s_4 \in f(s_1)$, $s_5 \notin f(s_1)$ i tako dalje. Dakle, dobivamo matricu:

	s_1	s_2	s_3	s_4	s_5	...
s_1	1	1	0	1	0	...
s_2	1	0	1	1	0	...
s_3	0	0	0	1	0	...
s_4	1	0	0	0	1	...
s_5	1	1	1	1	1	...
$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$

Sada u navedenoj matrici pogledajmo elemente dijagonale. Radi preglednosti ih podcrtamo s vodoravnom crtom:

	s_1	s_2	s_3	s_4	s_5	...
s_1	$\underline{1}$	1	0	1	0	...
s_2	1	$\underline{0}$	1	1	0	...
s_3	0	0	$\underline{0}$	1	0	...
s_4	1	0	0	$\underline{0}$	1	...
s_5	1	1	1	1	$\underline{1}$	...
$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$

U sljedećem koraku elementima dijagonale matrice promjenimo pridruženi binarni broj: na mjestu na kojem je pisalo 0 stavimo 1, a tamo gdje je pisalo 1 stavimo 0. Dobijemo matricu:

	s_1	s_2	s_3	s_4	s_5	...
s_1	$\underline{0}$	1	0	1	0	...
s_2	1	$\underline{1}$	1	1	0	...
s_3	0	0	$\underline{1}$	1	0	...
s_4	1	0	0	$\underline{1}$	1	...
s_5	1	1	1	1	$\underline{0}$	...
$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$

Sada se sjetimo interpretacije elemenata matrice kojima smo označili pripadnost pojedinog elementa nekom podskupu skupa S. U terminima podskupova od S, gledajući samo elemente na dijagonali matrice, dobijemo podskup $T = \{s_2, s_3, s_4, ...\}$ od S. Iz samog postupka mijenjanja nula za jedinice i jedinica za nule na mjestima dijagonale, jasno je da na taj način dobivamo jedan podskup od S koji je različit od bilo kojeg podskupa $f(s)$, gdje je $s \in S$ neki proizvoljan element skupa S. Kako god da smo odabrali početnu bijekciju, na ovaj ćemo način dobiti skup koji je različit od svih $f(s_i), i \in (N)$, prema konstrukciji skupa T.

Dakle, našli smo jedan element kodomene kojemu nije pridružen niti jedan element domene prema pravilu pridruživanja f. Stoga takvo preslikavanje f nije surjekcija, a onda nije niti bijekcija. Stoga možemo zaključiti da ne postoji bijekcija sa S na $\mathcal{P}(S)$ (zapravo surjekcija) pa zaključujemo da skup $\mathcal{P}(S)$ ima više elemenata od skupa S.

Argumentacija koju smo primijenili da bi pokazali nepostojanje bijekcije između S i $\mathcal{P}(S)$ naziva se Cantorov dijagonalni argument.

Uočimo formu gornjeg argumenta, a zapravo dokaza. Želimo pokazati tvrdnju da ne postoji bijekcija između S i $\mathcal{P}(S)$. Pretpostavili smo suprotno: postoji bijekcija $f : S \to \mathcal{P}$. Cantorovim dijagonalnim argumentom pokazujemo da f nije bijekcija. Dolazimo do kontradikcije (f je i nije bijekcija). Stoga je početna pretpostavka (postoji bijekcija $f : S \to \mathcal{P}(S)$) bila neistinita. Dakle, ne postoji bijekcija između S i $\mathcal{P}(S)$. Ovakav tip dokaza zove se dokaz kontradikcijom. □

Napomena 3.1.47. Vidjeli smo da uzastopnom primjenom Cantorovog teorema na partitivne skupove partitivnih skupova dobivamo različite beskonačnosti, odnosno različite kardinalne brojeve. U duhu oznake za prvi beskonačni kardinal možemo reći da dobivamo beskonačne kardinalne brojeve $\aleph_0, \aleph_1, \aleph_2, \aleph_3, \ldots$. Zbog načina na koji smo vidjeli da se mogu konstruirati skupovi sve većeg kardinalnog broja te prema analogiji s kardinalnim brojem partitivnog skupa konačnog skupa, možemo se zapitati da li je zapravo $\aleph_1$ kardinalni broj partitivnog skupa prirodnih brojeva, odnosno da li je $2^{\aleph_0} = \aleph_1$. Kako znamo da je kardinalni broj skupa realnih brojeva strogo veći od $\aleph_0$ zapravo se možemo zapitati da li je kardinalni broj skupa realnih brojeva jednak $\aleph_1$. Mogućnost da je ta tvrdnja istinita se naziva Cantorova hipoteza kontinuuma prema tradicionalnom nazivu kontinuum za skup realnih brojeva.

Po uzoru na prethodno pitanje općenito se možemo zapitati da li vrijedi da je $2^{\aleph_a} = \aleph_{a+1}$. Ta se tvrdnja naziva poooopćena hipoteza kontinuuma. Iako je obje hipoteze lagano formulirati i iako se čini da bi one mogle biti istinite sam dokaz tih tvrdnji se pokazao vrlo teškim problemom. Traženje odgovora na pitanje istinitosti hipoteza kontinuuma doveo je do nekih od najvećih napredaka u formalnoj logici. Na ovom mjestu ne možemo dati čak ni približan opis statusa hipoteza kontinuuma koristeći se znanjima koja imamo, ali u nastavku ćemo probati dati neke okvire u kojima se nalazi odgovor.

Rezultati o skupovima koje smo do sada prikazivali pripadaju tako zvanoj naivnoj teoriji skupova. U okviru te teorije se pojavljuju neki paradoksi koji proizlaze iz činjenice da smo zapravo rekli da je skup svaka kolekcija elemenata koja se može zadati nekim svojstvom. Britanski matematičar Bertrand Russel je pokazao da takva definicija vodi do paradoksa. Naime, definirajmo skup R kao skup svih skupova koji nisu elementi sami sebe. Simbolički to možemo zapisati kao $R = \{x \mid x \notin x\}$. Problem je što ako pretpostavimo da je da je R sadržan u R, onda prema definiciji skupa R zapravo R nije sadržan u R i obratno.

Da bi se izbjegli takvi paradoksi pristupilo se izradi aksiomatske teorije skupova (bilo je i drugih pravaca razvoja) koja je na kraju izrasla u standardnu Zermelo-Fraenkelovu aksiomatsku teoriju skupova (ZF teorija skupova). Riječ je o skupu od 9 aksioma koji su trebali dati potpun opis teorije skupova. Problem ZF teorije skupova je to što se u okviru te teorije ne može odrediti da li je hipoteza kontinuuma točna ili nije.

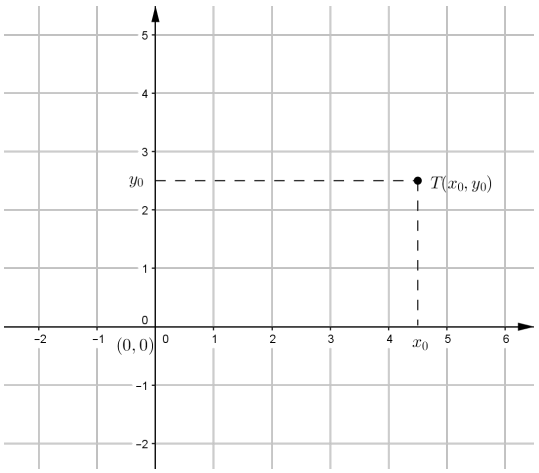
Austrijski matematičar Kurt Goedel je 30-tih godina prošlog stoljeća pokazao da bilo koji sustav aksioma koji je dovoljno kompleksan (a u tu kategoriju bi spadao sustav aksioma ZF teorije skupova) ne može biti istovremeno konzistantan i potpun. Sustav aksioma je konzistentan ako ne vodi do kontradikcija, a potpun je ako se bilo koja formula (izraz koji se može fomulirati unutar teorije koja se promatra) može dokazati ili opovrgnuti unutar teorije koju generiraju promatrani aksiomi. Također je Goedel dokazao da se konzistentnost neke grupe aksioma ne može dokazati u okviru tih aksioma. Riječ je kompleksnim rezultatima i ovdje ih ne možemo detaljnije objasniti.

Ipak, možemo konstatirati da je Goedel dokazao da je istinitost hipoteze kontinuuma konzistentna s aksiomima ZF teorije skupova. Doduše, kasnije je američki matematičar Paul Cohen dokazao i da je negacija hipoteze kontinuuma konzistentna s aksiomima

ZF teorije skupova. U osnovi to znači da je hipoteza kontinuuma nezavisna o ostalim aksiomima ZF teorije skupova (ne može se iz njih ni dokazati ni opovrgnuti). Na taj način je pitanje istinitosti hipoteze kontinuuma i dalje otvoreno pitanje, usprkos relativnoj jednostavnosti i intuitivnosti postavljene hipoteze. □

3.1.4 Kartezijev produkt skupova

Ideja Kartezijevog produkta skupova ima porijeklo u geometriji, gdje se dosta prirodno javlja potreba za preciznijim određivanjem položaja i odnosa među geometrijskim objektima (pravcima, ravninama, pravokutnicima, kružnicama i tako dalje). Uvođenjem, svima dobro poznatog, Kartezijevog koordinantnog sustava omogućeno je precizno određivanje pozicije bilo koje točke, a time i objekta koje točke grade poput dužine ili pravca, u ravnini. Grafički Karterzijev koordinantni sustav i položaj proizvoljne točke T u ravnini prikazujemo kao na slici:



Kao što znamo točka $(0,0)$ zove se ishodište, os x nazivamo apscisom, a os y ordinatom. Položaj bilo koje točke u ravnini moguće je odrediti pomoću dvije koordinate x i y. One nam govore koliko je točka T udaljena od ishodišta po osi x i po osi y. Na prethodnoj slici točka T je udaljena za x_0 od ishodišta u (pozitivnom) smjeru osi x te za y_0 od ishodišta u (pozitivnom) smjeru osi y. Naravno, x_0 i y_0 mogu biti i negativni ukoliko se od ishodišta udaljavamo u smjeru negativnih brojeva bilo na osi x ili na osi y.

Kada malo razmislimo uviđamo da je uvođenjem Karterzijevog koordinantnog sustava u ravnini definirano pravilo pridruživanja (bijekcija) koje svakoj točki T iz ravnine pridružuje njene koordinate (x_0, y_0). Koordinate (x_0, y_0) čine uređeni par. Za razliku od skupa $\{x_0, y_0\}$ kod uređenog para (x_0, y_0) je poredak važan jer nije svejedno koju koordinatu prvu napišemo (prva koordinata označava udaljenost u smjeru osi x od ishodišta, a druga u smjeru osi y). Dakle, uvođenjem Kartezijevog koordinatnog sustava u ravnini definirano je preslikavanje sa skupa svih točaka u ravnini na skup svih uređenih parova (x, y), gdje su $x, y \in \mathbb{R}$. Skup svih točaka u ravnini čini samu ravninu, označimo je s U, dok skup svih uređenih parova čini skup $\mathbb{R} \times \mathbb{R}$, što je oznaka za Kartezijev produkt skupova $\mathbb{R}$ i $\mathbb{R}$. Ova konstrukcija je motivacija za sljedeću definiciju.

Definicija 3.1.48 (Kartezijev produkt skupova)**.** Neka su S i T neprazni skupovi. **Kartezijev produkt** skupova S i T je skup koji označavamo s $S \times T$ i definiramo kao

$$S \times T = \{(s,t) \mid s \in S, t \in T\} \ \Big(= \{(s,t) \mid \ s \in S \wedge t \in T\}\Big).$$

Elementi Kartezijevog produkta skupova S i T su uređeni parovi (s,t), gdje je $s \in S$ i $t \in T$. Ukoliko su (s,t) i (u,v) dva elementa iz $S \times T$ onda su oni jednaki akko je $s = u$ i $t = v$. Ukoliko je bilo koji od skupova S ili T prazan, onda je $S \times T = \emptyset$.

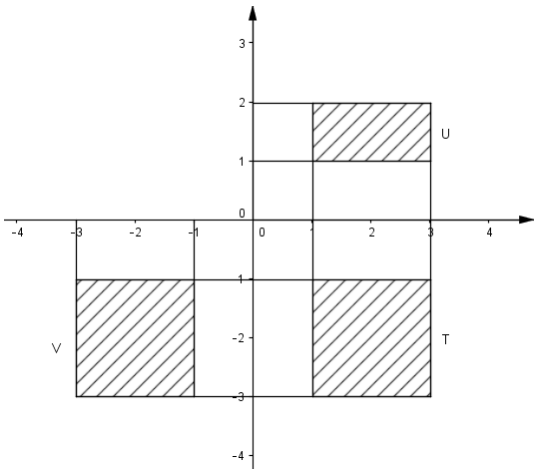
Napomenimo da se radi praktičnijeg zapisa za Kartezijev produkt skupa S sa samim sobom koristi oznaka S^2, odnosno

$$S \times S = S^2.$$

Naravno, tada je i

$$\mathbb{R} \times \mathbb{R} = \mathbb{R}^2.$$

Primjer 3.1.49. Pogledajmo kakve skupove dobivamo kad napravimo Kartezijev produkt skupova sa osi x i osi y. Tipično će to biti neki intervali (ili segmenti), a njihov Kartezijev produkt će biti pravokutnik kao što je prikazano na sljedećoj slici:



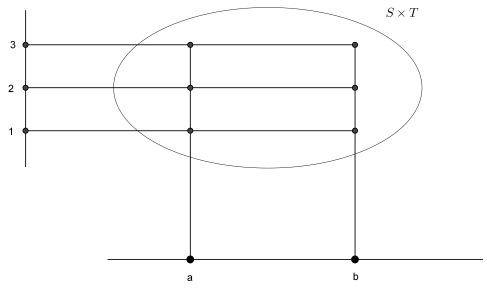
Skup U je Kartezijev produkt skupova $[1,3]$ i $[1,2]$, skup V je Kartezijev produkt skupova $[-3,-1]$ i $[-3,-1]$, dok je T Kartezijev produkt od $[1,3]$ i $[-3,-1]$. □

Pogledajmo jedan jednostavan primjer Kartezijevog produkta dva konačna skupa.

Primjer 3.1.50. Uzmimo skupove $S = \{a, b\}$ i $T = \{1, 2, 3\}$. Pogledajmo koje elemente sadrži skup $S \times T$. Prema gornjoj definiciji je $S \times T = \{(s,t) \mid s \in \{a,b\}, t \in \{1,2,3\}\}$ pa zaključujemo da je

$$S \times T = \{(a,1), (a,2), (a,3), (b,1), (b,2), (b,3)\}.$$

Kartezijev produkt skupova možemo i u ovom slučaju prikazati grafički samo što sada na os x nanosimo elemente skupa S, a na os y elemente skupa T:



Grafički, elementi skupa $S \times T$ su točke koje se nalaze u sjecištu paralela povučenih iz točaka a i b sa osi y i paralela povučenih iz točaka 1, 2 i 3 s osi x. Uočimo da skup $S \times T$ sadrži 6 točaka, a to je umnožak $|S|$ i $|T|$, odnosno kardinalnih brojeva skupova S i T. Dakle, $|S \times T| = |S| \cdot |T|$. □

Kao što smo uveli Kartezijeve koordinate u ravninu možemo uvesti Kartezijeve koordinate u trodimenzionalni prostor P. Definiramo preslikavanje $K : P \to \mathbb{R} \times \mathbb{R} \times \mathbb{R}$, kojim se svakoj točki $T \in P$ pridružuje uređena trojka (x_0, y_0, z_0) kojom zapravo prikazujemo relativne udaljenosti točke T od ishodišta $(0, 0, 0)$ u smjerovima x, y ,z. Opet, radi lakšeg zapisa uvodimo oznaku

$$\mathbb{R} \times \mathbb{R} \times \mathbb{R} = \mathbb{R}^3.$$

Prilično je jasno kako se pojam Kartezijevog produkta skupova poopćava na više skupova.

Definicija 3.1.51 (Kartezijev produkt konačno mnogo skupova)**.** Neka su $S_1, ..., S_n$ neprazni skupovi,$n \in \mathbb{N}$. Kartezijev produkt skupova $S_1, ..., S_n$ je skup

$$S = S_1 \times ... \times S_n = \{(s_1, ..., s_n) \mid s_1 \in S_1, ..., s_n \in S_n\}.$$

Elemente skupa $S_1 \times ... \times S_n$ zovemo uređenim n-torkama. Dvije uređene n-torke $(s_1, ..., s_n)$ i $(t_1, ..., t_n)$ iz $S_1 \times ... \times S_n$ su jednake akko je $s_1 = t_1$, $s_2 = t_2$, ... , $s_n = t_n$.

Ukoliko su svi $S_i = S$, gdje je S skup, $i = 1, 2, \ldots, n$, onda opet koristimo oznaku

$$S_1 \times ... \times S_n = S^n.$$

Tako, kada pišemo $\mathbb{N}^n$ ili $\mathbb{R}^n$, $n \in \mathbb{N}$, znamo da se radi o Kartezijevom produktu n skupova $\mathbb{N}$, odnosno $\mathbb{R}$, sa samim sobom.

Uočimo da se u najvećem dijelu matematike se pod produktom dva ili više skupova smatra Kartezijev produkt tih skupova. Možemo reći da je to "prirodan" produkt skupova. Naravno, to nije jedina mogućnost za produkt skupova jer smo za skupove S i T mogli definirati produkt poput $S \cdot T = \{s \cdot t \mid s \in S, t \in T\}$ (ukoliko znamo što je $s \cdot t$), ali ako se negdje posebno ne napomene pod produktom skupova smatramo Kartezijev produkt skupova. Utoliko su oznake $\mathbb{N}^n$ ili $\mathbb{R}^n$ univerzalne i svima razumljive.

Jedno od važnijih svojstava (Kartezijevog) produkta skupova se mogao naslutiti u Primjeru 3.1.50. Naime, za za općenite konačne skupove S i T vrijedi da je broj elemenata Kartezijevog produkta skupova S i T jednak produktu broja elemenata skupova S i T. Kraće zapisano, vrijedi

$$|S \times T| = |S| \cdot |T|. \tag{3.4}$$

Vrijedi i općenitija formula prema kojoj je za $S_1, ..., S_n$ konačne skupove

$$|S_1 \times ... \times S_n| = |S_1| \cdot ... \cdot |S_n|. \tag{3.5}$$

Ta je formula osnova za prebrojavanje elemenata vrlo različitih skupova što ćemo često koristiti u nastavku.

Kartezijev produkt skupova se dobro ponaša prema uniji i presjeku skupova. Za A, B, C tri skupa imamo:

$$(A \cup B) \times C = (A \times C) \cup (B \times C)$$

$$(A \cap B) \times C = (A \times C) \cap (B \times C).$$

Napomenimo za kraj ovog poglavlja sa skupovima da je skup $\{0, 1\}^{\mathbb{N}}$ neprebrojiv, odnosno da je $|\{0, 1\}^{\mathbb{N}}| = |\mathcal{P}(\mathbb{N}|)$. To zapravo znači da beskonačnih nizova nula i jedinica ima neprebrojivo mnogo. Uočite da smo već napomenuli da je konačan produkt prebrojivih skupova prebrojiv skup.

3.2 Skup elementarnih događaja i naivna definicija vjerojatnosti

Na početku ovog poglavlja smo rekli da se vjerojatnost bavi modeliranjem slučajnih eksperimenata. Ishodi slučajnih eksperimenata mogu se objediniti tako da čine skup. Taj skup ima istaknutu ulogu u vjerojatnosti. Imamo sljedeću definiciju.

Definicija 3.2.1. Skup svih mogućih ishoda slučajnog eksperimenta naziva se **prostor elementarnih događaja**. Njegovi elementi se nazivaju **elementarni događaji**. Prostor elementarnih događaja označavamo s Ω. Podskupove prostora elementarnih događaja Ω zovemo **slučajnim događajima**.

Vidjet ćemo, kroz primjere, da se elementarnim događajima smatraju oni ishodi slučajnih eksperimenata koji se ne mogu razložiti na jednostavnije ishode. Kako su slučajni događaji podskupovi od Ω jasno je da su njihovi elementi elemetarni događaji. Slučajne događaje tipično označavamo velikim slovima poput A, B, E, F.

Uočimo da ishodi nekog slučajnog eksperimenta ne moraju biti konačni. Sukladno tome prostor elementarnih događaja može biti konačan, prebrojiv ili neprebrojiv. U ovom poglavlju ćemo uglavnom gledati konačne prostore elementarnih događaja. Pogledajmo neke primjere.

Primjer 3.2.2 (Bacanje novčića)**.** Ako slučajnim eksperimentom smatramo bacanje novčića, onda u osnovi imamo samo dva moguća ishoda - pasti će pismo ili glava (pismo je ona strana novčića na kojoj je broj). Teoretski je moguće da novčić padne i na rub, ali to je toliko rijetko da se može zanemariti prilikom modeliranja tog slučajnog eksperimenta. Stoga je prostor elementarnih događaja u ovom slučaju $\Omega = \{\text{pismo}, \text{glava}\}$, odnosno skraćeno $\Omega = \{P, G\}$. Često ćemo umjesto ishoda P i G koristiti 0 i 1 pa možemo pisati $\Omega = \{0, 1\}$. □

Primjer 3.2.3 (Bacanje kockice)**.** Svi mogući ishodi prilikom bacanja kockice, a govorimo o broju na kockici koji je okrenut prema gore, su 1, 2, 3, 4 ,5 ili 6. Stoga je prostor elementarnih događaja za slučajni eksperiment bacanja simetrične kockice $\Omega = \{1, 2, 3, 4, 5, 6\}$.
Slučajne događaje smo definirali kao podskupove od Ω. Primjeri slučajnih događaja u ovom slučajnom eksperimentu su $A = \{1, 2, 3\}$ ili $B = \{2, 4, 6\}$. Često se slučajni događaji ne zadaju kao skupovi, nego se opisuju govornim jezikom. Tako je $A =$ "broj koji je pao na kockici je manji ili jednak 3", a $B =$ "broj koji je pao na kockici je paran". Za razliku od elementarnih događaja, slučajni događaji se mogu razložiti na elementarnije događaje. Prilikom izvođenja slučajnog eksperimenta potrebno je utvrditi sve moguće ishode slučajnog eksperimenta koji se ne mogu razložiti na jednostavnije ishode. Jasno, ti elementarni (nerazloživi) ishodi slučajnog eksperimenta čine prostor elementarnih događaja.
Uočite, podskupovi skupa mogu biti i jednočlani. Stoga su i jednočlani skupovi koji se sastoje od samo jednog elementarnog događaja također slučajni događaji. Tako je, na primjer, skup $C = \{2\}$ slučajni događaj koji se sastoji samo od elementarnog događaja 2 ("broj koji je pao na kockici je jednak 2"). Kao što smo vidjeli u odjeljku o skupovima $2 \neq \{2\}$, ali je $2 \in \{2\}$, odnosno elementarni događaj 2 je jedini element slučajnog događaja C.
Općenito, slučajne događaje (konačne ili prebrojive) možemo predstaviti kao unije jednočlanih skupova koji sadrže elementarne događaje. Na primjer, $A = \{1\} \cup \{2\} \cup \{3\}$. □

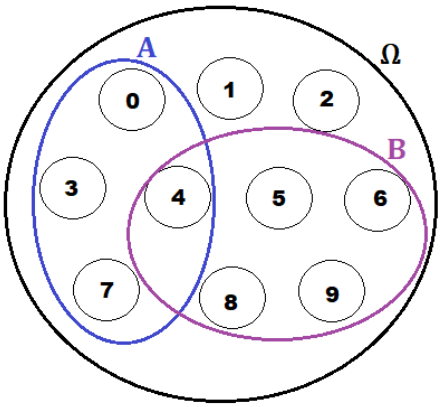
Primjer 3.2.4 (Mjesec rođenja)**.** Hodamo ulicom i pitamo se u kojem je mjesecu rođen prvi sljedeći čovjek kojeg ćemo sresti. Riječ je o slučajnom eksperimentu pa je prikladno

definirati prostor elementarnih događaja kao skup svih 12 mjeseci u godini. Dakle, možemo definirati $\Omega = \{sij, velj, ozu, tra, svi, lip, srp, kol, ruj, lis, stu, pro\}$. □

Primjer 3.2.5 (Broj riječi u knjizi)**.** Slučajno odaberemo neku knjigu i izbrojimo broj riječi u njoj. Riječ je o slučajnom eksperimentu (ne znamo unaprijed koja će knjiga biti izabrana, a onda niti broj riječi u njoj). Jasno je da broj riječi u knjizi može značajno varirati. Mogli bi razmišljati da uzmemo neki jako velik broj M, poput milijarde, pa onda definirati prostor elementarnih događaja kao skup $\{1, 2, \ldots, M\}$. S druge strane, nije prikladno da se prostor elementarnih događaja može relativno proizvoljno definirati. U takvoj situacije je bolje jednostavno definirati $\Omega = \mathbb{N}$. □

Primjer 3.2.6 (Vrijeme trajanja električnog aparata)**.** Kada kupimo i počnemo koristiti neki električni aparat za kućanstvo (perilica, TV, hladnjak,...) ne znamo koliki će biti njegov vijek trajanja. Stoga to vrijeme trajanja možemo smatrati slučajnim eksperimentom. Kako se vrijeme može mjeriti u raznim jednicama i s velikom preciznošću prirodno je definirati prostor elementarnih događaja $\Omega = [0, \infty)$ (skup nenegativnih realnih brojeva). □

Primjer 3.2.7 (Slučajni odabir dekadske znamenke)**.** Pogledajmo slučajni eksperiment u kojem biramo jednu od 10 dekadskih znamenki na slučajan način. Slučajan odabir znamenki možemo realizirati tako da na deset jednakih kuglica napišemo znamenke $0, 1, \ldots 9$, ubacimo ih u kutiju i na slučajan način odaberemo jednu kuglicu.[3]
Prirodno je za prostor elementarnih događaja uzeti $\Omega = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$. Uzmimo slučajne događaje A i B kao na slici.



Jasno, $A = \{0, 3, 4, 7\}$, a $B = \{4, 5, 6, 8, 9\}$. Kako su slučajni događaji skupovi, uobičajenim skupovnim operacijama možemo dobiti nove slučajne događaje od zadanih (polaznih) slučajnih događaja. Tako možemo dobiti slučajne događaje poput

$$A \cup B = \{0, 3, 4, 5, 6, 7, 8, 9\},$$

$$A \cap B = \{4\},$$

$$A \setminus B = \{0, 3, 7\}$$

ili

$$(A \cup B)^c = \{1, 2\}.$$

Možete se, za vježbu, uvjeriti da vrijedi $(A \cup B)^c = A^c \cap B^c$ (De Morganovo pravilo). □

[3] Drugi način je da generiramo (pseudo)slučajni broj na računalu. To će biti decimalni broj između 0 i 1. Zatim taj broj pomnožimo s 10 te odbacimo preostali decimalni dio. S generiranjem slučajnih brojeva ćemo se još susresti kasnije u skripti.

Primjer 3.2.8 (Uzastopno bacanje novčića; Primjer 1.2.2 u [3]). Prostor elementarnih događaja, a onda i slučajni događaji, mogu biti i složeniji od onih predstavljenih u prethodnim primjerima. Razmislimo kako bi izgledao prostor elementarnih događaja koji bi opisivao sve elementarne događaje slučajnog eksperimenta 10 uzastopnih bacanja novčića.
Vidjeli smo u Primjeru 3.2.2 da prilikom jednog bacanja novčića možemo identificirati elementarni događaj "palo je pismo" s nulom te elementarni događaj "pala je glava" s jednicom ($P \equiv 0$, $G \equiv 1$). Stoga se za prostor elementarnih događaja koji opisuje sve moguće ishode u jednom bacanju novčića može uzeti $\Omega_1 = \{0, 1\}$.
Uz takvu identifikaciju vidimo da se u 10 uzastopnih bacanja novčića dobivaju nizovi nula i jednica duljine 10 znakova poput 0011011101. Jasno je da se na svakom od 10 mjesta tako formiranih binarnih brojeva može pojaviti nula ili jedinica i svi takvi nizovi nula i jedinica tvore skup svih mogućih ishoda slučajnog eksperimenta 10 uzastopnih bacanja novčića. To znači da možemo definirati prostor elementarnih događaja za taj slučajni eksperiment kao

$$\Omega = \{(s_1, s_2, \ldots, s_{10}) \mid s_j \in \{0, 1\}, j = 1, 2, \ldots, 10\}.$$

Ako malo razmislimo i sjetimo se pojma Kartezijevog produkta, vidimo da je zapravo $\Omega = \Omega_1^{10}$, pri čemu je Ω_1^{10} oznaka za Kartezijev produkt 10 skupova Ω_1 (pogledajte definiciju 3.1.51 i stavite $S_1 = \ldots = S_{10} = \Omega_1$).
Definirajmo sada neke događaje na tako definiranom prostoru elementarnih događaja. Neka je A_1 događaj "u prvom bacanju je pala glava". Tada je

$$A_1 = \{(1, s_2, \ldots, s_{10}) \mid s_j \in \{0, 1\}, 2 \leq j \leq 10\}.$$

A_1 je podskup prostora elementarnih događaja pa je riječ o slučajnom događaju. Na sličan način definiramo slučajne događaje A_j, $j = 2, 3, \ldots, 10$, koji opisuju događaje "u j-tom bacanju je pala glava". Pomoću slučajnih događaja A_j možemo prikazati neke druge slučajne događaje.
Neka je B događaj "u 10 bacanja je barem jednom pala glava". Tada je

$$B = \bigcup_{j=1}^{10} A_j.$$

Ako je C događaj "u svih 10 bacanja je pala glava", onda je

$$C = \bigcap_{j=1}^{10} A_j.$$

Napokon, neka je D događaj "u prva tri bacanja nije pala glava". Tada je

$$D = A_1^c \cap A_2^c \cap A_3^c.$$

Uočite da se na razini elemenata skup E može zapisati kao

$$D = \{(0, 0, 0, s_4, \ldots, s_{10}) \mid s_j \in \{0, 1\}, 4 \leq j \leq 10\}.$$

□

U prethodnom primjeru smo upotrijebili neke nove načine formiranja slučajnih događaja. Oni su često primjenjivi pa ćemo ih dodatno istaknuti. Neka su $A_1, A_2, \ldots A_n$, $n \in \mathbb{N}$ slučajni događaji (na nekom prostoru elementarnih događaja Ω). Onda slučajni događaj

$$A_1 \cup A_2 \cup \ldots \cup A_n$$

opisuje događaj "dogodio se barem jedan od događaja $A_1, A_2, \ldots A_n$", a slučajni događaj

$$A_1 \cap A_2 \cap \ldots \cap A_n$$

opisuje događaj "dogodili su se svi događaji $A_1, A_2, \ldots A_n$". To je u skladu s definicijom unije i presjeka, ali vrijedi istaknuti tu činjenicu i u ovom kontekstu.

Primjer 3.2.9 (Bacanje dvije kockice)**.** Slučajni eksperiment s bacanjem kockice možemo učinit složenijim ukoliko na slučajan način bacamo dvije kockice istovremeno. Kockice međusobno razlikujemo (jedna može biti plava, a druga crvena). U tom slučaju prostor elementarnih događaja ima 36 elemenata jer je

$$\begin{aligned}\Omega = \{&(1,1),(1,2),(1,3),(1,4),(1,5),(1,6),\\ &(2,1),(2,2),(2,3),(2,4),(2,5),(2,6),\\ &(3,1),(3,2),(3,3),(3,4),(3,5),(3,6),\\ &(4,1),(4,2),(4,3),(4,4),(4,5),(4,6),\\ &(5,1),(5,2),(5,3),(5,4),(5,5),(5,6),\\ &(6,1),(6,2),(6,3),(6,4),(6,5),(6,6)\}.\end{aligned}$$

Bez popisivanja svih mogućnosti ishoda bacanja dvije kockice možemo izračunati broj elemenata skupa Ω tako da uočimo da na prvoj kockici može pasti bilo koji od 6 brojeva i za svaki taj ishod na drugoj kockici može pasti opet bilo koji od 6 brojeva. Ukupno $6 \cdot 6 = 36$ mogućnosti. Korisno je za uočiti da uz oznaku $\Omega_1 = \{1,2,3,4,5,6\}$ za prostor elementarnih događaja koji opisuje bacanje jedne kockice imamo $\Omega = \Omega_1 \times \Omega_1 = \Omega_1^2$. Znamo (vidi formulu (3.4)) da je $|\Omega| = |\Omega_1| \cdot |\Omega_1| = 6 \cdot 6 = 36$. Na sličan način smo opisali prostor elementarnih događaja u Primjeru 3.2.8.
Sada neki od slučajnih događaja vezanih uz ovaj eksperiment mogu biti E_1 ="zbroj na dvije kockice je jednak 11" ili E_2 ="na obje kockice je pao broj veći ili jednak od 5". Naravno, $E_1 = \{(5,6),(6,5)\}$ dok je $E_2 = \{(5,5),(5,6),(6,5),(6,6)\}$.
Ukoliko kockice ne razlikujemo, onda je prostor elementarnih događaja

$$\begin{aligned}\Omega_2 = \{&\{1,1\},\{1,2\},\{1,3\},\{1,4\},\{1,5\},\{1,6\},\\ &\{2,2\},\{2,3\},\{2,4\},\{2,5\},\{2,6\},\\ &\{3,3\},\{3,4\},\{3,5\},\{3,6\},\\ &\{4,4\},\{4,5\},\{4,6\},\\ &\{5,5\},\{5,6\},\\ &\{6,6\}\}.\end{aligned}$$

U tom slučaju su gore opisani događaji drugačiji jer je $E_1 = \{\{5,6\}\}$, dok za događaj E_2 imamo $E_2 = \{\{5,5\},\{5,6\},\{6,6\}\}$. □

Vjerojatnost nekog događaja u okvirima određenog slučajnog eksperimenta se u počecima razvoja teorije vjerojatnosti definirala kao omjer slučajeva u kojima se taj događaj dogodio u odnosu na ukupan broj slučajeva. Uz do sada uvedene pojmove možemo dati i precizniju definiciju.

Definicija 3.2.10 (Naivna definicija vjerojatnosti)**.** Neka je Ω prostor elementarnih događaja s konačno mnogo elemenata te $E \subset \Omega$ slučajni događaj iz Ω. Vjerojatnost događaja E, u oznaci $P(E)$, definira se kao

$$P(E) = \frac{|E|}{|\Omega|} = \frac{\text{broj ishoda slučajnog eksperimenta u kojima se dogodio } E}{\text{ukupan broj mogućih ishoda slučajnog eksperimenta}}. \qquad (3.6)$$

Ovakva definicija vjerojatnost se naziva **naivnom** jer nije dovoljno općenita (ne obuhvaća beskonačne skupove), ali je intuitivno jasna i zapravo široko primjenjiva. Uočimo da je vjerojatnost definirana na slučajnim događajima. Ona dodjeljuje broj između nule i jedan slučajnim događajima koji se odnose na neki slučajni eksperiment (E je podskup od Ω pa svakako ima manje ili jednako elemenata od prostora elementarnih događaja Ω).

Važno upozorenje: definicija vjerojatnosti dana u (3.6) implicitno **pretpostavlja da su svi elementarni događaji jednako vjerojatni**. Stoga ju je primjereno, i jedino moguće, koristiti samo u takvim slučajevima. Pogledajmo neke primjere.

Primjer 3.2.11 (Nastavak Primjera 3.2.2)**.** Neka je $\Omega = \{0, 1\}$. Da bismo mogli primijeniti formulu (3.6) mora vrijediti da je

$$P(\{0\}) = P(\{P\}) = \frac{1}{2} \quad \text{i} \quad P(\{1\}) = P(\{G\}) = \frac{1}{2}.$$

To znači da je jednako vjerojatno da će pasti pismo ili glava prilikom bacanja novčića na slučajan način. Novčić koji ima takvo svojstvo naziva se **simetričnim**.
Iz poglavlja o skupovima znamo da je broj mogućih podskupova dvočlanog skupa, dakle broj elemenata partitivnog skupa od Ω, jednak četiri. Dakle, mogući događaji vezani uz ovaj slučajni eksperiment su $\emptyset$, $\{0\}$, $\{1\}$, Ω. Iz definicije naivne vjerojatnosti slijedi je $P(\emptyset) = 0$ (prazan skup ima nula elemenata) kao i $P(\Omega) = 1$. □

Primjer 3.2.12 (Nastavak Primjera 3.2.3)**.** Sada je $\Omega = \{1, 2, 3, 4, 5, 6\}$. Opet, da bi mogli primijeniti formulu (3.6) moramo pretpostaviti da je vjerojatnost svih elementarnih događaja, odnosno jednočlanih skupova koji sadrže elementarne događaje, jednaka. Dakle, pretpostavimo da je

$$P(\{1\}) = P(\{2\}) = P(\{3\}) = P(\{4\}) = P(\{5\}) = P(\{6\}) = \frac{1}{6}.$$

Igraća kockica za koju to vrijedi naziva se **simetričnom**.
Kako oba događaja iz primjera 3.2.3 imaju po 3 elementa iz formule (3.6) slijedi da je $P(A) = P(B) = 3/6 = 1/2$. □

Primjer 3.2.13 (Nastavak Primjera 3.2.7)**.** Slučajni odabir jedne od dekadskih znamenki smo postavili tako da je odabir bilo koje od znamenki jednako vjerojatan. Stoga u ovom slučaju možemo koristiti formulu (3.6). S obzirom da lagano prebrojimo elemente svih skupova navedenih u primjeru 3.2.7 korištenjem formule (3.6) lagano dobijemo

$$P(A) = \frac{|\{0, 3, 4, 7\}|}{|\Omega|} = \frac{4}{10} = 0,4 \quad \text{i} \quad P(B) = \frac{|\{4, 5, 6, 8, 9\}|}{|\Omega|} = \frac{5}{10} = 0,5.$$

Na isti način izračunamo

$$P(A \cup B) = \frac{8}{10}, \quad P(A \cap B) = \frac{1}{10}, \quad P(A \setminus B) = \frac{3}{10} \quad \text{i} \quad P((A \cup B)^c) = \frac{2}{10}.$$

Uočimo da je

$$P((A \cup B)^c) = \frac{|\Omega \setminus (A \cup B)|}{|\Omega|} = \frac{|\Omega| - |(A \cup B)|}{|\Omega|} = 1 - \frac{|(A \cup B)|}{|\Omega|} = 1 - P(A \cup B).$$

Vidjet ćemo u sljedećem poglavlju da je to univerzalno svojstvo vjerojatnosti, odnosno za proizvoljan slučajni događaj E vrijedi da je $P(E^c) = 1 - P(E)$. E^c se naziva **suprotnim događajem** događaju E, a $P(E^c)$ **vjerojatnost suprotnog događaja** događaju E. □

Primjer 3.2.14 (Nastavak primjera 3.2.9)**.** Neka sada slučajni eksperiment uključuje bacanje dvije kockice istovremeno. Vidjeli smo da prostor elementarnih događaja Ω tada ima 36 elemenata (elementarnih događaja). Ukoliko je opet, kao u Primjeru 3.2.9, E_1 ="zbroj na dvije kocikce je jednak 11", a E_2 ="na obje kockice je pao broj veći ili jednak od 5" onda je vjerojatnost tih događaja

$$P(E_1) = \frac{|\{(5,6),(6,5)\}|}{|\Omega|} = \frac{2}{36} = 0,055555 = 0,0\dot{5}$$

i

$$P(E_2) = \frac{|\{(5,5),(5,6),(6,5),(6,6)\}|}{|\Omega|} = \frac{4}{36} = 0,11111 = 0,\dot{1}.$$

Završit ćemo ovaj primjer jednom malom napomenom iz povijesti teorije vjerojatnosti (matematike) koja se tiče već istaknute činjenice da se naivna definicija vjerojatnosti treba koristiti s oprezom jer je primjenjiva na slučajeve u kojima su svi ishodi eksperimenta jednako vjerojatni.
Naime, čuveni njemački matematičar Gottfried Wilhelm Leibniz (otkrio je deiferencijalni račun u isto vrijeme kao i Newton) je u jednom svom djelu argumentirao da je jednako vjerojatno da će zbroj brojeva na kockicama biti 11 ili 12. To nije istina jer smo vidjeli da je vjerojatnost da će zbroj brojeva na dvije kockice biti jednak 11 zapravo 2/36, dok je vjerojatnost da će zbroj biti 12 jednaka 1/36. U osnovi je Leibniz koristio prostor elementarnih događaja koji smo u Primjeru 3.2.9 označili s Ω_2 i koji sadrži 21 element. Iako on ispravno reprezentira slučaj bacanja kockica koje ne razlikujemo, u praksi slučajni eksperiment bacanja dvije kockice podrazumijeva bacanje različitih kockica (one su fizički različite). U to bi se mogli uvjeriti tako da velik broj puta bacamo dvije kockice i brojimo slučajeve u kojima je zbroj brojeva 11. Taj broj se približava 2/36. Kasnije ćemo vidjeti koje je teorijsko objašnjenje za taj argument.
Gledano iz suvremene perspektive, problem s Leibnizovim prebojavanjem i računanjem vjerojatnosti je u tome što prostor elementarnih događaja Ω_2 sadrži elementarne događaje koji nisu svi jednako vjerojatni. Više o ovom problemu može se naći u knjizi Prakash Gorroochurn, Classic Problems of Probability [7], Problem 15. □

Iz nekoliko prethodnih primjera smo vidjeli da se računanje vjerojatnosti korištenjem, tako zvane, naivne definicije vjerojatnosti svodi na prebrojavanje elemenata konačnih skupova. Određivanje broja elemenata nekog skupa može biti složeno, a dio matematike koji se (i) time bavi je Kombinatorika. Stoga u sljedećem odjeljku dajemo pregled osnovnih metoda prebrojavanja skupova. Opseg prezentiranog sadržaja iz Kombinatorike je dosta mali i vezan je uz potrebu računanja vjerojatnosti nekih slučajnih događaja.

3.3 Osnovne metode prebrojavanja; kombinatorika

Iako problemi prebrojavanja mogu biti vrlo složeni oni se oslanjaju na nekoliko jednostavnih pravila s kojima smo se već susreli. Problemi prebrojavanja se uobičajeno formuliraju u terminima određivanja broja elemenata nekih skupova. Stoga su i osnovna pravila (principi) prebrojavanja formulirani na taj način, a predstavljeni su u formi teorema koji dajemo u nastavku.

Teorem 3.3.1 (Osnovna pravila prebrojavanja)**.** *Neka su $S, T, S_1, S_2, \ldots, S_n$, $n \in \mathbb{N}$, konačni skupovi. Tada imamo*

*1) (**Pravilo jednakosti (bijekcije)**) Između skupova S i T postoji bijekcija ako i samo ako oni imaju jednak broj elemenata, odnosno ako je $|S| = |T|$.*

*2) (**Pravilo zbroja (sume)**) Neka su $S_1, S_2, \ldots, S_n$ međusobno disjunktni skupovi što znači da je $S_i \cap S_j = \emptyset$, $i \neq j$, $i, j \in \{1, 2, \ldots, n\}$. Tada je*

$$|S_1 \cup S_2 \cup \ldots \cup S_n| = |S_1| + |S_2| + \ldots + |S_n|. \tag{3.7}$$

*3) (**Pravilo umnoška (produkta)**) Vrijedi*

$$|S_1 \times S_2 \times \ldots \times S_n| = |S_1| \cdot |S_2| \cdot \ldots \cdot |S_n|. \tag{3.8}$$

Sva pravila iz gornjeg teorema se lagano pokažu, a malo formalniji dokaz je dan u knjizi Darka Veljana, Kombinatorna i diskretna matematika [14], str. 45. Sjetimo se da smo se s pravilom umnoška već susreli u formuli (3.5).

U nastavku ćemo vidjeti razne primjere korištenja pravila prebrojavanja iz prošlog teorema. Na ovom mjestu uočimo jednu stvar: kod problema u kojima imamo mali broj elemenata moguće je ne samo općenito prebrojati sve tražene elemente, nego ih i navesti. Naime, ukoliko možemo navesti sve elemente nekog skupa jasno je da ih možemo i prebrojati. Često je korisno promotriti neki problem za male brojeve kako bi se uvjerili da ispravno brojimo elemente nekog skupa, a onda lakše zaključimo što se događa u općenitom slučaju. Pogledajmo primjer.

Primjer 3.3.2. Sjetimo se slučajnog eksperimenta bacanja novčića te ga ponovimo četiri puta. Četiri ponovljena bacanja novčića možemo smatrati novim slučajnim eksperimentom pa možemo definirati prostor elementarnih događaja za taj slučajni eksperiment. Kao što smo već istaknuli, prostor elementarnih događaja treba obuhvaćati sve moguće ishode slučajnog eksperimenta koji proučavamo pa je

$$\begin{aligned}\Omega = \{&GGGG, GGGP, GGPG, GPGG, PGGG, GGPP, GPGP, GPPG,\\ &PGGP, PGPG, PPGG, GPPP, PGPP, PPGP, PPPG, PPPP\}.\end{aligned}$$

Vidimo da prostor elementarnih događaja, odnosno skup koji sadrži sve moguće ishode bacanja četiri novčića, ima 16 elemenata. Do tog broj smo došli navođenjem svih elemenata skupa Ω. Isto smo mogli zaključiti korištenjem pravila umnoška. Naime, ukoliko je $\tilde{\Omega} = \{P, G\}$ prostor elementarnih događaja za jedno bacanje novčića, onda se Ω može prikazati kao Kartezijev produkt četiri $\tilde{\Omega}$, odnosno

$$\Omega = \tilde{\Omega} \times \tilde{\Omega} \times \tilde{\Omega} \times \tilde{\Omega} = \tilde{\Omega}^4.$$

Prema pravilu umnoška (3.8) znamo da je

$$|\Omega| = |\tilde{\Omega}| \cdot |\tilde{\Omega}| \cdot |\tilde{\Omega}| \cdot |\tilde{\Omega}| = 2 \cdot 2 \cdot 2 \cdot 2 = 2^4 = 16.$$

U primjerima 3.2.2 i 3.2.8 smo proveli identifikaciju elementarnih događaja (za jedno bacanje novčića) "palo je pismo" s nulom i "pala je glava" s jednicom. U osnovi time definiramo bijekciju $f : \{P, G\} \to \{0, 1\}$ zadanu s $f(P) = 0$ i $f(G) = 1$. Prema pravilu jednakosti zaključujemo da skupovi $\tilde{\Omega}$ i $\Omega_1 = \{0, 1\}$ imaju jednak broj elemenata.[4] No, onda i skupovi $\tilde{\Omega}^4$ i Ω_1^4 imaju isti broj elemenata. Zbog toga možemo i u općenitom slučaju n bacanja novčića, $n \in \mathbb{N}$, "kodirati" pismo i glavu s 0 i 1 pa onda računati broj elemenata skupa Ω_1^n kako bi izračunali broj svih mogućnosti koje se mogu dogoditi prilikom n uzastopnih bacanja novčića. Primjenjujući zaključivanje koje smo upotrijebili za 4 bacnja novčića zaključujemo da prostor elementarnih događaja koji opisuje n bacanja novčića ima 2^n elemenata. Tako Ω iz primjera 3.2.8 ima $2^{10} = 1024$ elementa.

[4] Naravno, ovdje nam ne treba nikakvo uvjeravanje da dvočlani skupovi $\{P, G\}$ i $\{0, 1\}$ imaju jednak broj elemenata, ali navodimo formalnu argumentaciju koja će biti valjana i u problemima u kojima nije očit broj elemenata skupa.

U nastavku skripte ćemo uzastopno bacanje n novčića, $n \in \mathbb{N}$, modelirati prostorom elementarnih događaja Ω_1^n jer se pokazuje da je kodiranje nulama i jedinicama primjenjivo u mnogim situacijama koje nemaju veze s bacanjem novčića (uspjeh i neuspjeh u nekom slučajnom eksperimentu).
Završit ćemo ovaj primjer jednom općenitom napomenom. Pravilo umnoška ne pretpostavlja da se elementi nekog od skupova iz danog Kartezijevog produkta događaju prije ili kasnije nekih drugih elemenata. Stoga umjesto 4 uzastopna bacanja novčića (kasnije ćemo reći da su bacanja nezavisna) možemo gledati 4 novčića koji se istovremeno bacaju i onda simultano bilježiti rezultate bacanja svakog od novčića. Tako smo napravili u primjeru bacanja dvije kockice. □

Napomena 3.3.3 (O oznakama $\sum$ i $\prod$)**.** U matematici se često koriste oznake kako bi se lakše ili kraće zapisali neki izrazi. Tako se za skraćeno pisanje zbrojeva više brojeva koristi oznaka $\sum$. Koristeći se tim zapisom zbroj prva tri prirodna broja možemo skraćeno zapisati kao

$$1 + 2 + 3 = \sum_{i=1}^{3} i.$$

Oznaka $\sum$ s desne strane gornje jednkost nam govori da zbrajamo neke elemente (brojeve), a indeks i nam govori koje sve prirodne brojeve (mogu biti i cijeli) ćemo uzeti u obzir prilikom zbrajanja. U konkretnom slučaju će vrijednosti indeksa i biti, redom, $1, 2$ pa 3. Vrijednost tako označenog zbroja ne ovisi o slovu kojim označavamo indeks pa je, dakle, svejedno ako umjesto i pišeko j ili k.
Naravno, kod zbrojeva u kojima se pojavljuje tek nekoliko pribrojnika takav zapis i nije naročito koristan, ali je nezamijenjiv ako želimo promatrati općenite zbrojeve. Tako imamo zapise:

$$1 + 2 + \cdots + 10 = \sum_{k=1}^{10} k = 45$$

za zbroj prvih 10 prirodnih brojeva ili

$$1 + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{n} = \sum_{k=1}^{n} \frac{1}{k}$$

za zbroj prvih n članova niza $(1/k)$, $k \in \mathbb{N}$.
Uočimo da svi zbrojevi koje promatramo imaju konačan broj pribrojnika. Mogu se promatrati i beskonačni zbrojevi, odnosno redovi, ali tada moramo početi paziti na konvergenciju redova, odnosno na činjenicu da li uopće dobivamo konačne zbrojeve ili ne.

Ukoliko je općenito zadan neki niz realnih brojeva $\{a_k\}$, gdje je $k \in \mathbb{N} \cup \{0\}$, onda zbroj prvih n brojeva tog niza zapisujemo kao:

$$a_1 + a_2 + \ldots + a_n = \sum_{i=1}^{n} a_i.$$

Ovakav skraćeni zapis je vrlo fleksibilan jer omogućava prikaz zbroja članova niza od nekog m-tog člana do n-tog člana niza $\{a_k\}$, $m < n$, kao:

$$a_m + a_{m+1} + \ldots + a_n = \sum_{i=m}^{n} a_i.$$

Konkretno, zbroj članova niza $\{a_k\}$ od trećeg do sedmog člana niza bi zapisali kao: $\sum_{i=3}^{7} a_i$. Za zbrojeve vrijede i neke osnovne algebarske operacije poput

$$\sum_{i=1}^{n}(c \cdot a_i + d \cdot b_i) = c\sum_{i=1}^{n} a_i + d\sum_{i=1}^{n} b_i,$$

gdje su $\{a_k\}$ i $\{b_k\}$ nizovi realni brojeva, $n \in \mathbb{N}$, a c i d neke konstante (dakle, realni brojevi).
Uz navedenu oznaku $\sum$ te oznaku za konačnu uniju skupova (3.1) relaciju (3.7) možemo skraćeno zapisati kao

$$|\bigcup_{i=1}^{n} S_i| = \sum_{i=1}^{n} |S_i|.$$

U nastavku ćemo često koristiti takav skraćeni zapis.

Slično, možemo uvesti oznaku $\prod$ za umnožak određenog broja brojeva ili članova nekog niza. Tako umnožak prva četiri prirodna broja možemo zapisati kao

$$\prod_{j=1}^{4} j = 1 \cdot 2 \cdot 3 \cdot 4 = 24$$

dok umnožak prvih n članova niza realnih brojeva $\{a_k\}$, $k \in \mathbb{N} \cup \{0\}$, možemo zapisati kao

$$a_1 \cdot a_2 \cdot \ldots \cdot a_n = \prod_{i=1}^{n} a_i.$$

Ukoliko istu oznaku iskoristimo za skraćeni zapis Kartezijevog produkta konačnih skupova $S_1, S_2, \ldots, S_n$, $n \in \mathbb{N}$, odnosno

$$S_1 \times S_2 \times \ldots \times S_n = \prod_{i=1}^{n} S_i,$$

onda relaciju (3.8) možemo skraćeno zapisati kao

$$|\prod_{i=1}^{n} S_i| = \prod_{i=1}^{n} |S_i|.$$

□

3.3.1 Prebrojavanje skupova u kojima je poredak važan, permutacije

Pravilo umnoška je jedan od najkorištenijih alata u kombinatorici. Za $n = 2$ ono nam kaže da za S i T skupove za koje je $|S| = n$ i $|T| = k$, $n, k \in \mathbb{N}$, vrijedi da je $|S \times T| = n \cdot k$. Što nam govori ta formula? Ako imamo n različitih predmeta pri čemu svaki predmet ima nekih k različitih karakteristika, onda je broj ukupnih mogućnosti za odabir različitog predmeta s različitom karakteristikom jednak $n \cdot k$. Pogledajmo primjer.

Primjer 3.3.4. U nekoj prodavaonici imaju 3 tipa maskica za mobitel koji posjedujete, a svaki tip maskice se može kupiti u četiri boje: bijeloj, crnoj, zlatnoj i plavoj. Ako je $S = \{1, 2, 3\}$ skup tipova maskica za vaš mobitel, a $T = \{b, c, z, p\}$ skup boja u kojoj se svaka maskica može kupiti, onda je ukupni broj različitih maskica koje se mogu kupiti za vaš mobitel jednak $|S \times T| = 3 \cdot 4 = 12$. Taj izračun možemo lagano potvrditi navodeći sve mogućnosti formiranja različitih maskica za vaš mobitel:

$$\{(1,b),(1,c),(1,z),(1,p),(2,b),(2,c),(2,z),(2,p),(3,b),(3,c),(3,z),(3,p)\}.$$

Naravno, ako u prodavaonici imaju 10 tipova maskica za vaš mobitel i svaka se maskica može kupiti u jednoj od 6 boja, onda više nije tako jednostavno pobrojati sve mogućnosti, ali i dalje je lako izračunati broj različitih mogućnosti odabira maskica jer je, uz analogne oznake, sada $|S| = 10$, a $|T| = 6$ pa imamo 60 različitih mogućnosti odabira maskica. □

U kontekstu vjerojatnosti se često susrećemo sa situacijom u koja izvodimo dva slučajna eksperimenta pri čemu je broj mogućih ishoda u prvom slučajnom eksperimentu jednak n, a broj mogućih ishoda u drugom slučajnom eksperimentu je jednak k. Tada je ukupan broj mogućnosti u ta dva slučajna eksperimenta, opet prema pravilu umnoška, jednak $n \cdot k$.

Primjer 3.3.5. Bacimo najprije novčić, a zatim, neovisno o ishodu bacanja novčića, i igraću kockicu. Pitamo se koliko je različitih mogućnosti ishoda ta dva slučajna eksperimenta.[5]
U osnovi se pitamo na koliko načina možemo formirati uređeni par (nov, koc), pri čemu nov može biti jednak 0 ili 1 (dakle, pismo ili glava), a koc može biti jednak $1, 2, 3, 4, 5$ ili 6. No to je isto kao da se pitamo koliko elemenata ima Kartezijev produkt skupova $S = \{0, 1\}$ i $T = \{1, 2, 3, 4, 5, 6\}$. Kao što sada već znamo, $|S \times T| = 2 \cdot 6 = 12$. Dakle, ukupan broj različitih ishoda dva navedena slučajna eksperimenta je jednak 12. □

Navedena situacija sa izvođenjem slučajnih eksperimenata se može i poopćiti. Recimo da izvodimo n, $n \in \mathbb{N}$, slučajnih eksperimenata pri čemu u prvom slučajnom eksperimentu imamo k_1 mogućih ishoda, u drugom k_2 mogućih ishoda i tako dalje do n-tog slučajnog eksperimenta u kojem imamo k_n mogućih ishoda, $k_1, k_2, \ldots k_n \in \mathbb{N}$. Tada je, prema pravilu umnoška, ukupan broj različitih ishoda tih n slučajnih eksperimenata jednak $k_1 \cdot k_2 \cdot \ldots \cdot k_n$.

Kombinatorno se ta situacija češće opisuje tako da imamo n skupova $S_1, \ldots, S_n$, $n \in \mathbb{N}$, pri čemu je $|S_i| = k_i$, $i = 1, 2, \ldots n$, te biramo najprije jedan element iz skupa S_1, zatim jedan element iz skupa S_2 i tako dalje do odabira jednog elementa iz skupa S_n. Ukupan broj takvih odabira je, prema pravilu umnoška, jednak $k_1 \cdot k_2 \cdot \ldots \cdot k_n$.

Primjer 3.3.6. U nekom dućanu se na policama može naći 10 različitih vrsta čokolade, 6 vrsta čipseva, 8 vrsta bombona i 4 vrste žvakaća. Na koliko načina možemo odabrati po jednu čokoladu, čips, bombone i žvakaće?
Prema prethodnim oznakama sve vrste čokolade možemo združiti u skup S_1, sve vrste čipseva u skup S_2, sve vrste bombona u skup S_3 i sve vrste žvakaća u skup S_4. Dakle, $n = 4$, $k_1 = 10$, $k_2 = 6$, $k_3 = 8$ i $k_4 = 4$ pa je traženi broj načina odabira jednak $10 \cdot 6 \cdot 8 \cdot 4 = 1920$. □

Usprkos prije navedenim, vrlo korisnim, primjenama pravila umnoška, jedna od najčešćih primjena tog pravila je sljedeća: uzmimo n različitih objekata, odaberimo jedan, zabilježimo odabir pa ponovno biramo jedan objekt od istih n objekata te opet zabilježimo odabir te na isti način odaberemo k objekata, $n, k \in \mathbb{N}$. Prema pravilu umnoška je broj mogućih k odabira n različitih objekata jednak

$$\underbrace{n \cdot n \cdot \ldots \cdot n}_{k \text{ puta}} = n^k.$$

Za ovakve odabire objekata kažemo da su **odabiri s ponavljanjem** pri čemu je **važan** poredak odabira. Vidimo da se kod ovakvog odabira objekata zapravo biraju uređene k-torke iz n-članog skupa S, pri čemu se elementi skupa S mogu ponavljati na svakom od mjesta. To odgovara formiranju Kartezijevog produkta k kopija skupa S. Broj elemenata

[5] Kao što smo napomenuli pri kraju Primjera 3.3.2 istu situaciju dobijemo ako istovremeno bacimo novčić i kockicu i zabilježimo ishod bacanja.

Kartezijevog produkta S^k je jednak n^k. Napomenimo da se k-torke iz Kartezijevog produkta skupa S^k ponekad nazivaju i **varijacije s ponavljanjem**. Pogledajmo neke primjere uvedenih načina prebrojavanja.

Primjer 3.3.7 (binarni brojevi)**.** Pogledajmo koliko različitih binarnih brojeva možemo prikazati sa šest bitova (na šest mjesta). Odgovor na ovo pitanje je direktna posljedica pravila umnoška jer je riječ o odabiru binarnih znamenki koje se mogu ponavljati pri čemu je važan poredak znamenki. Naime, na svako od 6 mjesta se može odabrati jedna od dvije binarne znamenke (0 ili 1) pri čemu dobivamo različite binarne brojeve. Stoga je ukupan broj načina na koji se može formirati binarni broj unutar 6 bitova jednak $2^6 = 64$.
Uočimo da smo i kod bacanja novčića na isti način prebrojavali broj mogućnosti na koji oni mogu pasti u uzastopnim bacanjima što je direktna posljedica identifikacije $P \equiv 0$ i $G =\equiv 1$. □

Primjer 3.3.8 (Registarske tablice)**.** Pretpostavimo da se oznake na registarskim tablicama sastoje od dva mjesta rezervirana za slova iz hrvatskog jezika koja nemaju dijakritičke znakove i koja se ne sastoje od dva znaka (takvih je 22), dok su tri mjesta rezervirana za jednu od decimalnih znamenki (od 0 do 9). Koliko se različitih tablica može napraviti na taj način?
Odgovor: na prvom (od dva) znakovna mjesta može biti jedno od 22 slova, kao i na drugom (jasno, za svaki odabir slova na prvom mjestu može se napraviti bilo kakav odabir slova na drugom mjestu i slova se mogu ponvljati). Na trećem, četvrtom i petom mjestu se može odabrati jedna od 10 znamenki (opet su odabiri znamenki na pojedinom mjestu nezavisni, odnosno mogu se ponavljati, bez obzira na prethodne odabire slova ili znamenki). Prema pravilu umnoška je ukupan broj načina na koji možemo napraviti takve odabire jednak $22 \cdot 22 \cdot 10 \cdot 10 \cdot 10 = 484.000$. □

Primjer 3.3.9 (Različite funkcije)**.** Koliko različitih preslikavanja (funkcija) možemo definirati ukoliko domena ima m elemenata, a kodomena n elemenata (dva preslikavanja su različita ako im se razlikuje vrijednost barem jednog elementa).
Odgovor: označimo elemente domene s $a_1, a_2, \ldots, a_m$. Tada elelementu a_1 možemo pridružiti bilo koji od n elemenata kodomene, elementu a_2 opet možemo pridružiti bilo koji od n elemenata kodomene i tako dalje sve dok elementu a_m ne pridružimo bilo koji od n elemenata kodomene. Sva su takva preslikavanja različita, a ima ih n^m. U osnovi se odgovor na postavljeno pitanje svodi na činjenicu da funkciju možemo predstaviti kao skup uređenih parova, pri čemu na prvom mjestu uređenog para može biti jedan od m elemenata domene, dok na drugom mjestu može biti jedan od n elemenata kodomene. Naravno, u konkretnom slučaju domene s 4 elementa i kodomene sa 6 elemenata, ukupno ćemo imati $6^4 = 1.296$ različitih funkcija. □

Pravilo produkta se može primijeniti i na **odabir k različitih objekata** (od n njih) **bez ponavljanja** pri čemu je **važan** poredak odabira, $n, k \in \mathbb{N}$. Naime, ako imamo n objekata te biramo k objekata jedan po jedan, onda prvi objekt možemo odabrati na n načina, drugi objekt na $n-1$ načina i sve tako do k-tog objekta kojeg možemo odabrati na $n-k+1$ način, jer je toliko objekata ostalo za odabrati. Ukupno možemo napraviti

$$n \cdot (n-1) \cdot \ldots (n-k+1) = (n)_k$$

takvih odabira. S $(n)_k$ smo označili tzv. padajući k-faktorijel (ili k-permutaciju). Poseban, ali važan slučaj, je $k = n$. U tom slučaju je broj odabira jednak $n!$, gdje je

$$n! = n \cdot (n-1) \cdot \ldots \cdot 2 \cdot 1.$$

Uočimo da se definira $0! = 1$, a vrijedi i rekurzivna formula $n! = n \cdot (n-1)!$, $n \in \mathbb{N}$. Jasno, $1! = 1$, $2! = 1 \cdot 2 = 2$, $3! = 1 \cdot 2 \cdot 3 = 6$ i tako dalje.

Na razini skupova padajući k-faktorijel $(n)_k$ odgovara odabiru (uređene) k-torke $(x_1, x_2, \ldots, x_k)$ **različitih** elemenata skupa S koji ima n elemenata. Takve k-torke se ponekad nazivaju i **varijacije bez ponavljanja k-tog razreda**. Za $k = n$ dobivamo n-torku $(x_1, x_2, \ldots, x_n)$ različitih elemenata iz S koja se naziva **permutacijom** skupa S. Broj permutacija skupa S je jednak $n!$. Pogledajmo neke primjere.

Primjer 3.3.10 (Formiranje reda)**.** Tipičan primjer odabira različitih objekata bez ponavljanja pri čemu je važan poredak odabira je sljedeći: pretpostavimo da želimo poredati 8 ljudi u red (za kino, koncert, ...). Jasno je da se bilo koja od 8 osoba može staviti na samo jedno mjesto u redu, a također je jasno da je poredak ljudi u redu važan. Stoga je traženi broj načina na koji možemo poredati 8 ljudi u red jednak $8! = 40.320$. □

Primjer 3.3.11. Koliko troznamenkastih brojeva možemo napraviti od neparnih znamenki $\{1, 3, 5, 7, 9\}$ na način da se svaka od tih znamenki pojavljuje samo jednom?
Odgovor: Poredak znamenki čini troznamenkaste brojeve različitima pa je stoga važan. Stoga na ovaj problem možemo gledati kao na odabir uređene trojke brojeva (x_1, x_2, x_3) iz peteročlanog skupa $\{1, 3, 5, 7, 9\}$. Dakle, broj takvih brojeva je jednak $(5)_3 = 5 \cdot 4 \cdot 3 = 60$. Uočimo, ako ne zahtjevamo da se svaka znamenka pojavljuje samo jednom, onda je ukupan broj troznamenkastih brojeva koje možemo formirati od znamenki $\{1, 3, 5, 7, 9\}$ jednak $5^3 = 125$. □

Primjer 3.3.12 (Različite injekcije)**.** Koliko različitih injekcija možemo definirati ukoliko domena ima m elemenata, a kodomena n elemenata?
Odgovor: Uočimo najprije da za $m > n$ nije moguće definirati injekciju s domene koja ima m elemenata u kodomenu s n elemenata (zašto?). Stoga pretpostavimo da je $m \leq n$. Označimo elemente domene s $a_1, a_2, \ldots, a_m$. Tada elementu a_1 možemo pridružiti bilo koji od n elemenata kodomene. Elementu a_2 možemo pridružiti bilo koji od preostalih $n-1$ elemenata kodomene (ne možemo mu pridružiti već odabrani element kodomene koji je pridružen elementu a_1 jer onda ne bi imali injekciju). Sada je jasno, elementu a_3 možemo pridružiti jedan od preostalih $n-2$ elementa kodomene i tako dalje. U konačnici imamo $(n)_m = n \cdot (n-1) \cdot \ldots \cdot (n-m+1)$ različitih injekcija. Konkretno, ako domena ima 4 elementa, a kodomena 6 elemenata, ukupno ćemo imati $(6)_4 = 6 \cdot 5 \cdot 4 \cdot 3 = 360$ različitih injekcija. Naravno, ako i domena i kodomena imaju n elemenata imat ćemo točno $n!$ različitih injekcija. □

Pogledajmo još neke primjere koji uključuju i princip zbroja.

Primjer 3.3.13. Princip zbroja je u osnovi elelmentaran i gotovo da ga koristimo intuitivno. Uzmimo primjer bacanja dvije kockice. Ukoliko se pitamo na koliko načina mogu pasti brojevi na kockicama tako da im je zbroj manji od četiri ili veći od deset, onda možemo definirati dva skupa A_1 = "zbroj brojeva je manji manji od četiri" i A_2 = "zbroj brojeva je veći od deset". Jasno je da je $A_1 = \{(1,1), (1,2), (2,1)\}$ i $A_2 = \{(5,6), (6,5), (6,6)\}$. Kako su A_1 i A_2 disjunktni skupovi, onda je traženi broj načina, prema principu zbroja, jednak $|A_1| + |A_2| = 3 + 3 = 6$. □

Primjer 3.3.14 (Lozinke različitih duljina)**.** Na koliko se načina od znamenki $0, 1, \ldots, 9$ može napraviti različitih lozinki duljina 4 ili 5 znakova bez da se ijedna znamenka pojavljuje više od jednom?
Odgovor: razdvojit ćemo računanje različitih lozinki na one duljine 4 i one duljine 5. Kako su sve lozinke duljine 4 različite od lozinki duljine 5, jasno je da su skupovi koji sadrže takve lozinke disjuktni. Stoga će odgovor na početno pitanje biti, prema principu

zbroja, $|A_4| + |A_5|$, gdje smo s A_4 označili skup svih traženih lozinki duljine 4 znaka, a s A_5 smo označili skup svih traženih lozinki duljine 5 znakova.
Lozinke duljine 4 znaka, bez da se bilo koja znamenka pojavljuje više od jednom, možemo odabrati na $(10)_4 = 10 \cdot 9 \cdot 8 \cdot 7 = 5.040$ načina, a one duljine 5 na $(10)_5 = 10 \cdot 9 \cdot 8 \cdot 7 \cdot 6 = 30.240$ načina. Dakle, ukupan broj različitih lozinki duljina 4 i 5 znakova, pri čemu se niti jedna znamenka ne pojavljuje više od jednom, jednak je $5.040 + 30.240 = 35.280$. □

Primjer 3.3.15 (Raspored knjiga na polici)**.** Na koliko različitih načina možemo poredati 11 različitih knjiga iz 3 područja, od čega je 5 iz programiranja, 4 iz kombinatorike i 2 iz vjerojatnosti, i to tako da su sve knjige iz istog područja poredane jedna za drugom?
Odgovor: Da si olakšamo postupak pretpostavimo najprije da su prvo poredane knjige iz programiranja, zatim iz kombinatorike te na kraju iz vjerojatnosti. Već smo vidjeli da n (različitih) objekata u red/niz možemo razmjestiti na $n!$ načina pa knjige iz programiranja možemo poredati na 5! različitih načina, knjige iz kombinatorike na 4! različitih načina te knjige iz vjerojatnosti na 2! različitih načina. Za svaki fiksni poredak knjiga iz programiranja različiti poreci knjiga iz kombinatorike i vjerojatnosti daju novi poredak. To je samo drugi način da kažemo da zbog pravila umnoška imamo $5! \cdot 4! \cdot 2!$ različitih poredaka knjiga pri čemu su prvo poredane knjige iz programiranja, zatim iz kombinatorike te na kraju iz vjerojatnosti. Uočimo, kako god da smo poredali knjige po područjima (kombinatorika, vjerojatnost pa programiranje,...) uvijek ćemo imati $5! \cdot 4! \cdot 2!$ različitih poredaka knjiga.
Ostaje nam za izračunati broj načina na koji možemo poredati knjige po područjima. Knjige po područjima možemo poredati na 3! načina (3 područja u različitim porecima) i svi ti poreci su drugačiji. Formalno, možemo definirati 6 skupova koji sadrže različite poretke područja iz kojih su knjige: $A_1 = \{(komb, vje, pro)\}$, $A_2 = \{(komb, pro, vje)\}$ i tako dalje. Ti su skupovi disjunktni. Stoga, prema pravilu zbroja, slijedi da je ukupan broj načina na koji možemo poredati 5 knjiga iz programiranja, 4 iz kombinatorike i 2 iz vjerojatnosti tako da su sve knjige iz istog područja poredane jedna za drugom jednak $3! \cdot 5! \cdot 4! \cdot 2!$. Napomenimo da se najčešće u problemima ovog tipa ne navodi argumentacija definiranja disjunktnih skupova i primjene pravila zbroja, već se jednostavno konstatira, kao u ovom primjeru, da je ukupan broj načina na koji možemo poredati područja iz kojeg su knjige jednak 3! pa se taj broj pomnoži s brojem načina na koji možemo poredati knjige uz fiksan raspored područja. □

Završit ćemo ovaj odjeljak s dvije napomene.

Napomena 3.3.16 (Pravila umnoška i zbroja se prirodno pojavljuju u programiranju)**.** Pogledajmo sljedeća dva koda (u R-u) u kojima se izvršava m `for` petlji s time da su u lijevo navedenom kodu one ugniježđene, dok su u desno navedenom kodu navedene jedna za drugom.

```
k<-0
for (for i1 in 1:n1){
  for (for i2 in 1:n2){
  ...
    for (for im in 1:nm){
    k<-k+1
    }
  }
}
```

```
k<-0
for (for i1 in 1:n1){
k<-k+1
}
for (for i2 in 1:n2){
k<-k+1
}
...
for (for im in 1:nm){
k<-k+1
}
```

Vidimo da se svaka od `for` petlji izvršava ni puta, $i \in \{1, 2, \ldots, m\}$, pri čemu se desne petlje izvršavaju neovisno jedna o drugoj. Stoga će vrijednost od k nakon izvršenja svih petlji biti jednaka $n1 + n2 + \ldots + nm$, što je u skladu s pravilom zbroja. S druge strane, kod ugniježđenih petlji će se svaka unutrašnja petlja izvršiti onoliko puta koliko joj petlji prethodi pomnoženo s pripadnim ni, odnosno vrijednost od k nakon izvršenja svih petlji će biti jednaka $n1 \cdot n2 \cdot \ldots \cdot nm$, što je u skladu s pravilom umnoška. □

Napomena 3.3.17 (Stirlingova formula)**.** Vidjeli smo da funkcija $n!$ vrlo brzo raste (s porastom broja n). Općenito, $n!$ raste brže od eksponencijalne funkcije a^n, $a > 0$, ali sporije od funkcije n^n. Dobru procjenu broja $n!$ dao je škotski matematičar J. Stirling koji je pokazao da je $n! \sim \sqrt{2\pi n}(n/e)^n$, odnosno

$$\lim_{n\to\infty} \frac{n!}{\sqrt{2\pi n}(n/e)^n} = 1.$$

Ta se procjena naziva Stirlingovom formulom. Detaljnija rasprava o procjeni $n!$ može se naći u [14], str. 57-59. □

3.3.2 Prebrojavanje skupova u kojima poredak nije važan, kombinacije

U prošlom odjeljku smo gledali različite razmještaje/odabire nekih objekata pri čemu je poredak objekata bio važan. Razlikovali smo slučaj u kojem se objekti mogu ponavljati i onaj u kojem se ne mogu ponavljati. Ponovimo, ukoliko imamo n objekata i biramo k njih, a objekti se mogu ponavljati imat ćemo ukupno n^k načina na koje možemo odabrati objekte, a ako se ne mogu ponavljati imat ćemo $(n)_k = n \cdot (n-1) \cdot \ldots (n-k+1)$ načina na koji možemo odabrati objekte.

Jednako važan je slučaj odabira objekata pri čemu poredak odabranih objekata nije važan. Pretpostavimo opet da imamo n objekata od kojih biramo k njih, $n, k \in \mathbb{N}$. Opet razlikujemo dva slučaja: objekti se mogu ponavljati ili se ne mogu ponavljati.

Ukoliko se **objekti ne mogu ponavljati**, onda k objekata od n njih možemo odabrati na $\binom{n}{k}$ načina pri čemu **poredak objekata nije važan**. Podsjetimo se, $\binom{n}{k}$ se zove **binomni koeficijent** i definira se kao

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}.$$

Dodatno se definira $\binom{0}{0} = 1$, a za $k > n$ je $\binom{n}{k} = 0$.

Na razini skupova $\binom{n}{k}$ označava broj k-članih podskupova n članog skupa S pa se i naziva **k-kombinacija skupa S**. Uočimo, elemente k-članog skupa razlikujemo, ali njihov poredak nije važan. Ponekad se $\binom{n}{k}$ naziva i **kombinacija k-tog razreda bez ponavljanja od n elemenata**. Pogledajmo neke primjere.

Primjer 3.3.18 (Odabir ljudi)**.** Tipičan primjer kombinacija je odabir određenog broja ljudi od n njih. Na primjer, u razredu od 20 učenika, učiteljica odluči slučajno odabrati 3 učenice/učenika koje će ispitati na jednom satu. Na koliko to načina može učiniti? Odgovor je na $\binom{20}{3}$ načina. Naime, učenike svakako možemo razlikovati, a ako ne pazimo na to kojeg će učenika ispitati prvoga, koga drugoga, a koga trećega, onda se odabir učiteljice svede na odabir tročlanog skupa učenika među 20 njih, a to se može napraviti na $\binom{20}{3}$ načina. □

Primjer 3.3.19 (Veza odabira u kojima je poredak važan i onih u kojima nije važan)**.** Pogledajmo isti zadatak kao i prethodni, ali želimo razlikovati poredak tri učenika koje će učiteljica ispitati. Ukoliko je važan poredak i razlikujemo učenike, onda znamo da se takav odabir može napraviti na $(20)_3 = 20 \cdot 19 \cdot 18$ načina.

Dosta je jasna veza uređenog i neuređenog (poredak odabira je važan ili nije važan) odabira učenika: možemo najprije izabrati 3 učenika (neuređeno), što možemo napraviti na $\binom{20}{3}$ načina, a zatim još ispermutirati poredak ta tri učenika da dobijemo sve načine na koji možemo odabrati tri učenika na uređeni način. To možemo napraviti na 3! načina. Ukupno, gledano na ovaj način, možemo obaviti uređeni odabir tri učenika na $3! \cdot \binom{20}{3}$ načina. Ne bismo imali konzistentne definicije (ili bi konstatirali da smo nešto krivo prebrojali) kada ne bi imali

$$3! \cdot \binom{20}{3} = 3! \cdot \frac{20!}{3!17!} = \frac{20!}{17!} = 20 \cdot 19 \cdot 18 = (20)_3.$$

U kombinatorici se često skupovi mogu prebrojavati na različite načine, što pokazuje i ovaj primjer. □

Primjer 3.3.20 (Loto)**.** Na koliko načina možemo odabrati 7 brojeva od 39 njih? S obzirom da pri raspodjeli dobitaka nije važan poredak izvučenih brojeva, jasno je da je traženi broj načina jednak

$$\binom{39}{7} = \frac{39!}{7!32!} = \frac{39 \cdot 38 \cdot 37 \cdot 36 \cdot 35 \cdot 34 \cdot 33}{1 \cdot 2 \cdot 3 \cdot 4 \cdot 5 \cdot 6 \cdot 7} = 15.380.937.$$

□

Primjer 3.3.21 (Delegacije)**.** Pet studentica i tri studenta se pripremaju za ispit. Imaju neka pitanja vezana uz gradivo ispita i žele otići na konzultacije pa odluče napraviti "delegaciju" koja će se sastojati od 2 studentice i 1 studenta. Na koliko načina se može odabrati takva delegacija? Dodatno pitanje: na koliko načina se može odabrati delegacija koja će imati jednak broj studentica i studenata?
Odgovor: ukoliko biramo delegaciju od 2 studentice i jednog studenta, onda moramo izabrati 2 studentice od 5 njih što možemo napraviti na $\binom{5}{2}$ načina te jednog studenta od 3 njih što možemo napraviti na $\binom{3}{1}$ načina. Prema principu umnoška[6] je traženi broj mogućih delegacija jednak $\binom{5}{2} \cdot \binom{3}{1}$.
Za odgovor na drugo pitanje podijelimo mogućnosti formiranja delegacija s jednakim brojem studentica i studenata na tri slučaja: otići će jedna studentica i jedan student ili će otići dvije studentice i dva studenta ili će otići tri studentice i tri studenta. Svaki od tih slučajeva generira odgovarajuće skupove koji sadrže različite delegacije i ti su skupovi, očito, disjunktni. Prema principu zbroja (i opet umnoška za svaki od navedenih slučajeva formiranja delegacije) je ukupan broj mogućnosti za formiranje "rodno ravnopravnih" delegacija jednak $\binom{5}{1} \cdot \binom{3}{1} + \binom{5}{2} \cdot \binom{3}{2} + \binom{5}{3} \cdot \binom{3}{3}$. □

Ostao nam je još jedan osnovni način odabira objekata i odgovarajućeg broja načina na koji se objekti mogu odabrati. Naime, ukoliko se **objekti mogu ponavljati**, onda k objekata od n njih možemo odabrati na $\binom{n+k-1}{k}$ načina pri čemu **poredak objekata nije važan**. Napomenimo da neki autori uvode oznaku $\left(\!\binom{n}{k}\!\right)$ za $\binom{n+k-1}{k}$.

Na razini skupova $\binom{n+k-1}{k}$ označava broj k-članih podskupova n-članog skupa S pri čemu se odabrani elementi tog k-članog skupa mogu ponavljati. Uz tu interpretaciju $\binom{n+k-1}{k}$ možemo zvati **kombinacija k-tog razreda s ponavljanjem od n elemenata**. Kao i kod k-kombinacija skupa poredak odabranih elemenata k-članog skupa nije važan, ali u ovom slučaju ti elementi ne moraju biti različiti.

[6] Već smo u prijašnjim primjerima vidjeli da za primjenu principa umnoška nije važno da li prvo biramo studentice pa studente ili obratno. Stvar je u tome da je, za općenite skupove A i B, $A \times B$ općenito različito od $B \times A$ (Kartezijev produkt nije komutativna operacija), ali za broj elemenata Kartezijevog produkta skupova vrijedi $|A \times B| = |A| \cdot |B| = |B| \cdot |A| = |B \times A|$.

Imamo još jednu interpretaciju. Naime, $\left(\!\binom{n}{k}\!\right)$ označava broj k-članih podskupova n-članog multiskupa S. S je multiskup ukoliko sadrži neuređene elemente koji se mogu ponavljati, poput $\{1,1,3,2,5,5\}$. U ovoj skripti nećemo ulaziti u detalje ove interpretacije, a zainteresirani čitatelj može pronaći više detalja u poglavlju $II.5$ u [14]. Uočimo, uz ovu interpretaciju se može dokazati da je $\left(\!\binom{n}{k}\!\right) = \binom{n+k-1}{k}$ (Propozicija 10, str 70. u [14]). Pogledajmo jedan primjer. U sljedećem odjeljku ćemo ih vidjeti još nekoliko.

Primjer 3.3.22 (Voće na stolu)**.** Otišli ste na odmor u neku egzotičnu destinaciju i na stolu u restoranu vidite gomilu banana, naranči, ananasa i manga. Pošto vam je prvi dan putovanja odlučite ne pretjerati s probavanjem voća pa odaberete tri komada voće. Na koliko načina to možete napraviti?
Odgovor: U ovakvom tipu problema je prirodno ne razlikovati međusobno bilo koju vrstu voća (svejedno je koju točno bananu odaberete, odnosno pretpostavljamo da one nisu numerirane na neki poseban način). Stoga na ovaj problem možemo gledati kao na problem odabira tročlanog skupa čiji se elementi mogu ponavljati iz četveročlanog skupa $S = \{ba, na, as, ma\}$ u kojem smo pobrojali vrste dostupnog voća. Dakle, riječ je o odabiru $k = 3$ objekata od $n = 4$ njih pri čemu se objekti mogu ponavljati, a njihov poredak nije važan. Stoga je broj načina na koji možete odabrati tri komada voća jednak

$$\binom{4+3-1}{3} = \binom{6}{3} = \frac{6!}{3!3!} = \frac{4 \cdot 5 \cdot 6}{3!} = 4 \cdot 5 = 20.$$

S obzirom da imamo male brojeve n i k možemo, radi stjecanja intuicije o ovom tipu prebrojavanja, navesti sve moguće odabire. Tako imamo odabire u kojima odaberemo samo jednu vrstu voća

$$\{ba, ba, ba\}, \{na, na, na\}, \{an, an, an\}, \{ma, ma, ma\},$$

zatim imamo odabire u kojima imamo dva komada voća jedne vrste i jedan komad voća druge vrste

$$\{ba, ba, na\}, \{ba, ba, an\}, \{ba, ba, ma\}, \{na, na, ba\}, \{na, na, an\}, \{na, na, ma\},$$

$$\{an, an, ba\}, \{an, an, na\}, \{an, an, ma\}, \{ma, ma, ba\}, \{ma, ma, na\}, \{ma, ma, an\}$$

te odabire u kojima imamo sva tri različita komada voća

$$\{ba, na, an\}, \{ba, na, ma\}, \{ba, an, ma\}, \{na, an, ma\}.$$

Vidimo da ukupno imamo 20 načina na koji možemo odabrati tri komada voća od četiri vrste voća.
Iako broj $\binom{n+k-1}{k}$ izgleda "dosta simetričan" u odnosu na n i k, uočite da simetrija nije potpuna (nije svejedno ako zamijenite n i k). Da se uvjerite probajte izbrojati sve načine na koje možete odabrati 4 komada voća od 3 vrste dostupnog voća (na primjer, banane, ananas i mango). Vidjet ćete da ćete dobiti broj

$$\binom{3+4-1}{4} = \binom{6}{4} = \frac{6!}{4!2!} = \frac{5 \cdot 6}{2!} = 5 \cdot 3 = 15$$

što je očito različit broj od onoga koji se tražio na početku primjera. □

3.3.3 Kuglice i kutije

U kombinatorici je čest slučaj da se isti problem može riješiti na različite načine, odnosno da se može interpretirati na razne načine. Jedna od čestih interpretacija je ona

koja uključuje kuglice koje razmještamo u kutije. Taj problem se može učiniti dosta apstraktnim, a ovdje dajemo dva najjednostavnija slučaja.

Pogledajmo za početak razmještaj k **različitih kuglica** u n **različitih kutija**, gdje su $n, k \in \mathbb{N}$. Da bi shvatili o čemu se tu radi dajemo jedan primjer (Primjer (a), str 9. iz [6]). Napomenimo da ćemo gledati samo slučaj kutija koje međusobno razikujemo.

Primjer 3.3.23 (Razmještaj tri različite kuglice u tri kutije)**.** Označimo tri različite kuglice slovima a, b i c. Tada su svi mogući razmještaji te tri kuglice u tri kutije (možemo ih numerirati s 1, 2 i 3) dani u sljedećoj tablici. Vidimo da je ukupan broj

1.	abc	$-$	$-$	10.	a	bc	$-$	19.	$-$	a	bc
2.	$-$	abc	$-$	11.	b	ac	$-$	20.	$-$	b	ac
3.	$-$	$-$	abc	12.	c	ab	$-$	21.	$-$	c	ab
4.	ab	c	$-$	13.	a	$-$	bc	22.	a	b	c
5.	ac	b	$-$	14.	b	$-$	ac	23.	a	c	b
6.	bc	a	$-$	15.	c	$-$	ab	24.	b	a	c
7.	ab	$-$	c	16.	$-$	ab	c	25.	b	c	a
8.	ac	$-$	b	17.	$-$	ac	b	26.	c	a	b
9.	bc	$-$	a	18.	$-$	bc	a	27.	c	b	a

Tablica 3.1: Mogućnosti rasporeda tri različite kuglice u tri kutije

mogućnosti razmještaja kuglica jednak $3^3 = 27$. □

Prethodni primjer je samo poseban slučaj općenitije situacije u kojoj k različitih kuglica raspoređujemo u n različitih kutija. Općenito je teško predstaviti (grafički, kao u tablici iznad) razmještaj tih k kuglica u n kutija, ali nije teško izračunati njihov ukupan broj. Naime, taj se broj može izračunati tako da uočimo da se prva kuglica može staviti u jednu od n kutija. Za svaki smještaj prve kuglice u jednu od kutija imamo opet n načina na koji možemo smjestiti drugu kuglicu u jednu od kutija. Nadalje, za svaki smještaj prve i druge kuglice u jednu od kutija (a takvih različitih razmještaja ima n^2) opet imamo n načina na koje možemo smjestiti treću kuglicu u jednu od kutija. Na isti način nastavimo smještati ostale kuglice u kutije sve dok ne razmjestimo i zadnju, k-tu, kuglicu u jednu od kutija. Dakle, ukupno je broj načina na koji k različitih kuglica možemo razmjestiti u n (različitih) kutija jednak

$$n^k.$$

S tim smo se brojem već susreli kada smo gledali odabire s ponavljanjem k objekata od n njih, pri čemu je bio važan poredak odabira. Uočimo da kod navedene interpretacije s kuglicama i kutijama pretpostavljamo da se u svaku kutiju može smjestiti barem k kuglica.

U okviru interpretacije s različitim kutijama i kuglicama mogu se formulirati i neki drugi načini prebrojavanja. Pogledat ćemo jedan primjer koji ćemo najprije riješiti korištenjem pravila umnoška, a zatim ćemo dati interpretaciju s kuglicama i kutijama.

Primjer 3.3.24 (Raspodjela karata)**.** Pretpostavimo da trebamo raspodjeliti 52 karte iz špila karate četvorici igrača pri čemu svaki igrač treba dobiti 5 karata. Na koliko načina to možemo učiniti?
Odgovor: Prije svega se podsjetimo da špil karata sadrži 52 karte podijeljene u 4 boje pri čemu su karte označene brojevima od 1 do 10 te oznakama J, D, K te kartu "As" čija relativna snaga prema drugim kartama ovisi o konkretnoj igri koja se igra. U ovom

primjeru nije važna moguća hijerarhija karata, već činjenica da su sve karte međusobno različite.
Počnimo prebrojavati načine na koje 52 (različite) karte možemo podijeliti na četiri igrača tako da svatko dobije pet karata. Izvucimo 5 karata iz špila karata i dajmo ih prvom igraču. To možemo napraviti na $\binom{52}{5}$ načina (riječ je o odabiru 5 objekata od 52 njih koji se ne mogu ponavljati, a njihov poredak nije važan jer nije važno kojim je redom igrač dobio svojih 5 karata; to su sve karte koje su mu podijeljene, odnosno "drži ih u rukama"). Za svaki odabir karata koji je podijeljen prvom igraču drugome igraču možemo podijeliti njegovih 5 karata na $\binom{47}{5}$ načina jer sada onih prvih 5 podijeljenih karata više nije u špilu. Jasno je kako nastavljamo. Za svaki odabir karata prvom i drugom igraču možemo podijeliti 5 karata trećem igraču na $\binom{42}{5}$ načina, a nakon toga i četvrtom igraču na $\binom{37}{5}$ načina. Prema principu produkta zaključujemo da 52 karte možemo podijeliti na četiri igrača tako da svaki dobije 5 karata na

$$\binom{52}{5} \cdot \binom{47}{5} \cdot \binom{42}{5} \cdot \binom{37}{5}$$

načina. To je rješenje zadatka, ali možemo uočiti da dodatno vrijedi

$$\binom{52}{5} \cdot \binom{47}{5} \cdot \binom{42}{5} \cdot \binom{37}{5} = \frac{52!}{47!5!} \cdot \frac{47!}{42!5!} \cdot \frac{42!}{37!5!} \cdot \frac{37!}{32!5!} = \frac{52!}{5!5!5!5!32!}. \tag{3.9}$$

□

Izraz na desnoj strani relacije (3.9) možemo iskoristiti za interpetaciju pomoću kuglica i kutija. Naime, može se pokazati (što ovdje ne činimo) da je broj načina da se k različitih objekata rasporedi u n različitih kutija tako da svaka kutija sadrži k_i kuglica, $i = 1, 2, \ldots n$, $k_i \in \mathbb{N}_0$, $k_1 + k_2 + \ldots + k_n = k$, jednak

$$\frac{k!}{k_1!k_2! \cdots k_n!} = \frac{(k_1 + k_2 + \ldots + k_n)!}{k_1!k_2! \cdots k_n!}. \tag{3.10}$$

Taj broj se ponekad naziva i broj **permutacija s ponavljanjem**.

Prema relaciji (3.10) zaključujemo da raspodjela 52 karte na 4 igrača tako da svaki igrač dobije 5 karata odgovara raspodjeli 52 različite kuglice u 5 različitih kutija (4 igrača i neraspodijeljene karte) i to tako da prve četiri kutije sadrže po pet karata. Kao što smo vidjeli na taj način dobijemo izraz s desne strane relacije (3.9).

Ako se vratimo na Primjer 3.3.23 možemo i bez navođenja svih mogućnosti izračunati da je broj mogućnosti u kojima je u svakoj kutiji točno po jedna kuglica jednak

$$\frac{3!}{1!1!1!} = \frac{1 \cdot 2 \cdot 3}{1 \cdot 1 \cdot 1} = 6$$

što odgovara slučajevima označenim brojevima 22 do 27, dok je, na primjer, broj mogućnosti da su u prvoj kutiji dvije kuglice, u drugoj jedna, a u trećoj nijedna jednak

$$\frac{3!}{2!1!0!} = \frac{1 \cdot 2 \cdot 3}{2 \cdot 1 \cdot 1} = 3$$

što odgovara slučajevima označenim brojevima 4, 5 i 6.

Korištenjem formule (3.10) može se riješiti i problem određivanja broja različitih riječi koje se mogu formirati od određenih slova. Primjerice, uzmimo riječ STATISTIKA. Vidimo da se ona sastoji od 10 slova, pri čemu se slovo T pojavljuje 3 puta, slova A, I i S dva puta te slovo K jednom. Pitamo se koliko različitih riječi duljine 10 znakova možemo napraviti od tih slova (ne gledamo samo smislene riječi, nego sve koje se mogu napraviti).

U terminima kuglica i kutija ovom problemu možemo pristupiti na sljedeći način. Imamo 10 različitih kuglica koje označavaju mjesto u nizu od 10 znakova na kojem se nalazi pojedino slovo te 5 različitih kutija označenih slovima T, S, I, A i K. Sada problem određivanja broja različitih riječi možemo opisati kao problem određivanja broja razmještaja tih 10 kuglica u 5 kutija pri čemu kutija označena s T treba sadržavati 3 kuglice, kutije označene s A, I i S trebaju sadržavati po dvije kuglice, a kutija označena slovom K treba sadržavati jednu kuglicu. Prema formuli (3.10) slijedi da je broj takvih razmještaja jednak

$$\frac{10!}{3!2!2!2!1!} = 75.600.$$

Do istog zaključka smo mogli doći tako da uočimo da 10 različitih slova možemo permutirati (postaviti na različita mjesta u riječi) na 10! načina. S obzirom da ovdje nemamo različita slova 10! više puta broji neke od permutacija i to točno one u kojima se razmještaji, na primjer, slova T broje kao različiti kada se T nalazi na 2., 4. i 7. mjestu u riječi, a u osnovi su sve te riječi iste jer ne možemo razlikovati ta tri slova T. Stoga trebamo 10! korigirati za prevelik broj jednakih riječi koje smo brojali kao različite, odnosno podijeliti ga s 3! što je jednako broju permutacija tri objekta. Slično postupimo za sva druga slova koja imaju višestruka pojavljivanja da bi dobili isto rješenje

$$\frac{10!}{3!2!2!2!1!} = 75.600.$$

Naravno, i zaključivanjem koje smo primijenili u Primjeru 3.3.24 dolazimo do istog rješenja. Naime, od 10 mjesta u riječi (to su sada objekti) odabermo njih 3 gdje će biti slova T i to možemo napraviti na $\binom{10}{3}$ načina. Za svaki takav odabir mjesta odaberemo sljedeća dva mjesta od preostalih 7 na kojima ćemo razmjestiti slovo A na $\binom{7}{2}$ načina, zatim od od preostalih 5 mjesta odabremo ona na koje ćemo razmjestiti slovo I na $\binom{5}{2}$ načina pa na preostala 3 mjesta odaberemo dva na koje ćemo razmjestiti slovo S na $\binom{3}{2}$ načina i na preostalo mjesto razmjestimo slovo K. Prema principu umnoška je ukupan broj načina na koji to možemo napraviti jednak

$$\binom{10}{3} \cdot \binom{7}{2} \cdot \binom{5}{2} \cdot \binom{3}{2} \cdot \binom{1}{1} = \frac{10!}{3!2!2!2!1!} = 75.600.$$

Pogledajmo sada razmještaje k **jednakih kuglica** u n **različitih kutija**, $k, n \in \mathbb{N}$. Sada smo u nešto drugačijoj situaciji od prijašnjeg slučaja u kojem smo razlikovali kuglice. Očito će u ovom slučaju biti samo važno koliko kuglica ima u kojoj kutiji, a ne koje su kuglice u kojoj kutiji. Primjerice, ukoliko pogledamo opet slučaj 3 različite kuglice i 3 kutije, slučajevi 4, 5 i 6 iz tablice 3.1 će u slučaju nerazlučivih kuglica zapravo biti jednaki. U tablici 2.3 su navedeni svi slučajevi razmještaja 3 iste kuglice (kuglice koje ne razlikujemo) u 3 kutije (Primjer (*c*), str 11. iz [6]).

1.	●●●	–	–	6.	●	●●	–
2.	–	●●●	–	7.	●	–	●●
3.	–	–	●●●	8.	–	●●	●
4.	●●	●	–	9.	–	●	●●
5.	●●	–	●	10.	●	●	●

Tablica 3.2: Mogućnosti rasporeda tri kuglice koje ne razlikujemo u tri kutije

U općenitom slučaju k jednakih kuglica u n različitih kutija je ukupan broj različitih razmještaja jednak $\binom{n+k-1}{k}$. Sjetit ćemo se da smo se s tim izrazom već susreli kada

smo gledali odabire objekata koji se mogu ponavljati pri čemu poredak objekata nije bio važan. Sjetimo se da smo imali oznaku $\left(\!\binom{n}{k}\!\right)$ za $\binom{n+k-1}{k}$.

U kontekstu razmještaja kuglica koje ne razlikujemo u kutije koje razlikujemo možemo interpretirati i Primjer 3.3.22. Naime, u njemu možemo odabire pojedinog komada voća smatrati smještajem jedne od kuglica koje ne razlikujemo u kutiju koja je označena vrstom voća. Dakle, u tom je slučaju $k = 3$, a $n = 4$ pa opet dobivamo $\binom{4+3-1}{3} = 20$ načina na koji možemo razmjestiti te 3 kuglice u 4 kutije. Probajte za vježbu napraviti tablicu poput tablice 3.2 u kojoj ćete pobrojati sve te razmještaje. Pogledajmo još neke primjere.

Primjer 3.3.25 (Bronhi bomboni)**.** Na koliko načina možemo razdijeliti 6 Bronhi bombona među 8 djece?
Odgovor: Kako bombona ima manje nego djece, očito raspodjela neće biti "poštena". Dapače, kako nismo stavili niti jedno ograničenje na broj bombona koje može dobiti jedno dijete, može se dogoditi da jedno dijete dobije svih 6 bombona. Uočimo da bombone međusobno ne razlikujemo (svi su Bronhi bomboni) pa poredak rapodjele bombona nije važan. Ovo je tipičan primjer u kojem, ako želimo izbjeći interpretaciju pomoću multiskupa, na djecu možemo gledati kao na kutije, a na bombone kao na (jednake) kuglice. Stoga je traženi broj načina jednak $\binom{8+6-1}{6} = \binom{13}{6}$. Uočite da je kod ovakvih tipova zadataka dovoljno zapisati rješenje u ovakvom obliku jer je važnije odrediti način prebrojavanja, nego konkretan broj. Radi potpunosti navodimo da je $\binom{13}{6} = 1.716$. □

Primjer 3.3.26 (Izbori)**.** Na jednom biračkom mjestu je izašlo 1.200 glasača te su glasali za jednog od 3 kandidata. Na koliko načina mogu biti raspodjeljeni glasovi po kandidatima?
Odgovor: za rezultat izbora nije važno tko je kome dao glas, nego koliko je koji kandidat sakupio glasova. Stoga sve ishode izbora u kojem je, recimo, prvi kandidat dobio 100 glasova možemo smatrati jednakima iako su u svim takvim izborima različiti ljudi glasali za njega.[7] Gledajući tako na problem vidimo da je traženi broj načina jednak broju načina na koji 1.200 kuglica (koje su nerazlučive) raspodjelimo u tri kutije. Dakle, ukupan broj načina na koji 1.200 glasača može glasati za jednog od 3 kandidata je jednak $\binom{3+1200-1}{1200} = \binom{1202}{1200} = 721.801$. (Ukoliko imate dvojbe oko rješenja probajte napisati sve mogućnosti rezultata izbora na kojima 5 glasača glasa za 3 kandidata). □

Primjer 3.3.27 (Rastavi broja)**.** Neka je k neki prirodan broj. Koji je broj rastava broja k u n pribrojnika? Rastav broja k u n pribrojnika je uređena n-torka $(x_1, x_2, \ldots, x_n)$, $x_i \in \mathbb{N}_0$, $i = 1, 2, \ldots n$, za koju vrijedi $x_1 + x_2 + \ldots + x_n = k$.
Odgovor: u terminima kuglica i kutija na ovaj problem možemo gledati kao na problem smještaja k nerazlučivih kuglica u n kutija koje razlikujemo (jer gledamo uređene n-torke) pri čemu je u i-toj kutiji x_i kuglica. Znamo da to možemo napraviti na

$$\left(\!\binom{n}{k}\!\right) = \binom{n+k-1}{k}$$

načina. Uočite da je

$$\binom{n+k-1}{k} = \binom{n+k-1}{n-1}$$

što pruža mogućnost za još neke interpretacije, ali na ovom mjestu se time nećemo baviti. Konkretno, ukoliko se pitamo na koliko načina možemo napraviti rastav broja 6 na 3 pribrojnika iz gornjeg razmatranja zaključujemo da je broj načina na koji to možemo

[7] Inače, broj načina da prvi kandidat dobije točno 100 glasova je jednak $\binom{1200}{100}$, ako je važno (razlikujemo to) koji je glasač dao svoj glas tom kandidatu.

napraviti jednak

$$\left(\!\binom{3}{6}\!\right) = \binom{3+6-1}{6} = \binom{8}{6} = 28.$$

Probajte popisati sve moguće slučajeve. □

3.3.4 Binomni koeficijenti

Binomni koeficijenti $\binom{n}{k}$, $n, k \in \mathbb{N}$, imaju vrlo bogata svojstva. U ovom odjeljku navodimo neka najpoznatija, odnosno najkorisnija svojstva.

Osim iznimne kombinatorne važnosti binomni koeficijenti $\binom{n}{k}$ su važni i za algebru jer se pojavljuju u **binomnoj fomuli**. Naime, za $x, y \in \mathbb{R}$ (čak i za kompleksne brojeve) i $n \in \mathbb{N}$ vrijedi formula

$$\begin{aligned}(x+y)^n &= x^n + \binom{n}{1}x^{n-1}y + \binom{n}{2}x^{n-2}y^2 + \ldots + \binom{n}{n-1}xy^{n-1} + y^n \\ &= \sum_{k=0}^{n}\binom{n}{k}x^{n-k}y^k. \end{aligned} \tag{3.11}$$

Naravno, za $n = 2$ je $\binom{2}{0} = 1$, $\binom{2}{1} = 2$ i $\binom{2}{2} = 1$ pa dobivamo poznatu formulu

$$(x+y)^2 = x^2 + 2xy + y^2.$$

Iako su binomni koeficijenti definiraju kao $n!/(n-k)!k!$ možemo uočiti da se prvih k ili $n-k$ faktora od $n!$ u brojniku može pokratiti. Za sam izračun binomnih koeficijenata je to često vrlo praktično jer faktorijeli vrlo brzo rastu. Na primjer, možemo računati $\binom{15}{3}$ po definiciji tako da izračunamo 15!, a zatim 12! i 3! (broj 15! je veći od 1,3 biliona) ili tako da pokratimo što se može u brojniku i nazivniku pa dobijemo

$$\binom{15}{3} = \frac{15!}{12!3!} = \frac{(15)_3}{3!} = \frac{15\cdot 14\cdot 13}{1\cdot 2\cdot 3} = 455.$$

Binomni koeficijenti za manje vrijednosti n-a se često zapisuju (tako se lakše pamte) u obliku Pascalovog trokuta. Osim vanjskih jedinica, svaki broj u Pascalovom trokutu je jednak zbroju dva broja iz prethodnog retka koji se nalaze iznad tog broja. Vizualno imamo sljedeći trokut (prikazani su prvih pet redaka koji odgovaraju koeficijentima potencije binoma do $n = 4$). Općenitu vezu između elemenata Pascalovog trokuta možemo

				1				
			1		1			
		1		2		1		
	1		3		3		1	
1		4		6		4		1

Tablica 3.3: Pascalov trokut

opisati tzv. Pascalovom formulom, koja za $n, k \in \mathbb{N}$ i $1 \le k \le n-1$ daje

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}. \tag{3.12}$$

Pascalova formula je samo jedna u nizu identiteta koji uključuju binomne koeficijente. Jedan od očitijih identiteta je

$$\binom{n}{k} = \binom{n}{n-k}. \tag{3.13}$$

On se lagano pokaže tako da se raspišu lijeva i desna strana po definiciji binomnih koeficijenata. S druge strane, često se istinitost takvih jednakosti može pokazati kombinatornim argumentima. Tako, na primjer, imamo sljedeću argumentaciju: uzmimo n kuglica označenih brojevima od 1 do n koje se nalaze u jednoj kutiji. NJih k (od n) možemo odabrati i izvući iz kutije na $\binom{n}{k}$ načina. No, to je isto kao da smo odabrali $n-k$ kuglica koje su ostale u kutiji, a taj odabir možemo napraviti na $\binom{n}{n-k}$ načina. Ovakav tip argumentacije, odnosno dokaza, naziva se **kombinatornim dokazom**.

Također, ako binomne koeficijente $\binom{n}{k}$ interpretiramo kao broj podskupova n-članog skupa s k elemenata, a znamo da skup s n elemenata ukupno ima 2^n podskupova, onda je dosta jasno da vrijedi

$$\binom{n}{0}+\binom{n}{1}+\binom{n}{2}+\cdots+\binom{n}{n-1}+\binom{n}{n}=2^n$$

jer se svi podkupovi n-članog skupa mogu pobrojati tako da pobrojimo sve podskupove n-članog skupa koji imaju točno k elemenata, a takvih ima $\binom{n}{k}$, $k=0,1,\ldots,n$. Naravno, taj identitet možemo dobiti i algebarki i to tako da u binomnu formulu (3.11) uvrstimo $x=y=1$.

Bez želje za prezentacijom iole cjelovitijeg pregleda identiteta koji uključuju binomne koeficijente navodimo još nekoliko identiteta:

$$\binom{n}{k}=\frac{n}{k}\binom{n-1}{k-1},\ k\neq 0,$$

$$\binom{n}{m}\binom{m}{k}=\binom{n}{k}\binom{n-k}{m-k},$$

$$\sum_{k\leq n}\binom{r+k}{k}=\binom{r+n+1}{n},$$

Završit ćemo ovaj kratki pregled svojstava binomnih koeficijenata s još jednom opservacijom. Pogledajmo jedan redak Pascalovog trokuta:

$$\binom{n}{0},\ \binom{n}{1},\ldots,\binom{n}{k},\ldots,\binom{n}{n-1},\ \binom{n}{n}.$$

Tada se pokazuje da taj niz brojeva raste do sredine kako povećavamo k, odnosno raste do člana za koji je $k=\lfloor n/2\rfloor$, a nakon toga pada.[8] Na primjer, za $n=6$ imamo niz brojeva

$$\binom{6}{0}=1,\binom{6}{1}=6,\binom{6}{2}=15,\binom{6}{3}=20,\binom{6}{4}=15,\binom{6}{5}=6,\binom{6}{6}=1$$

dok za $n=5$ imamo niz brojeva

$$\binom{5}{0}=1,\binom{5}{1}=5,\binom{5}{2}=10,\binom{5}{3}=10,\binom{5}{4}=5,\binom{5}{5}=1.$$

Vidimo da su za neparne brojeve dva člana niz binomnih koeficijenata najveći. Maksimum se u ovom slučaju postiže za $k=\lfloor 2,5\rfloor=2$, ali je $\binom{5}{2}=\binom{5}{3}$ zbog formule (3.13).

[8] S $\lfloor\cdot\rfloor$ smo označili funkciju "pod" (eng. *floor*) čija je vrijednost za realne brojeve x jednaka najmanjem cijelom broju koji je manji ili jednak od x; na primjer, $\lfloor\pi\rfloor=3$.

3.4 Primjeri računanja vjerojatnosti naivnom definicijom vjerojatnosti

Osnovni motiv za pregled kombinatornih metoda prebrajanja u prethodnom potpoglavlju je bila bolja priprema za određivanje broja elemenata nekih skupova, odnosno za primjenu formule (3.6). Uočimo da praktički sve primjere koje smo predstavili u prethodnom potpoglavlju možemo prevesti u vjerojatnosne probleme. Tako se u primjeru 3.3.14 možemo pitati koja je vjerojatnost da će slučajno generirana lozinka duljine 4 biti jednaka "1234". Odgovor na ovo pitanje je lagan kada znamo koliko takvih lozinki ukupno ima. Naime, označimo s Ω skup svih lozinki duljine 4 sastavljenih od znamenki $0, 1, \ldots, 9$ pri čemu se niti jedna znamenka ne ponavlja. Vidjeli smo da je $|\Omega| = (10)_4 = 5.040$. Definiramo događaj $A =$ "generirana je lozinka 1234". Očito $|A| = 1$. Pitamo se koja je vjerojatnost događaja A.

Kako se sve slučajno generirane lozinke generiraju s istom vjerojatnošću (pod time zapravo i podrazumijevamo slučajno generiranje) možemo primijeniti naivnu definiciju vjerojatnosti, odnosno formulu (3.6). No, tada je jasno da je vjerojatnost da će slučajno generirana lozinka duljine 4 biti jednaka 1234 zapravo jednaka

$$P(A) = \frac{|A|}{|\Omega|} = \frac{1}{5040} \approx 0.000198.$$

Slično se, u primjeru 3.3.20, možemo pitati koja je vjerojatnost da će biti izvučena kombinacija $1, 2, 3, 4, 5, 6, 7$. Opet uočimo da su sve kombinacije (bez ponavljanja) 7 brojeva od njih 39 jednako vjerojatne jer se brojevi biraju na slučajan način. Vidjeli smo da je ukupan broj kombinacija jednak $\binom{39}{7}$ što znači da prostor elementarnih događaja Ω ima toliko jednako vjerojatnih elemenata. S obzirom da događaj čiju vjerojatnost želimo izračunati ima samo jedan element (zapravo je to elementarni događaj, odnosno element skupa Ω), onda je tražena vjerojatnost jednaka

$$\frac{1}{\binom{39}{7}} = \frac{7!}{33 \cdot 34 \cdot 35 \cdot 36 \cdot 37 \cdot 38 \cdot 39} \approx 6,5 \cdot 10^{-8}.$$

Uočite da je ta vjerojatnost jednaka vjerojatnosti da će biti izvučena kombinacija brojeva $2, 8, 16, 22, 25, 28, 34$, kao uostalom i bilo koja druga pojedinačna kombinacija 7 brojeva.

Napomena 3.4.1. Vratimo se još malo na primjer računanja vjerojatnosti generiranja nekih lozinki duljine 4 sastavljenih od znamenki $0, 1, \ldots, 9$ pri čemu se niti jedna znamenka ne ponavlja. Možemo pokušati odrediti vjerojatnosti nekih složenijih događaja. Na primjer, izračunajmo vjerojatnost da će lozinka sadržavati znamenku 3. U tu svrhu definirajmo četiri događaja: $A_1 =$ "znamenka 3 se nalazi na prvom mjestu", $A_2 =$ "znamenka 3 se nalazi na drugom mjestu", $A_3 =$ "znamenka 3 se nalazi na trećem mjestu" i $A_4 =$ "znamenka 3 se nalazi na četvrtom mjestu". Ti su događaji disjunktni jer se znamenke ne ponavljaju pa nalaženje znamenke 3 na i-tom mjestu isključuje da se ona nalazi na j-tom mjestu za $i \neq j$, $i, j \in \{1, 2, 3, 4\}$. S druge strane se događaj $A =$ "lozinka sadrži znamenku 3" može zapisati kao unija događaja A_i, $i = 1, 2, 3, 4$, odnosno

$$A = A_1 \cup A_2 \cup A_3 \cup A_4 = \bigcup_{i=1}^{4} A_i.$$

Koristeći se formulom (3.6) računamo vjerojatnost događaja A:

$$P(A) = \frac{|A|}{|\Omega|} = \frac{|\bigcup_{i=1}^{4} A_i|}{|\Omega|} = \frac{\sum_{i=1}^{4} |A_i|}{|\Omega|} = \sum_{i=1}^{4} \frac{|A_i|}{|\Omega|} = \sum_{i=1}^{4} P(A_i) = 4P(A_1). \tag{3.14}$$

Uočite da smo u trećoj jednakosti primijenili pravilo zbroja (A_i su disjunktni) dok smo u zadnjoj jednakost iskoristili činjenicu da su vjerojatnosti sva četiri događaja A_1, A_2, A_3, A_4 jednako vjerojatna, odnosno imaju jednak broj elemenata (zbog simetrije). Ostaje nam za izračunati $P(A_1)$, ali to je lagano kada uočimo da nakon smještaja znamenke 3 na prvo mjesto imamo još 9 znamenki kojemožemo smjestiti na preostala 3 mjesta što možemo napraviti na $(9)_3$ načina. Iz formule (3.14) dobivamo

$$P(A) = 4P(A_1) = 4\frac{|A_1|}{|\Omega|} = 4\frac{(9)_3}{(10)_4} = 4\frac{9 \cdot 8 \cdot 7}{10 \cdot 9 \cdot 8 \cdot 7} = 0.4.$$

Gornji izračun možemo kombinatorno argumentirati na sljedeći način: da bi odredili broj elemenata skupa A najprije trebamo odabrati mjesto na kojem se nalazi broj 3, što možemo napraviti na $\binom{4}{1}$ načina, a onda uočiti da se na preostala 3 mjesta preostalih 9 znamenki može rasporediti na $(9)_3$ načina. Naravno, dobivamo istu vjerojatnost.
Uočimo da sada jednostavno možemo izračunati vjerojatnost da slučajno generirana lozinka ne sadrži znamenku 3 jer je taj događaj komplement događaja A da lozinka sadrži znamenku 3. A^c nazivamo suprotnim događajem od A, a u Primjeru 3.2.13 smo vidjeli da se vjerojatnost suprotnog događaja računa kao $P(A^c) = 1 - P(A)$ pa je

$$P(A^c) = 1 - P(A) = 1 - 0,4 = 0,6.$$

To možemo potvrditi i direktnim izračunom jer lozinki koje ne sadrže znamenku 3 ima $(9)_4$ pa je $P(A^c) = (9)_4/(10)_4 = 6/10 = 0.6$. □

Pogledajmo još neke primjere računanja vjerojatnosti događaja koji se javljaju u nekim slučajnim eksperimentima.

Primjer 3.4.2. U skupu 10 različitih proizvoda nalazi se jedan koji posebno želimo. Koja je vjerojatnost da će slučajno odabrani uzorak od 4 proizvoda sadržavati baš taj predmet koji želimo?
Odgovor: Ukupan broj odabira 4 predmeta od 10 njih je jednak $\binom{10}{4}$. Dakle,

$$|\Omega| = \binom{10}{4}.$$

Događaj, označimo ga s B, koji je naveden u zadatku znači da će svaki takav odabir sadržavati baš predmet koji želimo, dok će ostati 9 predmeta za odabir. Kako smo već odabrali jedan predmet (baš onaj koji želimo) ostalo nam je za odabrati još 3 predmeta od 9 njih što možemo napraviti na $\binom{9}{3}$ načina, odnosno

$$|B| = \binom{9}{3}.$$

Dakle, tražena vjerojatnost je jednaka

$$P(B) = \frac{|B|}{|\Omega|} = \binom{9}{3}/\binom{10}{4} = 0,4.$$

U ovom primjeru imamo male brojeve pa traženu vjerojatnost jednostavno izračunamo. Uočimo da smo mogli iskoristiti i jedan od identiteta s binomnim koeficijentima koje smo naveli: $\binom{n}{k} = \frac{n}{k}\binom{n-1}{k-1}$ i onda zaključiti

$$\frac{\binom{9}{3}}{\binom{10}{4}} = \frac{\binom{9}{3}}{\frac{10}{4}\binom{9}{3}} = \frac{4}{10} = 0,4.$$

□

Primjer 3.4.3 (Uniformni raspored; Primjer (b), str. 32. u [6]). Razmještamo n različitih kuglica u n (različitih) kutija na slučajan način. Koja je vjerojatnost da će svaka kutija sadržavati točno jednu kuglicu?
Odgovor: Ukupan broj načina na koji možemo razmjestiti n različitih kuglica u n kutija je jednak n^n. S druge strane broj razmještaja n različitih kuglica u n kutija tako da svaka od kutija sadrži točno jednu kuglicu je jednak $n!$ (u prvu kutiju možemo staviti bilo koju od n kuglica, u drugu jednu od preostale $n-1$ kuglice i tako dalje). Dakle, tražena vjerojatnost je jednaka $n!/n^n$. Ukoliko je $n = 7$, na primjer, onda je ta vjerojatnost približno jednaka $0,00612$. Uočimo da je ta vjerojatnost dosta mala, što zapravo znači da je uniformna distribucija kuglica po kutijama (u svakoj kutiji je jednak broj kuglica) malo vjerojatna. To, posljedično, znači da će i raspodjela 7 automobilskih nesreća po svim danima u tjednu biti malo vjerojatna (ako se nesreće događaju na slučajan način), kao i slučaj u kojem će prilikom bacanja 6 kockica pasti svi različiti brojevi ($6!/6^6$). □

Primjer 3.4.4 (Izlasci iz lifta; Primjer (c), str. 32. u [6]). Pretpostavimo da u prizemlju zgrade od 10 katova u lift uđe 7 osoba. Pretpostavimo da tih 7 ljudi nisu u nekom posebnom odnosu te da je vjerojatnost da će izaći na bilo kojem od katova jednaka. Koja je vjerojatnost da niti na jednom katu neće izaći više od jedne osobe?
Odgovor: Sedmero ljudi smatramo različitima i njihov izlazak po katovima smatramo uređenim (osoba će izaći na 1. katu, na 2. katu i tako dalje). Već smo vidjeli takve primjere pa je jasno da je ukupan broj mogućnosti izlaska osoba iz lifta jednak 10^7 (prva osoba može izaći na jednom od 10 katova, druga osoba može izaći na jednom od 10 katova i tako dalje). Događaj u kojem niti jedne dvije (ili više) osobe ne izlaze na istom katu prebrajamo tako da uočimo da prva osoba može izaći na jednom od 10 katova, druga osoba na jednom od 9 katova i tako dalje. Dakle, broj načina na koji 7 osoba može izaći na 10 katova bez da ikoje dvije izađu na istom katu je jednak $(10)_7$, a vjerojatnost tog događaja je

$$\frac{(10)_7}{10^7} = \frac{10 \cdot 9 \cdot 8 \cdot 7 \cdot 6 \cdot 5 \cdot 4}{10^7} = 0,06048.$$

Ovaj primjer još jednom pokazuje da je uniformna distribucija objekata (jednak broj izlazaka po katovima) zapravo prilično malo vjerojatna. □

Primjer 3.4.5 (Rođendani; Primjer 1.4.10 u [3]). Pretpostavimo da se n osoba nalazi u sobi. Koja je vjerojatnost da dvije ili više osoba, od tih n osoba, imaju rođendan na isti dan u godini? Koliki mora biti n da bi ta vjerojatnost bila veća od $1/2$?
Odgovor: Malo precizirajmo problem pretpostavljajući da godina ima 365 dana te da ne postoji neka posebna povezanost između danih n osoba (npr. nema blizanaca). Ukupan broj mogućih rođendana koje može imati tih n osoba je 365^n. Direktan izračun (prebrojavanje) broja događaja u kojem dvije ili više osoba ima rođenda na isti dan je relativno teško izračunati, ali je dosta lagano izračunati broj načina na koji sve te osobe (ako ih je manje ili jednako 365) mogu imati rođendan na različite dane. Naime, taj je broj jednak $(365)_n$. Stoga je vjerojatnost događaja $E =$ "sve osobe imaju rođendan na različite dane je jednak

$$P(E) = \frac{365 \cdot 364 \cdot \ldots \cdot (365 - n + 1)}{365^n}.$$

Događaj koji se navodi na početku primjera je komplement ovog događaja pa je njegova vjerojatnost jednaka

$$P(E^c) = 1 - \frac{365 \cdot 364 \cdot \ldots \cdot (365 - n + 1)}{365^n}.$$

Pokazuje se da je za $n = 23$ ta vjerojatnost veća od $1/2$ (naravno, i za sve veće n). Može biti iznenađujuće da je već za 23 osobe vjerojatnost da će barem dvije među njima imati

rođendan na isti dan veća od 0.5, ali uočimo sljedeće: vjerojatnost da će par od dvije osobe imati rođendan na isti dan je jednaka $365/365^2 = 1/365$, a u grupi od 23 osobe imamo ukupno $\binom{23}{2} = 253$ različitih parova.

Problem rođendana je još jedan od klasičnih problema u vjerojatnosti koji je postavio von Mises 1939. godine. Više detalja može se naći u [7].

Primjer 3.4.6 (Poker)**.** Pogledajmo primjer igraćih karata (za poker ili bridge). Znamo da se u špilu karata nalaze karte u 4 boje (srce, karo, pik i tref) te po 13 karata u svakoj od boja (as, $2, 3, \ldots 10$, J, D K). Ukupno imamo 52 karte (nema jokera). U pokeru se dijeli 5 karata. Ukupan broj načina na koji možemo podijeliti 5 karata (izvlačenje bez ponavljanja, poredak nije bitan) je $\binom{52}{5}$. Stoga za skup svih mogućnosti dijeljenja 5 karata možemo uzeti vjerojatnosni prostor Ω s $\binom{52}{5}$ elemenata, pri čemu je svaki takav odabir jednako moguć/vjerojatan. Sada možemo računati vjerojatnosti dobivanja raznih kombinacija karata korištenjem formule (3.6).

Različite karte. Izračunajmo vjerojatnost da će svih 5 karata biti različite (tj. brojevi na njima će biti različiti). Znamo da 5 različitih karata od 13 mogućih možemo odabrati na $\binom{13}{5}$ načina, pri čemu svaka karta može biti u jednoj od 4 boje. Prema principu umnoška imamo $4^5\binom{13}{5}$ načina na koji možemo odabrati različite karte pa je tražena vjerojatnost jednaka

$$\frac{4^5\binom{13}{5}}{\binom{52}{5}} = 0,5070828.$$

Poker. Ukoliko su 4 karte (od 5 podijeljenih) iste, onda smo dobili poker, koja je jedna od najjačih kombinacija u igri poker (uočimo, snaga karata koje dobivamo u pokeru odgovara kombinacijama podijeljenih karata s manjom vjerojatnošću; manje vjerojatne kombinacije su jače). Ukoliko smo dobili poker karata, a njega možemo odabrati na $\binom{13}{1}$ načina, onda je jedina nepoznanica 5. karta koju smo dobili. Nju možemo odabrati na $\binom{12}{1}$ načina u jednoj od 4 boje. Stoga je vjerojatnost dobivanja pokera jednaka

$$\frac{\binom{13}{1}4\binom{12}{1}}{\binom{52}{5}} = 0,000240096.$$

Karte iste boje. Nakon pokera je po snazi ful (tri iste i dvije iste karte; njih možemo odabrati na $\binom{13}{1}\binom{4}{3}\binom{12}{1}\binom{4}{2}$ načina), a nakon njega boja, odnosno kombinacija karata koje su sve iste boje. Za odabir karata iste boje trebamo prvo odabrati jednu od 4 boje i onda 5 od 13 karata iste boje. Stoga je vjerojatnost dobivanja boje jednaka

$$\frac{4\binom{13}{5}}{\binom{52}{5}} = 0,001980792.$$

Iako je ovaj izračun točan, u pokeru su ipak izdvojene neke kombinacije boja (5 karata iste boje) koje su po snazi iznad boje pa čak i pokera. Naime, najjača kombinacija u pokeru je tzv. royal flush kod koje je dobiveno 5 (različitih) karata u nizu (10, J, D, K A) pri čemu su sve u istoj boji. Royal flush možemo odabrati na $\binom{4}{1}$ načina (ima samo 4 royal flusha). Odmah iza royal flusha, po snazi podijeljenih karata, je skala u boji koju čini 5 karata iste boje u nizu (A,2,3,4,5 pa 2,3,4,5,6 sve do 9,10,J,D,K). Ukoliko isključimo Royal flush, onda je broj mogućih skala u boji jednak $\binom{9}{1} \cdot \binom{4}{1}$ (odaberemo jednu od 9 početnih karata skale (A, 2, 3,...9) i odaberemo jednu od 4 boje). Kada zbrojimo sve royal flusheve i skale u boji dolazimo do $4\binom{10}{1}$ mogućnosti. Stoga je, u kontekstu igre poker, vjerojatnost dobivanja boje jednaka

$$\frac{4\binom{13}{5} - 4\binom{10}{1}}{\binom{52}{5}} = 0,001965402.$$

Skale. Nakon karata iste boje u pokeru po snazi dolaze skale, odnosno podjele karata u kojima su karte poredane po redu, s time da as može biti i 1 i doći nakon kralja. Da bi izbrojali mogućnosti dobivanja skale dovoljno je odabrati prvi broj skale jer su sljedeća četiri broja onda određena. Stoga je broj mogućih rasporeda u kojima se dobiva skala jednak $4^5\binom{10}{1}$ (svaka od karata skale može biti u jednoj od 4 boje). Opet možemo uočiti da trebamo napraviti korekciju za royal flusheve i skale u boji kako bi poštovali pravila pokera pa je vjerojatnost dobivanja skale jednaka

$$\frac{4^5\binom{10}{1} - 4\binom{10}{1}}{\binom{52}{5}} = 0,003924647.$$

Različite karte koje nisu dobitne. Kao što smo istaknuli, podjela različitih karata (od 5 njih) ne znači da kombinacija karata koju imamo u rukama nije dobitna (odnosno, nema neku snagu u pokeru). Naime, podjela različitih karata uključuje i royal flush i skalu u boji i podjele karata iste boje kao i uzastopnih karata, odnosno skala. Stoga, ako želimo izračunati vjerojatnost da če svih 5 podijeljenih karata biti različite te neće uključivati jednu od dobitnih kombinacija trebamo korigirati (oduzeti) prije izračunat ukupan broj načina na koji možemo odabrati svih 5 različitih karata za broj načina na koji se može dobiti jedna od skala. Moramo samo paziti da ne oduzmemo dva puta royal flusheve i skale u boji. Stoga je vjerojatnost da će se dobiti različite karte koje neće biti dobitne jednaka

$$\frac{4^5\binom{13}{5} - \left(4\binom{13}{5} - 4\binom{10}{1}\right) - \left(4^5\binom{10}{1} - 4\binom{10}{1}\right) - 4\binom{10}{1}}{\binom{52}{5}} = 0,5011774.$$

Do iste vjerojatnosti možemo doći i na malo drugačiji način - skupovno, što je bliže vjerojatnosnom pogledu na prebrajanja. U tu svrhu označimo s A skup (dakle, događaj) svih različitih karata, s B skup svih karata u istoj boji te sa C skup svih skala (cijelo vrijeme je vjerojatnosni prostor isti jer gledamo podjelu 5 karata od njih 52). Skupovi B i C su podskupovi od A te se skup A može zapisati kao disjunktna unija skupova $A \setminus (B \cup C)$ i $B \cup C$ (ako imate dvojbe nacrtajte Vennov dijagram za takve skupove). Kao što smo vidjeli u Napomeni 3.4.1 (zbog pravila zbroja) za disjunktne skupove vrijedi da je vjerojatnost unije jednaka zbroju vjerojatnosti pa je

$$P(A) = P(A \setminus (B \cup C)) + P(B \cup C).$$

Ako malo razmislimo vidjet ćemo da nama zapravo treba vjerojatnost događaja $A \setminus (B \cup C)$ jer on opisuje one mogućnosti podjele 5 karata u kojima nema posebnih razmještaja koji imaju značaj u pokeru. Dakle, imamo

$$P(A \setminus (B \cup C)) = P(A) - P(B \cup C). \tag{3.15}$$

Vjerojatnost događaja A smo već izračunali na samom početku ovog primjera pa nam ostaje za izračunati vjerojatnost događaja $B \cup C$. Događaji B i C nisu disjunktni, ali za sve skupove vrijedi

$$|B \cup C| = |B| + |C| - |B \cap C|.$$

To skupovno svojstvo se preko formule (3.6) prenosi na vjerojatnost pa imamo (razmislite i uvjerite se u to)

$$P(B \cup C) = P(B) + P(C) - P(B \cap C).$$

Vjerojatnost događaja B i C smo već izračunali, s time da ne trebamo posebno oduzimati skale u boji i royal flusheve. Naime, događaji B i C u svom presjeku imaju royal flusheve

i skale u boji pa je $P(B \cap C) = 4\binom{10}{1}$. Ako se sada vratimo na jednakost u (3.15) dobit ćemo

$$P(A \setminus (B \cup C)) = P(A) - P(B) - P(C) + P(B \cap C)$$

pri čemu već imamo izračunate sve vjerojatnosti s desne strane. Naravno, kada uvrstimo poznate vjerojatnosti dobivamo da je vjerojatnost događaja u kojem su podjeljene različite karte koje nisu dobitne jednaka $0,5011774$. □

Za kraj ovog potpoglavlja navodimo jedan primjer koji nas još jednom upozorava da je naivna definicija vjerojatnosti 3.2.10 primjenjiva za izračun vjerojatnosti konačnih skupova SAMO ako su sve vjerojatnosti elementarnih događaja jednake. Za usporedbu pogledajte i drugi dio primjera 3.2.14.

Primjer 3.4.7 (Problem s primjenom naivne definicije vjerojatnosti)**.** U odjeljku 3.3.3 smo pokazali kako se neki kombinatorni problemi mogu iskazati u terminima razmještanja kuglica, koje razlikujemo ili ne, u kutije koje razlikujemo (pogledajte tablice 3.1 i 3.2). Pogledajmo najprije slučaj kuglica koje razlikujemo i to za 3 kuglice i 3 kutije. Ukoliko sve slučajeve navedene u tablici 3.1 smatramo elementarnim događajima koji tvore prostor elementarnih događaja Ω_1, onda možemo zaključiti da su svi ti elementarni događaji jednako vjerojatni. Dakle, vjerojatnost svakog pojedinog elementarnog događaja je jednaka $1/27$. Stoga je u tom slučaju primjenjiva naivna definicija vjerojatnosti pa možemo lagano računati vjerojatnosti nekih događaja. Na primjer, neka je E_1 događaj "u prvoj kutiji se nalaze 2 kuglice, a u drugoj jedna", E_2 događaj "u svakoj kutiji se nalazi po jedna kuglica" te E_3 događaj "u drugoj kutiji se nalazi jedna kuglica, a u trećoj dvije kuglice".
Vjerojatnost događaja E_1 je jednaka $3/27 = 1/9$ jer se događaj E_1 sastoji od elementarnih događaja numeriranih u tablici 3.1 brojevima 4, 5 i 6. Na sličan način vidimo da je vjerojatnost događaja E_3 također jednaka $1/9$ (reci 19, 20 i 21 u tablici 3.1). Vjerojatnost događaja E_2 je jednaka $6/27 = 2/9$ (reci 22-27 u tablici 3.1)
Definirajmo sada događaj $E =$ "u drugoj kutiji se nalazi jedna kuglica". Jasno je da je $E = E_1 \cup E_2 \cup E_3$, pri čemu su E_1, E_2 i E_3 međusobno disjuntni. Zbroj pravila zbroja vidimo, kao u Napomeni 3.4.1, da je vjerojatnost događaja E jednaka zbroju vjerojatnosti događaja E_i, $i = 1, 2, 3$, jer je

$$\begin{aligned} P(E) &= \frac{|E|}{|\Omega|} = \frac{|E_1 \cup E_2 \cup E_3|}{|\Omega|} = \frac{|E_1| + |E_2| + |E_3|}{|\Omega|} = \frac{|E_1|}{|\Omega|} + \frac{|E_2|}{|\Omega|} + \frac{|E_3|}{|\Omega|} \\ &= P(E_1) + P(E_2) + P(E_3). \end{aligned}$$

Vidjet ćemo u sljedećem poglavlju da je to općenito svojstvo vjerojatnosti za disjunktne unije. Zaključujemo da je

$$P(E) = \frac{1}{9} + \frac{2}{9} + \frac{1}{9} = \frac{4}{9}.$$

Pogledajmo sada slučaj razmještaja 3 kuglice koje ne razlikujemo u 3 kutije. Iz tablice 3.2 zaključujemo da se u ovom slučaju prostor elementarnih događaja sastoji od 10 elemenata pri čemu su prije definirani skupovi E_1, E_2 i E_3 sada elementarni događaji (redovi 4, 9 i 10 u tablici 3.2). Kada bi, po uzoru na prijašnje primjere, htjeli da su svi ti elementarni događaji jednako vjerojatni onda bi vjerojatnost svakog od tih (elementarnih) događaja bila jednaka $1/10$. Oni su i dalje međusobno disjunktni, ali je sada $P(E) = 3/10 \neq 4/9$.
Razlika koja se javlja u rezultatu može se interpretirati tako da se konstatira da je stvarna raspodjela kuglica u naravi kao u tablici 3.1 pa stoga elementarni događaji u tablici 3.2 jednostavno nisu jednako vjerojatni. Stoga se naivna definicija vjerojatnosti ne primjenjuje u tom slučaju.

S druge strane, teorijski gledano, nema neke posebne zapreke da se u slučaju kuglica koje ne razlikujemo definira "nekakva" vjerojatnost koja svim elementarnim događajima iz tablice 3.2 dodijeli istu vjerojatnost. Izračunate vjerojatnosti neće odgovarati empirijskim vjerojatnostima koje bi mogli računati kada bi gledali stvarnu raspodjelu 3 kuglice u 3 kutije, ali to može poslužiti kao model za neki drugi slučajni eksperiment. Vidjet ćemo u sljedećem poglavlju da se na istom prostoru elementarnih događaja mogu definirati različite vjerojatnosti koje će, usprkos tome, imati zajednička svojstva. □

3.5 Primjena R-a za izračun vjerojatnosti

U R-u se mogu brzo računati i neke vjerojatnosti koje smo prije računali. R sadrži funkciju `factorial()` koja računa faktorijel od argumenta, kao i funkciju `choose` koja računa binomni koeficijent za zadane argumente. Tako možemo izračunati vrijednost od 15! ili od $\binom{10}{4}$:

```
> print(factorial(15), digits=15)

[1] 1307674368000

> choose(10,4)

[1] 210
```

Funkciju `choose` možemo iskoristiti da zorno vidimo kako se mijenja vrijednost binomnih koeficijenata $\binom{n}{k}$ kada mijenjamo k. Na primjer, imamo

```
> ind<-c(0:10)
> choose(10, ind)

 [1]   1  10  45 120 210 252 210 120  45  10   1
```

Na taj način možemo prikazati i prvih 11 redova Pascalovog trokuta

```
[1] 1
[1] 1 1
[1] 1 2 1
[1] 1 3 3 1
[1] 1 4 6 4 1
[1]  1  5 10 10  5  1
[1]  1  6 15 20 15  6  1
[1]  1  7 21 35 35 21  7  1
[1]  1  8 28 56 70 56 28  8  1
 [1]   1   9  36  84 126 126  84  36   9   1
 [1]   1  10  45 120 210 252 210 120  45  10   1
```

te se uvjeriti da vrijedi Pascalova formula (3.12) za binomne koeficijente. Naravno, možemo izračunati i razne vjerojatnosti koje smo izračunali ranije poput vjerojatnosti dobivanja pokera u Primjeru 3.4.6

```
> 4*choose(13,1)*choose(12,1)/choose(52,5)

[1] 0.000240096
```

R možemo iskoristiti i da generiramo slučajne uzorke (zapravo pseudo slučajne, pomoću generatora slučajnih brojeva) korištenjem funkcije `sample()`. Ako želimo generirati uređeni uzorak slučajnog odabira 5 brojeva od 10 njih bez ponavljanja iskoristimo sljedeći kod

```
> sample(10,5)

[1] 10  7  2  6  5
```

Riječ je o pseudoslučajnom uzorku, u što se možemo uvjeriti tako da promijenimo mjesto u generatoru slučajnih brojeva od kojega R počne uzimati slučajne brojeve između 0 i 1. To radimo funkcijom `set.seed()`. Funkcija `set.seed` je korisna jer omogućuje drugima da reproduciraju rezultate nekih simulacija koje smo napravili. Imamo sljedeći primjer.

```
> set.seed(1)
> sample(10,5)

[1] 9 4 7 1 2

> set.seed(2022)
> sample(10,5)

[1] 4 3 6 7 9
```

Ukoliko želimo generirati veći broj uzoraka možemo koristiti funkciju `replicate()` kojoj argument na prvom mjestu označava željeni broj ponavljanja. Generirajmo 13 uzoraka slučajnog odabira 5 brojeva od 10 njih bez ponavljanja

```
> replicate(13, sample(10,5))

     [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12] [,13]
[1,]    4    9    7    1    6    4    2    7    3     9     8     4     5
[2,]    6    8    6    2    7    8   10    1    5     8     1     7     3
[3,]    7    7    5    9   10    3    8   10    4     3    10     9     2
[4,]    9    5    1    7    5   10    5    3    2     4     3     8     1
[5,]   10    2    3    5    3    5    9    9    1     2     2    10     4
```

Možemo generirati i uzorke s ponavljanjem tako da u funkciju `sample` definiramo vrijednost argumenta `replace` kao `TRUE`.

```
> replicate(13, sample(10,5, replace=TRUE))

     [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12] [,13]
[1,]    2   10   10    3    2    1    5    2    4    10    10    10     7
[2,]   10    7    1    3    5    2    8    3    6    10     3    10     4
[3,]    5    7    7    4   10    5    1    6    5     6     4     1     9
[4,]    6    8    9    3    1    1    9    3    1     2     1     2     5
[5,]    1    8    9    6    8    2    7    4    4     1     3     6    10
```

R može generirati i uzorke znakova. Sljedeći kod generira uzorak duljine 5 sastavljen od slova a,b,c,d,e,f,g,h,i,j.

```
> sample(c("a","b","c","d","e","f","g","h","i","j"),5)

[1] "g" "a" "d" "j" "b"
```

U R-u se mogu generirati i sve permutacije nekog niza elemenata (brojeva, slova). Jedan od R-ovih paketa koji sadrži potrebne funkcije je `permute`.[9] Njegova funkcija `allPerms()` je iskorištena niže kako bi se generirale sve permutacije brojeva $1, 2, 3$. Uočite da funkcija `allPerms` ne navodi prvu permutaciju 1 2 3.

```
> library("permute")
> allPerms(c(1,2,3))

     [,1] [,2] [,3]
[1,]    1    3    2
[2,]    2    1    3
[3,]    2    3    1
[4,]    3    1    2
[5,]    3    2    1
```

R nam može pomoći u izračunu vjerojatnosti iz primjera 3.4.5 (rođendani). Naime, za $k = 23$ možemo jednostavno izračunati vjerojatnost da će barem dvoje od 23 ljudi imati rođendan na isti dan.

```
> k<-23
> p<-1-prod((365-k+1):365)/365^k
> cat("Tražena vjerojatnost je jednaka", p)

Tražena vjerojatnost je jednaka 0.5072972
```

Zanimljivo je da R ima ugrađene funkcije `pbirthday()` i `qbirthday()` koje računaju vjerojatnost da će barem dvije osobe (od broja koji navedemo) imati rođendan na isti dan, odnosno koje daju broj osoba koji je potreban da bi se postigla navedena vjerojatnost. Tako imamo

```
> pbirthday(23)

[1] 0.5072972

> qbirthday(0.5)

[1] 23
```

Korištenjem tih funkcija možemo izračunati i vjerojatnost (odnosno broj ljudi potreban da se postigne neka vjerojatnost) da će od određenog broja ljudi barem troje imati rođendan na isti dan. To računamo tako da dodamo parametar `coincide` u te funkcije i dodjelimo mu vrijednost 3. Imamo

```
> pbirthday(23, coincide =3)

[1] 0.01441541

> qbirthday(0.5, coincide=3)

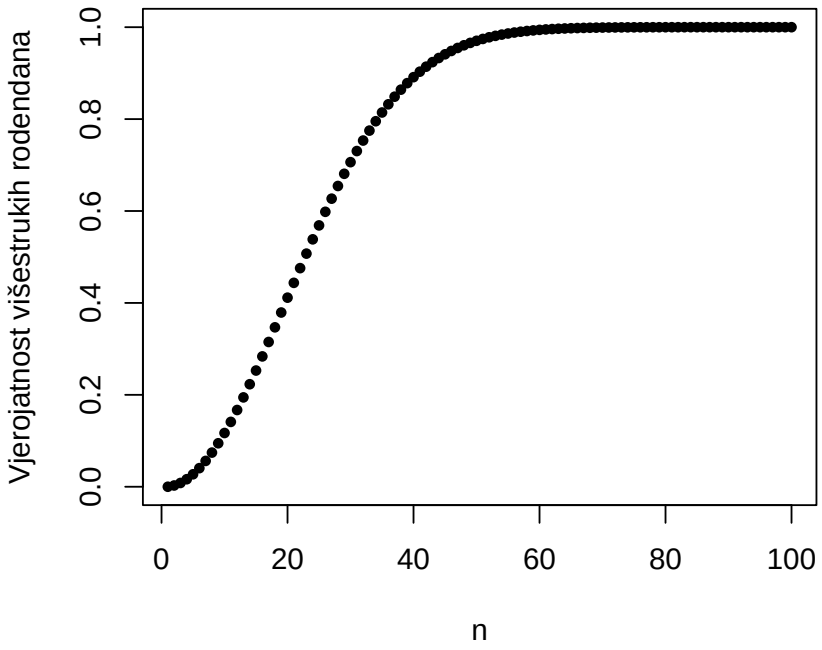
[1] 88
```

[9] Ima, naravno, i drugih paketa koji nam mogu pomoći za generiranje svih permutacija, a s malo programiranja se može i unutar standardnog R-a (bez dodatnih paketa) dobiti lista svih permutacija; pogledajte prilično opširnu raspravu na https://stackoverflow.com/questions/11095992/generating-all-distinct-permutations-of-a-list-in-r.

Vidimo da je sada potebno 88 osoba da bi vjerojatnost da će barem tri od njih imati rođendan na isti dan bila veća od $0,5$.

Vizualno možemo grafom predstaviti promjenu vjerojatnosti događaja "među n ljudi barem dvoje ima rođendan na isti dan" u ovisnosti o promjeni broja n. Na donjem grafu je predstavljeno kretanje vjerojatnosti za n između 1 i 100. Koristili smo `for` petlju da bi spremili te vjerojatnosti u vektor `p` te `plot()` funkciju da bi ih nacrtali.

```
> par(mar=c(4,4,2,2))
> for (k in 1:100){
+   p[k]<-1-prod((365-k+1):365)/365^k
+ }
> plot( p, pch=16, cex=0.8, xlab="n",
+       ylab="Vjerojatnost višestrukih rođendana")
```



Uočimo da funkcijom `sample` možemo generirati jedan uzorak raspodjele rođendana za 23 ljudi na sljedeći način. Dodali smo i tablični prikaz radi preglednosti (da se lakše uoče ponavljanja rođendana).

```
> options(width=75)
> set.seed(42)
> rodj <- sample(1:365,23,replace=TRUE)
> rodj

 [1]  49 321 153  74 228 146 122  49 128 303  24 327 356  89 165 110  20
[18] 297  89 283 109   5 212

> table(rodj)

rodj
  5  20  24  49  74  89 109 110 122 128 146 153 165 212 228 283 297 303
  1   1   1   2   1   2   1   1   1   1   1   1   1   1   1   1   1   1
321 327 356
  1   1   1
```

Ukoliko velik broj puta generirarmo takav uzorak, prebrojimo broj slučajeva u kojima je barem dvoje ljudi imalo rođendan na isti dan i podijelimo to s brojem ponavljanja, dobit ćemo aproksimaciju vjerojatnosti da će barem dvoje od 23 ljudi imati rođendan na isti dan. Postupak u kojem generiramo velik broj slučajnih uzoraka i onda obavimo neke račune zovemo **simulacijom**. Usporedimo rezultate simulacije koju smo proveli s vrijednosti `pbirthday(23)`.

```
> sim <- replicate(10^5, max(table(sample(1:365,23,replace=TRUE))))
> length(sim[sim>=2])/10^5

[1] 0.50754

> pbirthday(23)

[1] 0.5072972
```

3.6 Sažetak poglavlja

Neka su S, T i V skupovi.
Ako je s element skupa S pišemo $s \in S$.
Ako s nije element skupa S pišemo $s \notin S$.

Skupovi S i T su **jednaki** ako sadrže iste elemente. To znači da je svaki element skupa S ujedno i element skupa T i obratno, svaki element skupa T je i element skupa S.

S je **podskup** od T ako je svaki element od S ujedno i element od T. Pišemo $S \subset T$. Relaciju "biti podskup" zovemo i **skupovnom inkluzijom**.
$S = T$ akko je $S \subset T$ i $T \subset S$.
Skupovna inkluzija je **tranzitivna**: Ako je $S \subset T$ i $T \subset V$, onda je $S \subset V$. Vrijedi skupovna inkluzija

$$\mathbb{N} \subset \mathbb{Z} \subset \mathbb{Q} \subset \mathbb{R}.$$

Sami skupovi mogu biti elementi drugog skupa. Tako je, na primjer, $A = \{\{a\}, \{a, b\}\}$ dvočlani skup čiji su elementi skupovi $\{a\}$ i $\{a, b\}$.
Prazan skup $\emptyset$ ne sadrži niti jedan element i $\emptyset \subset S$ za proizvoljan skup S.

Unija skupova S i T je skup koji sadrži elemente skupa S ili skupa T.
Neka je $S_1, S_2, S_3, \ldots$ niz od beskonačno mnogo skupova. Unija tih skupova je skup S koji sadrži sve elemente koji su u bilo kojem od skupova $S_1, S_2, S_3, \ldots$. Oznaka

$$S = \bigcup_{i=1}^{\infty} S_i = \bigcup_{i \in \mathbb{N}} S_i.$$

Presjek skupova S i T je skup koji sadrži elemente koji su u skupu S i u skupu T.
Skupovi S i T su **disjunktni** ako im je presjek prazan skup: $S \cap T = \emptyset$.
Neka je $S_1, S_2, S_3, \ldots$ niz od beskonačno mnogo skupova. Presje tih skupova je skup S koji sadrži sve elemente koji su u svim skupovima $S_1, S_2, S_3, \ldots$. Oznaka

$$S = \bigcap_{i=1}^{\infty} S_i = \bigcap_{i \in \mathbb{N}} S_i.$$

Svojstva unije i presjeka

1. $S \cup S = S$, $S \cap S = S$ (idempotentnost)
2. $S \cup T = T \cup S$, $S \cap T = T \cap S$ (komutativnost)

3. $(S \cup T) \cup V = S \cup (T \cup V)$, $(S \cap T) \cap V = S \cap (T \cap V)$ (asocijativnost)
4. $S \cup \emptyset = S$, $S \cap \emptyset = \emptyset$
5. $S \cup T = T$ ako i samo ako je $S \subset T$
6. $S \cap T = T$ ako i samo ako je $T \subset S$
7. $S \cup (T \cap V) = (S \cup T) \cap (S \cup V)$ (distributivnost unije prema presjeku)
8. $S \cap (T \cup V) = (S \cap T) \cup (S \cap V)$ (distributivnost presjeka prema uniji)
9. $(S \cap T) \cup T = T$, $(S \cup T) \cap T = T$.

Neka su A i S proizvoljni neprazni skupovi, s time da je $A \subset S$. **Komplement skupa** A (u odnosu na S) je skup koji sadrži točno one elemente skupa S koji nisu elementi skupa A. Oznaka za komplement skupa A je A^c.
Za komplement skupova vrijede **De Morganova pravila**: ako su $A, B \subset S$, onda je

$$(A \cup B)^c = A^c \cap B^c \quad \text{i} \quad (A \cap B)^c = A^c \cup B^c.$$

Neka su S i T proizvoljni neprazni skupovi. **Razlika skupova** S i T je skup koji sadrži točno one elemente skupa S koji nisu elementi skupa T (dakle, jesu u S, ali nisu u T). Oznaka: $S \setminus T$.
Neka svojstva razlike skupova:

1. $S \setminus \emptyset = S$
2. $(S \setminus T) \cup (S \cap T) = S$
3. $(S \cup T) \setminus T = S \setminus T$
4. $(S \setminus T) \cup (S \cap T) \cup (T \setminus S) = S \cup T$
5. $(S \setminus T) \setminus V = S \setminus (T \cup V)$
6. $S \setminus (T \setminus V) = (S \setminus T) \cup (S \cap V)$

Broj elemenata skupa S nazivamo **kardinalnim brojem** skupa S. Oznaka $|S|$.

Skup svih podskupova skupa S nazivamo **partitivnim skupom** od S. Oznaka $\mathcal{P}(S)$. Ako je $|S| = n$, onda je $|\mathcal{P}(S)| = 2^n$.

Dva skupa imaju isti kardinalni broj ako među njima postoji bijekcija. $\mathbb{N}$ i $\mathbb{R}$ imaju različite kardinalne brojeve.
Za sve skupove, uključujući i beskonačne, je $|S| < |\mathcal{P}(S)|$ (Cantorov teorem)

Skupovi bijektivni s $\mathbb{N}$ (poput $\mathbb{Z}$, $\mathbb{Q}$ ili $\mathbb{N}^n$, $n \in \mathbb{N}$) se zovu **prebrojivi**.

Skupovi koji nisu prebrojivi se zovu **neprebrojivi**. Primjer je $\mathbb{R}$ ali i skupovi bijektivni s njim poput $(a, b) \subset \mathbb{R}$, $a, b \in \mathbb{R}$ ili $\mathbb{R}^n$, $n \in \mathbb{N}$.

Kartezijev produkt skupova S i T je skup koji označavamo s $S \times T$ i definiramo kao

$$S \times T = \{(s, t) \mid s \in S, t \in T\}.$$

Broj elemenata Kartezijevog produkta skupova lagano računamo: $|S \times T| = |S| \cdot |T|$.

* * * * *

Skup svih mogućih ishoda slučajnog eksperimenta naziva se **prostor elementarnih događaja** i označava se s Ω. Njegovi elementi se nazivaju **elementarni događaji**.

Podskupove prostora elementarnih događaja Ω zovemo **slučajnim događajima**.

Naivna definicija vjerojatnosti: **vjerojatnost** slučajnog događaja $E \subset \Omega$, gdje je Ω konačan skup, definira se kao

$$P(E) = \frac{|E|}{|\Omega|} = \frac{\text{broj ishoda slučajnog eksperimenta u kojima se dogodio } E}{\text{ukupan broj mogućih ishoda slučajnog eksperimenta}}.$$

Prethodna formula je primjenjiva samo ako su vjerojatnosti svih elementarnih događaja jednake.

Ako je E događaj, onda $E^c = \Omega \setminus E$ zovemo suprotnim događajem. $P(E^c) = 1 - P(E)$.

Ako su A i B disjunktni događaji, onda je $P(A \cup B) = P(A) + P(B)$.

* * * * *

Pravilo zbroja Neka su $S_1, S_2, \ldots, S_n$ međusobno disjunktni skupovi što znači da je $S_i \cap S_j = \emptyset$, $i \neq j$, $i, j \in \{1, 2, \ldots, n\}$. Tada je

$$|S_1 \cup S_2 \cup \ldots \cup S_n| = |S_1| + |S_2| + \ldots + |S_n|.$$

Pravilo umnoška Za konačne $S_1, S_2, \ldots, S_n$ vrijedi

$$|S_1 \times S_2 \times \ldots \times S_n| = |S_1| \cdot |S_2| \cdot \ldots \cdot |S_n|.$$

Broj **odabira** k **objekata** (od n njih) **s ponavljanjem** pri čemu je **važan** poredak odabira (varijacije s ponavljanjem) jednak je

$$\underbrace{n \cdot n \cdot \ldots \cdot n}_{k \text{ puta}} = n^k.$$

Broj **odabira** k **različitih objekata** (od n njih) **bez ponavljanja** pri čemu je **važan** poredak odabira (varijacije bez ponavljanja; permutacije za $k = n$) jednak je

$$n \cdot (n-1) \cdot \ldots (n-k+1) = (n)_k.$$

Broj **odabira** k **različitih objekata** (od n njih) **bez ponavljanja** pri čemu poredak odabira **nije važan** (kombinacije k-tog razreda bez ponavljanja) jednak je

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}.$$

Broj **odabira** k **objekata** (od n njih) **s ponavljanjem** pri čemu poredak odabira **nije važan** (kombinacije k-tog razreda s ponavljanjem) jednak je

$$\left(\!\binom{n}{k}\!\right) = \binom{n+k-1}{k}.$$

Interpretacija s kuglicama i kutijama

Broj razmještaja k različitih kuglica u n različitih kutija jednak je

$$n^k.$$

Broj razmještaja k jednakih kuglica u n različitih kutija jednak je

$$\binom{n+k-1}{k}.$$

Binomni koeficijenti

Binomna formula

$$(x+y)^n = x^n + \binom{n}{1}x^{n-1}y + \binom{n}{2}x^{n-2}y^2 + \ldots + \binom{n}{n-1}xy^{n-1} + y^n$$
$$= \sum_{k=0}^{n}\binom{n}{k}x^{n-k}y^k.$$

Pascalova formula, $1 \leq k \leq n-1$

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}.$$

Simetrija za binomne koeficijente

$$\binom{n}{k} = \binom{n}{n-k}.$$

Neke zanimljive formule

$$\binom{n}{0} + \binom{n}{1} + \binom{n}{2} + \cdots + \binom{n}{n-1} + \binom{n}{n} = 2^n$$

$$\binom{n}{k} = \frac{n}{k}\binom{n-1}{k-1},\ k \neq 0,$$

$$\binom{n}{m}\binom{m}{k} = \binom{n}{k}\binom{n-k}{m-k},$$

$$\sum_{k\leq n}\binom{r+k}{k} = \binom{r+n+1}{n}.$$

Niz brojeva

$$\binom{n}{0},\ \binom{n}{1},\ldots,\binom{n}{k},\ldots,\binom{n}{n-1},\ \binom{n}{n}$$

raste do člana za koji je $k = \lfloor n/2 \rfloor$, a nakon toga pada.

* * * * *

Binomni koeficijent u R-u: `choose(n,k)`
Generiranje uzorka u R-u: funkcija `sample(n,k)`
Generiranje uzorka s ponavljanjem u R-u: `sample(n,k, replace=TRUE)`
Generiranje većeg broja uzoraka u R-u; simulacije: funkcija `replicate`

3.7 Zadaci

Zadatak 3.7.1. *Zadani su sljedeći skupovi*

- $S = \{6,5,3,2,4\}$,
- $T = \{3,4,5\}$,
- $U = \{4,5,6,7\}$,
- $V = \{\{3\},\{3,4\},\{3,4,5\},\{3,4,5,6\},\{2,3,4,5,6\}\}$

Da li je $T \subset S$? Da li je $U \subset S$? Da li je $T \in V$? Da li je $T \subset V$?

Zadatak 3.7.2. *Neka su zadani isti skupovi kao u Zadatku 3.7.1. Da li je $T \in \mathcal{P}(S)$? Da li je $T \subset \mathcal{P}(S)$? Da li je $V \in P(S)$? Koliko je $|\mathcal{P}(S)|$? Koliko je $|V|$?*

Zadatak 3.7.3. *Pokažite da je funkcija $f : (1, +\infty) \to (1, 2)$ zadana s*

$$f(x) = 1 + \frac{1}{x},\ x \in (1, +\infty),$$

bijekcija.

Zadatak 3.7.4. *Neka su $A = \{0, 1\}$, $B = \{1, 2\}$ i $C = \{0, 1, 2\}$ skupovi. Odredite sve elemente njihovog Kartezijevog produkta. Koliko on ima elemenata?*

Zadatak 3.7.5. *Koliko će pribrojnika biti u izrazu $(x_1 + 1)(x_2 + 1) \dots (x_n + 1)$, $n \in \mathbb{N}$, nakon svih provedenih množenja? Pretpostavite da su svi x_i, $i = 1, 2, \dots, n$, različiti od nule.*

Zadatak 3.7.6. *Dodete u restoran s namjerom da pojedete predjelo, glavno jelo i desert. Pretpostavimo da je na meniju 8 predjela, 10 glavnih jela i 4 deserta. Koliko različitih slijedova (tri jela koja uključuju predjelo, glavno jelo i desert) možete ukupno odabrati?*

Zadatak 3.7.7. *Pretpostavimo da se od Pule do Pazina može doći prolazeći preko 3 različite ceste, od Pazina do Rijeke preko 2, od Rijeke do Karlovca preko 3 te od Karlovca do Zagreba preko 4 različite ceste. Na koliko se različitih načina (prolaskom barem jedne dionice puta različitom cestom) može doći od Pule do Zagreba?*

Zadatak 3.7.8. *Pred blagajnom kina stoji sedam osoba među kojima je i mali Ivica. Svih sedam osoba nakon nekog vremena stane u red na slučajan način. Koja je vjerojatnost da će mali Ivica biti prvi u redu?*

Zadatak 3.7.9. *Bacamo dvije kockice. Na koliko načina mogu pasti kockice tako da je umnožak brojeva koji su pali manji ili jednak od 4 ili veći ili jednak od 25?*

Zadatak 3.7.10. *Neka se u ravnini nalazi 10 točaka koje se nalaze u općem položaju, odnosno nikoje tri ne leže na istom pravcu. Koliko različitih dužina možemo napraviti od tih 10 točaka? Koliko različitih trokuta možemo napraviti od tih 10 točaka?*

Zadatak 3.7.11. *Košarkaška ekipa ima 12 igrača, a na terenu se nalazi 5 njih. Na koliko različitih načina trener može odabrati početnu petorku (petoricu igrača koji će započeti susret)? Pretpostavimo dodatno da trener preferira formaciju s jednim centrom, dva krila, bekom i organizatorom igre (playmakerom) te pretpostavimo da se u ekipi nalaze 3 centra, 2 organizatora igre, 2 beka i 5 krila. Na koliko načina trener može odabrati petorku poštujući svoj sustav igre?*

Zadatak 3.7.12. *Na nekom pismenom ispitu je zadano 10 zadataka, a u svakome je ponuđeno 4 odgovora od kojih je samo jedan točan. Na koliko načina se može riješiti točno 80% ispita, odnosno točno odgovoriti na 8 pitanja?*

Zadatak 3.7.13. *Na koliko različitih načina 10 ljudi može sjesti za okrugli stol? Dva rasporeda smatramo jednakim ukoliko se rotacijom ljudi može doći od jednoga do drugoga. (Uputa: nađite vezu s rasporedom ljudi u red.)*

Zadatak 3.7.14. *Koliko različitih riječi duljine 9 znakova možemo napraviti korištenjem slova koja čine riječ SLOVENIJA? Koliko različitih riječi duljine 10 znakova možemo napraviti korištenjem slova koja čine riječ MATEMATIKA?*

* * * * *

Zadatak 3.7.15. *Uzmimo znamenke* $0, 1, \ldots, 9$ *i formirajmo lozinku duljine 5 (od 5 znamenki) na slučajan način, odnosno slučajnim odabirom znamenki* $0, 1, \ldots, 9$ *pri čemu se znamenke mogu ponavljati. Koja je vjerojatnost da će lozinka sadržavati sve različite znamenke? Dodatno, koja je vjerojatnost da će lozinka sadržavati barem dvije jednake znamenke?*

Zadatak 3.7.16. *Izlazite na ispit pod uvjetima kao u zadatku 3.7.12. Koja je vjerojatnost da ćete proći ispit nasumice (na slučajan način) zaokružujući odgovore? Za prolazak ispita je potrebno točno odgovoriti na barem 5 pitanja.*

Zadatak 3.7.17. *[Zadatak 1.6 u [5]] U kutiji se nalazi deset kuglica, šest plavih i četiri crvene. Na slučajan način ("na sreću") biramo tri kuglice (bez vraćanja kuglica u kutiju). Izračunajte vjerojatnost sljedećih događaja*

$$A = \{ \textit{ sve tri izvučene kuglice su plave } \},$$

$$B = \{ \textit{ sve tri izvučene kuglice su iste boje } \},$$

$$C = \{ \textit{ dvije izvučene kuglice su plave, a jedna crvena } \}.$$

Zadatak 3.7.18. *Pretpostavimo da se u sobi nalazi n osoba. U Primjeru 3.4.5 smo izračunali vjerojatnost da dvije ili više osoba, od tih n osoba, imaju rođendan na isti dan u godini. Koja je vjerojatnost da točno dvije osobe imaju rođendan na isti dan u godini.?*

3.7.1 Rješenja zadataka

Rješenje 13 (Zadatak 3.7.1)**.** Znamo da je $T \subset S$ ako je svaki element od T ujedno i element od S. To je istina jer je $3 \in T$ i $3 \in S$, zatim $4 \in T$ i $4 \in S$ i napokon $5 \in T$ i $5 \in S$. To su svi elementi od T pa je $T \subset S$.
U nije podskup od S jer $7 \in U$, ali $7 \notin S$.
Da bi T bio element skupa V moramo ga naći na popisu elemenata od V. No to je istina jer je treći element skupa V upravo $T = \{3, 4, 5\}$. Dakle, $T \in V$.
Tje podskup od V ako je svaki element skupa T ujedno i element skupa V. Uzmimo $3 \in T$ i pogledajmo elemente skupa V. Vidimo da 3 ne nalazimo na popisu elemenata skupa V (sjetite se $3 \neq \{3\}$). To je dovoljno da zaključimo da skup T nije podskup skupa V.

Rješenje 14 (Zadatak 3.7.2)**.** $\mathcal{P}(S)$ sadrži sve podskupove skupa S. U prethodnom zadatku smo vidjeli da je $T \subset S$ pa zaključujemo da je $T \in \mathcal{P}(S)$. To ujedno znači da T nije podskup od $\mathcal{P}(S)$ jer su elementi od $\mathcal{P}(S)$ skupovi, a elementi od T brojevi.
Svaki element skupa V je ujedno i element skupa $\mathcal{P}(S)$ (u V su svi elementi podskupovi skupa S). Stoga je $V \subset \mathcal{P}(S)$, ali sam V ne nalazimo na popisu **elemenata** od $\mathcal{P}(S)$ pa $V \notin \mathcal{P}(S)$.
Kako je $|S| = 5$ znamo da je $|\mathcal{P}(S)| = 2^5 = 32$. Skup V ima pet elemenata (unutar vitičastih zagrada odvojenih zarezima) pa je $|V| = 5$.

Rješenje 15 (Zadatak 3.7.3)**.** Prema definiciji bijektivnosti trebamo pokazati da je funkcija f injekcija i surjekcija. Pokažimo najprije injektivnost. Funkcija je injekcija ako "razlikuje točke", odnosno ako su različitim elementima domene pridruženi različiti elementi kodomene. To svojstvo možemo sažeti u zahtjev: ako su x i y elementi domene, onda iz $x \neq y$ slijedi $f(x) \neq f(y)$. Po kontrapoziciji je ta implikacija ekvivalentna zahtjevu: ako je $f(x) = f(y)$, onda je $x = y$, za x i y elemente domene.
Pretpostavimo, dakle, da je $f(x) = f(y)$, odnosno

$$1 + \frac{1}{x} = 1 + \frac{1}{y}$$

pa je

$$\frac{1}{x} = \frac{1}{y}.$$

Kako su x i y su različiti od nule pomnožimo zadnju jednakost s $x \cdot y$ da dobijemo $x = y$, što smo i htjeli. Dakle, funkcija f je injekcija.
Pokažimo da je funkcija f surjekcija. To znači da se za svaki element kodomene y može naći element domene x takav da je $f(x) = y$. Uzmimo proizvoljni element y iz kodomene $(1, 2)$. Tada tržimo element x iz domene takav da je $f(x) = y$, odnosno

$$y = 1 + \frac{1}{x}.$$

Laganim računom dobivamo da je onda

$$x = \frac{1}{y-1}.$$

Uočimo da je $y > 1$ pa je $y - 1 > 0$, odnosno $y - 1 \neq 0$. Tvrdimo da je prije navedeni element x upravo taj elelemt koji f preslikava u y. Zaista,

$$f(x) = f\Big(\frac{1}{y-1}\Big) = 1 + \frac{1}{\frac{1}{y-1}} = 1 + y - 1 = y.$$

Zaključujemo da je funkcija f surjekcija. Uočimo da smo surjektivnost mogli pokazati i na dugačiji način - korištenjem znanja iz Matematičke analize (analize funkcija). Naime, zadana funkcija f je neprekidna funkcija ($1/x$ je neprekidna), padajuća je, kada x teži 1, vrijednost funkcije teži prema 2, a kada x teži prema $+\infty$, vrijednost funkcije teži prema 1. Zbog neprekidnosti, funkcija f mora poprimiti sve vrijednosti između 1 i 2 pa je zapravo surjektivna.

Rješenje 16 (Zadatak 3.7.4)**.** Kartezijev produkt $A \times B \times C$ se sastoji od uređenih trojki (a, b, c), gdje je $a \in A$, $b \in B$ i $c \in C$. I prije nego što navedemo članove Kartezijevog produkta $A \times B \times C$ možemo uočiti da je broj elemenata tog skupa jednak $|A| \cdot |B| \cdot |C| = 2 \cdot 2 \cdot 3 = 12$. Kako je riječ o malim skupovima možemo lagano navesti sve elemente Kartezijevog produkta A, B i C:
$A \times B \times C = \{(0,1,0), (0,1,1), (0,1,2), (0,2,0), (0,2,1), (0,2,2), (1,1,0), (1,1,1),$
$(1,1,2), (1,2,0), (1,2,1), (1,2,2)\}$.

Rješenje 17 (Zadatak 3.7.5)**.** Nakon što provedemo množenja svih binoma oblika $(x_i + 1)$, $i = 1, 2, \ldots, n$, dobit ćemo umnoške oblika $x^{i_1}x^{i_2}\ldots x^{i_n}$, pri čemu je $i_j \in \{0, 1\}$, $j = 1, 2, \ldots, n$ (ako su svi $i_j = 0$ dobijemo pribrojnik 1). Tih umnožaka ima kao i elemenata Kartezijevog produkta $\{0, 1\}^n$, a njih pak ima 2^n. Dakle, ukupno će biti 2^n pribrojnika nakon provođenja svih množenja.

Rješenje 18 (Zadatak 3.7.6)**.** Na prvom mjestu odabira (predjelo) može biti jedno od 8 jela. Za svaki odabir prvog jela možemo odabrati na drugom mjestu (kao glavno jelo) 10 jela, a za svaki odabir prva dva jela možemo odabrati jedan od deserta na 4 načina. Prema pravilu umnoška, ukupno možemo odabrati $8 \cdot 10 \cdot 4 = 320$ slijedova.

Rješenje 19 (Zadatak 3.7.7)**.** Prema uvjetima zadatka put od Pule do Zagreba možemo podijeliti na 4 dionice. To odgovara formiranju Kartezijevog produkta 4 skupa pri čemu prvi skup ima 3 elementa, drugi ima 2 elementa, treći ima 3 elementa i konačno četvrti skup ima 4 elementa. Prema pravilu umnoška je ukupan broj različitih načina na koji možemo doći od Pule do Zagreba jednak $3 \cdot 2 \cdot 3 \cdot 4 = 72$.

Rješenje 20 (Zadatak 3.7.8). Ukupan broj načina na koji je sedmero ljudi može poredati u red je jednak 7! (ljude međusobno razlikujemo, u redu se pojavljuje jedna osoba samo jednom - nema ponavljanja). Broj načina na koje se može stati u red, a da Ivica bude prvi je jednak 6! (Ivica je na prvom mjestu, a preostale osobe se na 6 mjesta može razmijestiti na 6! načina). Ukoliko s A označimo događaj "Ivica je prvi u redu" prema naivnoj definiciji vjerojatnosti dobivamo

$$P(A) = \frac{6!}{7!} = \frac{1}{7}.$$

Rješenje 21 (Zadatak 3.7.9). Pogledajmo skupove A_1 = "umnožak brojeva koji su pali na kockicama je manji ili jednak od 4" te A_2 = "umnožak brojeva koji su pali na kockicama je veći ili jednak od 25". Ako malo razmislimo vidimo da je $A_1 = \{(1,1),(1,2),(2,1),(1,3),(3,1),(2,2),(1,4),(4,1)\}$ te $A_2 = \{(5,5),(5,6),(6,5),(6,6)\}$. Kako su A_1 i A_2 disjunktni skupovi prema principu zbroja zaključujemo da je $|A_1 \cup A_2| = |A_1| + |A_2| = 8 + 4 = 12$, što je ujedno i rješenje zadatka.

Rješenje 22 (Zadatak 3.7.10). Iako je problem postavljen kao geometrijski vrlo se lako prevodi u kombinatorni. Naime, kako nikoje tri točke ne leže na istom pravcu svake dvije od 10 zadanih točaka određuju jedinstven pravac, a onda i dužinu koja ih spaja. Stoga je broj dužina jednak mogućim odabirima 2 točke od 10 njih, pri čemu je poredak točaka nevažan (ako nisu vektori dužina $\bar{AB}$ je jednaka dužini $\bar{BA}$, gdje su A i B neke točke). Stoga možemo napraviti (konstruirati) $\binom{10}{2}$ različitih dužina. Slično, svake tri točke jednoznačno određuju trokut (vrhove trokuta) pa različitih trokuta ima $\binom{10}{3}$.

Rješenje 23 (Zadatak 3.7.11). Ukoliko samo trebamo odabrati 5 igrača od 12 njih to možemo napraviti na $\binom{12}{5} = 792$ načina. Riječ je o odabiru bez ponavljanja pri čemu poredak nije važan i takve probleme uvijek rješavamo na sličan način.
Ukoliko trebamo paziti na zadnu formaciju, onda uočimo da jednog centra (od tri njih) možemo odabrati na $\binom{3}{1}$ načina. Za svaki takav odabir jednog organizatora igre (od dva koji su raspolaganju) možemo odabrati na $\binom{2}{1}$ načina, kao i jednog beka. Za sve takve odabire dva krila (od pet njih) možemo odabrati na $\binom{5}{2}$ načina. Prema principu produkta je ukupan broj petorki koji tako možemo sastaviti jednak

$$3 \cdot 2 \cdot 2 \cdot \binom{5}{2} = 120.$$

Jasno, što je više ograničenja na odabir, to je manji broj mogućnosti.

Rješenje 24 (Zadatak 3.7.12). Najprije uočimo da se može odgovoriti točno na 8 pitanja na $\binom{10}{8}$ načina (pitanja su različita, odaberemo 8 pitanja na koje je točno odgovoreno - nema ponavljanja). Da bi točno odgovorili na 8 pitanja na preostala 2 moramo odgovoriti pogrešno, odnosno u oba pitanja moramo odabrati jedan od 3 moguća netočna odgovora. To možemo napraviti na 3^2 načina. Dakle, za svaki odabir 8 točnih pitanja imamo 3^2 načina da odgovorimo netočno na preostala 2 pitanja. Prema principu produkta je traženi broj načina jednak $\binom{10}{8} \cdot 3^2 = 405$.

Rješenje 25 (Zadatak 3.7.13). Označimo ljude s brojevima $1, 2, \ldots, 10$. Uzmimo jedan proizvoljan raspored sjedenja ljudi za stolom (gledamo samo različite rasporede, u skladu s uvjetima zadatka). Naći ćemo bijekciju između rasporeda sjedenja ljudi za stolom i razmještaja ljudi u red pa ćemo pravilom jednakosti (bijekcije) dobiti broj razmještaja. U tu svrhu pogledajmo tko sjedi jedno mjesto udesno od osobe kojoj smo pridjelili broj 1 i stavimo je na prvo mjesto u redu. Zatim pogledajmo drugo mjesto udesno od osobe broj 1 i stavimo je na drugo mjesto u redu i tako sve do devetog mjesta gledano u desnu

stranu od osobe kojoj smo pridjelili broj 1 i tu osobu stavimo na deveto mjesto u redu. Obratno, ako uzmemo red od 9 ljudi (označenih brojevima $2, 3, \ldots, 10$ da ostanemo u kontekstu prvog dijela rješenja), onda posjednemo osobu kojoj smo pridjelili broj 1 na bilo koje mjesto za stolom te "namotamo" osobe iz reda od 9 ljudi udesno od te osobe. Preciznije, prvu osobu u redu posjednemo na prvo mjesto desno od osobe s brojem 1, drugu osobu u redu posjednemo na drugo mjesto zdesna od osobe s brojem 1 i tako dalje do devete osobe iz reda koju posjednemo na deveto mjesto zedesna od osobe s brojem jedan. Na taj način dobivamo bijekciju između rasporeda sjedenja 10 ljudi za stolom i rasporeda 9 ljudi u red. Kako znamo da je broj načina na koji se 9 ljudi može rasporediti u red jednak 9! (pogledajte Primjer 3.3.10) zaključujemo (pravilom jednakost) da je broj načina na koji 10 ljudi može sjesti za stol jednak 9!, pri čemu su dva rasporeda sjedenja jednaka ako se rotacijom može doći od jednoga do drugoga.
Naravno, na isti način zaključujemo da n ljudi, $n \in \mathbb{N}$, može biti razmješteno za stol na $(n-1)!$ različitih načina.

Rješenje 26 (Zadatak 3.7.14)**.** Sva slova riječi SLOVENIJA su različita pa se problem svede na određivanje broja različitih riječi koje se mogu napraviti od 9 (različitih) slova, a njih ima kao i različitih poredaka 9 različitih objekata na 9 mjesta pri čemu je poredak važan (i nema ponavljanja). Dakle, takvih riječi ima 9!. U princilu je dovoljno dati rješenje u ovoj formi, ali u R-u možemo lagano izračunati da je 9! jednako

```
> factorial(9)

[1] 362880
```

Riječ MATEMATIKA ima 10 slova, ali nisu sva različita: slovo A se pojavljuje 3 puta, slovo M dva puta, kao i slovo T. Soga ne možemo jednostavno zaključiti da je broj različitih rasporeda tih 10 slova jdnak 10!, već treba obaviti korekciju za ista slova. Takvu situaciju smo opisali permutacijama s ponavljanjem, odnosno formulom (3.10). Prema toj formuli je broj različitih riječi koje možemo napraviti korištenjem slova koja čine riječ MATEMATIKA je jednak

$$\frac{10!}{3!2!2!}.$$

U gornjoj formuli smo izostavili 3 ponavljanja 1! jer je $1! = 1$. Opet, možemo i izračunati taj broj korištenjem R-a

```
> factorial(10)/(factorial(3)*factorial(2)*factorial(2))

[1] 151200
```

Ako želite steći malo intuicije prilikom računanja permutacija s ponavljanjem probajte primijeniti formulu (3.10) na riječi DUD ili MAMA da vidite koliko se različitih riječi može sastaviti od pripadnih slova, ali i napisati sve te različite riječi.

Rješenje 27 (Zadatak 3.7.15)**.** Da bi izračunali traženu vjerojatnost najprije trebamo izračunati mogući broj ishoda slučajnog eksperimenta. Odabir 10 znamenki na 5 mjesta (lozinke se razlikuju ako je poredak drugačiji) možemo napraviti na 10^5 načina. To odgovara odabiru 5 različiitih predmeta s ponavljanjem pri čemu je važan poredak. S druge strane, ako je E događaj "lozinka sadrži sve različite znakove", onda se taj događaj pojavljuje onoliko puta koliko ima odabira 5 različitih predmeta od 10 njih bez ponavljanja, pri čemu je važan poredak elemenata. Dakle, ima ih $(10)_5 = 10 \cdot 9 \cdot 8 \cdot 7 \cdot 6$. Stoga je tražena vjerojatnost događaja E jednaka

$$P(E) = (10)_5/10^5 = 0,3024.$$

Drugu traženu vjerojatnost bi mogli izračunati tako da prebrojimo broj lozinki s 2 iste znamenke, s 3 iste, s 4 iste ili 5 istih znameni, ali je jednostavnije uočiti da je taj događaj (odabir lozinki koje sadržavaju barem dvije jednake znamenke) zapravo komplement od E. Stoga je njegova vjerojatnost jednaka $1 - P(E) = 0,6976$.

Rješenje 28 (Zadatak 3.7.16)**.** Označimo događaj "prolazak ispita" s A. Taj će se događaj dogoditi ako točno odgovorimo na 5 pitanja, na 6 pitanja, na 7 pitanja, na 8 pitanja , na 9 pitanja ili na 10 pitanja. Ako definiramo događaje A_i = "odgovoreno je točno na i pitanja", $i = 5, 6, 7, 8, 9, 10$, onda se događaj A može prikazati kao disjunktna unija

$$A = A_5 \cup A_6 \cup A_7 \cup A_8 \cup A_9 \cup A_{10}.$$

Zbroj pravila zbroja zaključujemo da je

$$|A| = |A_5| + |A_6| + |A_7| + |A_8| + |A_9| + |A_{10}|.$$

Već smo vidjeli u rješenju zadatka 3.7.12 da je

$$|A_8| = \binom{10}{8} 3^2.$$

Istim načinom zaključivanja vidimo da je

$$|A_i| = \binom{10}{i} 3^{10-i}, \ i = 5, 6, 7, 8, 9, 10.$$

Dakle,

$$|A| = \binom{10}{5} 3^5 + \binom{10}{6} 3^4 + \binom{10}{7} 3^3 + \binom{10}{8} 3^2 + \binom{10}{9} 3^1 + \binom{10}{10} 3^0.$$

Iskoristimo R da izračunamo

```
> choose(10,5)*3^5 + choose(10,6)*3^4+choose(10,7)*3^3

[1] 81486

> choose(10,8)*3^2+choose(10,9)*3^1+choose(10,10)*3^0

[1] 436
```

pa je

$$|A| = 81.922.$$

Kod nasumičnog odabira odgovora (slučajnog odabira) je vjerojatnost odabira bilo koje kombinacije odgovora jednako vjerojatna pa je primjenjiva naivna definicija vjerojatnosti. Da bi izračunali vjerojatnost događaja A trebamo izračunati ukupan broj načina na koji možemo odgovoriti na 10 pitanja. Kako je važan poredak pitanja, a odgovori se mogu ponavljati imamo ukupno 4^{10} mogućnosti za slučajan odabir 10 odgovora na pitanja. Stoga je vjerojatnost traženog događaja A jednaka

$$P(A) = \frac{81922}{4^{10}} = 0.07812691.$$

Rješenje 29 (Zadatak 3.7.17)**.** Kod ovakvih zadataka se može javiti dvojba da li kuglice koje su iste boje treba razlikovati ili ne. Uočimo da su one fizički različite iako su iste boje. Takvu smo situaciju već komentirali u primjerima 3.2.14 i 3.4.7. S druge strane, možemo zamisliti da su sve kuglice u kutiji označene brojevima od 1 do 10 pa ih možemo razlikovati. U svakom slučaju, uz upravo komentiranu pretpostavku tri kuglice od 10 njih možemo odabrati na $\binom{10}{3} = 120$ načina. Svi su ti načini jednako vjerojatni pa možemo koristiti formulu naivne vjerojatnosti, pri čemu prostor elementarnih događaja ima 120 elemenata.
Da bi odredili vjerojatnost skupa A trebamo odrediti broj njegovih elemenata ("povoljni ishodi izvlačenja kuglica za događaj A"), odnosno broj načina da su izvučene 3 plave kuglice. No, taj je broj jednak $\binom{6}{3}$ pa je

$$P(A) = \frac{\binom{6}{3}}{\binom{10}{3}} = \frac{20}{120} = \frac{1}{6}.$$

Događaj B možemo prikazati kao uniju disjunktnih događaja B_1 = "izvučene su tri plave kuglice" i B_2 = "izvučene su tri crvene kuglice". Kako je $|B_1| = \binom{6}{3}$, a $|B_2| = \binom{4}{3}$ prema principu zbroja dobivamo

$$P(B) = \frac{\binom{6}{3} + \binom{4}{3}}{\binom{10}{3}} = \frac{24}{120} = \frac{1}{5}.$$

Napokon, dvije plave kuglice možemo odabrati na $\binom{6}{2}$ načina, a za svaki takav odabir jednu crvenu kuglicu možemo odabrati na $\binom{4}{1}$ načina pa je

$$P(C) = \frac{\binom{6}{2} \cdot \binom{4}{1}}{\binom{10}{3}} = \frac{60}{120} = \frac{1}{2}.$$

Rješenje 30 (Zadatak 3.7.18)**.** U osnovi ćemo ovaj zadatak riješiti slično kao problem u Primjeru 3.4.5, s time da sada trebamo prebrojati broj načina da točno dvije osobe imaju rođendan na isti dan, a onda prebrojati broj načina da ostale osobe imaju rođendane na različite dane. Uočimo da je prostor elementarnih događaja isti kao u Primjeru 3.4.5 pa znamo da je broj njegovih elemenata 365^n.
Broj načina na koji dvije osobe mogu imati rođendan na isti dan odgovara broju načina na koji možemo odabrati dvije osobe od n njih, a znamo da to možemo napraviti na $\binom{n}{2}$ načina. Dodatno, za svaki odabir dvije osobe njihov rođendan može biti na jedan od 365 dana. Dakle, broj načina na koji dvije od n osoba može imati rođendan na neki od dana u godini je jednak

$$\binom{n}{2} \cdot 365.$$

Ostale su nam još $n-2$ osobe, a one moraju imati rođendane na različite datume te na različiti datum od dvije odabrane osobe s istim danom rođendana. Po uzoru na račun u Primjeru 3.4.5 borj načina da te osobe nemaju rođendan na isti dan je jednak $(364)_{n-2}$. Dakle, tražena vjerojatnost je jednaka

$$\frac{\binom{n}{2} \cdot 365 \cdot 364 \cdot \ldots \cdot (364 - (n-2) + 1)}{365^n}.$$

Time smo riješili zdatak, ali pogledajmo malo preciznije što se događa za $n = 23$. Uz pomoć R-a vidimo da je tražena vjerojatnost u tom slučaju jednaka

```
> choose(23,2)*365*prod((364-20):364)/365^23
```

```
[1] 0.3634222
```

Kao što smo vidjeli u odjeljku 3.5 funkcija `pbirthday()` izračunava vjerojatnost da će barem 2, 3 ili više osoba u problemu rođendana imati rođendan na isti dan. To znači da oduzimanjem tih vjerojatnosti možemo dobiti vjerojatnost da će dvije osobe imati rođendan na isti dan. Konkretno dobivamo da je ta vjerojatnost jednaka

```
> pbirthday(23, coincide=2)-pbirthday(23, coincide=3)
```

```
[1] 0.4928818
```

Vidimo razliku u odnosu na prije izračunatu vjerojatnost. Stvar je u tome da ova vjerojatnost uključuje i slučajeve da će jedan par osoba imati rođendan na isti dan, da će dva para imati rođendan na isti dan i tako dalje. Ipak, ta razlika može ostaviti sumnju u neke od izračunatih vjerojatnosti pa možemo probati simulacijom potvrditi preije dobiveno rješenje (simulacija ne može biti dokaz, ali može potvrditi naše uvjerenje u ispravnost nekog izračuna). Sljedeći kod daje procjenu vjerojatnosti da će točno dvije osobe (ne i dva para osoba) imati rođendan na isti dan.

```
> set.seed(23)
> sim<-replicate(10^5, prod(table(sample(1:365,23, replace=TRUE))))
> length(sim[sim==2])/10^5
```

```
[1] 0.36447
```

Kratki komentar gornjeg koda: ideja je izbjeći jedan ili više `if`-ova da se ubrza izvršavanje koda jer samo generiranje 10.000 uzoraka (funkcijom `replicate`) 23 rođendana u jednom od 365 dana (funkcijom `sample`) oduzima neko vrijeme (isprobajte). Funkcijom `table` dobivamo učestalost pojavljivaja broja rođendana na svaki od generiranih datuma. To znači da u slučaju u kojem su svi rođendani u različitim danima imamo samo jedinice, u slučaju u kojem su točno dva rođendana na isti datum imamo jednu dvojku i ostale jedinice, u slučaju u kojem imamo dva para rođendana na dva datuma imamo dvije dvojke i ostale jedinice, u slučaju kada su tri rođendana na isti datum, a ostali na različte dobivamo jednu trojku i ostale jedinice i tako dalje. Stoga izračun umnoška vrijednosti formiranih tablica daje vrijednost 2 samo onda kada točno dvoje ljudi ima rođendan na isti datum, a ostali svi imaju rođendane na različite datume (razmislite). Možete za vježbu probati procjeniti vjerojatnost da će dva para osoba imati rođendan na dva datuma (različita jer bi inače imali slučaj da četvero ljudi ima rođendan na isti datum).

Poglavlje 4

Vjerojatnost

Suvremeni počeci teorije vjerojatnosti uglavnom se vežu uz razne probleme vezane uz igre na sreću poput bacanja kockica, kartaških igara i slično. U 17. stoljeću (nove ere) su čuveni francuski matematičari Blaise Pascal i Pierre de Fermat u nizu pisama prvi puta, barem u zabilježenoj formi, proučavali probleme igara na sreću u formi vjerojatnosti. U stoljećima nakon toga je niz velikih matematičara (Jacob Bernoulli, Abraham de Moivre, Pierre-Simon marquis de Laplace i mnogi drugi) unaprijedilo koncepte vezane uz teoriju vjerojatnosti. Svoje aksiomatsko zasnivanje teorija vjerojatnosti duguje ruskom matematičaru Andreju Kolmogorovu koji je 1933. godine iznio svoje ideje u knjizi Grundbegriffe der Wahrscheinlichkeitsrechnung. Mi ćemo ovdje predstaviti dijelove aksiomatske teorije vjerojatnosti koji će nam trebati u nastavku skripte. Više o povijesti teorije vjerojatnosti i statistike može se naći, na primjer, na `www.britannica.com/science/probability/The-probability-of-causes` ili u članku Debnath, Basu: A Short History of Probability Theory and Its Applications (doi: 10.1080/0020739X.2014.936975). Vrlo cjelovit pregled vjerojatnosnih problema kroz povijest može se naći u [7].

4.1 Definicija vjerojatnosti i osnovna svojstva

U prošlom poglavlju smo vidjeli kako na jednostavan i intuitivan način možemo računati ishode nekih slučajnih eksperimenata. Sjetimo se, ishode slučajnih eksperimenata smo objedinili u skup i definirali **prostor elementarnih događaja** Ω (definicija 3.2.1). Elemente prostora elementarnih događaja zovemo **elementarnim događajima**. Podskupove prostora elementarnih događaja nazivamo **događajima** ili **slučajnim događajima** ako želimo istaknuti činjenicu da su nastali kao rezultat provođenja nekog slučajnog eksperimenta. Za događaje (skupove) koji imaju konačan broj elemenata smo definirali vjerojatnost P kao broj elemenata događaja koji promatramo podijeljen s ukupnim brojem elemenata prostora elementarnih događaja (definicija 3.6). Na taj način definiranu vjerojatnost možemo interpretirati i kao omjer povoljnih ishoda slučajnog eksperimenta kojega gledamo (za događaj čiju vjerojatnost želimo izračunati) i ukupnog broja ishoda danog slučajnog eksperimenta.

Definiciju vjerojatnosti iz prošlog poglavlja smo nazvali naivnom, ali ne zato što je ona manje vrijedna, nego zato što nije dovoljno općenita. Naime, ona se ne može primijeniti na beskonačne skupove te je primjenjiva samo ako je vjerojatnost svih elementarnih događaja jednaka (jednako je vjerojatno da se dogodi bilo koji od elementarnih događaja). S druge strane, naivna definicija vjerojatnosti je ispravna i intuitivno jasna za konačna skupove pa ne želimo definirati neku "drugačiju" vjerojatnost, nego proširiti definiciju vjerojatnosti na općenitije slučajeve. Također, želimo zadržati neka dobra svojstva vjerojatnosti definirane na konačnim događajima. Konkretno, "naivna" vjerojatnost je uvijek nenegativna, ali i manja ili jednaka od 1. Naime, događaji su podskupovi od prostora

elementarnih događaja Ω pa je njihov broj elemenata manji ili jednak broju elemenata od Ω, a

$$P(\Omega) = \frac{|\Omega|}{|\Omega|} = 1.$$

Nadalje, vidjeli smo da zbog principa zbroja za disjunktne slučajne događaje A i B vrijedi da je vjerojatnost unije događaja A i B jednaka zbroju njihovih vjerojatnosti, odnosno

$$P(A \cup B) = P(A) + P(B), \quad \text{ako je } A \cap B = \emptyset.$$

Uočite, ovo se svojstvo primjenom matematičke indukcije lagano proširi tako da vrijedi za konačno mnogo skupova. Tako dobijemo: ako su $A_1, A_2, \ldots A_n$ međusobno disjunktni slučajni događaji ($A_i \cap A_j = \emptyset$, za $i \neq j$, $i, j = 1, 2 \ldots, n$), onda vrijedi

$$P(A_1 \cap A_2 \cap \ldots \cap A_n) = P(A_1) + P(A_2) + \ldots + P(A_n). \tag{4.1}$$

Svojstvo navedeno u relaciji (4.1) se naziva svojstvo **konačne aditivnosti vjerojatnosti**. U skladu s oznakama uvedenim u prošlom poglavlju svojstvo konačne aditivnosti skraćeno zapisujemo u formi

$$P\Big(\bigcup_{i=1}^{n} A_i\Big) = \sum_{i=1}^{n} P(A_i).$$

Ako je A slučajni događaj, onda njegov komplement $A^c = \Omega \setminus A$ zovemo **suprotni događaj** događaja A. Za **vjerojatnost suprotnog događaja** imamo izraz

$$P(A^c) = 1 - P(A). \tag{4.2}$$

U istinitost te relacije se lagano uvjerimo primjenom svojstva konačne aditivnosti na skupovnu jednakost $\Omega = A \cup A^c$.

Kao što vidimo "naivna" vjerojatnost ima neka dobra i intuitivna svojstva koja želimo sačuvati proširenjem definicije vjerojatnosti. U razvoju teorije vjerojatnosti se pokazalo da je za poopćenje teorije važno definirati koji sve skupovi mogu biti slučajni događaji. Sukladno tome trebamo preciznije definirati familije skupova slučajnih događaja. Imamo sljedeću definiciju.

Definicija 4.1.1 (σ-algebra skupova)**.** Neka je Ω skup. Familija $\mathcal{F}$ podskupova od Ω je **σ-algebra skupova** na Ω ako zadovoljava sljedeća svojstva

i) $\emptyset \in \mathcal{F}$

ii) Ako je $A \in \mathcal{F}$, onda je i $A^c \in \mathcal{F}$

iii) Ako su $A_i \in \mathcal{F}$, $i \in \mathbb{N}$, onda je $\bigcup_{i \in \mathbb{N}} A_i \in \mathcal{F}$.

Prva dva svojstva u prethodnoj definiciji su jasna: prazni skup je element familije skupova $\mathcal{F}$ te ako je A element familije skupova $\mathcal{F}$, onda je i A^c također element te familije. Uočite, onda je i $\Omega = \emptyset^c \in \mathcal{F}$. Trećim svojstvom zahtjevamo da su prebrojive[1] unije elemenata od $\mathcal{F}$ sadržane u $\mathcal{F}$. Razlog za uvođenje tog svojstva je općenita definicija vjerojatnosti koju dajemo u nastavku. Naime, svojstvo *iii)* iz definicije 4.1.1 osigurava da su prebrojive unije elemenata iz $\mathcal{F}$ opet sadržane u $\mathcal{F}$, a to nam je potrebno kako bi proširili svojstvo konačne aditivnosti na prebrojivu aditivnost. Imamo sljedeću definiciju vjerojatnosti.

[1] Unije koje gledamo su prebrojive jer je indeksni skup po kojem se gleda unija skupova prebrojiv skup $\mathbb{N}$.

Definicija 4.1.2 (Vjerojatnost)**.** Neka je Ω skup i $\mathcal{F}$ σ-algebra na Ω. Funkcija $P : \mathcal{F} \to \mathbb{R}$ je **vjerojatnost** na Ω (ili na $(\Omega, \mathcal{F})$) ako vrijedi

(1) $P(A) \geq 0$ za sve $A \in \mathcal{F}$

(2) $P(\Omega) = 1$

(3) Za $A_i \in \mathcal{F}$, $i \in \mathbb{N}$, međusobno disjunktne ($A_i \cap A_j = \emptyset$ za $i \neq j$) vrijedi

$$P\Big(\bigcup_{i\in\mathbb{N}} A_i\Big) = \sum_{i=1}^{\infty} P(A_i).$$

Elemente skupa Ω nazivamo **elementarnim događajima**, dok elemente σ-algebre $\mathcal{F}$ nazivamo **slučajnim događajima**, odnosno **događajima**.
Uređenu trojku $(\Omega, \mathcal{F}, P)$ nazivamo **vjerojatnosnim prostorom**.

Kao što vidimo, vjerojatnost smo definirali kao funkciju koja podskupovima skupa Ω sadržanima u $\mathcal{F}$ pridružuje brojčanu vrijednost između nula i jedan. Svojstvo (3) nam govori da je vjerojatnost unije događaja koji se međusobno isključuju (disjunktni su međusobno) jednaka zbroju vjerojatnosti tih događaja. To svojstvo se naziva σ-**aditivnost** ili prebrojiva aditivnost vjerojatnosti. U sljedećoj propoziciji navodimo neka osnovna svojstva vjerojatnosti koja se mogu izvesti iz osnovnih pretpostavki[2] (1)-(3) navedenih u Definiciji 4.1.2.

Propozicija 4.1.3 (Svojstva vjerojatnosti)**.** *Neka je $(\Omega, \mathcal{F}, P)$ vjerojatnosni prostor. Tada vjerojatnost P ima sljedeća svosjtva:*

(1) $P(\emptyset) = 0$.

(2) Za slučajni događaj A vrijedi $P(A^c) = 1 - P(A)$.

(3) Za A, B slučajne događaje takve da je $B \subset A$ vrijedi

$$P(A \setminus B) = P(A) - P(B),$$

a posljedično i

$$P(B) \leq P(A).$$

To se svojstvo naziva ***monotonost vjerojatnosti****.*

(4) Za $A_1, \dots A_n$, $n \in \mathbb{N}$, slučajne događaje koji su međusobno disjunktni, odnosno $A_i \cap A_j = \emptyset$ za $i \neq j$, vrijedi ***konačna aditivnost***

$$P\Big(\bigcup_{i=1}^{n} A_i\Big) = \sum_{i=1}^{n} P(A_i).$$

(5) Za A, B slučajne događaje vrijedi $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

(6) Za niz slučajnih događaja $A_1, A_2, \dots$ (koji ne moraju biti disjunktni) vrijedi σ- ***poluaditivnost***

$$P\Big(\bigcup_{i=1}^{\infty} A_i\Big) \leq \sum_{i=1}^{\infty} P(A_i). \tag{4.3}$$

[2]Te se pretpostavke nazivaju aksiomima teorije vjerojatnosti. Općenito govoreći, aksiomi su u matematici tvrdnje koje se smatraju istinitima bez potrebe za njihovim dokazivanjem, a onda se ostale tvrdnje izvode iz njih korištenjem logičkih pravila zaključivanja.

Dokaz ove propozicije prepuštamo za vježbu u Zadatku 4.8.1. Uočimo da je konačna aditivnost direktna posljedica σ-aditivnosti. Naime, stavimo da je $A_i = \emptyset$ za $i \geq n+1$. Tada je $P(A_i) = 0$ za $i \geq n+1$, prema svojstvu (1) u Propoziciji 4.1.3, pa je

$$\bigcup_{i\in\mathbb{N}} A_i = \bigcup_{i}^{n} A_i \quad \text{i} \quad \sum_{i=1}^{\infty} P(A_i) = \sum_{i=1}^{n} P(A_i).$$

Naravno, za $n = 2$ dobivamo

$$P(A_1 \cup A_2) = P(A_1) + P(A_2),$$

ako su A_1 i A_2 disjunktni skupovi. Pogledajmo jedan jednostavan primjer u kojem ćemo iskoristiti neka svojstva vjerojatnosti, odnosno neke od navedenih formula koje općenito vrijede za vjerojatnost.

Primjer 4.1.4. Pretpostavimo da smo iz odjela rizika nekog poduzeća dobili sljedeću sigurnosnu IT procjenu: izgledi da će u tekućoj godini doći do značajnog zlćudnog napada na računalnu infrastrukturu poduzeća iznose 40%, izgledi da će u sljedećoj godini doći do takvog napada iznose 50%, a izgledi da ni u ovoj ni u sljedećoj godini neće doći do takvog značajnijeg napada iznose 30%. Izračunajmo vjerojatnosti sljedećih događaja:

a) u ovoj ili sljedećoj godini će doći do značajnog zlćudnog napada na računalnu infrastrukturu poduzeća

b) i u ovoj i u sljedećoj godini će doći do značajnog zlćudnog napada na računalnu infrastrukturu poduzeća

c) u ovoj godini će doći do značajnog zlćudnog napada na računalnu infrastrukturu poduzeća, ali u sljedećoj neće

d) do značajnog zlćudnog napada na računalnu infrastrukturu poduzeća će doći u samo jednoj od navedene dvije godine (ali ne u obje).

Da bismo izračunali tražene vjerojatnosti trebamo najprije prevesti na jezik vjerojatnosti informacije koje su nam dane (ne ulazeći sada u način na koji se do njih došlo). U tu svrhu definirajmo slučajne događaje $A =$ "u ovoj godini će doći do značajnog zlćudnog napada na računalnu infrastrukturu poduzeća" i $B =$ "u sljedećoj godini će doći do značajnog zlćudnog napada na računalnu infrastrukturu poduzeća". Uz takve definicije slučajnih događaja zadane informacije najprije prevedemo u vjerojatnosti. Imamo

$$P(A) = 0,4, \quad P(B) = 0,5 \quad \text{i} \quad P(A^c \cap B^c) = 0,3.$$

Izračunajmo tražene vjerojatnosti.
a) Tražimo vjerojatnost događaja $A \cup B$. Kako načelno događaji A i B nisu disjunktni ne možemo iskoristiti konačnu aditivnost vjerojatnosti. Stoga se čini razumno probati iskoristiti svojstvo (5) iz Propozicije 4.1.3, ali je problem što ne znamo $P(A \cap B)$. S druge strane, kada imamo događaje/skupove koji su unije ili presjeci komplemenata nekih drugih događaja/skupova dobra ideja je probati iskoristiti De Morganova pravila (formule (3.2) i (3.3) u prošlom poglavlju). Konkretno, ovdje će nam koristiti De Morganovo pravilo za uniju da dobijemo

$$(A \cup B)^c = A^c \cap B^c.$$

No, sada možemo iskoristiti formulu za vjerojtnost suprotnog događaja (svojstvo (2) u Propoziciji 4.1.3) da bi izračunali

$$P(A \cup B) = 1 - P((A \cup B)^c) = 1 - P(A^c \cap B^c) = 1 - 0,3 = 0,7.$$

b) U ovom djelu se traži vjerojatnost slučajnog događaja $A \cap B$. Kako znamo $P(A)$, $P(B)$ i $P(A \cup B)$ gotovo se nameće korištenje svojstva (5) iz Propozicije 4.1.3. Tako imamo

$$P(A \cap B) = P(A) + P(B) - P(A \cup B) = 0,4 + 0,5 - 0,7 = 0,2.$$

c) Prevedeno na jezik vjerojatnosti tražimo $P(A \cap B^c)$. Uočimo, što smo već koristili, da se $A \cap B^c$ može zapisati i kao $A \setminus B$, odnosno kao $A \setminus (A \cap B)$ (poslužite se Vennovim dijagramima ako ovo odmah "ne vidite"). Kako je $A \cap B \subset A$ iskoristimo svojstvo (3) u Propoziciji 4.1.3 da dobijemo

$$P(A \cap B^c) = P(A \setminus (A \cap B)) = P(A) - P(A \cap B) = 0,4 - 0,2 = 0,2.$$

d) Da do značajnijeg zločudnog napada neće doći u ovoj godini opisuje slučajni događaj $A^c \cap B$ dok $A \cap B^c$ opisuje događaj da do značajnijeg zločudnog napada neće doći u sljedećoj godini. $A \cap B^c$ i $A^c \cap B$ su disjunktni događaji (ne može neki element biti u A i ne biti u A, osim praznog skupa $\emptyset$). Želimo izračunati vjerojatnost $P((A \cap B^c) \cup (A^c \cap B))$. Kako je riječ o disjunktnoj uniji možemo iskoristiti svojstvo konačne aditivnosti (za $n = 2$) pa imamo

$$P((A \cap B^c) \cup (A^c \cap B)) = P(A \cap B^c) + P(A^c \cap B).$$

Vjerojatnost $P(A \cap B^c)$ smo već izračunali, a na isti način izračunamo $P(A^c \cap B)$. Imamo

$$P(A^c \cap B) = P(B \setminus (A \cap B)) = P(B) - P(A \cap B) = 0,5 - 0,2 = 0,3.$$

Dakle,

$$P((A \cap B^c) \cup (A^c \cap B)) = P(A \cap B^c) + P(A^c \cap B) = 0,2 + 0,3 = 0,5.$$

Time smo izračunali sve tražene vjerojatnosti. □

Svojstva vjerojatnosti (1) – (3) iz Definicije 4.1.2 kao i ona iz Propozicije 4.1.3 ćemo često koristiti u nastavku. S druge strane, pojam σ-algebre nećemo koristiti u punoj općenitosti u rezultatima i teoriji koju ćemo izložiti. Razlog za to je kompliciranija teorija koju je potrebno razviti u tom slučaju, a za većinu rezultata koje ćemo predstaviti nije potrebna takva razina općenitosti. Posebno, u slučaju konačnog ili prebrojivog skupa Ω skup svih slučajnih događaja se u principu podudara s partitivnim skupom od Ω. Drugim riječima, ukoliko je skup Ω konačan ili prebrojiv svi njegovi podskupovi se mogu smatrati slučajnim događajima. Za neprebrojive skupove Ω to općenito ne vrijedi. Vjerojatnosni prostori u kojima je skup Ω konačan ili prebrojiv skup zovu se **diskretni vjerojatnosni prostori**.[3] Jednostavnija struktura diskretnih vjerojatnosnih prostora, u odnosu na općenite vjerojatnosne prostore, proizlazi iz svojstva σ-aditivnosti vjerojatnosti.

Pretpostavimo da je prostor elementarnih događaja Ω konačan i da ima n elemenata, $n \in \mathbb{N}$. Tada je

$$\Omega = \{\omega_1, \omega_2, \ldots, \omega_n\}.$$

Kao što znamo, tada partitivni skup od Ω, koji označavamo s $\mathcal{P}(\Omega)$, ima 2^n elemenata. Stoga proizvoljna σ-algebra $\mathcal{F}$ na Ω ima konačan broj elemenata pa se zahtjev za σ-aditivnošću svede na zahtjev da su unije podskupova od Ω opet sadržane u $\mathcal{F}$. U takvoj situaciji se svaka vjerojatnost na Ω može promatrati kao da je definirana na $\mathcal{P}(\Omega)$.[4]

[3] Za podsjećanje na pojmove prebrojivog i neprebrojivog skupa pogledajte dio teksta prije Napomene 3.1.46.

[4] U principu se svaka vjerojatnost na Ω može proširiti tako da bude definirana na $\mathcal{P}(\Omega)$. Više o ovoj temi može se naći u poglavlju 3 knjige [10].

Uzmimo neku vjerojatnost $P : \mathcal{P}(\Omega) \to [0,1]$ i uzmimo proizvoljan slučajan događaj $A \in \mathcal{P}(\Omega)$ (dakle, $A \subset \Omega$). Tada se skup A može prikazati kao unija elemenata koji ga čine, što zapisujemo kao

$$A = \bigcup_{\{i \mid \omega_i \in A\}} \{\omega_i\} = \bigcup_{\{\omega_i \in A\}} \{\omega_i\}.$$

No, tada je, zbog konačne aditivnosti vjerojatnosti,

$$P(A) = P\Big(\bigcup_{\{\omega_i \in A\}} \{\omega_i\}\Big) = \sum_{\{\omega_i \in A\}} P(\{\omega_i\}). \tag{4.4}$$

Dakle, ako znamo vjerojatnosti elementarnih događaja

$$p_i := P(\{\omega_i\})$$

pomoću njih možemo izračunati vjerojatnosti svih slučajnih događaja na Ω (sjetimo se, ishode slučajnih eksperimenata modeliramo skupom Ω). Uočimo da su svi brojevi $p_i \geq 0$ (nenegativni) te je

$$\sum_{i=1}^{n} p_i = \sum_{i_1}^{n} P(\{\omega_i\}) = P\Big(\bigcup_{i=1}^{n} \{\omega_i\}\Big) = P(\{\omega_1, \omega_2, \ldots, \omega_n\}) = P(\Omega) = 1.$$

Zanimljivo je da vrijedi i obratna konstrukcija: ako je $p_1, p_2, \ldots, p_n$ niz nenegativnih brojeva, $0 \leq p_i \leq 1$, $i = 1, 2, \ldots, n$, takvih da je

$$\sum_{i=1}^{n} p_i = 1,$$

onda možemo definirati $P(\{\omega_i\}) = p_i$ da bi dobili vjerojatnost. Naime, u tom slučaju za $A \subset \Omega$ definiramo

$$P(A) = \sum_{\{\omega_i \in A\}} P(\{\omega_i\})$$

i tako dobijemo funkciju $P : \mathcal{P}(\Omega) \to [0,1]$ za koju vrijede svojstva $(1) - (3)$ iz definicije 4.1.2. Dakle, P je vjerojatnost na $(\Omega, \mathcal{P}(\Omega))$.

Slična je situacija i ako je Ω prebrojiv skup. Tada se Ω može zapisati kao

$$\Omega = \{\omega_1, \omega_2, \ldots\}.$$

Kao i u slučaju konačnog skupa Ω proizvoljan podskup $A \subset \Omega$ se može prikazati kao unija elemenata koji ga čine, što opet možemo zapisati kao

$$A = \bigcup_{\{i \mid \omega_i \in A\}} \{\omega_i\} = \bigcup_{\{\omega_i \in A\}} \{\omega_i\}$$

s time da su gore naznačene unije moguće i prebrojive (prebrojivo beskonačne). Neka je $P : \mathcal{P}(\Omega) \to [0,1]$ vjerojatnost na $(\Omega, \mathcal{P}(\Omega))$. Ako znamo vjerojatnosti elementarnih događaja $p_i := P(\{\omega_i\})$, $i \in \mathbb{N}$, onda se primjenom σ-aditivnosti vjerojatnosti P može izračunati vjerojatnost proizvoljnog podskupa A od Ω jer imamo

$$P(A) = P\Big(\bigcup_{\{\omega_i \in A\}} \{\omega_i\}\Big) = \sum_{\{\omega_i \in A\}} P(\{\omega_i\}).$$

U principu se situacija sa slučaja konačnog skupa Ω prenosi i na prebrojiv skup Ω te možemo ponoviti prije indiciran postupak konstrukcije vjerojatnosti na $(\Omega, \mathcal{P}(\Omega))$.

Prema tome, pitanje određivanja σ-algebre na konačnim i prebrojivim skupovima nije od presudne važnosti jer u osnovi možemo gledati vjerojatnosti definirane na partitivnom skupu prostora elementarnih događaja Ω (zainteresirani čitatelj može pogledati Teorem 3.4 u [10]). Zbog toga su diskretni vjerojatnosni prostori lakši za analizu. Općenitom situacijom se nećemo baviti u nastavku što znači da često nećemo strogo defnirati σ-algebre na kojima gledamo neke vjerojatnosti.

Ono što možemo zapamtiti iz prethodne rasprave je da se vjerojatnost konačnih ili prebrojivih disjunktnih unija može izračunati primjenom svojstva σ-aditivnosti vjerojatnosti. Dodatno, na konačnim ili prebrojivim prostorima elementarnih događaja Ω je vjerojatnost **u potpunosti određena svojim djelovanjem na elementarnim događajima** (zbog (4.4)).

4.2 Primjeri vjerojatnosti i vjerojatnosnih prostora

U prethodnom poglavlju smo vidjeli kako možemo računati vjerojatnosti raznih slučajnih događaja korištenjem naivne definicije vjerojatnosti. Ti izračuni su bili ograničeni na konačne skupove elementarnih događaja pri čemu su svi elementarni događaji bili jednako vjerojatnui. U sljedećem primjeru pokazujemo da je takva situacija poseban slučaj definicije vjerojatnosti (Definicija 4.1.2).

Primjer 4.2.1 (Uniformna vjerojatnost)**.** Uzmimo konačan skup Ω takav da je

$$\Omega = \{\omega_1, \omega_2, \ldots, \omega_n\},\ n \in \mathbb{N}$$

i na njemu definirajmo vjerojatnost[5] P koja svim elementarnim događajima dodjeljuje istu vjerojatnost

$$P(\{\omega_1\}) = P(\{\omega_2\}) = \ldots = P(\{\omega_n\}).$$

U prošlom odjeljku smo vidjeli da je vjerojatnost na konačnim skupovima zadana svojim vrijednostima $p_i = P(\{\omega_i\})$ na elementarnim događajima. No, onda iz svojstva vjerojatnosti P znamo da je $P(\Omega) = 1$ te da je P konačno aditivna (prema Definiciji 4.1.2) pa imamo

$$1 = P(\Omega) = P\Big(\bigcup_{i=1}^{n}\{\omega_i\}\Big) = \sum_{i=1}^{n} P(\{\omega_i\}).$$

Dakle, dobivamo

$$P(\{\omega_1\}) + P(\{\omega_2\}) + \ldots + P(\{\omega_n\}) = 1,$$

odnosno

$$P(\{\omega_i\}) = \frac{1}{n},\ i = 1, 2, \ldots, n.$$

Uzmimo sada proizvoljan slučajni događaj $E \subset \Omega$ (odnosno $E \in \mathcal{P}(\Omega)$). E se sastoji od nekih elemenata skupa Ω. To možemo općenito iskazati tvrdnjom da postoje indeksi $i_1, i_2, \ldots, i_k \in \{1, 2, \ldots, n\}$, $1 \leq k \leq n$, takvi da je

$$E = \{\omega_{i_1}, \omega_{i_2}, \ldots \omega_{i_k}\}.$$

Jer su svi jednočlani skupovi $\{\omega_{i_j}\}$, $1 \leq j \leq k$, međusobno disjunktni, zbog konačne aditivnosti vjerojatnosti P imamo

$$P(E) = P\Big(\bigcup_{j=1}^{k}\{\omega_{i_j}\}\Big) = \sum_{j=1}^{k} P(\{\omega_{i_j}\}) = \sum_{j=1}^{k}\frac{1}{n} = \underbrace{\frac{1}{n} + \frac{1}{n} + \ldots + \frac{1}{n}}_{k \text{ puta}} = \frac{k}{n},$$

[5] U skladu s raspravom s kraja prošlog odjeljka, ne trebamo previše paziti na σ-algebru na kojoj je definirana vjerojatnost P jer na konačnim i prebrojivo beskonačnim skupovima možemo uzeti $\mathcal{F} = \mathcal{P}(\Omega)$.

odnosno dobivamo da je

$$P(E) = \frac{|E|}{|\Omega|}.$$

Dakle, ako imamo definiranu uniformnu vjerojatnost na konačnom skupu Ω, onda se ta vjerojatnost podudara s naivnom definicijom vjerojatnosti koju smo dali u (3.6). Drugim riječima, naivna definicija vjerojatnosti je poseban slučaj opće definicije vjerojatnosti dane u Defenciji 4.1.2, što smo i željeli.
Da bi konkretizirali gornja razmatranja pogledajmo opet primjer 3.2.3 u kojem smo gledali vjerojatnosni prostor koji opisuje bacanje igraće kockice. U njemu je

$$\Omega = \{1, 2, 3, 4, 5, 6\},$$

odnosno $n = 6$. Intuitivno je jasno da za simetričnu kockicu imamo

$$P(\{1\}) = P(\{2\}) = P(\{3\}) = P(\{4\}) = P(\{5\}) = P(\{6\}) = \frac{1}{6}.$$

Dakle, imamo zadanu uniformnu vjerojatnost na Ω. Uzmimo slučajni događaj $B = \{4, 5, 6\}$. U skladu s gornjim oznakama je $k = 3$ te su $i_1 = 4$, $i_2 = 5$ i $i_3 = 6$. No, onda je jasno da je

$$P(B) = \frac{3}{6}$$

što smo već izračunali u prethodnom poglavlju korištenjem formule (3.6) za naivnu vjerojatnost.
Pokušajte sami na isti način raspisati vjerojatnosti iz Primjera 3.2.13. □

Kao što nam pokazuje prethodni primjer, primjeri izračuna vjerojatnosti koje smo dali u prethodnom poglavlju predstavljaju osnovne primjere vjerojatnosnih prostora. Pri tome je broj elementa prostora elementarnih događaja Ω jednak ukupnom broju mogućnosti u svakom pojedinom primjeru, a za σ-algebru možemo uzeti partitivni skup od Ω, što smo komentirali na kraju prošlog odjeljka. Iako je partitivni skup $\mathcal{P}(\Omega)$ od Ω konačan, uočite da je riječ o vrlo velikom skupu. Tako u Primjeru 3.4.6 Ω ima $\binom{52}{5}$ elemenata, a $\mathcal{P}(\Omega)$ $2^{\binom{52}{5}}$ elemenata. Pogledajmo još neke primjere vjerojatnosnih prostora.

Primjer 4.2.2 (Nastavak Primjera 3.2.14)**.** U primjeru 3.2.9 smo definirali dva prostora elementarnih događaja koji opisuju bacanje dvije simetrične igraće kockice na slučajan način. S Ω smo označili prostor elementarnih događaja koji opisuje ishode bacanja dvije kockice koje razlikujemo, dok smo s Ω_2 označili prostor elementarnih događaja koji opisuje ishode bacanja dvije kockice koje ne razlikujemo.
U slučaju prostora elementarnih događaja Ω prirodno je pretpostaviti da su svi elementarni događaji jednako vjerojatni, odnosno definirati uniformnu vjerojatnost P na Ω. Kao što smo vidjeli u prethodnom primjeru, takva definicija vjerojatnosti se podudara s naivnom definicijom vjerojatnosti na Ω_1 koju smo opisali u primjeru 3.2.14. Uočite da smo tamo komentirali da se takva definicija vjerojatnosti podudara sa stvarnom situacijom bacanja dvije kockice jer one fizički jesu različite.
S druge strane, nema neke teorijske zapreke da definiramo vjerojatnost na prostoru elementarnih događaja Ω_2.[6] To možemo napraviti tako da definiramo vjerojatnost P_2 na elementarnim događajima, odnosno elementima skupa Ω_2. Ukoliko ne razlikujemo dvije kockice koje bacamo bit će svejedno da li je, na primjer, na prvoj kockici pao broj 1, a

[6] Uočite da smo u primjeru 3.2.14 komentirali da u slučaju prostora elementarnih događaja Ω_2 nije primjenjiva naivna definicija vjerojatnosti jer svi elementarni događaji nisu jednako vjerojatni.

na drugoj broj dva ili je na prvoj kockici pao broj 2, a na drugoj broj jedan. Stoga je u ovom slučaju prirodno definirati

$$P_2(\{(1,2)\}) = \frac{2}{36},$$

odnosno općenito

$$P_2(\{(i,j)\}) = \frac{2}{36}, \quad \text{za} \;\; i = 1,2,3,4,5, \;\; j = i+1,\ldots,6.$$

Za $i = j$ stavimo $P_2(\{(i,i)\}) = 1/36$, $i = 1,2,3,4,5,6$, odnosno

$$P_2(\{(1,1)\}) = P_2(\{(2,2)\}) = P_2(\{(3,3)\}) = P_2(\{(4,4)\}) = P_2(\{(5,5)\}) = P_2(\{(6,6)\}) = \frac{1}{36}.$$

Da bi tako definirana funkcija P_2 na Ω_2, s vrijednostima u $[0,1]$, bila vjerojatnost mora vrijediti $P_2(\Omega_2) = 1$. To je zaista tako jer je

$$P_2(\Omega_2) = P_2\Big(\bigcup_{\substack{i=1,2,\ldots,6\\ j=i,\ldots,6}} \{(i,j)\}\Big) = \sum_{i=1}^{6} P_2(\{(i,i)\}) + \sum_{\substack{i=1,2,\ldots,5\\ j=i+1,\ldots,6}} P_2(\{(i,j)\}),$$

a vrijedi da je

$$\sum_{i=1}^{6} P_2(\{(i,i)\}) = \sum_{i=1}^{6} \frac{1}{36} = \frac{6}{36}$$

te

$$\sum_{\substack{i=1,2,\ldots,5\\ j=i+1,\ldots,6}} P_2(\{(i,j)\}) = \sum_{i=1}^{5}\sum_{j=i+1}^{6} P_2(\{(i,j)\}) = \sum_{i=1}^{5}\sum_{j=i+1}^{6} \frac{2}{36} = (5+4+3+2+1)\frac{2}{36} = \frac{30}{36}.$$

Napomenimo na kraju ovog primjera da smo na prostorima elementarnih događaja Ω_1 i Ω_2 mogli definirati i drugačije vjerojatnosti, ali tada više ne bi opisivali slučajan eksperiment bacanja dvije simetrične kockice (bilo da ih razlikujemo ili ne). □

Primjer 4.2.3 (Vjerojatnost na prebrojivim skupovima)**.** Neka je Ω prebrojiv skup. Znamo da to znači da postoji bijekcija s Ω na $\mathbb{N}$ pa radi jednostavnosti uzmimo $\Omega = \mathbb{N}$. Vidjeli smo na kraju prošlog odjeljka da se vjerojatnost na prebrojivim skupovima, pa posebno i na $\mathbb{N}$, može zadati nizom brojeva $p_n \in [0,1]$ i to tako da definiramo vjerojatnosti elementarnih događaja

$$P(\{n\}) = p_n, \;\; n \in \mathbb{N},$$

a onda za proizvoljan podskup $A \subset \Omega = \mathbb{N}$ stavimo

$$P(A) = \sum_{\{i \in A\}} P(\{i\}).$$

Važno je uočiti da niz nenegativnih brojeva p_n ne može biti proizvoljan jer zbog prebrojive aditivnosti mora vrijediti

$$\sum_{n=1}^{\infty} p_n = \sum_{n=1}^{\infty} P(\{n\}) = P(\Omega) = 1.$$

Tipičan primjer niza p_n koji zadovoljava gornji uvjet je niz $p_n = 1/2^n$ pa je dobro definirana vjerojatnost P_1 na $(\mathbb{N}, \mathcal{P}(\mathbb{N}))$ za koju je

$$P_1(\{n\}) = \frac{1}{2^n}$$

jer je[7]

$$\sum_{n=1}^{\infty} \frac{1}{2^n} = \frac{1/2}{1-1/2} = 1.$$

Još jedan primjer je dan nizom brojeva

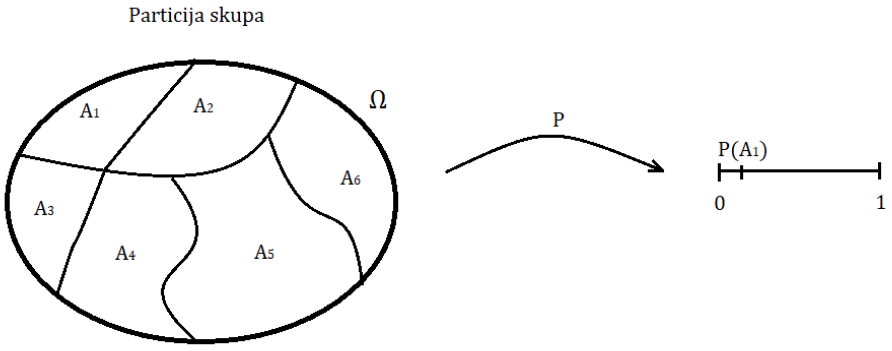
$$p_n = (1-p)^{n-1}p,$$

gdje je p broj takav da je $0 < p < 1$.
Uočite da p_n ne može biti konstantan niz poput $p_n = p$, $0 < p < 1$, jer beskonačan zbroj broja p sa samim sobom teži u beskonačnost, ma kako mali broj p odaberemo. Posebno to znači da ne možemo definirati uniformnu vjerojatnost na beskonačnom prebrojivom skupu. □

Primjer 4.2.4 (Particije prostora elementarnih događaja)**.** Već smo napomenuli da su neprebrojivi vjerojatnosni prostori zahtjevniji za analizu. Ipak, ponekad se izračun vjerojatnosti na neprebrojivom vjerojatnosnom prostoru može značajno olakšati ukoliko postoji partcija prostora elementarnih događaja na konačno ili prebrojivo mnogo elemenata.
Uzmimo neki skup Ω za koji postoji konačno mnogo skupova $A_i \subset \Omega$, $i = 1, 2, \ldots, n$, $n \in \mathbb{N}$, koji su međusobno disjunkni ($A_i \cap A_j = \emptyset$ za $i \neq j$, $i, j = 1, 2, \ldots, n$) te im je unija jednaka cijelom skupu Ω, odnosno

$$\bigcup_{i=1}^{n} A_i = \Omega.$$

Skupovi A_i čine konačnu **particiju skupa** Ω.
Sada definiramo vjerojatnost P na Ω tako da odredimo vjerojatnosti $p_i = P(A_i)$, $i = 1, 2, \ldots, n$. Apstraktno gledano sad smo u istoj situaciji kao kod definicije vjerojatnosti na konačnom skupu Ω. U skladu s time za σ-algebru na tom vjerojatnosnom prostoru možemo uzeti partitivni skup skupa $\{A_1, A_2, \ldots, A_n\}$. Sličnu situaciju dobijemo i ako gledamo prebrojivu particiju skupa Ω. Shematski prikaz particije skupa Ω, za particiju koja sadrži $n = 6$ članova, te vjerojatnosti na Ω dan je na donjoj slici.



Da bi konkretizirali gornja razmatranja, uzmimo $\Omega = [0, 1]$ (segment realnih brojeva između nule i jedinice). Jasno, Ω je neprebrojivo beskonačan skup. Uzmimo particiju od Ω koja ima četiri elementa: $A_1 = [0, 1/4)$, $A_2 = [1/4, 2/4)$, $A_3 = [2/4, 3/4)$ i $A_4 = [3/4, 1]$. Definirajmo vjerojatnost P na Ω tako da stavimo $P(A_i) = 1/4$. Tako dobijemo

[7] Sjetite se formule za zbroj geometrijskog reda

uniformnu vjerojatnost na Ω koja je u osnovi jednaka vjerojatnosti na konačnom skupu (pri čemu je sama particija skupa Ω bila konačna).

Naravno, na $\Omega = [0,1]$ možemo definirati i "pravu" vjerojatnost koja će biti definirana na Borelovoj σ-algebri otvorenih skupova, ali to je van dosega gradiva koje obrađujemo u ovoj skripti. □

Napomena 4.2.5. Particije prostora elementarnih događaja se prirodno pojavljuju. Na primjer, uzmimo prostor elementarnih događaja $\Omega = \{1,2,3,4,5,6\}$ kojim modeliramo slučajno bacanje igraće kockice ili nekog drugog slučajnog eksperimenta sa šest ishoda. Definirajmo slučajni događaj $A =$ "na kockici je pao paran broj" i slučajni događaj $A_2 =$ "na kockici je pao neparan broj. Tada je

$$A_1 = \{2,4,6\} \quad \text{i} \quad A_2 = \{1,3,5\}.$$

Očito je $A_1 \cap A_2 = \emptyset$ i $A_1 \cup A_2 = \Omega$. Dakle, $\{A_1, A_2\}$ čine particiju skupa Ω. Ukoliko je kockica simetrična prirodno je definirati vjerojatnost P_1 na toj particiji sa $P_1(A_1) = P_1(A_2) = 1/2$.
No, to nije jedina moguća vjerojatnost. Možemo definirati i vjerojatnost P_2 sa $P_2(A_1) = 1/3$ i $P_2(A_2) = 2/3$. Na sličan način možemo definirati velik broj[8] vjerojatnosti na $(\{A_1, A_2\}, \mathcal{P}(\{A_1, A_2\}))$
Uočimo da se definiranjem vjerojatnosti na particiji $\{A_1, A_2\}$ smanjila "rezolucija" vjerojatnosti na Ω. Naime, ukoliko particiju $\{A_1, A_2\}$ proglasimo novim vjerojatnosnim prostorom gubimo vezu s bivšim elementarnim događajima poput $\{1\}$ ili $\{4\}$. Sada više ne možemo računati njihove vjerojatnosti jer su novi elementarni događaji postali A_1 i A_2. Oni se ne mogu rastaviti na manje događaje (elementarni su) □

U nastavku skripte vidjet ćemo još primjera računanja vjerojatnosti raznih slučajnih događaja. Ipak, fokus izlaganja će se u sljedećem poglavlju pomjeriti s vjerojatnosnih prostora na slučajne varijable koje ćemo tamo definirati. Naravno, vjerojatnosni prostor je osnovni objekt u suvremenoj vjerojatnosti na kojem "žive" svi ostali vjerojatnosni objekti pa je njegov značaj izniman. Dodajmo za kraj ovog potpoglavlja da su svojstva vjerojatnosti koje smo naveli u ovom poglavlju (Definicija 4.1.2 i Propozicija 4.1.3) univerzalna i vrijede na svim vjerojatnosnim prostorima. Možete za vježbu ponovno pogledati zadnji dio Primjera 3.4.6 i zanemariti skupovne relacije koje smo komentirali - vidjet ćete da sve relacije s vjerojatnostima proizlaze iz svojstava vjerojatnosti koja smo naveli u ovom poglavlju.

4.3 Nezavisnost

Jedan od najvažnijih pojmova u vjerojatnosti je nezavisnost. Neformalno smo već na nekoliko mjesta govorili o, na primjer, nezavisnom bacanju dvije igraće kockice ili novčića. Uz definiciju vjerojatnosti koju smo uveli sada možemo preciznije definirati i pojam nezavisnosti u vjerojatnosti. Imamo sljedeću definiciju.

Definicija 4.3.1. Neka je $(\Omega, \mathcal{F}, P)$ vjerojatnosni prostor. Tada su slučajni događaji $A_1, A_2, \ldots, A_n \in \mathcal{F}$ **nezavisni** ako za svaki odabir indeksa $\{i_1, i_2, \ldots, i_k\} \subset \{1,2,\ldots,n\}$, $k \leq n$, vrijedi

$$P\Big(\bigcap_{j=1}^{k} A_{i_j}\Big) = \prod_{j=1}^{k} P(A_{i_j}). \tag{4.5}$$

Ukoliko imamo prebrojivo mnogo slučajnih događaja $A_1, A_2, \ldots \in \mathcal{F}$ onda su oni nezavisni ako za svaki odabir indeksa $\{i_1, i_2, \ldots, i_k\} \subset \mathbb{N}$, $k \in \mathbb{N}$, vrijedi relacija (4.5).

[8] Neprebrojivo mnogoa. Jednostavno stavimo $P(A_1) = p$ i $P(A_2) = 1-p$, gdje je p realan broj iz segmenta $[0,1]$.

Definicija nezavisnosti je dana u dosta apstraktnoj formi pa je za njeno razumijevanje dobro razmisliti što ona govori u jednostavnom slučaju. Uzmimo dva slučajna događaja A_1 i A_2. Tada su jedini podskupovi skupa indeksa $\{1,2\}$ skupovi indeksa $\{1\}$, $\{2\}$ i $\{1,2\}$. Formula (4.5) je trivijalna za jednočlane skupove indeksa pa se definicija nezavisnosti svede na zahtjev

$$P(A_1 \cap A_2) = P(A_1) \cdot P(A_2). \tag{4.6}$$

Dakle, u najjednostavnijoj formi su slučajni događaji A_1 i A_2 nezavisni ako je vjerojatnost njihovog presjeka jednaka produktu njihove vjerojatnosti. Uočimo simetričnost nezavisnosti, koja proizlazi iz komutativnosti presjeka i množenja: ako su slučajni događaji A_1 i A_2 nezavisni, onda su nezavisni i slučajni događaji A_2 i A_1.

Što nam Definicija 4.3.1 govori za nezavisnost tri slučajna događja? Uzmimo slučajne događaje A_1, A_2 i A_3. Ukoliko isključimo jednočlane podskupove vidimo da su mogući podskupovi indeksnog skupa $\{1,2,3\}$ skupovi $\{1,2\}$, $\{1,3\}$, $\{2,3\}$ i $\{1,2,3\}$. Stoga će slučajni događaji A_1, A_2 i A_3 biti nezavisni ako vrijede sljedeće četiri relacije

$$P(A_1 \cap A_2) = P(A_1) \cdot P(A_2), \quad P(A_1 \cap A_3) = P(A_1) \cdot P(A_3), \quad P(A_2 \cap A_3) = P(A_2) \cdot P(A_3)$$

i

$$P(A_1 \cap A_2 \cap A_3) = P(A_1) \cdot P(A_2) \cdot P(A_3).$$

Kao što vidimo, provjera nezavisnosti za više od dva slučajna događaja se značajno komplicira (za $n = 4$ moramo provjeriti 11 uvjeta[9]) i u općenitom slučaju nije ju lagano provjeriti.

Primjer 4.3.2. Zadan je prostor elementarnih događaja $\Omega = \{1,2,3,4,5,6,7,8\}$ i na njemu vjerojatnost P takva da je vjerojatnost svakog elementarnog događaja jednaka $1/8$. Uzmimo skupove $A = \{1,2,5,6\}$ i $B = \{4,5,6,7\}$. Provjerimo da li su oni nezavisni. Uočite, uvođenjem vjerojatnosti na skup Ω skupovi A i B postaju slučajni događaji (uz σ-algebru $\mathcal{P}(\Omega)$).

Vidimo da je na Ω zadana uniformna vjerojatnost koja svakom elementarnom događaju daje jednaku vjerojatnost $1/8$. Kako skupovi A i B imaju po 4 elementa njihova je vjerojatnost jednaka $4/8 = 1/2$ (sjetite se Primjera 4.2.1). S druge strane je $A \cap B = \{5,6\}$ pa je $P(A \cap B) = 2/8 = 1/4$. Stoga je

$$\frac{1}{4} = P(A \cap B) = P(A) \cdot P(B) = \frac{1}{2} \cdot \frac{1}{2}$$

pa su navedeni slučajni događaji nezavisni. □

Primjer 4.3.3 (Disjunktni slučajni događaji nisu nezavisni)**.** Moglo bi se učiniti, iako se to ne vidi u definiciji, da postoji veza između disjunktnih i nezavisnih slučajnih događaja. Ipak, to nije tako. Štoviše, ako imamo dva slučajna događaja čija je vjerojatnost strogo pozitivna, onda oni nisu nezavisni ako su disjuktni.

Za ilustraciju uzmimo primjer igraće kocke koju bacimo na slučajan način (jednako je vjerojatno da će pasti bilo koji od 6 brojeva na kocki). Označimo s A slučajni događaj "pao je paran broj", a s B slučajni događaj "pao je neparan broj". Znamo da je $\Omega = \{1,2,3,4,5,6\}$ te je $A = \{2,4,6\}$ i $B = \{1,3,5\}$. Lagano izračunamo vjerojatnost od A jer je, zbog konačne aditivnosti,

$$P(A) = P(\{2,4,6\}) = P(\{2\}) + P(\{4\}) + P(\{6\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{3}{6} = \frac{1}{2},$$

[9] Ovo je dobra prilika da primijenimo naučeno iz kombinatorike. Koliko ukupno ima dvočlanih, tročlanih i četveročlanih podskupova od $\{1,2,3,4\}$? Kod skupova poredak elemenata nije važan pa različitih dvočlanih podskupova ima $\binom{4}{2}$, različitih tročlanih podskupova ima $\binom{4}{3}$, a četveročlanih $\binom{4}{4}$. Laganim računom dolazimo do broja 11. Ukoliko imate dvojbe pogledajte pojam kombinacije u prošlom poglavlju.

a na isti način vidimo da je $P(B) = 1/2$.[10] Kako su A i B disjunktni presjek im je prazan skup (po definiciji disjunktnosti) pa je jasno da je

$$P(A \cap B) = 0.$$

Dakle,

$$0 = P(A \cap B) \neq P(A) \cdot P(B) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

Zaključujemo da A i B nisu nezavisni jer ne zadovoljavaju uvjet nezavisnosti (4.5), odnosno (4.6). Ovo nam pokazuje da pojmovi nezavisnosti i disjunktnosti nisu povezani. □

Primjer 4.3.4 (Nezavisnost tri slučajna događaja)**.** Ovaj primjer nam pokazuje da je za provjeru nezavisnosti tri slučajna događaja potrebno provjeriti sva četiri uvjeta koja smo naveli na početku ovog potpoglavlja, odnosno da nezavisnost "u parovima" nije dovoljna da bi zaključili da su tri slučajna događaja nezavisna.
Uzmimo dvije igraće kocke i bacimo ih na slučajan način. Označimo s A slučajni događaj "na prvoj kocki je pao paran broj", s B slučajni događaj "na drugoj kocki je pao neparan broj", a sa C slučajni događaj "zbroj brojeva na kockama je jednak 9". Izračunajmo vjerojatnosti tih događaja. Znamo da skup elementarnih događaja za slučajni eksperiment bacanja dvije kocke ima $6^2 = 36$ elemenata. Događaj A se može dogoditi tako da na prvoj kocki padne jedna od tri mogućnosti (2, 4 ili 6), a na drugoj kocki jedna od 6 mogućnosti. Prema principu umnoška skup A ima $3 \cdot 6 = 18$ elemenata pa je $P(A) = 1/2$. Na sličan način vidimo da je $P(B) = 1/2$. Elementi slučajnog događaja C su $\{(4,5),(3,6),(6,3),(5,4)\}$ pa je $P(C) = 4/36 = 1/9$.
Provjerimo nezavisnost tih događaja. Prije svega, događaj $A \cap B$ sadrži sva bacanja dvije kocke u kojima je na prvoj kocki pao paran broj, a na drugoj neparan. Stoga on ima $3 \cdot 3 = 9$ elemenata pa je $P(A \cap B) = 9/36 = 1/4$. Stoga je

$$P(A \cap B) = \frac{1}{4} = P(A)P(B)$$

pa su A i B nezavisni događaji. Nadalje, skup $A \cap C$ sadrži točno dva elementa (to su $(4,5)$ i $(6,3)$) pa je $P(A \cap C) = 2/36 = 1/18$. Dakle,

$$P(A \cap C) = \frac{1}{18} = P(A)P(C),$$

a na isti način vidimo da je

$$P(B \cap C) = \frac{1}{18} = P(B)P(C).$$

Kao što vidimo, sva su tri događaja u parovima nezavisni. No, to nije dovoljno da bismo konstatirali da su nezavisni jer još treba vrijediti $P(A \cap B \cap C) = P(A) \cdot P(B) \cdot P(C)$ što ovdje nije slučaj. Naime, $A \cap B \cap C = \{(4,5),(6,3)\}$ pa je $P(A \cap B \cap C) = 2/36 = 1/18$, a $P(A) \cdot P(B) \cdot P(C) = 1/2 \cdot 1/2 \cdot 1/9 = 1/36$. Dakle

$$P(A \cap B \cap C) \neq P(A) \cdot P(B) \cdot P(C)$$

pa događaji A, B i C nisu nezavisni.

[10] I ovdje smo se, kao u prošlom primjeru, mogli pozvati na Primjer 4.2.1 da bi pokazali da je vjerojatnost od A jednaka broju elemenata od A podijeljenim s brojem elemenata od Ω, ali smo htjeli istakuti činjenicu da se takve vjerojatnosti računaju lagano po definiciji vjerojatnosti. Naravno, ovi su svi računi jednostavni s obzirom da imamo uniformnu vjerojatnost pa sve račune možemo provesti pozivajući se na naivnu defincju vjeorjantosti. No, što ako vjerojatnost nikje uniformna?

Za vježbu probajte naći tri događaja za koje je $P(A \cap B \cap C) = P(A) \cdot P(B) \cdot P(C)$, ali nikoja dva nisu u parovima nezavisni (uputa: na istom vjerojatnosnom prostoru gledajte događaje "na prvoj kocki je pao broj 1,2 ili 3", "na prvoj kocki je pao broj 3, 4, ili 5" i događaj "zbroj brojeva na obje kocke je jednak 9"). □

Često se u problemima dolazi do situacije da trebamo provjeriti da li su komplementi nezavisnih događaja nezavisni. Dobra je stvar što to uvijek vrijedi, kao što pokazuje sljedeća propozicija.

Propozicija 4.3.5. *Neka su A i B nezavisni slučajni događaji na nekom vjerojatnosnom prostoru $(\Omega, \mathcal{F}, P)$. Tada su nezavisni i slučajni događaji A i B^c, kao i A^c i B te A^c i B^c.*

Dokaz. U pravilu u ovoj skripti ne navodimo formalne dokaze, ali dokaz ove propozicije je elementaran i dobra prilika za vježbu korištenja osnovnih svojstava vjerojatnosti.
Dokažimo najprije da su A i B^c nezavisni. Kao što smo već naučili, da bi to dokazali trebamo pokazati da vrijedi

$$P(A \cap B^c) = P(A)P(B^c). \tag{4.7}$$

U tu svhu razmislimo najprije koji su elementi događaja $A \cap B^c$. To su svi oni elementi prostora elementarnih događaja Ω koji su u A i nisu u B. Dakle, $A \cap B^c = A \setminus B$. Uočimo dodatno da ne možemo od A izuzeti neke elemente koji već nisu u njemu pa je zapravo

$$A \cap B^c = A \setminus (A \cap B).$$

Kako je $A \cap B \subset A$ prema svojstvu (3) u Propoziciji 4.1.3 dobivamo da je

$$P(A \cap B^c) = P(A \setminus (A \cap B)) = P(A) - P(A \cap B).$$

Zbog nezavisnosti je $P(A \cap B) = P(A)P(B)$ pa dobivamo

$$P(A \cap B^c) = P(A) - P(A)P(B) = P(A)(1 - P(B)) = P(A)P(B^c),$$

pri čemu smo u zadnjoj jednakosti iskoristili formulu za vjerojatnost suprotnog događaja (svojstvo (2) u Propoziciji 4.1.3). No sada smo gotovi jer smo dokazali da vrijedi relacija (4.7) što znači da su A i B^c nezavisni.
Ostale tvrdnje iz propozicije slijede iz upravo dokazanoga. Naime, ako zamijenimo mjesta od A i B^c, onda vidimo da imamo dokazano da su B^c i A nezavisni pa kao i gore zaključimo da su B^c i A^c nezavisni. No, onda su nezavisni i A^c i $(B^c)^c = B$, što smo željeli pokazati. □

4.4 Nezavisno izvođenje slučajnih eksperimenata - produktna vjerojatnost

Vidjeli smo da je nezavisnost velikog broja događaja zapravo prilično teško provjeriti u praksi. Ipak, jedan od načina na koji se prirodno pojavljuje nezavisnost je nezavisno ponavljanje slučajnog eksperimenta. Primjerice, bacimo simetrični novčić i bez obzira na ishod bacanja ponovimo bacanje simetričnog novčića. Vjerojatnost da će u prvom bacanju pasti glava je $1/2$, a kako je drugo bacanje novčića nezavisno opet je vjerojatnost da će pasti glava jednaka $1/2$. No ta nezavisnost bacanja znači i da je vjerojatnost da će "u prvom bacanju novčića pasti glava i u drugom bacanju novčića pasti glava" jednaka umnošku prve i druge vjerojatnosti, odnosno $1/2 \cdot 1/2$.

Ovo je samo poseban slučaj općenite situacije (s kojom ćemo se još susresti). Za sada ćemo uočiti sljedeće: recimo da neki slučajan eksperiment modeliramo prostorom elementarnih događaja Ω_1 i da ga ponavljamo dva puta na nezavisan način (sada pod nezavisnošću mislimo i u kontekstu stvarnog svijeta, odnosno da ishodi u jednom ponavljanju ne utječu na ishode u drugom ponavljanju i obratno). Onda je prirodno dva nezavisna ponavljanja tog eksperimenta modelirati Kartezijevim produktom skupa Ω_1 sa samim sobom, odnosno, prirodno je definirati novi prostor elementarnih događaja $\Omega = \Omega_1 \times \Omega_1 = \Omega_1^2$. Iz definicije Kartezijevog produkta znamo da je

$$\Omega = \{\omega = (\omega_1, \omega_2) \mid \omega_1, \omega_2 \in \Omega_1\}.$$

Vidjeli smo, kod pravila umnoška, da je $|\Omega| = |\Omega_1| \cdot |\Omega_1|$.

Paradigmatski slučaj u kojoj se pojavljuje ovakva situacija je uzastopno bacanje simetričnog novčića. Tada je $\Omega_1 = \{P, G\}$. Ukoliko novčić bacamo dva puta, onda je $\Omega = \{P, G\} \times \{P, G\} = \{(P, P), (P, G), (G, P), (G, G)\}$. Slično, ako bacamo kockicu dva puta uzastopno onda je $\Omega_1 = \{1, 2, 3, 4, 5, 6\}$, a $\Omega = \Omega_1 \times \Omega_1$. U Primjeru 3.2.9 smo naveli sve elemente skupa Ω u tom slučaju.

Ovako uvedeni prostor elementarnih događaja se naziva **produktni prostor elementarnih događaja**. Ako je P_1 vjerojatnost na Ω_1, onda je $P := P_1 \times P_1$ vjerojatnost na Ω. Pripadna σ-algebra je produktna σ-algebra koju nećemo posebno razmatrati, ali na taj način dobivamo **produktni vjerojatnosni prostor**. U diskretnom slučaju je za σ-algebru na Kartezijevom produktu $\Omega = \Omega^2$ moguće jednostavno uzeti $\mathcal{P}(\Omega)$.
Produktna vjerojatnost P se na produktnom prostoru elementarnih događaja Ω definira na sljedeći način: ako je $A \times B \subset \Omega$ događaj na produktnom skupu Ω, a tako upravo izgledaju događaji na Ω, onda je

$$P(A \times B) = P_1(A) \cdot P_1(B). \tag{4.8}$$

Ako malo razmislimo vidimo da se na ovaj način prirodno pojavljuje nezavisnost događaja. Vratimo se na primjer dva bacanja simetričnog novčića i neka je E slučajni događaj da će "u prvom bacanju pasti glava" i F slučajni događaj da će "u drugom bacanju pasti glava". E i F su događaji iz $\Omega = \Omega_1^2 = \{P, G\}^2$ i to takvi da je $E = \{G\} \times \Omega_1$ i $F = \Omega_1 \times \{G\}$. Tada je $E \cap F = \{G\} \times \{G\}$. Ako je P_1 vjerojatnost na Ω_1 te $A = \{G\}$ i $B = \{G\}$, onda prema (4.8) imamo

$$P(E \cap F) = P(A \times B) = P_1(A)P_1(B) = P_1(\{G\})P_1(\{G\}) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

S druge strane je, opet prema definiciji produktne vjerojatnosti dane u (4.8),

$$P(E) = P(\{G\} \times \Omega_1) = P_1(\{G\})P_1(\Omega) = \frac{1}{2} \cdot 1 = \frac{1}{2},$$

a na isti način vidimo da je $P(F) = 1/2$. No, onda zaključujemo da je

$$\frac{1}{4} = P(E \cap F) = P(E)P(F) = \frac{1}{2} \cdot \frac{1}{2}$$

pa su događaji E i F nezavisni. Uočite, oni su nezavisni u osnovi samo zato što se odnose svaki na svoje bacanje novčića, a za bacanja novčića smo pretpostavili da su nezavisna (jedno bacanje ne utječe na drugo i obratno).

U gornjem izračunu nije igrala presudnu ulogu činjenica da je novčić simetričan. Pretpostavimo da nije simteričan, odnosno da je $P_1(\{G\}) = 0,6$, a $P_1(\{P\}) = 0,4$. Uz iste oznake kao prije dobivamo $P(E \cap F) = 0,36$ te $P(E) = P(F) = 0,6$. Stoga opet dobivamo da je $P(E \cap F) = P(E)P(F)$ pa su E i F nezavisni događaji.

Kao što vidimo, nezavisno ponavljanje eksperimenata prirodno vodi do nezavisnih događaja (ako se događaji odnose na različita ponavljanja eksperimenta). Vrijedi napomenuti da se nezavisno ponavljanje eksperimenata može odnositi kako na uzastopno (vremenski) ponavljanje jednog te istog slučajnog eksperimenta, tako i na istovremeno izvođenje istih slučajnih eksperimenata. Konstrukcija produktnog prostora koju smo naveli primjenjiva je u oba slučaja, pri čemu pretpostavljamo nezavisno izvođenje slučajnih eksperimenata.

Konstrukcija produktnog vjerojatnosnog prostora ima direktnu vezu s naivnom definicijom vjerojatnosti, a poveznica je pravilo umnoška. Ako, primjerice, ponavljamo dva puta neki slučajni eksperiment koji opisujemo prostorom slučajnih događaja Ω_1 ima n elemenata te imamo slučajni događaj A s a elemenata i slučajni događaj B s b elemenata, onda je s

$$P(A \times B) = \frac{a}{n}\frac{b}{n}$$

dana vjerojatnost da će se u prvom ponavljanju slučajnog eksperimenta dogoditi A i u drugom dogoditi B. Uočite vezu s pravilom umnoška i odabirima objekata s ponavljanjem (u opisanoj situaciji ponavljanja slučajnog eksperimenta zaista uzastopno odabiremo elemente s ponavljanjem - svaki puta ispočetka možemo odabrati sve elemente).

Dosta je jasno da nema posebnog razloga da se navedena konstrukcija ograniči na dva ponavljanja slučajnog eksperimenta. Ona se prirodno proširuje na n, $n \in \mathbb{N}$, nezavisnih ponavljanja slučajnog eksperimenta.[11] Ukoliko je Ω_1 prostor elementarnih događaja koji opisuje ishode nekog slučajnog eksperimenta koji nezavisno ponavljamo n puta te P_1 vjerojatnost na Ω_1, onda se produktni prostor elementarnih događaja definira kao

$$\Omega = \underbrace{\Omega_1 \times \Omega_1 \times \ldots \times \Omega_1}_{n \text{ puta}} = \Omega_1^n,$$

a produktna vjerojatnost kao

$$P(A_1 \times A_2 \times \ldots \times A_n) = P_1(A_1) \cdot P_1(A_2) \cdot \ldots \cdot P_1(A_n), \tag{4.9}$$

gdje su $A_1, A_2, \ldots, A_n \subset \Omega_1$ slučajni događaji. Opet, u slučaju diskretnih vjerojtnosnih prostora, za σ-algebru na Ω možemo uzeti $\mathcal{P}(\Omega)$ pa na taj način dobivamo produktni vjerojatnosni prostor.

Pogledajmo kako bismo izračunali vjerojatnosti slučajnih događaja iz Primjera 3.2.8.

Primjer 4.4.1 (Nastavak Primjera 3.2.8)**.** U Primjeru 3.2.8 smo definirali produktni prostor elementarnih događaja koji modelira 10 nezavisnih bacanja novčića. Pretpostavimo da je novčić simetričan.
Pojedinačno bacanje novčića opisuje prostor elementarnih događaja $\Omega_1 = \{0, 1\}$ pri čemu smo proveli uobičajenu identifikaciju (bijekciju) $P \equiv 0$ i $G \equiv 1$. U skladu s gornjim razmatranjima je prostor elementarnih događaja Ω koji opisuje 10 nezavisnih bacanja tog novčića jednak Kartezijevom produktu Ω_1^{10}, odnosno

$$\Omega = \{(\omega_1, \omega_2, \ldots, \omega_{10}) \mid \omega_j \in \{0, 1\}, j = 1, 2, \ldots, 10\}.$$

U kontekstu formalne definicije vjerojatnosti Ω je produktni vjerojatnosni prostor. Na njemu je zadana vjerojatnost P za koju vrijedi da je

$$P(E_1 \times E_2 \times \ldots \times E_{10}) = P_1(E_1)P(E_2)\ldots P(E_{10}),$$

gdje su E_i slučajni događaji iz Ω_1, $i = 1, 2, \ldots, 10$, a P_1 je vjerojatnost na Ω_1 za koju je $P_1(\{0\}) = 1/2$ i $P_1(\{1\}) = 1/2$ zbog pretpostavke o simetričnosti novčića.

[11] A zapravo i na prebrojivo beskonačan slučaj.

Koristeći oznake iz Primjera 3.2.8 s A_j označavamo slučajni događaj "u j-tom bacanju je pala glava", $j = 1, 2, \ldots, 10$. U skladu s prirodom problema i prethodnim napomenama u ovom potpoglavlju A_j i A_k su nezavisni za $j \neq k$, $j, k = 1, 2, \ldots, 10$. Za vježbu pokažimo da su A_1 i A_2 nezavisni. Na skupovnoj razini je

$$A_1 = \{1\} \times \underbrace{\Omega_1 \times \ldots \times \Omega_1}_{9 \text{ puta}} \quad \text{i} \quad A_2 = \Omega_1 \times \{1\} \times \underbrace{\Omega_1 \times \ldots \times \Omega_1}_{8 \text{ puta}},$$

dok je na razini elemenata

$$A_1 = \{(1, \omega_2, \ldots, \omega_{10}) \mid \omega_j \in \{0, 1\}, 2 \leq j \leq 10\} \text{ te}$$

$$A_2 = \{(\omega_1, 1, \omega_3, \ldots, \omega_{10}) \mid \omega_j \in \{0, 1\}, j = 1, 3, 4 \ldots, 10\}.$$

Očito je, prema definiciji produktne vjerojatnosti,

$$P(A_1) = P_1(\{1\})P_1(\Omega_1) \ldots P_1(\Omega_1) = \frac{1}{2} \cdot \underbrace{1 \cdot 1 \cdot \ldots \cdot 1}_{9 \text{ puta}} = \frac{1}{2},$$

a na isti način vidimo da je $P(A_2) = 1/2$. S druge strane je

$$A_1 \cap A_2 = \{1\} \times \{1\} \times \underbrace{\Omega_1 \times \ldots \times \Omega_1}_{8 \text{ puta}}$$

pa je

$$P(A_1 \cap A_2) = P_1(\{1\})P_1(\{1\})P_1(\Omega_1) \ldots P_1(\Omega_1) = \frac{1}{2} \cdot \frac{1}{2} \cdot \underbrace{1 \cdot 1 \cdot \ldots \cdot 1}_{8 \text{ puta}} = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

Dakle, $P(A_1 \cap A_2) = P(A_1)P(A_2)$[12] pa su A_1 i A_2 nezavisni slučajni događaji prema definiciji nezavisnosti, odnosno prema relaciji (4.6). Slično se provjeri da su i A_i, A_j, A_k nezavisni događaji za $i \neq j \neq k$ kao i kombinacije višeslučajnih događaja A_j.
Uz nezavisnost događaja A_j lagano izračunamo vjerojatnost događaja C. Naime, zbog nezavisnosti je

$$P(C) = P\Big(\bigcap_{j=1}^{10} A_j\Big) = P(A_1 \cap \ldots \cap A_{10}) = P(A_1) \cdot \ldots \cdot P(A_{10}) = \prod_{j=1}^{10} P(A_j) = \prod_{j=1}^{10} \frac{1}{2} = \frac{1}{2^{10}}.$$

Pogledajmo kako bismo izračunali vjerojatnost događaja B. Sjetimo se, događaj B je definiran ako "u 10 bacanja je barem jednom pala glava". Najčešće je vjerojatnost takvih događaja lakše računati[13] ako se najprije izračuna vjerojatnost suprotnog događaja, odnosno vjerojatnost $P(B^c)$. Naime, B^c je slučajan događaj "u 10 bacanja niti jednom nije pala glava", odnosno "u svih 10 bacanja je palo pismo". Uočite da je, na primjer, događaj "u prvom bacanju je palo pismo" zapravo jednak A_1^c pa je

$$B^c = \bigcap_{j=1}^{10} A_j^c.$$

[12] Sve navedene izračune vjerojatnosti možemo dosta jednostavnije i intuitivnije izračunati koristeći se naivnom definicijom vjerojatnosti. Na primjer, vjerojatnost događaja A_1 možemo izračunati na sljedeći način: Ω_1^{10} ima 2^{10} elemenata, a A_1 ima 2^9 elemenata jer je u prvom bacanju "fiksiran" ishod 1 (glava), a u sljedećih 9 bacanja može pasti bilo koja kombinacija 0 i 1 pa dobivamo broj elemenata korištenjem pravila umnoška. Dakle, vjerojatnost od A_1 je jednaka $2^9/2^{10} = 1/2$. Za ovakav način argumentacije je ključno da su svih 2^{10} ishoda bacanja novčića jednako vjerojatni. No, što ako novčić nije simetričan?

[13] Alternativno se može iskoristiti vjerojatnosni analogon formule uključivanja-isključivanja, odnosno prošireno svojstvo (5) iz Propozicije 4.1.3, ali to u pravilu vodi na složenije račune.

Formalno do istog zaključka dolazimo ako primijenimo De Morganovo pravilo za uniju događaja (razmislite!) jer je

$$B^c = (\bigcup_{j=1}^{10} A_j)^c = \bigcap_{j=1}^{10} A_j^c.$$

Sada smo skoro gotovi. Jer su slučajni događaji $A_1, \ldots, A_{10}$ nezavisni, prema Propoziciji 4.3.5 su nezavisni i slučajni događaji $A_1^c, \ldots, A_{10}^c$. Kako je $P(A_j^c) = 1/2$ dobivamo

$$P(B^c) = P_1(A_1^c) \cdot P_1(A_2^c) \cdot \ldots P_1(A_{10}^c) = \frac{1}{2^{10}}.$$

Iskoristimo formulu za vjerojatnost suprotnog događaja (svojstvo (2) u Propoziciji 4.1.3) da dobijemo

$$P(B) = 1 - P(B^c) = 1 - \frac{1}{2^{10}}.$$

Možda vam se ovaj račun ne čini previše jednostavnim, ali uz malo vježbe vidjet ćete da on u osnovi jeste jednostavan: iskoristili smo De Morganovo pravilo i formulu za izračun vjerojatnosti suprotnog događaja. Uočite da intuitivno možemo interpretirati dobivenu vjerojatnost slučajnog događaja B. Naime, ako razmišljamo u terminima povoljnih i nepovoljnih ishoda za događaj B (dakle, kroz prizmu formule naivne vjerojatnosti) možemo uočiti da zapravo samo u jednom ishodu 10 uzastopnih nezavisnih bacanja novčića neće pasti niti jedna glava, a to je slučaj kada će pasti 10 pisama. No to znači da je broj povoljnih ishoda za događaj B jednak $2^{10} - 1$, a zapravo je

$$1 - \frac{1}{2^{10}} = \frac{2^{10} - 1}{2^{10}}.$$

Ostaje nam za izračunati vjerojatnosti slučajnog događaja D, no to je sada lagano za napraviti jer smo već prilikom izračuna vjerojatnosti $P(B^c)$ predstavili sve potrebne argumente. Naime, iskoristimo da su A_1^c, A_2^c i A_3^c nezavisni. Jer je $D = A_1^c \cap A_2^c \cap A_3^c$, zbog nezavisnosti imamo

$$P(D) = P(A_1^c)P(A_2^c)P(A_3^c) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{2^3}.$$

Time smo izračunali vjerojatnosti svih događaja definiranih u Primjeru 3.2.8. □

Primjer 4.4.2 (de Méréov problem)**.** Sljedeći problem je postavio (zapitao se) Francuz Chevaliere de Méré za potrebe igara na sreću, odnosno oklada koje je stavljao na ishode bacanja igraćih kockica. Više o povijesnoj pozadini problema može se naći u Problemu 3 u [7].

Zadan je događaj $A =$ "u 4 bacanja igraće kockice će pasti barem jedna šestica" i događaj $B =$ " u 24 bacanja dvije kockice će barem jednom pasti dvostruka šestica" (pasti će šestice na obje kockice). Koja je od te dvije vjerojatnosti veća? Kao što ćemo vidjeti, vjerojatnosti tih događaja se razlikuju iako bi se moglo intuitivno činiti da bi mogle biti jednake jer u drugom slučaju trebamo dvije šestice u istom bacanju, ali imamo na raspolaganju šest puta više bacanja.

Obje je vjerojatnosti prilično lako izračunati, s time da u oba slučaja pomaže gledati suprotne događaje $A^c =$ "u 4 bacanja igraće kocke nije pala niti jedna šestica" i $B^c =$ "u 24 bacanja igraće kocke nije niti jednom pala dvostruka šestica." Naravno, pretpostavljamo da su bacanja kockica nezavisna. Da bi izračunali prvu vjerojatnost gledamo (produktni) vjerojatnosni prostor $\Omega = \Omega_1^4$, gdje je $\Omega_1 = \{1, 2, 3, 4, 5, 6\}$. Slično kao u prošlom zadatku uočimo da je

$$A^c = \bigcap_{i=1}^{4} A_i,$$

gdje je A_i = "u i-tom bacanju nije pala šestica", $i = 1, 2, 3, 4$. Naravno, $P(A_i) = 5/6$, gdje je P produktna vjerojatnost na Ω. No, onda je zbog nezavisnosti, a prema formuli za vjerojatnost suprotnog događaja

$$P(A) = 1 - P(A^c) = 1 - P\Big(\bigcap_{i=1}^{4} A_i\Big) = 1 - \prod_{i=1}^{4} P(A_i) = 1 - \prod_{i=1}^{4} \frac{5}{6} = 1 - \Big(\frac{5}{6}\Big)^4 \approx 0,518.$$

Na ovom mjestu vrijedi navesti jednu napomenu. U prošlom primjeru smo vrlo detaljno raspisivali (računali) produktne vjerojatnosti slučajnih događaja. Tako bi u ovom slučaju, uz oznaku P_1 za uniformnu vjerojatnost na Ω_1 imali

$$P(A_1) = P(\{1, 2, 3, 4, 5\} \times \Omega_1 \times \Omega_1 \times \Omega_1) = P_1(\{1, 2, 3, 4, 5\}) P_1(\Omega_1)^3 = \frac{5}{6} \cdot 1^3 = \frac{5}{6}$$

i slično za A_2, A_3 i A_4. U nastavku nećemo tako detaljno raspisivati izračun produktnih vjerojatnosti, ali je dobro imati na umu što se događa "u pozadini". Ako niste sigurni u argumentaciju pogledajte ponovno prethodni primjer. Zapamtite da su bacanja nezavisna i da smo za takvo izvođenje slučajnih eksperimenata definirali produktni prosotor elementarnih događaja i produktnu vjerojatnost. Uočite da su slučajni događaji koji se odnose na različita nezavisna izvođenja slučajnog eksperimenta kojega analiziramo i sami nezavisni. U vjerojatnosnoj literaturi nije neuobičajeno prilikom rješavanja ovakvih problema izostaviti definiciju produktnog prostora implicitno pretpostavljajući da su vjerojatnosti s kojima se radi definirane na njemu.
Vjerojatnost događaja B izračunamo na sličan način. Naime,

$$B^c = \bigcap_{i=1}^{24} B_i,$$

gdje je B_i = "u i-tom bacanju nije pala dvostruka šestica", $i = 1, 2, \ldots, 24$. U ovom slučaju je (produktni) prostor na kojem je definirana vjerojatnost P prostor elementarnih događaja $\Omega = \Omega_2$, gdje je $\Omega_2 = \{(\omega_1, \omega_2) \mid \omega_1, \omega_2 = 1, 2, 3, 4, 5, 6\}$. Kao i prije uočimo da je $P_2(B_i) = 35/36$, $i = 1, 2, \ldots, n$, gdje je P_2 uniformna vjerojatnost na Ω_2. Opet, zbog nezavisnosti događaja B_i i formule za vjerojatnost suprotnog događaja imamo

$$P(B) = 1 - P(B^c) = 1 - P\Big(\bigcap_{i=1}^{24} B_i\Big) = 1 - \prod_{i=1}^{24} P_2(B_i) = 1 - \prod_{i=1}^{24} \frac{35}{36} = 1 - \Big(\frac{35}{36}\Big)^{24} \approx 0,491.$$

Kao što vidimo prvi događaj je vjerojatniji. Možemo se zapitati koliko zapravo treba bacanja da bi vjerojatnost događaja B bila veća od $0,5$.[14] U tu svrhu uočimo da je za n, $n \in \mathbb{N}$, bacanja dvije kockice vjerojatnost da će pasti barem dvije šestice jednaka

$$1 - \Big(\frac{35}{36}\Big)^n.$$

Uočite da je $(35/36)^n$ padajuća funkcija (kada n raste taj broj pada) pa je cijela ta vjerojatnost rastuća funkcija. Stoga možemo tražiti n za koji je $1 - (35/36)^n \geq 0,5$. Ispada da je za $n = 25$ to zadovoljeno (naravno, i za sve veće vrijednosti n). □

Napomena 4.4.3 (Frekventistička i bayesovska interpretacija vjerojatnosti)**.** U ovom poglavlju izlažemo osnove, tako zvane, aksiomatske teorije vjerojatnosti. Ona je osnova suvremene teorije vjerojatnosti, uključujući i primjene u statistici, i u zadnjih 50, 60

[14] U kladenju je to rijetkost, ali ako se igra u kojoj je vjerojatnost dobitka veća od $0,5$ igra velik broj puta, onda će očekivani dobitak biti pozitivan. S pojmom očekivanja ćemo se upoznati malo kasnije u skripti.

godina je postigla izniman napredak. U tom smislu je takav pristup teoriji vjerojatnosti standardan i praktički općeprihvaćen. S druge strane, priroda vjerojatnosti i njena veza sa "stvarnim" svijetom podložna je interpretacijama, odnosno različitim pogledima na vjerojatnost. Dvije osnovne interpretacije vjerojatnosti su frekventistička i bayesovska.
Frekventistički pogled na vjerojatnost pretpostavlja da su vjerojatnosti objektivne karakteristike stvarnog svijeta. Vjerojatnost možemo opažati kroz relativne frekvencije (slučajnih) događaja. Što su relativne frekvencije? Ako je E neki događaj vezan uz ishode slučajnog eksperimenta i ako taj slučajni eksperiment ponavljamo n puta, onda možemo brojiti ishode slučajnog eksperimenta u kojima se pojavljuje događaj E. Označimo takve ishode s n_E. Relativna frekvencija događaja E je tada

$$\frac{n_E}{n}.$$

U skladu s frekventističkim pogledom na prirodu vjerojatnosti, kada n raste, odnosno kada povećavamo broj izvođenja slučajnog eksperimenta, relativna frekvencija događaja E se sve više približava vjerojatnosti događaja E. Konkretno, ako bacamo simetričan novčić puno puta i E je događaj "na novčiću je pala glava", onda će se omjer broja slučajeva u kojima je pala glava u odnosu na ukupan broj bacanja približavati $1/2$ za velik broj bacanja novčića. Dakle, vjerojatnost da će pasti glava na novčiću je $1/2$.
Bayesovski pogled na vjerojatnost pretpostavlja da vjerojatnost predstavlja stupanj subjektivnog uvjerenja u ishode nekog slučajnog eksperimenta. Kako se mijenjaju dostupne informacije vezane uz taj slučajni eksperiment tako se mogu mijenjati i pripadne vjerojatnosti. Ovakav pogled na prirodu vjerojatnosti ima implikacije i na statistiku, ali ovdje nećemo dublje ulaziti u tu problematiku.
Na frekventistički i bayesovski pogled na vjerojatnost može se gledati i kao na komplementarne koncepte. Činjenica je da se neke slučajne eksperimente (rezultati nogometne utakmice, rezultati izbora, ulazak ekonomije u recesiju) ne može ponavljati puno puta i ima smisla razmisliti kako tada pristupiti procjenama vjerojatnosti. Temelj bayesovskog pogleda na vjerojatnost je zasnovan na pojmu uvjetne vjerojatnosti koji uvodimo u sljedećem potpoglavlju. Uvjetne vjerojatnosti nam daju mogućnost da prilagođavamo vjerojatnosti ishoda slučajnih eksperimenata novim informacijama koje su nam dostupne. □

4.5 Uvjetna vjerojatnost

U ovom potpoglavlju uvodimo pojam uvjetne vjerojatnosti. Uvjetne vjerojatnosti nam pružaju alat kojim možemo uključiti neke informacije koje znamo o ishodu određenog slučajnog eksperimenta u izračun vjerojatnosti slučajnog događaja koji nas zanima. Također, pomoću njih je moguće rastaviti neke složenije vjerojatnosne probleme na jednostavnije što u konačnici omogućava izračun vjerojatnosti nekih slučajnih događaja. Sljedeća definicija uvodi pojam uvjetne vjerojatnosti.

Definicija 4.5.1. Neka je $(\Omega, \mathcal{F}, P)$ vjerojatnosni prostor i neka je $C \in \mathcal{F}$ slučajni događaj takav da je $P(C) > 0$. Za proizvoljni slučajni događaj A iz $\mathcal{F}$ definiramo **uvjetnu vjerojatnost** od A u odnosu na C, u oznaci $P(A \mid C)$, kao

$$P(A \mid C) := \frac{P(A \cap C)}{P(C)}. \tag{4.10}$$

Intuitivno, uvjetnu vjerojatnost $P(A \mid C)$ možemo interpretirati kao vjerojatnost da će se dogoditi slučajni događaj A ako znamo da se dogodio slučajni događaj C. Na primjer, neka je A događaj "danas će padati kiša". Ako ne znamo ništa drugo (recimo da

ne znamo vremensku prognozu za taj dan), onda nećemo moći puno reći o vjerojatnosti događaja A. Gotovo da možemo odrediti našu procjenu o tome da li će pasti kiša ili ne u skladu sa slučajnim bacanjem simetričnog novčića: ako padne pismo padat će kiša, a ako padne glava neće padati kiša (ili obratno).

No, ako smo u prilici pogledati nebo, onda ćemo steći novu informaciju koja će nam pomoći u izračunu vjerojatnosti događaja A. Neka je C događaj "na nebu su teški crni oblaci". Znajući to, procjenit ćemo da je dosta izvjesno da će padati kiša pa ćemo izgledno povećati procjenu vjerojatnosti slučajnog događaj A bliže 1. Ta vjerojatnost slučajnog događaja A uz informaciju sadržanu u događaju C je zapravo uvjetna vjerojatnost od A u odnosu na C, odnosno $P(A \mid C)$. Pogledajmo neke primjere računanja uvjetne vjerojatnosti.

Primjer 4.5.2. Uzmimo slučajni eksperiment bacanja dvije kockice. Neka je slučajni događaj A "zbroj brojeva na dvije kockice je jednak 9", a slučajni događaj C je "na prvoj kockici je pao broj 4". S obzirom da je $A = \{(3,6),(4,5),(5,4),(6,3)\}$ znamo da je $P(A) = 4/36 = 1/9$. Ako imate dvojbe oko izračuna ove vjerojatnosti pogledajte ponovno Primjer 3.2.9.
Izračunajmo uvjetnu vjerojatnost $P(A \mid C)$. Prema definiciji 4.5.1 trebamo izračunati $P(C)$ i $P(A \cap C)$. $P(C) = 1/6$ jer je $C = \{(4,1),(4,2),(4,3),(4,4),(4,5),(4,6)\}$. S druge strane je $A \cap C = \{(4,5)\}$ pa je

$$P(A \mid C) = \frac{P(A \cap C)}{P(C)} = \frac{1/36}{1/6} = \frac{1}{6}.$$

Vidimo da se vjerojatnost događaja A promijenila ako znamo da se dogodio događaj C. Intuitivno, saznanje da se dogodio događaj C je smanjilo mogući broj izbora na njih 6, a samo jedan od tih 6 izbora je bio sadržan i u događaju A. Stoga je tražena uvjetna vjerojatnost jednaka $1/6$. Razmislite: kolika bi bila vjerojatnost od A uz uvjet da je na prvoj kockici pao broj 2? □

Primjer 4.5.3 (Nastavak Primjera 3.2.7 i 3.2.13)**.** Sjetimo se primjera slučajnog odabira jedne od dekadskih znamenki. Tamo smo definirali skupove $A = \{0,3,4,7\}$ i $B = \{4,5,6,8,9\}$. Koristeći terminologiju uvedenu u ovom poglavlju možemo reći da smo na $\Omega = \{0,1,2,3,4,5,6,7,8,9\}$ uveli uniformnu vjerojatnost P uz koju je vjerojatnost odabira bilo koje dekadske znamenke jednaka $1/10$. U Primjeru 3.2.13 smo jednostavno izračunali vjerojatnosti slučajnih događaja A, B i $A \cap B$[15] te dobili

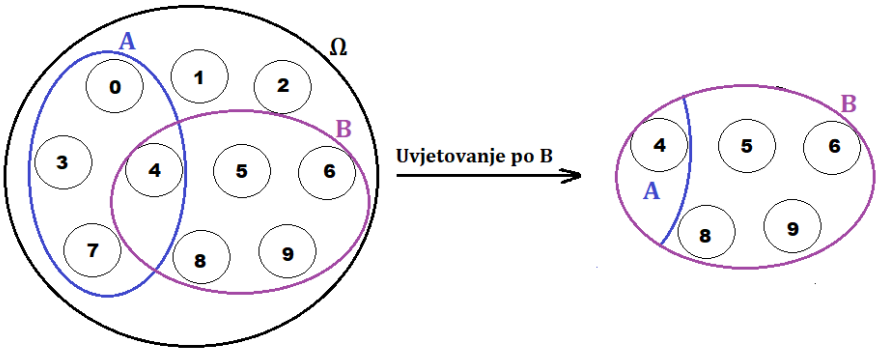
$$P(A) = \frac{4}{10}, \quad P(B) = \frac{5}{10} \quad \text{i} \quad P(A \cap B) = \frac{1}{10}.$$

Prema formuli (4.10) lagano izračunamo uvjetnu vjerojatnost $P(A \mid B)$ jer je

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{1/10}{5/10} = \frac{1}{5}.$$

Računski je sve jasno, ali se možemo zapitati što se tu događa na razini elemenata (jednostavan je primjer pa ćemo to moći i zorno pokazati). Odakle se pojavljuje ta jedna petina?
Da bi to probali zorno prikazati pogledajte donju sliku. S lijeve strane je slika koju smo iskoristili da bi prikazali događaje A i B u primjeru 3.2.7.

[15] Uočimo ponovno: te vjerojatnosti možemo izračunati i korištenjem svojstva konačne aditivnosti vjerojatnosti. Na primjer, $P(A) = P(\{0\} \cup \{3\} \cup \{4\} \cup \{7\}) = P(\{0\}) + P(\{3\}) + P(\{4\}) + P(\{7\}) = 4/10$.



S desne strane je prikazano što se događa kada gledamo uvjetnu vjerojatnost u odnosu na B. Naime, tada gledamo samo skup B te one elemente skupa A koji su ujedno i elementi skupa B, jer računamo vjerojatnost od $A \cap B$. Ostale elemente događaja A, kao i one iz Ω koje nisu u B, uopće ne uzimamo u obzir. Kao da smo ih izbrisali.[16]
Sada je nova vjerojatnost od A, uz saznanje da se dogodio B, jednaka omjeru dijela skupa A koji se nalazi u B i samog skupa B. Kako skup A čini jednu petinu skupa B dobivamo da je vjerojatnost skupa A u odnosu na B jednaka jednoj petini. Ta vjerojatnost je uvjetna vjerojatnost $P(A \mid B)$.
Uočite opet da se ovakva intuicija može iskoristiti zato što gledamo uniformnu vjerojatnost na Ω pa su svi elementarni događaji jednako vjerojatni. Da nije takva situacija, trebali bi dodatno preraspodjeljivati vjerojatnosti odgovarajućih elemenata da bi izračunali $P(A \mid B)$. Ipak, i uz to ograničenje je intuicija koju nam daje ovaj primjer vrijedna. Naime, razmišljajući o situaciji predstavljenoj u ovom primjeru, može nam se učiniti da je uvjetna vjerojatnost $P(A \mid B)$ zapravo neka nova vjerojatnost koja sada živi na skupu B. Vidjet ćemo uskoro da uvjetna vjerojatnost zaista je vjerojatnost u smislu Definicije 4.1.2. Na ovom mjestu možemo uočiti sljedeće: ako je $B \subset A$, onda su svi elementi iz A koji su ujedno u B zapravo svi elementi od B (formalno $A \cap B = B$). Dakle, uvjetna vjerojatnost od A u odnosu na B je jednaka 1. □

Primjer 4.5.4. U nekoj školi imamo 120 djece od čega njih 60 doma ima psa, dok ih 30 ima mačku. Koja je vjerojatnost da neko djete iz te škole ima mačku ako znamo da ima psa te ako je poznato da 10 djece ima i psa i mačku?
U skladu s prijašnjim oznakama $|\Omega| = 120$ (sva su djeca međusobno različita). Označimo s Pas skup koji sadrži svu djecu koja imaju psa, a s $Maca$ skup koji sadrži svu djecu koja imaju mačku. U primjeru piše da je $|Pas| = 60$, $|Maca| = 30$ i $|Pas \cap Maca| = 10$. Ukoliko se sada pitamo "koja je vjerojatnost da djete iz te škole ima psa", onda zapravo odgovaramo na pitanje "koja je vjerojatnost da slučajno odbarano dijete iz te škole ima psa". Ukupan broj djece je 120, a broj djece koja imaju psa je 60 pa u terminima prebrajanja to znači da dijete možemo odabrati na 120 načina, a djete koje ima psa na 60 načina. Stoga je $P(Pas) = 60/120 = 1/2$. Jasno, $P(Maca) = 30/120 = 1/4$ i $P(Pas \cap Maca) = 10/120 = 1/12$.
Izračunajmo sada (uvjetnu) vjerojatnost da neko dijete ima mačku ako znamo da ima psa. Formalno, u skladu s definicijom 4.5.1, imamo

$$P(Maca \mid Pas) = \frac{P(Pas \cap Maca)}{P(Pas)} = \frac{1/12}{1/2} = \frac{1}{6}.$$

Intuitivno, a na tragu prethodnog primjera, možemo na računanje gornje uvjetne vjerojatnosti gledati kao na spoznaju da se novi vjerojatnosni prostor (vlasnika pasa) smanjio na 60 djece od kojih 10 ima mačku. Onda je jasno da je $P(Maca \mid Pas) = 10/60 = 1/6$.

[16] U slučaju prikazane slike se to doslovno i dogodilo jer je slika napravljena u Paintu i na desnoj strani su izbrisani svi dijelovi s lijeve strane slike, osim skupa B.

Ovo je opet jednostavna situacija u kojoj intuicija može pomoći, ali često nas intuicija može i zavarati pa treba biti oprezan s njenim korištenjem. Uočimo da slučajan odabir jednog djeteta odgovara situaciji u kojoj su svi elementarni događaji jednako vjerojatni (jednaka je vjerojatnost da ćemo odabrati bilo koje dijete) pa je osnovna vjerojatnost na Ω opet uniformna. □

Kao što smo već istaknuli, činjenica da je nešto već poznato o nekom slučajnom eksperimentu mijenja vjerojatnost nekih događaja. Pogledajmo sljedeći jednostavan primjer.

Primjer 4.5.5. Neka obitelj ima dvoje djece. Ako znamo da je jedno djete cura (ženskog spola), koja je vjerojatnost da su oboje djece ženskog spola?
Prostor elementarnih događaja je u ovom slučaju $\Omega = \{(m,z),(z,m),(z,z),(m,m)\}$, uz očite oznake za muško i žensko dijete. Označimo s A događaj "u obitelji je oboje djece ženskog spola". Kada ne bi imali nikakvu dodatnu informaciju onda bi imali

$$P(A) = \frac{|(z,z)|}{|\Omega|} = \frac{1}{4}.$$

Označimo sada događaj "u obitelji je jedno dijete ženskog spola" s C. Jasno $C = \{(m,z),(z,m),(z,z)\}$ pa je $P(C) = 3/4$. Sada je vjerojatnost događaja A ako je poznato da je jedno dijete ženskog spola, dakle uvjetna vjerojatnost od A u odnosu na C, jednaka

$$P(A \mid C) = \frac{P(A \cap C)}{P(C)} = \frac{P(A)}{P(C)} = \frac{1/4}{3/4} = \frac{1}{3}.$$

Uočite, ako je B događaj "prvo dijete je žensko", onda je $B = \{(z,m),(z,z)\}$

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)}{P(B)} = \frac{1/4}{1/2} = \frac{1}{2}.$$

□

Iz dosadašnjih primjera je vjerojatno već jasno da je $P(A \mid B)$ općenito različita vjerojatnost od $P(B \mid A)$. Sljedeći primjer to zorno pokazuje.

Primjer 4.5.6 (Primjer 2.2.2 iz [3])**.** Uzmimo špil od 52 karte (koje su promješane). Izvlačimo dvije karte, jednu po jednu bez vraćanja izvučene karte natrag u špil. Neka je A slučajni događaj "prva izvučena karta je srce", a B slučajni događaj "druga izvučena karta je crvena" (dakle, srce ili karo). Izračunajmo vjerojatnosti $P(A \mid B)$ i $P(B \mid A)$.
Za izračun obje vjerojatnosti nam treba vjerojatnost događaja $A \cap B$. Ukupan broj mogućnosti na koji možemo izvući dvije karte (bez ponavljanja) je $52 \cdot 51$. Broj mogućnosti na koji možemo izabrati prvu kartu da bude srce je 13, a drugu kartu da bude crvena je 25 (već je odabrana jedna crvena karta u prvom izvlačenju). Prema pravilu produkta je

$$P(A \cap B) = \frac{13 \cdot 25}{52 \cdot 51} = \frac{25}{204}.$$

Vjerojatnost događaja A je jednaka $1/4$ (odnosno $13/52$). Da bi izračunali vjerojatnost događaja B rastavimo ga na dva disjunktna događaja $C =$ "u prvom izvlačenju je izvučena crna karta, a u drugom crvena" i $D =$ "u prvom izvlačenju je izvučena crvena karta i u drugom izvlačenju je izvučena crvena karta". Zbog konačne aditivnosti vjerojatnosti imamo

$$P(B) = P(C) + P(D) = \frac{26 \cdot 26}{52 \cdot 51} + \frac{26 \cdot 25}{52 \cdot 51} = \frac{26 \cdot 51}{52 \cdot 51} = \frac{1}{2}.$$

Sada možemo izračunati tražene uvjetne vjerojatnosti. Imamo

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{25/204}{1/2} = \frac{25}{102}$$

i

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)} = \frac{25/204}{1/4} = \frac{25}{51}.$$

Napomenimo da uvjetne vjerojatnosti ne treba promatrati na način da "jedan događaj uzrokuje drugi", nego samo tako da se pitamo što informacije o jednom događaju govore u drugom (i obratno). U tom smislu možemo reformulirati ovaj zadatak na sljedeći način. Umjesto da izvlačimo jednu pa drugu kartu možemo promješane karte rasprostrijeti po stolu i onda lijevom rukom odabrati jednu kartu, a desnom drugu kartu. Rješenje koje smo prikazali ostaje isto ako je A događaj "karta u lijevoj ruci je srce", a B događaj "karta u desnoj ruci je crvena".
Uočimo da vjerojatnost $P(B \mid A)$ odgovara na pitanje "koja je vjerojatnost da će druga izvučena karta biti crvena, ako je prva bila srce". Intuitivno, obavljamo odabir jedne od 25 crvenih karata koje su ostale u špilu od preostale 51 karte. □

Iako uvjetne vjerojatnosti imaju jasno vjerojatnosno značenje, može se činiti da je sam taj koncept donekle umjetan (artificijelan). Ipak, nije tako jer se u nekim vrlo uobičajenim situacijama, poput tabličnog pregleda podataka, vrlo jasno mogu formulirati vjerojatnosti koje su u uvjetnom obliku. Pogledajmo sljedeći primjer.

Primjer 4.5.7 (Instrukcije)**.** Provedeno je istraživanje na nekom fakultetu o učestalosti uzimanja instrukcija po semestru među studentima, pri čemu su se razlikovali redovni i izvanredni studenti. Rezultati su prezentirani u tablici 4.1.

	Broj instrukcija u semestru			
	Nijednom	Jednom ili dva puta	Tri i više puta	Ukupno
Redovni studenti	24	10	16	50
Izvanredni studenti	6	4	8	18
Ukupno	30	14	24	68

Tablica 4.1: Instrukcije koje uzimaju studenti

Sada se možemo pitati koja je vjerojatnost da će student uzeti tri ili više instrukcija u ovisnosti o tome da li je redovni student ili izvanredni student. Zašto bi se to zapitali? Recimo da gore nisu prezentirani podaci s jednog fakulteta, nego za reprezentativni uzorak studenata u RH ili EU. U tom slučaju se takve vjerojatnosti mogu upotrijebiti za procjenu broja studentata kolji uzimaju instrukcije, njihovu učestalost i slično te se dobiveni rezultati mogu koristiti za formiranje politika kako bi se taj broj smanjio ili što se već želi postići.
Koristeći se podacima iz tablice izračunajmo neke vjerojatnosti. Prije svega, izračunajmo vjerojatnost da student uopće ne uzima instrukcije (bez obzira da li je redovni ili izvanredni). Ta je vjerojatnost jednaka $P(\text{student ne uzima instrukcije}) = 30/68 \approx 0,44$.
Pogledajmo da li se ta vjerojatnost razlikuje ako gledamo posebno redovne ili izvanredne studente. U tom slučaju gledamo uvjetne vjerojatnosti. Pogledajmo najprije vjerojatnost

$$p_{0|red} = P(\text{student ne uzima instrukcije} \mid \text{student je redovni}).$$

Po definiciji je ta vjerojatnost jednaka vjerojatnosti presjeka skupova redovnih studenata i onih koji ne uzimaju instrukcije, a to je 24/68 podijeljeno se vjerojatnossću da je student

redovni, a to je 50/68. Dakle

$$p_{0|red} = \frac{16/68}{50/68} = \frac{24}{50} = 0,48.$$

Na isti način dobijemo da je vjerojatnost da student ne uzima instrukcije ako je izvanredni, u oznaci $p_{0|izv}$, jednaka

$$p_{0|izv} = \frac{6}{18} \approx 0,333.$$

Vidimo da se te vjerojatnosti razlikuju, a razlika je izražena i ako gledamo studente koji uzimaju instrukcije 3 ili više puta. Naime, u tom slučaju imamo, uz oznake u skladu s gornjima,

$$p_{3+|red} = \frac{16}{50} = 0,32$$

i

$$p_{3+|izv} = \frac{8}{18} \approx 0,444.$$

Uočimo da se računanje ovakvih uvjetnih vjerojatnosti prirodno računa po recima. Možemo se zapitati i drugačije pitanje poput "koja je vjerojatnost da je student izvanredni ako je išao na instrukcije tri ili više puta"? Sada trebamo izračunati vjerojatnost

$$p_{izv|3+} = P(\text{student je izvanredni} \mid \text{student je uzeo instrukcije 3 i više puta}).$$

Prema definiciji uvjetne vjerojatnosti imamo

$$p_{izv|3+} = \frac{8/68}{24/68} = \frac{8}{24} \approx 0,333.$$

Iako postotno više izvanrednih studenata uzima instrukcije 3 i više puta po semestru nego redovnih (što smo vidjeli prije), vidimo da je veća vjerojatnost da će student koji uzima instrukcije biti redovni,[17] nego izvanredni (0,333). To je posljedica činjenice da je redovnih studenata jednostavno više pa je vjerojatnije da je redovni student išao na instrukcije 3 i više puta, nego da je izvanredni student išao na instrukcije 3 i više puta. □

Napomena 4.5.8 (Frekventistička interpretacija uvjetne vjerojatnosti)**.** U Napomeni 4.4.3 smo vidjeli da se frekventisitčka interpretacija vjerojatnosti oslanja na velik broj nezavisnih ponavljanja nekog slučajnog eksperimenta. Tako za slučajne događaje A i B vezane uz promatrani slučajni eksperiment imamo (očekujemo) da će za velik broj ponavljanje n, $n \in \mathbb{N}$, vrijediti procjena

$$P(A) \approx \frac{n_A}{n} \quad \text{i} \quad P(B) \approx \frac{n_B}{n},$$

gdje su n_A i n_B jednaki broju ponavljanja slučajnog eksperimenta u kojima se dogodio slučajni događaj A, odnosno B. Istom logikom, jer je $A \cap B$ slučajni događaj, možemo očekivati da ćemo imati procjenu

$$P(A \cap B) \approx \frac{n_{A\cap B}}{n},$$

gdje je $n_{A\cap B}$ jednak broju ponavljanja slučajnog eksperimenta u kojima se dogodio slučajni događaj $A \cap B$.

[17] Tu vjerojatnost možemo izračunati, ali i uočiti da je uvjetna vjerojatnost vjerojatnost, kao što ćemo vidjeti uskoro, pa je ona jednaka $1-0,333$ jer je događaj "student je redovni" komplementaran događaju "student je izvanredni.

Vođeni istom logikom, a prema definiciji uvjetne vjerojatnosti, očekujemo da će za n nezavisnih ponavljanja promatranog slučajnog eksperimenta vrijediti procjena

$$P(A \mid B) \approx \frac{n_{A\cap B}/n}{n_B/n} = \frac{n_{A\cap B}}{n_B}.$$

Intuitivno gledano, to znači da da u nezavisnom ponavljanju slučajnih eksperimenata uvjetnu vjerojatnost možemo računati (aproksimirati) tako da izdvojimo ona ponavljanja slučajnog eksperimenta u kojima se dogodio slučajni događaj B, a onda izbrojimo, samo među tim izdvojenim ponavljanjima, koliko je bilo ponavljanja u kojima se dogodio slučajni događaj A pa, dakle, $A \cap B$.
Ukoliko fiksiramo broj ponavljanja promatranog slučajnog eksperimenta n, onda znamo da nezavisno ponavljanje možemo modelirati produktnim prostorom elementarnih događaja $\Omega = \Omega_1^n$, gdje je Ω_1 prostor elementarnih događaja za promatrani slučajni eksperiment (pogledajte potpoglavlje 4.4). Pretpostavimo da je Ω_1 konačan i da je vjerojatnost na njemu uniformna. Tada umjesto n_A, n_B i $n_{A\cap B}$ možemo pisati $|A|$, $|B|$ i $|A \cap B|$ u gore navedenim formulama pri čemu znak za aproksimaciju $\approx$ zamijenimo sa znakom za jednakost. □

4.5.1 Uvjetna vjerojatnost je vjerojatnost

U nekim od primjera smo već indicirali da je uvjetna vjerojatnost zapravo vjerojatnost. Formalno je to posljedica svojstava *a*), *b*) i *e*) u sljedećoj propoziciji. Naime, da bi pokazali da je neka funkcija s prostora elementarnih događaja u segment $[0, 1]$ vjerojatnost trebamo provjeriti svojstva $(1) - (3)$ iz Definicije 4.1.2.

Propozicija 4.5.9. *Neka je $(\Omega, \mathcal{F}, P)$ vjerojatnosni prostor i neka je $C \in \mathcal{F}$ slučajni događaj takav da je $P(C) > 0$. Neka su A i B proizvoljne slučajni događaji iz $\mathcal{F}$. Tada vrijedi*

a) $P(A \mid C) \geq 0$,

b) $P(\Omega \mid C) = 1$,

c) $P(A^c \mid C) = 1 - P(A \mid C)$.

d) Ako su A i B disjunktni, onda je $P(A \cup B \mid C) = P(A \mid C) + P(B \mid C)$.

e) Za $A_i \subset \mathcal{F}$, $i \in \mathbb{N}$, slučajne događaje koji su međusobno disjunktni ($A_i \cap A_j = \emptyset$ za $i \neq j$) vrijedi

$$P\Big(\bigcup_{i\in\mathbb{N}} A_i \mid C\Big) = \sum_{i=1}^{\infty} P(A_i \mid C).$$

Sva svojstva iz ove propozicije se lagano provjere. Jasno je da vrijedi svojstvo *a*) jer je uvjetna vjerojatnost definirana kao razlomak dvije vjerojatnosti. Za svojstvo *b*) uočimo

$$P(\Omega \mid C) = \frac{P(\Omega \cap C)}{P(C)} = \frac{P(C)}{P(C)} = 1.$$

Za svojstvo *d*) iskoristimo distributivnost unije prema presjeku i disjunktnost događaja $A \cap C$ i $B \cap C$ da dobijemo

$$\begin{aligned} P(A \cup B \mid C) &= \frac{P((A \cup B) \cap C)}{P(C)} = \frac{P((A \cap C) \cup (B \cap C))}{P(C)} \\ &= \frac{P(A \cap C) + P(B \cap C)}{P(C)} = P(A \mid C) + P(B \mid C), \end{aligned}$$

a na praktički isti način se pokaže da vrijedi svojstvo e). Uočite, kada se želi istaknuti činjenica da je uvjetna vjerojatnost zapravo vjerojatnost na $(\Omega, \mathcal{F})$ uobičajeno je uvesti oznaku

$$P_C(A) = P(A \mid C),$$

gdje je $A \in \mathcal{F}$ neki slučajan događaj. Taj zapis naglašava činjenicu da je funkcija

$$P_C : \mathcal{F} \to [0, 1]$$

vjerojatnost jer zadovoljava svojstva $(1) - (3)$ iz Definicije 4.1.2. Ova razmatranja pokazuju da se na Ω može definirati velik broj novih vjerojatnosti (za razne slučajne događaje C), što nije samo po sebi svrha uvođenja uvjetne vjerojatnosti, ali je dobro imati na umu.

Kako je uvjetna vjerojatnost vjerojatnost, na nju se mogu primijeniti koncepti koje općenito vrijede za vjerojatnosti. Konkretno, nezavisnost slučajnih događaja ima svoju uvjetnu formu. Uz iste oznake kao u Propoziciji 4.5.9 dodatno pretpostavimo da su slučajni događaji A i C nezavisni. Tada je

$$P(A \mid C) = \frac{P(A \cap C)}{P(C)} = \frac{P(A)P(C)}{P(C)} = P(A).$$

Dobivenu relaciju

$$P(A \mid C) = P(A) \tag{4.11}$$

možemo smatrati alternativnom definicijom nezavisnosti. Ona je, doduše, manje općenita od one iz Definicije 4.3.1 jer ovdje pretpostavljamo da je $P(C) > 0$. Relacija (4.11) nam intuitivno govori da uvjetovanje u odnosu na nezavisni događaj ne donosi nikakvu novu informaciju o vjerojatnosti slučajnog događaja A.

4.5.2 Bayesova formula i formula potpune vjerojatnosti

Iz definicije uvjetne vjerojatnosti vidimo da, množenjem s $P(C)$, dobivamo sljedeću formulu

$$P(A \cap C) = P(A \mid C)P(C). \tag{4.12}$$

Iako se može činiti da je vjerojatnost događaja $A \cap C$ fundamentalnija veličina od uvjetne vjerojatnosti pa zapravo nju želimo izračunati, često je pogodno imati formule poput (4.12). Ponekad je to zato što vjerojatnost presjeka može biti teška za izračun, a ponekad i zato što možemo imati neku (subjektivnu) procjenu vjerojatnosti određenog događaja, kao i uvjetnih vjerojatnosti ako se taj događaj dogodio pa zapravo s desne strane jednakosti u (4.12) imamo poznate vjerojatnosti.
Po simetriji, i ako je $P(A) > 0$, iz Defincije 4.5.1 dobivamo i formulu

$$P(A \cap C) = P(C \mid A)P(A).$$

Zajedno s formulom (4.12) zaključujemo da je

$$P(A \mid C) = \frac{P(C \mid A)P(A)}{P(C)}. \tag{4.13}$$

Ta se formula naziva **Bayesovom formulom** (Bayesovim pravilom) i često je korištena u raznim problemima vezanima uz uvjetne vjerojatnosti ili uz njihove primjene.

Vratimo se natrag na prostor elementarnih događaja Ω te neka je P vjerojatnost na njemu. Neka su $H_1, H_2, \ldots, H_n$, $n \in \mathbb{N}$, događaji iz Ω koji su neprazni i međusobno disjunktni te im je unija jednaka cijelom Ω, tj. $\Omega = \cup_{i=1}^{n} H_i$. Skup događaja $\{H_1, \ldots H_n\}$ se zove **potpun sustav događaja** na Ω. Taj je naziv uobičajen u kontekstu uvjetnih vjerojatnosti, ali uočimo da je zapravo riječ o particiji skupa Ω (pogledajte Primjer 4.2.4).

Uz pretpostavku o postojanju potpunog sustava događaja za slučajni događaj A iz Ω vrijedi **formula potpune vjerojatnosti**

$$P(A) = P(H_1)P(A \mid H_1) + \ldots + P(H_n)P(A \mid H_n) = \sum_{i=1}^{n} P(H_i)P(A \mid H_i). \tag{4.14}$$

Formula potpune vjerojatnosti vrijedi i za prebrojivo mnogo događaja, a za dva događaja poprima oblik

$$P(A) = P(H_1)P(A \mid H_1) + P(H_1^c)P(A \mid H_1^c) \tag{4.15}$$

jer je tada $\Omega = H_1 \cup H_2$. Kako su H_1 i H_2 disjunktni $H_2 = H_1^c$. Ukoliko formulu (4.14) uvrstimo u (4.13) dobijemo izraz (sada je H_i ono što je prije bio A, dok je A ono što je prije bio C)

$$P(H_i \mid A) = \frac{P(H_i)P(A \mid H_i)}{\sum_{j=1}^{n} P(H_j)P(A \mid H_j)},\ i = 1, 2, \ldots n. \tag{4.16}$$

Formula potpune vjerojatnosti (4.14) nam govori da običnu (ne-uvjetnu) vjerojatnost slučajnog događaja možemo izračunati kao vagani zbroj uvjetnih vjerojatnosti, gdje su težine uz uvjetne vjerojatnosti jednake vjerojatnostima događaja koji čine potpun sustav događaja, odnosno particiju skupa Ω. Formula poptune vjerojatnosti nam omogućava da neki složeniji problem rastavimo na više jednostavnijih problema. Utoliko je za njenu primjenu vrlo važan odabir slučajnih događaja H_i. Pogledajmo neke primjere korištenja navedenih formula.

Primjer 4.5.10. U nekom osiguravajućem društvu internim politikama (procjenama rizika) dijele vozače automobila na one koje su skloni nesrećama (automobilskima) i one koji nisu skloni nesrećama. Njihova je procjena da 80% vozača nije sklono nesrećama, dok je 20% vozača sklono nesrećama. Vjerojatnost da će vozač koji je sklon nesrećama imati nesreću unutar godine dana je $0,3$, dok je vjerojatnost da će vozač koji nije sklon nesrećama imati nesreću u sljedećih godinu dana jednaka $0,1$. Koja je vjerojatnost da će vozač koji prvi puta sklapa policu osiguranja s osiguravajućim društvom biti sklon nesrećama?

Odgovor na ovo pitanje je jednostavan. Naime, cijelu populaciju ljudi možemo podijeliti na one sklone nesrećama i one nesklone nesrećama. Ukoliko je novi vozač koji prvi puta dolazi u osiguravajuće društvo slučajno odabran (nema nekog posebnog pravila prema kojem dolazi u osiguravajuće društvo), onda je vjerjatnost da će biti sklon riziku, kao što piše u uvodu primjera, jednaka $0,2$. To možemo izračunati i tako da konstatiramo da ukupno imamo n vozača koji mogu osigurati auto pa je onda $0,2n$ njih sklono nesrećama, a $0,8n$ nesklono nesrećama. Uz moguće malo zaokruživanje, to znači da imamo ukupno n ljudi koje možemo odabrati (skup elementarnih događaja), a događaj koji nas zanima je da je odabran vozač sklon nesrećama i on ima $0,2n$ vozača (elemenata). Stoga je, prema naivnoj definiciji vjerojatnosti, vjerojatnost tog događaja jednaka $0,2n/n = 0,2$.

Pogledajmo sljedeće pitanje (uz iste uvjete): koja je vjerojatnost da će vozač koji prvi puta sklapa policu osiguranja s osiguravajućim društvom imati nesreću u sljedećih godinu dana.

Odgovor na ovo pitanje možemo lagano dati ako znamo da je vozač sklon nesrećama ili nije sklon nesrećama (te su vjerojatnosti dane u uvjetima primjera). Iako ne znamo kakav je točno tip vozača koji je došao u osiguravajuće društvo, znamo vjerojatnosti da je on jednog ili drugog tipa. Stoga je pogodno odgovor na ovo pitanje uklopiti u okvir formule potpune vjerojatnosti. U tu svrhu definirajmo događaje H_1 = "vozač koji je došao u osiguranje je sklon nesrećama" i H_2 = "vozač koji je došao u osiguranje nije sklon nesrećama". Jasno je da su ta dva događaja disjunktna (nema vozača koji je u njihovom presjeku), a ujedno obuhvaćaju sve vozače. Stoga, ako s Ω označimo skup svih

vozača , onda je $\Omega = H_1 \cup H_2$ i $H_1 \cap H_2 = \emptyset$. Dakle, $\{H_1, H_2\} = \{H_1, H_1^c\}$ je potpun sustav događaja. Prema uvjetima primjera znamo da je $P(H_1) = 0,2$, a $P(H_2) = P(H_1^c) = 0,8$. Neka je A događaj "vozač ima nesreću u prvoj godini osiguranja". Prema formuli potpune vjerojatnosti je

$$P(A) = P(H_1)P(A \mid H_1) + P(H_2)P(A \mid H_2) = 0,2 \cdot 0,3 + 0,8 \cdot 0,1 = 0,14,$$

jer je $P(A \mid H_1) = 0,3$, a $P(A \mid H_2) = 0,1$, prema zadanim uvjetima primjera.
Primjenjivost uvjetnih vjerojatnosti, pa i njihov značaj, proizlazi iz njihove prilagodljivosti dodavanju (dolasku) novih informacija. Pretpostavimo da novi vozač koji je došao u osiguravajuće društvo, onaj s početka primjera, ima nesreću u prvoj godini osiguranja. Da li će ta informacije promijeniti nešto u vjerojatnostima s kojima baratamo?
Pitamo se da li informacija o nesreći u prvih godinu dana osiguranja mijenja vjerojatnost da je taj vozač koji je došao u osiguravajuće društvo bio sklon ili nesklon nesrećama. Drugim riječima, želimo izračunati $P(H_1 \mid A)$, odnosno $P(H_2 \mid A)$. To možemo napraviti prema Bayesovoj formuli u (4.13), odnosno primjenom (4.12). Tako imamo

$$P(H_1 \mid A) = \frac{P(H_1 \cap A)}{P(A)} = \frac{P(A \mid H_1)P(H_1)}{P(A)} = \frac{0,3 \cdot 0,2}{0,14} = 0,42857.$$

Vidmo da će uvjetna vjerojatnost da je vozač skloniji nesrećama ako se dogodila nesreća u prvoj godini biti veća od "neutralne" vjerojatnosti da će slučajno odabrani vozač biti sklon nesrećama koja iznosi 0,3. Dodatna informacija je promijenila vjerojatnost događaja koji je i dalje slučajan. Uočimo da uvjetnu vjerojatnost $P(H_2 \mid A)$ ne moramo posebno računati jer je $P_A(\cdot) = P(\cdot \mid A)$ vjerojatnost pa je $P(H_2 \mid A) = P(H_1^c \mid A) = 1 - P(H_1 \mid A) = 0,57143$. □

Primjer 4.5.11. Imamo tri novčića od kojih su dva obična (simetrična), a jedan ima dvije glave. Izvlačimo nasumično jedan novčić i bacimo ga. Koja je vjerojatnost da će na njemu pasti glava?

Ukoliko definiramo H_1 = "izvučen je simetričan novčić", a H_2 = "izvučen je novčić s dvije glave", onda ta dva događaja čine potpun sustav događaja te je $P(H_1) = 2/3$, a $P(H_2) = 1/3$. Neka je A događaj "na novčiću je pala glava". Prema formuli potpune vjerojatnosti imamo

$$P(A) = P(H_1)P(A \mid H_1) + P(H_2)P(A \mid H_2) = \frac{2}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot 1 = \frac{2}{3}.$$

Izračunajmo $P(H_2 \mid A)$, odnosno vjerojatnost da je izvučen novčić s dvije glave ako je u bacanju novčića pala glava. Prema Bayesovoj formuli imamo

$$P(H_2 \mid A) = \frac{P(H_2)P(A \mid H_2)}{P(A)} = \frac{1/3 \cdot 1}{2/3} = \frac{1}{2}.$$

Vidimo da je činjenica da je u bacanju novčića pala glava osnažila pretpostavku (povećala vjerojatnost) da je izvučen novčić s dvije glave (bez te informacije je vjerojatnost tog događaja bila 1/3). □

Pogledajmo jedan primjer u kojem je potpun sustav događaja malo složeniji.

Primjer 4.5.12. Imamo dvije kutije: u prvoj se nalaze 4 plave i 2 crvene kuglice, a u drugoj 2 plave i 4 crvene kuglice. Bacate novčić da odaberete iz koje ćete kutije na slučajan način odabrati jednu kuglicu. Novčić nije potpuno simetričan i glava će pasti s vjerojatnošću 0,55, dok će pismo pasti s vjerojatnošću 0,45. Ukoliko padne glava odabrat ćete prvu kutiju za izvlačenje jedne kuglice, a ukoliko padne pismo odabrat ćete

drugu kutiju. Koja je vjerojatnost da ćete takvim odabirom kutija izvući plavu kuglicu? Koja je vjerojatnost da je odabrana druga kutija ako je izvučena kuglica plava?
Ako malo razmislimo o zadatku vidimo da imamo složen slučajni eksperiment u kojem se zapravo pojavljuju dvije slučajnosti (dva slučajna odabira): prvo bacamo novčić, a onda u ovisnosti o ishodu tog bacanja na slučajan način izvlačimo kuglicu. Vjerojatnosti izvlačenja kuglica iz pojedine kutije ovise o bacanju novčića pa su u osnovi uvjetne. U takvoj situaciji se čini razumnim pokušati rastaviti skup elementarnih događaja na jednostavnije dijelove, odnosno definirati neki odgovarajući potpuni sutav događaja.
Vođeni takvim razmišljanjem definirajmo događaje H_1 = "na novčiću je pala glava" i H_2 = "na novčiću je palo pismo". Ti događaji čine potpun sustav događaja pri čemu je $P(H_1) = 0,55$, a $P(H_2) = 0,45$. Sada s A označimo događaj "izvučena je plava kuglica". Jednostavno vidimo da je $P(A \mid H_1) = 4/6 = 2/3$ dok je $P(A \mid H_2) = 2/6 = 1/3$. Prema formuli potpune vjerojatnost je tada

$$P(A) = \frac{2}{3} \cdot 0,55 + \frac{1}{3} \cdot 0,45 \approx 0,51666.$$

Sada želimo još izračunati $P(H_2 \mid A)$. Iskoristimo Bayesovu formulu (4.13) da dobijemo

$$P(H_2 \mid A) = \frac{P(A \mid H_2)P(H_2)}{P(A)} = \frac{0,45/3}{0,51666} \approx 0,29.$$

Naravno, jer je $P_A(\cdot) = P(\cdot \mid A)$ vjerojatnost lagano dobijemo

$$P(H_1 \mid A) = P(H_2^c \mid A) = 1 - P(H_2 \mid A) \approx 0,71.$$

□

U sljedećem primjeru je potpun sustav događaja koji ćemo koristiti složeniji, ali je i sam događaj čiju vjerojatnost želimo izračunati složeniji.

Primjer 4.5.13. U jednoj grupi se nalaze tri strijelca (recimo zračnom puškom). Označimo ih s a, b i c. Vjerojatnost da će strijelac a pri bilo kojem od gađanja (pucanja) pogoditi centar mete iznos $0,3$, a ista vjerojatnost za strijelca b iznosi $0,2$ te $0,1$ za strijelca c. Slučajno se odabere jedan od strijelaca te u prvom pokušaju on pogodi centar mete. Koja je vjerojatnost da će isti strijelac u sljedeća dva gađanja jednom pogoditi centar i jednom promašiti?
Opet imamo slučaj u kojem ne znamo koji je strijelac odabran, ali načelno bi znali dati odgovor kada bi znali koji je strijelac odabran. Stoga je prikladno uvesti potpun sustav događaja $\{H_1, H_2, H_3\}$, gdje je H_1 = "odabran je strijelac a", H_2 = "odabran je strijelac b" i H_3 = "odabran je strijelac c". S obzirom da je strijelac slučajno odabran $P(H_i) = 1/3$, $i = 1, 2, 3$.
Neka je A događaj "odabrani strijelac je pogodio metu u prvom gađanju", a B događaj "odabrani strijelac je u sljedeća dva gađanja jednom pogodio i jednom promašio metu". Želimo izračunati uvjetnu vjerojatnost $P(B \mid A)$. Prema definiciji uvjetne vjerojatnosti imamo

$$P(B \mid A) = \frac{P(B \cap A)}{P(A)}.$$

Kao što smo već vidjeli, vjerojatnost od A možemo izračunati formulom potpune vjerojatnosti. Dakle,

$$\begin{aligned} P(A) &= P(H_1)P(A \mid H_1) + P(H_2)P(A \mid H_2) + P(H_3)P(A \mid H_3) \\ &= \frac{1}{3}(P(A \mid H_1) + P(A \mid H_2) + P(A \mid H_3)) = \frac{1}{3}(0,3 + 0,2 + 0,1) = 0,2. \end{aligned}$$

U osnovi bismo slično htjeli napraviti da izračunamo $P(B \cap A)$. Iako nije odmah jasno kako uklopiti potpun sustav događaja u izračun vjerojatnosti presjeka A i B pogledajmo sljedeći račun

$$\begin{aligned} P(B \cap A) &= P(\Omega \cap B \cap A) = P((\cup_{i=1}^{3} H_i) \cap B \cap A) \\ &= P(\cup_{i=1}^{3}(H_i \cap A \cap B)) = \sum_{i=1}^{3} P(H_i \cap A \cap B), \end{aligned} \tag{4.17}$$

pri čemu smo u gornjem izračunu iskoristili distributivnost unije prema presjeku, kao i konačnu aditivnost vjerojatnosti za disjunktne događaje $H_1 \cap A \cap B$, $H_2 \cap A \cap B$ i $H_3 \cap A \cap B$ (nadamo se da je jasno da disjunktnost tih događaja proizlazi iz disjunktnosti događaja H_1, H_2 i H_3). Iskoristimo relaciju (4.17) da zaključimo da je

$$P(B \mid A) = \frac{\sum_{i=1}^{3} P(H_i \cap A \cap B)}{P(A)}. \tag{4.18}$$

Iako se čini da si takvim raspisom nismo previše pomogli uočimo da je, za $i = 1, 2, 3$,

$$P(H_i \cap A \cap B) = P(B \mid H_i \cap A) P(H_i \cap A)$$

i

$$P(H_i \cap A) = P(H_i \mid A) P(A).$$

Kada ta dva izraza uvrstimo u (4.18) dobijemo

$$P(B \mid A) = \frac{\sum_{i=1}^{3} P(B \mid H_i \cap A) P(H_i \mid A) P(A)}{P(A)} = \sum_{i=1}^{3} P(B \mid H_i \cap A) P(H_i \mid A). \tag{4.19}$$

Zaključujemo, pomalo iznenađujuće, da $P(B \mid A)$ možemo izračunati bez izračuna vjerojatnosti od A. Doduše, da bi izračunali $P(H_i \mid A)$ nam treba $P(A)$. Naime, prema Bayesovoj formuli (4.13) je

$$P(H_i \mid A) = \frac{P(H_i) P(A \mid H_i)}{P(A)} = \frac{P(H_i) P(A \mid H_i)}{0,2}$$

pa je $P(H_1 \mid A) = 1/2$, $P(H_2 \mid A) = 1/3$ i $P(H_3 \mid A) = 1/6$.

Preostaje nam za izračunati $P(B \mid H_i \cap A)$, $i = 1, 2, 3$. Uzmimo, radi konkretnosti, $i = 1$, odnosno gađa strijelac a. Pitamo se koja je vjerojatnost da će prvi strijelac koji je pogodio u prvom gađanju u sljedeća dva gađanja jednom pogoditi i jednom promašiti. Događaj da je prvi strijelac u sljedeća dva bacanja jednom pogodio i jednom promašio možemo rastaviti na dva disjunktna događaja: u drugom gađanju je pogodio, a u trećem promašio i u drugom gađanju je promašio, a u trećem pogodio. U tekstu primjera je implicitno pretpostavljeno da u svakom od gađanja strijelac a (kao i ostala dva strijelca) pogodi ili promaši metu neovisno o ostalim gađanjima, odnosno da su gađanja nezavisna. Zbog nezavisnosti je vjerojatnost da je strijelac a u drugom gađanju pogodio, a u trećem promašio centar mete jednaka $0,3 \cdot (1 - 0,3) = 0,3 \cdot 0,7 = 0,21$, a tolika je i vjerojatnost da je u drugom gađanju promašio, a u trećem pogodio (zbog simetrije). Stoga je

$$P(B \mid H_1 \cap A) = 2 \cdot 0,3 \cdot (1 - 0,3) = 0,42.$$

Slično se vidi da je $P(B \mid H_2 \cap A) = 0,32$ te $P(B \mid H_3 \cap A) = 0,18$. Kada sve izračunate vrijednosti uvrstimo u (4.19) dobivamo

$$P(B \mid A) = 0,42 \cdot 1/2 + 0,32 \cdot 1/3 + 0,18 \cdot 1/6 = 0,34666.$$

Primjer se malo odužio jer smo detaljno objašnjavali korake, ali uočimo da je opet bilo ključno uvesti potpun sustav događaja i onda računati pripadne vjerojatnosti. □

Napomena 4.5.14. U prethodnom primjeru smo u osnovi dali skicu dokaza proširene formule potpune vjerojatnosti. Naime, ako je $\{H_1, \dots H_n\}$, $n \in \mathbb{N}$, potpun sustav događaja na vjerojatnosnom prostoru $(\Omega, \mathcal{F}, P)$ te su A i B događaji na tom vjerojatnosnom prostoru, onda vrijedi formula

$$P(B \mid A) = \sum_{i=1}^{n} P(B \mid H_i \cap A) P(H_i \mid A). \tag{4.20}$$

U vjerojatnosti se kao oznaka za presjek često koristi samo zarez pa je $P(B \mid H_i, A) = P(B \mid H_i \cap A)$. □

Završit ćemo ovaj odjeljak jednim primjerom čiji je rezultat pomalo iznenađujući, odnosno nije u skladu s intuicijom. Primjer je preuzet iz [3] (Primjer 2.3.9).

Primjer 4.5.15 (Dijagnosticiranje rijetke bolesti)**.** Pretpostavimo da se osoba X testira na neku rijetku bolest koja zahvaća 1% populacije. Rezultati testa su pozitivni, odnosno indiciraju da osoba X ima tu rijetku bolest. Želimo izračunati vjerojatnost da osoba X zaista boluje od te rijetke bolesti.

Označimo s D slučajni događaj "osoba X boluje od te bolesti", a s T slučajni događaj "rezultat testa je pozitivan". Želimo izračunati uvjetnu vjerojatnost $P(D \mid T)$. Da bi to mogli izračunati trebaju nam neki rezultati o pouzdanosti test koji se koristi za dijagnosticiranje te bolesti. Pretpostavimo da je test 95% pouzdan. Iako takvu tvrdnju treba dodatno raščlaniti u ovom slučaju ćemo pretpostaviti da to znači[18]

$$P(T \mid D) = 0,95 \quad \text{i} \quad P(T^c \mid D^c) = 0,95.$$

Traženu vjerojatnost $P(D \mid T)$ ćemo izračunati primjenom Bayesove formule (4.13). U ovom slučaju dobivamo

$$P(D \mid T) = \frac{P(T \mid D)P(D)}{P(T)}.$$

Jedina nepoznata vjerojatnost u izrazu na desnoj strani je $P(T)$. Nju možemo izračunati primjenom formule potpune vjerojatnosti i to one jednostavne verzije dane u relaciji (4.15). Tako dobivamo

$$\begin{aligned} P(D \mid T) &= \frac{P(T \mid D)P(D)}{P(T \mid D)P(D) + P(T \mid D^c)P(D^c)} \\ &= \frac{0,95 \cdot 0,01}{0,95 \cdot 0,01 + 0,05 \cdot 0,99} \approx 0,16. \end{aligned}$$

Dakle, vjerojatnost da je osoba X bolesna ako je test pozitivan iznosi $0,16$, usprkos činjenici da je test prilično pouzdan (95%). Stvar je u tome da je bolest vrlo rijetka (što je zadano kao informacija) pa se pouzdanost testa donekle "poništava" rijetkošću bolesti.

Da bi se stekla intuicija o ovom fenomenu pogledajmo sljedeći numerički primjer. Uzmimo skup (populaciju) od 10.000 ljudi. Ako ih 1% ima navedenu rijetku bolest to znači da od tih 10.000 osoba 100 njih boluje od te bolesti, a 9.900 osoba ne boluje. Pretpostavimo da testiramo svih 10.000 osoba (testom čije su karakteristike opisane u zadatku). Od 100 osoba koje boluju od te bolesti 95 će imati pozitivan rezultat na testu, a 5 negativan. S druge strane, od 9.900 osoba koju nema tu bolest 9.405 će biti negativni na testu, ali će preostalih 5%, dakle 495 osoba biti pozitivno na testu.

Ukoliko sada gledamo samo osobe koje su bile pozitivne na testu vidimo da ih je 95 zaista bolesno, dok ih 495 nema tu bolest. Dakle, većina testiranih osoba koji su pozitivni na testu zapravo nema promatranu bolest. □

[18] Te dvije vjerojatnosti se, redom, nazivaju osjetljivost i specifičnost testa.

4.6 Primjena R-a za računanje (uvjetnih) vjerojatnosti

U ovom poglavlju smo formalizirali koncept nezavisnosti, odnosno nezavisnog izvođenja slučajnih eksperimenata. U svijetlu frekventističke interpretacije vjerojatnosti (Napomena 4.4.3) možemo velik broj puta nezavisno izvoditi slučajni eksperiment i brojati one ishode u kojima se dogodio neki promatrani slučajni događaja te na taj način procjenjivati vjeorjatnosti. S time smo se već susreli u prošlom poglavlju kada smo primjenjivali R za računanje nekih vjeorjatnosti, a ovdje možemo za početak ponoviti naučeno.

Probajmo procijeniti vjerojatnosti u De Méréovom problemu (Primjer 4.4.2). Sjetimo se da u tu svrhu možemo koristiti funkcije `sample()` i `replicate()`. Tako, recimo, 12 bacanja 4 kockice možemo simulirati na sljedeći način.

```
> set.seed(42)
> DePom<-replicate(12,sample(6,4, replace=TRUE))
> DePom
```

```
     [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
[1,]    1    2    1    6    3    4    4    2    3     4     4     2
[2,]    5    4    4    4    1    5    2    1    6     6     5     3
[3,]    1    2    1    2    1    5    4    2    2     2     4     1
[4,]    1    2    5    2    3    5    3    6    4     5     2     5
```

Sjetimo se da bacanja s ponavljanjem simuliramo tako da u funkciji `sample` stavimo argument `replace=TRUE`. Funkcija `set.seed` određuje početni element niza pseudoslučajnih brojeva koje generira R, a koji nam služe kao aproksimacija nezavisnih bacanja/izvlačenja. Svrha definiranja tog elementa je reproducibilnost prikazanih simulacija od strane drugih jer u suprotnom R slučajno odabire početni element niza pseudoslučajnih brojeva. Sada je ideja da velik broj puta (ne samo 12) ponovimo takvu simulaciju i prebrojimo slučajeve 4 bacanja kockice u kojima je pala šestica te broj takvih slučajeva podijelimo s ukupnim brojem simulacija, odnosno izvođenja slučajnog pokusa. Taj će broj biti blizak vjeorjatnosti slučajnog događaja "u četiri bacanja će pasti barem jedna šestica".

U osnovi takve probleme možemo rješavati tako da napravimo velik broj simulacija i onda kombinacijom `for` petlji i `if`-ova prebrojimo simulacije u kojima nalazimo barem jednu šesticu. Iako su današnja računala brza, takve velike for petlje se mogu relativno dugo izvršavati pa dajemo i neka druga rješenja koja primjenjuju samo postojeće R funkcije. Ideja je da podijelimo sve elemente varijable `DePom` cjelobrojno sa 6 i onda na svim mjestima dobijemo nule, osim na onima na kojima se nalaze šestice. Zatim izračunamo maksimume po stupcima (nizovima četiri bacanja kockice) i uočimo da u stupcima u kojima nije bilo šestice dobivamo maksimum jednak 0. Preostaje zbrojiti te maksimume da izračunamo broj četiri uzastopna bacanja kockice u kojima je pala šestica. Konkretno, najprije podijelimo `DePom` cjelobrojno sa 6 da dobijemo

```
> DePom6<-DePom%/%6
> DePom6
```

```
     [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
[1,]    0    0    0    1    0    0    0    0    0     0     0     0
[2,]    0    0    0    0    0    0    0    0    1     1     0     0
[3,]    0    0    0    0    0    0    0    0    0     0     0     0
[4,]    0    0    0    0    0    0    0    1    0     0     0     0
```

Izračunajmo maksimum po stupcima. Za to ćemo upotrijebiti R-ovu funkciju `apply()` koja na zadanu varijablu (zapravo `data frame`) primijenjuje funkciju koju navedemo, pri čemu to može biti i korisnički definirana funkcija. Funkcija `apply` je vrlo korisna.

```
> apply(DePom6, 2, FUN=max)

 [1] 0 0 0 1 0 0 0 1 1 1 0 0
```

Uočimo da drugi argument u funkciji `apply` određuje da li ćemo funkciju `FUN` primijeniti na retke (ako je tamo 1) ili stupce (ako je tamo 2). Sada zbrojimo maksimume po stupcima i podijelimo ih s ukupnim brojem ponavljanja. Tako dobijemo prvu procjenu tražene vjerojatnosti.

```
> sum(apply(DePom6, 2, FUN=max))/12

[1] 0.3333333
```

S obzirom da je "prava" (izračunata) vjerojatnost bliska $0,518$ ovo nije naročito dobra procjena. No, 12 ponavljanja u simulaciji je vrlo mali broj. Ponovimo cijeli postupak, ali sada sa 100.000 ponavljanja.

```
> set.seed(42)
> DeMere1<-replicate(100000, sample(6,4, replace=TRUE))
> maks1<-apply(DeMere1%/%6, 2, FUN = max)
> sum(maks1)/100000

[1] 0.51748
```

Vidimo da uz povećan broj ponavljanja u simulaciji koju smo napravili dobivamo vrlo pristojnu procjenu.

Probajmo sada na sličan način procijeniti vjerojatnost da će u 24 bacanja dvije kockice u barem jednom bacanju pasti dvije šestice. Sjetimo se, izračunali smo da je ta vjerojatnost bliska $0,491$. Da bi procijenili tu vjerojatnost, generirat ćemo dva niza koji će simulrati 24 bacanja kockice i njih ćemo u paru smatrati bacanjem dvije kockice. Pomnožit ćemo ta dva niza i tako dobivene brojeve podijeliti cjelobrojno s 36. Sada će nam po stupcima (koji simuliraju 24 bacanja dvije kockice) ostati jedinice samo na mjestima (bacanjima) na kojima su bile dvije šestice. Za 100.000 ponavljanja dobijemo sljedeći rezultat

```
> set.seed(42)
> DeMere21<-replicate(100000, sample(6,24, replace=TRUE))
> DeMere22<-replicate(100000, sample(6,24, replace=TRUE))
> maks2<-apply((DeMere21*DeMere22)%/%36, 2, FUN = max)
> sum(maks2)/100000

[1] 0.49221
```

Vidimo da i u ovom slučaju dobijemo dosta dobru procjenu. Ako Vam je rješenje dano u previše "agregiranoj" probajte prvo simulirati mali broj ponavljanja i pogledajte što se događa kada množite `DeMere21` i `DeMere22`. S obzirom da nam je mali sporedni cilj upoznati se s R-om, i programskim tehnikama općenito, probajmo prvi dio ovog problema riješiti na još neke načine (drugi probajte na sličan način riješiti sami). Vratimo se na `data frame DePom`:

```
> set.seed(42)
> DePom<-replicate(12,sample(6,4, replace=TRUE))
> DePom
```

```
     [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
[1,]    1    2    1    6    3    4    4    2    3     4     4     2
[2,]    5    4    4    4    1    5    2    1    6     6     5     3
[3,]    1    2    1    2    1    5    4    2    2     2     4     1
[4,]    1    2    5    2    3    5    3    6    4     5     2     5
```

Možda Vam rješenje s s cjelobrojnim dijeljenjem izgleda donekle egzotično. Ima i drugih jednostavnih rješenja. Primjerice, ako uočimo da R vrijednosti logičkih varijabli `FALSE` i `TRUE` sprema kao vrijednosti 0 i 1, možemo to iskoristiti za brojenje maksimuma. Tako možemo napraviti sljedeće

```
> DePom2<-apply(DePom, 2, FUN=max)
> DePom2

 [1] 5 4 5 6 3 5 4 6 6 6 5 5

> sum(DePom2==6)/12

[1] 0.3333333
```

Vidimo da dobivamo isto rješenje kao i ranije. Stvar je u tome da se zadnja funkcija `sum` primjenjuje na logički vektor pa zapravo zbrajamo nule i jedinice. Radi cjelovitosti pogledajmo koje su vrijednosti uvjeta, a zapravo logičkog vektora `DePom2==6`.

```
> options(width=75)
> DePom2==6

 [1] FALSE FALSE FALSE  TRUE FALSE FALSE FALSE  TRUE  TRUE  TRUE FALSE
[12] FALSE
```

pa je

```
> sum(DePom2==6)

[1] 4
```

Prema tome, možemo dati i malo drugačije rješenje prvog dijela zadatka

```
> set.seed(42)
> DeMere1<-replicate(100000, sample(6,4, replace=TRUE))
> sum(apply(DeMere1, 2, FUN = max)==6)/100000

[1] 0.51748
```

Uočite da je za usporedbu rezultata bilo korisno da smo odredili jednak početak mjesta od kojega se generiraju pseudoslučajni brojevi. Jasno, jedno rješenje je i "klasično", korištenjem `for` petlji i `if`-ova. Tako imamo

```
> set.seed(42)
> brpon<-12
> brbac<-4
> brojac<-0
> DePom<-replicate(brpon,sample(6,brbac, replace=TRUE))
> for(i in 1:brpon){
+   j<-1
```

```
+   while (j <= brbac){
+     if (DePom[j,i]==6){brojac<-brojac+1; j<-brbac+1 }
+     else j<-j+1
+   }
+ }
> cat("Procjenjena vjerojatnost je", brojac/brpon)

Procjenjena vjerojatnost je 0.3333333
```

U slučaju 100.000 ponavljanja dobijemo

```
> set.seed(42)
> brpon<-100000
> brbac<-4
> brojac<-0
> DePom<-replicate(brpon,sample(6,brbac, replace=TRUE))
> for(i in 1:brpon){
+   j<-1
+   while (j <= brbac){
+     if (DePom[j,i]==6){brojac<-brojac+1; j<-brbac+1 }
+     else j<-j+1
+   }
+ }
> cat("Procjenjena vjerojatnost je", brojac/brpon)

Procjenjena vjerojatnost je 0.51748
```

Na sličan način, a u skladu s Napomenom 4.5.8, možemo probati procijeniti neke uvjetne vjerojatnosti. Naime, tamo smo napomenuli da uvjetne vjeorjatnosti tipa $P(A \mid B)$ možemo računati (procjenjivati) tako da n puta ponovimo promatrani slučajni eksperiment i onda uvjetnu vjerojatnost $P(A \mid B)$ procjenimo s $n_{A\cap B}/n_B$.

Pogledajmo kako bismo procijenili vjerojatnosti iz Primjera 4.5.5. Sjetimo se, događaj A je bio "u obitelji je dvoje djece ženskog spola", a C događaj "jedno dijete je ženskog spola". Želimo procijeniti uvjetnu vjerojatnost $P(A \mid C)$. Da bi to napravili prvo generirajmo nezavisne nizove spola prvog i drugog dijeteta, pri čemu muško dijete označimo s nulom, a žensko s jedinicom. Za 20 ponavljanja dobivamo

```
> set.seed(42)
> dij1<-sample(c(0,1), 20, replace=TRUE)
> dij1

 [1] 0 0 0 0 1 1 1 1 0 1 0 1 0 1 0 0 1 1 1 1

> dij2<-sample(c(0,1), 20, replace=TRUE)
> dij2

 [1] 0 0 0 0 0 1 0 0 0 0 1 1 1 1 0 1 0 1 1 1
```

Zadatak opet možemo riješiti na više načina. Jedan je da formiramo novi vektor koji množi `dij1` i `dij2` i formiramo vektor koji je jednak maksimumu od `dij1` i `dij2`

```
> dijoba<-dij1*dij2
> dijoba
```

```
 [1] 0 0 0 0 0 1 0 0 0 0 0 1 0 1 0 0 0 1 1 1
```

```
> dijpom<-data.frame(dij1, dij2)
> dijjedno<-apply(dijpom,1, FUN=max)
```

Vektor `dijoba` sadrži samo one parove dvoje djece u kojima su oba dijeteta ženskog spola, a vektor `dijjedno` samo one parove djece u kojima je jedno dijete ženskog spola. Zbrojimo broj jednih i drugih parova. Dijeljenjem ta dva broja dobivamo procjenu tražene uvjetne vjerojatnost

```
> cat("Tražena uvjetna vjerojatnost je", sum(dijoba)/sum(dijjedno))

Tražena uvjetna vjerojatnost je 0.4285714
```

Drugi način uključuje upotrebu logičkih operatora. Tako možemo napraviti sljedeće

```
> set.seed(42)
> nC<-sum(dij1==1 | dij2==1)
> nAC<-sum(dij1==1 & dij2==1)
> cat("Tražena uvjetna vjerojatnost je", nAC/nC)

Tražena uvjetna vjerojatnost je 0.4285714
```

Sa `|` je označen logički operator ILI. Kada povećamo broj ponavljanja dobijemo

```
> set.seed(42)
> dij1<-sample(c(0,1), 100000, replace=TRUE)
> dij2<-sample(c(0,1), 100000, replace=TRUE)
> dijoba<-dij1*dij2
> dijpom<-data.frame(dij1, dij2)
> dijjedno<-apply(dijpom,1, FUN=max)
> cat("Tražena uvjetna vjerojatnost je", sum(dijoba)/sum(dijjedno))

Tražena uvjetna vjerojatnost je 0.3326175
```

odnosno

```
> set.seed(42)
> dij1<-sample(c(0,1), 100000, replace=TRUE)
> dij2<-sample(c(0,1), 100000, replace=TRUE)
> nC<-sum(dij1==1 | dij2==1)
> nAC<-sum(dij1==1 & dij2==1)
> cat("Tražena uvjetna vjerojatnost je", nAC/nC)

Tražena uvjetna vjerojatnost je 0.3326175
```

Sličan postupak možemo primijeniti i na druge primjere. Tako za Primjer 4.5.12 trebamo prvo simulirati bacanje nesimetričnog novčića, a zatim i izvlačenje plave kuglice iz kutije, pri čemu odabir kutije zavisi o ishodu bacanja novčića. Želimo izračunati

$$P(H_2 \mid A) = \frac{P(H_2 \cap A)}{P(A)},$$

gdje je H_2 slučajni događaj "na novčiću je palo pismo", a A slučajni događaj "izvučena je plava kuglica". Uz identifikaciju 0 sa pismom te 1 s glavom, te "p" s plavom kuglicom i "c" sa crvenom kuglicom, traženu uvjetnu vjerojatnost računamo na sljedeći način

```
> set.seed(42)
> kug<-0
> nov<-sample(c(0,1), 100000, replace=TRUE, prob=c(0.45, 0.55))
> for (i in 1:100000){
+   if (nov[i]==0)
+     {kug[i]<-sample(c("p","c"), 1, replace=TRUE, prob<-c(1/3, 2/3))}
+   else
+     {kug[i]<-sample(c("p","c"), 1, replace=TRUE, prob<-c(2/3, 1/3))}
+ }
> nA<-sum(kug=="p")
> nAH<-sum(nov==0 & kug =="p")
> cat("Tražena uvjetna vjerojatnost je", nAH/nA)

Tražena uvjetna vjerojatnost je 0.2905158
```

Vidimo da dobivamo vjerojatnost koja je približno jednaka onoj koju smo izračunali u Primjeru 4.5.12.

Uočimo da smo opet koristili funkciju `sample` za generiranje uzorka, ali smo sada dodali argument `prob` koji govori s kojom vjerojatnošću se generira 0 ili 1 (pismo ili glava), odnosno "izvučena je plava kuglica" ili "izvučena je crvena kuglica". Funkcija `sample` je vrlo fleksibilna kako u pogledu objekata koji se slučajno generiraju (izvlačenje kuglice smo simulirali generiranjem uzorka iz vektora (p,c)), tako i u pogledu vjerojatnosti s kojima se ti objekti generiraju.

Pokušajte sami izračunati još neke uvjetne vjerojanosti bilo da su iz prije navedenih primjera ili neke koje su vam zanimljive.

4.7 Sažetak poglavlja

Neka je Ω skup.
Familija $\mathcal{F}$ podskupova od Ω je **σ-algebra skupova** na Ω ako zadovoljava sljedeća svojstva

i) $\emptyset \in \mathcal{F}$

ii) Ako je $A \in \mathcal{F}$, onda je i $A^c \in \mathcal{F}$

iii) Ako su $A_i \in \mathcal{F}$, $i \in \mathbb{N}$, onda je $\bigcup_{i\in\mathbb{N}} A_i \in \mathcal{F}$.

Funkcija $P : \mathcal{F} \to \mathbb{R}$ je **vjerojatnost** na $(\Omega, \mathcal{F})$ ako vrijedi

(1) $P(A) \geq 0$ za sve $A \in \mathcal{F}$

(2) $P(\Omega) = 1$

(3) Za $A_i \in \mathcal{F}$, $i \in \mathbb{N}$, međusobno disjunktne ($A_i \cap A_j = \emptyset$ za $i \neq j$) vrijedi

$$P\Big(\bigcup_{i\in\mathbb{N}} A_i\Big) = \sum_{i=1}^{\infty} P(A_i).$$

Svojstvo (3) se naziva σ-aditivnost vjerojatnosti P. Važno je uočiti da su skupovi A_i međusobno disjunktni.
Elementi skupa Ω zovu se elementarni događaji, a podskupovi od Ω koji su u σ-algebri $\mathcal{F}$ zovu se slučajni događaji ili samo događaji. Uređena trojka $(\Omega, \mathcal{F}, P)$ zove se **vjerojatnosni prostor**.

Vjerojatnost je funkcija koja slučajnim događajima, dakle skupovima, pridružuje brojeve iz $[0,1]$. Tako je

$$P(\Omega) = 1 \quad \text{i} \quad P(\emptyset) = 0.$$

Za A i B slučajne događaje imamo

$$P(A^c) = 1 - P(A),$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Ako je $B \subset A$ imamo

$$P(B) \leq P(A) \quad \text{i}$$

$$P(A \setminus B) = P(A) - P(B).$$

Poseban slučaj σ-aditivnosti je **konačna aditivnost**: ako su $A_1, A_2, \ldots A_n$ međusobno disjunktni slučajni događaji ($A_i \cap A_j = \emptyset$, za $i \neq j$, $i, j = 1, 2 \ldots, n$), onda je

$$P(A_1 \cap A_2 \cap \ldots \cap A_n) = P(A_1) + P(A_2) + \ldots + P(A_n).$$

Ako je Ω konačan ili prebrojiv skup, onda se $(\Omega, \mathcal{F}, P)$ zove **diskretni vjerojatnosni prostor**. Vjerojatnost na konačnim ili prebrojivim skupovima je određena svojim vrijednostima na elementarnim događajima ($0 \leq p_i = P(\{\omega_i\}) \leq 1$). Zapamtimo relaciju (4.4).
Za $\Omega = \{\omega_1, \omega_2, \ldots, \omega_n\}$ konačan možemo definirati vjerojatnost P na Ω takvu da je vjerojatnost svih elementarnih događaja jednaka

$$P(\{\omega_1\}) = P(\{\omega_2\}) = \ldots = P(\{\omega_n\}) = \frac{1}{n}.$$

Takvu vjerojatnost nazivamo uniformnom.

Za općeniti vjerojatnosni prostor $(\Omega, \mathcal{F}, P)$ definiramo pojam **nezavisnosti slučajnih događaja**. Dva slučajna događaja A_1 i A_2 su **nezavisni** ako vrijedi

$$P(A_1 \cap A_2) = P(A_1) \cdot P(A_2).$$

Slučajni događaji A_1, A_2 i A_3 su nezavisni ako vrijede sljedeće četiri relacije

$$P(A_1 \cap A_2) = P(A_1) \cdot P(A_2), \;\; P(A_1 \cap A_3) = P(A_1) \cdot P(A_3), \;\; P(A_2 \cap A_3) = P(A_2) \cdot P(A_3)$$

i

$$P(A_1 \cap A_2 \cap A_3) = P(A_1) \cdot P(A_2) \cdot P(A_3).$$

Općenito su slučajni događaji $A_1, A_2, \ldots, A_n \in \mathcal{F}$ **nezavisni** ako za svaki odabir indeksa $\{i_1, i_2, \ldots, i_k\} \subset \{1, 2, \ldots, n\}$, $k \leq n$, vrijedi

$$P\Big(\bigcap_{j=1}^{k} A_{i_j}\Big) = \prod_{j=1}^{k} P(A_{i_j}). \tag{4.21}$$

Neka je $(\Omega_1, \mathcal{F}_1, P_1)$ vjerojatnosni prostor koji opisuje neki slučajni eksperiment koji nezavisno ponavljamo n puta (n bacanja novčića na primjer). Definiramo produktni prostor elementarnih događaja $\Omega = \Omega_1^n$ (Kartezijev produkt n kopija Ω_1). Ω opisuje nezavisno ponavljanje promatranog slučajnog eksperimenta. Na njemu definiramo produktnu vjerojatnost P za koju vrijedi

$$P(A_1 \times A_2 \times \ldots \times A_n) = P(A_1) \cdot P(A_2) \cdot \ldots \cdot P(A_n),$$

gdje je $A_1 \times A_2 \times \ldots \times A_n \subset \Omega$. Ako je Ω_1 diskretan skup za prduktnu σ-algebru možemo uzeti $\mathcal{P}(\Omega)$. Pogledajte Primjer 4.4.1 za tipičnu primjenu koncepta produktnog prostora na nezavisno ponavljanje eksperimenata.

* * * * *

$(\Omega, \mathcal{F}, P)$ vjerojatnosni prostor, $C \in \mathcal{F}$ slučajni događaj takav da je $P(C) > 0$. Za proizvoljni slučajni događaj A iz $\mathcal{F}$ definiramo **uvjetnu vjerojatnost** od A u odnosu na C kao

$$P(A \mid C) := \frac{P(A \cap C)}{P(C)}.$$

Uvjetna vjerojatnost $P_C(\cdot) = P(\cdot \mid C)$ je vjerojatnost na $\mathcal{F}$.
Bayesova formula

$$P(A \mid C) = \frac{P(C \mid A)P(A)}{P(C)}.$$

Neka su $H_1, H_2, \ldots, H_n$, $n \in \mathbb{N}$, događaji iz Ω koji su neprazni i međusobno disjunktni te im je unija jednaka cijelom Ω, tj. $\Omega = \cup_{i=1}^n H_i$. Skup događaja $\{H_1, \ldots H_n\}$ se zove **potpun sustav događaja** na Ω. Za slučajni događaj A iz Ω vrijedi **formula potpune vjerojatnosti**

$$P(A) = P(H_1)P(A \mid H_1) + \ldots + P(H_n)P(A \mid H_n) = \sum_{i=1}^{n} P(H_i)P(A \mid H_i).$$

za dva događaja formula potpune vjerojatnosti poprima oblik

$$P(A) = P(H_1)P(A \mid H_1) + P(H_1^c)P(A \mid H_1^c)$$

Ukoliko formulu (4.14) uvrstimo u (4.13) dobijemo izraz

$$P(H_i \mid A) = \frac{P(H_i)P(A \mid H_i)}{\sum_{j=1}^n P(H_j)P(A \mid H_j)},\ i = 1, 2, \ldots n.$$

4.8 Zadaci

Zadatak 4.8.1. *Dokažite Propoziciju 4.1.3. Uputa: primjenite svojstvo konačne aditivnosti vjerojatnosti na sljedeće disjunktne unije $\Omega \cup \emptyset = \Omega$, $\Omega = A \cup A^c$, $A = B \cup A \setminus B$ (za $B \subset A$) i $A \cup B = (A \setminus (A \cap B)) \cup (A \cap B) \cup (B \setminus (A \cap B))$. Ako imate dvojbe oko valjanosti navedenih skupovnih jednakosti upotrijebite Vennove dijagrame da se uvjerite u njihovu istinitost.*

Zadatak 4.8.2. *Neka su A i B slučajni događaji na nekom vjerojatnosnom prostoru $(\Omega, \mathcal{F}, P)$. Simetrična razlika skupova A i B, u oznaci $A \triangle B$, se definira kao skup $(A \setminus B) \cup (B \setminus A)$. Koristeći se svojstvima vjerojatnosti pokažite da je*

$$P(A \triangle B) = P(A) + P(B) - 2P(A \cap B).$$

Zadatak 4.8.3. *Imamo sljedeća dva događaja: $A =$ "Zemlju će u sljedećih 100 godina pogoditi metor" i $B =$ "U sljedećih 100 godina će Sunce eksplodirati ili će Zemlju pogoditi metor". Koji je od ta dva događaja vjerojatniji? Zašto?*

Zadatak 4.8.4. *Neka su A i B slučajni događaji iz Ω i P vjerojatnost na Ω. Pretpostavimo da je $A \cup B = \Omega$ te da je $P(A) = 0,6$ i $P(B) = 0,5$. Izračunajte $P(A \cap B)$, $P(A^c)$, $P(B^c)$, $P(A^c \cup B^c)$, $P(A \cap B^c)$. Da li su A i B nezavisni slučajni događaji?*

Zadatak 4.8.5. *Spremate se za izlazak na ispit iz dva predmeta: Programiranje i Matematika. Spremali ste se za oba ispita i procjenjujete da su vam izgledi za prolazak kolegija Programiranje* 70%, *dok su Vam izgledi za prolazak kolegija Matematika* 50%. *Procjenjujete da sa samo* 10% *izgleda nećete položiti niti jedan kolegij. Kolika je vjerojatnost da ćete položiti barem jedan kolegij? Kolika je vjerojatnost da ćete položiti Matematiku, a ne Programiranje uz dane pretpostavke o polaganju ispita?*

Zadatak 4.8.6. *U kutiji se nalaze predmeti različitog oblika (kocka, kugla i piramida) i različitih boja (plave, crvene i bijele). Ako je vjerojatnost da će biti izvučena plava kocka jednaka* $0,05$, *vjerojatnost da će biti izvučena kocka jednaka* $0,3$, *a vjerojatnost da će biti izvučen plavi predmet jednaka* $0,15$, *koja je vjerojatnost da će biti izvučen plavi predmet ili kocka?*

Zadatak 4.8.7. *U nekoj kutiji se nalazi 6 različitih vrsta kalkulatora i 5 različitih vrsta mobitela. Na slučajan način biramo 4 proizvoda iz te kutije (bez vraćanja proizvoda nakon izvlačenja). Koja je vjerojatnost*

a) da među izvučenim proizvodima neće biti niti jedan mobitel?

b) da će među izvučenim proizvodima biti najviše jedan mobitel?

c) da će među izvučenim proizvodima biti najmanje jedan mobitel?

Zadatak 4.8.8. *Došli ste na degustaciju vina i u ponudi su 3 pjenušca, 5 svježih bijelih vina, 4 odležana bijela vina te 7 crnih vina. Predviđeno je da isprobate po jedno vino iz svake kategorije. Ne znate ništa o ponuđenim vinima pa se odlučujete na slučajan odabir po jednog vina iz svake kategorije (dakle, ukupno 4 vina). Pretpostavimo da proizvođač vina Alfa na toj degustaciji ima 1 vino u kategoriji pjenušaca, 2 u kategoriji svježih bijelih vina, 2 u kategoriji odležanih bijelih vina i 3 u kategoriji crnih vina. Izračunajte*

a) vjerojatnost da su sva vina koja ste odabrali od proizvođača Alfa i

b) vjerojatnost da je barem jedno od vina koja ste odabrali od proizvođača Alfa.

Zadatak 4.8.9. *Spremate se za odlazak na ispit. Na stolu imate 7 različitih kemijskih olovaka i 5 različitih običnih olovaka. U brzini (dakle, slučajno) uzmete sa stola 4 pisalice (objekta za pisanje: dakle, kemijske ili obične olovke). Izračunajte*

a) vjerojatnost da ćete izabrati po dvije kemijske i obične olovke i

b) vjerojatnost da ćete izabrati barem jednu običnu olovku.

Zadatak 4.8.10. *Zadan je prostor elementarnih događaja* $\Omega = \{a, b, c, d, e, f\}$ *i na njemu vjerojatnost* P *takva da je vjerojatnost svakog elementarnog događaja jednaka* $1/6$. *Uzmimo skupove* $A = \{a, c, e\}$ *i* $B = \{b, c, d\}$. *Da li su oni nezavisni?*

Zadatak 4.8.11. *Zadan je prostor elementarnih događaja* $\Omega = \{a, b, c, d, e, f\}$ *i na njemu vjerojatnost* P *takva da je* $P(\{a\}) = 1/6$, $P(\{b\}) = P(\{c\}) = P(\{d\}) = P(\{e\}) = 1/12$ *i* $P(\{f\}) = 1/2$. *Uzmimo skupove* $A = \{a, c, e\}$ *i* $B = \{b, c, d\}$. *Da li su oni nezavisni?*

Zadatak 4.8.12. *Pogledajmo slučajni eksperiment nezavisnog bacanja dvije kockice. Neka je slučajni događaj* $A =$ *"na drugoj kockici je pao paran broj". Definirajmo još tri slučajna događaja*

i) $B_1 =$ *"na drugoj kockici je pao broj 4"*

ii) $B_2 =$ *"na drugoj kockici je pao broj 1"*

iii) $B_3 =$ *"na prvoj kockici je pao broj 1".*

Izračunajte $P(A \mid B_1)$, $P(A \mid B_2)$ *i* $P(A \mid B_3)$.

Zadatak 4.8.13. *Na stolu se nalaze dvije kutije. U prvoj su 4 (različite) čokolade s lješnjacima i 2 (različite) čokolade s rižom, dok su u drugoj kutiji 3 (različite) čokolade s lješnjacima i 3 (različite) čokolade s rižom. Na slučajan način odaberete jednu čokoladu iz prve kutije i bez gledanja je prebacite u drugu kutiju. Nakon toga na slučajan način odaberete jednu čokoladu iz druge kutije. Koja je vjerojatnost da će ta čokolada (iz druge kutije) biti s rižom?*

Zadatak 4.8.14. *Dva strijelca nezavisno gađaju neku metu. Vjerojatnost da će prvi strijelac pogoditi metu iznosi* $0,8$*, a vjerojatnost da će drugi strijelac pogoditi metu iznosi* $0,6$*. Nakon gađanja je utvrđeno da je meta pogođena samo jednom (jednim hicem). Koja je vjerojatnost da je prvi strijelac pogodio metu?*

Zadatak 4.8.15. *Spremate se okititi bor i izvadili ste tri kutije s kuglicama, pri čemu je u svakoj kutiji po 10 kuglica. Jedine kuglice koje imate su crvene i bijele s time da su u prvoj kutiji 8 crvenih kuglica i 2 bijele, u drugoj 6 crvenih i 4 bijele i u trećoj 4 crvene i 6 bijelih. Ne znate od koje kutije krenuti kititi bor pa ste ju (kutiju) odlučili odabrati na slučajan način. Kako nemate kockicu pri ruci odlučite nasumično baciti dva novčića i odlučite da ćete odabrati prvu kutiju ako padnu dvije glave, drugu kutiju ako padnu dva pisma te treću kutiju ako padne po jedno pismo i glava. Iz odbrane kutije na slučajan način birate dvije kuglice (odjednom). Koja je vjerojatnost da će obje odabrane kuglice biti bijele? Koja je vjerojatnost da ste odabrali prvu kutiju ako su obje odabrane kuglice bile bijele?*

Zadatak 4.8.16. *Dok čekate večernji izlazak sjeli ste pred računalo i odlučili odigrati partiju šaha u nekom programu za šah. Nude vam se 3 opcije težine protivnika (računalnog programa): razina za početnike, srednja razina i razina za iskusne igrače. Moguće je i odabrati jednu od te tri težine protivnika na slučajan način (dakle, bilo koja od te tri težine se odabire s vjerojatnošću* $1/3$*). Odlučite odabrati razinu upravo tako: na slučajan način. Koja je vjerojatnost da ćete pobjediti u toj partiji ako je vjerojatnost vaše pobjede na razini za početnike jednaka* $0,8$*, na srednjoj razini* $0,5$*, a na razini za iskusne igrače* $0,3$*? Dodatno, izračunaje vjerojatnost da je slučajno odabrana razina bila ona za početnike ako ste pobijedili u toj partiji šaha.*

Zadatak 4.8.17. *Vratimo se u kontekst Primjera 4.4.1. Definirajmo slučajni događaj* $E =$ *"u barem dva uzastopna bacanja je pala glava". Uz iste oznake kao u Primjeru 4.4.1 vidimo da je*

$$E = \bigcup_{j=1}^{9} (A_j \cap A_{j+1}).$$

Izračunajte vjerojatnost slučajnog događaja E.

4.8.1 Rješenja zadataka

Rješenje 31 (Zadatak 4.8.1)**.** Jer je $\Omega \cup \emptyset = \Omega$ te je to unija disjunktnih skupova možemo iskoristiti konačnu aditivnost vjerojatnosti da zaključimo $P(\Omega) + P(\emptyset) = P(\Omega)$ pa je $P(\emptyset) = 0$.
Jer je $A \cup A^c = \Omega$ te je to unija disjunktnih skupova možemo iskoristiti konačnu aditivnost vjerojatnosti da zaključimo $P(A) + P(A^c) = 1$ pa je $P(A^c) = 1 - P(A)$.
Jer je $A = B \cup A \setminus B$ za $B \subset A$ te je to unija disjunktnih skupova možemo iskoristiti konačnu aditivnost vjerojatnosti da zaključimo $P(A) = P(B) + P(A \setminus B)$ pa je $P(A \setminus B) =$

$P(A) - P(B)$. Kako je vjerojatnost nenegativna funkcija znamo da je $P(A \setminus B) \geq 0$ pa iz $P(A) = P(B) + P(A \setminus B)$ zaključujemo $P(B) \leq P(A)$.
Jer je $A \cup B = (A \setminus (A \cap B)) \cup (A \cap B) \cup (B \setminus (A \cap B))$ te je to unija disjunktnih skupova možemo iskoristiti konačnu aditivnost vjerojatnosti da zaključimo

$$P(A \cup B) = P(A \setminus (A \cap B)) + P(A \cap B) + P(B \setminus (A \cap B)). \tag{4.22}$$

Sada uočimo da je $A \cap B \subset A$ pa iz već dokazanih svojstava zaključujemo da vrijedi $P(A \setminus (A \cap B)) = P(A) - P(A \cap B)$. Analogno zaključujemo da je $P(B \setminus (A \cap B)) = P(B) - P(A \cap B)$. Oba ta izraza uvrstimo u formulu (4.22) da dobijemo svojstvo (5) u Propoziciji 4.1.3.
Da bi dokazali σ-poluaditivnost trebamo prikazati uniju $\bigcup_{i=1}^{\infty} A_i$ kao uniju disjunktnih skupova. U tu svrhu definiramo slučajne događaje B_i, $i \in \mathbb{N}$, na sljedeći način: $B_1 = A_1$, $B_2 = A_2 \setminus A_1$ i općenito $B_n = A_n \setminus \bigcup_{i=1}^{n-1} A_i$ za $n \geq 3$. Uočimo da su B_i međusobno disjunktni, $B_i \subset A_i$ te je $\bigcup_{i=1}^{\infty} A_i = \bigcup_{i=1}^{\infty} B_i$. Zbog σ-aditivnosti i monotonosti vjerojatnosti imamo

$$P(\bigcup_{i=1}^{\infty} A_i) = P(\bigcup_{i=1}^{\infty} B_i) = \sum_{i=1}^{\infty} P(B_i) \leq \sum_{i=1}^{\infty} P(A_i).$$

Rješenje 32 (Zadatak 4.8.2)**.** Ovakve zadatke možemo riješiti na sličan način kao što smo riješili Zadatak 4.8.1. Simetričnu razliku $A \triangle B$ želimo napisati kao disjunktnu uniju skupova. No, ona je već po definiciji disjunktna unija skupova $A \setminus B$ i $B \setminus A$ pa je

$$P(A \triangle B) = P(A \setminus B) + P(B \setminus A).$$

Sada uočimo da je $A \setminus B = A \setminus (A \cap B)$ i slično $B \setminus A = B \setminus (A \cap B)$. Kako je $A \cap B \subset A$ iz prijašnjih svojstava vjerojatnosti (vidi (3) u Propoziciji 4.1.3) slijedi da je

$$P(A \setminus B) = P(A) - P(A \cap B)$$

pa dobivamo tvrdnju zadatka.

Rješenje 33 (Zadatak 4.8.3)**.** Jasno je da je $A \subset B$ pa je zbog monotnonosti vjerojatnosti $P(A) \leq P(B)$. Stoga je događaj B vjerojatniji.

Rješenje 34 (Zadatak 4.8.4)**.** Kako za slučajne događaja A i B vrijedi da je $A \cup B = \Omega$, a $P(\Omega) = 1$ za svaku vjerojatnost (svojstvo (2) u definiciji vjerojatnosti 4.1.2) zaključujemo da je

$$P(A \cup B) = 1.$$

Prema svojstvu (5) iz Propozicije 4.1.3 dobijemo

$$P(A \cap B) = P(A) + P(B) - P(A \cup B) = 0,6 + 0,5 - 1 = 0,1.$$

Iz toga odmah vidimo da slučajni događaji A i B nisu nezavisni jer je

$$0,1 = P(A \cap B) \neq P(A)P(B) = 0,6 \cdot 0,5 = 0,3.$$

Prema formuli za vjerojatnost suprotnog događaja (svojstvo (2) u Propoziciji 4.1.3) lagano dobivamo

$$P(A^c) = 1 - P(A) = 1 - 0,6 = 0,4 \quad \text{i} \quad P(B^c) = 1 - P(B) = 1 - 0,5 = 0,5.$$

Iako znamo vjerojatnosti od A^c i B^c nije odmah jasno kako izračunati vjeorjatnost od $A^c \cup B^c$. Ako se prisjetimo De Morganovih pravila za komplement unije i presjeka

(formula (3.3) u prošlom poglavlju)) vidimo da se $P(A^c \cup B^c)$ lagano izračuna primjenom formule za vjerojatnost suprotnog događaja jer imamo

$$P(A^c \cup B^c) = P((A \cap B)^c) = 1 - P(A \cap B) = 1 - 0,1 = 0,9.$$

Napokon, kao što smo već vidjeli u nekim primjerima iz ovog poglavlja, imamo skupovnu relaciju $A \cap B^c = A \setminus (A \cap B)$ (uvjerite se Vennovim dijagramima). Zbog svojstva (3) iz Propozicije 4.1.3 vrijedi

$$P(A \cap B^c) = P(A \setminus (A \cap B)) = P(A) - P(A \cap B) = 0,6 - 0,1 = 0,5.$$

Rješenje 35 (Zadatak 4.8.5)**.** Za rješavanje ovog zadatka nam treba nekoliko osnovnih skupovnih operacija i svojstava vjerojatnosti. Označimo slučajne događaje $A =$ "položit ću Programiranje" i $B =$ "- "položit ću Matematiku". U zadatku je zadano

$$P(A) = 0,7, \quad P(B) = 0,5, \quad P(A^c \cap B^c) = 0,1.$$

Zbog jedne od De Morganovih formula je

$$(A \cup B)^c = A^c \cap B^c$$

pa je, prema formuli za vjerojatnost suprotnog događaja,

$$P(A \cup B) = 1 - P((A^c \cap B^c) = 1 - 0,1 = 0,9.$$

To je odgovor na prvo pitanje.
Da bi odgovorili na drugo pitanje uočimo da trebamo izračunati vjerojatnost slučajnog događaja

$$A^c \cap B.$$

Sada uočimo (nacrtajte Vennove dijagrame ako ne "vidite" odmah) da je

$$A^c \cap B = B \setminus A = B \setminus (A \cap B).$$

Kako je $A \cap B \subset B$ vrijedi

$$P(A^c \cap B) = P(B \setminus (A \cap B)) = P(B) - P(A \cap B).$$

$P(B)$ znamo, a $P(A \cap B)$ izračunamo

$$P(A \cap B) = P(A) + P(B) - P(A \cup B) = 0,7 + 0,5 - 0,9 = 0,3.$$

Stoga je tražena vjerojatnost jednaka

$$P(A^c \cap B) = P(B) - P(A \cap B) = 0,5 - 0,3 = 0,2.$$

Mala napomena: nije moguće općenito koristiti "jednostavnu" formulu

$$P(A^c \cap B) = P(A^c)P(B) = (1 - P(A))P(B) = 0,3 \cdot 0,7$$

jer ona vrijedi kada su A i B nezavisni, što općenito nije slučaj. Konkretno, u ovom zadatku A i B nisu nezavisni.

Rješenje 36 (Zadatak 4.8.6)**.** Kod ovakvog zadatka je korisno malo formalnije zapisati što je uopće zadano u zadatku. Označimo s A događaj "izvučena je kocka", a s B događaj "izvučen je plavi predmet". U zadatku je zadano $P(A) = 0,3$, $P(B) = 0,15$ i $P(A \cap B) = 0,05$, a pita se koliko je $P(A \cup B)$. Kada ovako postavimo zadatak sjetimo se (trebali bi se) osnovne formule za vjerojatnost unije $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ pa zapravo lagano izračunamo da je tražena vjerojatnost jednaka $0,4$. Time je zadatak riješen. Napomenimo sljedeće: da su A i B bili nezavisni događaji (na primjer A opisjue izbor predmeta iz jedne kutije, a B izbor predmeta iz druge kutije), onda ne bi ni trebali imati zadanu vjerojatnost $P(A \cap B)$ jer je za nezavisne događaje $P(A \cap B) = P(A) \cdot P(B)$.

Rješenje 37 (Zadatak 4.8.7)**.** Svi predmeti su različiti pa ih razlikujemo. Ukupan broj načina na koji možemo odabrati 4 proizvoda od $6+5=11$ njih je $\binom{11}{4}$ i svi su jednako vjerojatni. Stoga se zadatak može riješiti prebrojavanjem povoljnih slučajeva za svaki od navedenih slučajnih događaja navedenim pod a), b) ili c).
a) Odabiri u kojima nije odabran niti jedan mobitel su oni u kojima su odabrana 4 kalkulatora. Takvih odabira ima $\binom{6}{4}$. Stoga je tražena vjerojatnost jednaka

$$\frac{\binom{6}{4}}{\binom{11}{4}} = \frac{\frac{5\cdot 6}{2}}{\frac{8\cdot 9\cdot 10\cdot 11}{1\cdot 2\cdot 3\cdot 4}} \approx 0,0455.$$

b) Odabiri u kojima je odabran najviše jedan mobitel su oni u kojima je odabran točno jedan mobitel i oni u kojima nije odabran niti jedan mobitel. Broj načina na koji možemo odabrati samo jedan mobitel i 3 kalkulatora je jednak $\binom{5}{1}\binom{6}{3}$, a već smo vidjeli da je broj načina na koji možemo odabrati 4 kalkulatora (i niti jedan mobitel) jednak $\binom{6}{4}$. Stoga je tražena vjerojatnost jednaka

$$\frac{\binom{5}{1}\binom{6}{3}+\binom{6}{4}}{\binom{11}{4}} = \frac{\frac{5\cdot 6\cdot 5\cdot 4}{3\cdot 2\cdot 1}+\frac{6\cdot 5}{2}}{\frac{11\cdot 10\cdot 9\cdot 8}{4\cdot 3\cdot 2\cdot 1}} = \frac{\frac{5\cdot 6\cdot 5\cdot 4+6\cdot 5\cdot 3}{3\cdot 2\cdot 1}}{\frac{11\cdot 10\cdot 9\cdot 8}{4\cdot 3\cdot 2\cdot 1}} = \frac{4\cdot 23\cdot 6\cdot 5}{11\cdot 10\cdot 9\cdot 8} \approx 0,3485.$$

c) Odabiri u kojima je odabran barem jedan mobitel su oni u kojima je odabran jedan mobitel, dva mobitela tri mobitela ili četiri mobitela (od četiri odabrana predmeta). Relativno je lagano, a po uzoru na rješenje ovog zadatka pod b), izračunati broj odabira u svakom od tih slučajeva. Ipak, kao što smo već bili istaknuli u prethodnim zadacima, traženu vjerojatnost je lakše izračunati kao vjerojatnost suprotnog događaja od slučajnog događaja $A=$ "od četiri odabrana proizvoda niti jedan nije mobitel". U a) dijelu zadatka smo izračunali $P(A)=0,0455$ pa je tražena vjerojatnost, prema formuli za vjerojatnost suprotnog događaja (svojstvo (2) u Propoziciji 4.1.3), jednaka

$$1-P(A)=1-0,0455=0,9545.$$

Rješenje 38 (Zadatak 4.8.8)**.** Sve slučajne odabire 4 vina (po jedno iz svake od 4 kategorije) možemo predstaviti Kartezijevim produktom 4 skupa, pri čemu su u prvom skupu svi pjenušci, u drugom sva svježa bijela vina, u trećem sva odležana bijela vina i u četvrtom sva crna vina. Ukupan broj odabira je jednak ukupnom broju elemenata u tom Kartezijevom produktu skupova te su svi odabiri jednako vjerojatni (slučajni odabir). Stoga je ukupan broj odabira, prema principu umnoška, jednak

$$3\cdot 5\cdot 4\cdot 7=420.$$

Ako Vam je lakše tako gledati, broj ukupnih odabira je jednak formiranju uređene četvorke (p, sb, ob, c) gdje se na prvom mjestu može pojaviti jedan od 3 pjenušca, na drugom jedno od 5 sviježih bijelih vina i tako dalje.
Sličnim zaključivanjem možemo odgovoriti na postavljena pitanja.
a) Neka je A slučajan događaj "odabrana su sva vina proizvođača Alfa". Kako su svi odabiri 4 vina jednako vjerojatni primjenjiva je naivna defincija vjerojatnosti. Broj elemenata slučajnog događaja A određujemo na isti način kao i ukupan broj događaja. Naime, A se može prikazati kao Kartezijev produkt 4 skupa pri čemu se u prvom skupu nalazi jedan element (pjenušac), u drugom i trećem skupu po dva elementa i u četvrtom tri elementa. Stoga je tražena vjerojatnost jednaka

$$P(A)=\frac{1\cdot 2\cdot 2\cdot 3}{3\cdot 5\cdot 4\cdot 7}\approx 0,0286.$$

b) Pogledajmo slučajni događaj $B=$ "nije odabrano niti jedno vino proizvođača Alfa". Jasno, B^c je slučajni događaj čiju vjerojatnost želimo izračunati pa je ideja izračunati

vjerojatnost od B i onda iskoristiti formulu za izračun vjerojatnosti suprotnog događaja da bi izračunali traženu vjerojatnost. Uočimo, kada isključimo vina od Alfe preostaju nam za odabir 2 pjenušca, 3 svježa bijela vina, 2 odležana bijela vina i 4 crna vina. Stoga je

$$P(B) = \frac{2 \cdot 3 \cdot 2 \cdot 4}{3 \cdot 5 \cdot 4 \cdot 7} \approx 0,1143$$

pa je tražena vjerojatnost jednaka

$$P(B^c) = 1 - P(B) = 0,8857.$$

Rješenje 39 (Zadatak 4.8.9)**.** Na stolu imamo ukupno 12 predmeta i biramo 4 od njih na slučajan način. I bez napomene o različitosti predmeta bi to trebali pretpostaviti (napomenulo bi se da treba smatrati drugačije). U svakom slučaju svi ishodi tog slučajnog eksperimenta su jednako vjerojatni pa je primjenjiva naivna definicija vjerojatnosti. Ukupan broj odabira 4 predmeta od njih 12 (očito poredak nije važan) je

$$\binom{12}{4}.$$

Sada možemo odgovoriti na postavljena pitanja.
a) broj načina na koji možemo odabrati 2 kemijske olovke od 7 njih je $\binom{7}{2}$, a za svaki takav izbor možemo odbrati 2 obične olovke od 5 njih na $\binom{5}{2}$ načina. Prema principu produkta je tražena vjerojatnost jednaka

$$\frac{\binom{7}{2} \cdot \binom{5}{2}}{\binom{12}{4}} \approx 0,42.$$

b) Označimo sa A slučajni događaj "odabrana je barem jedna olovka". Mogli bi razložiti taj slučajni događaja na disjunktne događaje "odabrana je jedna olovka", "odabrane su dvije olovke", "odabrane su tri olovke" i "odabrane su četiri olovke", ali je lakše izračunati vjerojatnost od komplementa A^c = "nije odbrana niti jedna olovka". Dakle, vjerojatnost od A^c je zapravo vjerojatnost da su odabrane 4 kemijske olovke, a ona je jednaka

$$\frac{\binom{7}{4}}{\binom{12}{4}} \approx 0,07.$$

Sada je tražena vjerojatnost, prema formuli za vjerojatnost suprotnog događaja,

$$P(A) = 1 - P(A^c) = 1 - 0,07 \approx 0,93.$$

Rješenje 40 (Zadatak 4.8.10)**.** Na Ω je zadana vjerojatnost P svojim djelovanjem na elementarnim događajima

$$P(\{a\}) = P(\{b\}) = P(\{c\}) = P(\{d\}) = P(\{e\}) = P(\{f\}) = \frac{1}{6}.$$

P je uniformna vjerojatnost pa su svi elementarni događaji jednako vjerojatni. Stoga je primjenjiva naivna definicija vjerojatnosti pa je

$$P(A) = \frac{|\{a, b, c\}|}{|\Omega|} = \frac{3}{6} = \frac{1}{2}.$$

Alternativno, zbog konačne aditivnosti vjerojatnosti, imamo

$$P(A) = P(\{a\}) + P(\{c\}) + P(\{e\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}.$$

Slično je

$$P(B) = \frac{1}{2}.$$

Kako je

$$A \cap B = \{c\}$$

dobijemo

$$P(A \cap B) = \frac{1}{6}.$$

Dakle,

$$\frac{1}{6} = P(A \cap B) \neq P(A)P(B) = \frac{1}{2} \cdot \frac{1}{2}$$

pa slučajni događaji A i B nisu nezavisni.

Rješenje 41 (Zadatak 4.8.11)**.** Na Ω je zadana vjerojatnost P svojim djelovanjem na elementarnim događajima

$$P(\{a\}) = \frac{1}{6}, \quad P(\{b\}) = P(\{c\}) = P(\{d\}) = P(\{e\}) = \frac{1}{12}, \quad P(\{f\}) = \frac{1}{2}.$$

U ovom slučaju nisu svi elementarni događaji jednako vjerojatni pa naivna definicija vjerojatnosti nije primjenjiva. No, vjerojatnost je konačno aditivna pa je

$$P(A) = P(\{a\}) + P(\{c\}) + P(\{e\}) = \frac{1}{6} + \frac{1}{12} + \frac{1}{12} = \frac{4}{12} = \frac{1}{3}.$$

Slično je

$$P(B) = P(\{b\}) + P(\{c\}) + P(\{d\}) = \frac{1}{12} + \frac{1}{12} + \frac{1}{12} = \frac{3}{12} = \frac{1}{4}.$$

Kako je

$$A \cap B = \{c\}$$

dobijemo

$$P(A \cap B) = \frac{1}{12}.$$

Dakle,

$$\frac{1}{12} = P(A \cap B) = P(A)P(B) = \frac{1}{3} \cdot \frac{1}{4}$$

pa su slučajni događaji A i B nezavisni.
U ovom zadatku je važno uočiti, a zapravo se prisjetiti, da je naivna definicija vjerojatnosti samo ponekad primjenjiva (kada je vjerojatnost uniformna), ali konačna aditivnost vjerojatnosti uvijek vrijedi prema definiciji vjerojatnosti. Malo konkretnije, ako je vjerojatnost na konačnom ili prebrojivom skupu zadana na svim elementarnim događajima, onda je zbog (4.4) jednoznačno određena vjerojatnost svih slučajnih događaja na Ω.

Rješenje 42 (Zadatak 4.8.12)**.** Ovaj zadatak ćemo riješiti primjenom definicije uvjetne vjerojatnosti, odnosno formule (4.10). Zanimljivo je da praktički ne bi ni trebali tako računati zadane uvjetne vjerojatnosti jer se sve mogu izračunati iz odnosa skupa A sa skupovima B_1, B_2 i B_3.
Da bi riješili ovaj zadatak trebamo najprije uočiti da je prostor elementarnih događaja onaj isti Ω kao u 3.2.9, a što bi sada već trebali znati. Na njemu je definirana uniformna vjerojatnost P koja svim elementarnim događajima dodjeljuje istu vjerojatnost $1/36$. Skup A je jednak

$$\begin{aligned} A = \{&(1,2),(2,2),(3,2),(4,2),(5,2),(6,2) \\ &(1,4),(2,4),(3,4),(4,4),(5,4),(6,4), \\ &(1,6),(2,6),(3,6),(4,6),(5,6),(6,6)\}. \end{aligned}$$

pa je $P(A) = 18/36 = 1/2$. Izračunajmo tražene uvjetne vjerojatnosti.

i) Jasno je da je $B_1 = \{(1,4),(2,4),(3,4),(4,4),(5,4),(6,4)\}$ i $P(B_1) = 6/36 = 1/6$. S druge strane je $A \cap B_1 = B_1$. Zato je

$$P(A \mid B_1) = \frac{P(A \cap B_1)}{P(B_1)} = \frac{P(B_1)}{P(B_1)} = 1.$$

Intuitivno, kako je $B_1 \subset A$, znajući da se dogodio slučajni događaj B_1 znamo da se dogodio i događaj A pa je tražena uvjetna vjerojatnost jednaka 1. To je u skladu s napomenom s kraja primjera 4.5.3.

ii) $P(B_2) = 6/36 = 1/6$ zato što je $B_2 = \{(1,1),(2,1),(3,1),(4,1),(5,1),(6,1)\}$. S druge strane je $A \cap B_2 = \emptyset$ pa je

$$P(A \mid B_2) = \frac{P(A \cap B_2)}{P(B_2)} = \frac{0}{1/6} = 0.$$

I bez tog računa možemo znati da je $P(A \mid B_2) = 0$, jer su A i B_2 disjunktni.

iii) Sada je $B_3 = \{(1,1),(1,2),(1,3),(1,4),(1,5),(1,6)\}$, $P(B_3) = 6/36 = 1/6$, $A \cap B_3 = \{(1,2),(1,4),(1,6)\}$ i $P(A \cap B_3) = 3/36 = 1/12$. Računamo traženu uvjetnu vjerojatnost

$$P(A \mid B_3) = \frac{P(A \cap B_3)}{P(B_3)} = \frac{1/12}{1/6} = \frac{1}{2} = P(A).$$

Kao što vidimo, uvjetovanje na slučajan događaj B_3 ne mijenja vjerojatnost slučajnog događaja A. To je u skladu s formulom (4.11), odnosno činjenicom da su A i B_3 nezavisni događaji. Naime, vrijedi

$$\frac{1}{12} = P(A \cap B_3) = P(A)P(B_3) = \frac{1}{2} \cdot \frac{1}{6}.$$

Rješenje 43 (Zadatak 4.8.13)**.** Kako su u zadatku opisana dva uzastopna slučajna eksperimenta - odabir čokolade iz prve kutije i odabir čokolade iz druge kutije, s time da ishodi odabira čokolade iz druge kutije ovise o prvom odabiru, gotovo se nameće pokušati iskoristiti formulu potpune vjerojatnosti (4.14). U tu svrhu definirajmo dva disjuktna slučajna događaja koji iscrpljuju sve mogućnosti ishoda prvog slučajnog eksperimenta (unija im je Ω za prvi slučajni eksperiment)

$$H_1 = \{\text{odabrana je čokolada s lješnjacima}\} \quad \text{i}$$

$$H_2 = \{\text{odabrana je čokolada s rižom}\}.$$

Te vjerojatnosti lagano izračunamo. Ukupno imamo 6 čokolada u prvoj kutiji i od toga su 4 s lješnjacima i 2 s rižom pa je

$$P(H_1) = \frac{4}{6} = \frac{2}{3} \quad \text{i} \quad P(H_2) = \frac{2}{6} = \frac{1}{3}.$$

Neka je A slučajan događaj "iz druge kutije je odabrana čokolada s rižom". Prema formuli potpune vjerojatnosti je

$$P(A) = P(A \mid H_1)P(H_1) + P(A \mid H_2)P(H_2).$$

Poanta formule potpune vjerojatnosti je da uvjetne vjerojatnosti $P(A \mid H_i)$, $i = 1, 2$, lagano izračunamo. U ovom slučaju je to svakako istina jer znamo sastav druge kutije ako znamo koja je čokolada premještena u nju, a to znamo ako znamo da li se dogodio

H_1 ili H_2 (koji su disjunktni). Ako je premještena čokolada s lješnjacima, onda se u drugoj kutiji nalaze 4 čokolade s lješnjacima i 3 čokolade s rižom. Stoga je

$$P(A \mid H_1) = \frac{3}{7}.$$

Ako je u drugu kutiju premještena čokolada s rižom, onda se u drugoj kutiji nalaze 3 čokolade s lješnjacima i 4 čokolade s rižom pa je

$$P(A \mid H_2) = \frac{4}{7}.$$

Prema formuli potpune vjerojatnosti je

$$P(A) = \frac{3}{7} \cdot \frac{2}{3} + \frac{4}{7} \cdot \frac{1}{3} = \frac{6+4}{21} \approx 0,4762.$$

Napomena: u zadatku smo istaknuli da su čokolade različite, ali općenito to nije potrebno učiniti. Situacija je slična kao da u kutijama imamo kuglice dvije boje, a odabiri se u tom slučaju obavljaju uz pretpostavku da su kuglice fizički različite. U problemima u kojima možemo (ili trebamo) pretpostaviti da su one jednake ta pretpostavka slijedi ili iz prirode problema (poput nekih problema u prethodnom poglavlju) ili uz eksplicitnu napomenu da kuglice/čokolade ne možemo razlikovati.

Rješenje 44 (Zadatak 4.8.14)**.** Neka je A slučajni događaj "meta je pogođena samo jednom". S obzirom da ne znamo koji je strijelac pogodio metu čini se perspektivnim rastaviti skup svih mogućnosti pogodaka u metu na potpun sustav događaja. U tu svrhu definirajmo slučajne događaje

$$H_1 = \{\text{oba strijelca su promašila metu}\},$$

$$H_2 = \{\text{prvi strijelac je pogodio metu, a drugi promašio}\},$$

$$H_3 = \{\text{prvi strijelac je promašio metu, a drugi pogodio}\},$$

$$H_4 = \{\text{oba strijelca su pogodila metu}\}.$$

Jasno je da su svi H_i, $i = 1, 2, 3, 4$, međusobno disjunktni te se svakako jedan do tih slučajnih događaja mora dogoditi ($\cup_{i=1}^{4} H_i = \Omega$). Stoga oni čine potpun sustav događaja. S obzirom da strijelci gađaju metu nezavisno jedan o drugome lagano izračunamo vjerojatnost od H_i:

$$P(H_1) = 0,2 \cdot 0,4 = 0,08,$$

$$P(H_2) = 0,8 \cdot 0,4 = 0,32,$$

$$P(H_3) = 0,2 \cdot 0,6 = 0,12,$$

$$P(H_4) = 0,8 \cdot 0,6 = 0,12.$$

Kako je $P(A \mid H_1) = P(A \mid H_4) = 0$ i $P(A \mid H_2) = P(A \mid H_3) = 1$ korištenjem formule potpune vjerojatnosti (4.14) lagano izračunamo

$$P(A) = P(A \mid H_2)P(H_2) + P(A \mid H_3)P(H_3) = 1 \cdot 0,32 + 1 \cdot 0,12 = 0,44.$$

Sada iskoristimo Bayesovu formulu (4.13) da izračunamo $P(H_2 \mid A)$. Imamo

$$P(H_2 \mid A) = \frac{P(H_2)P(A \mid H_2)}{P(A)} = \frac{0,32}{0,44} \approx 0,727.$$

Uočimo da se potpun sustav događaja može definirati na različite načine. Na primjer, mogli smo definirati slučajne događaje

$$G_1 = \{\text{prvi strijelac je pogodio metu}\},$$

$$G_2 = \{\text{prvi strijelac je promašio metu}\}.$$

Opet je riječ o disjunktnim događajima koji iscrpljuju sve mogućnosti, odnosno

$$\{G_1, G_2\} = \{G_1, G_1^c\}$$

čini potpun sustav događaja. Naravno, $P(G_1) = 0,8$, a $P(G_2) = 1 - P(G_1) = 0,2$. Uvjetne vjerojatnosti $P(A \mid G_1)$ i $P(A \mid G_2)$ su sada drugačije od uvjetnih vjerojatnosti koje smo ranije računali jer su sada informacije koje su nam poznate drugačije. Konkretno, $P(A \mid G_1)$ je vjerojatnost da je meta pogođena jednom ako znamo da je prvi strijelac pogodio metu. To je moguće samo ako je drugi strijelac promašio metu pa je $P(A \mid G_1) = 0,4$. Malo formalnije možemo računati i na sljedeći način

$$P(A \mid G_1) = \frac{P(A \cap G_1)}{P(G_1)} = \frac{P(H_2)}{P(G_1)} = \frac{0,32}{0,8} = 0,4.$$

Slično vidimo da je

$$P(A \mid G_2) = 0,6.$$

Opet iskoristimo formulu potpune vjerojatnosti, s time da sada možemo iskoristiti verziju danu u relaciji (4.15), da dobijemo

$$P(A) = P(A \mid G_1)P(G_1) + P(A \mid G_2)P(G_2) = 0,4 \cdot 0,8 + 0,6 \cdot 0,2 = 0,44.$$

Korištenjem Bayesove formule napokon dobijemo

$$P(G_1 \mid A) = \frac{P(G_1)P(A \mid G_1)}{P(A)} = \frac{0,32}{0,44} \approx 0,727.$$

Rješenje 45 (Zadatak 4.8.15)**.** Kako su u zadatku opisana dva uzastopna slučajna eksperimenta - bacanje novčića i slučajan odabir 2 kuglice od 10 njih, te ishod drugog eksperimenta ovisi o prvome (tako određujemo iz koje kutije biramo kuglice) gotovo se nameće pokušati iskoristiti formulu potpune vjerojatnosti (4.14). U tu svrhu definirajmo tri disjuktna slučajna događaja koji iscrpljuju sve mogućnosti ishoda prvog slučajnog eksperimenta (unija im je Ω za prvi slučajni eksperiment)

$$H_1 = \{\text{ na dva novčića su pale dvije glave}\},$$

$$H_2 = \{\text{ na dva novčića su pala dva pisma}\} \text{ i}$$

$$H_3 = \{\text{ na dva novčića je pala jedna glava i jedno pismo}\}.$$

Skup svih elementarnih događaja pri bacanju dva novčića je

$$\Omega = \{(P,P), (P,G), (G,P), (G,G)\}$$

i svi su ti elementarni događaji jednako vjerojatni. Stoga je

$$P(H_1) = 1/4, \quad P(H_2) = 1/4, \quad P(H_3) = 1/2.$$

Neka je A slučajan događaj "odabrane su dvije bijele kuglice". Prema formuli potpune vjerojatnosti je

$$P(A) = P(A \mid H_1)P(H_1) + P(A \mid H_2)P(H_2) + P(A \mid H_3)P(H_3).$$

Opet ističemo, poanta formule potpune vjerojatnosti je da uvjetne vjerojatnosti $P(A \mid H_i)$, $i = 1, 2, 3$, lagano izračunamo jer znamo koja je kutija odabrana. Ako je odabrana prva kutija, onda biramo dvije kuglice od deset njih, to možemo napraviti na $\binom{10}{2}$ načina (poredak nije važan), a dvije bijele kuglice od dvije bijele kuglice možemo odabrati na $\binom{2}{2} = 1$ način. Stoga je

$$P(A \mid H_1) = \frac{1}{\binom{10}{2}}.$$

Slično izračunamo

$$P(A \mid H_2) = \frac{\binom{4}{2}}{\binom{10}{2}} \quad \text{i} \quad P(A \mid H_3) = \frac{\binom{6}{2}}{\binom{10}{2}}.$$

Prema formuli potpune vjerojatnosti je

$$P(A) = \frac{1}{\binom{10}{2}} \cdot \frac{1}{4} + \frac{\binom{4}{2}}{\binom{10}{2}} \cdot \frac{1}{4} + \frac{\binom{6}{2}}{\binom{10}{2}} \cdot \frac{1}{2} = \frac{1 + \binom{4}{2} + 2\binom{6}{2}}{4\binom{10}{2}} = \frac{37}{180} \approx 0,206.$$

Za izračun druge vjerojatnosti koristimo Bayesovu formulu (4.13). Imamo

$$P(H_1 \mid A) = \frac{P(A \mid H_1)P(H_1)}{P(A)} = \frac{\frac{1}{4\binom{10}{2}}}{0,206} \approx 0,027.$$

Rješenje 46 (Zadatak 4.8.16)**.** Ukoliko znamo težinu protivnika protiv kojega igramo (razinu igre) nemamo problema s računanjem vjerojatnosti (jer su zadane). Problem je što se težina protivnika protiv kojega igramo bira na slučajan način. Ideja rješavanja zadatka je razdijeliti slučajeve težine protivnika, odnosno definirati potpun sustav događaja. U tu svrhu definirajmo disjunktne događaje H_i, $i = 1, 2, 3$, koji čine potpun sustav događaja.
Dakle, definiramo da je H_1 događaj "odabrana je razina za početnike", H_2 događaj "odabrana je srednja razina" i H_3 događaj "odabrana je napredna razina". Svi su ti događaji disjunktni, a unija im je skup svih mogućih događaja (osnovni slučajni eksperiment je odabir razine na kojoj igramo). Prema uvjetima zadatka je $P(H_1) = P(H_2) = P(H_3) = 1/3$. Ako dodatno definiramo događaj A kao događaj "pobijedili ste u partiji šaha na odabranoj razini", onda je u zadatku zadano i $P(A \mid H_1) = 0,8$, $P(A \mid H_2) = 0,5$ i $P(A \mid H_1) = 0,3$.Prema formuli potpune vjerojatnosti je

$$P(A) = P(A \mid H_1)P(H_1) + P(A \mid H_2)P(H_2) + P(A \mid H_2)P(H_3).$$

S obzirom da su nam sve vjerojatnosti s desne strane gornje jednakosti poznate lagano izračunamo

$$P(A) = \frac{0,8 + 0,5 + 0,3}{3} \approx 0,533.$$

Time je dan odgovor na prvo pitanje. Da bi odgovorili na drugo pitanje koristimo Bayesovu formulu (formula (4.13)):

$$P(H_1 \mid A) = \frac{P(A, H_1)}{P(A)} = \frac{P(A \mid H_1)P(H_1)}{P(A)}.$$

Kako smo upravo izračunali $P(A)$ opet s desne strane gornje jednakosti imamo sve poznate vrijednosti pa je

$$P(H_1 \mid A) = \frac{0,8 \cdot 1/3}{0,533} \approx 0,5.$$

Za vježbu probajte izračunati $P(H_2 \mid A)$ i $P(H_3 \mid A)$. Uočite da zbroj te tri uvjetne vjerojatnosti treba biti jednak 1 jer je $P(\cdot \mid A)$ i sama vjerojatnost (dobiju se vjerojatnosti $0,3125$ i $0,1875$).

Ovaj zadatak bi se mogao proširiti tako da prepostavimo da je pobjeda (općenito ishod partije) na bilo kojoj razini težine na kojoj igra računalni šahovski program nezavisna u svakom ponavljanju igre i jednaka je u svakoj igri (dakle, ako igramo na srednjoj razini je pobjeda u drugoj igri nezavisna od one u prvoj igri i jednaka je, opet, $0,5$). Pretpostavimo to i pretpostavimo da ste dosta brzo odigrali prvu partiju pa kako imate još vremena nastavljate igrati još jednu partiju šaha i to na istoj razini na kojoj ste odigrali prvu partiju. Ako s B označimo događaj "pobijedili ste u drugoj partiji šaha na odabranoj razini", možemo se pitati koja je vjerojatnost da ćete pobjediti u drugoj partiji šaha ako ste pobijedili u prvoj, odnosno želimo izračunati $P(B \mid A)$. Tu uvjetnu vjerojatnost možemo izračunati prema formuli (4.5.14) u Napomeni 4.20:

$$P(B \mid A) = \sum_{i=1}^{3} P(B \mid H_i \cap A) P(H_i \mid A)$$

$P(H_i \mid A)$, $i = 1, 2, 3$, smo već izračunali. Što se tiče vjerojatnosti $P(B \mid H_i \cap A)$ trebamo uočiti da je se pobjeda u drugoj partiji ostvaruje neovisno o onoj u prvoj partiji pa je samo važno koja je razina težine isprve bila odabrana. Stoga je $P(B \mid H_1 \cap A) = 0,8$, $P(B \mid H_2 \cap A) = 0,5$ i $P(B \mid H_3 \cap A) = 0,3$. Prema gornjoj formuli tada imamo

$$P(B \mid A) = 0,8 \cdot 0,5 + 0,5 \cdot 0,3125 + 0,3 \cdot 0,1875 = 0,6125.$$

Rješenje 47 (Zadatak 4.8.17)**.** Ako smo pročitali Primjer 4.4.1 prva ideja za izračun vjerojatnosti slučajnog događaja E nam može biti da gledamo komplement od E:

$$E^c = \Big(\bigcup_{j=1}^{9} (A_j \cap A_{j+1})\Big)^c = \bigcap_{j=1}^{9} (A_j^c \cup A_{j+1}^c).$$

Problem je što sada za skupove u tom presjeku ne možemo jednostavno argumentirati da su nezavisni. S druge strane, u originalnoj uniji

$$\bigcup_{j=1}^{9} (A_j \cap A_{j+1})$$

nemamo disjunktne događaje pa ne možemo iskoristiti konačnu aditivnost vjerojatnosti. Ako se okrenemo prebrojavanju ishoda bacanja u kojima se pojavljuju barem dva uzastopna bacanja u kojima je pala glava, ubrzo shvaćamo da prilično lagano možemo prebrojati bacanja u kojima su u točno dva (i samo dva) uzastopna bacanja na novčićima pale glave, ali prelazak na "barem dva uzastopna bacanja" nije očit.
U takvoj situaciji, u kojoj nije jasno kako bismo nastavili s rješavanjem zadatka. nije loše pokušati shvatiti što se događa u slučajevima kada imamo manji broj bacanja novčića: 2, 3 ili 4 bacanja. Uzmimo za početak dva bacanja novčića. Uz identifikaciju glave s 1 i pisma s 0 vidimo da su sve mogućnosti u dva uzastopna bacanja novčića

$$(0,0), (1,0), (0,1), (1,1).$$

Samo se u jednom slučaju pojavljuju dva uzastopna bacanja u kojima je pala glava. Dakle, za $n = 2$ je broj slučajeva u kojima je barem u dva uzastopna bacanja pala glava jednak $D(2) = 1$.
Pogledajmo sada što se događa kada imamo tri bacanja novčića. Tada su sve mogućnosti

$$(0,0,0), (0,0,1), (0,1,0), (0,1,1)(1,0,0), (1,0,1), (1,1,0), (1,1,1).$$

Sada su bacanja u kojima se pojavljuje glava barem dva puta uzastopno $(0,1,1)$, $(1,1,0)$ i $(1,1,1)$. Dakle, za $n = 3$ je $D(3) = 3$.

Pogledajmo sada što se događa kada imamo četiri uzastopna bacanja novčića. Tada su sve mogućnosti

$$(0,0,0,0),(0,0,0,1),(0,0,1,0),(0,0,1,1)(0,1,0,0),(0,1,0,1),(0,1,1,0),(0,1,1,1)$$
$$(1,0,0,0),(1,0,0,1),(1,0,1,0),(1,0,1,1)(1,1,0,0),(1,1,0,1),(1,1,1,0),(1,1,1,1)$$

Prebrajanjem vidimo da je $D(4) = 8$ za $n = 4$. Razmislimo što se tu događa, pri čemu ćemo apstrahirati prirodu nastanka nula i jedinica i koncentrirati se samo na prebrojavanje uzastopnih jedinica. Nizovi nula i jedinica duljine 4 nastaju od nizova duljine 3 kojima na početku dodajemo 0 ili 1. Ako dodajemo 0 na početak niza duljine 3, onda ne možemo dobiti dodatni niz koji sadrži dvije uzastopne jedinice pa nizova duljine 4 koji sadrže dvije uzastopne jedinice i počinju s nulom ima kao nizova duljine 3 koji sadrže dvije uzastopne jedinice (dakle, 3). Ako dodamo jedinicu na početak možemo razlikovati dva slučaja. Ako je na drugom mjestu 0, onda dodavanje jedinice na početak ne može napraviti dvije uzastopne jedinice. Kako su preostala samo dva mjesta znamo da na njima ima samo jedan niz (to je $(1,1)$) koji ima dvije uzastopne jedinice. Ako je na drugom mjestu 1, onda dodavanje jedinice na prvo mjesto odmah čini taj niz nula i jedinica takvim da sadrži barem dvije uzastopne jedinice. Takvih nizova ima kao i nizova duljine 3 koji na prvom mjestu imaju 1, a to je jednako 4, odnosno 2^2. Čini se da vrijedi relacija $D(4) = D(3) + D(2) + 2^2$.
Pogledajmo što se događa za pet uzastopnih bacanja novčića. Napišimo najprije sve slučajeve. Dobivamo

$$(0,0,0,0,0),(0,0,0,0,1),(0,0,0,1,0),(0,0,0,1,1)(0,0,1,0,0),(0,0,1,0,1),(0,0,1,1,0),(0,0,1,1,1)$$
$$(0,1,0,0,0),(0,1,0,0,1),(0,1,0,1,0),(0,1,0,1,1)(0,1,1,0,0),(0,1,1,0,1),(0,1,1,1,0),(0,1,1,1,1)$$
$$(1,0,0,0,0),(1,0,0,0,1),(1,0,0,1,0),(1,0,0,1,1)(1,0,1,0,0),(1,0,1,0,1),(1,0,1,1,0),(1,0,1,1,1)$$
$$(1,1,0,0,0),(1,1,0,0,1),(1,1,0,1,0),(1,1,0,1,1)(1,1,1,0,0),(1,1,1,0,1),(1,1,1,1,0),(1,1,1,1,1)$$

Prebrajanjem vidimo da je sada broj nizova koji sadrže barem dvije uzastopne jedinice jednak $D(5) = 19$. Provjerimo logiku koju smo primijenili na nizovima duljine 4. Kada dodamo nulu na početak niza duljine 4 ne možemo dobiti dodatni niz s uzastopnim jedinicama pa takvih nizova ima $D(4) = 8$. Kada dodamo jedinicu na početak, a na drugom mjestu se nalazi nula, onda preostaju 3 mjesta na kojima se mogu mijenjati nule i jedinice, a nizova duljine 3 koji sadrže barem dvije uzastopne jedinice ima $D(3) = 3$. Napokon, kada se na drugom mjestu nalazi jedinica, onda dodavanje jedinice na prvo mjesto odmah stvara niz u kojem imamo barem dvije uzastopne jedinice. Nizova duljine 4 koji na prvom mjestu imaju jedinicu ima $2^3 = 8$. Zbrojimo te brojeve da dobijemo $8 + 3 + 8 = 19$.
Istu logiku možemo primijeniti i na nizove duljine 6, i tako dalje. Zaključujemo da vrijedi rekurzija

$$D(n) = D(n-1) + D(n-2) + 2^{n-2}, n \geq 4. \tag{4.23}$$

Nas zanima $D(10)$. Pomoću R-a izračunamo taj broj:

```
> d1<-3
> d2<-8
> for (i in 5:10){
+   d3<-d1+d2+2^(i-2)
+   d1<-d2
+   d2<-d3
+ }
> print(d3)
```

```
[1] 880
```

Kako nizova nula i jedinica duljine 10 ima $2^{10} = 1024$ zaključujemo da je

$$P(E) = \frac{880}{1024} \approx 0,8594.$$

Slično, a možda i lakše, bismo zaključivali da smo gledali E^c i uočili da taj skup čine nizovi u kojima nema uzastopnih jedinica. Prebrojavanjem vidimo da za $n = 2$ takvih nizova ima 3, za $n = 3$ takvih nizova ima 5, za $n = 4$ takvih nizova ima 8 i tako dalje. Za općeniti n odmah isključimo nizove koji počinju s 11 (oni sadrže dvije uzastopne jedinice) i pogledamo nizove koji počinju s 0 ili 10. Nizova duljine n koji počinju s 0 i ne sadrže dvije jedinice ima kao i onih duljine $n - 1$, a onih koji počinju s 10, a ne sadrže dvije jedinice ima kao i onih duljine $n - 2$. U ovom slučaju dobivamo rekurziju $N(n) = N(n-1) + N(n-2)$, gdje je $N(n)$ broj nizova duljine n koji ne sadrže dvije uzastopne jednice. Riječ je poznatoj rekurziji koja generira Fibonaccijeve brojeve. Proizlazi da nizova nula i jedinica duljine 10 koji ne sadrže dvije uzastopne jedinice ima $N(10) = F(12) = 144$ pa je tražena vjerojatnost jednaka

$$1 - \frac{144}{1024} = \frac{880}{1024}.$$

Napomenimo još da je problem nalaženja nizova koji sadrže "točno dvije jedinice" (u točno dva bacanja je pala glava) značajno lakši, odnosno lakše ga možemo uklopiti u okvir uobičajenijih vjerojatnosnih problema i to korištenjem binomnih slučajnih varijabli, odnosno binomne razdiobe. O tome ćemo više reći u sljedećem poglavlju.
Ako vam je gornje rješenje "sumnjivo" probajte generirati na računalu sve nizove nula i jedinica duljine 10 i prebrojati one koji imaju barem dvije uzastopne jedinice.

Poglavlje 5

Slučajne varijable i njihove razdiobe

Vidjeli smo u prethodnom poglavlju kako se slučajni eksperimenti modeliraju (opisuju) prostorom elementarnih događaja Ω, odnosno skupom svih (nerazloživih) ishoda nekog eksperimenta na kojem je definirana vjerojatnosna funkcija P. U nekim primjerima smo vidjeli da prostori elementarnih događaja i slučajni događaji na njima mogu biti dosta kompleksni, kao i njihov zapis. Dodatno, često se javlja potreba za modeliranjem složenijih slučajnih eksperimenata (bacanje kockice pa bacanje novčića pa izvlačenje koglice iz kutije i tako dalje) pa se postavlja pitanje kako definirati vjerojatnosni prostor koji može modelirati takve složenije slučajne eksperimente, pogotovo ako nisu nezavisni. U vjerojatnosti i statistici je uobičajeno "teret" opisivanja ishoda nekog slučajnog eksperimenta i računanja specifičnih vjerojatnosti prebaciti s vjerojatnosnog prostora na **slučajne varijable**. U drugom koraku čak niti pojedinačne slučajne varijable neće biti od primarnog interesa, nego njihove **razdiobe**. Svi ti pojmovi uključuju određenu razinu apstrahizacije pa je potrebno uložiti određeni napor da bi se ovladalo njima. No, objekti i terminologija koji će biti uvedeni u ovom poglavlju predstavljaju temelj suvremene vjerojatnosti i statistike i praktički je nemoguće nastaviti razvoj bilo kakve suvislije teorije bez poznavanja istih.

5.1 Slučajne varijable

Često se događa da zapravo nismo zainteresirani za sve ishode slučajnog eksperimenta, pogotovo ako ih ima puno, nego za neke kvantitativne karakteristike vezane uz taj slučajni eksperiment. Na primjer, kod dva bacanja simetričnog novčića (ili više njih) možemo biti zainteresirani za broj pojavljivanja glave u ta dva bacanja ili kod bacanja dvije igraće kocke možemo biti zainteresirani za zbroj brojeva koji su pali na kockama. Kod skupa svih ljudi možemo biti zainteresirani za visinu ili težinu pojedinog čovjeka, a kod skupa nekih proizvoda za njihovu cijenu ili količinu. Sve su to primjeri kvantitativnih karakteristika koje pridružujemo nekom skupu elementarnih događaja, odnosno ishodima nekog slučajnog eksperimenta. U vjerojatnosti i statistici se takve kvantitativne karakteristike opisuju slučajnim varijablama. Imamo sljedeću definiciju.

Definicija 5.1.1. Neka je Ω neki skup elementarnih događaja na kojem je definirana vjerojatnost P. **Slučajna varijabla** X je funkcija definirana na Ω i s vrijednostima u $\mathbb{R}$. Pišemo

$$X : \Omega \to \mathbb{R}.$$

Kada pogledamo prethodnu definiciju ne vidimo ništa neuobičajeno. Imamo (determinističku) funkciju kojoj je domena skup Ω, a kodomena skup realnih brojeva $\mathbb{R}$. Jedino je čudno što funkciju označavamo velikim slovom, što je uobičajeno u vjerojatnosti i statistici, dok su uobičajene oznake za funkcije f, g, h i slično. Ono što funkciju X

iz prethodne definicije čini posebnom je njena domena. Naime $(\Omega, \mathcal{F}, P)$ je vjerojatnosni prostor pa je funkcija X definirana na vjerojatnosnom prostoru. U takvom kontekstu se funkcije nazivaju slučajnim varijablama.

Zašto je uopće važno da je slučajna varijabla X definirana na vjerojatnosnom prostoru? Zato što nam to omogućava da računamo neke vjerojatnosti vezane uz slučajne varijable. Da vidimo o čemu je tu riječ uzmimo "običnu" funkciju $f : \mathbb{R} \to [0, +\infty)$ definiranu s

$$f(x) = x^2, \ x \in \mathbb{R}.$$

U primjenama je često važno odrediti sve točke domene za koje se vrijednost funkcije nalazi u nekom skupu. Tipični skupovi u $\mathbb{R}$ su segmenti $[c, d]$ ili intervali (c, d) (ili unije i presjeci takvih skupova), gdje su $c, d \in \mathbb{R}$, $c \leq d$. To zapravo znači da se pitamo koji su to elementi sljedećeg skupa

$$A := \{x \in \mathbb{R} \mid c \leq f(x) \leq d\}$$

koji je podskup domene funkcije f. Terminološki, skup A se naziva **praslikom** skupa $[c, d]$. Često se koristi oznaka

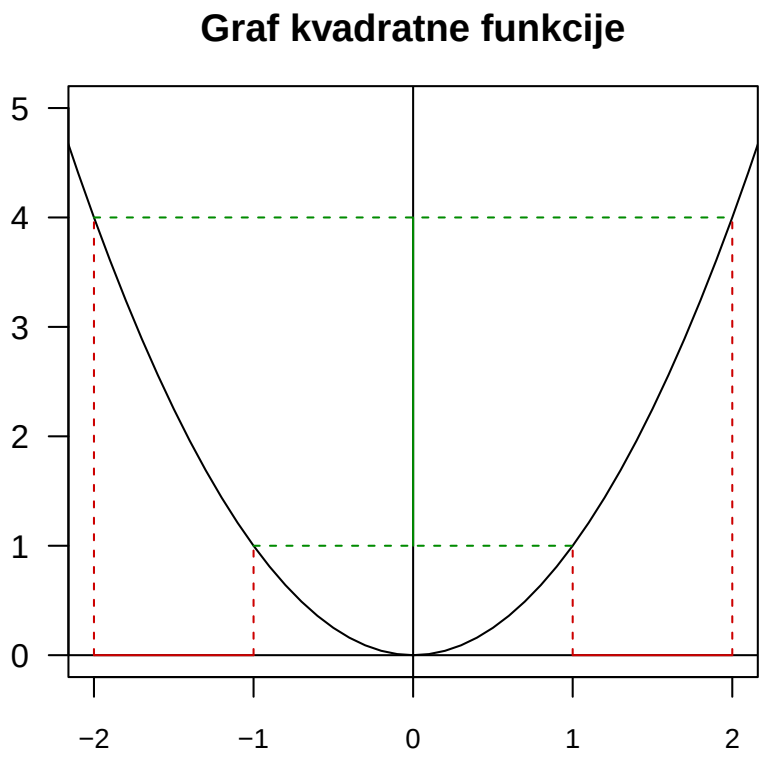
$$A = f^{-1}([c, d])$$

pri čemu f^{-1} ne shvaćamo kao inverznu funkciju (jer ne mora ni postojati ako f nije bijekcija), nego kao skup svih točaka iz domene koje f preslikava u $[c, d]$.

Za konkretnu funkciju $f(x) = x^2$ i, na primjer, $c = 1$ i $d = 4$ dobivamo

$$A := \{x \in \mathbb{R} \mid 1 \leq x^2 \leq 4\} = [-2, -1] \cup [1, 2].$$

Na sljedećem grafu su prikazani skupovi $[-2, -1] \cup [1, 2] \subset \mathbb{R}$ (crvenom bojom, na x osi) i $[1, 4] \subset [0, +\infty)$ (zelenom bojom, na y osi). U terminima praslike, A je praslika segmenta $[1, 4]$ po funkciji x^2.



Uzmimo sada slučajnu varijablu $X : \Omega \to \mathbb{R}$. Kao i kod "običnih" funkcija, možemo se pitati koji su elementi domene za koje je vrijednost od X u nekom segmentu $[c, d]$.

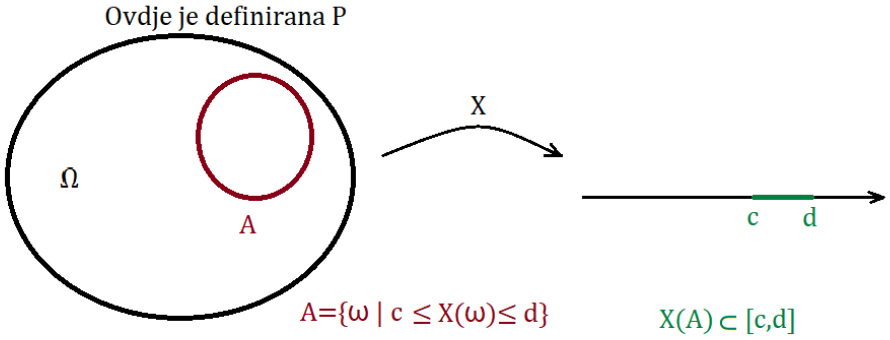
Dakle, pitamo se koji je to skup

$$A := \{\omega \in \Omega \mid c \leq X(\omega) \leq d\}. \tag{5.1}$$

Sada uočimo da je $A \subset \Omega$ pa je to slučajan događaj (pogledajte Napomenu 5.1.2 u nastavku). No, onda možemo izračunati i vjerojatnost od A, odnosno načelno znamo kolika je vjerojatnost

$$P(\{\omega \in \Omega \mid c \leq X(\omega) \leq d\}) \in [0, 1].$$

To je nova informacija koja, općenito govoreći, nije dostupna za neku proizvoljnu funkciju f i to je posebnost slučajnih varijabli. Shematski promatranu situaciju prikazujemo na donjoj slici. U skladu s uvedenim pojmom praslike možemo reći da je slučajni događaj A praslika segmenta $[c, d]$ pa možemo pisati i $X^{-1}([c, d]) = A$. U nastavku ćemo češće koristiti zapis kao u relaciji (5.1).



Napomena 5.1.2 (Općenite slučajne varijable)**.** Do uvođenja pojma slučajne varijable nije bilo prevažno da li radimo s općenitim vjerojatnostnim prostorom $(\Omega, \mathcal{F}, P)$ ili diskretnim vjerojatnosnim prostorom $(\Omega, \mathcal{P}(\Omega), P)$. Ovdje razlika postaje važna, ali ćemo je u nastavku zanemariti. Naime, ako gledamo definiciju slučajne varijable i posebno relaciju (5.1) trebamo uočiti da nemamo garanciju da će skup A zaista biti slučajan događaj, odnosno da će biti $A \in \mathcal{F}$. Da bi to bilo uvijek zadovoljeno ipak treba imati malo veći zahtjev na funkciju X: ona mora biti izmjeriva. Zahtjev za izmjerivošću zapravo i znači da su praslike intervala iz $\mathbb{R}$ sadržane u σ-algebri $\mathcal{F}$. Uvođenje pojma izmjerive funkcije prilično komplicira razvoj teorije koju predstavljamo pa je uobičajeno preskočiti taj dio teorije u uvodnim kolegijima iz vjerojatnosti te u velikom dijelu statistike. U skladu s time, u nastavku skripte se izmjerivost funkcija neće koristiti. Znatiželjniji studenti ne trebaju previše brinuti oko ove činjenice - može se predstaviti velik broj rezultata i bez pojma izmjerivosti funkcije. Dodatno, neprekidne funkcije su izmjerive pa to zapravo znači da je velik broj funkcija izmjeriv. Napokon, na diskretnim vjerojatnosnim prostorima je situacija opet jednostavnija jer je svaka funkcija na Ω izmjeriva (str. 236 u [10]). □

Napomena 5.1.3 (Skraćeni zapis vjerojatnosti slučajnih događaja)**.** U vjerojatnosti je uobičajeno vjerojatnost slučajnih događaja vezanih uz slučajne varijable zapisivati u skraćenoj formi. Naime, umjesto da pišemo

$$P(\{\omega \in \Omega \mid c \leq X(\omega) \leq d\})$$

u pravilu ćemo pisati skraćeno

$$P(c \leq X \leq d).$$

Uočite da su u drugom izrazu izostavljene vitičaste zagrade i, što je za razumijevanje značajno problematičnije, argument ω. Razlog za takav, skraćeni, zapis, treba tražiti u efikasnijem predstavljanju vjerojatnosnih izračuna. U skladu s time, za neki $B \subset \mathbb{R}$ ćemo pisati

$$P(X \in B), \tag{5.2}$$

ili čak

$$P(X^{-1}(B)),$$

ali vrlo rijetko

$$P(\{\omega \in \Omega \mid X(\omega) \in B\}).$$

Slično, možemo pisati, na primjer

$$P(X > 0)$$

ili

$$P(X \in (0, +\infty)),$$

ali ćemo rijetko koristiti zapis

$$P(\{\omega \in \Omega \mid X(\omega) > 0\}).$$

Ovaj skraćeni zapis definitivno može izazvati pomutnju kada gledamo neke vjerojatnosti. Primjerice, uzmimo X i Y dvije slučajne varijable na Ω i primjetimo (kao što smo već vidjeli u Napomeni 4.5.14) da se u vjerojatnosti za presjek skupova često koristi zarez umjesto znaka $\cap$. Tako ćemo vjerojatnost slučajnog događaja u kojem je X veći od nule, a Y manji ili jednak od jedan kratko zapisati kao

$$P(X > 0, Y \leq 1),$$

dok se zapravo radi o vjerojatnosti

$$P(\{\omega \in \Omega \mid X(\omega) > 0\} \cap \{\omega \in \Omega \mid Y(\omega) \leq 1\}).$$

Ovdje vidimo zorno prednost "kratke notacije", ali i problem s pravilnom interpretacijom iste ukoliko nismo dovoljno koncentrirani na objekte s kojima radimo ili jednostavno nismo dovoljno istrenirani da prihvatimo konvenciju o zapisu vjerojatnosti slučajnih događaja vezanih uz slučajne varijable o kojima govorimo u ovoj napomeni.
Ono što uvijek trebamo imati na umu je činjenica da je **vjerojatnost funkcija definirana na skupovima** pa se u slučaju dvojbe o tome na što se vjerojatnost odnosi trebamo podsjetiti te činjenice i vidjeti o kojem se točno skupu radi u nekom specifičnom slučaju. □

R kod 5.1.4. Radi lakše čitljivosti teksta smo prijašnji graf kvadratne funkcije s označenim skupovima na domeni (x-osi) i kodomeni (y-osi) u različitim bojama prikazali bez R koda. Radi potpunosti, a s obzirom da nam je jedan od ciljeva da se naučimo koristiti R-om, na ovom mjestu dajemo prikaz tog koda. Vidjet ćete da smo koristili funkciju `segments` koja nam omogućuje da na jednostavan način dodajemo razne linije po grafu. Za sam prikaz grafa smo koristili osnovnu R-ovu funkciju `plot`.

```
> par(mar=c(2,3,3,2))
> x<- seq(-4,4, 0.1)
> plot(x, x^2, xlim=c(-2,2), ylim=c(0,5),
+      main="Graf kvadratne funkcije", cex=0.7, type="l", yaxt="n")
> axis(2, at = c(0, 1, 2, 3, 4,5), las=2)
> abline(h=0)
```

```
> segments(x0=-2,y0=0,x1=-1,y1=0,col="red3")
> segments(x0=1,y0=0,x1=2,y1=0,col="red3")
> segments(x0=-2,y0=0,x1=-2,y1=4,col="red3", lty=2)
> segments(x0=-1,y0=0,x1=-1,y1=1,col="red3", lty=2)
> segments(x0=1,y0=0,x1=1,y1=1,col="red3", lty=2)
> segments(x0=2,y0=0,x1=2,y1=4,col="red3", lty=2)
> abline(v=0)
> segments(x0=0,y0=1,x1=0,y1=4,col="green4")
> segments(x0=-1,y0=1,x1=1,y1=1,col="green4", lty=2)
> segments(x0=-2,y0=4,x1=2,y1=4,col="green4", lty=2)
```

□

Pogledajmo neke primjere slučajnih varijabli. Praktički sve primjere računanja vjerojatnosti nekih događaja iz prošlog poglavlja možemo prikazati pomoću slučajnih varijabli.

Primjer 5.1.5. Slučajne varijable se prirodno javljaju prilikom opisa karakteristika neke populacije (skupa jedinki). Na primjer, ukoliko s Ω označimo neku populaciju ljudi, $\Omega = \{\omega_1, \omega_2, \ldots, \omega_n\}$, onda je visina pojedine osobe, označimo je s V, slučajna varijabla na Ω, odnosno funkcija koja elementima skupa Ω pridružuje neki realan broj

$$\omega_i \mapsto V(\omega_i) \in \mathbb{R},\ i \in \{1, 2, \ldots, n\}.$$

Slično, na težinu pojedine osobe možemo gledati kao na slučajnu varijablu na Ω, označimo je s T, koja svakoj osobi pridružuje realan broj

$$\omega_i \mapsto T(\omega_i) \in \mathbb{R},\ i \in \{1, 2, \ldots, n\}.$$

Slučajna varijabla može biti i funkcija H koja svakoj osobi pridružuje količinu hemoglobina u krvi (u gramima po litri). Opet se svakoj osobi pridružuje broj

$$\omega_i \mapsto H(\omega_i) \in \mathbb{R},\ i \in \{1, 2, \ldots, n\}.$$

Za potrebe nekog sportskog testiranje može se mjeriti i brzina trčanja na 100 metara pa se svakoj osobi iz populacije kojoj mjerimo brzinu pridružuje broj. Na taj način je opet definirana slučajna varijabla, u oznaci B, koja elementima skupa Ω pridružuje ostvareno vrijeme za koje je određena osoba pretrčala 100 metara

$$\omega_i \mapsto B(\omega_i) \in \mathbb{R},\ i \in \{1, 2, \ldots, n\}.$$

Primjera funkcija koje elementima populacije, u ovom slučaju ljudi, pridružuju neke kvantitativne vrijednosti ima zaista puno. To može biti broj pročitanih knjiga u godini, broj koraka u danu, kvocijent inteligencije, ukupno ostvareni dohodak u godini ili indeks tjelesne mase. Uočimo, indeks tjelesne mase je zapravo kvocijent dvije slučajne varijable: T i V^2. Kako su slučajne varijable funkcije, za njih vrijede opće definicije i pravila koja vrijede za funkcije. Vidjet ćemo u nastavku da će nas najviše zanimati vjerojatnosni aspekti karakteristika slučajnih varijabli.
Kao što smo već bili napomenuli na početku poglavlja Opisne statistike, pojam populacije se ne odnosi samo na populacije ljudi. Populacije mogu biti i zvijezde kojima mjerimo masu (time je definirana slučajna varijabla) ili ptice kojima mjerimo raspon krila (time je također definirana slučajna varijabla). Vrijednosti slučajnih varijabli su brojevi. U osnovi se skupovi podataka za koje računamo neke opisne statistike mogu shvatiti kao realizacije slučajnih varijabli (vrijednosti slučajnih varijabli pridružene elementima neke populacije). Naš je cilj shvatiti vjerojatnosnu pozadinu slučajnih varijabli, a onda i njihovih realizacija.

Mala napomena: mogli bi se zapitati gdje je vjerojatnosni prostor na Ω u gornjim primjerima. Naime, vidjeli smo da se slučajnim eksperimentima prirodno pridružuju određeni vjerojatnosni prostori. U prije opisanim primjerima je jedna od tipičnih situacija ona u kojoj proučavanjem nekih karakteristika uzorka iz populacije želimo nešto reći (procijeniti) o cijeloj populaciji. U toj situaciji tipično ćemo "na slučajan način" izabrati k osoba od n njih i onda za njih obaviti neke procjene. Slučajni odabir osobe je slučajni eksperiment i u tom svjetlu je prirodna vjerojatnost koju možemo definirati na Ω uniformna vjerojatnost. Na taj način dolazimo do statističkih problema kojima ćemo se kasnije baviti. □

Primjer 5.1.6 (Dva novčića i dvije slučajne varijable)**.** Pogledajmo slučajni eksperiment bacanja dva novčića. Njega smo već detaljno upoznali, u malo drugačijem kontekstu, na početku potpoglavlja 4.4. Znamo da je za taj slučajni eksperiment prostor elementarnih događaja[1]

$$\Omega = \{(P,P),(P,G),(G,P),(G,G)\}.$$

Definirajmo na Ω funkciju, dakle slučajnu varijablu, X koja broji pojavljivanja glave u ta dva bacanja novčića. Jasno,

$$X((G,G)) = 2, \quad X((G,P)) = X((P,G)) = 1 \quad \text{i} \quad X((P,P)) = 0.$$

Dakle, X je slučajna varijabla (funkcija) koja prima vrijednosti u skupu $\{0,1,2\}$. Možemo definirati i drugu slučajnu varijablu na Ω kao

$$Y = 2 - X.$$

Ako malo razmislimo vidimo da Y zapravo broji pojavljivanje pisma u dva bacanja simetričnog novčića. Imamo $Y((G,G)) = 2 - X((G,G)) = 2 - 2 = 0$. Slično vidimo da je $Y((G,P)) = Y((P,G)) = 1$ i $Y((P,P)) = 2$.
Ono što je važno za uočiti je da smo slučajne varijable X i Y definirali na skupu Ω na kojem je definirana vjerojatnost P. Ako je novčić simetričan, a bacanja novčića nezavisna znamo da je vjerojatnost sva četiri elementarna događaja iz Ω jednaka $1/4$. No, onda se možemo pitati koja je vjerojatnost da je, na primjer, vrijednost od X jednaka 2. Ta je vjerojatnost jednaka vjerojatnosti slučajeva u kojima je X jednaka 2, odnosno ona je jednaka vjerojatnosti elementarnih događaja za koje je vrijednost od X jednaka 2. Stoga je vjerojatnost da je $X = 2$ je jednaka vjerojatnosti skupa $\{(G,G)\}$ a to je jednako $1/4$. Ukratko imamo

$$P(X = 2) = P(\{(G,G)\}) = \frac{1}{4}.$$

Slično,

$$P(X = 1) = P(\{(G,P),(P,G)\}) = \frac{1}{2}$$

i

$$P(X = 0) = P(\{(P,P)\}) = \frac{1}{4}.$$

Sada je zanimljivo (i važno) za uočiti da je

$$P(Y = 2) = P(\{(P,P)\}) = \frac{1}{4},$$

$$P(Y = 1) = P(\{(G,P),(P,G)\}) = \frac{1}{2}$$

[1] U nastavku ćemo u pravilu koristiti identifikaciju $P \equiv 0$ i $G \equiv 1$, ali ovdje radi veće intuitivnosti nastavljamo s oznakama P i G.

i

$$P(Y=0) = P(\{(G,G)\}) = \frac{1}{4}.$$

Zaključujemo da su, vjerojatnosno gledano, slučajne varijable X i Y vrlo slične (vidjet ćemo uskoro da imaju jednaku razdiobu). Stoga se njihova analiza može raditi, u okviru vjerojatnosti, na jednak način.
Kako smo već vidjeli u, važnoj, Napomeni 5.1.3 u vjerojatnosti je uobičajeno koristiti skraćeni zapis za računanje vjerojatnosti slučajnih događaja koji uključuju slučajne varijable. Tako smo u ovom primjeru pisali, na primjer

$$P(X=1) = 1/2,$$

a znamo da to zapravo znači da je

$$P(\{\omega \in \Omega \mid X(\omega) = 1\}) = 1/2$$

što je zaista jednako $P(\{(G,P),(P,G)\})$ jer je

$$\{\omega \in \Omega \mid X(\omega) = 1\} = \{(G,P),(P,G)\}.$$

Slično je i s ostalim vjerojatnostima koje smo računali. Razmislite o tome. □

Primjer 5.1.7 (Bacanje igraćih kockica)**.** Gledamo slučajni eksperiment bacanja dvije igraće kocke. Znamo da za prostor elementarnih događaja možemo uzeti skup

$$\Omega = \{(i,j) \mid i,j \in \{1,2,3,4,5,6\}\}$$

te da je vjerojatnost svakog elementarnog događaja jednaka $1/36$, odnosno $P((i,j)) = 1/36$, $i,j \in \{1,2,3,4,5,6\}$ (sjetite se primjera 3.2.9 i 3.2.14). U skladu s razmatranjima o produktnim vjerojatnosnim prostorima, na Ω možemo gledati i kao na Kartezijev produkt dva prostora elementarnih događaja $\Omega_1 = \{1,2,3,4,5,6\}$ na kojima je vjerojatnost P_1 zadana kao $P_1(\{i\}) = 1/6$, $i \in \{1,2,3,4,5,6\}$. Jasno, u tom slučaju je $P((i,j)) = P_1(\{i\}) \cdot P_1(\{j\}) = 1/6 \cdot 1/6 = 1/36$.
Definirajmo na Ω slučajnu varijablu Z kao

$$Z(\{(i,j)\}) = i + j, \quad i,j \in \{1,2,3,4,5,6\}.$$

Vrijednosti slučajne varijable Z su zbrojevi brojeva koji su pali na kockicama i nalaze se u skupu $\{2,3,4,5,6,7,8,9,10,11,12\}$. Možemo izračunati koja je vjerojatnost da će Z biti jednak bilo kojem od brojeva iz tog skupa. Tako je

$$P(Z=2) = P(\{(1,1)\}) = \frac{1}{36} = P(\{(6,6)\}) = P(Z=12)$$

kao i

$$P(Z=3) = P(\{(1,2),(2,1)\}) = \frac{2}{36} = P(\{(5,6),(6,5)\}) = P(Z=11).$$

Sjetimo se da je zapravo

$$P(Z=2) = P(\{\omega \in \Omega \mid Z(\omega) = 2\}) = P(\{(1,1)\}) = \frac{1}{36}.$$

Slično vidimo da je

$$P(Z=4) = P(\{(1,3),(2,2),(3,1)\}) = \frac{3}{36} = P(\{(4,6),(5,5),(6,4)\}) = P(Z=10).$$

I u ovom slučaju koristimo pokratu $P(Z=4) = P(\{\omega \in \Omega \mid P(\{\omega\}) = 4\}$, a očito su svi ω za koje je $Z(\omega) = 4$ upravo $\omega_1 = (1,3)$, $\omega_2 = (2,2)$ i $\omega_3 = (3,1)$. Uvjerite se sami da je $P(Z=5) = P(Z=9) = 4/36$, $P(Z=6) = P(Z=8) = 5/36$ te $P(Z=7) = 6/36$. Uočimo jednu opću karakteristiku slučajnih varijabli koje su slične[2] Z-u: zbroj vrijednosti $P(Z=i)$ je jednak 1. U slučaju ove konkretne slučajne varijable imamo

$$\begin{aligned} &P(Z=2)+P(Z=3)+P(Z=4)+P(Z=5)+P(Z=6)+P(Z=7)\\ &\quad+P(Z=8)+P(Z=9)++P(Z=10)+P(Z=11)+P(Z=12)\\ &\quad=\frac{1}{36}+\frac{2}{36}+\frac{3}{36}+\frac{4}{36}+\frac{5}{36}+\frac{6}{36}+\frac{5}{36}+\frac{4}{36}+\frac{3}{36}+\frac{2}{36}+\frac{1}{36}=1. \end{aligned}$$

Ako malo razmislimo, ovo nije iznenađenje jer smo zapravo zbrojili sve vjerojatnosti elemenata skupa elementarnih događaja, a njihov zbroj mora biti, prema definiciji vjerojatnosti, jednak jedan. Formalno zapisano vrijedi

$$1 = P(\Omega) = P\Big(\bigcup_{i=2}^{12}\{Z=i\}\Big) = \sum_{i=2}^{12} P(Z=i).$$

Uočimo da smo u gornjoj jednakosti iskoristili konačnu aditivnost vjerojatnosti primjenjenu na skupove oblika $\{Z=i\} = \{\omega \mid Z(\omega) = i\}$ koji su disjunktni za različite vrijednosti od i. Disjunktnost proizlazi iz činjenice da je Z funkcija; funkcija ne može istom elementu domene pridružiti različite elemente kodomene.
Naravno, na ovom vjerojatnosnom prostoru $(\Omega, \mathcal{P}(\Omega), P)$ možemo definirati brojne druge slučajne varijable poput R koju definiramo kao $R(\{(i,j)\}) = i-j$, $i,j \in \{1,2,3,4,5,6\}$ (vrijednosti slučajne varijable R su razlike prvog i drugog broja koji je pao na kockicama). Probajte razmisliti koje vrijednosti poprima slučajna varijabla R i s kojim vjerojatnostima. □

U nastavku ćemo vidjeti još niz primjera slučajnih varijabli. Za sada zapamtimo da vrijednosti slučajnih varijabli ovise o ishodima slučajnih eksperimenata na koje se odnose promatrane slučajne varijable. Dakle, slučajnost postizanja pojedine vrijednosti slučajne varijable proizlazi iz slučajnosti ishoda samog slučajnog eksperimenta, a tu slučajnost modeliramo vjerojatnosnim prostorom na kojem je definirana slučajna varijabla. Slučajnim varijablama možemo sažeti neka pitanja o slučajnom eksperimentu koji promatramo u jednostavnom numeričkom obliku.

S obzirom da su vrijednosti slučajnih varijabli brojevi, možemo se pitati, primjerice, koja je vjerojatnost da će neka slučajna varijabla biti veća od nekog broja a, koja je vjerojatnost da će biti jednaka nekom broju b ili da će joj vrijednost biti u nekom intervalu $[c,d]$ ili (c,d). Takva razmatranja nisu akademski motivirana, već su motivirana primjenama vjerojatnosti. Recimo, moguće se zapitati koja je vjerojatnost da će slučajna varijabla V, koja opisuje vodostaj neke rijeke, biti veća od vodostaja 600 u sljedećih godnu dana (ili deset godina). Ili, možemo se pitati koja je vjerojatnost da će u sljedećih godinu dana slučajna varijabla T, koja broji potrese u RH jače od 6 stupnjeva Richtera, biti jednaka nuli. Ili, koja je vjerojatnost da će se slučajna varijabla N, koja mjeri količinu prometa na nekom komunikacijskom kanalu, kretati između vrijednosti 20 i 50 (u primjerenim mjernim jednicama). Možemo se pitati i kolika je vjerojatnost da će vrijednost slučajne variable Z, koja mjeri životni vijek čovjeka, biti veća od 80 godina. I tako dalje.

Slučajne varijable su temeljni objekti kojima proučavamo vjerojatnosti vezane uz slučajne eksperimente. Matematički gledano, razlikujemo diskretne i neprekidne slučajne varijable. Više o njima reći ćemo u sljedećim potpoglavljima.

[2] Uskoro ćemo vidjeti da se takve slučajne varijable zovu diskretne.

5.2 Diskretne slučajne varijable

Slučajne varijable kojima je skup mogućih vrijednosti najviše prebrojiv skup zovu se diskretne slučajne varijable. Imamo sljedeću definiciju.

Definicija 5.2.1 (Slučajna varijabla)**.** Neka je Ω prostor elementarnih događaja i P vjerojatnost na njemu. Slučajna varijabla $X : \Omega \to \mathbb{R}$ je **diskretna** ako joj je kodomena konačan ili prebrojiv skup, odnosno ako postoje realni brojevi $a_1, a_2, a_3, \ldots \in \mathbb{R}$ takvi da je

$$X(\omega) \in \{a_1, a_2, \ldots a_n\}, \quad n \in \mathbb{N}$$

ili

$$X(\omega) \in \{a_1, a_2, a_3, \ldots\},$$

za sve $\omega \in \Omega$.

Slučajne varijable iz primjera 5.1.6 i 5.1.7 su diskretne slučajne varijable jer im je skup mogućih vrijednosti konačan.

Uzmimo općenitu slučajnu varijablu X čiji je skup svih vrijednosti $\{a_1, a_2, \ldots, a_n\}$, $n \in \mathbb{N}$. Definirajmo slučajne događaje A_i kao

$$A_i = \{X = a_i\} = \{\omega \in \Omega \mid X(\omega) = a_i\}, \ i = 1, 2 \ldots, n.$$

Jasno je da je $A_i \subset \Omega$, ali i

$$\bigcup_{i=1}^{n} A_i = \Omega$$

jer za svaki $\omega \in \Omega$ postoji neki $i \in \{1, \ldots, n\}$ takav da je $\omega \in A_i$.[3] Nadalje, A_i i A_j su disjunktni za $i \neq j$ jer je X funkcija (funkcija ne može preslikati jednu vrijednost iz domene u dvije vrijednosti iz kodomene). Dakle, $\{A_1, A_2, \ldots, A_n\}$ su disjunktni slučajni događaji čija je unija cijeli Ω. U Primjeru 4.2.4 smo rekli da se takvi skupovi slučajnih događaja zovu particije skupa Ω. Na isti način vidimo da za slučajnu varijablu X čiji je skup svih vrijednosti prebrojiv skup $\{a_1, a_2, \ldots\}$ možemo definirati prebrojiv niz slučajnih događaja $A_i = \{X = a_i\}$, $i \in \mathbb{N}$, koji čine particiju skupa Ω. Dakle, svaka diskretna slučajna varijabla na prirodan način generira neku particiju skupa Ω koja je konačna ili prebrojivo beskonačna.

Kako su A_i slučajni događaji dobro su definirani i brojevi

$$p_i = P(A_i) = P(X = a_i), \ i = 1, 2, \ldots, n.$$

Naravno, $p_i \in [0, 1]$ te im je zbroj jednak 1 jer je, zbog konačne aditivnosti vjerojatnosti,

$$1 = P(\Omega) = P\Big(\bigcup_{i=1}^{n} A_i\Big) = \sum_{i=1}^{n} P(A_i) = \sum_{i=1}^{n} p_i \ \Big(= \sum_{i=1}^{n} P(X = a_i)\Big). \tag{5.3}$$

Ukoliko je skup vrijednosti slučajne varijable X prebrojivo beskonačan, na isti način definiramo prebrojiv niz brojeva $p_1, p_2, \ldots$ takvih da su $p_i \in [0, 1]$, $i \in \mathbb{N}$, i zbroj im je jednak 1.

[3] Jer su jedine moguće vrijednosti slučajne varijable X brojevi $\{a_1, a_2, \ldots, a_n\}$.

5.2.1 Razdioba diskretnih slučajnih varijabli

Kao što smo vidjeli, ako slučajna varijabla X ima konačno ili prebrojivo beskonačno mnogo vrijednosti a_i, onda joj je jednoznačno pridružen niz brojeva $p_i = P(X = a_i)$ čiji je zbroj jednak 1. U osnovi ti brojevi daju potpun vjerojatnosni opis slučajne varijable X. Kažemo da oni čine razdiobu ili distribuciju od X. Imamo sljedeću važnu definiciju razdiobe slučajne varijable X.

Definicija 5.2.2 (Razdioba slučajne varijable)**.** Neka je X diskretna slučajna varijabla na Ω koja prima vrijednosti u skupu realnih brojeva $\{a_1, a_2, a_3, \ldots\}$. **Razdioba** slučajne varijable X (**distribucija** slučajne varijable X), je funkcija $p_X : \mathbb{R} \to [0, 1]$ koja se definira sa

$$p_X(x) = P(X = x), \ x \in \mathbb{R}.$$

Funkcija p_X je jednaka nuli za sve x, osim za $x \in \{a_1, a_2, a_3, \ldots\}$, za koje je

$$p_X(a_i) = P(X = a_i) = P(\{\omega \in \Omega \mid X(\omega) = a_i\}).$$

Razdiobe diskretnih slučajnih varijabli je uobičajeno prikazivati u obliku tablice kojoj se u gornjem redu nalaze vrijednosti koje postiže slučajna varijabla X, a u donjem redu pripadne vjerojatnosti skupova na kojima je X jednak pojedinom elementu iz skupa svojih vrijednosti. Dakle, razdiobu (distribuciju) diskretnih slučajnih varijabli zapisujemo u obliku

$$X \sim \begin{pmatrix} a_1 & a_2 & \cdots & a_n & \cdots \\ p_1 & p_2 & \cdots & p_n & \cdots \end{pmatrix}. \tag{5.4}$$

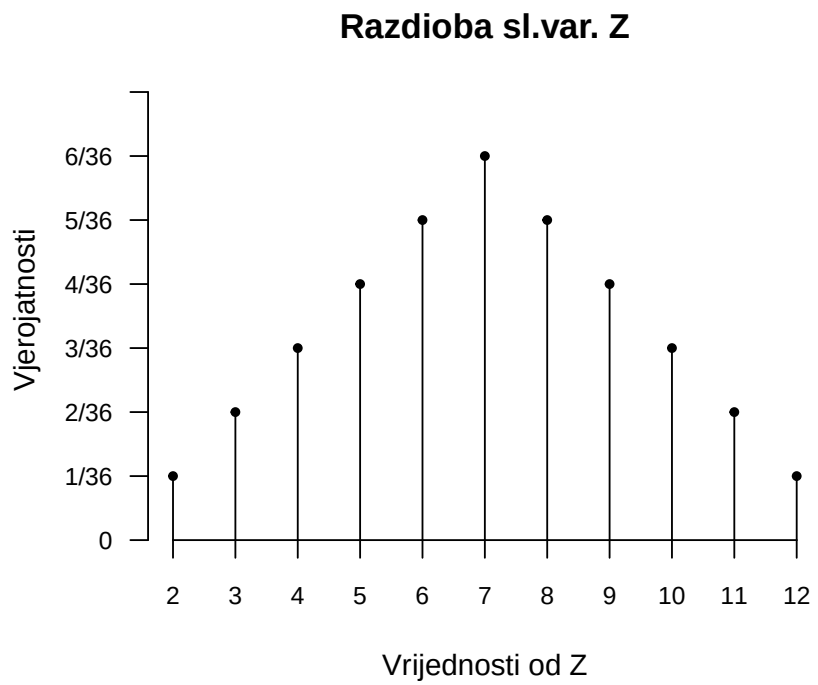
U skladu s tim zapisom vidimo da je razdioba slučajne varijable X iz primjera 5.1.6 jednaka

$$X \sim \begin{pmatrix} 0 & 1 & 2 \\ 1/4 & 1/2 & 1/4 \end{pmatrix}.$$

Uočimo da je razdioba od Y ista kao i od X. Slučajna varijabla Z iz primjera 5.1.7 ima razdiobu (distribuciju)

$$Z \sim \begin{pmatrix} 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 & 10 & 11 & 12 \\ 1/36 & 2/36 & 3/36 & 4/36 & 5/36 & 6/36 & 5/36 & 4/36 & 3/36 & 2/36 & 1/36 \end{pmatrix}.$$

Razdiobu slučajne varijable Z možemo prikazati i grafički



Vidimo da je graf funkcije p_Z koncentriran u točkama koje su moguće vrijednosti slučajne varijable Z. Na y-osi prikazujemo vjerojatnosti koje odgovaraju vjerojatnostima slučajnih događaja $A_i = P(X = a_i)$, $i = 1, 2, \ldots, 12$. Tako direktno s grafa "čitamo" da je $4/36$ vjerojatnost da je slučajna varijabla Z jednaka 9. Važno je uočiti da za razdiobu p_X vrijedi

$$\sum_{i=1}^{n} p_X(a_i) = 1, \quad \text{odnosno} \quad \sum_{i=1}^{\infty} p_X(a_i) = 1,$$

gdje su a_i brojevi iz Definicije 5.2.2.

Važno je zapamtiti, razdioba, odnosno distribucija, diskretne slučajne varijable X je zadana vrijednostima $\{a_1, a_2, a_3, \ldots\}$ koje postiže slučajna varijabla X te pripadnim vjerojatnostima $p_i = P(X = a_i)$, $i \in \mathbb{N}$. U vjerojatnosnom smislu parovi (a_i, p_i), $i \in \mathbb{N}$, daju **sve potrebne informacije** o diskretnoj slučajnoj varijabli X. Što to znači? Uzmimo proizvoljan[4] skup $B \subset \mathbb{R}$. Tada je, zbog konačne aditivnosti vjerojatnosti,

$$P(X \in B) = P\Big(\bigcup_{\{i:a_i \in B\}} \{X = a_i\}\Big) = \sum_{\{i:a_i \in B\}} P(X = a_i) = \sum_{a_i \in B} P(X = a_i), \tag{5.5}$$

pri čemu se zadnja suma uzima po svim indeksima i za koje je $a_i \in B$. Podsjetimo se još jednom

$$P(X \in B) = P(\{\omega \in \Omega \mid X(\omega) \in B\}).$$

U principu nas ne zanima tako općenita situacija s proizvoljnim skupom B, nego situacija u kojoj gledamo skupove poput $B = (a, b)$, $B = (-\infty, b]$ ili $B = [a, \infty)$, $a, b \in \mathbb{R}$. Tako je, na primjer, za slučajnu varijablu Z iz primjera 5.1.7 i skup $B = [0, 4]$

$$\begin{aligned} P(Z \in [0,4]) = P(0 \le Z \le 4) &= \sum_{a_i \le 4} p_Z(a_i) = \sum_{a_i \le 4} P(Z = a_i) \\ &= P(Z = 2) + P(Z = 3) + P(Z = 4) = \frac{1}{6} + \frac{2}{6} + \frac{3}{6} = \frac{6}{36} = \frac{1}{6}. \end{aligned}$$

Još jednom napominjemo, nemojmo smetnuti s uma da je

$$P(Z \in [0,4]) = P(\{\omega \in \Omega \mid Z(\omega) \in [0,4]\}) = P(\{\omega \in \Omega \mid 0 \le Z(\omega) \le 4\}).$$

Vjerojatnost je funkcija koja skupovima pridružuje brojeve iz $[0, 1]$.

Zaključimo, ako znamo parove (a_i, p_i), $i \in \mathbb{N}$, za slučajnu varijablu X možemo izračunati vjerojatnost da se vrijednosti te slučajne varijable nalaze u proizvoljnom skupu B. Sa stajališta vjerojatnosti i statistike to je sve što nas zanima. U tom kontekstu čak i nije važno kakva je točno struktura prostora elementarnih događaja Ω jer su vjerojatnosti p_i zapravo vjerojatnosti skupova A_i koji čine particiju skupa Ω pri čemu je $X(\omega) = a_i$, za $\omega \in A_i$. Pogledajmo sljedeći primjer koji to ilustrira.

Primjer 5.2.3 (Različite slučajne varijable, iste razdiobe)**.** Promotrimo slučajni eksperiment bacanja simetrične igraće kockice. Vidjeli smo u primjerima 3.2.3 i 4.2.1 da je za opis tog slučajnog eksperimenta prirodno uzeti vjerojatnosni prostor $(\Omega, \mathcal{P}(\Omega), P)$, gdje je $\Omega = \{1, 2, 3, 4, 5, 6\}$, a P uniformna vjerojatnost na Ω.

Pogledajmo sada kako možemo pristupiti problemu modeliranja ishoda bacanja simetrične igraće kockice, odnosno broja koji će pasti na kockici, primjenom slučajnih varijabli. Uzmimo isti vjerojatnosni prostor $(\Omega, \mathcal{P}(\Omega), P)$ kao gore i definirajmo slučajnu varijablu X za sve elemente prostora elementarnih događaja Ω tako da stavimo

$$X(i) = i, \ \ i = 1, 2, 3, 4, 5, 6.$$

[4] Uz ograničenje koje smo izložili u Napomeni 5.1.2.

Jasno, sada su $a_i = i$, $i = 1, 2, 3, 4, 5, 6$, $A_i = \{i\}$ te je

$$p_i = P(A_i) = P(X = i) = \frac{1}{6},\ i = 1, 2, 3, 4, 5, 6.$$

Uočite, iako bi izgubili na intuitivnosti, sve bi bilo isto da smo uzeli prostor elementarnih događaja $\Omega_1 = \{o, p, r, s, t, u\}$ na kojem je definirana uniformna vjerojatnost P_1 i definirali slučajnu varijablu X_1 na Ω_1 stavljajući

$$X_1(o) = 1,\ X_1(p) = 2,\ X_1(r) = 3,\ X_1(s) = 4,\ X_1(t) = 5,\ X_1(u) = 6.$$

Opet imamo niz vrijednosti $a_i = i$, $i = 1, 2, 3, 4, 5, 6$ i odgovarajući niz $p_i = 1/6$, $i = 1, 2, 3, 4, 5, 6$. Jedina je razlika što sada trebamo pojedinačno zapisivati događaje A_i, poput $A_3 = \{X_1 = 3\} = \{r\}$.

Pogledajmo sada sljedeći vjerojatnosni prostor

$$\Omega_2 = \{a, b, c, d, e, f, g, h, i, j\}$$

i na njemu definirajmo[5] vjerojatnost P_2:

$$P_2(a) = P_2(f) = P_2(j) = \frac{1}{6},\ P_2(\{b\}) = P_2(\{c\}) = P_2(\{d\}) = P_2(\{e\}) = \frac{1}{12}$$

i

$$P_2(g) = P_2(h) = P_2(i) = \frac{1}{18}.$$

Definirajmo na vjerojatnosnom prostoru $(\Omega_2, \mathcal{P}(\Omega_2), P_2)$ slučajnu varijablu X_2 tako što ćemo definirati njene vrijednosti na elementima skupa Ω_2:

$$X_2(a) = 1,\quad X_2(b) = X_2(c) = 2,\quad X_2(d) = X_2(e) = 3,\quad X_2(f) = 4,$$

$$X_2(g) = X_2(h) = X_2(i) = 5,\quad \text{te}\ \ X_2(j) = 6.$$

Izračunajmo vjerojatnosti da će X_2 biti jednaka nekom od brojeva $1, 2, 3, 4, 5$ ili 6. Imamo

$$P_2(X_2 = 1) = P(\{\omega \in \Omega_2 \mid X_2(\omega) = 1\}) = P_2(a) = \frac{1}{6},$$

a na isti način vidimo da je

$$P_2(X_2 = 4) = P_2(f) = \frac{1}{6}\quad \text{i}\ \ P_2(X_2 = 6) = P_2(j) = \frac{1}{6}.$$

Korištenjem konačne aditivnosti na sličan način vidimo

$$P_2(X_2 = 2) = P(\{\omega \in \Omega_2 \mid X_2(\omega) = 2\}) = P_2(\{b, c\}) = P_2(b) + P_2(c) = \frac{1}{12} + \frac{1}{12} = \frac{1}{6}$$

i

$$P_2(X_2 = 3) = P_2(\{d, e\}) = P_2(d) + P_2(e) = \frac{1}{12} + \frac{1}{12} = \frac{1}{6}.$$

Napokon,

$$P_2(X_2 = 5) = P_2(\{g, h, i\}) = P_2(g) + P_2(h) + P_2(i) = \frac{1}{18} + \frac{1}{18} + \frac{1}{18} = \frac{1}{6}.$$

[5] Na kraju potpoglavlja 4.1 smo pokazali da je vjerojatnost na diskretnim vjerojatnosnim prostorima u potpunosti zadana vrijednostima koje postiže na elementarnim događajima (sjetite se relacije (4.4)). Uočite poveznicu s diskretnim slučajnim varijablama, pri čemu su sada određujući elementi praslike vrijednosti a_i promatrane slučajne varijable.

Zaključujemo da je

$$p_i = P_2(X_2 = i) = \frac{1}{6}, \quad \text{za } i = 1, 2, 3, 4, 5, 6.$$

Vidimo da opet dobivamo slučajnu varijablu s vrijednostima $a_i = i$ i pripadnim vjerojatnostima $p_i = P(X_2 = i) = 1/6$, $i = 1, 2, 3, 4, 5, 6$.

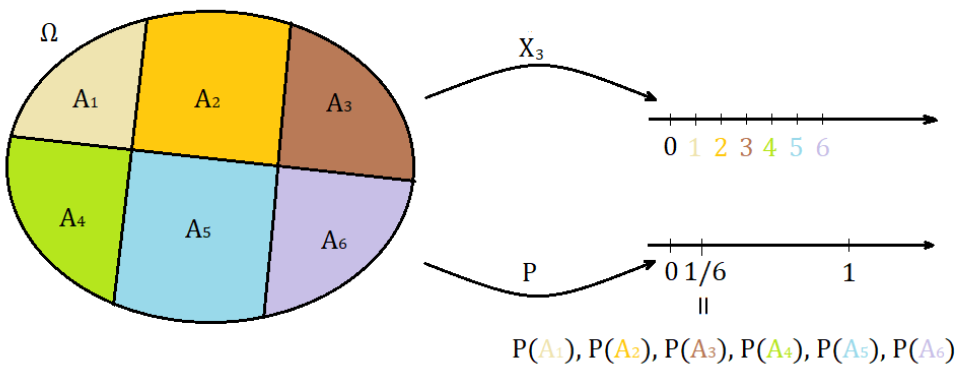
Uzmimo sada neki proizvoljan vjerojatnosni prostor za koji pretpostavimo, radi jednostavnosti, da je diskretan: $(\Omega_3, \mathcal{P}(\Omega_3), P_3)$. Pretpostavimo da postoji particija skupa Ω_3 na 6 skupova, koje označimo $A_1, A_2, A_3, A_4, A_5, A_6$.[6] Pretpostavimo da je $P(A_i) = 1/6$, $i = 1, 2, 3, 4, 5, 6$. Definirajmo slučajnu varijablu X_3 na Ω_3 sa

$$X_3(\omega) = i, \text{ za } \omega \in A_i, \ i = 1, 2, 3, 4, 5, 6.$$

To možemo kraće[7] zapisati kao

$$X_3(A_i) = i, \ i = 1, 2, 3, 4, 5, 6.$$

Shematski imamo situaciju kao na sljedećoj slici.



Iz definicije slučajne varijable X_3 vidimo da su vrijednosti te slučajne varijable brojevi $a_i = i$ s pripadnim vjerojatnostima $p_i = P(X_3 = i) = 1/6$, $i = 1, 2, 3, 4, 5, 6$.

Zaključujemo da slučajne varijable X, X_1, X_2, X_3 sve imaju istu razdiobu

$$\begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \end{pmatrix}.$$

Stoga će sve vjerojatnosti vezane uz te slučajne varijable[8] biti jednake iako su, kao što vidimo, sve slučajne varijable različite i definirane na različitim vjerojatnosnim prostorima.

Što nam sve ovo govori? U principu nam je važnije utvrditi razdiobu slučajnih varijabli koje promatramo, nego njihovo djelovanje na pojedinačnim elementima prostora elementarnih događaja. Statistički gledano to znači da proučavanjem kvantitivnih karakteristika neke slučajne pojave (pojave koja ima elemente slučajnosti) želimo nešto zaključiti o pravilnostima koje se pojavljuju u razdiobi promatranih kvantitativnih karakteristika,

[6] Dakle, $\cup_i A_i = \Omega_3$ te je $A_i \cap A_j = \emptyset$, za $i \neq j$, $i, j = 1, 2, 3, 4, 5, 6$.

[7] Ovo je samo skraćeni zapis koji nije precizan. Funkcija treba biti definirana na elementima domene. U ovom slučaju su to elementarni događaji. Funkcija X_3 je definirana tako da za $\omega \in \Omega_3$ uočimo da postoji jedinstveni $i \in \{1, 2, 3, 4, 5, 6\}$ takav da je $\omega \in A_i$, a onda definiramo $X_3(\omega) = i$.

[8] Poput "na kockici je pao paran broj", "na kockici je pao broj veći od 4", "na kockici je pao broj 10" i tako dalje. Ovo su samo primjeri, ali riječ je o vjerojatnostima da će vrijednosti slučajne varijable biti iz proizvoljnog podskupa iz $\mathbb{R}$, kao što smo i vidjeli u razmatranjima prije ovog primjera.

a ne o pojedinačnim vrijednostima promatranih kvantitativnih karakteristika na promatranoj populaciji. Neformalno gledano možemo ustvrditi da se pravilnosti u slučajnim pojavama ne pojavljuju na razini jedinki, nego na razini agregiranog pogleda na pojavu, odnosno na razini razdioba. □

Prošli primjer se odužio jer smo htjeli pokazati da možemo na razne načine definirati slučajne varijable, a da one imaju istu razdiobu. U skladu s time često ćemo naići na formulaciju "neka je X slučajna varijabla s razdiobom tom i tom". To znači da imamo slučajnu varijablu X za koju odmah kažemo da joj je razdioba ta i ta jer je to najvažnija informacija koju dajemo za tu slučajnu varijablu. Formalno, ako su $a_1, \ldots, a_n$, $n \in \mathbb{N}$, vrijednosti od X, onda skupovi $A_i = \{X = a_i\}$ formiraju particiju nekog prostora elementarnih događaja, a vjerojatnosti tih slučajnih događaja A_i su oni p_i koji su navedeni u razdiobi, odnosno tablici razdiobe. U osnovi dobivamo konstrukciju poput one koja je prikazana na slici u prethodnom primjeru.

Uočimo da se uvođenjem pojma slučajne varijable polako odmičemo od proučavanja konkretnih vjerojatnosnih prostora. Oni su uvijek prisutni u pozadini (tako su i definirane slučajne varijable), ali je stvar u tome da mogu biti vrlo kompleksni. Na primjer, nerjetko se vjerojatnosni prostori definiraju vrlo općenito u informacijskom smislu pa tako možemo smatrati da neki vjerojatnosni prostor, odnosno σ-algebra definirana na njemu, sadrži sve informacije sadržane do nekog trenutka. To neće biti smetnja proučavanju slučajnih varijabli jer se u principu za svaku slučajnu varijablu s nekom razdiobom može definirati vjerojatnosni prostor na kojem ona "živi".

5.2.2 Funkcije distribucije

Osim razdiobe (distribucije) diskretne slučajne varijable X, uobičajeno je gledati i funkciju distribucije koja je definirana za sve slučajne varijable (ne samo diskretne). Imamo sljedeću definiciju.

Definicija 5.2.4. Neka je X slučajna varijabla (na vjerojatnosnom prostoru $(\Omega, \mathcal{F}, P)$). **Funkcija distribucije** slučajne varijable X je funkcija $F = F_X : \mathbb{R} \to [0, 1]$ definirana sa

$$F_X(x) = P(X \leq x), \ x \in \mathbb{R}. \tag{5.6}$$

U skladu s prethodnim napomenama znamo da je

$$P(X \leq x) = P(\{\omega \in \Omega \mid X(\omega) \leq x\}).$$

Funkcije distribucije pružaju još jedan način za vjerojatnosni opis slučajnih varijabli. Kao i razdiobe (funkcije razdiobe p_X), funkcije distribucije omogućavaju izračun praktički svih vjerojatnosti vezanih uz slučajne varijable. Općenito za $a, b \in \mathbb{R}$ takve da je $a < b$ i slučajnu varijablu X imamo

$$P(a < X \leq b) = F_X(b) - F_X(a). \tag{5.7}$$

Gornja jednakost se lagano dobije: skup $\{X \leq b\}$ se može rastaviti u disjunktnu uniju skupova $\{X \leq a\}$ i $\{a < X \leq b\}$ pa je

$$P(X \leq b) = P(X \leq a) + P(a < X \leq b),$$

a onda se sjetimo da je $F_X(b) = P(X \leq b)$ i $F_X(a) = P(X \leq a)$ (prema definiciji funkcije distribucije). Uočite različitost nejednakosti događaja $\{a < X \leq b\}$: lijeva je stroga nejednakost, dok je desna nejednakost koja uključuje i točku b. Gledano na razini svojstava funkcije to je rezultat činjenice da je funkcije distribucije F zdesna neprekidna. Osnovna svojstva funkcije distribucije navodimo u sljedećoj propoziciji. Navedena svojstva vrijede za sve slučajne varijable (ne samo diskretne).

Propozicija 5.2.5 (Svojstva funkcije distribucije)**.** *Za funkciju distribucije F slučajne varijable X vrijedi*

i) Ako su $x, y \in \mathbb{R}$ takvi da je $x \leq y$, onda je $F(x) \leq F(y)$. Funkcija distribucije je neopadajuća funkcija.

ii) $\lim_{x\to-\infty} F(x) = 0$ *i* $\lim_{x\to\infty} F(x) = 1$. *Posebno, F_X je nenegativna funkcija.*

iii) F je zdesna neprekidna: $\lim_{\epsilon\downarrow 0} F(x+\epsilon) = F(x)$, $x \in \mathbb{R}$.

Napomena 5.2.6. U engleskoj literaturi se razdioba (distribucija) diskretne slučajne varijable naziva *probability mass function*, dok se funkcija distribucije naziva *cumulative distribution function* ili samo *distribution function*. □

Vratimo se opet na primjer 5.1.7 i pogledajmo kako izgleda funkcija distribucije slučajne varijable Z. Prije svega uočimo da je za $x < 2$ $F_Z(x) = P(Z < 2) = P(\emptyset) = 0$, jer Z ne poprima vrijednosti manje od 2. Nadalje,

$$F_Z(2) = P(Z \leq 2) = P(Z = 2) = 1/36.$$

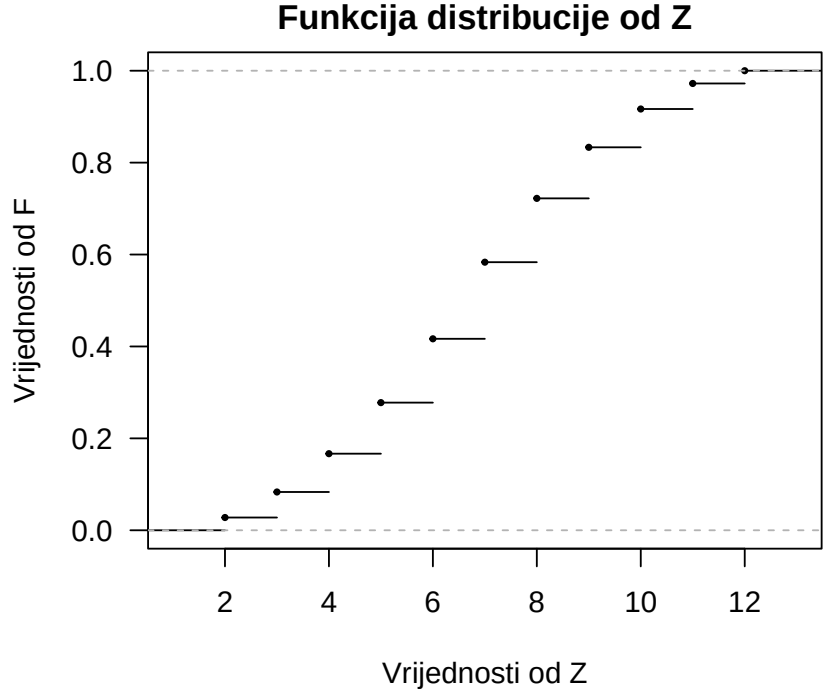
Za $x \in [2, 3)$ je $F_Z(x) = P(Z = 2) = 1/36$. No, kada je $x = 3$ vrijednost od F_Z se promijeni:

$$F_Z(3) = P(Z \leq 3) = P(Z = 2) + P(Z = 3) = 1/36 + 2/36 = 3/36.$$

Uočimo da je $F_Z(3) - F_Z(2) = 3/36 - 1/36 = 2/36 = P(Z = 3)$, odnosno, kao što smo već napomenuli $F_Z(3) - F_Z(2) = P(2 < Z \leq 3)$. Možemo nastaviti na isti način. Za $x \in [3, 4)$ je $F_Z(x) = P(Z < 4) = F_Z(3) = 3/36$ dok za $x = 4$ imamo

$$F_Z(4) = P(Z \leq 4) = P(Z = 2) + P(Z = 3) + P(Z = 4) = 1/36 + 2/36 + 3/36 = 6/36.$$

Donja slika jasno pokazuje kako izgleda F_Z.



Stepenasti izgled funkcije distribucije od Z je tipičan za funkcije distribucije diskretnih slučajnih varijabli. **Točke skoka funkcije F_Z se podudaraju s točkama a_i u kojima je koncentrirana razdioba od Z.** To su one točke a_i za koje je

$p_i = p_Z(a_i) = P(Z = a_i) > 0$. Veličine skokova ("razmaci" na y-osi) odgovaraju upravo vrijednostima p_i za koje znamo da je $\sum_i p_i = 1 = \lim_{x\to\infty} F_Z(x)$. Formalno je

$$F_Z(x) = P(Z \leq x) = P(\{X < x\} \cup \{X = x\}) = P(X < x) + P(X = x)$$

za sve $x \in \mathbb{R}$, a onda i za $x = a_i$. U osnovi to znači da iz funkcije distribucije možemo rekonstruirati (ili zadati njome) razdiobu slučajne varijable. Na primjer, za $a_3 = 4$ je $p_3 = F_Z(4) - F_Z(3)$. Jasno, za ostale vrijednosti a_i na isti način izračunamo pripadnu vjerojatnost p_i.

U svijetlu činjenice da je vjerojatnosno ponašanje slučajnih varijabli određeno razdiobom, odnosno funkcijom distribucije slučajne varijable, slučajne varijable možemo zadavati upravo zadavanjem razdiobe ili funkcije distribucije slučajne varijable. Mala terminološka napomena: u principu se jednako često koriste termini razdioba ili distribucija za funkciju p_X (ali i šire) što može biti malo zbunjujuće s obzirom na postojanje funkcije distribucije F_X, što je potpuno drugi objekt. Stoga u nastavku preferiramo korištenje termina razdioba, a ne distribucija.

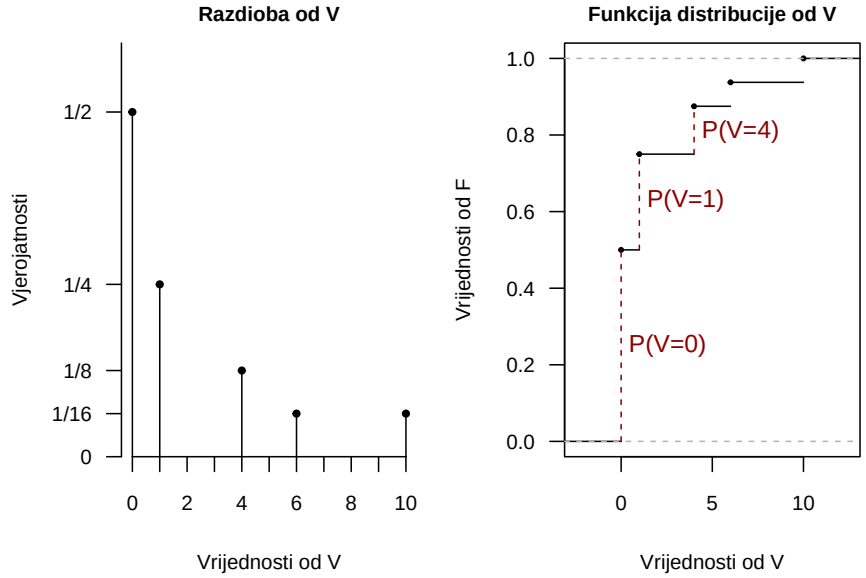
Primjer 5.2.7. Zadajmo neku slučajnu varijablu V razdiobom

$$V \sim \begin{pmatrix} 0 & 1 & 3 & 6 & 10 \\ 1/2 & 1/4 & 1/8 & 1/16 & 1/16 \end{pmatrix}.$$

Kao što smo već rekli, gornjim zapisom je definirano da je $p_1 = P(V = 0) = 1/2$, $p_2 = P(V = 1) = 1/4$ i tako sve do $p_5 = P(V = 10) = 1/16$. Naravno, da bi to bila vjerojatnosna razdioba nužno je da je zbroj vjerojatnosti p_i jednak 1, što je istina jer je

$$p_1 + p_2 + p_3 + p_4 + p_5 = 1/2 + 1/4 + 1/8 + 1/16 + 1/16 = 1.$$

Na donjoj slici su prikazani grafovi funkcije razdiobe p_V i funkcije distribucije F_V slučajne varijable V.



Vjerojatnosno gledano smo u potpunosti opisali slučajnu varijablu V, odnosno zadali smo je definiranjem bilo razdiobe, bilo funkcije distribucije. Jednostavno možemo definirati vjerojatnosni prostor na kojem bi takva slučajna varijabla mogla "živjeti": uzmemo skup Ω sa 16 elemenata, prvih osam preslikamo u 0, sljedeća četiri u 1 i tako dalje do zadnjeg elementa koji preslikamo u 10. Za σ-algebru uzmemo partitivni skup od Ω, a vjerojatnost uniformnu. Kao što smo vidjeli u Primjeru 5.2.3 definicija vjerojatnosnog prostora na kojem je definirana slučajna varijabla V nije jedinstvena, odnosno postoje

razni vjerojatnosni prostori na kojima V može "živjeti". S druge strane, kao što smo i napomenuli u tom primjeru, eksplicitnu definiciju vjerojatnosnog prostora na kojem je definirana slučajna varijabla V ne trebamo niti napraviti jer ukoliko imamo zadanu razdiobu (funkciju distribucije), onda uvijek postoji vjerojatnosni prostor na kojoj je definirana slučajna varijabla s tom razdiobom. Dakle, slučajne varijable je dovoljno zadati funkcijom distribucije, odnosno razdiobom u slučaju diskretnih slučajnih varijabi. Za primjere računanja vjerojatnosti vezanih uz slučajnu varijablu V pogledajte Zadatak 5.7.3. □

Slučajne varijable se, naravno, ne pojavljuju samo kod vjerojatnosnih prostora vezanih uz razna bacanja ili izvlačenja objekata, kao što smo i napomenuli u Primjeru 5.1.5. Smisao uvođenja slučajnih varijabli je da one mogu pružiti uvid u neke karakteristike cijele populacije (na primjer, ljudi) putem proučavanja karakteristika dijela te populacije, odnosno uzorka iz populacije. Tipičan jednostavni primjer je visina ili težina ljudi.

Primjer 5.2.8 (Visina ljudi)**.** Pogledajmo skup podataka koji sadrži podatke o visini i težini 25.000 osoba, a preuzet je s mrežne stranice Statistics Online Computational Resource http://www.socr.ucla.edu/. Podaci su spremljeni u tablicu. Već smo vidjeli kako "skinuti" podatke zapisane u tablici na nekoj mrežnoj stranici (sjetite se Primjera 2.7.2 - najveća urbana naselja u EU). Podatke spremamo u `data frame` `visina` s time da smo ih pretvorili u centimetre (originalno su u inčima).

```
> library(rvest)
> uclas<-"http://socr.ucla.edu/docs/resources/"
> datahw<-"SOCR_Data/SOCR_Data_Dinov_020108_HeightsWeights.html"
> vis<-read_html(paste0(uclas,datahw))%>%
+   html_nodes(css = "table") %>% html_table(fill = T)
>  vis<-vis[[1]]
>  visina<-as.data.frame(vis[,c(1,2)])
>  names(visina)=c("Broj", "Visina")
>  visina<-visina[2:25001, ]
> visina$Broj<-as.numeric(visina$Broj)
> visina$Visina<-round(as.numeric(visina$Visina)*2.54)
> str(visina)

'data.frame':        25000 obs. of  2 variables:
 $ Broj  : num  1 2 3 4 5 6 7 8 9 10 ...
 $ Visina: num  167 182 176 173 172 174 177 178 172 170 ...
```

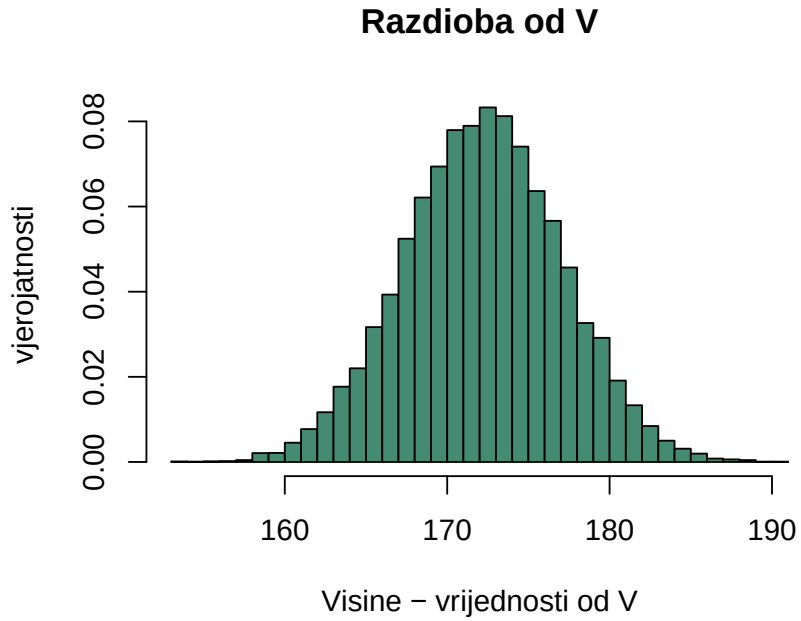
Visina ljudi, označimo je s V, je sada diskretna slučajna varijabla na skupu 25.000 osoba. Ako gledamo na razini vjerojatnosnih prostora, onda je skup elementarnih događaja jednak skupu tih 25.000 osoba s time da je vjerojatnost pridružena svakom elementarnom događaju ("vjerojatnost odabira pojedine osobe") jednaka za sve elementarne događaje, odnosno jednaka je 1/25.000. No, sada nas zanima razdioba slučajne varijable V, odnosno razdioba visine na odabranom uzorku od 25.000 ljudi. Slučajna varijabla V poprima velik broj vrijednosti koje možemo označiti s a_i, u skladu s prethodnim oznakama. Ukoliko na njene vrijednosti gledamo kao na skup numeričkih podataka onda znamo da možemo jednostavno dobiti uvid u osnovne numeričke karakteristike korištenjem funkcije `summary()`. Konkretno, dobijemo

```
> summary(visina$Visina)

   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  153.0   169.0   173.0   172.7   176.0   191.0
```

Nadalje, histogram relativnih frekvencija će nam dati uvid u razdiobu (distribuciju) slučajne varijable V jer on zapravo prikazuje frekvencije pojavljivanja pojedine vrijednosti od V podijeljene s ukupnim brojem vrijednosti slučajne varijable V. Stoga na histogram relativnih frekvencija možemo gledati kao na graf razdiobe od V, odnosno graf funkcije p_V (vidite definiciju 5.2.2). Razlika u odnosu na standardan prikaz razdiobe od V je u tome što smo više vrijednosti slučajne varijable V grupirali u isti razred te smo visine prikazali vertikalnim stupićima, a ne vertikalnim crtama, kako je to i uobičajeno kod histograma.

```
> hvis<-hist(visina$Visina, main="Razdioba od V", probability= TRUE,
+            xlab="Visine - vrijednosti od V", breaks=39, cex=0.8,
+            xlim=c(153, 191),ylab="vjerojatnosti", col = "aquamarine4")
```



Osim grafičkog prikaza, histogram (varijabla `hvis`) sadrži numeričke vrijednosti koje su, u oznakama koje smo uveli, jednake $p_i = P(V \in \text{ razred}_i)$, $i = 1, 2, \ldots, 38$.

```
> options(width=70)
> hvis$density
```

```
 [1] 0.00012 0.00008 0.00016 0.00020 0.00044 0.00208 0.00212 0.00452
 [9] 0.00772 0.01168 0.01768 0.02200 0.03168 0.03932 0.05244 0.06212
[17] 0.06940 0.07796 0.07896 0.08328 0.08124 0.07408 0.06364 0.05664
[25] 0.04568 0.03264 0.02916 0.01912 0.01332 0.00844 0.00500 0.00312
[33] 0.00196 0.00080 0.00060 0.00044 0.00008 0.00008
```

Jasno, zbroj tih vjerojatnosti je jednak 1.

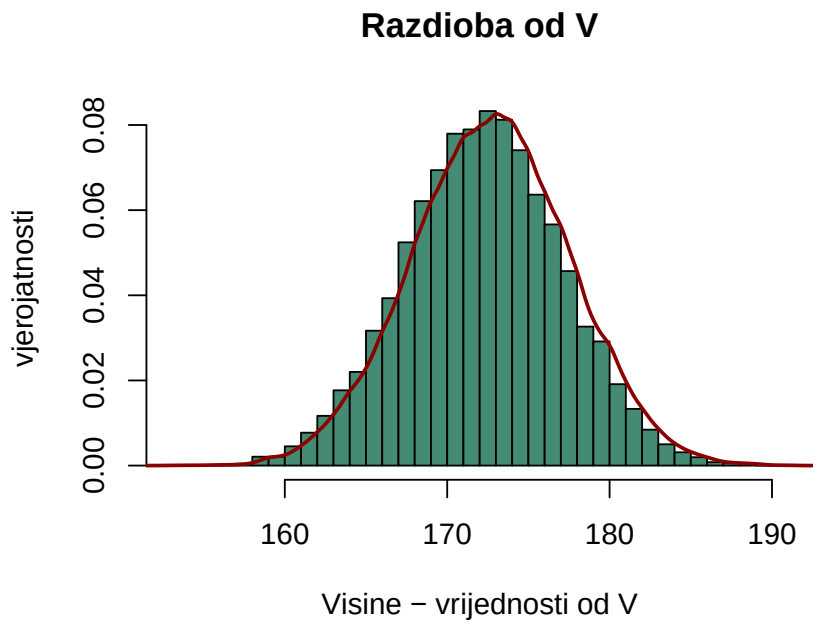
```
> sum(hvis$density)
```

```
[1] 1
```

Na histogramu relativnih frekvencija možemo dodati još jednu "glatku" liniju (crvenom bojom) koja prati oblik histograma, a rekli smo da histogram prikazuje agregirani graf razdiobe visine ljudi koji čine uzorak koji promatramo, odnosno graf razdiobe slučajne

varijable V. Sličnu crvenu liniju smo vidjeli i u Primjeru 2.7.3 na jednom od histograma. Ta crvena linija je analogon razdiobe ali za neprekidne slučajne varijable s kojima ćemo se uskoro upoznati. Uočimo, površina ispod te crvene linije je jednaka 1, a funkciju čiji je to graf ćemo zvati **funkcijom gustoće** odgovarajuće slučajne varijable.

```
> hvis<-hist(visina$Visina, main="Razdioba od V", probability= TRUE,
+            xlab="Visine - vrijednosti od V", breaks=39, cex=0.8,
+            xlim=c(153, 191),ylab="vjerojatnosti", col = "aquamarine4")
> lines(density(visina$Visina), col="darkred", lwd=2)
```



Kada opet pogledamo bilo histogram relativnih frekvencija slučajne varijable V, bilo dodanu crvenu liniju, vidimo da je on dosta pravilan u smislu "zvonastog" oblika. Kasnije ćemo vidjeti da otprilike tako izgleda funkcija gustoće normalne slučajne varijable, koja nije diskretna već neprekidna. Da li je zaista V distribuirana kao normalna distribucija moći ćemo provjeriti jednim statističkim testom. □

Prethodni primjer samo ilustrira mogućnost definicije velikog broja slučajnih varijabli u različitim situacijama (visina određene vrste biljke na nekom području, broj gostiju koji uđu u restoran ili neki dućan u nekom razdoblju, broj kvarova u nekom komunikacijskom kanalu ili data centru, životni vijek nekog organizma, broj potomaka i tako dalje). Mnoge od njih su diskretne, a ponekad je pogodnije smatrati da su vrijednosti slučajnih varijabli koje promatramo neprebrojivi skupovi poput $\mathbb{R}$ ili $[0, +\infty)$. Na taj način ćemo dobivati neprekidne slučajne varijable. Prije nego što se posvetimo njima upoznat ćemo se s nekim od najpoznatijih diskretnih razdioba, odnosno razdioba diskretnih slučajnih varijabli.

5.2.3 Neke poznatije diskretne razdiobe

Diskretnih razdioba ima puno i mnoge su međusobno vrlo različite. Neke od njih se ipak češće pojavljuju u primjenama pa ih predstavljamo u nastavku ovog odjeljka. Mala napomena: u nastavku ćemo govoriti o diskretnim razdiobama koje su razdiobe diskretnih slučajnih varijabli. Kao što smo naučili, razdiobe (distribucije) u potpunosti određuju vjerojatnosno djelovanje slučajnih varijabli čije su razdiobe zadane. U tom smislu govorit ćemo o diskretnim slučajnim varijablama iz pojedine razdiobe, smatrajući da je riječ o diskretnim slučajnim varijablama čije je razdioba zadana.

5.2.3.1 Diskretna uniformna razdioba

Diskretna uniformna slučajna varijabla X poprima vrijednosti u konačnom skupu od n elemenata, $n \in \mathbb{N}$, pri čemu su iste vjerojatnosti da će X biti jednaka bilo kojem od tih elemenata. Ukoliko označimo s $\{1, 2, \ldots, n\}$ elemente skupa s n elemenata, onda je distribucija slučajne varijable X na $\{1, 2, \ldots, n\}$ dana s

$$X \sim \begin{pmatrix} 1 & 2 & \ldots & n \\ 1/n & 1/n & \ldots & 1/n \end{pmatrix}.$$

Razdiobu diskretne uniformne slučajne varijable nazivamo **diskretnom uniformnom razdiobom**.

Tipičan primjer diskretne uniformne varijable je slučajna varijabla koja opisuje ishod bacanja simetrične kocke. Slučajna varijabla koja je jednaka broju koji je pao na kocki može poprimiti jednu od 6 vrijednosti ($n = 6$) i vjerojatnost poprimanja bilo koje od tih vrijednosti je jednaka $1/6$. Dakle, u tom slučaju je razdioba od X jednaka

$$X \sim \begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \end{pmatrix}.$$

Uočimo: bilo koji izbor nekog od n elemenata pri čemu je vjerojatnost da ćemo odabrati pojedini element jednaka je primjer uniformne diskretne slučajne varijable. Također, diskretna uniformna slučajna varijabla X se može definirati na bilo kojem konačnom skupu elemenata $\{a, a+1, \ldots, b\}$, pri čemu su a i b cijeli brojevi i $a < b$. Pošto skup $\{a, a+1, \ldots, b\}$ ima $b - a + 1$ element imamo

$$P(X = k) = 1/(b - a + 1),\ k \in \{a, a+1, \ldots, b\}.$$

U tom slučaju imamo **oznaku**

$$X \sim Unif\{a, b\}$$

(oznaku $Unif(a, b)$ ili $U(a, b)$ čuvamo za neprekidnu uniformnu slučajnu varijablu koju ćemo upoznati kasnije). Ovaj primjer smo počeli s $X \sim Unif\{1, n\}$.

Napomenimo da je jednostavno izračunati funkciju distribucije diskretne uniformne slučajne varijable $X \sim Unif\{a, b\}$ jer je

$$F_X(x) = (\lfloor x \rfloor - a + 1)/(b - a + 1), \quad \text{za} \ \ x \in [a, b].$$

Za $x < a$ je $F_X(x) = 0$, a za $x \geq b$ je $F_X(x) = 1$. S $\lfloor \cdot \rfloor$ smo označili funkciju najveće cijelo čija je vrijednost najveći cijeli broj koji je manji ili jednak od x. Na primjer, $\lfloor 3, 14 \rfloor = 3$.

Diskretna uniformna razdioba se može definirati i za općeniti konačni skup S. Ukoliko je $s \in S$, element skupa S, onda se diskretna uniformna razdioba zadaje sa

$$P(X = s) = \frac{1}{|S|},$$

gdje je $|S|$ broj elemenata skupa S. Ovako općenito definirana diskretna uniformna razdioba podsjeća na naivnu definiciju vjerojatnosti. Zaista, ukoliko je $T \subset S$, onda je

$$P(X \in T) = \frac{|T|}{|S|}.$$

5.2.3.2 Bernoullijeva slučajna varijabla

Jedna od najjednostavnijih, ali i najvažnijih slučajnih varijabli je **Bernoullijeva** slučajna varijabla X s parametrom $p \in [0,1]$, u oznaci $X \sim Bernoulli(p)$ ili kraće $X \sim Ber(p)$. Ona može poprimiti dvije vrijednosti: nula i jedan, a zadana je distribucijom

$$X \sim \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}.$$

Iz gornjeg zapisa je jasno $P(X=0) = 1-p$, $P(X=1) = p$. Bernoullijeva slučajna varijabla s parametrom p modelira slučajni eksperiment s dva ishoda koji se često interpretiraju kao uspjeh (označen s 1) i neuspjeh (označen s 0). U takvoj interpretaciji je vjerojatnost uspjeha jednaka p, a vjerojatnost neuspjeha jednaka $1-p$. Uspjeh i neuspjeh se u ovakvoj interpretaciji mogu shvatiti vrlo široko pa uspjeh može biti "pala je glava", ali i "na igraćoj kocki su pali brojevi 5 ili 6", "strijelac je pogodio centar mete", "proizvod je ispravan" ili u slučajnom eksperimentu pogađanja točnog odgovora od nekoliko mogućih "odabran je ispravan odgovor".

Treba uočiti da Bernoullijeva slučajna varijabla s parametrom p nije jedna slučajna varijabla, nego skup slučajnih varijabli parametriziran s $p \in [0,1]$. Drugim riječima, za svaki takav p dobivamo neku drugu Bernoullijevu slučajnu varijablu. Primjerice, za $p = 1/2$ dobijemo Bernoullijevu slučajnu varijablu koja opisuje bacanje simetričnog novčića. Za $p = 1/3$ dobijemo Bernoullijevu slučajnu varijablu koja opisuje bacanje igraće kockice pri čemu se uspjehom smatra da su pali brojevi 5 ili 6. Za $p = 0,3$ dobijemo Bernoullijevu slučajnu varijablu koja opisuje gađanja prvog strijelca iz primjera 4.5.13 pri čemu je uspjeh pogodak u središte mete. Naravno, interpretacija pojedine Bernoullijeve slučajne varijable s odabranim parametrom p se može razlikovati. Tako Bernoullijeva slučajna varijabla s parametrom $p = 1/2$ može opisivati i bacanje simetrične kocke pri čemu je uspjeh ako na kocki padne paran broj. Zbog svih tih interpetacija se parametar p Bernoullijeve slučajne varijable naziva **vjerojatnost uspjeha**, a $1-p$ **vjerojatnost neuspjeha**.

Često se Bernoullijeva slučajna varijabla prikazuje kao indikator skupa. Općenito, za događaj A definiramo funkciju $I_A : \Omega \to \{0,1\}$ kao

$$I_A(\omega) = \begin{cases} 1, & \omega \in A \\ 0, & \text{inače.} \end{cases} \tag{5.8}$$

I_A je zapravo jednostavna slučajna varijabla koja je jednaka 1 na A, a 0 na A^c. I_A se naziva **indikator** skupa A ili **indikatorska funkcija** skupa A.

Ukoliko je slučajni događaj A_p takav da je $P(A_p) = p$, onda zapravo možemo definirati Bernoullijevu slučajnu varijablu X kao

$$X = I_{A_p}.$$

Iako prikaz Bernoullijeve slučajne varijable pomoću indikatora može izgledati malo isforsiran (uvodimo novi objekt da bi opisali vrlo jednostavnu slučajnu varijablu), on je zapravo koristan, u što ćemo se uvjeriti kada uvedemo i analiziramo neka svojstva binomne slučajne varijable.

5.2.3.3 Binomna razdioba

Slučajna varijabla X je **binomna** slučajna varijabla s parametrima n i p, $n \in \mathbb{N}, p \in [0,1]$, ako prima vrijedosti u skupu $\{0,1,\ldots,n\}$ s pripadnim vjerojatnostima

$$P(X=k) = \binom{n}{k} p^k (1-p)^{n-k}, \ k = 0,1,\ldots,n. \tag{5.9}$$

Skup vrijednosti $\{0, 1, \ldots, n\}$ i pripadne vjerojatnosti iz (5.9) definiraju **binomnu razdiobu**. Ukoliko slučajna varijabla X ima binomnu razdiobu koristimo oznaku $X \sim B(n, p)$. Da je riječ o dobro definiranoj razdiobi[9] jasno vidimo iz binomnog teorema (formula (3.11)) jer je

$$\sum_{k=0}^{n} P(X = k) = \sum_{k=0}^{n} \binom{n}{k} p^k (1-p)^{n-k} = (p + (1-p))^n = 1^n = 1.$$

Jasno, za različite vrijednosti od n i p dobivamo različite slučajne varijable. Tablični prikaz binomne razdiobe je malo nezgrapan za općeniti n, ali ona je u potpunosti zadana relacijom (5.9).

Značaj binomne razdiobe proizlazi iz njene interpretacije, odnosno primjene. Pogledajmo slučajni eksperiment s dva ishoda (pismo-glava, pogodak-promašaj, ispravno-neispravno) i ponovimo ga **nezavisno** n puta, $n \in \{1, 2, \ldots\}$. S obzirom da ponavljamo isti slučajni eksperiment n puta, u svakom od n izvođenja vjerojatnost uspjeha je jednaka p. Označimo s X slučajnu varijablu koja broji uspjehe u tih n ponavljanja promatranog slučajnog eksperimenta. Ako s 1 označimo uspjeh, a s 0 neuspjeh, onda će X biti jednaka $k \in \{0, 1, \ldots, n\}$ ako se u n izvođenja slučajnog eksperimenta točno k puta pojavila jedinica.

Odredimo vjerojatnost da će se u n nezavisnih ponavljanja promatranog slučajnog pokusa pojaviti k jedinica, odnosno da će slučajna varijabla X postići vrijednost k. U skladu s opisom slučajnog eksperimenta, n izvođenja tog slučajnog eksperimenta možemo predstaviti nizom nula i jedinica duljine n, odnosno nizom oblika $(1, 1, 0, 1, 0, 0, \ldots, 0, 1, 0)$ koji je duljine n. Dakle, vjerojatnost da će slučajna varijabla X, čija je vrijednost jednaka broju uspjeha, biti jednaka k jednaka je vjerojatnosti da će se u nizu od n binarnih znamenki pojaviti točno k jedinica i $n-k$ nula pri čemu je vjerojatnost pojavljivanja jedinice u svakom od izvođenja slučajnog eksperimenta jednaka p, a vjerojatnost pojavljivanja nule je jednaka $1-p$. Uočimo da je, zbog nezavisnosti[10], vjerojatnost pojavljivanja k jedinica i $n-k$ nula je jednaka $p^k(1-p)^{n-k}$, a broj načina na koji se tih k jedinica može rasporediti na n mjesta je jednak $\binom{n}{k}$ (biramo k od n različitih mjesta - to određuje i mjesta na kojima se nalaze nule). Prema principu umnoška je

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

što je upravo razdioba binomne slučajne varijable, odnosno X je iz binomne razdiobe.

Primjer 5.2.9. Pogledajmo slučajni eksperiment 6 nezavisnih bacanja nesimetričnog novčića: vjerojatnost da će pasti glava je $0,55$, a vjerojatnost da će pasti pismo je, dakle, $0,45$.
Odredimo najprije vjerojatnost da će prvo pasti dva puta glava, a nakon toga četiri puta pismo. U skladu s prijašnjom interpretacijom uspjeha i neuspjeha, pri čemu odredimo, na primjer, da je uspjeh da će pasti glava, zapravo se pitamo koja je vjerojatnost da ćemo u nizu od 6 nula i jednica dobiti niz $(1, 1, 0, 0, 0, 0)$. Kako su bacanja novčića nezavisna, ta je vjerojatnost jednaka produktu vjerojatnosti dobivanja jedinice ili nule (glave ili pisma) u svakom od bacanja, odnosno, ona je jednaka

$$0,55 \cdot 0,55 \cdot 0,45 \cdot 0,45 \cdot 0,45 \cdot 0,45 \approx 0,0124.$$

Uočimo, da smo imali simterični novčić, onda bismo i bez znanja o binomnoj razdiobi znali da je ukupan broj kombinacija smještaja 0 i 1 na 6 mjesta jednak 2^5, a "povoljan" slučaj je upravo kombinacija $(1, 1, 0, 0, 0, 0)$. Dakle, vjerojatnost bi bila $1/2^6 \approx 0,01563$.

[9] Sjetimo se, zbroj vjerojatnosti $P(X = a_i)$ mora biti jednak 1, pri čemu su a_i različite vrijednosti diskretne slučajne varijable X.

[10] Sjetite se odjeljka 4.4 o nezavisnom ponavljanju slučajnih eksperimenata.

Odredimo sada vjerojatnost da će točno dva puta pasti glava u 6 nezavisnih bacanja novčića. Prema prijašnjim razmatranjima vezanim uz binomnu razdiobu znamo da je ona (vjerojatnost) jednaka

$$\binom{6}{2}0,55^2 0,45^4 \approx 0.1861.$$

Navedenu formulu lakše pamtimo ako se sjetimo da se ta vjerojatnost dobije tako da se pobroje (zbroje) sve vjerojatnosti razmještaja dvije jedinice na 6 mjesta, a onda znamo da je vjerojatnost svakog takvog razmještaja jednaka $0,0124$. Kako je ukupan broj razmještaja 2 jedinice na 6 mjesta jednak odabiru dva mjesta od 6 njih (onda su na preostalih $6-4=2$ mjesta nule), a to možemo napraviti na $\binom{6}{2}$ načina (od 6 različtih objekata/mjesta odaberemo dva). Dakle, tražena je vjerojatnost jednaka $\binom{6}{2}0,55^2 0,45^4$. Napokon, zapitajmo se koja je vjerojatnost da će pasti najviše dvije glave u 6 nezavisnih bacanja gore opisanog nesimetričnog novčića. S jedne strane možemo računati vjerojatnost razmještaja za 0 glava (to je lagano), za jednu glavu i za dvije glave i onda ih zbrojiti. S druge strane, možemo iskorisitti konceptualni okvir koji nam pružaju slučajne varijable da izračunamo traženu vjerojatnost. Naime, ako binomna slučajna varijabla opisuje nezavisna ponavljanja slučajnog pokusa s dva ishoda, onda je, prema općenitim napomenama koje smo dali o distribuciji diskretnih slučajnih varijabli, tražena vjerojatnost jednaka

$$\sum_{k=0}^{2}\binom{6}{k}0,55^k 0,45^{6-k} = \binom{6}{0}0,55^0 0,45^6 + \binom{6}{1}0,55^1 0,45^5 + \binom{6}{2}0,55^2 0,45^4 \approx 0,2553.$$

Nadamo se da je jasno kako dolazimo do gornjeg računa. Tražimo vjerojatnost da je slučajna varijabla $X \sim B(6,0,55)$ manja ili jednaka od 2. Riječ je o diskretnoj slučajnoj varijabli pa je, zbog konačne aditivnosti vjerojatnosti,

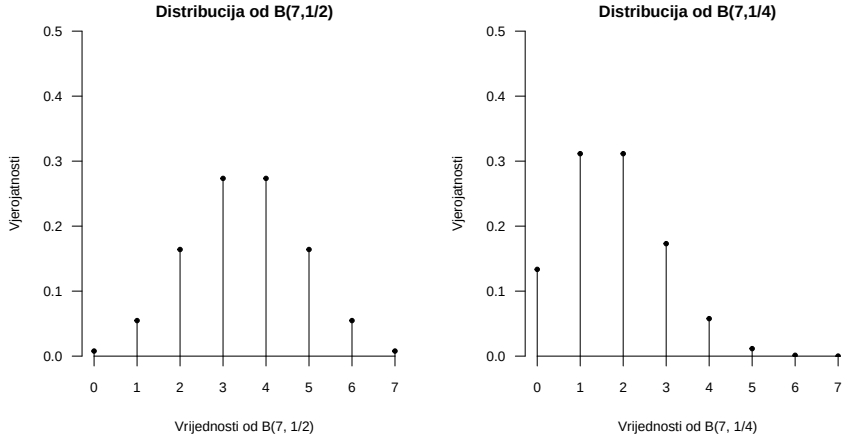
$$\begin{aligned} P(X \leq 2) &= P(X \in \{0,1,2\}) = P(X=0) + P(X=1) + P(X=2) \\ &= \sum_{k=0}^{2} P(X=k) = \sum_{k=0}^{2}\binom{6}{k}0,55^k 0,45^{6-k}. \end{aligned}$$

Usput, tražena vjerojatnost je jednaka i $F_X(2)$, gdje je $X \sim B(6,0,55)$, a F_X je funkcija distribucije slučajne varijble X. Uočimo još jednom da smo koristili pokratu koju koristimo u vjerojatnosti pa smo pisali

$$P(X \leq 2) \quad \text{umjesto} \quad P(\{\omega \in \Omega \mid X(\omega) \leq 2\}).$$

Vidimo da navedene pokrate značajno štede vijeme i postor koje je potrebno za zapisivanje određenih vjerojatnosti, a to je i najvažniji razlog za njihovo uvođenje. □

Na donjim slikama grafički prikazujemo razdiobe binomnih varijabli za razne n i p.



Za izračun vjerojatnosti $P(X = i)$, $i = 1, 2, \ldots, 7$, gdje je $X \sim B(7, 1/4)$, smo koristili R-ovu funkciju `dbinom()` koja upravo računa te vjerojatnosti. Uočimo da su vjerojatnosti poprimanja nekih vrijednosti, poput 7 za $B(7, 1/4)$, zapravo vrlo male

```
> dbinom(7,7,0.25)

[1] 6.103516e-05
```

R ima i druge funkcije kojima se mogu računati vjerojatnosti vezane uz binomnu slučajnu varijablu. Tako R-ova funkcija `pbinom()` računa funkciju distribucije binomne varijable u točki. Na primjer, vrijednost funkcije distribucije binomne $B(7, 1/4)$ u točki 4 je jednaka

```
> pbinom(4,7,0.25)

[1] 0.9871216
```

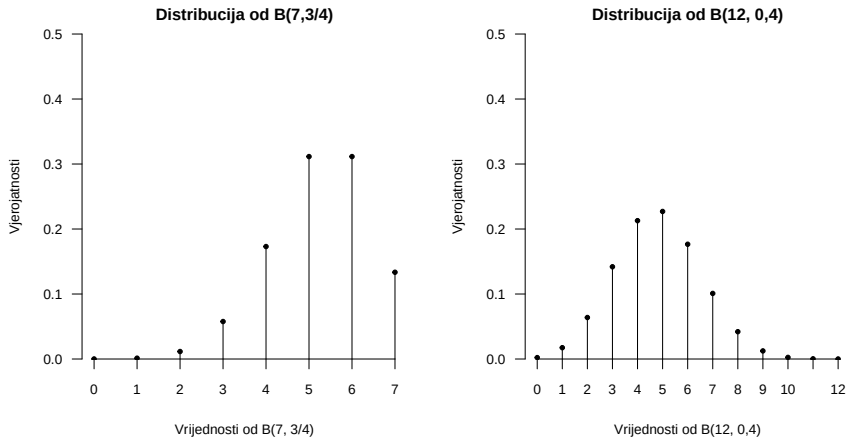
Sjetimo se, vrijednost funkcije distribucije u točki je jednaka vjerojatnosti da je određena slučajna varijabla manja ili jednaka od točke koju smo odabrali. U ovom slučaju je to vjerojatnost da je X manja ili jednaka od 4, odnosno da je X jednaka 0, 1,2,3 ili 4, gdje je $X \sim B(7, 1/4)$.

Zadnja funkcija u tom nizu je `rbinom()` koja generira slučajan uzorak duljine k iz određene binomne distribucije (znamo već da je to na računalu zapravo pseudoslučajno). Na primjer, 28 vrijednosti generiranih iz distribucije $B(7, 1/4)$ dobijemo kao

```
> rbinom(28,7,0.25)

 [1] 3 1 2 2 4 3 1 1 1 2 2 2 1 2 1 1 2 0 2 2 4 4 2 2 3 3 4 1
```

Pogledajmo još neke grafove razdiobi binomnih slučajnih varijabli.



Binomna razdioba je važna i često korištena. Zapamtimo da binomna razdioba opisuje postizanje k uspješnih ishoda u n nezavisnih ponavljanja slučajnog eksperimenta u kojem se pojavljuju dva ishoda - uspjeh i neuspjeh, pri čemu je vjerojatnost uspjeha jednaka p. Kada uvedemo pojam nezavisnosti slučajnih varijabli vidjet ćemo da se binomna slučajna varijabla može prikazati kao zbroj nezavisnih Bernoullijevih slučjnih varijabli s parametrom p.

5.2.3.4 Geometrijska razdioba

U okviru nezavisnog ponavljanja slučajnog eksperimenta s dva ishoda (uspjeh - neuspjeh) smo vidjeli da binomna distribucija daje odgovor na pitanje "koja je vjerojatnost da će u n nezavisnih ponavljanja biti k uspjeha".

Ukoliko postavimo drugačije pitanje dobit ćemo, naravno, drugačiji odgovor. Konkretno, ukoliko slučajna varijabla X broji ponavljanja slučajnog pokusa do prvog pojavljivanja uspjeha (pala je glava, strijelac je pogodio središte mete,...) onda je njena razdioba **geometrijska**, a ona se naziva **geometrijskom slučajnom varijablom**, u oznaci $X \sim Geom(p)$. Geometrijska razdioba je zadana sa

$$P(X = k) = (1-p)^{k-1}p,\ k = 1, 2, \ldots$$

gdje je $p \in (0, 1]$ vjerojatnost uspjeha u svakom pojedinačnom ponavljanju slučajnog pokusa (uočite da smo pretpostavili da je $p > 0$). Jasno je kako se izračuna gornja vjerojatnost: ona je jednaka vjerojatnosti događaja "$k-1$ puta je postignut neuspjeh, a onda je postignut uspjeh". Zbog nezavisnosti ponavljanja slučajnog eksperimenta ta je vjerojatnost jednaka $(1-p)^{k-1}p$. Uočimo da je geometrijska razdioba primjer diskretne distribucije s prebrojivo mnogo mogućih vrijednosti. Da je zaista riječ o distribuciji vidimo iz

$$\sum_{k=1}^{\infty} P(X = k) = p\sum_{k=1}^{\infty}(1-p)^{k-1} = p\sum_{k=0}^{\infty}(1-p)^{k} = \frac{p}{1-(1-p)} = 1.$$

U gornjem izračunu smo iskoristili formulu za sumu geometrijskog reda $\sum_{k=0}^{\infty} q^k = 1/(1-q)$, $|q| < 1$.

Primjer 5.2.10. Pretpostavimo da student izlazi na neki ispit više puta i vjerojatnost prolaska u svakom od izlazaka na ispit je 40%. Pretpostavljamo da su izlasci na ispit nezavisni. Koja je vjerojatnost da će student izaći na ispit 3 ili manji broj puta?
Ako uspjehom označimo prolaskom ispita, a neuspjeh padom ispita, onda je vjerojatnost uspjeha $p = 0,4$, a vjerojatnost neuspjeha $1 - p = 0,6$. Broj izlazaka na ispit do prvog uspjeha modeliramo geometrijskom slučajnom varijablom X pa odgovor na postavljeno pitanje daje vjerojatnost da je $X \leq 3$ (što je ujedno i $F_X(3)$, gdje je F_X funkcija distribucije slučajne varijable X). Dakle

$$P(X \leq 3) = P(X = 1) + P(X = 2) + P(X = 3) = 0,4 + 0,6 \cdot 0,4 + 0,6^2 \cdot 0,4 = 0,784.$$

Prema formuli za vjerojatnost suprotnog događaja znamo da je $P(X > 3) = 1 - P(X \leq 3) = 0,216$. Vidimo da je zapravo vrlo mala vjerojatnost da će studentu trebati više od 3 izlaska na ispit da bi ga položio. □

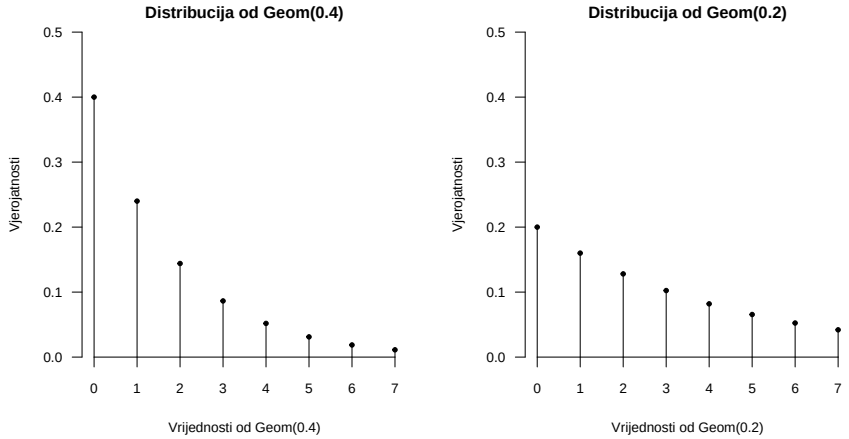
Ako malo razmislimo vidimo da vjerojatnosti u geometrijskoj razdiobi dosta brzo padaju s porastom k. Korištenjem R-ove funkcije `dgeom()` nacrtali smo donja dva grafa (opet možemo koristiti i funkcije `pgeom()` i `rgeom()` na analogni način kao kod binomne slučajne varijable - prvu za izračun funkcije distribucije, a drugu za simulaciju uzorka iz geometrijske razdiobe). Gornji izračun vjerojatnosti $P(X \leq 3)$ potvrđuje i

```
> pgeom(2, 0.4)

[1] 0.784
```

Možemo uočiti malu razliku definicije geometrijske distribucije u odnosu na onu koju smo mi dali. Naime, R prikazuje distribuciju vjerojatnosti postizanja k neuspjeha i ona je jednaka $p(1-p)^k$, gdje je $k = 0, 1, 2, \ldots$. Dakle, sada k može biti i nula s time da su

vjerojatnosti u obje definicije jednake, ali pomaknute za 1. Korištenje jedne od te dvije verzije geometrijske distribucije zavisi o konkretnom pitanju na koji dajemo odgovor.



Zanimljivo je da je geometrijska razdioba primjer razdiobe koja "nema memoriju". Naime, ako malo razmislimo vidimo da je $P(X > n) = (1-p)^n$, za $n \in \mathbb{N}$. Onda je, prema defnciji uvjetne vjerojatnosti, za $k = 0, 1, 2, ..$

$$P(X > n+k \mid X > k) = \frac{P(X > n+k, X > k)}{P(X > k)} = \frac{P(X > n+k)}{P(X > k)}$$
$$= \frac{(1-p)^{n+k}}{(1-p)^k} = (1-p)^n = P(X > n),$$

što znači da je bezuvjetna vjerojatnost da je $X > n$ jednaka uvjetnoj vjerojatnosti da ćemo "odmaknuti" n mjesta od k ako već znamo da je $X > k$, a to je $P(X > n+k \mid X > k)$.

5.2.3.5 Hipergeometrijska razdioba

Pretpostavimo da se u nekoj kutiji nalazi p plavih kuglica i c crvenih kuglica te da na slučajan način izvlačimo n kuglica iz kutije, bez vraćanja kuglica u kutiju. Neka slučajna varijabla X broji izvučene plave kuglice u n izvlačenja kuglica. Tada je X **hipergeometrijska slučajna varijabla** čija je razdioba dana s

$$P(X = k) = \frac{\binom{p}{k}\binom{c}{n-k}}{\binom{p+c}{n}},\ k \in \{0, 1, \ldots, p\},\ n-k \in \{0, 1, \ldots, c\}.$$

a ostale vrijednosti k je $P(X = k) = 0$. Parametri hipergeometrijske distribucije su p, c i n.

Prijašnje slučajne varijable su opisivale neke kvantitativne karakteristike slučajnih eksperimenata koje ponavljamo nezavisno. Opisano izvlačenje plavih i crvenih kuglica možemo shvatiti kao ponavljanje slučajnog eksperimenta, ali su slučajni eksperimenti koje ponavljamo zavisni (ishod sljedećeg slučajnog eksperimenta zavisi o broju izvučenih bijelih i plavih kuglica u eksperimentima koji su prethodili).

Hipergeometrijska slučajna varijabla, odnosno razdioba, se javlja u velikom broju primjena u kojima imamo dvije grupe objekata ili objekte možemo razvrstati u dvije grupe objekata. Na primjer, kod dijeljenja 5 karata iz špila od 52 karte se možemo pitati koja je vjerojatnost da ćemo dobiti 3 desetke, dok će preostale dvije karte biti neke karte različite od 10. Na tu situaciju možemo gledati kao na izvlačenje 5 objekata (kuglica) od čega su 3 odabrane od 4 iste (4 desetke reprezentiramo s 4 plave kuglice u prethodnom razmatranju), a 2 od preostalih 48 karata (analogno, 48 crvenih kuglica). Prema toj

interpretaciji proizlazi da za slučajnu varijablu koja broji izvučene desetke mi želimo izračunati vjerojatnost $P(X = 3)$. Kako je riječ o slučajnoj varijabli s hipergeometrijskom distribucijom imamo

$$P(X = 3) = \frac{\binom{4}{3}\binom{48}{2}}{\binom{52}{5}}.$$

Sličnu argumentaciju možemo primijeniti i u situaciji kada imamo dvije grupe proizvoda (ispravni/neispravni, proizvodi jedne robne marke/proizvodi neke druge robne marke, muškarci/žene i tako dalje). Hipergeometrijskom razdiobom se mogu modelirati i odabiri delegacija poput onih opisanih u Primjeru 3.3.21. Kao i u slučaju drugih diskretnih razdioba koje smo opisali, postavlja se pitanje procjene parametara hipergeometrijske razdiobe, ali to je već statistički problem koji ne analiziramo na ovom mjestu.

5.2.3.6 Poissonova razdioba

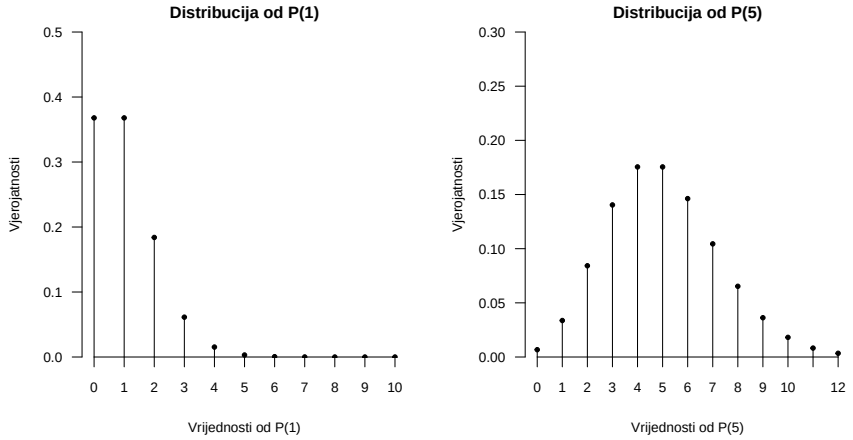
Neka je X slučajna varijabla s vrijednostima u skupu $\{0, 1, 2, \ldots\}$. X je **Poissonova** slučajna varijabla s parametrom $\lambda > 0$ ako joj je razdioba dana s

$$P(X = k) = e^{-\lambda}\frac{\lambda^k}{k!},\ k = 0, 1, 2, \ldots.$$

Razdiobu slučajne varijable X nazivamo Poissonovom razdiobom i koristimo oznaku $X \sim P(\lambda)$. Da je zaista riječ o razdiobi možemo se uvjeriti tako da iskoristimo razvoj eksponencijalne funkcije u red. Imamo

$$\sum_{k=0}^{\infty} P(X = k) = e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!} = e^{-\lambda}e^{\lambda} = 1.$$

Na donjim grafovima je grafički prikazana distribucija Poissonove slučajne varijable s parametrima 1 i 5.



Za izračun Poissonove distribucije koristili smo R-ovu funkciju `dpois()`. Prema analogiji s prethodnim primjerima funkciju distribucije Poissonove slučajne varijable možemo izračunati s `ppois()`. Tako za $X \sim P(5)$ dobijemo da je $F_X(7)$ jednako

```
> ppois(7,5)

[1] 0.8666283
```

Za generiranje uzorka iz Poissonove distribucije koristimo R-ovu funkciju `rpois()`.

Iako veći parametar Poissonove distribucije pomiče "centar" distribucije (najveće vjerojatnosti pojedinih točaka) udesno, vidimo da vjerojatnosti da će Poissonova slučajna

varijabla biti jednaka nekom k vrlo brzo padaju prema nuli s porastom broja k. Poissonova distribucija se koristi za modeliranje slučajnih eksperimenata u kojima se neka pojava rijetko događa. Neki primjeri uključuju broj neispravnih proizvoda u nekoj grupi proizvedenih industrijskih proizvoda, broj tiskarskih grešaka na stranici knjige ili na nekoliko stranica knjige, broj krivo prenesenih poruka u nekom komunikacijskom kanalu u jednici vremena, broj posjeta nekoj mrežnoj stranici u nekom intervalu vremena, broj potresa na nekom području, ali i broj čestica u radioaktivnom raspadu. Svi ti primjeri podrazumjevaju da je, primjerice, vrlo mala vjerojatnost pojedinačne tiskarske greške, ali ako gledamo velik broj stranica onda se može očekivati pojavljivanje tiskarskih grešaka. Slično je i za broj neispravnih proizvoda ili posjeta nekoj mrežnoj stranicu (unutar minute, recimo).

Primjenjivost Poissonove slučajne varijable proizlazi i iz činjenice da je ona dobra aproksimacija za binomnu slučajnu varijablu kada je n velik, a p mali. Konkretnije, za $X \sim B(n,p)$ te veliki n i mali p definirajmo $\lambda = n \cdot p$. Tada vrijedi aproksimacija

$$P(X = k) \approx e^{-\lambda} \frac{\lambda^k}{k!}. \tag{5.10}$$

Kada je vjerojatnost p vrlo mala, a n velik (na primjer $p = 0,002$, a $n = 5.000$), parametar λ možemo interpretirati kao intenzitet pojavljivanja promatrane slučajne pojave. Pogledajmo jedan jednostavan primjer.

Primjer 5.2.11 (Primjer 5.2b iz [11]). pretpostavimo da je vjerojatnost da će neki proizvod biti neispravan jednaka $0,1$ te da su proizvodi neispravni nezavisno jedan od drugoga. Nađimo vjerojatnost da će u 10 slučajno odabranih proizvoda najviše jedan biti neispravan.
Ovakav zadatak nas upućuje na binomnu slučajnu varijablu. Neka je X slučajna varijabla koja koja broji neispravne proizvode. Tražimo vjerojatnost da je $X \leq 1$. Vjerojatnost uspjeha je $0,1$ (proizvod je neispravan), a vjerojatnost neuspjeha je $0,9$ (proizvod je ispravan). Tada je

$$P(X \leq 1) = P(X = 0) + P(X = 1) = \binom{10}{0}(0,1)^0(0,9)^{10} + \binom{10}{1}(0,1)^1(0,9)^9 = 0,7361.$$

Definirajmo sada $\lambda = 10 \cdot 0,1 = 1$ i neka je $Y \sim P(1)$. Tada je

$$P(Y \leq 1) = P(Y = 0) + P(Y = 1) = e^{-1}\frac{1^0}{0!} + e^{-1}\frac{1^1}{1!} \approx 0,7358.$$

Korisnost Poissonove aproksimacije binomne slučajne varijable još je očitija kada je n zaista velik, poput, milion ili više. □

5.2.4 Nezavisne slučajne varijable

U prošlom poglavlju smo se upoznali s pojmom nezavisnih događaja. Podsjetimo se: događaji A i B iz prostora elementarnih događaja Ω su nezavisni ako je

$$P(A \cap B) = P(A) \cdot P(B),$$

s time da je deifinicija za nezavisnost više od dva događaja bila složenija - nije dovoljno da su događaji nezavisni u parovima, nego moraju biti nezavisni svi parovi, sve trojke događaja, sve četvorke i tako dalje.

Definicija nezavisnosti se prenosi i na slučajne varijable. Naime, slučajne varijable X i Y su **nezavisne** ako za sve skupove $A, B \subset \mathbb{R}$ vrijedi

$$P(X \in A, Y \in B) = P(X \in A) \cdot P(Y \in B).$$

Slučajne varijable koje nisu nezavisne su zavisne. Kao što smo već više puta napomenuli, gornja jednakost je zapravo pokrata za

$$P(\{\omega \in \Omega \mid X(\omega) \in A\} \cap \{\omega \in \Omega \mid Y(\omega) \in B\}) \\ = P(\{\omega \in \Omega \mid X(\omega) \in A\}) \cdot P(\{\omega \in \Omega \mid Y(\omega) \in B\}).$$

Općenito, imamo sljedeću definiciju.

Definicija 5.2.12. Slučajne varijable $X_1, X_2, \dots X_n$, $n \in \mathbb{N}$, su **nezavisne** ako za sve $B_1, B_2, \dots B_n \subset \mathbb{R}$ vrijedi

$$P\Big(\bigcap_{i=1}^{n}\{X_i \in B_i\}\Big) = \prod_{i=1}^{n} P(X_i \in B_i). \tag{5.11}$$

Načelno govoreći gornja definicija ne vrijedi za sve skupove $B_i \in \mathbb{R}$, ali je dovoljno provjeriti da vrijedi za sve "normalne" podskupove skupa realnih brojeva.[11] No to za nas i nije prevažno zbog sljedećeg teorema (Teorem 11.1. u [10]).

Teorem 5.2.13. *Slučajne varijable $X_1, X_2, \dots X_n$ su nezavisne ako i samo ako za sve $x_1, x_2, \dots x_n \in \mathbb{R}$, $n \in \mathbb{N}$, vrijedi*

$$P(X_1 \le x_1, X_2 \le x_2, \dots, X_n \le x_n) = P(X_1 \le x_1) \cdot P(X_2 \le x_2) \cdot \ldots \cdot P(X_n \le x_n). \tag{5.12}$$

U slučaju diskretnih slučajnih varijabli se nezavisnost može okarakterizirati pomoću razdioba slučajnih varijabli (vidi Teorem 5.3. u [10]).

Teorem 5.2.14. *Neka su X, Y diskretne slučajne varijable zadane svojim distribucijama*

$$X \sim \begin{pmatrix} a_1 & a_2 & \dots & a_n & \dots \\ p_1 & p_2 & \dots & p_n & \dots \end{pmatrix} \quad Y \sim \begin{pmatrix} b_1 & b_2 & \dots & b_n & \dots \\ q_1 & q_2 & \dots & q_n & \dots \end{pmatrix},$$

gdje su $p_i, q_j \ge o$, $i, j \in \mathbb{N}$ takvi da je $\sum_{i=1}^{\infty} p_i = 1$ i $\sum_{i=1}^{\infty} q_i = 1$. Tada je nezavisnost slučajnih varijabli X i Y ekvivalentna uvjetu

$$P(X = a_i, Y = b_j) = P(X = a_i) \cdot P(Y = b_j) = p_i \cdot q_j, \ i, j \in \mathbb{N}. \tag{5.13}$$

Za n diskretnih slučajnih vrijabli se nezavisnost može okarakterizirati uvjetom analognom onome u (5.13).

Kao što vidimo, provjera nezavisnosti diskretnih slučajnih varijabli svodi na provjeru svojstava razdiobi slučajnih varijabli. Vjerojatnost s lijeve strane jednakosti (5.13) predstavlja **zajedničku razdiobu** slučajnih varijabli X i Y. Ona se prirodno javlja kada proučavamo dvije ili više kvantitativnih karakteristika nekog slučajnog eksperimenta. Na ovom mjestu nećemo preduboko ulaziti u zajedničke karakteristike slučajnih varijabli, ali možemo uočiti da se zajednička razdioba diskretnih slučajnih varijabli X i Y s vrijednostima (a_i) i (b_j) može prikazati tablicom poput niže navedene. Zbroj svih vrijednosti u tablici mora biti 1.

	a_1	a_2	$\dots$	a_n	$\dots$
b_1	$P(X = a_1, Y = b_1)$	$P(X = a_2, Y = b_1)$	$\dots$	$P(X = a_n, Y = b_1)$	$\dots$
b_2	$P(X = a_1, Y = b_2)$	$P(X = a_2, Y = b_2)$	$\dots$	$P(X = a_n, Y = b_2)$	$\dots$
b_3	$P(X = a_1, Y = b_3)$	$P(X = a_2, Y = b_3)$	$\dots$	$P(X = a_n, Y = b_3)$	$\dots$
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$

(5.14)

[11] Uočite da neki od skupova B_i mogu biti jednaki $\mathbb{R}$ pa je $\{X_i \in B_i\} = \Omega$. Posljedično, definicija nezavisnosti slučajnih varijabli uključuje da su promatrane slučajne varijable nezavisne u parovima, u trojkama i tako dalje.

Iako smo to više puta istaknuli, ponovimo da je vjerojatnost $P(X = a_i, Y = b_j)$ pokrata za

$$P(\{\omega \in \Omega \mid X(\omega) = a_i\} \cap \{\omega \in \Omega \mid Y(\omega) = b_j\}).$$

Teorem 5.2.14 govori o tome da je zajednička razdioba slučajnih varijabli X i Y jednaka umnošku odgovarajućih razdiobi slučajnih varijabli X i Y kada su X i Y nezavisne slučajne varijable. Naravno, to ne mora biti slučaj i tada kažemo da su slučajne varijable X i Y **zavisne**. Ovdje se nećemo baviti zavisnim slučajnim varijablama jer je riječ o zaista velikoj temi koja bi nas značajno skrenula s puta prezentiranja osnova teorije vjerojatnosti. Ipak, dajemo jedan primjer radi ilustracije.

Primjer 5.2.15. Pogledajmo slučajni eksperiment nezavisnog bacanja dvije kockice. Neka je X slučajna varijabla koja je jednaka broju koji je pao na prvoj kockici, Y slučajna varijabla koja je jednaka broju koji je pao na drugoj kockici, a Z slučajna varijabla koja je jednaka zbroju brojeva koji su pali na kockicama (pogledajte primjer 5.1.7).
Dosta je jasno da su X i Y nezavisne slučajne varijable jer su bacanja kockica nezavisna. Na primjer, u skladu s prijašnjim oznakama, neka je $a_2 = 2$ i $b_3 = 3$. Tada je

$$P(X = 2) = \frac{1}{6} \quad \text{i} \quad P(Y = 3) = \frac{1}{6}.$$

S druge strane, X i Y, gledano u paru, mogu postići jednu od 36 vrijednosti uređenih parova oblika (i, j), gdje su $i, j = 1, 2, \ldots, 6$. Sve su one jednako vjerojatne pa je

$$P(X = 2, Y = 3) = \frac{1}{36}.$$

Stoga je $P(X = 2, Y = 3) = P(X = 2)P(Y = 3)$, a ista argumentacija pokazuje da je to istina za sve vrijednosti a_i i b_j slučajnih varijabli X i Y, $i, j = 1, 2, \ldots, 6$ pa su one nezavisne.[12]
S druge strane, X i Z nisu nezavisne slučajne varijable (zavisne su). Da bi to pokazali dovoljno je pokazati da relacija (5.13) ne vrijedi za po jednu vrijednost slučajnih varijabli X i Z.[13] Uzimo, na primjer $a = 1$ i $c = 3$. Tada je

$$P(X = 1) = \frac{1}{6} \quad \text{i} \quad P(Z = 3) = \frac{2}{36}.$$

S druge strane, ako zahtjevamo da je istovremeno na prvoj kockici pala jedinica, a da je zbroj jednak 3, onda vidimo da je to moguće samo ako je na kockicama pao par $(1, 2)$ (na drugoj kockici je pao broj 2). Dakle,

$$P(X = 1, Z = 3) = \frac{1}{36}$$

pa je

$$\frac{1}{36} = P(X = 1, Z = 3) \neq P(X = 1)P(Z = 3) = \frac{1}{6} \cdot \frac{2}{36}.$$

Stoga X i Z nisu nezavisne slučajne varijable. Naravno, mogli smo upotrijebiti i neke druge parove vrijednosti a i c. Tako za $a = 1$ i $c = 12$ imamo $P(X = 1) = 1/6$, $P(Z = 12) = 1/36$, ali $P(X = 1, Z = 12) = 0$ jer zbroj na dvije kockice ne može biti jednak 12, ako je na prvoj kockici pala jedinica.

[12] Uočite, na X i Y možemo gledati kao na slučajne varijable definirane na $\Omega = \{(i, j) \mid i, j = 1, 2, 3, 4, 5, 6\}$. Tada je, na primjer, $\{X = 2\} = \{(2, 1), (2, 2), (2, 3), (2, 4), (2, 5), (2, 6)\}$ pa je $P(X = 2) = 6/36 = 1/6$.

[13] Općenito, ako neko svojstvo zahtjeva da neka relacija $R(x, y)$ vrijedi za sve x i y, onda ja za dokaz da to svojstvo ne vrijedi dovoljno naći neke x_0 i y_0 takve da relacija $R(x_0, y_0)$ nije istinita.

Mogu se definirati i razne druge slučajne varijable koje neće biti nezavisne. Neka je V slučajna varijabla koja je jednaka 1 ako na prvoj kocki padne broj 5, W slučajna varijabla koja je jednaka 1 ako na prvoj kocki padne neparan broj. Tada su V i W zavisne slučajne varijable. Naime, $P(W = 1) = P(\text{"pao je neparan broj na prvoj kocki"}) = 1/2$, dok je $P(V = 1) = 1/6$. S druge strane je $P(Z = 1, V = 1) = P(V = 1) = 1/6$. Stoga

$$P(Z = 1, V = 1) = \frac{1}{6} \neq \frac{1}{2} \cdot \frac{1}{6} = P(Z = 1) \cdot P(V = 1).$$

Dakle, relacija (5.13) nije zadovoljena pa V i W nisu nezavisne. □

Napomena 5.2.16 (Slučajni vektori)**.** Ako malo bolje pogledamo relaciju (5.12) vidimo da s desne strane jednakosti imamo umnožak funkcija (koje ovise o x_i) oblika $P(X_i \leq x_i)$, $i \in \{1, 2, \ldots, n\}$. Znamo da je tako definirana funkcija distribucije slučajne varijable X_i. S druge strane, slučajne varijable X_i možemo združiti u vektor $X^n = (X_1, X_2, \ldots X_n)$, po uzoru na združivanje brojeva u vektore. Sada je X^n preslikavanje s Ω u $\mathbb{R}^n$, $n \in \mathbb{N}$ i naziva se **slučajnim vektorom**. Gledano tako, u relaciji (5.12) piše da je funkcija distribucije slučajnog vektora jednaka umnošku funkcija distribucije njegovih komponenata, naravno, ako su slučajne varijable $X_1, X_2, \ldots, X_n$ nezavisne. To je jedna od korisnijih karakterizacija nezavisnosti slučajnih varijabli.
Uočimo dodatno da iz nezavisnosti n slučajnih varijabli $X_1, X_2, \ldots X_n$ slijedi nezavisnost parova (ili trojki, četvorki,...) tih slučajnih varijabli i to tako da pustimo da svi x_i teže u ∞ osim x_j-ova onog para slučajnih varijabli za koji želimo pokazati nezavisnost. U osnovi na kraju tog argumenta iskoristimo da je $P(X_i < \infty) = 1$ za sve i. Ako malo razmislimo uviđamo da je "prirodno" da to vrijedi jer u suprotnom ne bi imali usklađenost definicija nezavisnosti slučajnih događaja i slučajnih varijabli. □

Napomena 5.2.17 (Konstante)**.** Pogledajmo funkciju $C : \Omega \to \mathbb{R}$ za koju je $C(\omega) = c \in \mathbb{R}$, za sve $\omega \in \Omega$. Tada je C zapravo konstantna funkcija, ondosno **konstanta**. Pišemo $C \equiv c$ ili skraćeno $C = c$.
Konstanta je diskretna slučajna varijabla s distribucijom

$$C \sim \begin{pmatrix} c \\ 1 \end{pmatrix}.$$

Konstante su nezavisne s bilo kojom drugom slučajnom varijablom. Naime, ako je X neka druga slučajna varijabla, onda relaciju (5.12) čitamo kao

$$P(X \leq x_1, C \leq x_2) = P(X_1 \leq x_1) \cdot P(C \leq x_2),\ x_1, x_2 \in \mathbb{R}.$$

Za $x_2 < c$ je $P(C \leq x_2) = 0$ jer je $\{\omega \in \Omega \mid c \leq x_2\} = \emptyset$, a iz istog razloga je i $P(X \leq x_1, C \leq x_2) = P(\emptyset) = 0$. Sjetimo se opet - zarez označava presjek dva skupa.
Za $x_2 \geq c$ je $P(C \leq x_2) = 1$ jer je $\{\omega \in \Omega \mid c \leq x_2\} = \Omega$. No onda i s desne strane ostane samo $P(X \leq x_1)$ pa i u tom slučaju vrijedi da je $P(X \leq x_1, C \leq x_2) = P(X_1 \leq x_1) \cdot P(C \leq x_2)$. Zaključujemo da ta relacija vrijedi za sve $x_1, x_2 \in \mathbb{R}$ pa zbog (5.12) slijedi da su X i C nezavisne. □

Nezavisnost slučajnih varijabli implicira (uzrokuje) dosta poželjnih svojstava. S nekima ćemo se uskoro upoznati, a za sada dajemo primjere u kojima je nezavisnost nužna da bi zbroj slučajnih varijabli imao neka poželjna svojstva.
1. Zbroj **nezavisnih** Bernoullijevih slučajnih varijabli. Neka su $X_1, X_2, \ldots X_n$ nezavisne Bernoullijeve slučajne varijable s parametrom p. Tada je njihov zbroj binomna slučajna varijabla $B(n, p)$, odnosno

$$X_1 + X_2 + \ldots + X_n \sim B(n, p).$$

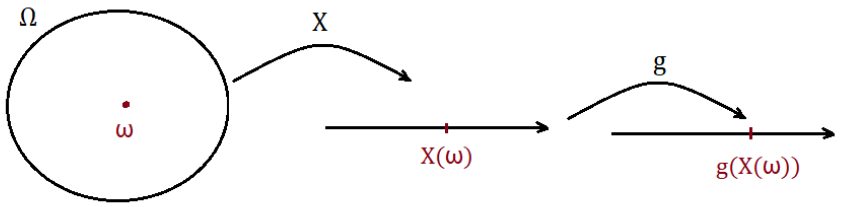
S obzirom na interpretaciju Bernoullijevih slučajnih varijabli kao indikatora, vidimo da se zapravo binomna slučajna varijabla može prikazati kao zbroj nezavisnih indikatora.
2. Zbroj dvije **nezavisne** binomne slučajne varijable je opet binomna slučajna varijabla. Malo preciznije, ako su $X \sim B(n,p)$ i $Y \sim B(m,p)$, $n,m \in \mathbb{N}$, nezavisne slučajne varijable, onda je

$$X + Y \sim B(n+m,p).$$

Jasno, ovo svojstvo se lagano proširi na n nezavisnih binomnih slučajnih varijabli, $n \in \mathbb{N}$.
3. Zbroj dvije **nezavisne** Poissonove slučajne varijable je opet Poissonova slučajna varijabla. Preciznije, ako su $X \sim P(\lambda_1)$ i $Y \sim P(\lambda_2)$ nezavisne Poissonove slučajne varijable, onda je

$$X + Y \sim P(\lambda_1 + \lambda_2).$$

Završit ćemo ovaj kratki pregled nezavisnosti slučajnih varijabli s još jednim korisnim rezultatom. Neka je X slučajna varijabla i $g : \mathbb{R} \to \mathbb{R}$ funkcija. Onda je $g(X)$ opet slučajna varijabla s Ω u $\mathbb{R}$. Načelno g mora zadovoljavati još neka slaba svojstva, ali to je uvijek istina za neprekidne funkcije (zbrajanje, oduzimanje, potencije, eksponencijalnu i logaritamsku funkcije, sinus i kosinus i tako dalje). Shematski prikaz slučajne varijable $g(X)$ dan je na donjoj slici.



g(X) je slučajna varijabla s Ω u R (skup realnih brojeva)

Ako je X diskretna slučajna varijabla i g realna funkcija kao gore, onda možemo naći i razdiobu te nove slučajne varijable $g(X)$. Općenito nije moguće dati eksplicitnu formulu za to (problem može biti u bijektivnosti funkcije g), ali za većinu jednostavnih primjena je lagano odrediti razdiobu od $g(X)$. Pogledajmo primjer.

Primjer 5.2.18. Neka je diskretna slučajna varijabla X zadana razdiobom (distribucijom)

$$X \sim \begin{pmatrix} -1 & 0 & 1 & 2 \\ 1/4 & 1/8 & 1/2 & 1/8 \end{pmatrix}.$$

Pogledajmo funkciju $g(x) = x+2$. Funkcija g je bijekcija (kao i svaka linearna funkcija). Rekli smo da je $g(X) = X + 2$ opet slučajna varijabla. Njene vrijednosti su $1, 2, 3$ i 4, u što se lagano uvjerimo. Na primjer, neka je

$$A_1 = \{\omega \in \Omega \mid X(\omega) = -1\}.$$

Dakle, za $\omega \in A_1$ je $X(\omega) = -1$ pa je

$$g(X(\omega)) = g(-1) = -1 + 2 = 1.$$

No, onda je i

$$P(g(X) = 1) = P(A_1) = 1/4.$$

Na isti način provjerimo da se postižu ostale vrijednosti s istim vjerojatnostima kao u polaznoj razdiobi, odnosno vrijedi

$$X+2 \sim \begin{pmatrix} 1 & 2 & 3 & 4 \\ 1/4 & 1/8 & 1/2 & 1/8 \end{pmatrix}.$$

Uzmimo sada funkciju $h(x) = 2 \cdot x$. Opet je $h(X)$ slučajna variajbla i to s vrijednostima $-2, 0, 2$ i 4, a ujedno je i bijekcija. Kao i u slučaju s funkcijom g vidimo da je

$$2X \sim \begin{pmatrix} -2 & 0 & 2 & 4 \\ 1/4 & 1/8 & 1/2 & 1/8 \end{pmatrix}.$$

U oba slučaja vidimo da funkcije primjenjujemo na vrijednosti slučajne varijable, dok **vjerojatnosti ostaju nepromijenjene**.

Malo je drugačija situacija ako funkcija g nije bijekcija. Na primjer, uzmimo $g(x) = x^2$. Tada su vrijednosti od $g(X)$ brojevi $0, 1$ i 4. U tom slučaju ne možemo samo "prepisati" pripadne vjerojatnosti jer je funkcija g "zalijepila" vrijednosti -1 i 1 slučajne varijable X u vrijednost 1 slučajne varijable X^2. U tom slučaju trebamo zbrojiti sve (u ovom slučaju dvije) vjerojatnosti točaka koje su preslikane u isto po funkciji g. Konkretno, za $g(x) = x^2$ dobivamo

$$X^2 \sim \begin{pmatrix} 0 & 1 & 4 \\ 1/8 & 3/4 & 1/8 \end{pmatrix}.$$

gdje je $3/4 = P(X = -1) + P(X = 1) = P(X^2 = 1)$.[14] □

Kao što smo nagovijestili u prethodnom primjeru, ukoliko je funkcija g bijekcija, vrlo jednostavno možemo odrediti razdiobu diskretne slučajne varijable $Y = g(X)$. Naime, u tom slučaju je za realni broj x

$$P(Y = g(x)) = P(g(X) = g(x)) = P(X = x),$$

pri čemu zadnja jednakost vrijedi zbog bijektivnosti funkcije g. U slučaju da su $a_1, a_2, \ldots$ sve vrijednosti koje postiže slučajna varijabla X, onda su $g(a_1), g(a_2), \ldots$ sve vrijednosti koje poprima slučajna varijabla $Y = g(X)$, a pripadne vjerojatnosti su

$$P(Y = g(a_i)) = P(X = a_i),\ i \in \mathbb{N}.$$

Time je u potpunosti određena razdioba slučajne varijable Y. U prethodnom primjeru sa slučajnom varijablom X i funkcijom $g(x) = x + 2$ su vrijednosti slučajne varijable X brojevi $a_1 = -1$, $a_2 = 0$, $a_3 = 1$ i $a_4 = 2$, dok su vrijednosti slučajne varijable $Y = X + 2$ brojevi $g(a_1) = 1$, $g(a_2) = 2$, $g(a_3) = 3$ i $g(a_4) = 4$. Pripadne vjerojatnosti postizanja odgovarajućih vrijednosti slučajnih varijabli X i Y se ne mijenjaju zbog bijektivnosti funkcije $g(x) = x + 2$.

Funkcije slučajnih varijabli se često koriste i prirodno se pojavljuju u primjenama. Za ilustraciju pogledajmo sljedeći primjer.

Primjer 5.2.19. Pretpostavimo da je neki strijelac došao na natjecanja na kojem svaki strijelac gađa metu 15 puta, a za prolazak u finale je potrebno pogoditi metu 12 puta. Pretpostavimo da određeni strijelac S s pogađa mets s vjerojatnosti $0,7$ pri čemu su međusobna gađanja mete nezavisna. Znamo da tada broj pogodaka strijelca S u metu možemo modelirati slučajnom varijablom $X \sim B(15,\ 0,7)$.

[14] Jasno je kako smo došli do tog izračuna: $\{X^2 = 1\}$ (svi elementi iz Ω koje X^2 preslikava u 1) je unija disjunktnih skupova $\{X = -1\}$ i $\{X = 1\}$ pa zbog konačne aditivnosti vrijedi navedena jednakost vjerojatnosti.

Definirajmo novu slučajnu varijablu $Y = X - 12$. Ona je kompozicija funkcije $g(x) = x - 12$, koja je bijektivna, i slučajne varijable X. Sada se vjerojatnost prolaska strijelca S u finale jednostavno može interpretirati kao vjerojatnost da je slučajna varijabla Y nenegativna. Dakle, ako izračunamo vjerojatnost

$$P(Y \geq 0)$$

izračunat ćemo vjerojatnost prolaska strijelca S u finale. Za vježbu izračunajmo tu vjerojatnost. Zbog bijektivnosti funkcije g imamo

$$\begin{aligned} P(Y \geq 0) &= P(Y = 0) + P(Y = 1) + P(Y = 2) + P(Y = 3) \\ &= P(X = 12) + P(X = 13) + P(X = 14) + P(X = 15) \\ &= \binom{15}{12} 0,7^{12} 0,3^3 + \binom{15}{13} 0,7^{13} 0,3^2 + \binom{15}{14} 0,7^{14} 0,3^1 + \binom{15}{15} 0,7^{15} 0,3^0 \\ &\approx 0,2969. \end{aligned}$$

Dakle, vjerojatnost prolaska strijelca S u finale iznosi $0,2969$. Vidimo da ona nije velika, ali možemo uočiti da je i norma za prolazak u finale dosta visoko postavljena (na 80% uspješnosti pogodaka). Možete za vježbu provjeriti da se vjerojatnost prolaska strijelca u finale poveća na $0,648$ ako je vjerojatnost pogotka mete u svakom gađanju jednaka $0,8$. □

Kada razmišljamo o nezavisnosti slučajnih varijabli koje su su nastale kompozicijom nezavisnih slučajnih varijabli možemo se zapitati da li se time "kvari" nezvisnost. Važno je za uočiti da transformacije slučajnih varijabli funkcijama (svake pojedinačno) ne može "pokvariti" nezavisnost. Imamo sljedeću propoziciju (Propozicija 5.3 u [10]).

Propozicija 5.2.20. *Neka su $X_1, X_2, \ldots, X_n$, $n \in \mathbb{N}$, nezavisne slučajne varijable i $g_1, g_2, \ldots, g_n$ realne funkcije. Tada su nezavisne i slučajne varijable $g_1(X_1)$, $g_2(X_2)$, …, $g_n(X_n)$.*

5.3 Integrali

Vidjeli smo da se u slučaju diskretnih slučajnih varijabli sve zanimljive vjerojatnosti mogu izračunati pomoću zbrajanja određenih brojeva koji su zadani razdiobom slučajnih varijabli. U općenitom slučaju to više neće biti moguće jer ćemo većinu vjerojatnosnih objekata izraziti pomoću integrala. Iako bi s integralima već trebali biti upoznati, u ovom potpoglavlju dajemo kratak pregled osnovnih rezultata vezanih uz integrale.

Povijesno gledano su integrali vezani uz problem određivanja površine. Osnova za izračun površina raznih oblika je površina pravokutnika koju znamo izračunati. Naravno, ako su oblici čiju površinu želimo izračunati nepravilni više ne možemo primijeniti osnovnu formulu za površinu pravokutnika. Stara je ideja, još iz stare Grčke, da u tom slučaju pokušamo podijeliti površinu oblika čiju površinu želimo odrediti na puno manjih pravokutnika koji otprilike ispunjavaju (ili obujmljuju) traženu površinu i onda zbrojimo površine pravokutnika kojima smo pokušali aproksimirati traženu površinu. Ukoliko gledamo sve manje i manje pravokutnike kojima aproksimiramo traženu površinu dobivat ćemo sve bolje i bolje procjene tražene površine lika koji promatramo. Na taj način su izračunate površine kruga, elipse, dijela parabole i sličnih likova.

Dugo vremena, sve do Newtona i Leibniza, nije bilo jasno kako dati općenitu metodu za određivanje površine omeđene nekom krivuljom. No, formaliziranjem pojma derivacije i njene veze s integralom došlo je znatnog razvoja dijela matematike koji danas nazivamo Matematičkom analizom. Njemački matematičar Bernhard Riemann je u 19. stoljeću

formalizirao pojam integrala pa se "obični"[15] integrali koji se koriste u analizi često i zovu Riemannovi integrali.

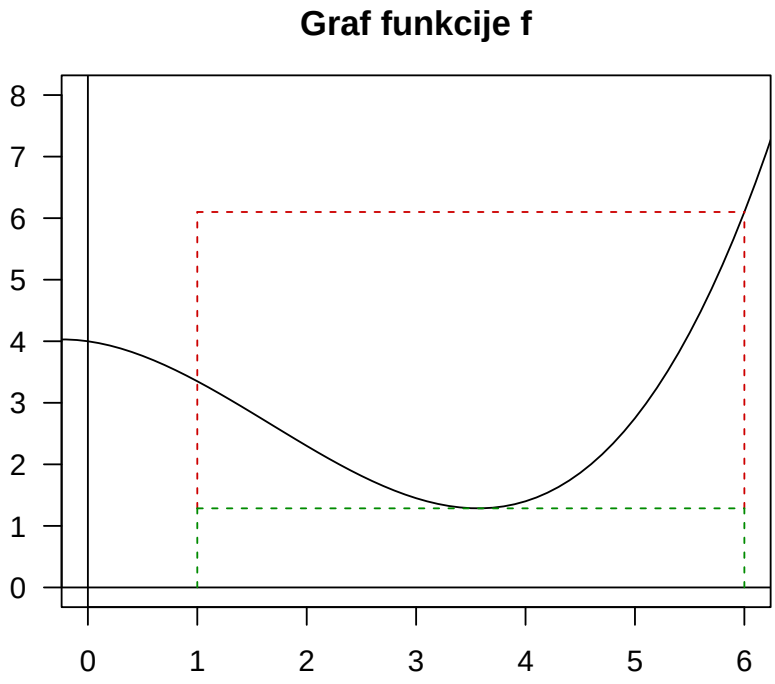
5.3.1 Određeni i neodređeni integrali

Pogledajmo na jednom primjeru ideju izračuna površine ispod neke krivulje. Uzmimo funkciju

$$f(x) = 0,1x^3 - 0,5x^2 - 0,25x + 4,\ x \in \mathbb{R}$$

i razmislimo kako možemo izračunati površinu koju određuje ta krivulja (graf te funkcije) s osi x i to za $x \in [1, 6]$. Geometrijski gledano, željeli bi površinu nepravilne površine koji omeđuje graf funkcije f nekako procijeniti površinama pravokutnika jer njihove površine možemo jednostavno računati.

Graf funkcije f je prikazan na donjoj slici. Na graf smo dodali nekoliko linija da istaknemo dodatne površine koje nas zanimaju. Zelena horizontalna linija prolazi kroz minimum funkcije f na segmentu $[1, 6]$ (označimo ga s m), dok crvena horizontalna linija prolazi kroz maksimum funkcije f na segmentu $[1, 6]$ (označimo ga s M).



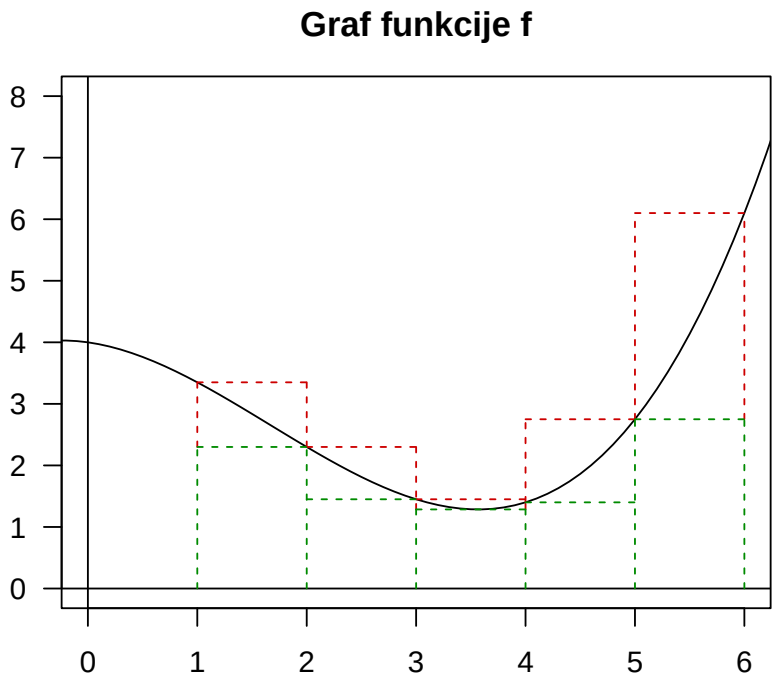
Mi želimo izračunati površinu lika omeđenog segmentom $[1, 6]$ na x osi, pravcima $x = 1$ i $x = 6$ sa strane lika i grafom funkcije f odozgo. Jasno je da je ta površina veća od površine pravokutnika omeđenog segmentom $[1, 6]$ na x osi, pravcima $x = 1$ i $x = 6$ sa strane lika i pravcem $y = m$, a manja od površine pravokutnika omeđenog segmentom $[1, 6]$ na x osi, pravcima $x = 1$ i $x = 6$ sa strane lika i pravcem $y = M$. Površina manjeg pravokutnika je jednaka $m \cdot (6 - 1)$, dok je površina većeg pravokutnika jednaka $M \cdot (6 - 1)$. Na ovoj razini ideja aproksimacije tražene površine pravokutnicima ne izgleda naročito perspektivno.

Pogledajmo što se dogodi kada malo profinimo našu aproksimaciju. U tu svrhu podijelimo segment $[1, 6]$ na x osi na 5 jednakih dijelova i sada na svakom od tih 5 podsegmenata ($[1, 2]$, $[2, 3]$, $[3, 4]$, $[4, 5]$ i $[5, 6]$) opet označimo minimum i maksimum zelenom odnosno crvenom crtom. Sada je, opet, površina traženog lika veća od zbroja površina zelenih pravokutnika i manja od zbroja površina pravokutnika koji su s donje strane omeđeni osi x, a s gornje crvenim linijama. Uočimo da sada više nememo jedan

[15] Postoje i općenitiji integrali poput Lebesguevog integrala. Oni su definirani za općenitije funkcije.

minimum i maksimum, već imamo pet minimuma i maksimuma na svakom od podsegmenata na koje smo podijelili segment $[1, 6]$. U ovom slučaju je aproksimacija površine traženog lika dosta bolja nego u prethodnom slučaju.

Navedena situacija je prikazana na sljedećoj slici.



Jasno je kako nastaviti dalje: podijelimo os x prvo na 10 jednakih dijelova (ili 12, nije to važno), zatim na 20 jednakih dijelova i tako dalje. U svakom koraku izračunamo površine zelenih i crvenih pravokutnika i uočavat ćemo da se one sve manje i manje razlikuju, odnosno da se sve više približavaju traženoj površini ispoda grafa funkcije f na segmentu $[1, 6]$.

Apstraktno govoreći, prije opisani postupak aproksimacije površine ispod grafa funkcije f podrazumijeva odabir brojeva $x_0, x_1, \ldots x_n$, $n \in \mathbb{N}$, takvih da je

$$1 = x_0 \leq x_1 \leq \ldots \leq x_{n-1} \leq x_n = 6.$$

Te točke dijele segment $[1, 6]$ na n dijelova (ne moraju nužno biti jednaki). S m_i označimo minimum, a s M_i maksimum funkcije f na podsegmentu $[x_{i-1}, x_i]$ segmenta $[1, 6]$, $i = 1, 2, \ldots, n$. Definirajmo s_n kao zbroj površina manjih kvadrata (zelenih prema gornjim slikama, samo u općenitijem slučaju)

$$s_n = \sum_{i=1}^{n} m_i (X_i - x_{i-1})$$

a S_n kao zbroj površina većih kvadrata

$$S_n = \sum_{i=1}^{n} M_i (X_i - x_{i-1}).$$

Ukoliko s P označimo traženu površinu vrijedi ocjena

$$m(6-1) \leq s_n \leq P \leq S_n \leq M(6-1).$$

Uz još malo napora se zapravo može pokazati da zbrojevi s_n i S_n teže istom broju kada n teži u beskonačnost i taj broj je jednak površini P, odnosnu integralu funkcije f na

segmentu $[1,6]$; u oznaci

$$\int_{[1,6]}(0.1x^3-0.5x^2-0.25x+4)dx=\int_1^6(0.1x^3-0.5x^2-0.25x+4)dx.$$

U općenitom slučaju se za velik broj funkcija $g:\mathbb{R}\to\mathbb{R}$ i segmenata $[a,b]\subset\mathbb{R}$, $a\leq b$, može ponoviti gore opisani postupak. Sam postupak treba biti malo općenitiji (gledaju se infimumi i supremumu fukcije, kao i infimumi i supremumi svih zbrojeva oblika s_n i S_n), ali je isti zaključak: ako zbrojevi[16] oblika s_n i S_n konvergiraju istom broju, onda se funkcija g naziva Riemann-integrabilnom, a taj broj se zove **integral** funkcije g na segmentu $[a,b]$. Oznaka za integral je

$$\int_{[a,b]}g(x)dx=\int_a^b g(x)dx=\int_a^b g(t)dt.$$

Uočimo da je x, odnosno t, samo "tehnička" varijabla koja se naziva varijablom integracije. Funkcija g se naziva **integrandom**, a segment $[a,b]$ **područjem integracije**. Više o definiciji integrala može se naći u [9].

Pokazuje se da je skup funkcija koje su (Riemann-)integrabilne dosta velik, a svakako uključuje neprekidne funkcije na segmentu.[17] Uočimo da su sve potencije neprekidne pa su stoga i zbrojevi potencija neprekidne fnkcije koje se nazivaju polinomima. Funkcija f koju smo uveli na početku ovog potpoglavlja je primjer polinoma pa je ona neprekidna funkcija i to na cijelom $\mathbb{R}$. Primjeri neprekidnih funkcija su i eksponencijalna i logaritamska funkcija, trigonometrijske funkcije, ali i mnoge racionalne funkcije, s time da kod njih treba paziti na područje njihove definicije (u nultočkama nazivnika one imaju singularitete). Uočimo da je kompozicija dvije neprekidne funkcije opet neprekidna funkcija. U ovoj skripti će nam se pojavljivati u pravilu funkcije koje su neprekidne i integrabilne.

Jedno od zanimljivijih svojstava integrala je da je integral po području integracije duljine nula zapravo i sam jednak nula. Drugim riječima za $a\in\mathbb{R}$ je

$$\int_a^a g(x)dx=0.$$

To u principu znači da iz područja integracije $[a,b]$ integrala $\int_a^b g(x)dx$ možemo izostaviti konačno ili čak prebrojivo beskonačno mnogo točaka i vrijednost integrala se neće promijeniti. S druge strane gledano, funkcija g koju integriramo može imati i prekide na području integracije (skokove za konačne vrijednosti) i opet ostati integrabilnom. Ta je činjenica relevantna za vjerojatnost, ali je nećemo koristiti u nastavku.

Neka je f neka realna funkcija koja je integrabilna. Kao što smo vidjeli vrijednost integrala $\int_a^b g(x)dx$ je broj. Stoga se taj integral zove i **određeni integral**. On ima neka vrlo dobra svojstva koja su sažeta u sljedećem teoremu.

Teorem 5.3.1. *Neka su f i g integrabilne funkcije na $[a,b]\subset\mathbb{R}$, $a\leq b$, i r realan broj. Tada vrijede sljedeća svojstva:*

1) $\int_a^b(f(x)+g(x))dx=\int_a^b f(x)dx+\int_a^b g(x)dx$,

2) $\int_a^b r\cdot f(x)dx=r\cdot\int_a^b f(x)dx$,

3) *ako je $f(x)\leq g(x)$, za sve $x\in[a,b]$, onda je*

$$\int_a^b f(x)dx\leq\int_a^b g(x)dx,$$

[16] Zbrojevi oblika s_n se zovu donje Darbouxove sume, a zbrojevi oblika S_n se zovu gornje Darbouxove sume.

[17] Derivabilna funkcija je nužno neprekidna pa je stoga i integrabilna.

4) ako je c realan broj takav da je $a < c < b$, onda vrijedi

$$\int_a^b f(x)dx = \int_a^c f(x)dx + \int_c^b f(x)dx.$$

Uočimo da iz svojstava 1) i 2) slijedi da je za p i r realne brojeve

$$\int_a^b (p \cdot f(x) + r \cdot g(x))dx = p \cdot \int_a^b f(x)dx + r \cdot \int_a^b g(x)dx.$$

To svojstvo se zove svojstvo **linearnosti** integrala. Svojstvo 3) se zove svojstvo **monotonosti** integrala.

Vratimo se sada na početni primjer s funkcijom $f(x) = 0.1x^3 - 0.5x^2 - 0.25x + 4$ i iskoristimo svojstvo linearnosti integrala da dobijemo

$$\int_1^6 (0,1x^3 - 0,5x^2 - 0,25x + 4)dx = 0,1\int_1^6 x^3dx - 0,5\int_1^6 x^2dx - 0,25\int_1^6 xdx + 4\int_1^6 dx. \tag{5.15}$$

Prema svemu rečenome, znamo da svi gore navedeni integrali postoje, ali još uvijek nije jasno kako ih izračunati. Naime, iako se neki integrali mogu izračunati preko definicije (određenog) integrala, taj je postupak dosta zahtjevan. Stoga se postavlja pitanje kako u ovom, ali i općenitom slučaju, računati vrijednosti određenih integrala. Odgovor na to pitanje daje osnovni teorem matematičke analize (eng. *Fundamental theorem of calculus*) koji dovodi u vezu integral i derivaciju. Imamo sljedeći teorem (Teorem 28 u [9]).

Teorem 5.3.2. *Neka je $I \subset \mathbb{R}$ otvoreni interval i $f : I \to \mathbb{R}$ neprekidna funkcija. Tada za svaki $[a, b] \subset I$, $a < b$, vrijedi*

$$\int_a^b f(x)dx = F(b) - F(a), \tag{5.16}$$

gdje je funkcija F antiderivacija od f, odnosno vrijedi

$$F'(x) = f(x),\ x \in I.$$

Funkcija F iz gornjeg teorema se naziv **primitivnom** funkcijom funkcije f. Uočimo da za proizvoljnu konstantu $C \in \mathbb{R}$ vrijedi

$$(F(x) + C)' = F(x)' = f(x),\ x \in I$$

jer je derivacija konstante jednaka nuli. Stoga zapravo možemo govoriti o skupu primitivnih funkcija funkcije f i taj skup označavamo s

$$\int f(x)dx$$

i nazivamo **neodređenim** integralom.

Formulu (5.16) nazivamo Leibniz-Newtonovom formulom i ona je osnovna formula kojom računamo vrijednosti određenih integrala. Za velik broj funkcija f su izračunate vrijednosti neodređenog integrala $\int f(x)dx$ i tabelirane u tako zvanim tablicama neodređenih integrala. Neke od najjednostavnijih funkcija za koje je to napravljeno su potencije. Naime, jer je za prirodne broj n (uključujući i nulu)

$$(x^n)' = nx^{n-1}$$

proizlazi da je

$$\int x^n dx = \frac{1}{n+1}x^{n+1} + C, \tag{5.17}$$

pri čemu ta formula vrijedi za sve cijele brojeve n, $n \neq -1$. Radi potpunosti prezentacije napomenimo da je

$$\int \frac{1}{x}dx = \ln(x),$$

gdje je s ln označen prirodni logaritam.

Sada smo napokon spremni za izračun površine ispod grafa funkcije f koju smo uveli na početku ovog potpoglavlja. Pri tome smo si olakšali izračun jer smo u formuli (5.15) vidjeli da se tražena vrijednost integrala $\int_1^6 f(x)dx$ može prikazati kao zbroj integrala potencija, a te određene integrale znamo izračunati. Njjednostavniji je integral $\int_1^6 dx$. Za njega prema (5.17) imamo

$$\int_1^6 dx = \int_1^6 x^0 dx = x\Big|_{x=1}^{x=6} = 6 - 1 = 5.$$

Uočimo da smo mogli samo napisati

$$\int_1^6 x^0 dx = 6 - 1,$$

jer je primitivna funkcija od $x^0 = 1$ jednaka $x + C$, ali je radi jasnoće uobičajeno u nizu jednakost prilikom rješavanja integrala napisati

$$x\Big|_{x=1}^{x=6}$$

da bi jasno indicirali da je x tražena primitivna funkcija koju računamo u granicama od 1 do 6. Sada na sličan način izračunamo i vrijednosti ostalih integrala. Imamo

$$\int_1^6 x dx = \frac{1}{2}x^2\Big|_{x=1}^{x=6} = \frac{36}{2} - \frac{1}{2} = \frac{35}{2},$$

$$\int_1^6 x^2 dx = \frac{1}{3}x^3\Big|_{x=1}^{x=6} = \frac{216}{3} - \frac{1}{3} = \frac{215}{3} \text{ i}$$

$$\int_1^6 x^3 dx = \frac{1}{4}x^4\Big|_{x=1}^{x=6} = \frac{1296}{4} - \frac{1}{4} = \frac{1295}{4}.$$

Dobivene vrijednosti uvrstimo u (5.15). Izračunamo

$$\begin{aligned}\int_1^6 f(x)dx &= 0,1\int_1^6 x^3 dx - 0,5\int_1^6 x^2 dx - 0,25\int_1^6 x dx + 4\int_1^6 dx \\ &= 0,1 \cdot \frac{1295}{4} - 0,5 \cdot \frac{215}{3} - 0,25 \cdot \frac{35}{2} + 4 \cdot 5 \\ &\approx 12.16667,\end{aligned}$$

što je tražena vrijednost integrala $\int_1^6 f(x)dx$, odnosno površine ispod grafa funkcije f na segmentu $[1, 6]$.

Uočimo da nam R može pomoći da brzo izračunamo vrijednost određenog integrala. Za to nam koristi funkcija `integrate()` kojoj je prvi argument funkcija koju je potrebno definirati. Konkretno u ovom slučaju imamo

```
> fx<-function(x) { 0.1*x^3 - 0.5*x^2 - 0.25*x + 4}
> integrate(fx, lower=1, upper=6)
```

```
12.16667 with absolute error < 1.4e-13
```

R koristi numeričku integraciju za izračun integrala pa u skladu s time prijavljuje preciznost s kojom je izračunao vrijednost određenog integrala. U R-u se mogu računati i simboličke vrijednosti integrala korištenjem paketa `Ryacas` ili `rSymPy`, ali ćemo dalje istraživanje te tematike prepustiti zainteresiranim čitateljima.

5.3.2 Računanje integrala

Određivanje vrijednosti integrala, bilo određenog ili neodređenog, općenito nije lagano. Velik dio kolegija je potreban da bi se malo detaljnije opisali načini računanja integrala. Stoga ovdje dajemo samo kratki pregled nekih osnovnih metoda.

Kao što smo već rekli, za velik broj funkcija f su izračunate vrijednosti neodređenog integrala $\int f(x)dx$ i tabelirane u tako zvanim tablicama neodređenih integrala. Niže navodimo nekoliko najčešće korištenih vrijednosti neodređenih integrala.[18] Ovdje to ne navodimo, ali se već za neke jednostavne integrale kao antiderivacije pojavljuju razne nestandardne funkcije poput sinusa i kosinusa hiperbolnog i njihove inverzne funcije.

$$\int dx = x + C$$
$$\int x^a dx = \frac{1}{a+1}x^{a+1} + C,\ a \in \mathbb{R},\ a \neq -1$$
$$\int e^x dx = e^x + C$$
$$\int a^x dx = \frac{a^x}{\ln a} + C\ a > 0,\ a \neq 1$$
$$\int \frac{dx}{x} = \ln|x| + C$$
$$\int \cos x dx = \sin x + C$$
$$\int \sin x dx = -\cos x + C$$
$$\int \frac{dx}{\sqrt{1-x^2}} = \arcsin x + C$$
$$\int \frac{dx}{1+x^2} = \arctan x + C$$

U prošlom odjeljku smo vidjeli kako se računaju integrali nekih potencija, odnosno polinoma. Uočimo da nam druga od navedenih formula govori o tome da se i općenite potencije (osim za vrijednost eksponenta jednaku -1) računaju na sličan način. Pogledajmo jednostavan primjer.

Primjer 5.3.3. Izračunajmo vrijednost određenog integrala

$$\int_1^2 \frac{dx}{\sqrt{x}}.$$

Da bi izračunali vrijednost tog integrala prvo uočimo kakvog je oblika integrand (funkcija koju integriramo). Vidimo da je on oblika x^a, gdje je $a = -1/2$. Prema tablici integrala

[18] Uobičajeno je tabelirati vrijednosti neodređenih integrala jer je njihova veza s određenim integralima dana kroz Leibniz-Newtonovu formulu. Također, vrijednosti određenih integrala ovise o području integracije.

znamo da je

$$\int x^{-1/2}dx = \frac{1}{-1/2+1}x^{-1/2+1} + C = 2x^{1/2} + C.$$

Prema Leibniz-Newtonovoj fomuli imamo

$$\int_1^2 \frac{dx}{\sqrt{x}} = 2x^{1/2}\Big|_{x=1}^{x=2} = 2(\sqrt{2} - \sqrt{1}) \approx 0,828.$$

To možemo provjeriti i u R-u.

```
> fp1<-function(x) { 1/sqrt(x)}
> integrate(fp1, lower=1, upper=2)

0.8284271 with absolute error < 9.2e-15
```

Za vježbu probajte riješiti sljedeće integrale (u zagradi su rješenja).

- $\int_0^1 (x^3 - 3x + 4)dx$ (Rj: 17/6)
- $\int_1^2 (x-4)/x^3 dx$ (Rj: -1)
- $\int_0^{\pi/6} (2\cos x - 5\sin x)dx$ (Rj: $-4 + 5\sqrt{3}/2$) □

Znajući da postoje tablice integrala mogli bi pomisliti da su one "svemoguće", odnosno da se postupak rješavanja, odnosno izračuna, nekih integrala svede na postupak traženja odgovarajućeg integrala u tablici neodređenih integrala i ponavljanja računa poput onoga u prošlom primjeru. Ipak, situacija u kojoj se nalazimo nije tako jednostavna. Primjerice, pretpostavimo da želimo izračunati vrijednost integrala

$$\int_0^1 e^{-2x}dx.$$

U osnovnim tablicama neodređenih integrala nećemo naći takav integral pa se postavlja pitanje što napraviti s njim. Taj određeni integral je "malo" promijenjen u odnosu na osnovi tabelirani integral $\int e^x dx$, ali i to je dovoljno da ne možemo direktno izračunati njegovu vrijednost. Naravno, cijela teorija integralnog računa bi bila začuđujuće nepotpuna kada ne bi mogli izračunati takve integrale, a "alat" kojim ih rješavamo je zasnovan na teoremu o zamjeni varijabli.

Teorem o zamjeni varijable u integralu (vidi Teorem 31 u [9]) nam kaže da za f neprekidnu funkciju na intervalu I i funkciju $g : J \to I$, gdje je J neki interval te $\alpha, \beta \in J$ vrijedi

$$\int_\alpha^\beta f(g(x))g'(x)dx = \int_{g(\alpha)}^{g(\beta)} f(x)dx. \tag{5.18}$$

Fukcija g je u pravilu monotona i diferencijabilna te ima inverznu funkciju g^{-1}. Formula (5.18) se u osnovi čita s desna na lijevo (želimo izračunati integral funkcije f) pa je možemo zapisati i kao

$$\int_a^b f(x)dx = \int_{g^{-1}(a)}^{g^{-1}(b)} f(g(x))g'(x)dx, \tag{5.19}$$

gdje je $[a, b] \subset I$. Za primjenu te formule treba paziti da je $g([\alpha, \beta]) \subset [a, b]$. Pogledajmo na jednom primjeru neodređenog integrala kako se koristi formula o zamjeni varijable, odnosno supstituciji varijable.

Primjer 5.3.4. [primjer 1, str. 278 u [9]] Pogledajmo integral

$$\int \frac{\ln x}{x} dx.$$

Integral izgleda dosta složeno i nije jasno kako bismo ga riješili bez uvođenja, odnosno zamjene varijable integracije. No, ako definiramo $g(x) = e^t$ i, uz malu zloupotrebu oznaka (to se može formalizirati), zapišemo $dx = g'(t)dt = e^t dt$ vidimo da se brojnik značajno pojednostavljuje, dok se uz dt javlja faktor e^t koji je jednak nazivniku razlomka koji mu prethodi. Prema tome, imamo

$$\begin{aligned} \int \frac{\ln x}{x} dx = & \qquad (x = e^t,\ dx = e^t dt) \\ = \int \frac{t}{e^t} e^t dt = \int t dt = \frac{t^2}{2} + C & \qquad (t = \ln x) \\ = \frac{(\ln x)^2}{2} + C. & \end{aligned}$$

Dakle, dobivamo da je

$$\int \frac{\ln x}{x} dx = \frac{(\ln x)^2}{2} + C,\ x > 0.$$

□

Primjenom formule o zamjeni varijable možemo riješiti i određeni integral s e^{-2x} koji smo ranije spomenuli.

Primjer 5.3.5. Izračunajmo vrijednost integrala $\int_0^1 e^{-2x} dx$. U skladu s gornjim napomenama uvedimo novu varijablu

$$t = -2x.$$

Onda je

$$dt = -2dx,$$

odnosno

$$dx = -\frac{1}{2} dt.$$

Još trebamo vidjeti što se događa s područjem integracije, odnosno granicama integracije. Za $x = 0$ je i $t = 0$, a za $x = 1$ je $t = -2$. stoga imamo

$$\int_0^1 e^{-2x} dx = \int_0^{-2} -\frac{1}{2} e^t dt = -\frac{1}{2} \int_0^{-2} e^t dt = -\frac{1}{2} e^t \Big|_{t=0}^{t=-2} = -\frac{1}{2}(e^{-2} - e^0) \approx 0,43233.$$

Dobiveni izračun možemo provjeriti i u R-u

```
> fp2<-function(x) { exp(-2*x)}
> integrate(fp2, lower=0, upper=1)

0.4323324 with absolute error < 4.8e-15
```

□

U gornjem primjeru smo dobili integral

$$-\frac{1}{2} \int_0^{-2} e^t dt$$

kojemu je gornja granica integrala veća od donje. Općenito za $a \leq b$ vrijedi da je

$$\int_b^a f(x)dx = -\int_a^b f(x)dx.$$

Stoga smo mogli pisati i

$$-\frac{1}{2}\int_0^{-2} e^t dt = -\frac{1}{2}\Big(-\int_{-2}^0 e^t dt\Big) = \frac{1}{2}\int_{-2}^0 e^t dt.$$

Dobili bismo isti rezultat.

Negativna vrijednost integrala se dobiva i u jednoj situaciji u kojoj je ne bi očekivali, iako je u skladu s definicijom određenog integrala. Pogledajmo sljedeći integral

$$\int_{-2}^2 x dx.$$

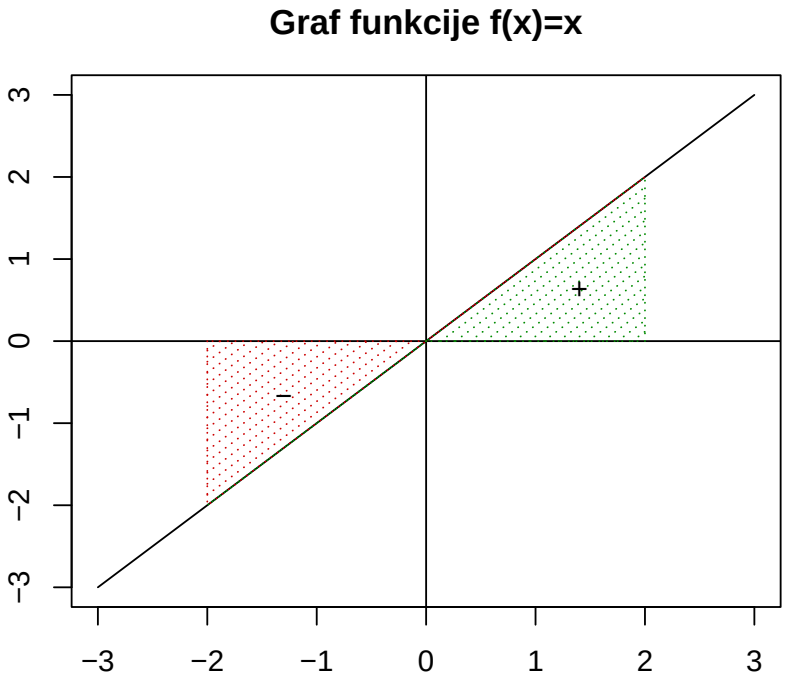
Vidimo da je riječ o jednostavnom integralu koji znamo izračunati. Imamo

$$\int_{-2}^2 x dx = \frac{x^2}{2}\Big|_{x=-2}^{x=2} = \frac{2^2}{2} - \frac{(-2)^2}{2} = \frac{4}{2} - \frac{4}{2} = 0.$$

Što se sada dogodilo? Dobivamo nulu iako je površina koju nalazimo između grafa funkcije i osi x strogo veća od nule (pogledajte donju sliku). Dapače, mi tu površinu znamo i izračunati jer se sastoji od dva pravokutna trokuta ćije su stranice duljine 2 pa je prema formuli za površinu trokuta ona (površina ta dva trokuta jednaka)

$$\frac{2 \cdot 2}{2} + \frac{2 \cdot 2}{2} = 4.$$

Stvar je u tome da je vrijednost određenog integrala jednaka površini ispod grafa funkkcije i iznad osi x. No, na $[-2, 0)$ je funkcija $f(x) = -x$ negativna pa je i dobivena "površina", računata određenim integralom, negativna. Ona je po apsolutnoj vrijednosti jednaka površini ispod krivulje na segmentu $[0, 2]$, ali se nalazi ispod osi x pa je po predznaku negativna.



Općenito, ako je f **neparna** funkcija, onda je

$$\int_{-a}^{a} f(x)dx = 0.$$

Funkcija $f(x) = x$ je neparna. S druge strane, ako je f **parna** funkcija, onda je

$$\int_{-a}^{a} f(x)dx = 2\int_{0}^{a} f(x)dx.$$

Tako je, na primjer,

$$\int_{-2}^{2} x^2dx = 2\int_{0}^{2} x^2dx = 2\frac{x^3}{3}\Big|_{x=0}^{x=2} = 2\frac{2^3}{3} = \frac{16}{3}.$$

Osim formule o zamjeni varijable integracije za izračun integrala često je korisna i formula **parcijalne integracije** prema kojoj za funkcije $u, v : I \to \mathbb{R}$, $a, b \in I$, vrijedi

$$\int_{a}^{b} u'(x)v(x)dx = (uv)\Big|_{a}^{b} - \int_{a}^{b} u(x)v'(x)dx. \tag{5.20}$$

Malo kasnije ćemo pokazati jednu primjenu formule parcijalne integracije (5.20).

Zadatak 5.3.6. *Dajemo nekoliko zadataka s rješenjima za vježbu. Potrebno je izračunati vrijednost sljedećih integrala.*

1) $\int_0^1 x\sqrt{1-x^2}dx$ *(Uputa:* $t = 1 - x^2$*; Rješenje:* $\frac{1}{3}$*)*

2) $\int_0^{\ln 2} \frac{e^x}{\sqrt{e^x+1}}dx$ *(Uputa:* $t = e^x + 1$*; Rješenje:* $2(\sqrt{3} - \sqrt{2})$*)*

3) $\int_0^1 xe^{-\frac{x^2}{2}}dx$ *(Uputa:* $t = -\frac{x^2}{2}$*; Rješenje:* $1 - e^{-\frac{1}{2}}$*)*

4) $\int \frac{x}{\sqrt{x+1}}dx$ *(Uputa:* $t = \sqrt{x+1}$*; Rješenje:* $\frac{2}{3}\sqrt{x+1}(x-1) + C$*)*

5.3.3 Nepravi integral

U vjerojatnosti se često pojavljuju integrali oblika

$$\int_{0}^{\infty} f(x)dx.$$

Iz do sada rečenoga nije jasno koje je značenje gornje granice takvog integrala jer smo do sada gledali integrale na intervalima koji su konačni podskupovi od $\mathbb{R}$. Takvi integrali se nazivaju **nepravima**, a definirani su kao

$$\int_{0}^{\infty} f(x)dx = \lim_{x\to\infty} \int_{0}^{x} f(x)dx.$$

Ta definicija nije samorazumljiva jer se postavlja pitanje integrabilnosti funkcije f kada $x \to \infty$, ali na ovom mjestu nećemo ulaziti u tu problematiku. Nepravi integrali se mogu promatrati i u nekim drugim situacijama poput one u kojoj funkcija f ima singularitete u nekim točkama. takva je, recimo funkcija $f(x) = 1/\sqrt{x}$ u nuli.

Pogledajmo neke primjere koji će nam biti zanimljivi u vjerojatnosti.

Primjer 5.3.7. Izračunajmo vrijednost nepravog integrala

$$\int_0^\infty e^{-x}dx.$$

Za početak, uzmimo neki strogo pozitivan $B > 0$ (načelno velik, ali za sada je dovoljno da je pozitivan). Prema prijašnjim primjerima znamo da integral

$$\int_0^B e^{-x}dx$$

možemo rješavati zamjenom varijable (supstitucijom) $t = -x$. Na taj način dobivamo

$$\int_0^B e^{-x}dx = -e^t\Big|_0^{-B} = 1 - e^{-B}.$$

Kako $e^{-B} \to 0$, za $B \to \infty$ imamo

$$\int_0^\infty e^{-x}dx = \lim_{B\to\infty}(1 - e^{-B}) = 1.$$

□

Primjer 5.3.8 (Gama-funkcija)**.** Za $\alpha \geq 1$ je dobro definiran nepravi integral

$$\Gamma(\alpha) = \int_0^\infty e^{-x}x^{\alpha-1}dx$$

koji se zove **gama-funkcija** (ovisi o α) ili Eulerov integral druge vrste. Formulom parcijalne integracije (5.20) može se pokazati da vrijedi

$$\Gamma(\alpha + 1) = \alpha\,\Gamma(\alpha).$$

Zaista, imamo

$$\int_0^t e^{-x}x^\alpha dx = -e^{-x}x^\alpha\Big|_{x=0}^{x=t} + \int_0^t e^{-x}\alpha x^{\alpha-1}dx.$$

Kako $e^{-t}t^\alpha \to 0$, za $t \to \infty$ dobivamo

$$\Gamma(\alpha + 1) = \lim_{t\to\infty}\alpha\int_0^t e^{-x}x^{\alpha-1}dx = \alpha\,\Gamma(\alpha).$$

U prošlom primjeru smo vidjeli da je za $\alpha = 1$ $\Gamma(1) = 1$. Stoga je za $\alpha = n \in \mathbb{N}$

$$\Gamma(n + 1) = n\Gamma(n) = n(n - 1)\Gamma(n - 1) = \ldots = n(n - 1)\cdot\ldots\cdot 2\,\Gamma(1) = n!$$

Stoga gama funkciju možemo smatrati proširenjem funkcije $(n - 1)!$ na $[1, \infty)$. □

Primjer 5.3.9. Za vjerojatnost je važno odrediti vrijednost nepravog integrala

$$N = \int_{-\infty}^\infty e^{-\frac{x^2}{2}}dx.$$

Jedan način da se izračuna vrijednost tog integrala je da se funkcija $e^{-x^2/2}$ razvije u Taylorov red pa se onda integrira član po član. U tom postupku treba paziti na konvergenciju redova, a to je tema koju ne obrađujemo u ovoj skripti. Drugi način je da se iskoristi jedan "trik" i vodi na izračun dvostrukog integrala. Dvostruke integrale

nećemo posebno obrađivati, ali napomenimo da se oni računaju po redoslijedu integracije pri čemu se mogu razdvojiti ako se u funkciji koju promatramo varijable mogu separirati. Ovdje ćemo prikazati taj drugi način izračuna integrala N na ilustrativnoj razini (dovoljno uvjerljivo, ali ne sa svim formalnim argumentima). Započnimo tako da pomnožimo N sa samim sobom. Tako dobivamo

$$N^2 = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} e^{-\frac{x^2+y^2}{2}} dxdy.$$

Sada uvedemo polarne koordinate (r, θ) (na tom mjestu nemamo sve detalje jer bi trebali malo detaljnije pogledati formulu o zamjeni varijabli za višestruke integrale) pa dobijemo

$$N^2 = \int_{0}^{2\pi}\int_{0}^{\infty} e^{-\frac{r^2}{2}} rdrd\theta.$$

Sada uvedemo supstituciju $t = r^2/2$ pa dobijemo

$$N^2 = \int_{0}^{2\pi}\int_{0}^{\infty} e^{-t} dtd\theta.$$

U primjeru (5.3.7) smo vidjeli da je $\int_0^\infty e^{-t}dt = 1$ pa je

$$N^2 = \int_{0}^{2\pi} 1 \; d\theta = 2\pi.$$

Dakle,

$$\int_{-\infty}^{\infty} e^{-x^2/2} dx = \sqrt{2\pi}. \tag{5.21}$$

Time smo izračunali traženu vrijednost integrala. □

5.4 Neprekidne slučajne varijable

Do sada smo malo detaljnije proučili svojstva i načine zadavanja diskretnih slučajnih varijabli. Sjetimo se, slučajne varijable kojima je skup mogućih vrijednosti najviše prebrojiv skup zovu se diskretne slučajne varijable. **Neprekidne slučajne varijable** su funkcije s nekog vjerojatnosnog prostora $(\Omega, \mathcal{F}, P)$ u skup $\mathbb{R}$ s time da im kodomena može biti i $[0, \infty)$ ili općenito neki interval (a, b), gdje su $a < b$ realni brojevi. **Definirajuće svojstvo** neprekidne slučajne varijable X je postojanje nenegativne funkcije $f = f_X : \mathbb{R} \to [0, \infty)$ takve da za funkciju distribucije F_X od X vrijedi

$$F_X(x) = \int_{-\infty}^{x} f_X(x)dx, \;\; x \in \mathbb{R}. \tag{5.22}$$

Funkcija f_X se zove **vjerojatnosna funkcija gustoće** (eng. *probability density function*). Uočimo da je

$$\int_{-\infty}^{\infty} f_X(x)dx = 1$$

što direktno slijedi iz činjenice da $F_X(x) \to 1$, za $x \to \infty$. Uočimo da svojstva funkcije distribucije F_X ne ovise o karakteru slučajne varijable (diskretna ili neprekidna) jer smo je zadali pomoću vjerojatnosti:

$$F_X(x) = P(X \leq x), \;\; x \in \mathbb{R}.$$

Stoga svojstva iz Propozicije 5.2.5 vrijede i u ovom slučaju.

Mi ćemo uglavnom gledati neprekidne slučajne varijable X za koje je funkcija gustoće f_X neprekidna. Tada vrijedi da je

$$F'(x) = f(x)$$

za sve $x \in \mathbb{R}$ (osim za moguće mali broj točaka x, ali to ćemo zanemariti u nastavku teksta). U osnovi to znači da uz zadanu funkciju gustoće možemo izračunati funkciju distribucije, ali i obratno: ako je zadana funkcija distribucije možemo izračunati funkciju goustoće.
Vidjeli smo da za funkciju gustoće nužno vrijedi

1) $f(x) \geq 0$, $x \in \mathbb{R}$ i

2) $\int_{-\infty}^{\infty} f(x)dx = 1$,

a može se pokazati da su ta dva svojstva i dovoljna da bi neka neprekidna realna funkcija bila vjerojatnosna funkcija gustoće (precizni iskaz je dan u Propoziciji 9.5 u [10]).

Uočimo razliku s diskretnim slučajnim varijablama: tamo smo imali gustoću (distribuciju) koja je imala pozitivne vrijednosti za konačno ili prebrojivo mnogo vrijednosti x, dok je (vjerojatnosna) funkcija gustoće za neprekidne slučajne varijable pozitivna za neprebrojivo mnogo vrijednosti x. Za proizvoljan skup (do na neke detalje koje ovdje ne obrađujemo) $B \subset \mathbb{R}$ vrijedi

$$P(X \in B) = \int_B f_X(x)dx.$$

Posebno, a za nas i najvažnije svojstvo je da, za $a, b \in \mathbb{R}$, $a \leq b$ vrijedi

$$P(a < X \leq b) = \int_a^b f_X(x)dx = F_X(b) - F_X(a). \tag{5.23}$$

Jasno, ako znamo izračunati vjerojatnost da će se vrijednosti slučajne varijable nalaziti u nekom intervalu, onda znamo izračunati i razne druge vjerojatnosti. Na primjer,

$$P(X > 0) = \int_0^{\infty} f_X(x)dx,$$

ali i

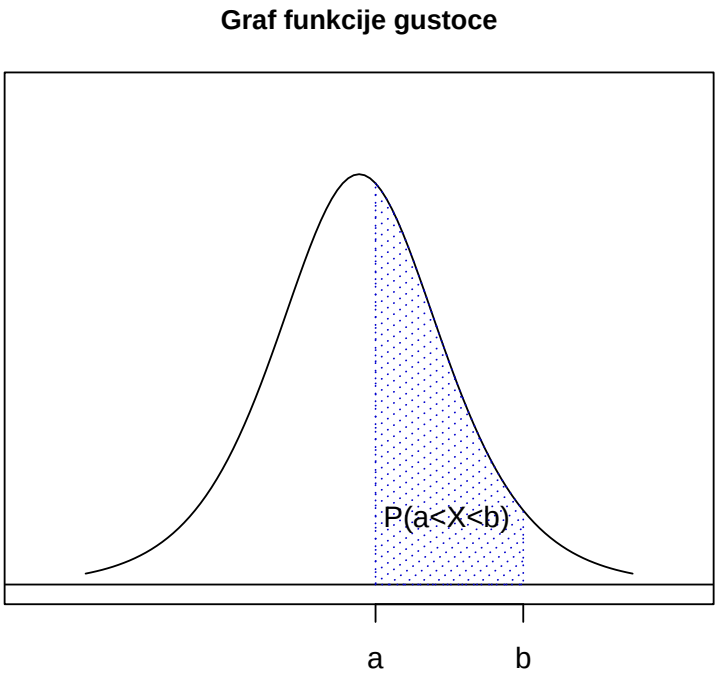
$$P(X \notin [a,b]) = \int_{-\infty}^{a} f_X(x)dx + \int_b^{\infty} f_X(x)dx, \ a, b \in \mathbb{R}, \ a \leq b,$$

jer je

$$\begin{aligned} \{X \notin [a,b]\} &= \{\omega \in \Omega \mid X(\omega) \notin [a,b]\} \\ &= \{\omega \in \Omega \mid X(\omega) \in (-\infty, a)\} \cup \{\omega \in \Omega \mid X(\omega) \in (b, \infty)\} \end{aligned}$$

pri čemu je zadnje navedena unija disjunktna. Uočimo da se svojstva integrala zapravo prenose na izračun vjerojatnosti jer smo vjerojatnosti neprekidnih slučajnih varijabli izrazili pomoću integrala funkcije gustoće.

Zaključujemo: ako znamo funkciju gustoće neprekidne slučajne varijable X ili njenu funkciju distribucije možemo odrediti praktički sve vjerojatnosti događaja vezanih uz X (analogna je situacija u diskretnom slučaju ako znamo gustoću slučajne varijable). Ilustracija vjerojatnosti $P(a < X < b)$ je dana na donjoj slici. Vidimo da je ta vjerojatnost zapravo jednaka površini ispod grafa funkcije gustoće f_X, kao što nam i govori formula (5.23). Naravno, površina ispod cijelog grafa funkcije gustoće je jednaka 1.



Velika razlika neprekidnih slučajnih varijabli u odnosu na diskretni slučaj je ta da za $a \in \mathbb{R}$ vrijedi

$$P(X = a) = \int_a^a f_X(x)dx = 0.$$

Dakle, vjerojatnost da je neprekidna slučajna varijabla jednaka nekom broju je jednaka nuli. Stoga je za neprekidne slučajne varijable

$$P(a < X \leq b) = P(a < X < b) = P(a \leq X < b) = P(a \leq X \leq b).$$

Napomena 5.4.1 (Gotovo sigurno)**.** Neka je X neprekidna slučajna varijabla te neka su $a_1, a_2, \ldots$ neki različiti realni brojevi. Tada je unija skupova za koje je slučajna varijabla X jednaka tim brojevima disjunktna pa je, zbog prebrojive aditivnosti vjerojatnosti,

$$P\Big(\bigcup_{i=1}^{\infty}\{X = a_i\}\Big) = \sum_{i=1}^{\infty} P(X = a_i) = 0.$$

Ako malo razmislimo shvatit ćemo da je moguće da se neke dvije neprekidne slučajne varijable razlikuju u prebrojivo mnogo svojih vrijednosti, a da su zapravo vjerojatnosno jednake. Kaže se da su **gotovo sigurno** jednake, odnosno jednake na skupu vjerojatnosti 1 (eng. *almost surely equal*).
Formulacija "gotovo sigurno" se javlja i u nekim drugim kontekstima. Tako, na primjer, za niz slučajnih varijabli X_i, $i \in \mathbb{N}$, koji je definiran na istom vjerojatnosnom prostoru kao neke slučajna varijabla X kažemo da **gotovo sigurno konvergira** prema X ako konvergira na skupu vjerojatnosti 1. Formalno,

$$X_n \to X,\ n \to \infty \text{ (g.s)},$$

ako postoji događaj $E \in \mathcal{F}$, $P(E) = 0$, takav da

$$\lim_{n\to\infty} X_n(\omega) = X(\omega),\ \omega \in E^c.$$

Naravno, zbog formule za vjerojatnost suprotnog događaja je $P(E^c) = 1 - P(E) = 1$. □

Pogledajmo jedan primjer koji ilustrira koncept funkcije gustoće. Malo kasnije ćemo vidjeti najvažnije primjere neprekidnih slučajnih varijabli u vjerojatnosti, kao i njihovih funkcija gustoće.

Primjer 5.4.2. Uzmimo realni broj c i definirajmo funkciju f kao

$$f(x) = \begin{cases} c(9-x^2), & x \in [-3,3] \\ 0, & \text{inače.} \end{cases}$$

Izračunajmo kolika mora biti vrijednost konstante c da bi to bila (vjerojatnosna) funkcija gustoće neke slučajne varijable X. To možemo napraviti tako da iskoristimo svojstvo

$$\int_{-\infty}^{\infty} f(x)dx = 1.$$

U ovom slučaju je funkcija f jednaka nuli van segmenta $[-3,3]$ pa je gornji uvjet zapravo

$$c\int_{-3}^{3}(9-x^2)dx = c(9x - \frac{x^3}{3})\Big|_{x=-3}^{x=3} = c(27+27-(9+9)) = 36c = 1.$$

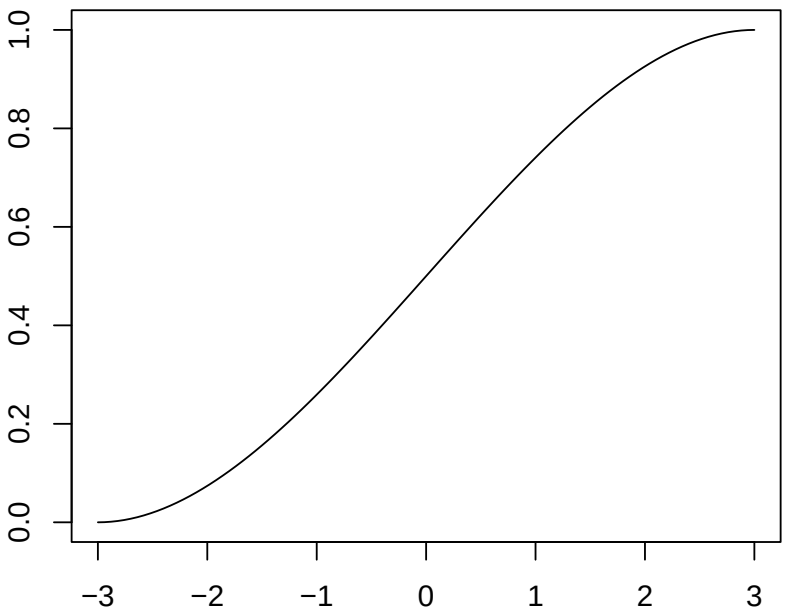
Stoga je $c = 1/36$. Izračunajmo još i $P(X \geq 0)$. Znamo da je ta vjerojatnost jednaka $P(X > 0)$. Prema prijašnjim razmatranjima imamo

$$P(X \geq 0) = \frac{1}{36}\int_{0}^{3}(9-x^2)dx = \frac{1}{36}(9x - \frac{x^3}{3})\Big|_{x=0}^{x=3} = \frac{1}{36}(27-9) = \frac{1}{2}.$$

Ovakav rezultat ne bi trebao biti iznenađenje ako se sjetimo iterpretacije integrala kao površine ispod grafa funkcije. Naime, integral funkcije f na cijeloj domeni $[-3,3]$ je jednak 1, a funkcija f je simetrična oko nule. Naravno, za neki općeniti broj $a \in [-3,3]$ je $P(X \geq a) = 1 - P(X \leq a) = 1 - F_X(a)$, gdje je F_X funkcija distribucije od X. U ovoj konkretnoj situaciji je

$$F_X(a) = \frac{1}{36}\int_{-3}^{a}(9-x^2)dx = \frac{1}{36}(9x - \frac{x^3}{3})\Big|_{x=-3}^{x=a} = \frac{1}{36}(9a+27-(\frac{a^3}{3}+9)).$$

Grafički funkcija distribucije F_X izgleda kao na donjoj slici.



Kao i prije, jer su to svojstva koja ne ovise o diskretnosti, znamo da je F_X rastuća, u $-\infty$ teži k nuli (ovdje je nula za $x \leq -3$), a u ∞ teži k jedan (ovdje je jedan za $x \geq 3$). Osnovna razlika funkcija distribucije diskretnih i neprekidnih alučajnih varijabli leži u činjenici da je za neprekidne slučajne varijable F_X neprekidna funkcija, dok kod diskretnih slučajnih varijabli F_X ima tipičan "stepenasti" izgled i u tom slučaju je F_X samo neprekidna zdesna. □

5.4.1 Neke poznatije razdiobe neprekidnih slučajnih varijabli

Postoji velik broj različitih neprekidnih slučajnih varijabli, kao i njihovih razdioba. Razdiobe neprekidnih slučajnih varijabli u pravilu se zadaju funkcijama gustoće.[19]

5.4.1.1 Normalna razdioba

Mnogi će se složiti da je najvažnija razdioba u vjerojatnosti normalna razdioba (distribucija). Ona se javlja u mnogim pojavama u prirodi, a i velik dio vjerojatnosti, poput centralnih graničnih teorema, bavi se temama usko vezanima uz normalnu razdiobu. U ovom odjeljku ćemo se početi upoznavati s normalnom razdiobom.

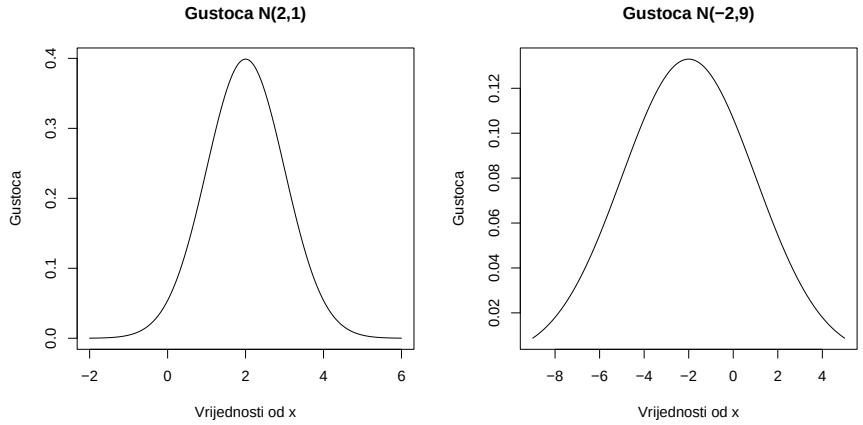
Definicija 5.4.3. Neprekidna slučajna varijabla X ima **normalnu razdiobu** s parametrima $\mu \in \mathbb{R}$ i $\sigma^2 > 0$ ako joj je funkcija gustoće

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \ x \in \mathbb{R}. \tag{5.24}$$

Oznaka za slučajnu varijablu iz normalne razdiobe (dakle, normalnu slučajnu varijablu) je

$$X \sim N(\mu, \sigma^2).$$

U Primjeru 5.3.9 smo vidjeli da je f_X funkcija gustoće. U sljedećem poglavlju ćemo vidjeti da su parametri μ i σ^2 očekivanje i varijanca slučajne varijable X. I bez znanja te činjenice možemo istaknuti da se maksimum funkcije gustoće normalne slučajne varijable postiže u točki $x = \mu$. Parametar σ^2 određuje koliko će funkcija gostoće f_X biti koncentrirana oko μ (za veće σ, f_X će biti manje koncentrirana, odnosno bit će raspršenija[20]). To se jasno može vidjeti na sljedećim grafovima.



Normalna razdioba, odnosno funkcije gustoće i distribucije normalne slučajne varijable, ima razna zanimljiva i dobra svojstva. Jedno od takvih je i činjenica da je linearna

[19] Ovo napominjemo jer bi alternativno neprekidne slučajne varijable mogli zadavati i funkcijama distribucije.

[20] Malo formalnije, bit će veća površina ispod krivulje van segmenta $[\mu - \epsilon, \mu + \epsilon]$, za $\epsilon > 0$.

transformacija normalne razdiobe opet normalna razdioba. Zaista, uzmimo $a, b \in \mathbb{R}$, $a \neq 0$ i definirajmo novu slučajnu varijablu Y kao

$$Y = aX + b.$$

Tada za $c, d \in \mathbb{R}$, $c < d$, imamo

$$P(c < Y < d) = P(c < aX + b < d) = P\Big(\frac{c-b}{a} < X < \frac{d-b}{a}\Big).$$

S obzirom da je $X \sim N(\mu, \sigma^2)$ prema općenitoj formuli (5.23) imamo

$$P\Big(\frac{c-b}{a} < X < \frac{d-b}{a}\Big) = \int_{\frac{c-b}{a}}^{\frac{d-b}{a}} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx.$$

U gornjem integralu uvedemo novu varijablu $t = a \cdot x + b$ pa je $dx = dt/a$, odnosno

$$P(c < Y < d) = \int_c^d \frac{1}{a\sigma\sqrt{2\pi}} e^{-\frac{(t-b-a\mu)^2}{2a^2\sigma^2}} dt. \tag{5.25}$$

Uočimo da relacija (5.25) vrijedi za sve $c, d \in \mathbb{R}$, $c < d$, pa najprije možemo pustiti $c \to -\infty$ da dobijemo[21]

$$F_Y(d) = \int_{-\infty}^d \frac{1}{a\sigma\sqrt{2\pi}} e^{-\frac{(t-b-a\mu)^2}{2a^2\sigma^2}} dt,$$

iz čega zaključujemo da je

$$Y \sim N(b + a\mu, a^2\sigma^2). \tag{5.26}$$

Dakle, Y je također normalno distribuirana slučajna varijabla. Vrlo važan poseban slučaj dobivamo kada uzmemo $a = 1/\sigma$ i $b = -\mu/\sigma$. U tom slučaju često koristimo i posebnu oznaku Z za Y, a prema zaključenome imamo

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1). \tag{5.27}$$

Uobičajeno je reći da slučajna varijabla Z ima **jediničnu normalnu razdiobu** ili **standardnu normalnu razdiobu** jer se postupak transformacije slučajne varijable X kao u (5.27) zove **standardizacija** slučajne varijable X. Slučajna varijabla Z se zove **jedinična** ili **standardna normalna** slučajna varijabla.

Kao što smo vidjeli, svaka se slučajna varijabla X iz normalne razdiobe može standardizirati na $Z \sim N(0, 1)$. Funkcija gustoće slučajne varijable Z ima posebnu oznaku φ pa je

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \ x \in \mathbb{R}.$$

Uočimo da je φ **parna** funkcija

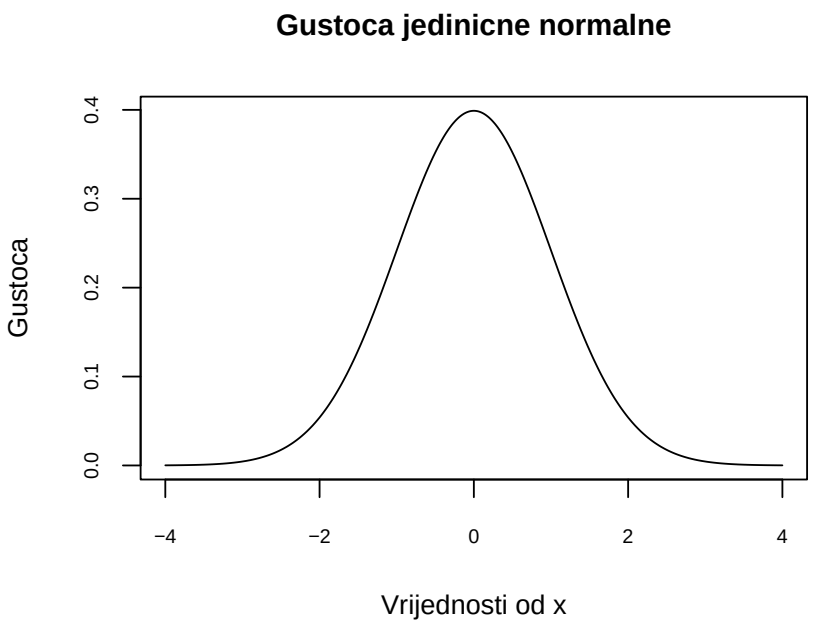
$$\varphi(-t) = \varphi(t), \ t \in \mathbb{R}$$

pa je Z **simetrična** slučajna varijabla, odnosno

$$Z, -Z \sim N(0, 1).$$

[21] Na ovom mjestu formalno trebamo iskoristiti neprekidnost vjerojatnosti na rastući niz događaja, a onda i definiciju nepravog integrala, ali nećemo na tome inzistirati.

Kada nacrtamo graf funkcije gustoće normalne distribucije (slučajne varijable) dobivamo čuveni "zvonasti" graf. Na donjoj slici je graf funkcije gustoće jedinične normalne razdiobe.

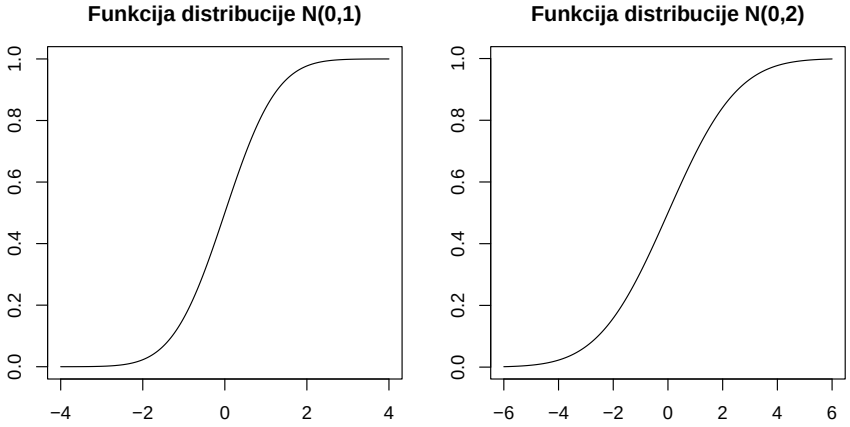


Za jedničnu normalnu slučajnu varijablu Z uobičajeno je koristiti oznaku Φ za njenu funkciju distribucije F_Z. Dakle,

$$\Phi(x) = \int_{-\infty}^{x} \varphi(t)dt = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-t^2/2}dt, \ x \in \mathbb{R}. \tag{5.28}$$

Na donjim grafovima su prikazane funkcije distribucije $Z \sim N(0,1)$ i $X \sim N(0,2)$. Naravno, za $Z \sim N(0,1)$ te $a, b \in \mathbb{R}$, $a < b$, vrijedi

$$P(a < Z < b) = \Phi(b) - \Phi(a) \ \Big(= \frac{1}{\sqrt{2\pi}} \int_{a}^{b} e^{-x^2/2}dx \Big). \tag{5.29}$$



Važnost funkcija φ i Φ za statistiku je iznimna. Vrijednosti od Φ nije lako izračunati, ali su one izračunate numeričkom integracijom i tabelirane. Naravno, vrijednosti od φ i Φ su dostupne u raznim programskim paketima. Tako u R-u imamo funkciju `pnorm()` koja računa vrijednost funkcije distribucije Φ. Tako je $\Phi(0)$

```
> pnorm(0, mean=0, sd=1)
```

```
[1] 0.5
```

dok je $\Phi(\infty)$, očekivano,

```
> pnorm(Inf, mean=0, sd=1)
```

```
[1] 1
```

Funkcija `dnorm()` daje vrijednosti funkcije φ. Na primjer, $\varphi(0)$ (maksimum funkcije φ na $\mathbb{R}$) je jednak

```
> dnorm(0, mean=0, sd=1)
```

```
[1] 0.3989423
```

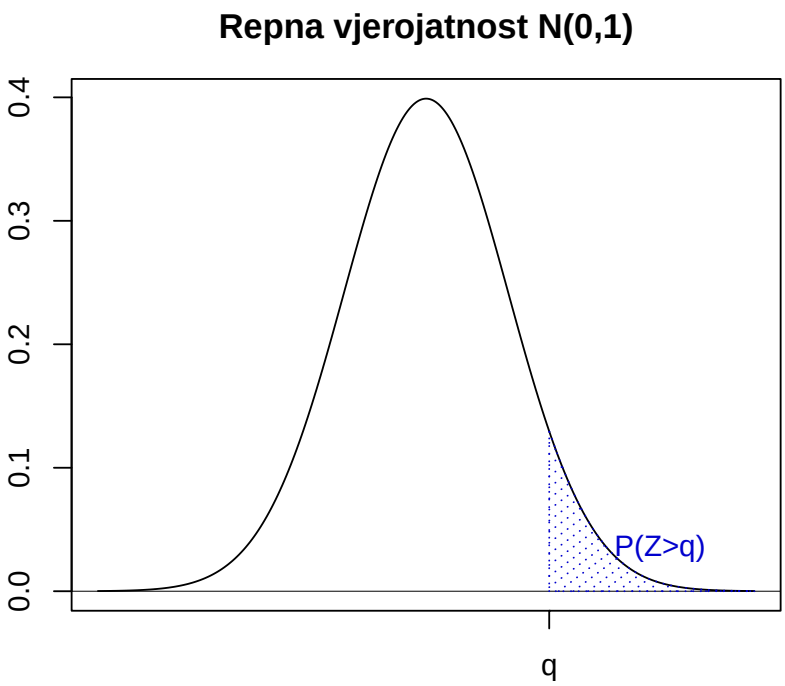
Jedna od vjerojatnosti koja se prirodno javlja uz jediničnu normalnu razdiobu je **repna vjerojatnost** (eng. *Tail probability*). U sljedećoj definiciji je definirana repna vjerojatnost.

Definicija 5.4.4. Neka je X slučajna varijabla na vjerojatnosnom prostoru $(\Omega, \mathcal{F}, P)$. Repna vjerojatnost se definira kao

$$P(X > x) \tag{5.30}$$

gdje je x neki realan broj.

Na sljedećoj slici je prikazana repna vjerojatnost jedinične normalne slučajne varijable Z za $x = q$ te je označena plavim točkicama.



Naravno, vjerojatnost $P(Z > q)$ je jednaka površini ispod grafa funkcije gustoće f_Z za vrijednosti argumenta x veće od q. Ona se može izračunati i pomoću funkcije distribucije Φ jedinične normalne razdiobe jer je

$$P(Z > q) = 1 - P(Z \leq q) = 1 - \Phi(q).$$

U vjerojatnosti se često želi izračunati broj q tako da vrijedi

$$P(Z > q) = p$$

za neki unaprijed određeni broj $p \in [0, 1]$. U R-u funkcija `qnorm()` računa vrijednost broja q s time da R računa broj q tako da vrijedi

$$\Phi(q) = P(Z \leq q) = 1 - p.$$

Uočimo da se q može interpretirati kao **kvantil** distribucije Φ (vratit ćemo se na tu temu kasnije). Pogledajmo jedan primjer.

Primjer 5.4.5. Izračunajmo broj q takav da je $P(Z > q) = 0,2$. Intuitivno, želimo naći broj q takav da je površina ispod grafa funkcije gustoće jedinične normalne razdiobe desno od tog broja jednaka $0,2$.
Na sljedećem grafu je plavom bojom označena površina ispod grafa funkcije gustoće jedinične normalne razdiobe koja je jednaka $0,2$. Nađimo broj q. S obzirom na R-ovu funkciju `qnorm` njega računamo ovako

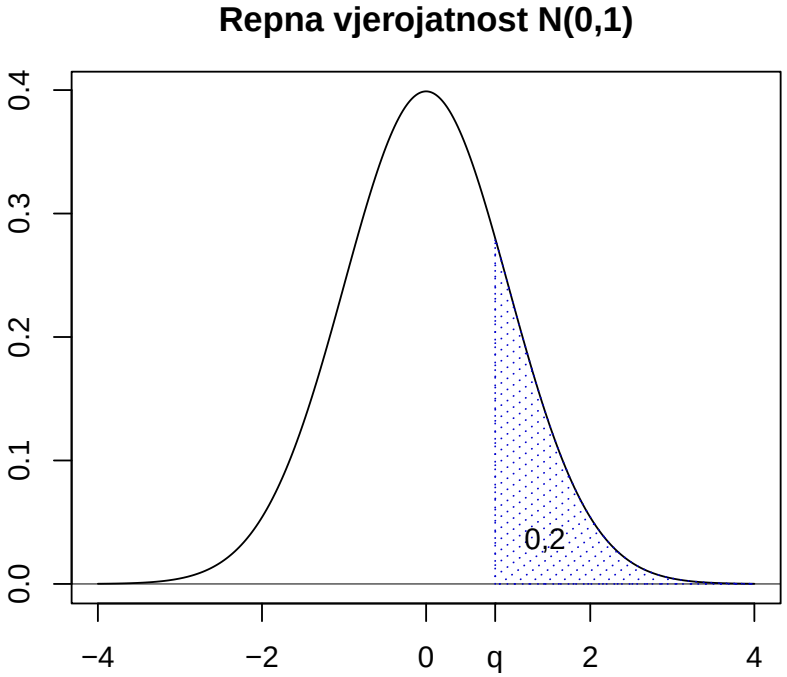
```
> qnorm(0.8, mean=0, sd=1)

[1] 0.8416212
```

Prema tome, $P(Z \leq 0,84162) = 0,8$, odnosno $P(Z > 0,84162) = 0,2$. To možemo i provjeriti jer je

```
> pnorm(0.8416212, 0, 1)

[1] 0.8
```



□

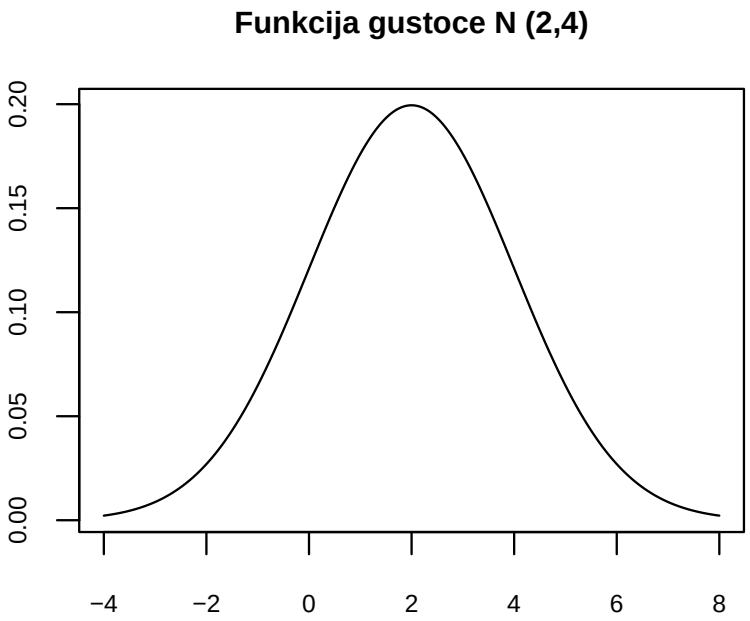
Kao što smo vidjeli, vjerojatnosti vezane uz jediničnu normalnu razdiobu možemo relativno jednostavno računati. Dosta je jasno da bi bilo prilično nepraktično tabelirati vrijednosti funkcije gustoće f_X ili funkcije distribucije F_X za različite parametre μ i σ^2

normalne slučajne varijable $X \sim N(\mu, \sigma^2)$. No to nije niti potrebno jer za $a, b \in \mathbb{R}$, $a < b$, imamo

$$P(a < X < b) = P\Big(\frac{a-\mu}{\sigma} < \frac{X-\mu}{\sigma} < \frac{b-\mu}{\sigma}\Big)$$
$$= P\Big(\frac{a-\mu}{\sigma} < Z < \frac{b-\mu}{\sigma}\Big) = \Phi\Big(\frac{b-\mu}{\sigma}\Big) - \Phi\Big(\frac{a-\mu}{\sigma}\Big), \tag{5.31}$$

gdje je $Z \sim N(0,1)$, a Φ, standardno, funkcija distribucije od Z. Dakle, vjerojatnosti vezane uz općenite slučajne varijable iz normalne razdiobe računamo pomoću jedinične normalne razdiobe. Pogledajmo jedan jednostavan primjer.

Primjer 5.4.6. Uzmimo normalnu slučajnu varijablu $X \sim N(2,4)$. Graf njene funkcije gustoće je prikazan na sljedećoj slici.



Izračunajmo vjerojatnost $P(X \leq 2)$. S obzirom da je u $x = \mu$ sredina funkcije gustoće (uvrstite $x = \mu$ u (5.24)), a fukcija gustoće je simetrična oko μ znamo da je $P(X \leq 2) = 1/2$. Ta će nam činjenica poslužiti za provjeru računa koji provodimo.
Prije svega se podsjetimo da je

$$P(X \leq 2) = \frac{1}{2\sqrt{2\pi}} \int_{-\infty}^{2} e^{-\frac{(x-2)^2}{2\cdot 4}} dx,$$

a također je

$$P(X \leq 2) = F_X(2)$$

gdje je F_X funkcija distribucije slučajne varijable X. Prema računu u (5.31) znamo da je (uz $a = -\infty$, $b = 2$)

$$P(X \leq 2) = \Phi\Big(\frac{2-2}{2}\Big) = \Phi(0)$$

jer $\Phi(x) \to 0$ za $x \to -\infty$. Mi znamo da je $\Phi(0) = 1/2$, ali iskoristimo R (odnosno neke tablice vrijednosti od Φ) da dobijemo

```
> pnorm(0,0,1)

[1] 0.5
```

Nadamo se da je jasno da smo za izračun odabrali vjerojatnost $P(X \leq 2)$ kako bi zapravo provjerili svoj izračun. Naravno, prema gore rečenome, je primjerice

$$P(0 \leq X \leq 4) = \Phi\Big(\frac{4-2}{2}\Big) - \Phi\Big(\frac{0-2}{2}\Big) = \Phi(1) - \Phi(-1),$$

odnosno

```
> pnorm(1,0,1)-pnorm(-1,0,1)

[1] 0.6826895
```

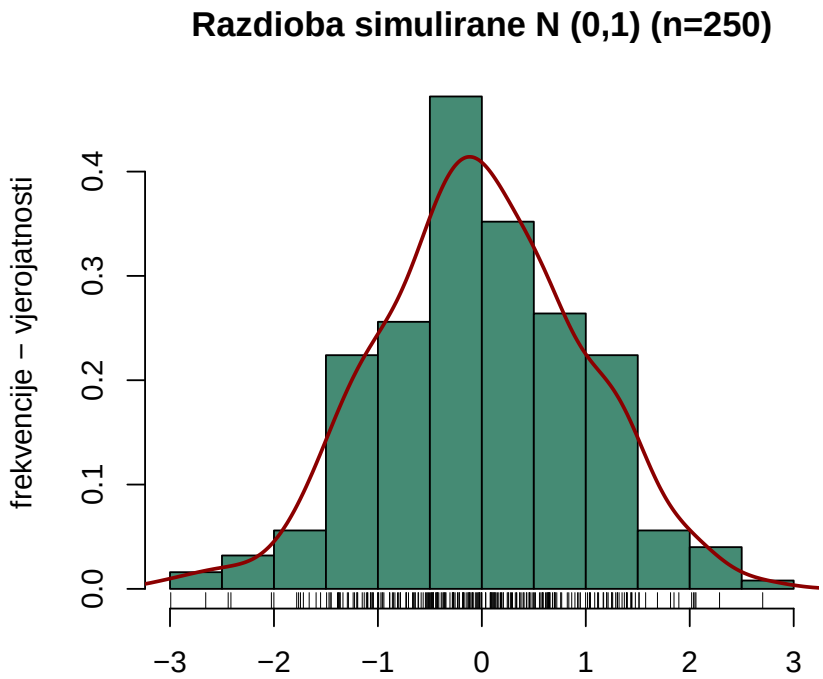
pa je $P(0 \leq X \leq 4) = 0,6826895$. □

Za kraj ovog pregleda normalne razdiobe, kojoj ćemo se višekratno vraćati u sljedećim poglavljima, pogledajmo još kako se koristi R-ova funkcija `rnorm()` koja generira uzorak iz normalne razdiobe.

Primjer 5.4.7. Argumenti funkcije `rnorm` su duljina niza brojeva koji želimo generirati, a sljedeća dva parametra su μ i σ. Generirajmo uzorak duljine 250 iz $N(0,1)$.

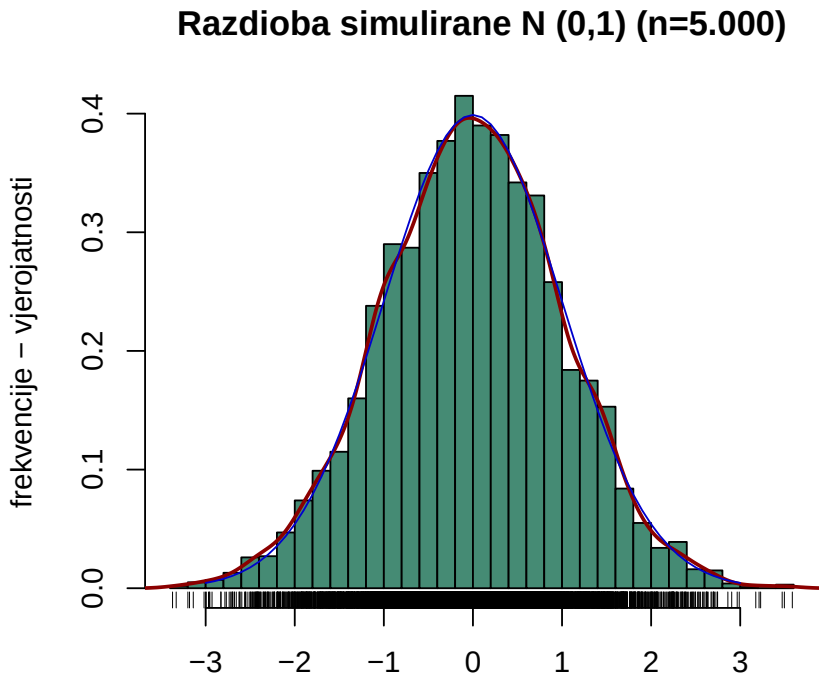
```
> set.seed(42)
> x<-rnorm(250,0,1)
```

Sada se možemo prije svega zapitati kako grafički predočiti simulirane vrijednosti koje možemo smatrati realizacijama slučajne varijable iz razdiobe $N(0,1)$. Ukoliko koristimo običnu funkciju `plot` prikazat ćemo dobivene brojeve, ali u poretku nastajanja, a to nije naročito vrijedna informacija.
S druge strane, slutimo da će se dobiveni brojevi grupirati oko nule (ne u potpunosti, naravno) pa bi htjeli iskoristiti neki prikaz koji predstavlja podatke na agregiran način. Stoga se histogram nameće kao logičan odabir. Na donjoj slici je prikazan histogram relativnih frekvencija simuliranih podataka koje smo spremili u vektor `x`.



Na os x smo dodali jednodimenzionalni graf koji prikazuje simulirane podatke, a u naravi njihovu gustoću (u uobičajenom, ne-vjerojatnosnom smislu). Sjetimo se, histogram prikazuje visinom stupića broj podataka u svakom od razreda u koje je svrstao, u ovom

slučaju simulirane, podatke. Crvena linija prikazuje aproksimaciju dobivenog histograma neprekidnom funkcijom. Izgleda poznato? Ponovimo postupak za $n = 5.000$ podataka.



Vidimo da i crvena linija i histogram podataka sve više izgledaju kao da su iz jedinične normalne razdiobe (što ne čudi jer smo tako simulirali podatke). Radi usporedbe smo dodali i plavu liniju koja crta "pravu" funkciju gustoće jedinične normalne razdiobe. Vidimo da su plava i crvena linija skoro nerazlučive. □

Napomena 5.4.8 (Od histograma do gustoće)**.** Prethodni primjer nas može navesti na razmišljanje o vezi histograma i funkcije gustoće. Naime, znamo da je zbroj površina stupića koji čine histogram relativnih frekvencija jednak 1. Ukoliko imamo neki slučajni eksperiment čije ishode mjerimo i izrađujemo od njih histogram, možemo očekivati da će, za velik broj ponavljanja mjerenja, relativna frekvencija pojedinog razreda (intervala u kojem su grupirani podaci) biti solidna aproksimacija vjerojatnosti da će rezultat mjerenja biti u tom razredu. Ukoliko mjerenja opisujemo slučajnom varijablom X to znači da bi se teorijska vjerojatnost da će se slučajna varijabla X nalaziti u nekom od razreda histograma mogla procijeniti relativnom frekvencijom realizacija slučajne varijable X (mjerenjem dobivamo realizacije).
Kako povećavamo broj ponavljanja promatranog slučajnog eksperimenta možemo očekivati da ćemo imati velik broj podataka u sve manjim i manjim intervalima, a rekli smo da bi ti podaci (relativne frekvencije) mogli biti dobra aproksimacija za vjerojatnosti da će se vrijednosti slučajne varijable X nalaziti u tim malim intervalima. No, sjetimo se definicije određenog integrala kao limesa (može biti tehnički supremum ili infimum nekih suma, ali zanemarimo to sada) zbroja površina malih pravokutnika pa shvatimo da bi moglo biti vrlo prirodno vjerojatnosti vezane uz slučajne varijable opisivati integralima nekih funkcija za koje je površina ispod njihovog grafa jednaka 1. No, tako smo upravo i definirali općenitu funkciju gustoće neprekidne slučajne varijable.
Uočimo da nije čak niti važno da li za sve podatke, odnosno sve kvantitativne karakteristike koje mjerimo slučajnim varijablama, možemo provesti gore opisani postupak sve dok postoje neke važne za koje možemo. Ideja je i dalje dobra i vrijedna i vodi nas na opis razdiobe slučajnih varijabli pomoću vjerojatnosnih funkcija gustoće. Instruktivno je za uočiti da se histogram ne mora savršeno podudarati s teorijskom funkcijom gustoće. Pitanje je koliko se razlikuju podaci i teorijsko predviđanje, no to je već statistička tema.

□

5.4.1.2 Eksponencijalna razdioba

Sljedeća neprekidna slučajna varijabla s kojom ćemo se upoznati je eksponencijalna slučajna varijabla. Eksponencijalnom slučajnom varijablom se često modelira vrijeme čekanja do nekog događaja. Primjeri su vrijeme čekanja do dolaska novog kupca u neku prodavaonicu, vrijeme čekanja do nove posjete nekoj mrežnoj stranici ili vrijeme čekanja do sljedećeg potresa. Imamo sljedeću definiciju.

Definicija 5.4.9. Neprekidna slučajna varijabla X ima **eksponencijalnu razdiobu** s parametrom λ, $\lambda > 0$, ako joj je funkcija gustoće

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0. \end{cases} \tag{5.32}$$

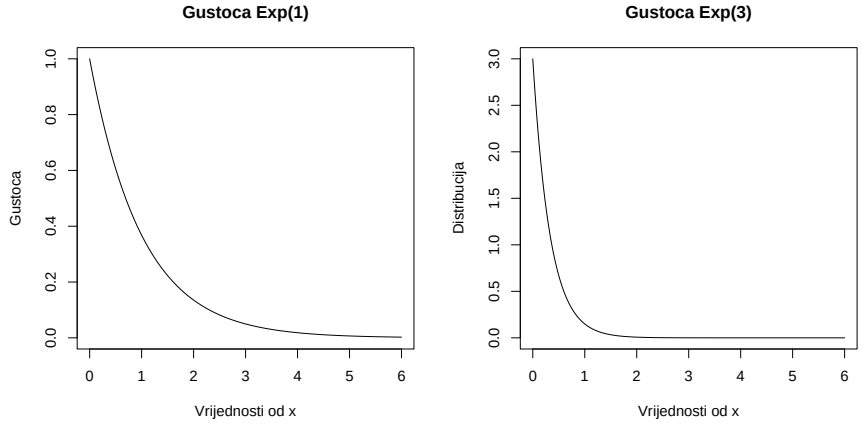
Oznaka za slučajnu varijablu iz eksponencijalne razdiobe (dakle, eksponencijalnu slučajnu varijablu) s parametrom λ je

$$X \sim Exp(\lambda).$$

Vidimo da eksponencijalna slučajna varijabla ima samo jedan parametar λ. Ako eksponencijalnu slučajnu varijablu intepretiramo kao vrijeme čekanja do nekog događaja, onda je λ broj tih događaja koji će se dogoditi u jedinici vremena. Njena se funkcija distribucije lagano izračuna. Naime, za $x \leq 0$ je $F_X(x) = 0$, a za $x > 0$ je

$$F_X(x) = P(X \leq x) = \int_0^x \lambda e^{-\lambda t} dt = -\int_0^{-\lambda x} e^u du = -e^u \Big|_{u=0}^{u=-\lambda x} = 1 - e^{-\lambda x}. \tag{5.33}$$

Uočite da smo u gornjoj integraciji napravili susptituciju $u = -\lambda x$. Na sljedećim slikama pokazujemo grafove funkcije gustoće eksponencijalne slučajne varijable za različite vrijednosti parametra λ. Uočimo da se u R-u funkcijama `dexp()` i `pexp()` mogu računati vrijednosti funkcije gustoće i funkcije distribucije slučajne varijable iz eksponencijalne razdiobe.



Ukoliko je X slučajna varijabla iz eksponencijalne razdiobe te je $\lambda = 1$, onda se kaže da je razdioba od X **jedinična eksponencijalna** razdioba. Lagano se vidi da je

$$Y = \frac{X}{\lambda} \sim Exp(\lambda)$$

jer je

$$F_Y(x) = P\Big(\frac{X}{\lambda} \leq x\Big) = P(X \leq \lambda x) = 1 - e^{-\lambda x},\ x > 0.$$

pri čemu smo u zadnjoj jednakost primijenili relaciju (5.33) na argument λx. Dakle, svaka se eksponencijalna slučajna varijabla s parametrom λ jednostavnom transformacijom može dobiti iz jedinične eksponencijalne slučajne varijable.

Eksponencijalno distribuirana slučajna varijabla X nema memoriju. Sjetimo se da je to svojstvo imala i slučajna varijabla s geometrijskom distribucijiom pa eksponencijalnu razdiobu možemo smatrati vjerojatnosnim analogonom geometrijske razdiobe (diskretne) u neprekidnom slučaju. Formalno, imamo sljedeće svojstvo: za $s, t > 0$ vrijedi

$$P(X > s + t \mid X > t) = P(X > s). \tag{5.34}$$

U osnovi to znači da "čekanje do novog uspjeha" (po analogiji s geometrijskom razdiobom) ne ovisi o vremenu koje se provelo čekajući. Gornje svojstvo se lagano provjeri jer, prema definiciji uvjetne vjerojatnosti, imamo

$$\begin{aligned} P(X > s + t \mid X > t) &= \frac{P(X > s + t, X > t)}{P(X > t)} = \frac{P(X > s + t)}{P(X > t)} \\ &= \frac{1 - F_X(s + t)}{1 - F_X(t)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda(t)}} = e^{-\lambda s}. \end{aligned}$$

Zanimljivo je za uočiti da ukoliko neprekidna pozitivna slučajna varijabla ima svojstvo nedostatka memorije, onda je ona eksponencijalno distribuirana (Teorem 5.3.3 u [3]). Pogledajmo jedan primjer računa s eksponencijalnom slučajnom varijablom.

Primjer 5.4.10. Pretpostavimo da imamo auto te da je vrijeme trajanja zupčastog remena na motoru (vrijeme do njegovog puknuća) eksponencijalno distribuirano pri čemu je prosječno vrijeme trajanja zupčastog remena 4 godine. Pretpostavimo da idete na neki dalek put na kojem ćete ostati godinu dana. Pitate se da li je dobro prije toga zamijeniti remen, a to ćete procijeniti tako da izračunate vjerojatnost da remen neće puknuti dok ste na putu.
Neka je X slučajna varijabla koja mjeri vrijeme do puknuća zupčastog remena. Prije navedeni uvjeti kažu da je $X \sim Exp(\lambda)$. Na prvi pogled nam se čini da nedostaje informacija o tome koliko je vremena prošlo od zadnje primjene zupčastog remena. No, kako je vrijeme trajanja zupčastog remena eksponencijalno distribuirano to neće biti važno zbog svojstva nedostatka memorije (5.34).
Za početak želimo utvrditi o kojoj se eksponencijalnoj slučajnoj varijabli, odnosno koliki je λ. Za eksponencijalnu slučajnu varijablu s parametrom λ je očekivano vrijeme trajanja do događaja čije pojavljivanje ona mjeri jednako $1/\lambda$.[22] Prema uvjetima zadatke ispada da je

$$\frac{1}{\lambda} = 4, \quad \text{odnosno} \quad \lambda = \frac{1}{4}.$$

Dakle, $X \sim Exp(1/4)$. Ako s $t > 0$ označimo vrijeme koje je prošlo od zadnje zamjene zupčastog remena, onda zapravo želimo izračunati vjerojatnost

$$P(X > 1 + t \mid X > t).$$

No, zbog (5.34) je ta vjerojatnost jednaka

$$P(X > 1) = 1 - F_X(1) = 1 - (1 - e^{-\frac{1}{4}}) = e^{-\frac{1}{4}} \approx 0,78.$$

Vidimo da je vjerojatnost da će remen ostati čitav u sljedećoj godini dana dosta velika. □

[22] To je zapravo očekivanje slučajne varijable X, kao što ćemo vidjeti u sljedećem poglavlju.

5.4.1.3 Uniformna razdioba

Sljedeća neprekidna slučajna varijabla s kojom ćemo se upoznati je uniformna slučajna varijabla. Njena je funkcija gustoće vrlo jednostavna, ali joj je značaj u vjerojatnosti velik jer se može smatrati univerzalnom neprekidnom slučajnom varijablom: mnoge druge razdiobe mogu se prikazati pomoću uniformne. Imamo sljedeću definiciju.

Definicija 5.4.11. Neprekidna slučajna varijabla U ima **uniformnu razdiobu** na intervalu (a,b), $a,b\in\mathbb{R}$, $a<b$, ako joj je funkcija gustoće

$$f_U(x)=\begin{cases}\frac{1}{b-a}, & x\in(a,b)\\ 0, & \text{inače.}\end{cases} \tag{5.35}$$

Oznaka za slučajnu varijablu iz uniformne razdiobe (dakle, uniformnu slučajnu varijablu) na intervalu (a,b) je

$$U\sim U(a,b).$$

Lagano provjerimo da je f_U funkcija gustoće: nenegativna je, a integral joj je jednak 1

$$\int_{-\infty}^{\infty}\frac{1}{b-a}I_{(a,b)}dx=\frac{1}{b-a}\int_a^b dx=\frac{1}{b-a}x\Big|_{x=a}^{x=b}=\frac{b-a}{b-a}=1.$$

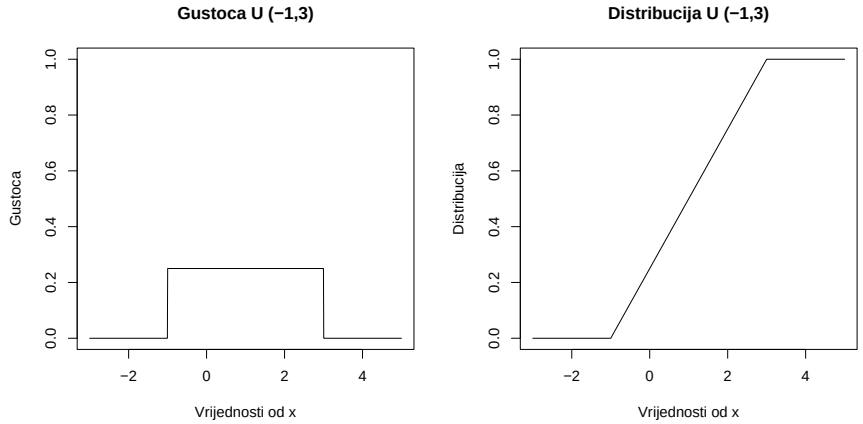
S $I_{(a,b)}$ smo označili indikator intervala (a,b). S indikatorom skupa smo se već susreli u (5.8) pri čemu je tamo indikator bio definiran na Ω, a ovdje je definiran na $\mathbb{R}$. Definicija je analogna prijašnjoj:

$$I_{(a,b)}(x)=\begin{cases}1, & x\in(a,b)\\ 0, & \text{inače.}\end{cases} \tag{5.36}$$

S obzirom da je uniformna slučajna varijabla primjer neprekidne slučajne varijable i za nju vrijedi važna općenita formula (5.23). Primjenom te formule lagano izračunamo funkciju distribucije od $U(a,b)$. Dobijemo (provjerite za vježbu)

$$F_U(x)=\begin{cases}0, & x\le a\\ \frac{x-a}{b-a}, & x\in(a,b)\\ 1, & x\ge b.\end{cases} \tag{5.37}$$

Na donjim slikama su prikazani grafovi funkcije gustoće i funkcije distribucije slučajne varijable iz razdiobe $U(-1,3)$.



Uočite da je funkcija dsitribucije slučajne varijable U iz uniformne razdiobe linearna. Uz formulu (5.23) to zapravo znači da je vjerojatnosti da je U u nekom intervalu proporcionalna duljini tog intervala za intervale koji se nalaze unutar (a,b). Pogledajmo jedan primjer računanja vjerojatnosti uniformne slučajne varijable.

Primjer 5.4.12. Uzimo $U \sim U(-1,3)$. Kako je $a=-1$ i $b=3$ vidimo da je $b-a=4$ pa je prema (5.35) funkcija gustoće od U

$$f_U(x) = \begin{cases} \frac{1}{4}, & x \in (-1,3) \\ 0, & \text{inače.} \end{cases} \tag{5.38}$$

Izračunajmo sada vjerojatnosti $P(U \in (-1,0))$ i $P(U \in (-1,2))$. Imamo

$$P(U \in (-1,0)) = \int_{-1}^{0} \frac{1}{4} du = \frac{1}{4} u \Big|_{u=-1}^{u=0} = \frac{1}{4}(0-(-1)) = \frac{1}{4}$$

i

$$P(U \in (-1,2)) = \int_{-1}^{2} \frac{1}{4} du = \frac{1}{4} u \Big|_{u=-1}^{u=2} = \frac{1}{4}(2-(-1)) = \frac{3}{4}.$$

Uočimo da je $P(U \in (-1,2)) = 3P(U \in (-1,0))$ što odgovara činjenici da je interval $(-1,2)$ tri puta dulji od intervala $(-1,3)$. □

Ukoliko u Definiciji 5.4.11 uzmemo $a=0$, a $b=1$ dobivamo **jediničnu** uniformnu slučajnu varijablu U, odnosno jediničnu uniformnu razdiobu. Jasno, tada je njena funkcija gustoće dana s

$$f_U(x) = \begin{cases} 1, & x \in (0,1) \\ 0, & \text{inače,} \end{cases} \tag{5.39}$$

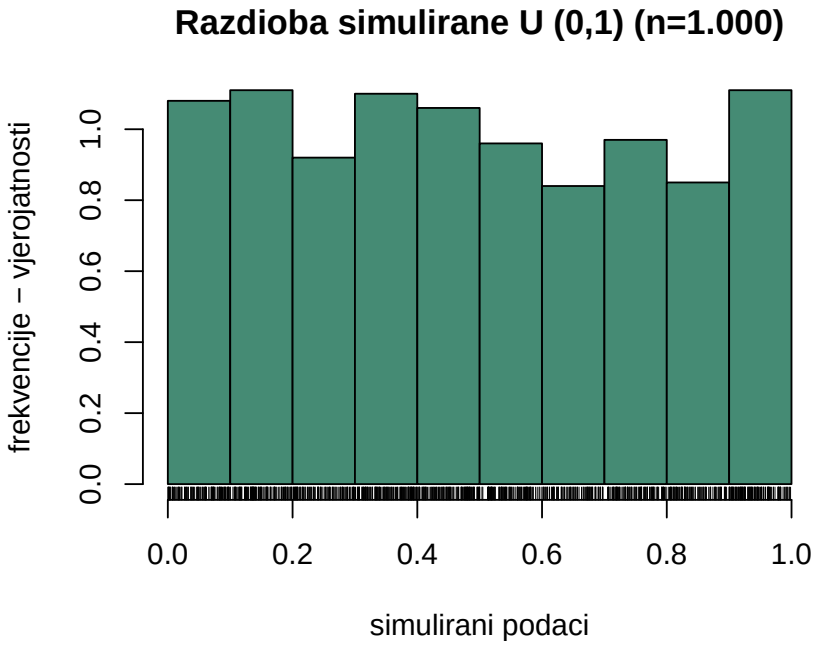
a funkcija distribucije

$$F_U(x) = \begin{cases} 0, & x \leq 0 \\ x, & x \in (0,1) \\ 1, & x \geq b. \end{cases} \tag{5.40}$$

Uočimo nekoliko stvari vezanih uz jediničnu uniformnu razdiobu. Prije svega treba istaknuti da su generatori slučajnih brojeva u raznim programskim paketima zapravo iz jedinične uniformne razdiobe $U(0,1)$, odnosno oni su realizacije slučajne varijable iz te razdiobe. Konkretno, u R-u se (pseudo-)slučajni brojevi dobivaju korištenjem funkcije `runif()`. Pogledajmo primjer.

Primjer 5.4.13. Generirat ćemo 1.000 slučajnih brojeva korištenjem funkcije `runif` te ćemo nacrtati histogram dobivenih brojeva. Argumenti funkcije `runif` su, redom, veličina generiranog uzorka, donja granica intervala a i gornja granica intervala b. Ukoliko izostavimo donju i gornju granicu intervala R će uzeti $a=0$ i $b=1$. To je najčešći slučaj generiranja slučajnih brojeva pa je to i uzeto kao osnovna (deafaultna) opcija. Isto smo napravili i mi na donjem histogramu.
Uočite da smo na graf (uz os x) dodali i jednodimenzionalni graf korištenjem funkcije `rug`. On nam pokazuje razmještaj podataka koje prikazujemo. S njime smo se višekratno susreli u poglavlju o Opisnim statistikama.

```
> set.seed(42)
> x<-runif(1000)
> par(mar=c(5,4,3,2))
> hunif<-hist(x, main="Razdioba simulirane U (0,1) (n=1.000)",
+             probability= TRUE, xlab="simulirani podaci",
+             cex=0.8, ylab="frekvencije - vjerojatnosti",
+             col = "aquamarine4")
> rug(x, side=1)
```



Kao što smo istaknuli u Napomeni 5.4.8, histogram simuliranih podataka će aproksimirati gustoću jedinične uniformne distribucije koja je zapravo jednaka 1 na intervalu $(0,1)$. Uočimo da razdioba dobivenih brojeva nije savršeno uniformna, što je u velikoj mjeri očekivano, ali toga treba biti svjestan prilikom izvođenja simulacija na računalu. Naravno, većim brojem simulacija bi dobili bolju procjenu, ali i taj proces ima svoje granice (ograničenja). □

Uzmimo jediničnu uniformnu slučajnu varijablu $U \sim U(0,1)$. Definirajmo slučajnu varijablu V

$$V = a + (b-a) \cdot U,$$

gdje su a i b realni brojevi, $a < b$. Izračunajmo funkciju distribucije slučajne varijable V. Za $x \in (a,b)$ imamo

$$F_V(x) = P(V \leq x) = P(a + (b-a)U \leq x) =)(U \leq (x-a)/(b-a)) = \frac{x-a}{b-a}$$

pri čemu smo u zadnjoj jednakost iskoristili (5.40). Vidimo da je funkcija distribucije od V ista kao funkcija distribucije u (5.37) pa je $V \sim U(a,b)$. Dakle, svaka se uniformna slučajna varijabla može dobiti (izraziti) pomoću jedinične uniformne slučajne varijable. No, vrijedi i puno više.

Neka je X neprekidna slučana varijabla s funkcijom distribucije F_X. Pretpostavimo da funkcija distribucije F_X ima inverz[23], odnosno da postoji funkcija $F_X^{-1} : (0,1) \to \mathbb{R}$ takva da vrijedi.

$$F_X^{-1}(F_X(x)) = x, \ x \in \mathbb{R} \quad \text{i} \quad F_X(F_X^{-1}(y)) = y, \ y \in (0,1).$$

Definirajmo novu slučajnu varijablu $Y = F_X(X) : \Omega \to [0,1]$. Izračunajmo njenu funkciju distribucije. Imamo

$$P(Y \leq y) = 0 \ \text{ za } \ y \leq 0$$

i

$$P(Y \leq y) = 1 \ \text{ za } \ y \geq 1.$$

[23] Ako je F_X strogo rastuća i neprekidna imat će inverznu funkciju.

Prema definiciji funkcije distribucije F_Y, odnosno F_X, vrijedi

$$P(Y \leq y) = P(F_X(X) \leq y) = P(X \leq F_X^{-1}(y)) = F_X(F_X^{-1}(y)) = y, \quad \text{za} \quad y \in (0,1).$$

Uočimo da je F_Y zapravo jednaka funkciji distribucije jedinične uniformne slučajne varijable pa zaključujemo da je

$$Y = F_X(X) \sim U(0,1). \tag{5.41}$$

Dakle, za proizvoljnu slučajnu varijablu X i njenu funkciju distribucije F_X, uz uvjet invertibilnosti od F_X, vrijedi da je kompozicija F_X i X jedinična uniformna slučajna varijabla.

Uzmimo sada funkciju distribucije F koja je invertibilna i jediničnu uniformnu slučajnu varijablu U. Definirajmo slučajnu varijablu $X = F^{-1}(U)$. Tada je za $x \in \mathbb{R}$

$$F_X(x) = P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F_U(F(x)) = F(x).$$

Dakle, ako uzmemo funkciju distribucije F i definiramo $X = F^{-1}(U)$, onda slučajna varijabla X ima funkciju distribucije F. Što nam to govori? Recimo da imamo neku slučajnu varijablu X s razdiobom F_X koja je invertibilna. Upravo smo rekli da slučajna varijabla $F_X^{-1}(U)$ ima razdiobu F_X. Ako to spojimo s činjenicom da su slučajni brojevi u raznim programima zapravo iz uniformne razdiobe $U(0,1)$, onda zaključujemo da velik broj slučajnih varijabli X možemo simulirati tako da izračunamo F_X^{-1} te tu funkciju primijenimo na slučajno generirane brojeve (iz $U(0,1)$) da bi dobili uzorak koji će imati istu razdiobu kao polazna slučajna varijable X. Važnost uniformne razdiobe za vjerojatnost ne proizlazi iz njene široke primjene u modeliranju slučajnih pojava, nego iz činjenice da se njome mogu dobiti/simulirati brojne druge razdiobe (slučajne varijable iz brojnih drugih razdioba). Pogledajmo neke primjere.

Primjer 5.4.14 (Simulacija eksponencijalne razdiobe)**.** Želimo simulirati jediničnu eksponencijalnu razdiobu. Neka je X slučajna varijabla, $X \sim Exp(1)$. Znamo da je njena funkcija distribucije

$$F_X(x) = 1 - e^{-x}. \tag{5.42}$$

Kako je e^{-x} strogo padajuća funkcija zaključujemo da je F_X strogo rastuća pa je i injekcija. Kako je neprekidna, ona je i bijekcija (sa $\mathbb{R}$ na $(0,1)$). Stoga funkcija distribucije (jedinične) eksponencijalne slučajne varijable ima inverz. Nađimo ga. Uzmimo $u \in (0,1)$. Tada je

$$u = 1 - e^{-x},$$

odnosno

$$x = -\ln(1-u).$$

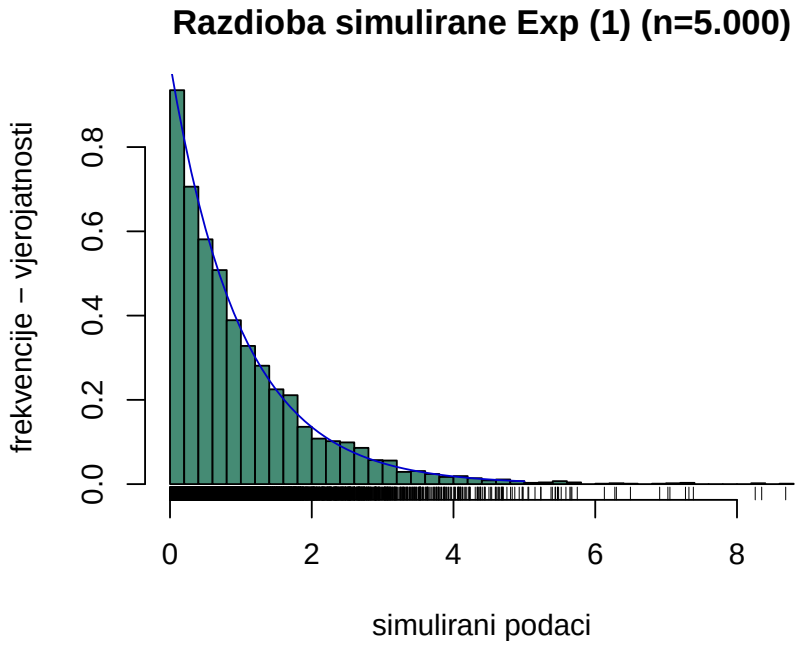
Dakle,

$$F_X^{-1}(u) = -\ln(1-u), \ u \in (0,1).$$

Konstatirali smo da slučajna varijabla

$$F_X^{-1}(U) = -\ln(1-U)$$

ima istu razdiobu kao polazna slučajna varijabla X, ako je $U \sim U(0,1)$. Dakle, simulirajući slučajnu varijablu U, a to činimo generirajući slučajne brojeve u R-u, simuliramo razdiobu slučajne varijable $X \sim Exp(1)$. Napravimo 5.000 simulacija i prikažimo podatke histogramom. Dobivamo



Na grafu smo plavom linijom označili vrijednosti funkcije gustoće jedinične eksponencijalne razdiobe korištenjem R-ove funkcije `dexp`. Vidimo se da se dobiveni (simulirani) podaci dobro slažu s teorijskom funkcije gustoće. Postupak je jednostavan i vrlo efikasan. Ako malo razmislimo uvidjet ćemo da je najveći problem naći inverznu funkciju od F_X. □

Primjer 5.4.15 (Simulacija Gumbelove razdiobe)**.** U teoriji ekstremnih vrijednosti[24] je jedna od važnijih razdioba **Gumbelova** razdioba. I ona ima svoje parametre poput normalne ili uniformne razdiobe, ali ovdje gledamo standardnu Gumbelovu distribuciju kojoj je funkcija gustoće dana s

$$f(x) = e^{-(x+e^{-x})},\ x \in \mathbb{R}. \tag{5.43}$$

dok joj je funkcija distribucije dana s

$$F(x) = e^{(-e^{-x})},\ x \in \mathbb{R}. \tag{5.44}$$

Pokažimo, za vježbu, da je to zaista funkcija distribucije od f. Prema definiciji funkcije distribucije je

$$F(x) = \int_{-\infty}^{x} e^{-(t+e^{-t})}dt = \int_{-\infty}^{x} e^{-t}e^{-e^{-t}}dt.$$

Uvedimo novu varijablu u gornjem integralu $u = -e^{-t}$. Tada je $du = e^{-t}dt$. Što se tiče granica integracije, uočimo da je imamo nepravi integral. Stoga je

$$F(x) = \lim_{a\to-\infty}\int_{a}^{x} e^{-t}e^{-e^{-t}}dt.$$

Uz gore navedenu zamjenu varijabli donja granica postaje $-e^{-a}$, a gornja $-e^{-x}$. Dakle,

$$\int_{a}^{x} e^{-t}e^{-e^{-t}}dt = \int_{-e^{-a}}^{-e^{-x}} e^{u}du = e^{u}\Big|_{-e^{-a}}^{-e^{-x}} = e^{-e^{-x}} - e^{-e^{-a}}$$

[24] Riječ je o grani vjerojatnosti koja se bavi proučavanjem i modeliranjem ekstremnih događaja poput velikih poplava, potresa i sličnih slučajnih događaja.

pa je

$$F(x) = \lim_{a\to-\infty}(e^{-e^{-x}} - e^{-e^{-a}}) = e^{-e^{-x}} - \lim_{a\to-\infty} e^{-e^{-a}} = e^{-e^{-x}},$$

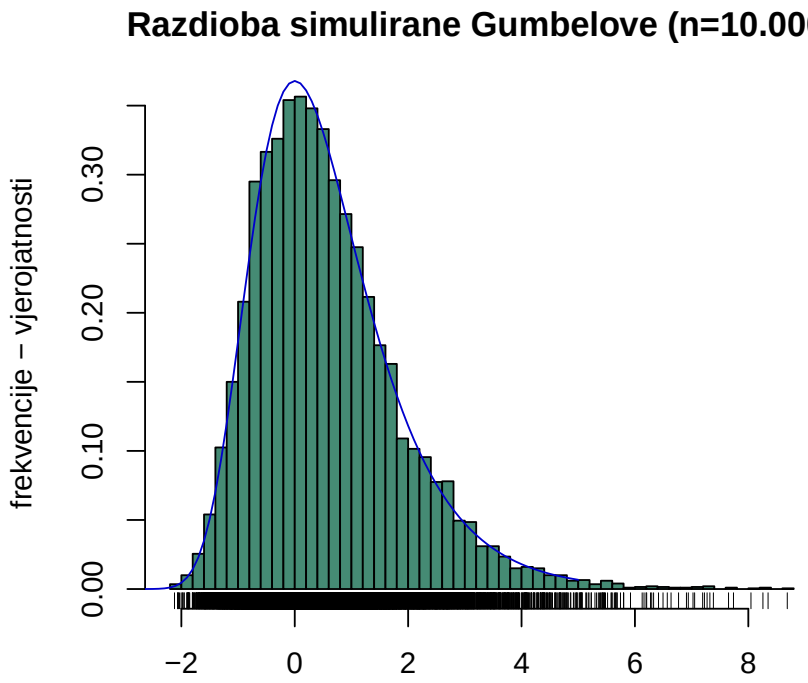
jer je a negativan pa $-a$ teži u beskonačnost, a onda i e^{-a}, ali na kraju ostajemo s eksponencijalnom funkcijom čiji argument teži u $-\infty$ (zbog negativnog predzaka), a znamo da je limes eksponencijalne funkcije u $-\infty$ jednak nuli.
Nađimo inverznu funkciju od F. Uzmimo $u \in (0,1)$ iz slike funkcije F. Tada iz jednakosti $F(x) = u$ najprije dobivamo

$$e^{-x} = -\ln(u),$$

a onda[25] i

$$x = -\ln(-\ln(u)).$$

Dakle, $F^{-1}(u) = -\ln(-\ln(u))$. Sada opet iskoristimo činjenicu da slučajna varijabla $F^{-1}(U) = -\ln(-\ln(U))$, za $U \sim U(0,1)$, ima istu distribuciju kao Gumbelova slučajna varijabla X kojoj je F funkcija distribucije, odnosno f iz (5.43) funkcija gustoće.



Na gornjem histogramu su prikazani rezultati simulacije uzorka slučajne varijable X uz generiranje 10.000 slučajnih brojeva iz jedinične uniformne razdiobe. Za prikaz teorijske funkcije gustoće Gumbelove razdiobe smo koristili funkciju `dgumbel()` iz paketa `evd`.
Vidimo da opet dobivamo prilično dobru aproksimaciju teorijskih vrijednosti Gumbelove funkcije gustoće. □

5.4.1.4 Paretova razdioba

Definicija 5.4.16. Neprekidna slučajna varijabla X ima **Paretovu razdiobu** s parametrom $\alpha > 0$ ako joj je funkcija gustoće

$$f_X(x) = \begin{cases} \frac{\alpha}{x^{\alpha+1}}, & x \geq 1 \\ 0, & x < 1. \end{cases} \tag{5.45}$$

[25] Uočimo da je, za $u \in (0,1)$, $\ln(u) \in (-\infty, 0)$ pa je $-\ln(u) \in (0,\infty)$, što znači da je $\ln(-\ln(u))$ dobro definirana funkcija.

Funkcija distribucije Paretove slučajne varijable je tada

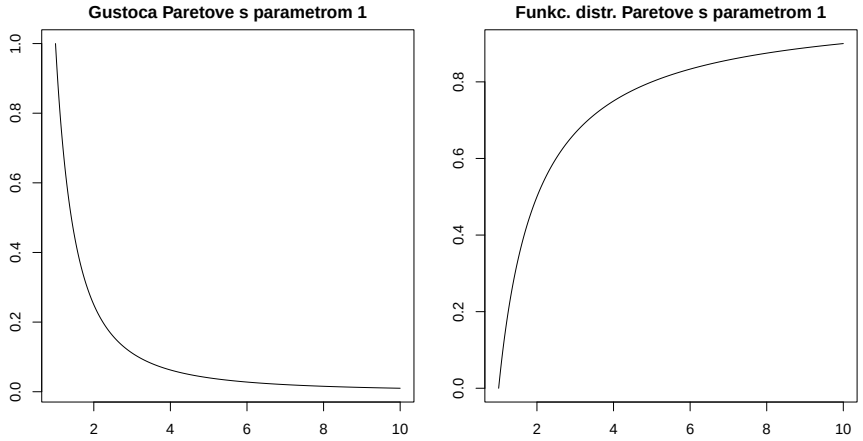
$$F_X(x) = \begin{cases} 1 - \frac{1}{x^\alpha}, & x \geq 1 \\ 0, & x < 1. \end{cases}$$

Zanimljivo je da se kod Paretove razdiobe (slučajne varijable X s Paretovom razdiobom) češće gleda njena repna distribucija $\bar{F}_X$ od same funkcije distribucije. Imamo sljedeću formulu za repnu distribuciju

$$\bar{F}_X(x) = P(X > x) = \begin{cases} \frac{1}{x^\alpha}, & x \geq 1 \\ 1, & x < 1. \end{cases} \tag{5.46}$$

Razlog za proučavanje ponašanja repne distribucije Paretove slučajne varijable je njena primjenjivost na opisivanje pojava u kojima se neke velike vrijednosti pojavljuju s pozitivnim vjerojatnostima (veličina gradova, slušanost hitova u glazbenoj industriji, jačina potresa, najveća dnevna količina padalina u godini na jednom mjernom mjestu i sl.). Sam Pareto, talijanski ekonomist, je uočio da se broj bogatih pojedinaca u nekoj zemlji ponaša u skladu s Paretovom razdiobom (ima rep polinomijalnog oblika s $\alpha \approx 1,16$).

Na donjim grafovima je prikazana gustoća i funkcija distribucije Paretove slučajne varijable s parametrom $\alpha = 1$.



Za kraj ovog kratkog pregleda Paretove razdiobe uočimo da se Paretova slučajna varijabla s parametrom $\alpha > 0$ može dobiti iz eksponencijalno distribuirane slučajne varijable. Preciznije, ako je X eksponencijalna slučajna varijabla s parametrom α, onda je

$$Y = e^X$$

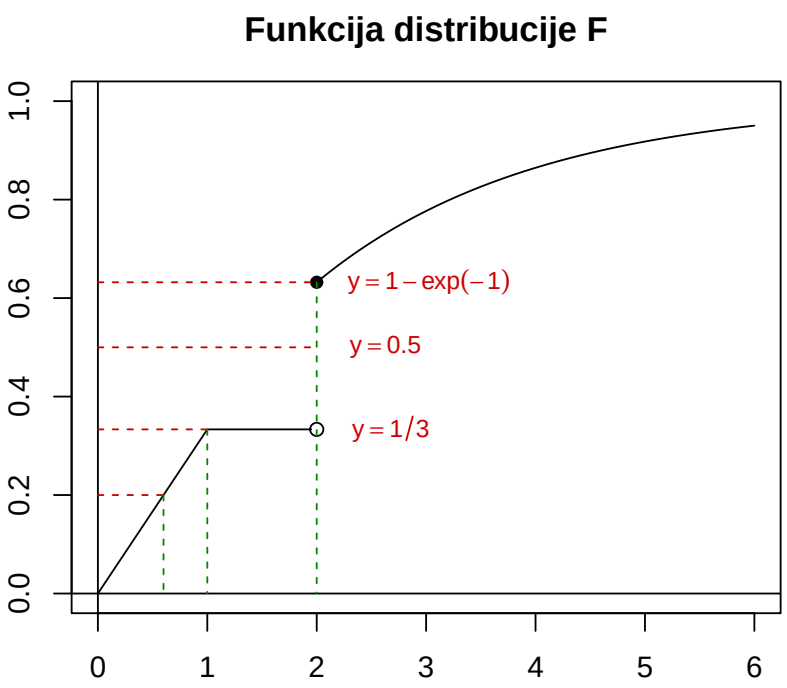
Paretova slučajna varijabla s parametrom α. Kako to možemo provjeriti? Opet koristimo svojstvo da je razdioba slučajne varijable određena njenom funkcijom distribucije. Dakle, ako izračunamo funkciju distribucije slučajne varijable Y (ili repnu funkciju distribucije $1 - F_Y$) i pokažemo da je ona jednaka funkciji distribucije Paretove slučane varijable, onda je Y Paretova slučajna varijabla s parametrom α. Provjerimo to. Za $x \geq 1$ imamo

$$P(Y > x) = P(e^X > x) = P(X > \ln(x)) = e^{-\alpha \ln(x)} = e^{\ln(x)^{-\alpha}} = \frac{1}{x^\alpha}.$$

Napomena 5.4.17 (Još malo o simulacijama uniformnom)**.** U primjerima 5.4.14 i 5.4.15 smo vidjeli da se simulacija razdiobe kojoj je funkcija distribucije F invertibilna može prilično lagano izvesti simulacijom realizacija slučajne varijable

$$X = F^{-1}(U),$$

gdje je $U \sim U(0,1)$. Postavlja se pitanje da li se nešto slično može napraviti kada inverz funkcije distribucije F ne postoji.
Da bi vidjeli u čemu je problem pogledajmo jednu razdiobu čiji je graf funkcije distribucije F prikazan na donjoj slici



Radi potpunosti navedimo da je funkcija distribucije F definirana s

$$F(x) = \begin{cases} 0, & x < 0 \\ 1/3\ x, & 0 \leq x < 1 \\ 1/3, & 1 \leq x < 2 \\ 1 - e^{-x/2}, & x \geq 2. \end{cases}$$

Uočimo da funkcija distribucije ima skok u točki $x = 2$ koji je tipičan za diskretne slučajne varijable.[26] Činjenica da je funkcija distribucije neprekidna zdesna znači sljedeće. S desne strane točke $x = 2$ je funkcija F jednaka $1 - e^{-x/2}$ i kako se približavamo vrijednosti argumenta 2 tako se vrijednosti funkcije F neprekidno približavaju vrijednosti $F(2) = 1 - e^{-1}$. S lijeve strane točke $x = 2$ je funkcija F jednaka $1/3$ i ima prekid (skok) do vrijednosti $F(2)$.
Što se tiče invertibilnosti funkcije F vidimo da se ona razlikuje od intervala do intervala. Na $(0,1)$ je F jednaka linearnoj funkciji pa je invertibilna na cijelom intervalu. Zbog toga za svaku točku iz područja vrijednosti $(0, 1/3)$ funkcije F možemo naći točku na osi x u koju je ta točka preslikana. Tako smo indicirali, crvenom i zelenom crtom, da je točka $0,2$ na y osi preslikana iz točke $0,6$ na x osi.
Na intervalu $[1,2)$ je funkcija F konstantna pa nije invertibilna. Jasno, sve točke iz $[1,2)$ se preslikavaju u točku $1/3$ na y osi pa kada gledamo $F^{-1}(1/3)$ ne možemo odrediti jednoznačnu vrijednost x koja se preslikava u $1/3$.
Naravno, na intervalu $[2,\infty)$ je F jednaka strogo rastućoj funkciji $1 - e^{-x/2}$ pa je opet F invertibilna. S druge strane, kada gledamo invertibilnost, možemo uočiti da funkcija F niti jednu točku s x ne preslikava u interval $(1/3, 1 - e^{-1})$. Na gornjem grafu funkcije

[26] Mi smo gledali neprekidne i diskretne slučajne varijable, ali postoje i hibridne. One mogu uglavnom izgledati kao neprekidne, ali mogu imati i skokove na grafu funkcije distribucije koji su tipični za diskretne slučajne varijable. To je tema za sebe i za puni opis mogućih slučajnih varijabli bi trebali još neke teorijske alate.

F smo prikazali točku $0,5 \in (1/3, 1-e^{-1})$ koja nije preslikana niti iz jedne točke s osi x po funkciji F jer je točka $x=2$ preslikana u $F(2)=1-e^{-1}$, kao što smo već istaknuli (naravno, imamo na umu da funkcija bilo kojoj točki iz domene može pridružiti najviše jednu točku iz kodomene).

Iako funkcija F nije invertibilna, može se definirati njen, tako zvani, **poopćeni inverz**. Njega označavamo s $F^{\leftarrow}$ i definiramo ga kao

$$F^{\leftarrow}(u) = \inf\{x \mid F(x) \geq u\},\ u \in (0,1). \tag{5.47}$$

Razmislimo čemu je jednaka funkcija $F^{\leftarrow}$. Uočimo da njen argument ima vrijednosti iz $(0,1)$. Grafički, funkcija $F^{\leftarrow}$ pridružuje točkama s osi y točke na osi x.
Vidimo da na intervalu $(0,1/3)$ vrijedi $F^{\leftarrow} = F^{-1}$ jer je na tom intervalu funkcija invertibilna. Ista je situacija na intervalu $(1-e^{-1}, \infty)$ (funkcija je invertibilna). Što je s točkom $y=1/3$? Prema definiciji funkcije $F^{\leftarrow}$ je

$$F^{\leftarrow}(1/3) = \inf\{x \mid F(x) \geq 1/3\}$$

pa je $F^{\leftarrow}(1/3)=1$ jer je $x=1$ najmanja vrijednost varijable x za koju je $F(x)=1/3$ pa i $F(x) \geq 1/3$.
Pogledajmo što se događa s, na primjer, točkom $y=0,5$? Sada se pitamo koja je to najmanja vrijednost x (u smislu infimuma) za koju je $F(x) \geq 0,5$. Ako malo razmislimo, shvatit ćemo da je $x=2$ najmanja vrijednost x-a za koju je funkcijska vrijednost $F(x)$ veća ili jednaka od $1-e^{-1}$, a onda i od $y=0,5$. Stoga je $F^{\leftarrow}(0,5)=2$. Istu vrijednost će postići funkcija $F^{\leftarrow}$ za sve vrijednosti iz $(1/3, 1-e^{-1}]$.

Poopćeni inverzi se koriste na mnogim mjestima u vjerojatnosti. U kontekstu simulacija oni nam omogućavaju da poopćimo rezultat o simulacijama jer za funkciju distribucije poput F iz ove napomene vrijedi da slučajna varijabla

$$X = F^{\leftarrow}(U)$$

ima funkciju distribucije F, gdje je $U \sim U(0,1)$. Taj se rezultat pokaže kao i u slučaju postojanja inverza od F s time da se ovdje treba uočiti da je

$$\{u \mid F^{\leftarrow}(u) \leq x\} = \{u \mid u \leq F(x)\}$$

zbog desne neprekidnosti funkcije distribucije F. □

5.4.2 Nezavisne neprekidne slučajne varijable

U potpoglavlju 5.2.4 smo se upoznali s pojmom nezavisnih slučajnih varijabli. U Definiciji 5.2.12 smo dali općenitu definiciju nezavisnosti slučajnih varijabli koja je primjenjiva i na neprekidne slučajne varijable. U teoremu 5.2.13 smo iskazali jednu praktičnu karakterizaciju nezavisnoti slučajnih varijabli. Sjetimo se, $X_1, X_2, \ldots X_n$ su nezavisne slučajne varijable ako i samo ako za sve $x_1, x_2, \ldots x_n \in \mathbb{R}$, $n \in \mathbb{N}$, vrijedi

$$F_X(x_1, x_2, \ldots x_n) = F_{X_1}(x_1) \cdot F_{X_2}(x_2) \cdot \ldots \cdot F_{X_n}(x_n), \tag{5.48}$$

pri čemu smo s $X = (X_1, X_2, \ldots X_n)$ označili slučajni vektor koji čine slučajne varijable $X_1, X_2, \ldots X_n$, a F_X je funkcija distribucije slučajnog vektora X koju definiramo kao

$$F_X(x_1, x_2, \ldots x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \ldots, X_n \leq x_n).$$

Karakterizacija nezavisnosti dana u (5.48) je općenita (vrijedi i za diskretne i za neprekidne slučajne varijable) i pokazuje nam da se funkcija distribucije slučajnog vektora

može prikazati kao umnožak funkcija distribucije pojedinačnih slučajnih varijabli koje čine taj slučajni vektor ako su $X_1, X_2, \dots X_n$ nezavisne slučajne varijable. To, općenito, ne mora biti slučaj jer zajednička funkcija distribucije više slučajnih varijabli može biti vrlo složena. To je tema za sebe i uglavnom se njome ne bavimo detaljnije u ovoj skripti.

Za nezavisne slučajne varijable iz normalne razdiobe imamo sljedeće svojstvo: neka su $X \sim N(\mu_1, \sigma_1^2)$ i $X \sim N(\mu_2, \sigma_2^2)$ **nezavisne** slučajne varijable. Onda je i $X + Y$ slučajna varijable iz normalne razdiobe i vrijedi (za detalje pogledajte Primjer 11.10. iz [10])

$$X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2). \tag{5.49}$$

Matematičkom indukcijom se to svojstvo lagano proširi na n nezavisnih normalnih slučajnih varijabli. Dakle, ako su $X_1, X_2, \dots, X_n$ nezavisne slučajne varijable takve da je $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, 2, \dots, n$, onda je

$$\sum_{i=1}^{n} X_i \sim N(\sum_{i=1}^{n} \mu_i, \sum_{i=1}^{n} \sigma_i^2).$$

I za zbrojeve nezavisnih slučajnih varijabli iz nekih drugih razdioba vrijede slična svojstva, ali ih ne navodimo na ovom mjestu.

U Teoremu 5.2.14 smo vidjeli da se nezavisnost diskretnih slučajnih varijabli može okarakterizirati funkcijom razdiobe pojedinačnih slučajnih varijabli. Analogon tog rezultata u slučaju neprekidnih slučajnih varijabli je teorem koji nam kaže da se nezavisnost slučajnih varijabli $X_1, X_2, \dots X_n$ može okarakterizirati činjenicom da je funkcija gustoće slučajnog vektora $X = (X_1, X_2, \dots X_n)$ jednaka produktu pojedinačnih funkcija gustoće slučajnih varijabli $X_1, X_2, \dots X_n$ (Teorem 11.2. u [10]). Precizan iskaz tog teorema zahtjeva nekoliko definicija pa ga ovdje izostavljamo, ali dajemo ilustrativan primjer s jednostavnom razdiobom - uniformnom razdiobom u dvije dimenzije.

Primjer 5.4.18. Želimo definirati funkciju gustoće dvodimenzionalne uniformne razdiobe. Kod (jednodimenzionalne) neprekidne uniformno distribuirane slučajne varijable U na intervalu (a, b) je funkcija gustoće bila konstantna na $[a, b]$ (ili (a, b), što je svejedno za neprekidne slučajne varijable). Da bi integral funkcije gustoće bio jednak 1 sam iznos konstante kojoj je jednaka funkcija gustoće na (a, b) je trebao biti jednak recipročnoj vrijednosti duljine intervala (a, b), odnosno $1/(b - a)$.

U dvodimenzionalnom slučaju nemamo jednu slučajnu varijablu, nego slučajni vektor (U, V) koji se sastoji od dvije slučajne varijable U i V. Radi konkretnosti, pretpostavimo da želimo odrediti funkciju gustoće dvodimenzionalne uniformne razdiobe na produktu $[1, 4] \times [1, 3]$ (mogli smo uzeti i općenite $[a, b] \times [c, d]$). Riječ je o Kartezijevom produktu dva segmenta, a on je jednak pravokutniku. Dobiveni pravokutnik je označen na donjoj slici s M i obojan je plavom bojom. Njegova je površina jednaka $(4 - 1) \cdot (3 - 1) = 6$.

Prema analogiji s jednodimenzionalnim slučajem, definirajmo funkciju gustoće uniformno distribuiranog slučajnog vektora (U, V) kao funkciju

$$f_{(U,V)}(x, y) = \begin{cases} c, & (x, y) \in M \\ 0, & \text{inače.} \end{cases} \tag{5.50}$$

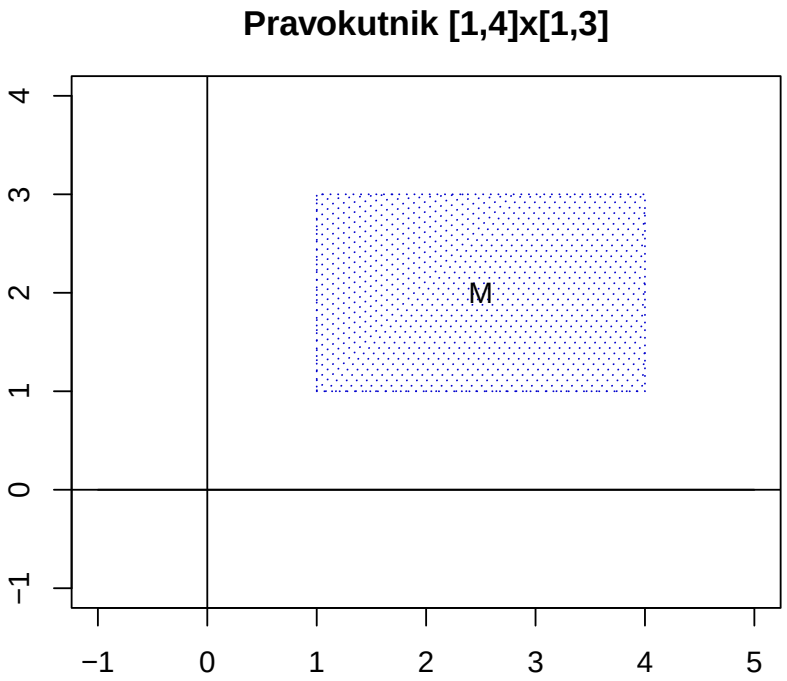
U dvije dimenzije osnovni uvjet vrijednosti integrala funkcije $f_{(U,V)}$ glasi

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{(U,V)}(x, y) dx dy = 1.$$

Iz tog uvjeta izračunamo kolika mora biti konstanta c. Naša funkcija gustoće je različita od nule samo na pravokutniku M pa imamo

$$\int_1^3 \int_1^4 c \, dx dy = c \int_1^3 x \Big|_{x=1}^{x=4} dy = c \int_1^3 (4 - 1) dy = 3cy \Big|_{y=1}^{y=3} = 3c(3 - 1) = 6c = 1.$$

Stoga je $c = 1/6$. To smo mogli zaključiti i bez računanja integrala jer je površina pravokutnika M jednaka 6, ali želimo pokazati principe koji vrijede u dvije dimenzije.



Kada znamo funkciju gustoće $f_{(U,V)}$ možemo lagano računati vjerojatnosti vezane uz slučajni vektor (U, V). Recimo, za $A = [1, 2] \times [1, 2]$ imamo

$$P((U,V) \in A) = \int\int_{(x,y)\in A} f_{(U,V)}(x,y)dxdy = \frac{1}{6}\int_1^2\int_1^2 dxdy = \frac{1}{6}.$$

To je i geometrijski jasno jer površina kvadrata A čini jednu šestinu površine pravokutnika M.

Zajednička funkcija gustoće slučajnog vektora (U, V) sadrži i informacije o pojedinačnim slučajnim varijablama U i V. Jezikom vjerojatnosti, iz zajedničke funkcije gustoće vektora (U, V) možemo izračunati marginalne gustoće slučajnih varijabli U i V. Njih računamo na sljedeći način. Za $x \in [1, 4]$ je

$$f_U(x) = \int_{-\infty}^{\infty} f_{(U,V)}(x,y)dy = \frac{1}{6}\int_1^3 dy = \frac{2}{6} = \frac{1}{3},$$

dok je za ostale x $f_U(x) = 0$. Slično, za $y \in [1, 3]$ imamo

$$f_V(y) = \int_{-\infty}^{\infty} f_{(U,V)}(x,y)dx = \frac{1}{6}\int_1^4 dx = \frac{3}{6} = \frac{1}{2},$$

dok je za ostale y $f_V(y) = 0$. Ako malo pažljivije promotrimo dobivene funkcije gustoće f_U i f_V vidimo da je $U \sim U(1, 4)$ i $V \sim U(1, 3)$. Dakle,

$$f_{(U,V)}(x,y) = f_U(x)f_V(y)$$

pa zaključujemo da su U i V nezavisne slučajne varijable, prema karakterizaciji nezavisnosti slučajnih varijabli pomoću funkcija gustoće. Dakle, uniformnu razdiobu u dvije dimenzije dobivamo pomoću nezavisnih slučajnih varijabli iz (jednodimenzionalne) uniformne razdiobe.

To neće biti općenito slučaj. Tako će dvodimenzionalni normalni slučajni vektor biti sastavljen od nezavisnih jednodimenzionalnih normalnih slučajnih varijabli samo u posebnom slučaju. □

5.5 Razdiobe u R-u

U glavnom dijelu teksta smo se na više mjesta referirali na razne R-ove funkcije kojima se mogu računati vrijednosti funkcije gustoće, funkcije distribucije, kvantila ili se može generirati uzorak iz određene razdiobe. Za normalnu slučajnu varijablu su to bile, redom funkcije `dnorm`, `pnorm`, `qnorm` i `rnorm`. Prefiksi `d`, `p`, `q` i `r` se u R-u najčešće koriste u tom kontekstu i za mnoge druge razdiobe.

Konceptualno je, za simulacije, najvažnije saznanje iz ovog poglavlja da se slučajna varijabla iz praktički proizvoljne razdiobe može izraziti pomoću uniformne slučajne varijable. Podsjetimo se, ako je F neka funkcija distribucije koja je invertibilna[27], onda je razdioba slučajne varijable

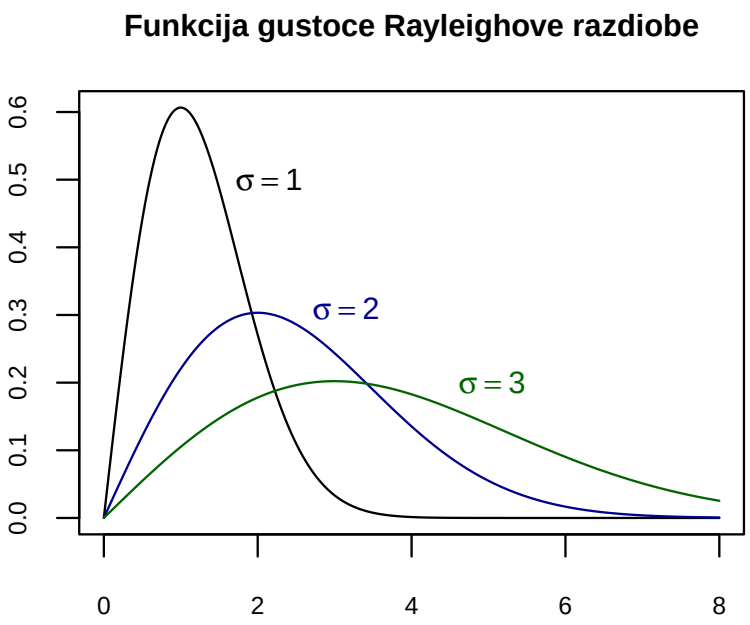
$$X = F^{-1}(U)$$

upravo F. Kako generator slučajnih brojeva generira realizacije uniformne slučajne varijable iz $U(0,1)$ na taj možemo dobiti i realizacije slučajne varijable X kojoj je funkcija distribucije F. Kažemo da na taj način možemo simulirati slučajnu varijablu X, odnosno vrijednosti slučajne varijable X. U primjerima 5.4.14 i 5.4.15 smo vidjeli kako to napraviti za slučajne varijable iz eksponencijalne i Gumbelove razdiobe.
Pogledajmo još jedan primjer. Možete i sami probati napraviti simulaciju, ali u nastavku dajemo rješenje.

Kaže se da slučajna varijabla ima Rayleigh-ovu razdiobu s parametrom $\sigma > 0$ ako joj je funkcija gustoće dana s

$$f(x) = \begin{cases} \frac{x}{\sigma^2} e^{-x^2/(2\sigma^2)}, & x \geq 0 \\ 0, & \text{inače.} \end{cases} \tag{5.51}$$

Na donjoj slici je prikazana funkcija gustoće Rayleighove razdiobe za vrijednosti parametra $\sigma = 1$, $\sigma = 2$ i $\sigma = 3$. Vidimo da povećenjem parametra σ povećavamo raspršenost funkcije distribucije Rayleigh-ove razdiobe. Za određivanje vrijednosti funkcije f smo koristili funkciju `drayleigh()` iz paketa `extraDistr` u kojem se mogu naći mnoge nestandardne razdiobe.



[27] Vidjeli smo u Napomeni 5.4.17 da se takva konstrukcija može proširiti i na neinvertibilne funkcije distribucije i to uvođenjem poopćenog inverza funkcije distribucije F.

Uzmimo radi jednostavnosti u nastavku $\sigma = 1$. Tada je funkcija distribucije

$$F(x) = 1 - e^{-x^2/2}, \ x > 0.$$

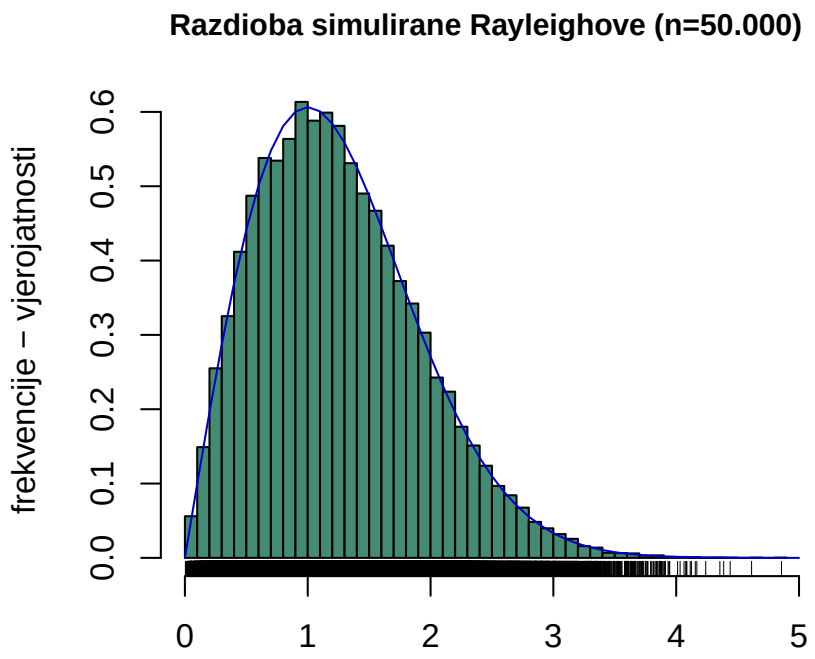
Kako je $x > 0$ inverzna funkcija od F je

$$F^{-1}(u) = \sqrt{-2\ln(1-u)}, \ u \in (0,1)$$

pa slučajna varijabla

$$X = F^{-1}(U) = \sqrt{-2\ln(1-U)}$$

ima Rayleighovu razdiobu s parametrom $\sigma = 1$ ako je $U \sim U(0,1)$. To nam omogućava da simuliramo realizacije slučajne varijable X.



Na prethodnoj slici je prikazan histogram simuliranih vrijednosti od X uz 50.000 simulacija. Radi potpunosti dajemo R-kod kojim smo generirali gornji histogram.

```
> par(mar=c(2,4,3,2))
> library(evd)
> set.seed(42)
> u<-runif(50000)
> x<- sqrt(-2*log(1-u))
> hray<-hist(x, main="Razdioba simulirane Rayleighove (n=50.000)",
+            probability= TRUE, xlab="simulirani podaci", breaks =40,
+            cex=0.8, cex.main=0.9,
+            ylab="frekvencije - vjerojatnosti", col = "aquamarine4")
> rug(x, side=1)
> xpom<- seq(0,5, 0.1)
> ypom <- drayleigh(xpom,sigma=1)
> lines(xpom, ypom,  col="blue3")
```

Do sada smo simulirali neprekidne slučajne varijable. Možemo se zapitati kako simulirati neke od osnovnih primjera slučajnih eksperimenata koje smo upoznali. Na primjer, možemo se zapitati kako bi na računalu simulirali slučajno bacanje kockice. Uočite da kod diskretnih slučajnih varijabli funkcija distribucije nije neprekidna i ima područja na

kojima je konstantna pa njen inverz ne postoji u uobičajenom (funkcijskom) smislu. No u slučaju diskretnih slučajnih varijabli, odnosno slučajnih događaja s diskretnim ishodima, možemo probati direktno simulirati razdiobu.

Da ilustriramo ideju pogledajmo kako bi simulirali ishode bacanja simetrične kockice. U tu svrhu definirajmo slučajnu varijablu X na intervalu $(0,1)$ kao

$$X(u) = \begin{cases} 1, & u \in (0, 1/6) \\ 2, & u \in [1/6, 2/6) \\ 3, & u \in [2/6, 3/6) \\ 4, & u \in [3/6, 4/6) \\ 5, & u \in [4/6, 5/6) \\ 6, & u \in [5/6, 1). \end{cases}$$

Neka je $U \sim U(0,1)$. Onda je, na primjer,

$$P(X = 1) = P(U \in (0, 1/6)) = \frac{1}{6},$$

zatim

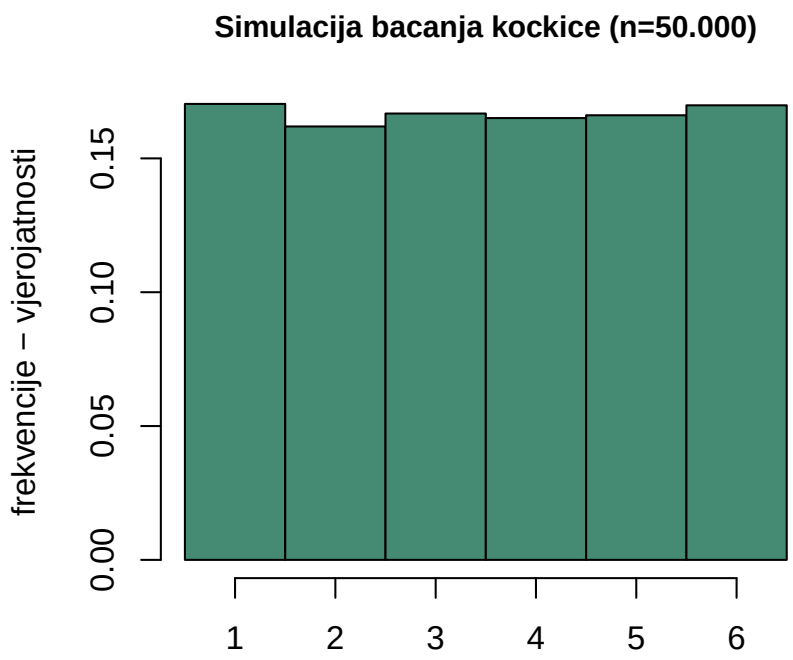
$$P(X = 2) = P(U \in [1/6, 2/6)) = \frac{1}{6}$$

i tako dalje. Dobivamo

$$P(X = i) = \frac{1}{6},\ i = 1, 2, 3, 4, 5, 6.$$

Sada možemo simulirati slučajnu varijablu X koja ima distribuciju kao i slučajna varijabla koja je jednaka broju koji je pao na kockici koju slučajno bacamo tako da generiramo velik uzorak (niz brojeva) iz jedinične uniformne distribucije i brojimo ponavljanja brojeva iz svakog od intervala $[i/6, (i+1)/6)$, $i = 0, 1, 2, 3, 4, 5$.

Histogram relativnih frekvencija tako dobivenih brojeva (slika ispod) pokazuje da su svi stupci histograma relativnih frekvencija otprilike jednaki $1/6$. Izveli smo 50.000 simulacija slučajnih brojeva. Jasno je da ovakva simulacija zorno prikazuje ovisnost o kvaliteti samih slučajnih brojeva koje generiramo (korištenjem R-ove funkcije `runif`). Napomenimo da smo realizacije od X generirali kao $\lfloor u \cdot 6 \rfloor + 1$. Vrijednost funkcije $\lfloor \cdot \rfloor$ je najveći cijeli broj koji je manji od argumenta te funkcije (npr. $\lfloor \pi \rfloor = 3$).



5.6 Sažetak poglavlja

$(\Omega, \mathcal{F}, P)$ je vjerojatnosni prostor.
Slučajna varijabla X je funkcija definirana na Ω i s vrijednostima u $\mathbb{R}$.

U vjerojatnosti je uobičajeno koristiti skraćeni zapis u kojem se izostavlja argument ω slučajne varijable X. Tako ćemo za c i d realne brojeve $(c \leq d)$ umjesto

$$P(\{\omega \in \Omega \mid c \leq X(\omega) \leq d\})$$

u pravilu pisati skraćeno

$$P(c \leq X \leq d).$$

Slično, za neki $B \subset \mathbb{R}$ ćemo pisati

$$P(X \in B), \tag{5.52}$$

umjesto

$$P(\{\omega \in \Omega \mid X(\omega) \in B\}).$$

Slučajna varijabla $X : \Omega \to \mathbb{R}$ je **diskretna** ako joj je kodomena konačan ili prebrojiv skup, odnosno ako postoje realni brojevi $a_1, a_2, a_3, \ldots \in \mathbb{R}$ takvi da je za sve $\omega \in \Omega$

$$X(\omega) \in \{a_1, a_2, \ldots a_n\}, \quad n \in \mathbb{N}$$

ili

$$X(\omega) \in \{a_1, a_2, a_3, \ldots\}.$$

Definiramo disjunktne slučajne događaje A_i, $i = 1, 2 \ldots, n$, kao

$$A_i = \{X = a_i\} = \{\omega \in \Omega \mid X(\omega) = a_i\}, \ i = 1, 2 \ldots, n.$$

Jasno je da su $A_i \subset \Omega$, ali i

$$\bigcup_{i=1}^{n} A_i = \Omega.$$

$\{A_1, A_2, \ldots, A_n\}$ čine particiju skupa Ω. Analogna konstrukcija se dobije ako X ima prebrojivo beskonačno različitih vrijednosti.

Definiramo brojeve (vjerojatnosti)

$$p_i = P(A_i) = P(X = a_i), \ i = 1, 2, \ldots, n.$$

Vrijedi da su $p_i \in [0, 1]$ te im je zbroj jednak 1.

Neka je X diskretna slučajna varijabla na Ω koja prima vrijednosti u skupu realnih brojeva $\{a_1, a_2, a_3, \ldots\}$. **Razdioba** slučajne varijable X (**distribucija** slučajne varijable X), je funkcija $p_X : \mathbb{R} \to [0, 1]$ koja se definira sa

$$p_X(x) = P(X = x), \ x \in \mathbb{R}.$$

Funkcija p_X je jednaka nuli za sve x, osim za $x \in \{a_1, a_2, a_3, \ldots\}$, za koje je

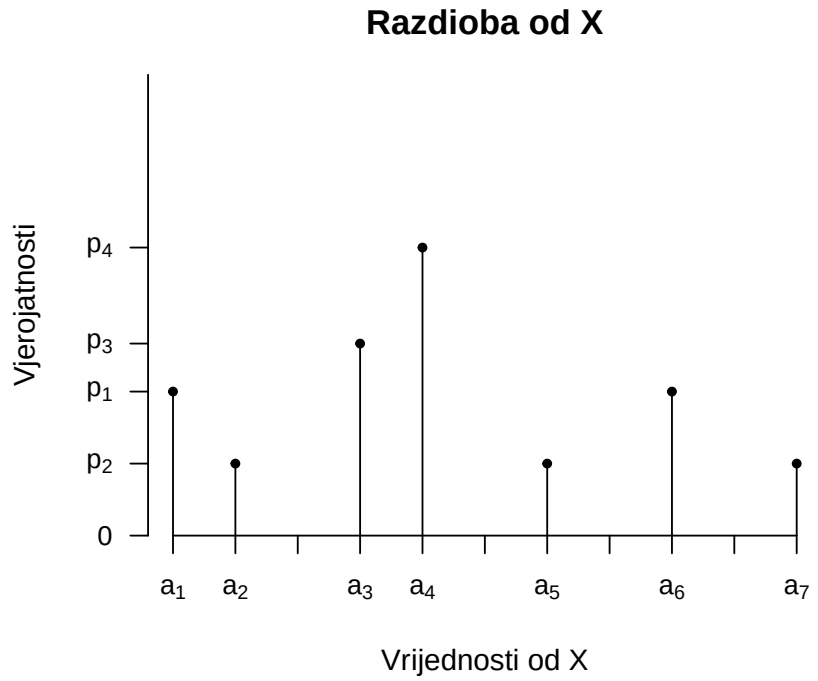
$$p_X(a_i) = P(X = a_i) = P(\{\omega \in \Omega \mid X(\omega) = a_i\}).$$

Razdiobe diskretnih slučajnih varijabli je uobičajeno prikazivati u obliku tablice kojoj se u gornjem redu nalaze vrijednosti koje postiže slučajna varijabla X, a u donjem redu

pripadne vjerojatnosti skupova na kojima je X jednak pojedinom elementu iz skupa svojih vrijednosti (dakle, $p_i = P(X = a_i)$).

$$X \sim \begin{pmatrix} a_1 & a_2 & \cdots & a_n & \cdots \\ p_1 & p_2 & \cdots & p_n & \cdots \end{pmatrix}. \tag{5.53}$$

Tipičan graf funkcije razdiobe p_X je poput onoga na donjoj slici.



Razdioba slučajne varijable X omogućava izračun svih vjerojatnosti vezanih uz slučajnu varijablu X. Za skup $B \subset \mathbb{R}$ vrijedi

$$P(X \in B) = \sum_{\{i: a_i \in B\}} P(X = a_i).$$

Tipično će biti $B = [a, b]$, $a \leq b$, pa će vrijediti

$$P(a \leq X \leq b) = \sum_{\{i: a \leq a_i \leq b\}} P(X = a_i).$$

Funkcija distribucije slučajne varijable X je funkcija $F = F_X : \mathbb{R} \to [0, 1]$ definirana sa

$$F_X(x) = P(X \leq x), \ x \in \mathbb{R}. \tag{5.54}$$

Za $a, b \in \mathbb{R}$ takve da je $a < b$ i slučajnu varijablu X imamo

$$P(a < X \leq b) = F_X(b) - F_X(a). \tag{5.55}$$

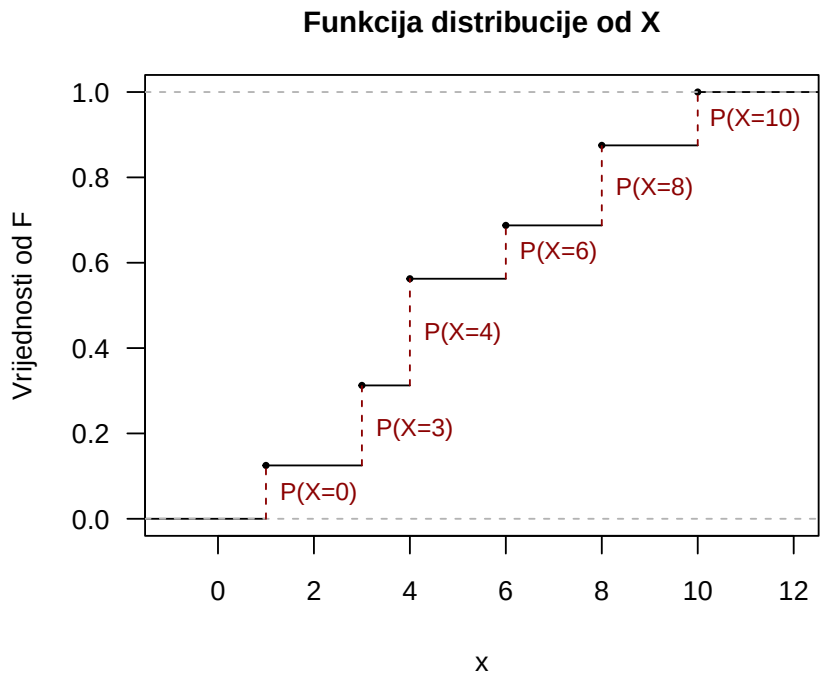
Uočimo da je funkcija distribucije definirana za sve slučajne varijable (ne samo diskretne). Funxcija distribucije, kao i funkcija razdiobe, u potpunosti opisuje vjerojatnosno ponašanje slučajne varijable X.
Svojstva funkcije distribucije F:

i) Ako su $x, y \in \mathbb{R}$ takvi da je $x \leq y$, onda je $F(x) \leq F(y)$. Funkcija distribucije je neopadajuća funkcija.

ii) $\lim_{x \to -\infty} F(x) = 0$ i $\lim_{x \to \infty} F(x) = 1$. Posebno, F_X je nenegativna funkcija.

iii) F je zdesna neprekidna: $\lim_{\epsilon \downarrow 0} F(x+\epsilon) = F(x)$, $x \in \mathbb{R}$.

Tipičan graf funkcije distribucije F_X **za diskretnu** slučajnu varijablu X je poput onoga na donjoj slici. Veličine skokova funkcije F_X u točkama a_i odgovaraju vjerojatnostima $P(X = a_i)$.



Primjeri diskretnih razdioba (diskretnih slučajnih varijabli).
Diskretna uniformna slučajna varijabla X. Razdioba joj je dana s

$$X \sim \begin{pmatrix} 1 & 2 & \dots & n \\ 1/n & 1/n & \dots & 1/n \end{pmatrix}.$$

Bernoullijeva slučajna varijabla X s parametrom $p \in [0,1]$, u oznaci $X \sim Bernoulli(p)$ ili kraće $X \sim Ber(p)$. Razdioba joj je dana s

$$X \sim \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}.$$

Binomna slučajna varijabla X s parametrima n i p, $n \in \mathbb{N}, p \in [0,1]$, prima vrijedosti u skupu $\{0, 1, \dots, n\}$ s pripadnim vjerojatnostima

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \ k = 0, 1, \dots, n.$$

Oznaka $X \sim B(n, p)$.
Geometrijska slučajna varijabla X s parametrom $p \in (0,1]$, u oznaci $X \sim Geom(p)$. Razdioba joj je dana sa

$$P(X = k) = (1-p)^{k-1} p, \ k = 1, 2, \dots$$

Hipergeometrijska slučajna varijabla X s parametrima $p, c, n \in \mathbb{N}$. Razdioba joj jedana s

$$P(X = k) = \frac{\binom{p}{k}\binom{c}{n-k}}{\binom{p+c}{n}}, \ k \in \{0, 1, \dots, p\}, \ n-k \in \{0, 1, \dots, c\}.$$

a za ostale vrijednosti k je $P(X = k) = 0$.
Poissonova slučajna varijabla X s parametrom $\lambda > 0$, u oznaci $X \sim P(\lambda)$. Razdioba joj je dana s

$$P(X = k) = e^{-\lambda}\frac{\lambda^k}{k!},\ k = 0, 1, 2, \ldots.$$

* * * * *

Slučajne varijable X i Y su **nezavisne** ako za sve skupove $A, B \subset \mathbb{R}$ vrijedi

$$P(X \in A, Y \in B) = P(X \in A) \cdot P(Y \in B).$$

Općenito vrijedi (i za diskretne i za neprekidne slučajne varijable): slučajne varijable $X_1, X_2, \ldots X_n$ su **nezavisne** ako i samo ako za sve $x_1, x_2, \ldots x_n \in \mathbb{R}$, $n \in \mathbb{N}$, vrijedi

$$P(X_1 \leq x_1, X_2 \leq x_2, \ldots, X_n \leq x_n) = P(X_1 \leq x_1) \cdot P(X_2 \leq x_2) \cdot \ldots \cdot P(X_n \leq x_n).$$

Uočimo da se s desne strane gornje jednakost nalazi produkt funkcija distribucije slučajnih varijabli $X_1, X_2, \ldots X_n$.
Posebno, ako su X, Y diskretne slučajne varijable zadane svojim distribucijama

$$X \sim \begin{pmatrix} a_1 & a_2 & \ldots & a_n & \ldots \\ p_1 & p_2 & \ldots & p_n & \ldots \end{pmatrix} \quad Y \sim \begin{pmatrix} b_1 & b_2 & \ldots & b_n & \ldots \\ q_1 & q_2 & \ldots & q_n & \ldots \end{pmatrix},$$

gdje su $p_i, q_j \geq o$, $i, j \in \mathbb{N}$ takvi da je $\sum_{i=1}^{\infty} p_i = 1$ i $\sum_{i=1}^{\infty} q_i = 1$, onda je nezavisnost slučajnih varijabli X i Y ekvivalentna uvjetu

$$P(X = a_i, Y = b_j) = P(X = a_i) \cdot P(Y = b_j) = p_i \cdot q_j,\ i, j \in \mathbb{N}. \tag{5.56}$$

Za neke razdiobe nezavisnost ima važne posljedice na zbroj slučajnih varijabli.
1. Ako su $X_1, X_2, \ldots X_n$ **nezavisne** Bernoullijeve slučajne varijable s parametrom p, onda je

$$X_1 + X_2 + \ldots + X_n \sim B(n, p).$$

2. Ako su $X \sim B(n, p)$ i $Y \sim B(m, p)$, $n, m \in \mathbb{N}$, **nezavisne** binomne slučajne varijable, onda je

$$X + Y \sim B(n + m, p).$$

3. Ako su $X \sim P(\lambda_1)$ i $Y \sim P(\lambda_2)$ **nezavisne** Poissonove slučajne varijable, onda je

$$X + Y \sim P(\lambda_1 + \lambda_2).$$

Neka je X slučajna varijabla i $g : \mathbb{R} \to \mathbb{R}$ funkcija. Onda je $g(X)$ opet slučajna varijabla s Ω u $\mathbb{R}$. Ukoliko je funkcija g bijekcija te su $a_1, a_2, \ldots$ sve vrijednosti koje postiže slučajna varijabla X, onda su $g(a_1), g(a_2), \ldots$ sve vrijednosti koje poprima slučajna varijabla $Y = g(X)$, a pripadne vjerojatnosti su

$$P(Y = g(a_i)) = P(X = a_i),\ i \in \mathbb{N}.$$

Time je u potpunosti određena razdioba slučajne varijable Y.

Općenito vrijedi: ako su $X_1, X_2, \ldots, X_n$, $n \in \mathbb{N}$, nezavisne slučajne varijable te su $g_1, g_2, \ldots, g_n$ realne funkcije, onda su nezavisne i slučajne varijable $g_1(X_1)$, $g_2(X_2)$, ..., $g_n(X_n)$.

* * * * *

Definirajuće svojstvo neprekidne slučajne varijable $X : \Omega \to \mathbb{R}$ je postojanje nenegativne funkcije $f = f_X : \mathbb{R} \to [0, \infty)$ takve da za funkciju distribucije F_X od X vrijedi

$$F_X(x) = \int_{-\infty}^{x} f_X(x)dx, \ x \in \mathbb{R}.$$

Funkcija f_X se zove **vjerojatnosna funkcija gustoće** i vrijedi da je

$$\int_{-\infty}^{\infty} f_X(x)dx = 1$$

Za neprekidne slučajne varijable X za koje je funkcija gustoće f_X neprekidna vrijedi

$$F'(x) = f(x)$$

Za X neprekidnu slučajnu varijablu te $a, b \in \mathbb{R}$, $a \leq b$, vrijedi

$$P(a < X \leq b) = \int_a^b f_X(x)dx = F_X(b) - F_X(a). \tag{5.57}$$

Dakle, ako znamo funkciju gustoće, ili funkciju distribucije, možemo odrediti sve vjerojatnosti vezane uz neprekidnu slučajnu varijablu X. Uočimo da posebno vrijedi

$$P(X = a) = \int_a^a f_X(x)dx = 0.$$

Primjeri neprekidnih razdioba (neprekidnih slučajnih varijabli).

Neprekidna slučajna varijabla X ima **normalnu razdiobu** s parametrima $\mu \in \mathbb{R}$ i $\sigma^2 > 0$, u oznaci $X \sim N(\mu, \sigma^2)$., ako joj je funkcija gustoće

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx, \ x \in \mathbb{R}. \tag{5.58}$$

Za $X \sim N(\mu, \sigma^2)$ vrijedi

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

Slučajna varijabla Z ima **jediničnu (standardnu) normalnu razdiobu**. Slučajna varijabla Z se zove **jedinična** ili **standardna normalna** slučajna varijabla. Uočimo, ako je $Z \sim N(0, 1)$, onda je

$$X = \sigma Z + \mu \sim N(\mu, \sigma^2).$$

Funkcija gustoće slučajne varijable Z se označava φ pa je

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \ x \in \mathbb{R}.$$

Uočimo: φ je **parna** funkcija

$$\varphi(-t) = \varphi(t), \ t \in \mathbb{R}$$

pa je Z **simetrična** slučajna varijabla, odnosno

$$Z, -Z \sim N(0, 1).$$

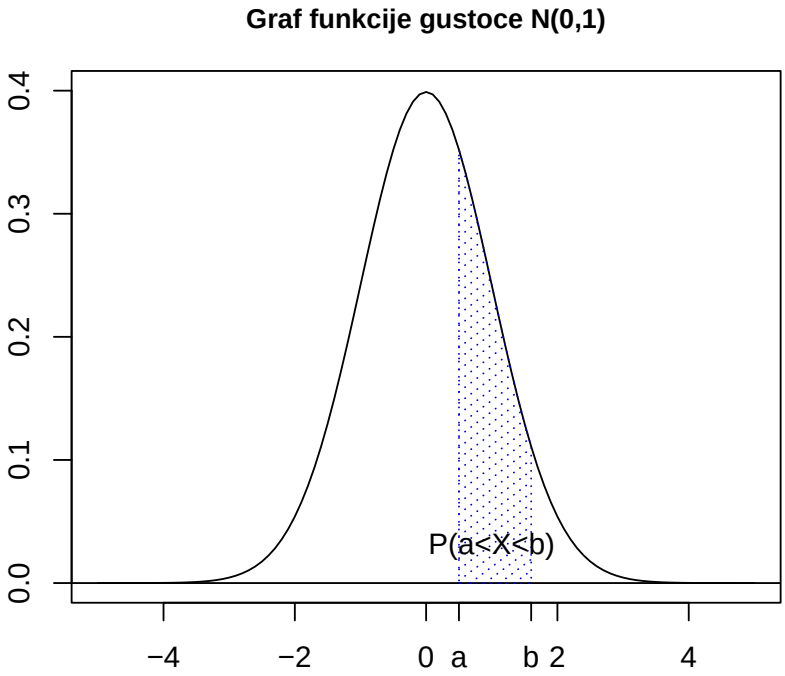
Za Z jedničnu normalnu slučajnu varijablu uobičajeno je koristiti oznaku Φ za njenu funkciju distribucije F_Z.

$$\Phi(x) = \int_{-\infty}^{x} \varphi(t)dt = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-t^2/2}dt, \ x \in \mathbb{R}.$$

Za $X \sim N(\mu, \sigma^2)$ i $a, b \in \mathbb{R}$, $a < b$, imamo

$$P(a < X < b) = \Phi\Big(\frac{b-\mu}{\sigma}\Big) - \Phi\Big(\frac{a-\mu}{\sigma}\Big).$$

Dakle, vjerojatnosti vezane uz općenite slučajne varijable iz normalne razdiobe računamo pomoću jedinične normalne razdiobe.



Neprekidna slučajna varijabla X ima **eksponencijalnu razdiobu** s parametrom λ, $\lambda > 0$, u oznaci $X \sim Exp(\lambda)$, ako joj je funkcija gustoće

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0. \end{cases}$$

Eksponencijalno distribuirana slučajna varijabla X, kao i ona iz geometrijske razdiobe, nema memoriju. Preciznije, za $s, t > 0$ vrijedi

$$P(X > s + t \mid X > t) = P(X > s).$$

Neprekidna slučajna varijabla U ima **uniformnu razdiobu** na intervalu (a, b), $a, b \in \mathbb{R}$, $a < b$, u oznaci $U \sim U(a, b)$, ako joj je funkcija gustoće

$$f_U(x) = \begin{cases} \frac{1}{b-a}, & x \in (a, b) \\ 0, & \text{inače.} \end{cases}$$

Funkcija distribucije od $U(a, b)$ je

$$F_U(x) = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & x \in (a, b) \\ 1, & x \geq b. \end{cases}$$

Posebno, U ima **jediničnu** uniformnu razdiobu ako joj je funkcija gustoće dana s

$$f_U(x) = \begin{cases} 1, & x \in (0,1) \\ 0, & \text{inače}, \end{cases}$$

a funkcija distribucije s

$$F_U(x) = \begin{cases} 0, & x \leq 0 \\ x, & x \in (0,1) \\ 1, & x \geq b. \end{cases}$$

Generatori (pseudo-)slučajnih brojeva u raznim programskim paketima su iz jedinične uniformne razdiobe $U(0,1)$, odnosno oni su realizacije slučajne varijable iz te razdiobe. U R-u se slučajni brojevi dobivaju korištenjem funkcije `runif()`.

Uniformna slučajna varijabla ima važna svojstva koja omogućavaju prikaz (simulaciju) drugih razdioba. Ako je X neprekidna slučana varijabla s funkcijom distribucije F_X, onda je

$$F_X(X) \sim U(0,1).$$

Neka je F funkcija distribucije koja je invertibilna i U jedinična uniformna slučajna varijabla. Definirajmo slučajnu varijablu $X = F^{-1}(U)$. Tada je za $x \in \mathbb{R}$

$$F_X(x) = F(x).$$

Dakle, ako uzmemo funkciju distribucije F i definiramo $X = F^{-1}(U)$, onda slučajna varijabla X ima funkciju distribucije F. Generirajući realizacije slučajne varijable U dobivamo realizacije slučajne varijable X s funkcijom distribucije F.

Neprekidna slučajna varijabla X ima **Paretovu razdiobu** s parametrom $\alpha > 0$ ako joj je funkcija gustoće

$$f_X(x) = \begin{cases} \frac{\alpha}{x^{\alpha+1}}, & x \geq 1 \\ 0, & x < 1. \end{cases}$$

Za slučajne varijable X s Paretovom razdiobom češće se gleda njena **repna distribucija** $\bar{F}_X$ od same funkcije distribucije. Imamo sljedeću formulu za repnu distribuciju

$$\bar{F}_X(x) = P(X > x) = \begin{cases} \frac{1}{x^{\alpha}}, & x \geq 1 \\ 1, & x < 1. \end{cases}$$

Općenito, za X slučajnu varijablu definiramo **repnu vjerojatnost** kao

$$P(X > x)$$

gdje je x neki realan broj.

5.7 Zadaci

Zadatak 5.7.1. *Pogledajte primjer 5.1.7 u kojem opisujemo slučajno bacanje dvije simetrične kockice. Definirajmo slučajnu varijablu na Ω sa*

$$R(\{(i,j)\}) = i - j, \ i,j \in \{1,2,3,4,5,6\}.$$

Nađite razdiobu slučajne varijable R.

Zadatak 5.7.2. *Provjerite da je funkcija P_2 iz Primjera 5.2.3 zaista vjerojatnost.*

Zadatak 5.7.3. *Uzmimo slučajnu varijablu V iz Primjera 5.2.7 čija je razdioba zadana s*

$$V \sim \begin{pmatrix} 0 & 1 & 3 & 6 & 10 \\ 1/2 & 1/4 & 1/8 & 1/16 & 1/16 \end{pmatrix}.$$

Izračunajte sljedeće vjerojatnosti:

a) $P(V \in [1,8]) = P(2 \leq V \leq 8)$,

b) $P(V \in (7,20) = P(7 < V < 20)$,

c) $P(V > 8)$,

d) $P(V \in [1,6]) = P(1 \leq V \leq 6)$,

e) $P(V \in (1,6) = P(1 < V < 6)$,

d) $P(V < 0)$.

Zadatak 5.7.4. *Zadana je sljedeća razdioba*

$$\begin{pmatrix} -2 & 0 & 1 & 2 \\ 2/9 & 1/3 & a & 2/9 \end{pmatrix}.$$

Koliki mora biti broj a da bi to zaista bila razdioba neke slučajne varijable? Neka je Y diskretna slučajna varijabla koja ima gore navedenu razdiobu. Izračunajte $P(Y \geq 1)$ i $P(Y < 1)$.

Zadatak 5.7.5. *Bacamo simetričan novčić 5 puta uzastopno, pri čemu su bacanja nezavisna. Koja je vjerojatnost da će:*

1) barem u jednom bacanju pasti glava?

2) u dva bacanja pasti glava?

3) samo u trećem i četvtom bacanju pasti glava?

4) u trećem i četvrtom bacanju pasti glava?

Zadatak 5.7.6. *Riješite zadatak 5.7.5 ako je novčić nesimetričan (ili modeliramo neki drugi slučajni događaj s dva moguća ishoda) pri čemu je vjerojatnost da će pasti glava jednaka $0,6$, a vjerojatnost da će pasti pismo je jednaka $0,4$.*

Zadatak 5.7.7. *Bliži se kraj godine i u poduzeću B analiziraju podatke o isporučenim pošiljkama svojim kupcima. U godini je isporučeno 200 pošiljki kupcima i u svakoj se pošiljci nalazila barem jedna staklena boca (s raznim sadržajima). Prema pritužbama svojih kupaca poduzeće B zna da su u 2 pošiljke bile razbijene boce te su morali ponovno dostaviti naručene proizvode svojim kupcima. Iz tih podataka u poduzeću B procjenjuju da do njihovih kupaca stižu ispravne pošiljke u 99% slučajeva. Razumno je pretpostaviti da se mogućnost razbijanja boce u bilo kojoj od pošiljki događa neovisno o drugim pošiljkama jer se sve pošiljke pakiraju na isti način. Za sljedeću godinu poduzeće B očekuje udvostručenje pošiljki koje će poslati svojim kupcima. U poduzeću bi htjeli znati koliko je vjerojatno*

a) da će sljedeće godine sve pošiljke biti isporučene kupcima bez loma boca

b) da će biti više od 4 pošiljke u kojima su boce razbijene.

Izračunajte te vjerojatnosti da pomognete poduzeću u planiranju troškova sljedeće godine.

Zadatak 5.7.8. *U odjeljku o geometrijskoj razdiobi smo naveli da za X slučajnu varijablu iz geometrijske razdiobe s parametrom p vrijedi*

$$P(X > n) = (1-p)^n$$

za prirodni broj n. Dokažite to. Usput uočite da odmah zaključujemo da za funkciju distribucije geometrijske slučajne varijable vrijedi

$$F_X(n) = P(X \leq n) = 1 - P(X > n) = 1 - (1-p)^n, \ n \in \mathbb{N}.$$

Zadatak 5.7.9. *Pretpostavimo da igrate rulet. Na ruletu imamo 37 polja (ograđenih malim pregradama) poredanih u krug, a na njima su napisani brojevi od nule (označena je zelenom bojom) do 36. Ostali brojevi (osim nule) su označeni crvenom ili crnom bojom, pri čemu je broj crvenih i crnih polja jednak (dakle i jednih i drugih ima 18). Na slučajan način se odabire jedan od tih brojeva (kuglicom). Odlučite se kladiti na crveno polje i igrate niz uzastopnih igara. Jasno, uspjeh je ako se kuglica na ruletu zaustavi na crvenom polju. Izračunajte*

a) vjerojatnost da ćete ostvariti dobitak u trećem pokušaju

b) vjerojatnost da će Vam trebati barem tri pokušaja da ostvarite dobitak

c) broj igara koje su potrebne da s vjerojatnosti $0,95$ ostvarite dobitak.

Zadatak 5.7.10. *Pretpostavimo da je vjerojatnost da ćete dobiti gripu u jednoj zimskoj sezoni $0,1$. Dodatno, pretpostavimo da je mogućnost zaraze gripom u bilo kojoj od zimskih sezona neovisna o zarazi virusom gripe u drugim zimskim sezonama. Izračunajte*

a) vjerojatnost da u 10 zimskih sezona nećete dobiti gripu

b) vjerojatnost da u šestoj zimskoj sezoni nećete dobiti gripu, ako je prije toga niste dobili u prethodnih 5 zimskih sezona.

Zadatak 5.7.11. *U nekom gradskom vijeću se nalazi 18 zastupnika od čega je 10 žena i 8 muškaraca. Uskoro bi delegacija sastavljena od 4 članice ili člana gradskog vijeća trebala otići u radni i prijateljski posjet gradu Rimu. Kako se vijećnici ne mogu dogovoriti oko sastava delegacije, četiri člana delegacije se biraju na slučajan način. Izračunajte*

a) vjerojatnost da će se delegacija sastojati od istog broja žena i muškaraca

b) vjerojatnost da će u delegaciji biti barem jedna žena.

Zadatak 5.7.12. *Zadana je diskretna slučajna varijabla X svojom razdiobom*

$$X \sim \begin{pmatrix} 0 & 1 & 2 & 3 \\ 1/6 & 1/4 & 1/2 & 1/12 \end{pmatrix}.$$

Nađite razdiobu slučajnih varijabli $Y = 2X-3$ i $Z = 1-X^2$. Izrazite funkciju distribucije slučajne varijable Y pomoću F_X (funkcija distribucije slučajne varijable X).

Zadatak 5.7.13. *Zadana je diskretna slučajna varijabla X svojom razdiobom*

$$X \sim \begin{pmatrix} -2 & -1 & 1 & 2 \\ 0,2 & 0,3 & 0,3 & 0,2 \end{pmatrix}.$$

Nađite razdiobu slučajne varijable $|X|$ (apsolutna vrijednost od X).

Zadatak 5.7.14. *Zadana je funkcija*

$$g(x) = \begin{cases} kx, & 0 \leq x \leq 4 \\ 0, & \text{inače.} \end{cases}$$

Odredite konstantu k da bi g bila vjerojatnosna funkcija gustoće. Neka je X slučajna varijabla kojoj je funkcija gustoće g. Izračunajte $P(X \leq 1)$ i $P(X \in [1,3])$. Odredite funkciju distribucije slučajne varijable X.

Zadatak 5.7.15. *Zadana je funkcija*

$$f(x) = \frac{c}{1+x^2}, \quad x \in \mathbb{R}.$$

Odredite konstantu c da bi f bila vjerojatnosna funkcija gustoće. Neka je X slučajna varijabla kojoj je funkcija gustoće f. Izračunajte $P(X \geq 1)$ i $P(|X| \leq 1)$. Odredite funkciju distribucije slučajne varijable X.

Zadatak 5.7.16. *Neka je $X \sim N(0,4)$. Izračunajte $P(|X| \leq 2)$, $P(|X| \leq 4)$ i $P(|X| \leq 6)$. (Uputa: pogledajte Primjer 5.4.6.)*

Zadatak 5.7.17. *Neka je Z jedinična normalna slučajna varijabla, $Z \sim N(0,1)$, a S diskretna slučajna varijabla čija je razdioba*

$$S \sim \begin{pmatrix} -1 & 1 \\ 1/2 & 1/2 \end{pmatrix}.$$

Pokažite da je $SZ \sim N(0,1)$. (Uputa: probajte izračunati funkciju distribucije slučajne varijable SZ.)

Zadatak 5.7.18. *U primjeru 5.4.15 smo se upoznali s Gumbelovom razdiobom i vidjeli da joj je funkcija distribucije dana s*

$$F(x) = e^{(-e^{-x})}, \ x \in \mathbb{R}.$$

Neka je $X \exp(1)$, jedinična eksponencijalna slučajna varijabla. Pokažite da je tada $Y = -\ln(X)$ slučajna varijabla s Gumbelovom razdiobom. (Uputa: koristite funkciju distribucije eksponencijalne razdiobe po uzoru na zadnji račun koji smo pokazali u odjeljku 5.4.1.4 o Paretovoj razdiobi.)

Zadatak 5.7.19. *Ispitajte da li su sljedeće funkcije vjerojatnosne funkcije distribucije*

1. *$F(x) = 0$, za $x \in (-\infty, 0)$, i $F(x) = e^{-x}$, za $x \in [0, \infty)$*
2. *$F(x) = 0$, za $x \in (-\infty, 0)$, i $F(x) = 2x$, za $x \in [0, \infty)$*
3. *$F(x) = 0$, za $x \in (-\infty, 0)$, i $F(x) = x/2$, za $x \in [0, 2]$, $F(x) = 1$, za ≥ 2*
4. *$F(x) = 0$, za $x \in (-\infty, 0)$, i $F(x) = \sin(x)$, za $x \in [0, \infty)$*
5. *$F(x) = 0$, za $x \in (-\infty, 0)$, i $F(x) = |\sin(x)|$, za $x \in [0, \infty)$ ($|\cdot|$ je apsolutna vrijednost)*

Zadatak 5.7.20. *Neka je $Z \sim N(0,1)$ (jedinična normalna slučajna varijabla). Definiramo novu slučajnu varijablu $X = Z^2$. Funkcija gustoće slučajne varijable X je prilično komplicirana, ali i bez njenog znanja, a koristeći se funkcijom distribucije slučajne varijable Z, možemo računati razne vjerojatnosti. Probajte izračunati $P(1 \leq X \leq 4)$ na taj način.*

5.7.1 Rješenja zadataka

Rješenje 48 (Zadatak 5.7.1). Prema definiciji 5.2.2 trebamo naći funkciju $p_R : \mathbb{R} \to [0,1]$ za koju je

$$p_R(x) = P(R = x),\ x \in \mathbb{R}.$$

Vidjeli smo da se to za diskretne slučajne varijable svede na pronalazak svih mogućih vrijednosti $a_1, a_2 \ldots, a_n$ slučajne varijable R te pripadnih vjerojatnosti

$$p_R(a_i) = P(R = a_i) = P(\{\omega \in \Omega \mid R(\omega) = a_i\}) = p_i.$$

Vrijednosti slučajne varijable R su razlike brojeva koji su pali na prvoj kockici i brojeva koji su pali na drugoj kockici. Stoga se moguće vrijednosti slučajne varijable R kreću od najmanje -5, koju dobijemo kada na prvoj kockici padne 1, a na drugoj 6, pa sve do najveće 5, kada na prvoj kockici padne 6, a na drugoj 1. Dakle, moguće vrijednosti slučajne varijable R su

$$a_1 = -5, a_2 = -4, a_3 = -3, a_4 = -2, a_5 = -1, a_6 = 0, a_7 = 1, a_8 = 2, a_9 = 3, a_{10} = 4, a_{11} = 5.$$

Izračunajmo pripadne vjerojatnosti za sve vrijednosti a_i slučajne varijable R. Uočimo simetriju vjerojatosti oko vrijednosti 0.
Prvo želimo odrediti vjerojatnost da je R jednaka -5, odnosno

$$P(R = -5) = P(\{\omega \in \Omega \mid R(\omega) = -5\}).$$

Dakle, pitamo se za koje je elemente $\omega \in \Omega : R(\omega) = -5$. Elementi skupa Ω su uređeni parovi (i,j), $i,j = 1,2,\ldots,6$ pa se pitamo za koji je uređeni par (i,j) $R(\{(i,j)\}) = i - j = -5$. Jasno je da je to moguće jedino za $i = 1$ i $j = 6$. Dakle,

$$\{\omega \in \Omega \mid R(\omega) = -5\} = \{(1,6)\}.$$

Kako su kockice simetrične svi elementi su jednako vjerojatni, a ima ih 36, pa je

$$p_1 = P(R = -5) = P(\{\omega \in \Omega \mid R(\omega) = -5\}) = P(\{(1,6)\}) = \frac{1}{36}.$$

Da si olakšamo posao s izračunom svih vjerojatnosti p_i, $i = 1,2,\ldots,11$, odmah uočimo da je i skup $\omega \in \Omega : R(\omega) = 5$ jednočlan jer sadrži samo element $\{(6,1)\} \in \Omega$ (razlika brojeva na prvoj i drugoj kockici može biti jednaka 5 samo ako je na prvoj kockici pao broj 6, a na drugoj 1). Stoga je

$$p_{11} = P(R = 5) = P(\{\omega \in \Omega \mid R(\omega) = -5\}) = P(\{(1,6)\}) = \frac{1}{36}.$$

Sada na isti način nastavimo izračun ostalih vjerojatnosti p_i. Pitamo se koji su to elementi iz Ω, dakle uređeni parovi oblika (i,j) za koje je $R(\{(i,j)\}) = i - j = -4$. Sada su to uređeni parovi $\{(2,6)\}$ i $\{(1,5)\}$. Stoga je

$$p_2 = P(R = -4) = P(\{\omega \in \Omega \mid R(\omega) = -4\}) = P(\{(2,6),(1,5)\}) = \frac{2}{36}.$$

Opet, zbog simetrije, vidimo da je $R(\{(i,j)\}) = i - j = 4$ za uređeni parovi $\{(2,6)\}$ i $\{(1,5)\}$ pa je

$$p_{10} = P(R = 4) = P(\{\omega \in \Omega \mid R(\omega) = -4\}) = P(\{(6,2),(5,1)\}) = \frac{2}{36}.$$

Slično vidimo da je

$$p_3 = P(R = -3) = P(\{\omega \in \Omega \mid R(\omega) = -3\}) = P(\{(3,6),(2,5),(1,4)\}) = \frac{3}{36} \quad \text{i}$$

$$p_9 = P(R = 3) = P(\{\omega \in \Omega \mid R(\omega) = 3\}) = P(\{(6,3),(5,2),(4,1)\}) = \frac{3}{36}.$$

Nadalje imamo

$$p_4 = P(R = -2) = P(\{(4,6),(3,5),(2,4),(1,3)\}) = \frac{4}{36} \quad \text{i}$$

$$p_8 = P(R = 2) = P(\{(6,4),(5,3),(4,2),(3,1)\}) = \frac{4}{36}$$

te

$$p_5 = P(R = -1) = P(\{(5,6),(4,5),(3,4),(2,3),(1,2)\}) = \frac{5}{36} \quad \text{i}$$

$$p_7 = P(R = 1) = P(\{(6,5),(5,4),(4,3),(3,2),(2,1)\}) = \frac{5}{36}.$$

Napokon je

$$p_6 = P(R = 0) = P(\{(6,6),(5,5),(4,4),(3,3),(2,2),(1,1)\}) = \frac{6}{36}.$$

Dakle, razdioba slučajne varijable R je dana s

$$R \sim \begin{pmatrix} -5 & -4 & -3 & -2 & 1 & 0 & 1 & 2 & 3 & 4 & 5 \\ 1/36 & 2/36 & 3/36 & 4/36 & 5/36 & 6/36 & 5/36 & 4/36 & 3/36 & 2/36 & 1/36 \end{pmatrix}.$$

Rješenje 49 (Zadatak 5.7.2)**.** Sjetimo se, funkciju P_2 smo definirali na svim elementima skupa Ω_2 tako da smo definirali

$$P_2(a) = P_2(f) = P_2(j) = \frac{1}{6},\ P_2(\{b\}) = P_2(\{c\}) = P_2(\{d\}) = P_2(\{e\}) = \frac{1}{12}$$

i

$$P_2(g) = P_2(h) = P_2(i) = \frac{1}{18}.$$

Da bi funkcija P_2 bila vjerojatnost, mora zadovoljavati aksiome vjerojatnosti iz Definicije 4.1.2. Da bismo mogli provjeriti te aksiome, trebamo znati kako P_2 djeluje na podskupovima skupa Ω_2. No, to je djelovanje samorazumljivo jer definiramo da P_2 na podskupovima od Ω_2 djeluje tako da joj je vrijednost jednaka zbroju vrijednosti na pojedinačnim elementima. Tako, na primjer, za $\{a,b,c\} \subset \Omega_2$ imamo

$$P_2(\{a,b,c\}) = P_2(a) + P_2(b) + P_2(c) = \frac{1}{6} + \frac{1}{12} + \frac{1}{12} = \frac{4}{12} = \frac{1}{3}.$$

Zbog takve definicije je jasno da je P_2 konačno aditivna pa vrijedi svojstvo (3) iz Definicije 4.1.2 (prebrojiva aditivnost se u ovom slučaju svede na konačnu aditivnost jer je skup Ω_2, pa onda i $\mathcal{P}(\Omega_2)$, konačan). Uočite da se ovakav postupak uvijek može provesti kada je vjerojatnost zadana na svim elementima (konačnog ili prebrojivog) skupa. Tu smo konstrukciju pažljivije komentirali na kraju potpoglavlja 4.1 gdje smo pokazali da je vjerojatnost na diskretnim vjerojatnosnim prostorima u potpunosti zadana vrijednostima koje postiže na elementarnim događajima.
S obzirom da se gore opisani postupak uvijek može provesti treba biti svjestan te činjenice, ali za rješavanje ovakvog zadatka ne treba uvijek ispočetka ponavljati taj postupak. Stoga se rješavanje ovog zadatka svede na provjeru uvjeta (1) i (2) iz Definicije 4.1.2, odnosno provjeru da je zadana funkcija nenegativna i da je vjerojatnost cijelog skupa jednaka 1.

P_2 je očito nenegativna (sve vrijednosti koje poprima su nenegativne), a provjera uvjeta $P_2(\Omega_2) = 1$ se svede na provjeru zahtjeva da je zbroj vjerojatnosti svih elemenata iz Ω_2 (dakle, elementarnih događaja) jednak 1. Naime, zbog konačne aditivnosti je

$$P_2(\Omega_2) = P_2(a) + P_2(b) + P_2(c) + P_2(d) + P_2(e) + P_2(f) + P_2(g) + P_2(h) + P_2(i) + P_2(j).$$

Želimo provjeriti da je zbroj s desne strane gornje jednakosti jednak 1. Taj je zbroj, prema definiciji funkcije P_2, jednak

$$\frac{1}{6} + \frac{1}{12} + \frac{1}{12} + \frac{1}{12} + \frac{1}{12} + \frac{1}{6} + \frac{1}{18} + \frac{1}{18} + \frac{1}{18} + \frac{1}{6} = \frac{3}{6} + \frac{4}{12} + \frac{3}{18} = \frac{1}{2} + \frac{1}{3} + \frac{1}{6} = 1.$$

Dakle, P_2 je vjerojatnost.

Rješenje 50 (Zadatak 5.7.3)**.** Zadatak se lagano riješi ako se sjetimo općenite relacije (5.5) u kojoj smo konstatirali da za diskretnu slučajnu varijablu X i proizvoljan skup $B \subset \mathbb{R}$ vrijedi

$$P(X \in B) \sum_{\{i:a_i \in B\}} P(X = a_i).$$

Skup B može biti oblika $[1, 8]$, $(7, 20)$, $(8, \infty)$ ili $(-\infty, 0)$, a suma u gornjoj formuli se uzima po onim indeksima i za koje je $a_i \in B$, gdje su a_i moguće vrijednosti diskretne slučajne varijable X. Nemojmo zaboraviti da su u drugom redu tabličnog prikaza razdiobe vjerojatnosti $p_i = P(X = a_i)$.
Sada primjenimo relaciju (5.5) na slučajnu varijablu V. Iz razdiobe slučajne varijable V "čitamo" da su vrijednosti slučajne varijable V redom $a_1 = 0$, $a_2 = 1$, $a_3 = 3$, $a_4 = 6$, i $a_5 = 10$, dok su odgovarajuće vjerojatnosti $p_1 = 1/2$, $p_2 = 1/4$, $p_3 = 1/8$, $p_4 = 1/16$ i $p_5 = 1/16$. Izračunajmo tražene vjerojatnosti.
a) Pitamo se za koje su indekse i vrijednosti a_i slučajne varijable V u segmentu $[1, 8]$. Vidimo da su to vrijednosti $a_2 = 1$, $a_3 = 3$ i $a_4 = 6$. Prema (5.5) je

$$P(V \in [1, 8]) = \sum_{i=2}^{4} p_i = p_2 + p_3 + p_4 = \frac{1}{4} + \frac{1}{8} + \frac{1}{16} = \frac{7}{16}.$$

b) Pitamo se za koje su indekse i vrijednosti a_i slučajne varijable V u intervalu $(7, 20)$. Vidimo da je samo $a_5 = 10 \in (7, 20)$ pa je

$$P(V \in (7, 20)) = p_5 = \frac{1}{16}.$$

c) Pitamo se za koje su indekse i vrijednosti a_i slučajne varijable V veće od 8, odnosno u intervalu $(8, \infty)$. Vidimo da je opet samo $a_5 = 10 \in (7, 20)$ pa je

$$P(V > 8) = p_5 = \frac{1}{16}.$$

d) Pitamo se za koje su indekse i vrijednosti a_i slučajne varijable V u segmentu $[1, 6]$. Vidimo da su to vrijednosti $a_2 = 1$, $a_3 = 3$ i $a_4 = 6$. Prema (5.5) je

$$P(V \in [1, 6]) = \sum_{i=2}^{4} p_i = p_2 + p_3 + p_4 = \frac{1}{4} + \frac{1}{8} + \frac{1}{16} = \frac{7}{16}.$$

e) Pitamo se za koje su indekse i vrijednosti a_i slučajne varijable V u intervalu $(1, 6)$. Uočimo da interval $(1, 6)$ ne sadrži svoje rubove - točke 1 i 6. Stoga je samo $a_3 = 3 \in (1, 6)$ pa je

$$P(V \in (1, 6)) = P(1 < V < 6) = p_3 = \frac{1}{8}.$$

f) Pitamo se za koje su indekse i vrijednosti a_i slučajne varijable V manje od nule, odnosno u intervalu $(-\infty, o)$. S obzirom da su sve vrijednosti slučajne varijable V nenegativne niti jedna od vrijednosti slučajne varijable V nije u $(-\infty, o)$. Stoga je

$$P(V < 0) = 0.$$

To je u osnovi jasno i zato što je $\{V < 0\} = \emptyset$.

Rješenje 51 (Zadatak 5.7.4)**.** Da bi razdioba zadana u zadatku zaista bila vjerojatnosna razdioba neke diskretne slučajne varijable zbroj vjerojatnosti u donjem retku treba biti jednak 1. Ako niste sigurni zašto podsjetite se relacije (5.3). Dakle, mora vrijediti

$$\frac{2}{9} + \frac{1}{3} + a + \frac{2}{9} = 1$$

pa jednostavno vidimo da je $a = 2/9$. Stoga je

$$Y \sim \begin{pmatrix} -2 & 0 & 1 & 2 \\ 2/9 & 1/3 & 2/9 & 2/9 \end{pmatrix}.$$

Sada možemo lagano izračunati navedene vjerojatnosti. Iako smo izračun takvih vjerojatnosti detaljno prikazali u prethodnom zadatku, ponovimo to i ovdje. Iz razdiobe slučajne varijable Y "čitamo" da su vrijednosti slučajne varijable Y redom $a_1 = -2$, $a_2 = 0$, $a_3 = 1$ i $a_4 = 2$, dok su odgovarajuće vjerojatnosti $p_1 = 2/9$, $p_2 = 1/3$, $p_3 = 2/9$ i $p_4 = 2/9$.
Da bi izračunali vjerojatnost $P(Y \geq 1)$ trebamo odrediti sve indekse i za koje su vrijednosti a_i slučajne varijable Y u intervalu $[1, \infty)$. Vidimo da se samo vrijednosti $a_3 = 1$ i $a_4 = 2$ nalaze u $[1, \infty)$ pa prema (5.5) izračunamo

$$P(Y \geq 1) = P(Y \in [1, \infty)) = \sum_{i=3}^{4} p_i = p_3 + p_4 = \frac{2}{9} + \frac{2}{9} = \frac{4}{9}.$$

Slično, uočimo da se samo vrijednosti slučajne varijable Y $a_1 = -2$ i $a_2 = 0$ nalaze u $(-\infty, 1)$ pa je prema (5.5)

$$P(Y < 1) = P(Y \in (-\infty, 1)) = \sum_{i=1}^{2} p_i = p_1 + p_2 = \frac{2}{9} + \frac{1}{3} = \frac{5}{9}.$$

Vjerojatnost $P(Y < 1)$ možemo i lakše izračunati tako da uočimo da je $(-\infty, 1)^c = [1, \infty)$. Stoga su slučajni događaji $\{Y \geq 1\}$ i $\{Y < 1\}$ suprotni događaji pa je prema formuli za izračun vjerojatnosti suprotnog događaja(svojstvo (2) u Propoziciji 4.1.3)

$$P(Y < 1) = P(\{Y \geq 1\}^c) = 1 - P(Y \geq 1) = 1 - \frac{4}{9} = \frac{5}{9}.$$

Rješenje 52 (Zadatak 5.7.5)**.** S obzirom da je novčić simetričan, dosta lagano možemo prebrajanjem slučajeva izračunati sve tražene vjerojatnosti. Ipak, korisno je uočiti da je prirodan okvir za rješavanje nezavisnog ponavljanja slučajnog eksperimenta s dva ishoda uvođenje binomne slučajne varijable.
S obzirom da je novčić simetričan ukupan broj mogućnosti ishoda bacanja je u svim slučajevima jednak i iznosi $2^5 = 32$ (na svakom od 5 mjesta može biti pismo ili glava (0 ili 1) pa prema principu produkta slijedi tvrdnja). Iako se ovaj zadatak može riješiti korištenjem slučajnih varijabli, korisno se prisjetiti potpoglavlja 4.4.
1) U pravilu je kod odgovora na takva pitanja pogodno koristiti formulu za vjerojatnost suprotnog (komplementarnog) događaja: $P(A^c) = 1 - P(A)$. Ako je $A =$ "barem u

jednom bacanju je pala glava", onda je A^c = "niti jednom nije pala glava", a to znači da je u svakom bacanju palo pismo. No taj je događaj (skup) jednočlan, a kako su svi ishodi bacanja jednako vjerojatni njegova je vjerojatnost jednaka $(1/2)^5$. Stoga je tražena vjerojatnost jednaka $1-1/2^5 = 31/32 \approx 0,9688$ (uočite da je i $P(A) = 1-P(A^c)$, ako imate dvojbu).

2) Za odgovor na drugo pitanje ne treba puno filozofirati (iako je u fazi učenja korisno provesti mentalnu vježbu prebrajanja - pogledajte odjeljak o binomnoj slučajnoj varijabli i Primjer 5.2.9) pa odmah uočimo da 5 nezavisnih bacanja novčića modeliramo binomnom slučajnom varijablom s parametrima 5 i $p = 1/2$ jer je novčić simetričan. Stoga je tražena vjerojatnost jednaka vjerojatnosti da je binomna slučajna varijabla $B(5, 1/2)$ jednaka 2, a to je jednako

$$\binom{5}{2}(1/2)^2(1/2)^3 = 10/2^5 = 0,3125.$$

Treće i četvrto pitanje izgledaju slično pa je potrebno malo razmisliti što se točno traži u svakom pitanju.

3) U trećem pitanju se zapravo pita koja je vjerojatnost da će u 5 bacanja biti ostvaren raspored $(0, 0, 1, 1, 0) = (P, P, G, G, P)$. Kako je to samo jedan od 32 moguća rasporeda jasno je da je odgovor na treće pitanje 1/32.

4) U četvrtom pitanju se kaže samo da je u trećem i četvrtom bacanju pala glava, ali se ne kaže što je palo u prvom, drugom i petom bacanju. Stoga trebamo prebrojati sve mogućnosti koje uključuju prvo, drugo i peto bacanje. No, tih je mogućnosti jednako broju mogućnosti ishoda 3 nezavisna bacanja simetričnog novčića što je jednako 2^3. Stoga je tražena vjerojatnost jednaka $2^3/2^5 = 1/4 = 0,25$. Iako je ovo rješenje jasno, vrijedi se prisjetiti i produktne vjerojatnosti u potpoglavlju 4.4, odnosno Primjera 4.4.1, u kojem smo detaljno raspisivali skupove iz produktnog prostora koji nastaje nezavisnim ponavljanjem slučajnog eksperimenta.

U skladu s time označimo s Ω_1 skup ishoda slučajnog eksperimenta bacanja simetričnog novčića $\{0, 1\} = \{P, G\}$. Na njemu je zadana vjerojatnost P_1 takva da je $P_1(0) = P_1(1) = 1/2$ jer je novčić simetričan. Definirajmo produktni prostor $\Omega = \Omega_1^5$ koji modelira slučajni eksperiment 5 nezavisnih bacanja simetričnog novčića. Na Ω je definirana produktna vjerojatnost P (pogledajte relacije (4.8), odnosno (4.9)). Sada slučajni događaj iz 4. dijela zadatka možemo zapisati kao

$$C = \Omega_1 \times \Omega_1 \times \{1\} \times \{1\} \times \Omega_1.$$

Prema definiciji produktne vjerojatnosti je

$$P(C) = P_1(\Omega_1)P_1(\Omega_1)P_1(\{1\})P_1(\{1\})P_1(\Omega_1) = 1 \cdot 1 \cdot \frac{1}{2} \cdot \frac{1}{2} \cdot 1 = \frac{1}{4},$$

što smo već bili izračunali.

Rješenje 53 (Zadatak 5.7.6)**.** Ovaj zadatak je vezan na prethodni pa samo nastavljamo s rješavanjem. Ono što odmah možemo uočiti da svi ishodi 5 nezavisnih bacanja nesimetričnog novčića nisu jednako vjerojatni pa ne možemo iskoristiti argumentaciju koju smo dali već za prvi dio prethodnog zadatka. Jedan način rješavanja zadatka u ovom slučaju je da definirate produktni prostor, kao što smo ga definirali u rješenju četvrtog dijela prethodnog zadatka, pri čemu je $P_1(0) = 0,4$, a $P_1(1) = 0,6$. Tada u prvom dijelu zadatka računamo vjerojatnost $P(A^c) = P_1(0)^5 = 0,4^5$, a dalje napravimo sve kao i prije. I ostali dijelovi zadatka se mogu riješiti analogno, ali kako smo u ovom poglavlju uveli slučajne varijable pogledajmo kako bismo njima riješili ovaj zadatak.

U tu svrhu definirajmo slučajne varijable X_1, X_2, X_3, X_4 i X_5, pri čemu su vrijednosti slučajne varijable X_i jednaki ishodu bacanja novčića u i-tom bacanju. Dakle, vrijednosti

slučajne varijable X_i jednaki su 0 ili 1, u zavisnosti o tome da li je u i-tom bacanju palo pismo ili glava. U skladu s uvjetima zadatka je

$$P(X_i = 0) = 0,4, \quad \text{i} \quad P(X_i = 1) = 0,6, \quad i = 1,2,3,4,5.$$

Dakle, sve su slučajne varijable X_i jednako distribuirane te im je razdioba dana s

$$X_i \sim \begin{pmatrix} 0 & 1 \\ 0,4 & 0,6 \end{pmatrix},$$

$i = 1,2,3,4,5$. Prepoznajemo da su X_i Bernoullijeve slučajne varijable s parametrom $p = 0,6$. One su nezavisne. Kako to znamo? Formalno, mogli bi u tu svrhu iskoristiti Teorem 5.2.14, ali stvar je u tome da će to uvijek biti slučaj kada imamo nezavisna izvođenja nekog slučajnog eksperimenta i ako se slučajne varijable odnose na pojedinačna izvođenja slučajnog eksperimenta. Ovo uvijek možete, i trebate, iskoristiti. Važno je paziti da se svaka od slučajnih varijabli koje promatramo odnosi na različita nezavisna izvođenja slučajnog eksperimenta, odnosno da vrijednost neke od slučajnih varijabli koje promatramo ne ovisi o vrijednostima drugih slučajnih varijabli. Na primjer, da je X_3 jednaka $X_2 + X_4$ ne bi više imali nezavisne slučajne varijable.
U svakom slučaju, ishode 5 nezavisnih bacanja nesimetričnog novčića iz ovog zadatka možemo modelirati nezavisnim Bernoullijevim slučajnim varijablama X_1, X_2, X_3, X_4, X_5 s parametrom $p = 0,6$. Pogledajmo kako sada možemo riješiti zadatak.
1) Opet je najjednostavniji put onaj u kojem definiramo $A =$ "barem u jednom bacanju je pala glava" pa je $A^c =$ "u svim bacanjima je palo pismo". Sada je (sjetite se, zarezi označavaju presjeke za skupove)

$$A^c = \{X_1 = 0, X_2 = 0, X_3 = 0, X_4 = 0, X_5 = 0\}.$$

Jer su X_i, $i = 1,2,3,4,5$, nezavisne slučajne varijable, prema Teoremu 5.2.14 slijedi

$$P(A^c) = P(X_1 = 0)P(X_2 = 0)P(X_3 = 0)P(X_4 = 0)P(X_5 = 0) = 0,4^5 \tag{5.59}$$

pa je tražena vjerojatnost

$$P(A) = 1 - 0,4^5 \approx 0,9898.$$

Uočite, skraćeni zapis vjerojatnosti slučajnih događaja vezanih uz slučajne varijable koji smo uveli u Napomeni 5.1.3 definitivno zahtjeva određenu dozu apstrahizacije, ali on je gotovo pa nužan. Razmislite kako bi izgledala formula (5.59) da ne koristimo taj skraćeni zapis.
2) U potpoglavlju 5.2.4 o nezavisnim slučajnim varijablama smo vidjeli da za nezavisne slučajne varijable X_1, X_2, X_3, X_4, X_5 iz Bernoullijeve razdiobe s parametrom p vrijedi da im je zbroj distribuiran kao binomna slučajna varijabla, odnosno

$$X_1 + X_2 + X_3 + X_4 + X_5 \sim B\ (n, p).$$

Ovakva karakterizacija binomne slučajne varijable je toliko često korištena u vjerojatnosti da se može smatrati alternativnom definicijom binomne slučajne varijable. I u sljedećem poglavlju ćemo vidjeti da takav rpikaz binomne slučajne varijable može olakšati razne izračune.
U drugom dijelu zadatka se pitamo koja je vjerojatnost da će točno dvije od 5 nezavisnih Bernoullijevih slučajnih varijabli X_1, X_2, X_3, X_4, X_5 biti jednake 1, a ostale će biti jednake 0. To znači da se pitamo kolika je vjerojatnost da je $X_1 + X_2 + X_3 + X_4 + X_5 = 2$. No, jer je taj zbroj iz binomne razdiobe znamo da je ta vjerojatnost jednaka

$$\binom{5}{2}(p)^2(1-p)^3 = \binom{5}{2}0,6^2 0,4^3 = 0,2304.$$

3) U ovom dijelu zadatka se pitamo koja je vjerojatnost slučajnog događaja

$$\{X_1 = 0, X_2 = 0, X_3 = 1, X_4 = 1, X_5 = 0\}.$$

Zbog nezavisnosti slučajnih varijabli X_i, $i = 1, 2, 3, 4, 5$, a prema Teoremu 5.2.14 slijedi da je tražena vjerojatnost jednaka

$$P(X_1 = 0)P(X_2 = 0)P(X_3 = 1)P(X_4 = 1)P(X_5 = 0) = 0,4 \cdot 0,4 \cdot 0,6 \cdot 0,6 \cdot 0,4 = 0,02304.$$

4) U ovom dijelu zadatka se pitamo koja je vjerojatnost slučajnog događaja

$$\{X_3 = 1, X_4 = 1\}.$$

U osnovi je to isto kao da računamo vjerojatnost događaja

$$\{X_1 \in \{0,1\}, X_2 \in \{0,1\}, X_3 = 1, X_4 = 1, X_5 \in \{0,1\}\}$$

jer je $X_i \in \{0,1\} = \Omega$. U svakom slučaju, zbog nezavisnosti, dobivamo da je tražena vjerojatnost

$$P(X_3 = 1)P(X_4 = 1) = 0,6 \cdot 0,6 = 0,36.$$

Rješenje 54 (Zadatak 5.7.7)**.** Ako smatramo da je uspjeh isporuka ispravne pošiljke kupcu, a neuspjeh isporuka u kojoj je razbijena boca, te uz pretpostavku o 400 isporučenih pošiljki u sljedećoj godini, broj ispravno isporučenih pošiljki u sljedećoj godini možemo smatrati binomnom slučajnom varijablom $B \sim B(400, 0.99)$. Prema interpretaciji binomne slučajne varijable možemo izračunati tražene vjerojatnosti.
a) Tražimo vjerojatnost $P(B = 0)$. Znamo da je

$$P(B = 0) = \binom{400}{0} 0,99^{400} 0,01^0 = 0,99^{400} = 0,01795.$$

Vidimo da je ova vjerojatnost vrlo mala.
b) U ovom dijelu zadatka se traži $P(B > 4)$. S obzirom na broj pribrojnika koje treba računati lakše je izračunati $P(B \leq 4)$ i onda formulom potpune vjerojatnosti dobiti traženu vjerojatnost. Kako je

$$P(B \leq 4) = P(B = 0) + P(B = 1) + P(B = 2) + P(B = 3) + P(B = 4)$$

možemo u R-u izračunati traženi vjerojatnost (ili kalkulatorom):

```
> S<-0
> for (i in 0:4) {
+   S<-S+choose(400,i)*0.99^(400-i)*0.01^i
+ }
> S

[1] 0.6288386
```

Dakle, tražena vjerojatnost je

$$P(B > 4) = 1 - 0.6289 = 0.3711.$$

Rješenje 55 (Zadatak 5.7.8)**.** Sjetimo se konteksta geometrijske slučajne varijable: nezavisno ponavljamo slučajni eksperiment u kojem je vjerojatnost uspjeha jednaka $p > 0$. Geometrijska slučajna varijabla X jednaka je broju ponavljanja promatranog slučajnog eksperimenta do prvog uspjeha. Razdioba joj je

$$P(X = k) = (1 - p)^{k-1} p, \ k = 1, 2, 3, \ldots.$$

Prema tome je

$$\begin{aligned} P(X > n) &= P(X \geq n+1) = P(X = n+1) + P(X = n+2) + P(X = n+2) + \dots \\ &= (1-p)^n p + (1-p)^{n+1} p + (1-p)^{n+2} p + \dots \\ &= p(1-p)^{n+1}(1 + (1-p) + (1-p)^2 + \dots) \\ &= p(1-p)^{n+1} \frac{1}{1-(1-p)} = (1-p)^{n+1}, \end{aligned}$$

prema formuli za zbroj geometrijskog reda $\sum_{i=0}^{\infty}(1-p)^i$.

Rješenje 56 (Zadatak 5.7.9)**.** U zadatku imamo niz nezavisnih slučajnih eksperimenata u kojima je vjerojatnost dobitka jednaka

$$p = \frac{18}{37}.$$

Neka je X slučajna varijabla koja je jednaka broju vrtnji ruleta (ponavljanja slučajnog eksperimenta) do prvog zaustavljanja kuglice ruleta na crvenom polju, odnosno do dobitka u igri. Dakle, $X \sim Geom(18/37)$. Odgovori na postavljena pitanja su
a) Tražimo vjerojatnost $P(X = 3)$. S obzirom da je X geometrijska slučajna varijabla imamo

$$P(X = 3) = (1 - 18/37)^2 \cdot 18/37 = 0,1283.$$

b) Pitamo se kolika je vjerojatnost $P(X \leq 3)$. Računamo je

$$\begin{aligned} P(X \leq 3) &= P(X = 1) + P(X = 2) + P(X = 3) \\ &= 18/37 + (1 - 18/37) \cdot 18/37 + (1 - 18/37)^2 \cdot 18/37 = 0,8646. \end{aligned}$$

c) Tražimo n takav da je $P(X \leq n) \geq 0.95$. U prošlom zadatku smo vidjeli da je $P(X \leq n) = 1 - (1 - 18/37)^n$. Dakle, tražimo n takav da je

$$1 - (1 - 18/37)^n \geq 0,95,$$

odnosno

$$(1-p)^n \leq 0,05.$$

Logaritam je rastuća funkcija pa logaritmiranjem gornje nejednakosti dobivamo

$$n \ln(1-p) \leq \ln(0,05).$$

Podijelimo nejednakost s $\ln(1-p)$, koji je negativan broj jer je $1 - p < 1$, pa dobijemo

$$n \geq \frac{\ln(0,05)}{\ln(1-p)}$$

odnosno

$$n \geq 4,495.$$

Dakle, treba nam barem 5 igara da bi s vjerojatnošću $0,95$ bili sigurni da ćemo ostvariti dobitak.

Rješenje 57 (Zadatak 5.7.10)**.** Prema uvjetima zadatka imamo niz nezavisnih slučajnih eksperimenata (oboljevanje od gripe u zimskoj sezoni) pri čemu je vjerojatnost da nećemo oboliti od gripe 0.9, a vjerojatnost da ćemo oboliti od gripe je jednaka $0,1$. U kontekstu slučajnog ponavljanja nezavisnih događaja želimo brojati zimske sezone (godine) u kojima nismo dobili gripu prije nego je dobijemo. Stoga se uspjehom smatra

oboljevanje od gripe, a neuspjehom neoboljevanje od gripe. Ako slučajna varijabla X broji godine koje će proteći do oboljevanja od gripe, onda je, prema uvjetima zadatka, $X \sim Geom(0,1)$.
a) Pitamo se koja je vjerojatnost $P(X > 10)$. Kako je općenito za geometrijsku slučajnu varijablu $P(X > n) = (1-p)^n$, pri čemu je $p = 0,1$, dobivamo

$$P(X > 10) = (1 - 0,1)^{10} = 0,3487.$$

b) Vjerojatnost da u pet sezona nećemo dobiti gripu je $P(X > 5)$, a vjerojatnost da niti u šestoj sezoni nećemo dobiti gripu je $P(X > 6)$ (ne kaže se što će se dogoditi u sedmoj, osmoj ili bilo kojoj sljedećoj godini, ali to nije niti bitno). Želimo izračunati vjerojatnost $P(X > 6 \mid X > 5)$. Prema definiciji uvjetne vjerojatnosti imamo

$$P(X > 6 \mid X > 5) = \frac{P(X > 6 \cap X > 5)}{P(X > 5)} = \frac{P(X > 6)}{P(X > 5)} = \frac{(1 - 0,1)^6}{(1 - 0,1)^5} = (1 - 0,1) = 0,9$$

što je vjerojatnost da u prvoj promatranoj zimskoj sezoni nećemo dobiti gripu. Ovakav rezultat je posljedica činjenice da geometrijska slučajna varijabla ne pamti prethodne neuspjehe (nema memoriju) s čime smo se upoznali u odjeljku o geometrijskoj slučajnoj varijabli. Sjetimo se da isto svojstvo ima eksponencijalna slučajna varijabla koja je neprekidna.

Rješenje 58 (Zadatak 5.7.11)**.** S ovakvim tipom zadatka (odabir delegacije) smo se već susreli u Primjeru 3.3.21. S obzirom da se članovi delegacije biraju na slučajan način svi odabiri 4 člana delegacije od 18 članova vijeća (a ima ih $\binom{18}{4}$) su jednako vjerojatni pa je primjenjiva naivna definicija vjerojatnosti. No, kao i većina primjera i zadataka koji se mogu riješiti korištenjem naivne definicije vjerojatnosti i ovaj se zadatak može riješiti korištenjem konceptualnog okvira slučajnih varijabli pa ovdje dajemo takvo rješenje.
Apstrahirano promatrano u zadatku odabiremo n objekata od ukupno $p + c$ njih (bez ponavljanja) pri čemu imamo p objekata jednog tipa i c objekata drugog tipa. Želimo odrediti vjerojatnost odabira tih n objekata na način da je k odabranih objekata prvog tipa i $n-k$ odabranih objekata drugog tipa. To je konceptulani okvir koji opisuje hipergeometrijska slučajna varijabla X, pri čemu je vrijednost slučajne varijable X jednaka broju odabranih objekata prvog tipa. Naravno, time je određen i broj odabranih objekata drugog tipa, ali da bi dobro definirali slučajnu varijablu X trebamo odrediti koji su objekti prvog tipa, a koji drugog.
U slučaju ovog zadatka imamo 18 vjećnika od čega je $p = 10$ žena i $c = 8$ muškaraca. Biramo ukupno $n = 4$ člana vijeća. Slučajna varijabla X jednaka je broju odabranih žena u odabiru 4 člana vijeća. Izračunajmo tražene vjerojatnosti.
a) Računamo vjerojatnost $P(X = 2)$. Prema definiciji razdiobe hipergeometrijske slučajne varijable je

$$P(X = 2) = \frac{\binom{10}{2}\binom{8}{2}}{\binom{18}{4}} = 0,4118.$$

b) Želimo izračunati vjerojatnost $P(X \geq 1)$. Naravno,

$$P(X \geq 1) = P(X = 1) + P(X = 2) + P(X = 3) + P(X = 4),$$

ali je lakše izračunati vjerojatnost suprotnog događaja. Prema tome je tražena vjerojatnost

$$P(X \geq 1) = 1 - P(X = 0) = 1 - \frac{\binom{8}{4}}{\binom{18}{4}} = 0,977.$$

Rješenje 59 (Zadatak 5.7.12)**.** Kao što smo vidjeli u Primjeru 5.2.18 (pogledajte ga) trebamo najprije odrediti vrijednosti slučajne varijable Y. Slučajna varijabla Y je kompozicija funkcije $g(x) = 2x - 3$ i slučajne varijable X. Kao što znamo diskretne slučajne varijable prirodno induciraju particiju prostora elementarnih događaja Ω (na kojem je definirana slučajna varijabla X). Konkretno,

$$\begin{aligned}
&\text{za } \omega \in A_1 = \{X = 0\} = \{\omega \in \Omega \mid X(\omega) = 0\} \quad \text{je} \quad X(\omega) = 0,\\
&\text{za } \omega \in A_2 = \{X = 1\} = \{\omega \in \Omega \mid X(\omega) = 1\} \quad \text{je} \quad X(\omega) = 1,\\
&\text{za } \omega \in A_3 = \{X = 2\} = \{\omega \in \Omega \mid X(\omega) = 2\} \quad \text{je} \quad X(\omega) = 2,\\
&\text{za } \omega \in A_4 = \{X = 3\} = \{\omega \in \Omega \mid X(\omega) = 3\} \quad \text{je} \quad X(\omega) = 3
\end{aligned}$$

te je $\{A_1, A_2, A_3, A_4\}$ particija skupa Ω (pogledajte Primjer 4.2.4). Sada je

$$\begin{aligned}
&\text{za } \omega \in A_1 \quad \text{je} \quad Y(\omega) = 2 \cdot X(\omega) - 3 = 2 \cdot 0 - 3 = -3,\\
&\text{za } \omega \in A_2 \quad \text{je} \quad Y(\omega) = 2 \cdot X(\omega) - 3 = 2 \cdot 1 - 3 = -1,\\
&\text{za } \omega \in A_3 \quad \text{je} \quad Y(\omega) = 2 \cdot X(\omega) - 3 = 2 \cdot 2 - 3 = 1 \quad \text{i}\\
&\text{za } \omega \in A_4 \quad \text{je} \quad Y(\omega) = 2 \cdot X(\omega) - 3 = 2 \cdot 3 - 3 = 3.
\end{aligned}$$

Dakle, vrijedosti koje postiže slučajna varijabla Y su $-3, -1, 1$ i 3. Ujedno je

$$\begin{aligned}
P(Y = -3) = P(X = 0) = P(A_1) &= \frac{1}{6}\\
P(Y = -1) = P(X = 1) = P(A_2) &= \frac{1}{4}\\
P(Y = 1) = P(X = 2) = P(A_3) &= \frac{1}{2} \quad \text{i}\\
P(Y = 3) = P(X = 3) = P(A_4) &= \frac{1}{12}.
\end{aligned}$$

Dakle, razdioba od Y je dana s

$$Y \sim \begin{pmatrix} -3 & -1 & 1 & 3 \\ 1/6 & 1/4 & 1/2 & 1/12 \end{pmatrix}.$$

Izrazito smo detaljno raspisali rješenje ovog dijela zadatka da ne ostavimo nedoumice oko izračuna koji se provode. U osnovi se može argumentirati i jednostavnije. Funkcija g je bijekcija, vrijednosti $0, 1, 2, 3$ preslikava, redom, u brojeve $-3, -1, 1, 3$, a pripadne vjerojatnosti ostaju nepromijenjene jer nije došlo do "ljepljenja" točaka (zbog bijektivnosti od g).
Odmah možemo vidjeti kako računati funkciju distribucije od Y:

$$F_Y(x) = P(Y \leq x) = P(2X - 3 \leq x) = P\Big(X \leq \frac{x+3}{2}\Big) = F_X\Big(\frac{x+3}{2}\Big).$$

Razdiobu slučajne varijable Z nalazimo slično kao i onu slučajne varijable Y. Uočimo da funkcija $h(x) = 1 - x^2$ nije bijekcija (injektivnost je problematična), ali na skupu nenegativnih realnih, pa i cijelih, brojeva je bijekcija. To je u ovom slučaju dovoljno jer su vrijednosti slučajne varijable X nenegativne. Stoga nema nekih značajnih razlika u računu u odnosu na račun koji smo proveli za pronalazak razdiobe od Y. Samo trebamo paziti koja se vrijednost slučajne varijable X preslikava u koju od vrijednosti slučajne varijable $h(X) = 1 - X^2$ te koje su pripadne vjerojatnosti. Naime, kada je

$X = 0$, vrijednost od $1 - X^2$ je jednaka 1 i ta se vrijednost postiže s vjerojatnošću $P(X = 0) = 1/6$.
Nadalje, kada je $X = 1$, vrijednost od $1 - X^2$ je jednaka 0 i ta se vrijednost postiže s vjerojatnošću $P(X = 1) = 1/4$, a kada je $X = 2$, vrijednost od $1-X^2$ je jednaka -3 i ta se vrijednost postiže s vjerojatnošću $P(X = 2) = 1/2$. Napokon, kada je $X = 3$, vrijednost od $1 - X^2$ je jednaka -8 i ta se vrijednost postiže s vjerojatnošću $P(X = 3) = 1/12$. Prema uobičajenom zapisu je razdioba slučajne varijable $Z = 1 - X^2$

$$Z \sim \begin{pmatrix} -8 & -3 & 0 & 1 \\ 1/12 & 1/2 & 1/4 & 1/6 \end{pmatrix}.$$

Stvar je u tome da je u razdiobi uobičajeno navoditi vrijednosti slučajne varijable u rastućem redoslijedu, ali načelno govoreći ne bi bila greška kada to i ne bismo napravili.

Rješenje 60 (Zadatak 5.7.13)**.** Trebamo naći razdiobu slučajne varijable $Y = |X|$ koja je kompozicija funkcija $g(x) = |x|$ i slučajne varijable X. U ovom slučaju funkcija g nije bijekcija pa trebamo malo paziti prilikom određivanja vjerojatnosti s kojima se postižu vrijednosti slučajne varijable Y.
Prije svega uočimo da su vrijednosti slučajne varijable Y brojevi 1 i 2 jer je $g(-1) = |-1| = 1 = g(1)$ i $g(-2) = |-2| = 1 = g(2)$. Nadalje, uočimo da je, zbog konačne aditivnosti,

$$P(Y = 1) = P(\{X = -1\} \cup \{X = 1\}) = P(X = -1) + P(X = 1) = 0,3 + 0,3 = 0,6 \quad \text{i}$$

$$P(Y = 2) = P(\{X = -2\} \cup \{X = 2\}) = P(X = -2) + P(X = 2) = 0,2 + 0,2 = 0,4.$$

Stoga je razdioba slučajne varijable $Y = |X|$

$$Y \sim \begin{pmatrix} 1 & 2 \\ 0,6 & 0,4 \end{pmatrix}.$$

To nije važno za ovaj zadatak, ali uočimo da je $Y = B + 1$, gdje je $B \sim Ber(0,4)$ (Bernoullijeva slučajna varijabla s parametrom $0,4$). Sada bi već trebalo biti jasno kako se to (lagano) pokaže.

Rješenje 61 (Zadatak 5.7.14)**.** Funkcija g je nenegativna, a da bi bila funkcija gustoće mora vrijediti

$$\int_{-\infty}^{\infty} g(x)dx = 1,$$

odnosno

$$k\int_0^4 xdx = k\frac{x^2}{2}\Big|_{x=0}^{x=4} = k\Big(\frac{4^2}{2} - \frac{0^2}{2}\Big) = 8k = 1.$$

Stoga je $k = 1/8$ pa je Zadana je funkcija

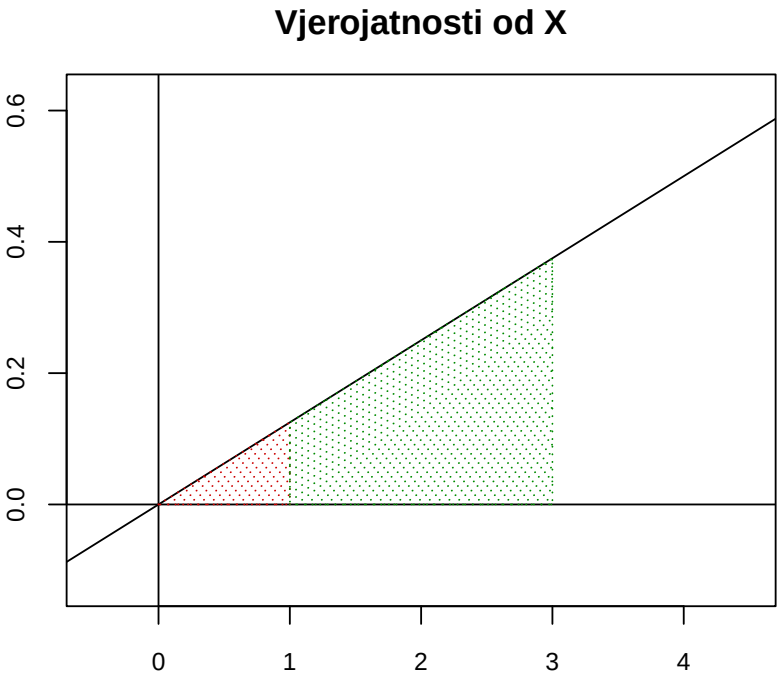
$$g(x) = \begin{cases} \frac{1}{8}x, & 0 \le x \le 4 \\ 0, & \text{inače.} \end{cases}$$

Računamo tražene vjerojatnosti. Imamo

$$P(X \le 1) = \int_{-\infty}^{1} g(x)dx = \frac{1}{8}\int_0^4 xdx = \frac{1}{8}\frac{x^2}{2}\Big|_{x=0}^{x=1} = \frac{1}{8}\frac{1}{2} = \frac{1}{16} \quad \text{i}$$

$$P(1 \le X \le 3) = \frac{1}{8}\int_1^3 xdx = \frac{1}{8}\frac{x^2}{2}\Big|_{x=1}^{x=3} = \frac{1}{8}\Big(\frac{3^2}{2} - \frac{1^2}{2}\Big) = \frac{1}{8}\cdot\frac{8}{2} = \frac{1}{2}.$$

Na donjoj slici su zorno prikazane izračunate vjerojatnosti. Sjetimo se, one su jednake površini ispod funkcije gustoće na promatranim intervalima, ili segmentima, što je za neprekidne slučajne varijable nevažno jer je vjerojatnost postizanja bilo koje pojedinačne točke jednaka nuli.



Vjerojatnost $P(X \leq 1)$ je prikazana crvenom bojom, a $P(1 \leq X \leq 3)$ zelenom bojom. Još je preostalo da izračunamo funkciju distribucije F_X. Prema definiciji imamo

$$F_X(x) = P(X \leq x) = \frac{1}{8}\int_0^x t dt = \frac{1}{8}\frac{t^2}{2}\Big|_{t=0}^{t=x} = \frac{1}{8}\frac{t^2}{2} = \frac{1}{16}t^2, \quad x \in \mathbb{R}.$$

Rješenje 62 (Zadatak 5.7.15)**.** Funkcija f je nenegativna, a da bi bila funkcija gustoće mora vrijediti

$$\int_{-\infty}^{\infty} f(x)dx = 1,$$

odnosno

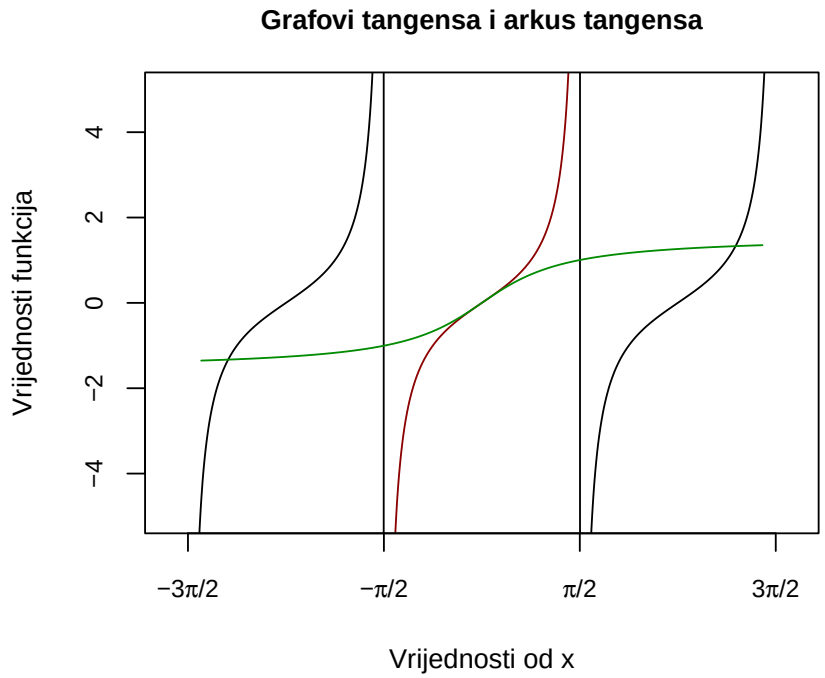
$$\begin{aligned}\int_{-\infty}^{\infty} f(x)dx &= c\int_{-\infty}^{\infty} \frac{1}{1+x^2}dx = c\arctan(x)\Big|_{x=-\infty}^{x=\infty} \\ &= c(\arctan(\infty) - \arctan(-\infty)) = c(\frac{\pi}{2} - (-\frac{\pi}{2})) = \pi c = 1\end{aligned}$$

pa je $c = 1/\pi$. S arctan je označena funkcija arkus tangens, a u gornjem računu[28] smo koristili jednu od osnovnih tabeliranih vrijednosti neodređenog integrala

$$\int \frac{1}{1+x^2}dx = \arctan(x) + C.$$

Potrebno je napomenuti da je funkcija tengens periodička (s periodom π) pa nema inverz. Stoga se najčešće gleda tako zvana glavna vrijednost tangensa, odnosno funkcija tan : $(-\pi/2, \pi/2) \to \mathbb{R}$ čija je inverzna funkcija arkus tangens kojoj je domena cijeli skup $\mathbb{R}$, a kodomena $(-\pi/2, \pi/2)$.

[28] Formalno smo trebali umjesto $\arctan(\infty)$ pisati $\lim_{x\to\infty} \arctan(x)$ i slično za $\arctan(-\infty)$, ali izračun je isti kao onaj naveden u zadatku.



Na slici je prikazan graf funkcije tangens pri čemu je restrikcija tangensa na $(-\pi/2, \pi/2)$ prikazana crvenom bojom, a njegov inverz arkus tangens zelenom bojom. Vertikalne linije predstavljaju asimptote funkcije tangens u točkama u kojima nije definiran, odnosno u kojima teži $\pm\infty$.

Izračunajmo tražene vjerojatnosti slučajne varijable X čija je funkcija gustoće f. Imamo najprije

$$\begin{aligned} P(X \geq 1) &= \frac{1}{\pi}\int_1^{\infty} \frac{1}{1+x^2}dx = \frac{1}{\pi}\arctan(x)\Big|_{x=1}^{x=\infty} \\ &= \frac{1}{\pi}(\arctan(\infty) - \arctan(1)) = \frac{1}{\pi}\Big(\frac{\pi}{2} - \frac{\pi}{4}\Big) = \frac{1}{4}. \end{aligned}$$

Kako je funkcija gustoće f parna računamo i

$$\begin{aligned} P(|X| \leq 1) = P(-1 \leq X \leq 1) &= \frac{1}{\pi}\int_{-1}^{1} \frac{1}{1+x^2}dx = 2\frac{1}{\pi}\int_0^1 \frac{1}{1+x^2}dx \\ &= \frac{2}{\pi}\arctan(x)\Big|_{x=0}^{x=1} = \frac{2}{\pi}(\arctan(1) - \arctan(0)) = \frac{2}{\pi}\Big(\frac{\pi}{4} - 0\Big) = \frac{1}{2}. \end{aligned}$$

Na sličan način možemo izračunati i funkciju distribucije slučajne varijable X. Imamo

$$\begin{aligned} F_X(x) = P(X \leq x) &= \frac{1}{\pi}\int_{-\infty}^{x} \frac{1}{1+t^2}dt = \frac{1}{\pi}(\arctan(x) - \arctan(-\infty)) \\ &= \frac{1}{\pi}\Big(\arctan(x) - \Big(-\frac{\pi}{2}\Big)\Big) = \frac{1}{\pi}\arctan(x) + \frac{1}{2}, \quad x \in \mathbb{R}. \end{aligned}$$

Uočimo za kraj još jednu činjenicu. Neprekidne slučajne varijable zadajemo uglavnom funkcijom gustoće, ali isto bismo mogli napraviti i tako da zadamo funkciju distribucije jer je

$$F_X'(x) = f_X(x).$$

U kontekstu ovog zadatka, da smo zadali slučajnu varijablu X funkcijom distribucije F_X, imali bi

$$f_X(x) = F_X'(x) = \Big(\frac{1}{\pi}\arctan(x) + \frac{1}{2}\Big)' = \frac{1}{\pi}\frac{1}{1+x^2}, \quad x \in \mathbb{R}.$$

Rješenje 63 (Zadatak 5.7.16)**.** Probleme u kojima trebamo izračunati određene vjerojatnosti vezane uz normalne razdiobe rješavamo tako da ih svedemo na izračune vezane uz jediničnu normalnu razdiobu pri čemu je poveznica dana u relaciji (5.31).
U ovom zadatku imamo $X \sim N(0,4)$ što znači da je $\mu = 0$, a $\sigma = 2$. Prema (5.31) imamo

$$P(|X| \leq 2) = P(-2 \leq X \leq 2) = \Phi\Big(\frac{2}{2}\Big) - \Phi\Big(\frac{-2}{2}\Big) = \Phi(1) - \Phi(-1). \tag{5.60}$$

U Primjeru 5.4.6 smo već vidjeli da je ta vjerojatnost jednaka $0,68269$. U R-u imamo

```
> pnorm(1,0,1)-pnorm(-1,0,1)

[1] 0.6826895
```

Na sličan način vidimo da je

$$P(|X| \leq 4) = P(-4 \leq X \leq 4) = \Phi\Big(\frac{4}{2}\Big) - \Phi\Big(\frac{-4}{2}\Big) = \Phi(2) - \Phi(-2)$$

što je jednako $0,9545$ jer je

```
> pnorm(2,0,1)-pnorm(-2,0,1)

[1] 0.9544997
```

Napokon,

$$P(|X| \leq 6) = P(-6 \leq X \leq 6) = \Phi\Big(\frac{6}{2}\Big) - \Phi\Big(\frac{-6}{2}\Big) = \Phi(3) - \Phi(-3)$$

što je jednako $0,9973$ jer je

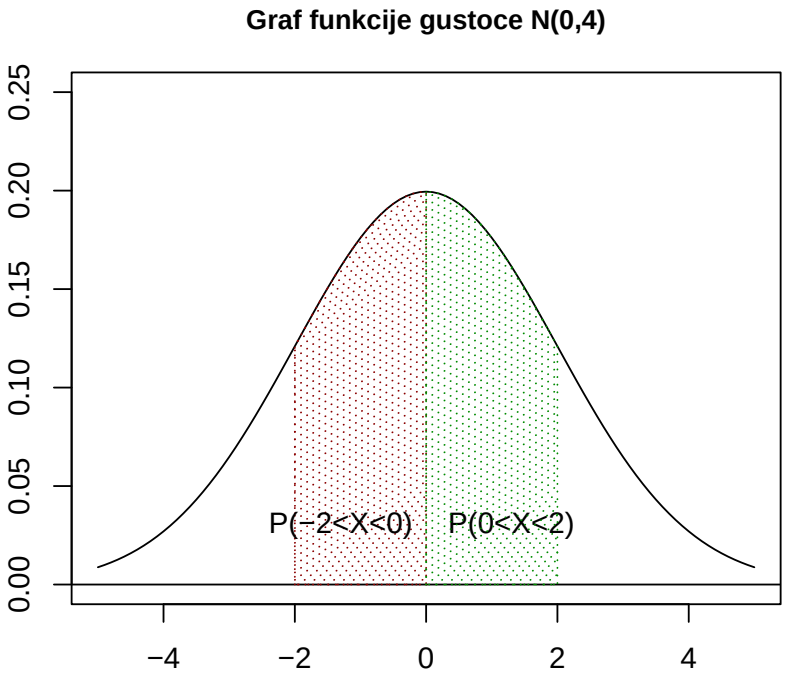
```
> pnorm(3,0,1)-pnorm(-3,0,1)

[1] 0.9973002
```

S obzirom da je normalna razdioba od velike važnosti i u vjerojatnosti i u statistici pogledajmo još jedan način na koji možemo računati tražene vjerojatnosti. Naime, napomenuli smo da je funkcija gustoće normalne razdiobe parna za $\mu = 0$ pa je zbog svojstava integrala parnih funkcija vjerojatnost u (5.60) moguće izračunati i kao

$$\begin{aligned} P(|X| \leq 2) &= P(-2 \leq X \leq 2) = 2P(0 \leq X \leq 2) \\ &= 2(\Phi(1) - \Phi(0)) = 2(\Phi(1) - 1/2) = 2 \cdot 0,341345 = 0,68269. \end{aligned}$$

U gornjem nizu jednakost smo iskoristili da je $\Phi(0) = 1/2$ što opet znamo zbog parnosti funkcije gustoće normalne slučajne varijable i činjenice da je integral funkcije gustoće na cijelom $\mathbb{R}$ jednak 1. Na donjoj slici prikazujemo vjerojatnosti $P(0 \leq X \leq 2)$ zelenom bojom i $P(-2 \leq X \leq 0)$ crvenom bojom. Te su dvije jednakost jednake pa je njihov zbroj, a to je vjerojatnost $P(-2 \leq X \leq 2)$, jednak $2P(0 \leq X \leq 2)$.



Rješenje 64 (Zadatak 5.7.17). Izračunajmo funkciju distribucije slučajne varijable SZ. Iskoristit ćemo činjenicu da slučajna varijabla S poprima samo dvije vrijednosti pa je $\{S = -1\} \cup \{S = 1\} = \Omega$, pri čemu je Ω prostor elementarnih događaja na kojem su definirane obje slučajne varijable. Uočimo da disjunktni skupovi $\{S = -1\}$ i $\{S = 1\}$ čine particiju skupa Ω pa prema formuli potpune vjerojatnosti imamo

$$\begin{aligned} F_{SZ}(x) &= P(SZ \leq x) \\ &= P(SZ \leq x \mid S = -1)P(S = -1) + P(SZ \leq x \mid S = 11)P(S = 1) \\ &= P(Z \leq x)\frac{1}{2} + P(-Z \leq x)\frac{1}{2} = P(Z \leq x)\frac{1}{2} + P(Z \geq -x)\frac{1}{2} \\ &= P(Z \leq x)\frac{1}{2} + P(Z \leq x)\frac{1}{2} = P(Z \leq x) = \Phi(x), \ x \in \mathbb{R}. \end{aligned}$$

Kako se funkcije distribucije slučajnih varijabli SZ i Z podudaraju, one imaju istu razdiobu pa je $SZ \sim N(0, 1)$.

Rješenje 65 (Zadatak 5.7.18). Za $X \sim Exp(1)$ i $Y = -\ln(X)$ imamo

$$\begin{aligned} F_Y(x) &= P(Y \leq x) = P(-\ln(X) \leq x) = P(\ln(X) \geq -x) \\ &= P\left(e^{\ln(X)} \geq e^{-x}\right) = P(X \geq e^{-x}) = e^{-e^{-x}}, \ x \in \mathbb{R}, \end{aligned}$$

jer je $P(X > x) = e^{-x}$ za $X \sim Exp(1)$. Prema tome je funkcija distribucije slučajne varijable Y jednaka funkciji distribucije Gumbelove razdiobe pa je razdioba slučajne varijable $Y = -\ln(X)$ Gumbelova.

Rješenje 66 (Zadatak 5.7.19). Osnovna svojstva vjerojatnosne funkcije distribucije su navedena u Propoziciji 5.2.5. Dakle, svaka vjerojatnosna funkcije distribucije mora zadovoljavati sva ta svojstva. Ako barem jedno od njih ne zadovoljava, onda promatrana funkcija nije funkcija distribucije.[29] Pogledajmo sada funkcije iz zadatka

[29] Ovo slijedi prema osnovnoj verziji De Morganove formule za sudove. Konkretno, ako su A, B, C i D sudovi (ili formule logike prvoga reda), onda je $\neg(A \cap B \cap C \cap D) \equiv \neg A \cup \neg B \cup \neg C \cup \neg D$, gdje je $\equiv$ oznaka za logičku ekvivalenciju.

1) Nije funkcija distribucije. Naime, funkcija distribucije je funkcija koja mora biti, između ostaloga, neopadajuća. Funkcija e^{-x} je padajuća na $[0, \infty)$ pa to nije (vjerojatnosna) funkcija distribucije.
2) Nije funkcija distribucije. Funkcija F je rastuća, neprekidna i vrijednost joj je jednaka nuli za $x \to -\infty$. No, $F(x) \to \infty$, kada x raste (odnosno za $x \to \infty$), a trebala bi konvergirati prema 1 da bi bila vjerojatnosna funkcija dsitribucije.
3) Je funkcija distribucije. Funkcija F je rastuća, neprekidna, vrijednost joj je jednaka nuli za $x \to -\infty$ i $F(x) \to 1$ za $x \to \infty$.
4) Nije funkcija distribucije. Sjetite se da je funkcija distribucije zapravo jednaka vjerojatnosti, a vjerojatnost ne može biti negativna pa je funkcija distribucije u svim točkama nenegativna. Funkcija sinus nije nenegativna jer je, na primjer, $\sin(3\pi/2) = -1$.
5) Nije funkcija distribucije. Sada je funkcija $F(x) = \sin(x)|$ nenegativna, ali nije neopadajuća jer, na primjer, na intervalu $[\pi/2, \pi]$ pada. Nacrtajte u R-u tu funkciju da se uvjerite.

Rješenje 67 (Zadatak 5.7.20)**.** Najprije uočimo da je

$$P(1 \leq X \leq 4) = P(\{-2 \leq Z \leq -1\} \cup \{1 \leq Z \leq 2\}) = P(-2 \leq Z \leq -1) + P(1 \leq Z \leq 2).$$

Pošto Z ima simetričnu funkciju gustoće (oko nule) znamo da je $P(-2 \leq Z \leq -1) = P(1 \leq Z \leq 2)$. Prema tome,

$$P(1 \leq X \leq 4) = 2P(1 \leq Z \leq 2) = 2(\Phi(2) - \Phi(1)),$$

gdje je Φ oznaka za funkciju distribucije normalne slučajne varijable. Vrijednosti od $\Phi(2)$ i $\Phi(1)$ su tabelirane, a možemo ih izračunati i u R-u korištenjem funkcije `pnorm()`. Dobivamo

```
> pnorm(2)

[1] 0.9772499

> pnorm(1)

[1] 0.8413447
```

pa je

$$P(1 \leq X \leq 4) = 2 \cdot (0,9772499 - 0,8413447) = 0,2718104.$$

Među rješenjima zadataka smo imali tri slike (grafa). Kako nam je jedan od ciljeva usvojiti neke tehnike baratanja i prikazivanja podataka u R-u dajemo R-kod tih grafova.

```
> par(mar=c(2,3,3,2))
> x<- seq(-1,5, 0.1)
> y<-x/8
> plot(x, y, xlim=c(-0.5,4.5), main="Vjerojatnosti od X",
+      cex=0.7, type="l", cex.axis=0.8)
> abline(h=0)
> abline(v=0)
> x1<- c(0,1)
> y1<-c(0,1/8)
> polygon(x = c(0, x1, 1), y = c(0, y1, 0),col = "red3",
+         density = 30, angle = 37, lty =3)
```

```
> x2<- c(1,3)
> y2<-c(1/8,3/8)
> polygon(x = c(1, x2, 3), y = c(0, y2, 0),col = "green4",
+         density = 30, angle = 37, lty =3)



> par(mar=c(4,4,3,2))
> x.values = seq(-pi/2,pi/2, length = 1000)
> y.values = tan(x.values)
> oznakex<-c(expression(paste("-3",pi, "/2")),
+            expression(paste("-",pi, "/2")),
+            expression(paste(,pi, "/2")),
+            expression(paste("3",pi, "/2")))
> plot(x.values, y.values, type="l", lty=1, xlab="Vrijednosti od x",
+      xlim=c(-5,5), ylim=c(-5,5), ylab="Vrijednosti funkcija",
+      main="Grafovi tangensa i arkus tangensa",
+      cex.main=0.9, cex.axis=0.8, col="red4", xaxt="n", cex.lab=0.9)
> axis(1, at=c(-3*pi/2, -pi/2, pi/2, 3*pi/2),
+      labels=oznakex, cex.axis=0.8)
> x1<-seq(-3*pi/2,-pi/2, length = 1000)
> y1 = tan(x1)
> lines(x1, y1, type="l", lty=1, xlim=c(-5,5), ylim=c(-5,5),
+       xaxt="n", yaxt="n")
> x2<-seq(pi/2,3*pi/2, length = 1000)
> y2 = tan(x2)
> lines(x2, y2, type="l", lty=1, xlim=c(-5,5), ylim=c(-5,5),
+       xaxt="n", yaxt="n")
> x3<-seq(-4.5,4.5, length = 1000)
> y3 = atan(x3)
> lines(x3, y3, type="l", lty=1, xlim=c(-5,5), ylim=c(-5,5),
+       xaxt="n", yaxt="n", col="green4")



> par(mar=c(2,3,3,2))
> x<- seq(-5,5, 0.1)
> y<-dnorm(x, 0,2)
> plot(x, y, xlim=c(-5,5), ylim=c(0,0.25), cex.main=0.9,
+      main="Graf funkcije gustoće N(0,4)", cex=0.7, type="l")
> abline(h=0)
> x<- seq(-2, 0, 0.1)
> y<-dnorm(x, 0,2)
> polygon(x = c(-2, x, 0), y = c(0, y, 0),col = "red4",
+         density = 30, angle = 37, lty =3)
> text(1.3, 0.03, "P(0<X<2)", col="black")
> x<- seq(0, 2, 0.1)
> y<-dnorm(x, 0,2)
> polygon(x = c(0, x, 2), y = c(0, y, 0),col = "green4",
+         density = 30, angle = 37, lty =3)
> text(-1.3, 0.03, "P(-2<X<0)", col="black")
```

Poglavlje 6

Matematičko očekivanje i granični teoremi

U prošlom poglavlju smo uveli pojam slučajne varijable. Slučajne varijable nam omogućavaju proučavanje raznih kvantitativnih pojava bez detaljne razrade vjerojatnosnih prostora kojima modeliramo slučajne eksperimente. Vidjeli smo da se slučajne varijable mogu, vjerojatnosno gledano, u potpunosti opisati funkcijom razdiobe u diskretnom slučaju, odnosno funkcijom gustoće u neprekidnom slučaju. Razdiobe slučajnih varijabli mogu biti kompleksne ili sadržavati velik broj različitih mogućih vrijednosti (u diskretnom slučaju) i često se javlja potreba da se opišu nekim jednostavnim numeričkim karakteristikama. Matematičko očekivanje je temeljni pojam koji omogućava sažimanje informacija o slučajnim varijablama. Ono je korisno i u situacijama kada želimo odrediti neke osnovne značajke uzorka podatka koje dobivamo o nekom slučajnom eksperimentu. Intuitivno, matematičko očekivanje neke slučajne varijable jednako je prosjeku vrijednosti te slučajne varijable. Mogli bi reći da je matematičko očekivanje jednako očekivanoj vrijednosti slučajne varijable, ali potrebno je malo detaljnije objasniti te pojmove što radimo u nastavku teksta. Pokazuje se da je pojam matematičkog očekivanja puno širi od prosječne vrijednosti pa se čak i vjerojatnost može definirati u terminima matematičkog očekivanja. U nastavku ćemo često izostavljati pridjev matematičko u frazi matematičko očekivanje jer neće biti zabune o kakvom očekivanju govorimo.

6.1 Matematičko očekivanje

Započet ćemo ovo potpoglavlje s definicijom matematičkog očekivanja, a nakon toga ćemo razjasniti sam pojam te dati niz primjera računanja matematičkog očekivanja. Kao što smo razlikovali diskretne i neprekidne slučajne varijable te način njihovog zadavanja, tako će se i definicija matematičkog očekivanja razlikovati za ta dva tipa slučajnih varijabli. Započet ćemo s definicijom matematičkog očekivanja za diskretne slučajne varijable.

Definicija 6.1.1. Neka je X diskretna slučajna varijabla s razdiobom

$$X \sim \begin{pmatrix} a_1 & a_2 & \dots & a_n & \dots \\ p_1 & p_2 & \dots & p_n & \dots \end{pmatrix}.$$

Matematičko očekivanje slučajne varijable X (očekivana vrijednost od X, eng. *expectation* ili *mean*) se definira kao

$$EX = E(X) := \sum_{i=1}^{\infty} a_i p_i = \sum_{i=1}^{\infty} a_i P(X = a_i). \tag{6.1}$$

Ukoliko slučajna varijabla X ima konačno mnogo vrijednosti $a_1, a_2, \dots a_n$ njeno je očekivanje jednako

$$EX = \sum_{i=1}^{n} a_i p_i = \sum_{i=1}^{n} a_i P(X = a_i). \tag{6.2}$$

Vidimo da je očekivanje slučajne varijable X realan broj. Mali oprez je potreban u slučajevima u kojima X ima beskonačno mnogo vrijednosti jer tada očekivanje može i ne postojati ili biti jednako $+\infty$ ili $-\infty$. To se može izbjeći ukoliko se dodatno zahtjeva da je $\sum_x |x| P(X = x) < \infty$, gdje se zbraja po svim vrijednostima od X za koje je $P(X = x) > 0$.

Ponekad se za očekivanje slučajne varijable X koristi i oznaka μ, odnosno definira se $\mu = EX$. Za neke jednostavne slučajne varijable se lagano izračuna njihovo očekivanje. Na primjer, za Bernoullijevu slučajnu varijablu X s parametrom p je

$$EX = 0 \cdot (1 - p) + 1 \cdot p = p.$$

Jasno, ako je $p = 1/2$ (slučaj simetričnog novčića), onda je $EX = 1/2$. Nadalje, ako promatramo slučajni eksperiment bacanja jedne kockice, a Y je slučajna varijabla koja je jednaka broju koji je pao na kockici, znamo da je razdioba od Y dana s

$$Y \sim \begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \end{pmatrix}.$$

Njeno je očekivanje, prema relaciji (6.2), jednako

$$EY = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = \frac{21}{6} = 3,5.$$

Malo općenitije, neka je Z slučajna varijabla s uniformnom diskretnom razdiobom koja poprima vrijednosti $a_1, a_2, \dots a_n$. Znamo da je razdioba slučajne varijable Z dana s

$$Z \sim \begin{pmatrix} a_1 & a_2 & \dots & a_n \\ 1/n & 1/n & \dots & 1/n \end{pmatrix}$$

pa joj je očekivanje, opet prema relaciji (6.2), jednako

$$EZ = a_1 \cdot \frac{1}{n} + a_2 \cdot \frac{1}{n} + \ldots + a_n \cdot \frac{1}{n} = \frac{1}{n} \sum_{i=1}^{n} a_i.$$

Vidimo da je u tom slučaju očekivanje slučajne varijable Z jednako aritmetičkoj sredini brojeva $a_1, a_2, \dots a_n$. Stoga se na matematičko očekivanje može gledati kao na poopćenje aritmetičke sredine brojeva. U tom kontekstu se na očekivanje slučajne varijable može gledati kao na mjeru centralnog okupljanja, ali ovaj puta ne brojeva, nego razdiobe slučajnih varijabli. Ipak, matematičko očekivanje slučajnih varijabli je značajno općenitiji pojam, a da bi se upoznali s njegovim punim potencijalom trebamo ga definirati i za neprekidne slučajne varijable. Imamo sljedeću definiciju.

Definicija 6.1.2. Neka je X neprekidna slučajna varijabla čija je funkcija gustoće $f_X(x)$, $x \in \mathbb{R}$. **Matematičko očekivanje slučajne varijable** X se definira kao

$$EX = \int_{-\infty}^{\infty} x f_X(x) dx. \tag{6.3}$$

Uočimo da integral u (6.3) ne mora uvijek postojati pa je potrebno dodati uvjet integrabilnosti

$$\int_{-\infty}^{\infty} |x| f_X(x) dx < \infty$$

da bi očekivanje neprekidne slučajne varijable bilo dobro definirano.

Iako je u slučaju diskretnih slučajnih varijabli dosta jasna interpretacija matematičkog očekivanja kao očekivane vrijednosti slučajne varijable, ta je interpretacija zadržana i u slučaju neprekidnoh slučajnih varijbli. Uočimo da se očekivanje slučajne varijable izražava u istim jedinicama u kojima je bila i sama slučajna varijabla (kilogrami, centimetri, litre, ...).

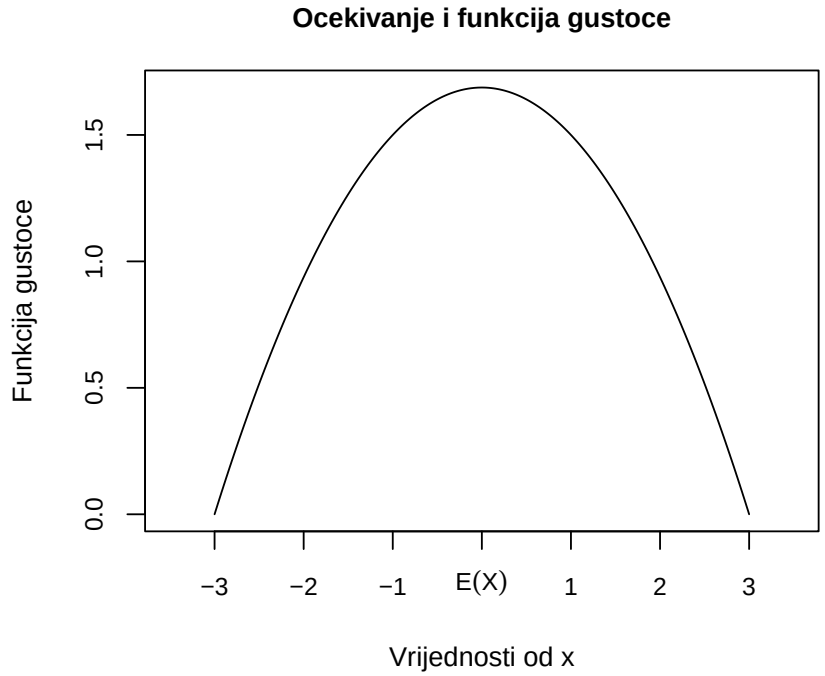
Primjer 6.1.3. Izračunajmo očekivanje neprekidne slučajne varijable X čija je funkcija gustoće ona iz Primjera 5.4.2. Podsjetimo se

$$f(x) = \begin{cases} \frac{1}{36}(9-x^2), & x \in [-3,3] \\ 0, & \text{inače.} \end{cases}$$

Prema (6.3) računamo (matematičko) očekivanje slučajne varijable X

$$\begin{aligned} EX &= \frac{1}{36}\int_{-3}^{3} x(9-x^2)dx = \frac{9}{36}\int_{-3}^{3} xdx - \frac{1}{36}\int_{-3}^{3} x^3dx \\ &= \frac{1}{4}\frac{x^2}{2}\Big|_{x=-3}^{x=3} - \frac{1}{36}\frac{x^4}{4}\Big|_{x=-3}^{x=3} = \frac{1}{4}\Big(\frac{3^2}{2} - \frac{(-3)^2}{2}\Big) - \frac{1}{36}\Big(\frac{3^4}{4} - \frac{(-3)^4}{4}\Big) = 0. \end{aligned}$$

U računskom smislu nas ovaj rezultat ne treba čuditi jer integriramo neparne funkcije $x \mapsto x$ i $x \mapsto x^3$ na simetričnom segmentu $[-3,3]$ pa iz općih svojstava integrala znamo da će integrali tih funkcija biti jednaki nuli.



U sadržajnom smislu je dobivena vrijednost očekivanja slučajne varijable X intuitivno jasna. Naime, kod neprekidnih slučajnih varijabli se matematičko očekivanje nalazi u središtu funkcije gustoće, pri čemu se uzima u obzir i sam izgled funkcije gustoće, odnosno raspodjela površine ispod grafa funkcije gustoće (dakle, vjeorjatnost). Funkcija gustoće je u ovom primjeru simetrična oko nule pa je "očekivana" vrijednost slučajne varijable s tom gustoćom baš nula (pogledajte gornju sliku). Naravno, ta informacija nije sama po sebi dovoljna za malo precizniji opis slučajne varijable X, ali u kombinaciji s varijancom slučajne varijable pruža mogućnost osnovnog kvantitativnog opisa slučajne varijable X. Varijancu slučajne varijable ćemo uskoro definirati. □

Napomena 6.1.4. Ovu napomenu možete slobodno preskočiti. Navodimo ju radi potpunosti.
Ponekad u literaturi možete naići na izraze u kojima se matematičko očekivanje slučajne varijable X izražava kao

$$EX = \int_{-\infty}^{\infty} x dF_X(x),$$

gdje je F_X funkcija distribucije od X. S desne strane gornje nejednakosti se nalazi integral s kojim ne radimo u ovoj skripti, niti smo ga definirali. Riječ je u općenitom slučaju o Lebesgueovom integralu, odnosno Riemann-Stieltjesovom integralu u većini aplikacija. On je poopćenje "običnog" Riemannovog integrala i za njegovo uvođenje je potrebno uvesti pojam mjere i izmjerivosti funkcija. U Napomeni 5.1.2 smo kratko komentirali pojam izmjerivosti, a ovo je još jedno mjesto na kojem bi se mogle dati općenitije definicije od predstavljenih. Primjer funkcije distribucije koja nije ni diskretna ni neprekidna je dan u Napomeni 5.4.17.
Opet napominjemo da se većina nama potrebne teorije može razviti na razini na kojoj je prezentiramo u ovoj skripti. Primjerice, ako je X neprekidna slučajna varijabla s funkcijom gustoće f_X, onda je jednostavno

$$EX = \int_{-\infty}^{\infty} x dF_X(x) = \int_{-\infty}^{\infty} x f_X(x) dx.$$

Slično se dobije i izraz u (6.1), kao poseban slučaj općenitog integrala. Više o ovoj temi se može naći u poglavlju 10 iz [10]. □

6.1.1 Osnovna svojstva matematičkog očekivanja

Matematičko očekivanje ima neka vrlo dobra svojstva koja olakšavaju njegovo računanje. Najvažnija svojstva matematičkog očekivanja navodimo u sljedećem važnom teoremu. Uočimo da je $X \leq Y$ s vjerojatnošću 1 ako je $P(X \leq Y) = P(Y - X \geq 0) = 1$.

Teorem 6.1.5 (Osnovna svojstva matematičkog očekivanja)**.** *Neka su X i Y slučajne varijable te $a, b \in \mathbb{R}$. Tada je*

$$E(aX + bY) = aEX + bEY. \tag{6.4}$$

Ako je $X \leq Y$ s vjerojatnošću 1, onda je

$$EX \leq EY. \tag{6.5}$$

Ako su X i Y nezavisne slučajne varijable, onda je

$$E(XY) = EX \cdot EY. \tag{6.6}$$

Neka je $g : \mathbb{R} \to \mathbb{R}$ neka funkcija.[1] *Tada je $g(X)$ slučajna varijabla. Ako je X diskretna slučajna varijabla s razdiobom*

$$X \sim \begin{pmatrix} a_1 & a_2 & \dots & a_n & \dots \\ p_1 & p_2 & \dots & p_n & \dots \end{pmatrix}.$$

onda je

$$E(g(X)) = \sum_{i=1}^{\infty} g(a_i) p_i = \sum_{i=1}^{\infty} g(a_i) P(X = a_i), \tag{6.7}$$

a ako je X neprekidna slučajna varijabla s funkcijom gustoće f_X, onda je

$$E(g(X)) = \int_{-\infty}^{\infty} g(x) f_X(x) dx. \tag{6.8}$$

[1] U principu g treba biti izmjeriva, ali to je svakako zadovoljeno ako je g neprekidna.

Ovaj teorem zaslužuje nekoliko komentara.

1) Svojstvo (6.4) se naziva **linearnost (matematičkog) očekivanja**, dok se svojstvo (6.5) naziva **monotonost (matematičkog) očekivanja**. S njima smo se već susreli u Teoremu 5.3.1 u kojem smo naveli svojstva integrala. S obzirom da se očekivanje neprekidnih slučajnih varijabli računa kao integral nije iznenađenje da i za očekivanje slučajnih varijabli vrijede ista svojstva. Ona se prilično lagano dokažu i za diskretne slučajne varijable (što ovdje ne činimo). Uočimo da se monotonost očekivanja ne iskazuje uz zahtjev $X(\omega) \leq Y(\omega)$, za sve $\omega \in \Omega$, što bi značilo da je kao funkcija X manja ili jednaka od Y, nego uz zahtjev da je $X(\omega) \leq Y(\omega)$ za ω iz skupa vjerojatnosti 1. U principu zahtjevamo da je $X \leq Y$ gotovo sigurno, što je prirodan zahtjev za slučajne varijable, a u skladu s Nepomenom 5.4.1.

2) Vidjeli smo u primjerima računanja očekivanja diskretnih slučajnih varijabli da sama vrijednost očekivanja ne mora biti jednaka niti jednoj od vrijednosti koju postiže slučajna varijabla. Naravno, ima slučajeva kada je očekivanje jednako nekoj od vrijednosti koje postiže slučajna varijabla, a najjednostavniji je slučaj konstante. S konstantom (konstantnom slučajnom varijablom) smo se susreli u Napomeni 5.2.17. Vidjeli smo da je konstanta slučajna varijabla bez varijabilnosti, $C \equiv c$ za koju je $P(C = c) = 1$, $c \in \mathbb{R}$. U tom slučaju je $EC = c \cdot 1 = c$, odnosno skraćeno zapisano

$$E(c) = c, \ c \in \mathbb{R}.$$

Zaključujemo da je očekivanje broja jednako tom broju.[2]

3) Ukoliko u svojstvu (6.4) uzmemo $b = 0$ i $Y = 0$ vidimo da je

$$E(aX) = aEX, \ a \in \mathbb{R}.$$

Tako je, na primjer, $E(2X) = 2EX$, za proizvoljnu slučajnu varijablu X, ali je i $E(-X) = -EX$.

4) Ukoliko u svojstvu (6.4) uzmemo $a = 1$ i $b = 1$ dobivamo

$$E(X + Y) = EX + EY.$$

Matematičkom indukcijom se to svojstvo lagano proširi na zbroj n slučajnih varijabli. Naime, ako su $X_1, X_2, \ldots, X_n$, $n \in \mathbb{N}$, slučajne varijable, onda za njihov zbroj vrijedi

$$E(X_1 + X_2 + \ldots + X_n) = E(X_1) + E(X_2) + \ldots + E(X_n) \tag{6.9}$$

Kod primjene obje navedene formule potreban je mali oprez. Naime, može se dogoditi da su očekivanja slučajnih varijabli X i Y jednaka $+\infty$, odnosno $-\infty$ (konvergiraju prema $+\infty$ i $-\infty$) pa u izračunu $E(X + Y) = EX + EY$ dobijemo nedefinirani izraz $\infty - \infty$. Stoga obje navedene formule vrijede uz pretpostavku da navedena očekivanja postoje, odnosno da su konačna, što se svede na zahtjev da su konačna očekivanja poput $E|X|$, gdje smo s $|\cdot|$ označili apsolutnu vrijednost broja.

5) U (6.6) vidimo da se očekivanje produkta dvije slučajne posebno lagano računa ako su te dvije slučajne varijable nezavisne. To svojstvo općenito **ne vrijedi bez pretpostavke nezavisnosti** kao što to pokazujemo u Primjeru 6.1.9.

6) Svojstva (6.7) i (6.8) nam omogućavaju da jednostavno računamo očekivanja raznih transformiranih slučajnih varijabli, poput EX^2, $E\sqrt{X}$ ili $E(\sin(X))$. Pogledajmo neke primjere (a kasnije ćemo vidjeti još velik broj njih).

[2] Zapravo je očekivanje konstante, kao slučajne varijable, jednako broju kojem je ta konstanta jednaka, ali skraćeno možemo prihvatiti ovu formulaciju.

Primjer 6.1.6. Uzmimo jednostavnu slučajnu varijablu S kojoj je razdioba dana s

$$S \sim \begin{pmatrix} -1 & 1 \\ 1/2 & 1/2 \end{pmatrix}.$$

Prema (6.1) je očekivanje slučajne varijable S jednako

$$ES = -1 \cdot \frac{1}{2} + 1 \cdot \frac{1}{2} = 0.$$

Prema (6.7), uz funkciju $g(x) = x^2$, je očekivanje slučajne varijable S^2 jednako

$$ES^2 = (-1)^2 \cdot \frac{1}{2} + 1^2 \cdot \frac{1}{2} = \frac{1}{2} + \frac{1}{2} = 1.$$

Očekivanje od S^2 smo mogli izračunati i tako da prvo odredimo razdiobu slučajne varijable S^2, kao što smo to napravili za neke slučajne varijable u Primjeru 5.2.18, pa onda izračunamo očekivanje od S^2, ali nam relacija (6.7) daje mogućnost da traženo očekivanje direktno računamo. □

Primjer 6.1.7. Neka je X diskretna slučajna varijabla zadana razdiobom

$$X \sim \begin{pmatrix} -1 & 0 & 1 & 2 \\ 1/4 & 1/8 & 1/2 & 1/8 \end{pmatrix}.$$

Sa slučajnom varijablom X smo se već susreli u Primjeru 5.2.18 kada smo računali razdiobe slučajnih varijabli $X+2$, $2X$ i X^2. Izračunajmo njihovo očekivanje. S obzirom da znamo razdiobe tih slučajnih varijabli očekivanje im možemo računati prema Definiciji 6.1.1. Probajte to napraviti.
Alternativno, možemo iskoristiti svojstva očekivanja navedena u Teoremu 6.1.5. Izračunajmo najprije očekivanje slučajne varijable X. Imamo

$$EX = -1 \cdot \frac{1}{4} + 0 \cdot \frac{1}{8} + 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{8} = -\frac{1}{4} + \frac{1}{2} + \frac{1}{4} = \frac{1}{2}.$$

Korištenjem linearnosti očekivanja, iskazanoj u relaciji (6.4), za $a = 1$, $b = 2$ i $Y = 1$ računamo

$$E(X+2) = EX + 2 = \frac{1}{2} + 2 = \frac{5}{2},$$

a za $a = 2$ i $b = 0$ dobijemo

$$E(2X) = 2EX = 2 \cdot \frac{1}{2} = 1.$$

Ukoliko želimo izračunati EX^2 iskoristit ćemo relaciju (6.7) s $g(x) = x^2$. Imamo

$$EX^2 = (-1)^2 \cdot \frac{1}{4} + 0^2 \cdot \frac{1}{8} + 1^2 \cdot \frac{1}{2} + 2^2 \cdot \frac{1}{8} = \frac{1}{4} + \frac{1}{2} + \frac{4}{8} = \frac{5}{4}.$$

□

Nadamo se da je jasno da svojstva iz Teorema 6.1.5 značajno olakšavaju izračun očekivanja za zbrojeve slučajnih varijabli ili za slučajne varijable koje se dobivaju kompozicijom s nekim funkcijama. Sljedeći primjer to dodatno ilustrira.

Primjer 6.1.8. Neka su X i Y diskretne slučajne varijable koje su zadane svojim distribucijama

$$X \sim \begin{pmatrix} 1 & 2 & 3 & 6 \\ 1/4 & 1/4 & 1/3 & 1/6 \end{pmatrix} \quad Y \sim \begin{pmatrix} 10 & 20 & 50 \\ 2/3 & 1/4 & 1/12 \end{pmatrix}.$$

Očekivanje od X i Y računamo prema definiciji

$$EX = 1 \cdot \frac{1}{4} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{3} + 6 \cdot \frac{1}{6} = \frac{11}{4} = 2,75$$

dok je

$$EY = 10 \cdot \frac{2}{3} + 20 \cdot \frac{1}{4} + 50 \cdot \frac{1}{12} = \frac{80 + 60 + 50}{12} \approx 15,8333.$$

Zbog linearnosti očekivanja (relacija (6.4) u Teoremu 6.1.5) je

$$E(X + Y) = EX + EY = 2,75 + 15,8333 = 18,58333,$$

ali i

$$E(6Y) = 6EY = 6 \cdot \frac{190}{12} = 95.$$

Formula (6.7) nam kaže da je

$$E(X^2) = 1 \cdot \frac{1}{4} + 4 \cdot \frac{1}{4} + 9 \cdot \frac{1}{3} + 36 \cdot \frac{1}{6} = 10,25,$$

$$E(X^3) = 1 \cdot \frac{1}{4} + 8 \cdot \frac{1}{4} + 27 \cdot \frac{1}{3} + 216 \cdot \frac{1}{6} = 47,25,$$

ali i

$$E(e^X) = e^1 \cdot \frac{1}{4} + e^2 \cdot \frac{1}{4} + e^3 \cdot \frac{1}{3} + e^6 \cdot \frac{1}{6} = 76,46015.$$

Jasno, u prvom slučaju odaberemo funkciju $g_1(x) = x^2$, u drugom slučaju $g_2(x) = x^3$, a u trećem slučaju funkciju $g_3(x) = e^x$. □

Primjer 6.1.9. Neka je $\Omega_1 = \{1, 2, 3, 4, 5, 6\}$ na kojem je definirana uniformna vjerojatnost P_1 te neka je $\Omega = \Omega_1 \times \Omega_1$ na kojemu je vjerojatnost $P = P_1 \times P_1$ (pogledajte potpoglavlje 4.4). Znamo da P djeluje na elementarnim događajima iz Ω tako da je

$$P((i, j)) = \frac{1}{36} \quad i, j = 1, 2, 3, 4, 5, 6.$$

Definirajmo slučajne varijable X, Y i Z na Ω takve da je

$$X((i, j)) = i, \quad Y((i, j)) = j, \quad Z((i, j)) = i + j.$$

Znamo da na ovaj način možemo modelirati slučajni eksperiment slučajnog bacanja dvije kockice pri čemu je slučajna varijabla X jednaka broju koji je pao na prvoj kockici, Y je jednaka broju koji je pao na drugoj kockici, a Z je jednaka zbroju brojeva koji su pali na kockicama. X i Y su nezavisne slučajne varijable, dok X i Z nisu nezavisne. Pogledajte Primjer 5.2.15.

U prošlom poglavlju smo vidjeli da slučajne varijable ne moramo zadavati eksplicitno kao što smo to napravili (podsjetili se) na početku ovog primjera, već ih možemo zadati razdiobama. Tako smo mogli jednostavno reći da su X i Y nezavisne diskretne slučajne varijable s razdiobom

$$X, Y \sim \begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \end{pmatrix}$$

dok je $Z = X + Y$. Ono što nismo detaljnije razjasnili do sada u skripti je kako u tako općenitoj situaciji odrediti razdiobu slučajne varijable Z jer to uključuje malu detaljniju obradu pojma zajedničke razdiobe dvije slučajne varijable, odnosno slučajnog vektora te

funkcija slučajnih vektora. No, s obzirom na interpretaciju slučajnih varijabli X, Y i Z znamo (pogledajte Primjer 5.1.7) da je razdioba slučajne varijable Z dana s

$$Z \sim \begin{pmatrix} 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 & 10 & 11 & 12 \\ 1/36 & 2/36 & 3/36 & 4/36 & 5/36 & 6/36 & 5/36 & 4/36 & 3/36 & 2/36 & 1/36 \end{pmatrix}.$$

Već smo izračunali da je $EX = EY = 3,5$, a korištenjem formule (6.1) možemo izračunati i očekivanje slučajne varijable Z. Imamo

$$\begin{aligned} EZ &= 2\frac{1}{36} + 3\frac{2}{36} + 4\frac{3}{36} + 5\frac{4}{36} + 6\frac{5}{36} + 7\frac{6}{36} + 8\frac{5}{36} + 9\frac{4}{36} + 10\frac{3}{36} + 11\frac{2}{36} + 12\frac{1}{36} \\ &= \frac{1}{36}(2 + 6 + 12 + 20 + 30 + 42 + 40 + 36 + 30 + 22 + 12) = \frac{252}{36} = 7. \end{aligned}$$

Ovaj rezultat je očekivan s obzirom na simetričnost razdiobe slučajne varijable Z oko vrijednosti 7, ali uočimo da smo ga mogli dosta jednostavnije izračunati korištenjem linearnosti očekivanja (relacija (6.4) u Teoremu 6.1.5) jer je

$$EZ = E(X + Y) = EX + EY = 3.5 + 3,5 = 7.$$

Napominjemo da za taj račun nije bila potrebna nezavisnost slučajnih varijabli X i Y. Izračunajmo sada očekivanje slučajne varijable XZ. Iz definicije slučajne varijable Z je jasno da je

$$XZ = X(X + Y) = X^2 + XY$$

pa je, opet zbog linearnosti očekivanja,

$$E(XZ) = EX^2 + E(XY). \tag{6.10}$$

Zbog nezavisnosti slučajnih varijabli X i Y je

$$E(XY) = EXEY = 3,5 \cdot 3,5 = 12,25.$$

Očekivanje od X^2 računamo prema (6.7). Imamo[3]

$$EX^2 = 1^2\frac{1}{6} + 2^2\frac{1}{6} + 3^2\frac{1}{6} + 4^2\frac{1}{6} + 5^2\frac{1}{6} + 6^2\frac{1}{6} = \frac{1}{6}(1+4+9+16+25+36) = \frac{91}{6} = 15,1667.$$

Sada se vratimo u (6.10) pa vidimo da je

$$E(XZ) = 15,1667 + 12,25 = 27,41667.$$

S druge strane je

$$EX \cdot EZ = 3,5 \cdot 7 = 24,5$$

pa je

$$EXZ \neq EX \cdot EZ.$$

Dakle, za slučajne varijable koje nisu nezavisne ne mora vrijediti relacija (6.6). □

Primjer 6.1.10. Neka je $U \sim U(0,2)$, neprekidna uniformna slučajna varijabla na $(0,2)$. Izračunajmo EU, $E(U-1)^2$ i $E\sqrt{U}$.
Sjetimo se da (neprekidna) uniformna slučajna varijabla ima funkciju gustoće koja je konstantna na intervalu na kojem je definirana. Kako integral funkcije gustoće mora biti jednak 1 proizlazi da je funkcija gustoće od U jednaka

$$f_U(u) = \begin{cases} \frac{1}{2}, & u \in (0,2) \\ 0, & \text{inače.} \end{cases}$$

[3] Matematičkom indukcijom se lagano pokaže da je zbroj kvadrata prvih n prirodnih brojeva jednak $n(n+1)(2n+1)/6$ pa za $n = 6$ imamo $6(6+1)(2 \cdot 6+1)/6 = 91$.

Očekivanje od U jednostavno računamo prema osnovnoj formuli (6.3)

$$EU = \int_0^2 u\frac{1}{2}du = \frac{1}{2}\frac{u^2}{2}\Big|_{u=0}^{u=2} = \frac{1}{2}\Big(\frac{2^2}{2} - \frac{0^2}{2}\Big) = 1.$$

Da bi izračunali $E(U-1)^2$ i $E\sqrt{U}$ iskoristit ćemo relaciju (6.8) iz Teorema 6.1.5 primijenjenom na funkcije $g(x) = (x-1)^2$ i $h(x) = \sqrt{x}$. Imamo sljedeći račun

$$\begin{aligned} E(U-1)^2 &= \int_0^2 (u-1)^2\frac{1}{2}du = \{u-1=t\} \\ &= \frac{1}{2}\int_{-1}^1 t^2dt = \frac{1}{2}\frac{t^3}{3}\Big|_{t=-1}^{t=1} = \frac{1}{2}\Big(\frac{1^3}{3} - \frac{(-1)^3}{3}\Big) = \frac{1}{2}\cdot\frac{2}{3} = \frac{1}{3} \end{aligned}$$

pri čemu smo nakon druge jednakost uveli supstituciju varijable $t = u-1$ pa su se granice integrala promijenile. Izračunajmo i $E\sqrt{U}$

$$E\sqrt{U} = \int_0^2 \sqrt{u}\frac{1}{2}du = \frac{1}{2}\int_0^2 u^{1/2}du = \frac{1}{2}\frac{u^{3/2}}{3/2}\Big|_{u=0}^{u=2} = \frac{1}{2}\cdot\frac{2}{3}(2^{3/2} - 0^{3/2}) \approx 0,9428.$$

Nadamo se da je jasno kako bi se računala i očekivanja poput $E(U-1)^3$ ili $E(1/(U^2+1))$. □

6.1.2 Varijanca

Ako na očekivanje gledamo kao na osnovni kvantitativni sažetak[4] o nekoj slučajnoj varijabli, onda je dosta jasno da informacija o srednjoj vrijednosti neke slučajne varijable ne pruža dovoljno informacija o njoj. Naime, kao i kod brojeva (vidi potpoglavlje 2.3), želimo imati informaciju o raspršenosti razdiobe slučajne varijable. U vjerojatnosti je osnovna mjera raspršenosti, odnosno disperzije, varijanca slučajne varijable. Imamo sljedeću definiciju.

Definicija 6.1.11. Neka je X slučajna varijabla. Tada je **varijanca** slučajne varijable X, u oznaci $\mathrm{Var}\,(X)$, definirana kao

$$\mathrm{Var}\,(X) = E[(X - EX)^2]. \tag{6.11}$$

Za varijancu se često koristi oznaka $\sigma^2 = \mathrm{Var}\,(X)$. **Standardna devijacija** slučajne varijable X je drugi korijen varijance od X, odnosno

$$SD(X) = \sqrt{E[(X - EX)^2]},$$

gdje je $SD(X)$ oznaka za standardnu devijaciju. Jasno, $\sigma = SD(X)$.

Varijanca slučajne varijable se riječima može opisati kao očekivano srednjekvadratno odstupanje slučajne varijable od očekivane vrijednosti. Uočimo da je EX samo broj pa je jedina slučajna vrijednost u definiciji varijance upravo slučajna varijabla X. Ukoliko to želimo sugestivno naznačiti, možemo označiti $\mu = EX$, i definirati funkciju $g : \mathbb{R} \to [0,\infty)$ s $g(x) = (x-\mu)^2$, pa je onda

$$\mathrm{Var}\,(X) = E[g(X)] = E[(X-\mu)^2].$$

Ukoliko neće biti zabune, izostavljat ćemo vanjske zagrade u definiciji varijance pa ćemo jednostavno pisati

$$\mathrm{Var}\,(X) = E(X - EX)^2.$$

[4] Iako je ono puno više, što nam indiciraju svojstva Teorema 6.1.5, ali i rezultati koje ćemo predstaviti u sljedećem odjeljku.

U definiciji varijance ne razlikujemo slučajeve diskretne i neprekidne slučajne varijable, ali je jasno, prema definiciji očekivanja, da se relacija (6.11) može dodatno eksplicirati za slučajeve diskretnih i neprekidnih slučajnih varijabli. Tako za X diskretnu slučajnu varijablu s razdiobom

$$X \sim \begin{pmatrix} a_1 & a_2 & \dots & a_n & \dots \\ p_1 & p_2 & \dots & p_n & \dots \end{pmatrix}.$$

zaključujemo, prema formuli (6.7), da je varijanca jednaka

$$\operatorname{Var}(X) = \sum_{i=1}^{\infty} (a_i - EX)^2 p_i = \sum_{i=1}^{\infty} (a_i - EX)^2 P(X = a_i). \tag{6.12}$$

Jasno, (6.7) smo primijenili na funkciju $g(x) = (x - EX)^2$.

Slično, ako je X neprekidna slučajna varijabla s funkcijom gustoće f_X, onda je, prema (6.8), varijanca od X jednaka

$$\operatorname{Var}(X) = \int_{-\infty}^{\infty} (x - EX)^2 f_X(x) dx. \tag{6.13}$$

U praksi se varijanca rijetko računa pomoću formula iz (6.12) i (6.13) jer imamo još jedan izraz za varijancu koji se lagano izvede iz (6.11). Naime, vrijedi da je

$$\operatorname{Var}(X) = E(X^2) - (EX)^2. \tag{6.14}$$

Dakle, varijanca je jednaka očekivanju slučajne varijable X^2 umanjenom za kvadrat očekivanja slučajne varijable X. Lagano se pokaže da (6.14) slijedi iz (6.11) jer je

$$\begin{aligned} \operatorname{Var}(X) &= E(X - EX)^2 = E(X^2 - 2XEX + (EX)^2) = \text{ linearnost očekivanja} \\ &= E(X^2) - 2(EX)^2 + (EX)^2 = E(X^2) - (EX)^2. \end{aligned}$$

Nemojmo zaboraviti da je EX samo broj pa smo u gornjem nizu jednakosti iskoristili

$$E(-2XEX) = -2EXE(X) = -2(EX)^2 \quad \text{i} \quad E((EX)^2) = (EX)^2 E(1) = (EX)^2.$$

Pogledajmo jedan jednostavan primjer s diskretnim slučajnim varijablama.

Primjer 6.1.12. Neka je X diskretna slučajna varijabla čija je razdioba dana s

$$X \sim \begin{pmatrix} 1 & 2 & 3 & 6 \\ 1/4 & 1/4 & 1/3 & 1/6 \end{pmatrix}.$$

Vidjeli smo u Primjeru 6.1.8 da je $EX = 2,75$. Stoga je varijanca od X, prema definiciji varijance, odnosno zbog formule (6.12), jednaka

$$\operatorname{Var}(X) = (1 - 2,75)^2 \cdot \frac{1}{4} + (2 - 2,75)^2 \cdot \frac{1}{4} + (3 - 2,75)^2 \cdot \frac{1}{3} + (6 - 2,75)^2 \cdot \frac{1}{6} = 2,6875.$$

Alternativno, možemo iskoristiti relaciju (6.14) za izračun varijance od X. Prema njoj je

$$\operatorname{Var}(X) = E(X^2) - (EX)^2 = 10.25 - (2,75)^2 = 2,6875,$$

pri čemu smo iskoristili izračunatu vijednost od X^2 iz Primjera 6.1.8.
Intuitivno će varijanca slučajne varijable biti to veća što su njene vrijednosti "razmaknutije", odnosno raspršenije. Tako za slučajnu varijablu Y čija je distribucija

$$Y \sim \begin{pmatrix} -2 & 1 & 3 & 12 \\ 1/4 & 1/4 & 1/3 & 1/6 \end{pmatrix}$$

izračunamo očekivanje $EY = 2,75$, dok je varijanca od Y jednaka $\operatorname{Var}(Y) = 20,6875$. Provjerite to. □

Kao i očekivanje, a u osnovi baš zbog toga, i varijanca ima neka dobra svojstva koja navodimo u sljedećoj propoziciji.

Propozicija 6.1.13 (Svojstva varijance)**.** *Neka su X i Y slučajne varijable te a, b realni brojevi. Tada vrijedi*

i) $\operatorname{Var}(X+b) = \operatorname{Var}(X)$

ii) $\operatorname{Var}(aX) = a^2 \operatorname{Var}(X)$

iii) Ako su X i Y nezavisne, onda je $\operatorname{Var}(X+Y) = \operatorname{Var}(X) + \operatorname{Var}(Y)$. *To općenito ne vrijedi za slučajne varijable koju nisu nezavisne.*

iv) Ako su $X_1, X_2, \ldots, X_n$ nezavisne slučajne varijable onda je

$$\operatorname{Var}(X_1 + X_2 + \ldots + X_n) = \operatorname{Var}(X_1) + \operatorname{Var}(X_2) + \ldots + \operatorname{Var}(X_n). \tag{6.15}$$

Da bi se malo zbližili s računanjem očekivanja, pomoću kojega je definirana varijanca, pokažimo da vrijede svojstva navedena u prethodnoj propoziciji. Za svojstvo *i)* korištenjem linearnosti očekivanja i relacije (6.14) jednostavno vidimo da je

$$\begin{aligned}\operatorname{Var}(X+b) &= E(X+b)^2 - (E(X+b))^2 = E(X^2 + 2bX + b^2) - (EX + b)^2 \\ &= EX^2 + 2bEX + b^2 - ((EX)^2 + 2bEX + b^2) = EX^2 - (EX)^2 = \operatorname{Var}(X).\end{aligned}$$

Slično pokažemo da vrijedi i svojstvo *ii)*

$$\begin{aligned}\operatorname{Var}(aX) &= E(aX)^2 - (E(aX))^2 = E(a^2X^2) - (aEX)^2 \\ &= a^2EX^2 - a^2(EX)^2 = a^2(EX^2 - (EX)^2) = a^2 \operatorname{Var}(X).\end{aligned}$$

Da bi dokazali da vrijedi svojstvo *iii)* iskoristimo svojstva iz (6.14) i (6.6) da dobijemo

$$\begin{aligned}\operatorname{Var}(X+Y) &= E(X+Y)^2 - (E(X+Y))^2 = E(X^2 + 2XY + Y^2) - (EX + EY)^2 \\ &= EX^2 + 2E(XY) + EY^2 - ((EX)^2 + 2EXEY + (EY)^2) \\ &= \text{ iskoristimo nezavisnost od } X \text{ i } Y \\ &= EX^2 + 2EXEY + EY^2 - (EX)^2 - 2EXEY - (EY)^2 \\ &= EX^2 - (EX)^2 + EY^2 - (EY)^2 = \operatorname{Var}(X) + \operatorname{Var}(Y).\end{aligned}$$

Svojstvo (iv) slijedi iz *iii)* matematičkom indukcijom. Uočimo još da je varijanca konstante jednaka nuli. Malo preciznije ako je $C \equiv c$, $c \in \mathbb{R}$, konstantna slučajna varijabla, onda je

$$\operatorname{Var}(C) = E(C^2) - (E(C))^2 = C^2 - C^2 = 0.$$

To je u skladu s intuitivnom interpretacijom varijance. Naime, ako prihvatimo varijancu kao mjeru varijablinosti slučajne varijable, onda je jasno da je varijanca konstante jednaka nuli jer konstanta nema varijabilnosti.
U nastavku ovog odjeljka računamo ili samo navodimo očekivanje i varijancu nekih od najvažnijih slučajnih varijabli s kojima smo se susreli u prošlom poglavlju.

Diskretne razdiobe (slučajne varijable)

1) **Bernoullijeva** slučajna varijabla X s parametrom p
Već smo vidjeli da je $EX = p$. Kako je, prema (6.7),

$$EX^2 = 0^2 \cdot (1-p) + 1^2 p = p$$

iz (6.14) slijedi

$$\text{Var } X = EX^2 - (EX)^2 = p - p^2 = p(1-p) = pq,$$

gdje je $q = 1 - p$. U slučaju $p = 1/2$ dobivamo da je $EX = 1/2$ i $\text{Var}\,(X) = 1/4$.

2) **Diskretna uniformna** slučajna varijabla X na $\{1, 2 \ldots, n\}$, $n \in \mathbb{N}$
Sjetimo se, za X vrijedi $P(X = i) = 1/n$, $i = 1, 2, \ldots, n$. Prema definiciji očekivanja je

$$EX = \sum_{i=1}^{n} i\frac{1}{n} = \frac{1}{n}\sum_{i=1}^{n} i = \frac{1}{n}\frac{n(n+1)}{2} = \frac{n+1}{2}$$

jer je

$$1 + 2 + \ldots + n = \frac{n(n+1)}{2}$$

što lagano dokažemo matematičkom indukcijom. Korištenjem matematičke indukcije možemo pokazati i da je

$$1^2 + 2^2 + \ldots + n^2 = \frac{n(n+1)(2n+1)}{6}$$

pa je

$$EX^2 = \sum_{i=1}^{n} i^2\frac{1}{n} = \frac{1}{n}\sum_{i=1}^{n} i^2 = \frac{1}{n}\frac{n(n+1)(2n+1)}{6} = \frac{(n+1)(2n+1)}{6}.$$

Prema (6.14) je

$$\begin{aligned}\text{Var}\,(X) &= \frac{(n+1)(2n+1)}{6} - \Big(\frac{n+1}{2}\Big)^2 = \frac{(2n^2+3n+1)}{6} - \frac{(n+1)^2}{4} \\ &= \frac{4n^2+6n+2-3n^2-6n-3}{12} = \frac{n^2-1}{12}.\end{aligned}$$

Za $n = 6$ slučajnu varijablu X možemo intepretirati kao ishode bacanja simetrične kockice. Tada je $EX = (6+1)/2 = 3,5$, što smo već vidjeli. Varijanca od X je $\text{Var}\,(X) = (6^2 - 1)/12 = 2,91667$.

3) **Binomna** slučajna varijabla B s parametrima n i p
U sljedećem odjeljku ćemo na jednostavan način izračunati očekivanju i varijancu slučajne varijable $B \sim B(n, p)$ pa ovdje samo navodimo da je

$$EB = np \quad \text{Var}\,(B) = np(1-p) = npq,$$

gdje je $q = 1 - p$. Ukoliko uzmemo, na primjer, $n = 5$ i $p = 1/2$, onda vrijednosti binomne slučajne varijable možemo interpretirati kao broj bacanja, od 5 nezavisnih bacanja, simetričnog novčića u kojima je pala glava. U tom slučaju je

$$EB = 5 \cdot \frac{1}{2} = 2,5 \;\text{ i }\; \text{Var}\,(B) = 5 \cdot \frac{1}{2} \cdot \frac{1}{2} = 1,25.$$

Uočimo, ako se povećava (ili smanjuje) vjerojatnost uspjeha u pojedinom slučajnom eksperimentu koji modeliramo binomnom slučajnom varijablom, onda se povećava (smanjuje) i očekivanje binomne slučajne varijable, ali se varijanca svakako smanjuje. Na primjer, za $n = 5$ i $p = 3/4$ dobivamo

$$EB = 5 \cdot \frac{3}{4} = 3,75 \;\text{ i }\; \text{Var}\,(B) = 5 \cdot \frac{3}{4} \cdot \frac{1}{4} = 0,9375.$$

Dakle, binomna slučajna varijabla ima najraspršenije (najdisperziranije) vrijednosti za $p = 1/2$. Formalno to možemo provjeriti tako da gledmo funkciju $f(p) = p(1-p) = p - p^2$,

deriviramo je da vidimo da je točka ekstrema te funkcije $p = 1/2$, a s obzirom da je $f''(p) < 0$ taj je ekstrem maksimum.
Kako slučajna varijabla $B \sim B(5, 1/2)$ ima 6 mogućih različitih vrijednosti možemo je usporediti diskretnom uniformnom slučajnom varijablom na $\{1, 2, 3, 4, 5, 6\}$. Usporedbom s prethodnim primjerom vidimo da binomna slučajna varijabla ima manju varijancu. Dodatno, uočimo da varijanca diskretne uniformne raste proporcionalno kvadratu od n, dok varijanca binomne raste proporcionalno n-u. Tako je, na primjer, za $n = 100$ varijanca diskretne uniformne slučajne varijable X na $\{1, 2, \ldots, 100\}$ jednaka

$$\mathrm{Var}\,(X) = \frac{100^2 - 1}{12} = 833,25,$$

dok je varijanca $B \sim B(99, 1/2)$ jednaka

$$\mathrm{Var}\,(B) = 99 \cdot \frac{1}{2} \cdot \frac{1}{2} = 24,75.$$

Još je jedno svojstvo binomne razdiobe vrijedno za zapamtiti. Naime, u odjeljku 5.2.4 o nezavisnosti slučajnih varijabli smo napomenuli da za nezavisne binomne slučajne varijable $B_1 \sim B(n, p)$ i $B_2 \sim B(m, p)$, $n, m \in \mathbb{N}$, vrijedi da je $B_1 + B_2 \sim B(n + m, p)$. To znači da je

$$E(B_1 + B_2) = (n + m)p,$$

te je

$$\mathrm{Var}\,(B_1 + B_2) = (n + m)p(1 - p).$$

Uočimo da bi obje te jednakost mogli izračunati, zbog (6.4) i *iii*) iz Propozicije 6.1.13, i bez znanja o tome da je razdioba od $B_1 + B_2$ opet binomna.

4) **Geometrijska** slučajna varijabla G s parametrom p
Bez dokaza navodimo da je

$$E(G) = \frac{1}{p} \quad \text{i} \quad \mathrm{Var}\,(G) = \frac{1 - p}{p^2}.$$

Ukoliko geometrijskom slučajnom varijablom modeliramo broj bacanja simetričnog novčića do ishoda u kojem je pala glava, onda je $p = 1/2$ pa je očekivanje takve slučajne varijable jednako 2. Dakle, očekivani broj bacanja da bi dobili glavu je jednak 2, što je, pretpostavljamo, u skladu s intuicijom.

5) **Hipergeometrijska** slučajna varijabla X s parametrima p, c i n
Sjetimo se, u kutiji imamo p plavih kuglica i c crvenih kuglica te biramo n kuglica (bez vraćanja). Hipergeometrijska slučajna varijabla broji izvučene plave kuglice. Bez dokaza navodimo

$$E(X) = n\frac{p}{p + c} \quad \text{i} \quad \mathrm{Var}\,(X) = \frac{npc(p + c - n)}{(p + c)^2(p + c - 1)}.$$

6) **Poissonova** slučajna varijabla X s parametrom λ
Iako to i nije teško izračunati, bez dokaza navodimo

$$EX = \lambda \quad \text{i} \quad \mathrm{Var}\,(X) = \lambda.$$

Kao što smo već napomenuli, Poissonovom slučajnom varijablom možemo modelirati slučajne događaje koji se događaju s malim vjerojatnostima (ali ih se može pojaviti velik broj). Znamo da je $P(X = k) = \lambda^k e^{-\lambda}/k!$, $k = 0, 1, 2, \ldots$. Vidimo da parametar λ ima jasnu interpetaciju kao očekivanje te slučajne varijable, odnosno kao očekivani broj pojavljivanja nekih slučajnih događaja koje modeliramo (često u nekoj jedinici vremena).

Neprekidne razdiobe (slučajne varijable)

1) **Uniformna** slučajna varijabla U na (a,b)
Funkcija gustoće uniformne razdiobe je vrlo jednostavna pa se lagano izračunaju njeno očekivanje i varijanca prema (6.1), odnosno (6.7). Imamo

$$EU = \frac{1}{b-a}\int_a^b u du = \frac{1}{b-a}\frac{u^2}{2}\Big|_{u=a}^{u=b} = \frac{1}{b-a}\Big(\frac{b^2}{2}-\frac{a^2}{2}\Big) = \frac{(b-a)(b+a)}{2(b-a)} = \frac{a+b}{2}$$

i

$$\begin{aligned} EU^2 &= \frac{1}{b-a}\int_a^b u^2 du = \frac{1}{b-a}\frac{u^3}{3}\Big|_{u=a}^{u=b} \\ &= \frac{1}{b-a}\Big(\frac{b^3}{3}-\frac{a^3}{3}\Big) = \frac{(b-a)(b^2+ab+a^2)}{3(b-a)} = \frac{a^2+ab+b^2}{3} \end{aligned}$$

pa je

$$\begin{aligned} \mathrm{Var}\,(U) = EU^2 - (E(U))^2 &= \frac{a^2+ab+b^2}{3} - \Big(\frac{a+b}{2}\Big)^2 = \frac{a^2+ab+b^2}{3} - \frac{a^2+2ab+b^2}{4} \\ &= \frac{4a^2+4ab+4b^2-3a^2-6ab-3b^2}{12} = \frac{a^2-2ab+b^2}{12} = \frac{(b-a)^2}{12}. \end{aligned}$$

Posebno je za $U \sim U(0,1)$

$$EU = \frac{1}{2} \quad \text{i} \quad \mathrm{Var}\,(U) = \frac{1}{12}.$$

U Primjeru 6.1.10 smo izračunali očekivanje slučajne varijable $U \sim U(0,2)$, kao i varijancu te slučajne varijable pri čemu smo iskoristili relaciju (6.13).

2) **Eksponencijalna** slučajna varijabla X s parametrom λ
Korištenjem formule parcijalne integracije (5.20) uz $u(x) = -e^{-\lambda x}/\lambda$ i $v(x) = x$ dobivamo

$$EX = \lambda\int_0^\infty xe^{-\lambda x}dx = \lambda\Big(-\frac{1}{\lambda}xe^{-\lambda x}\Big|_{x=0}^{x=\infty} + \frac{1}{\lambda}\int_0^\infty e^{-\lambda x}dx\Big).$$

Prvi izraz u velikoj zagradi je jednak (teži k) nuli, a u drugom integralu uvedemo zamjenu varijabli $u = -\lambda x$ (pogledajte Primjer 5.3.5) pa dobijemo

$$EX = \lambda\cdot\frac{1}{\lambda^2} = \frac{1}{\lambda}.$$

Slično se izračuna

$$EX^2 = \frac{2}{\lambda^2}$$

pa je

$$\mathrm{Var}\,(X) = EX^2 - (EX)^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}.$$

3) **Normalna** slučajna varijabla X s parametrima μ i σ^2
Očekivanje slučajne varijable X se prilično lako izračuna uz mali "trik". Naime, x možemo zapisati kao $x-\mu+\mu$ pa je

$$\begin{aligned} EX &= \frac{1}{\sigma\sqrt{2\pi}}\int_{-\infty}^\infty xe^{-\frac{(x-\mu)^2}{2\sigma^2}}dx \\ &= \frac{1}{\sigma\sqrt{2\pi}}\int_{-\infty}^\infty (x-\mu)e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx + \mu\frac{1}{\sigma\sqrt{2\pi}}\int_{-\infty}^\infty e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx \end{aligned}$$

Drugi integral u zadnjem redu gornjih jednakosti je jednak 1 jer je to integral funkcije gustoće. U prvom integralu uvedemo jednostavnu zamjenu varijabli $t = x - \mu$ pa je on jednak

$$\frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} te^{-\frac{t^2}{2\sigma^2}} dt = 0$$

jer je integrand (funkcija ispod integrala) neparna, a područje integracije je simetrično. Dakle,

$$EX = \mu.$$

Parcijalnom integracijom se može izračunati da je

$$\mathrm{Var}\,(X) = \sigma^2.$$

Dakle, parametri normalne razdiobe μ i σ^2 su, redom, očekivanje i varijanca te slučajne varijable. Jasno, jedinična normalna razdioba ima očekivanje 0 i varijancu 1.

4) **Paretova** slučajna varijabla X s parametrom α
Prema definiciji očekivanja iz (6.1.2) je

$$EX = \int_1^{\infty} x \frac{\alpha}{x^{\alpha+1}} dx = \alpha \int_1^{\infty} \frac{1}{x^{\alpha}} dx.$$

Izračun vrijednosti dobivenog integrala je delikatan jer vrijednost ovisi o α. Da bi jasnije vidjeli što se događa raspišimo dobiveni nepravi integral prema definiciji

$$\alpha \int_1^{\infty} x^{-\alpha} dx = \lim_{B\to\infty} \alpha \int_1^{B} x^{-\alpha} dx.$$

Ako je $\alpha > 1$, onda je

$$\alpha \int_1^{B} x^{-\alpha} dx = \alpha \frac{x^{-\alpha+1}}{-\alpha+1}\Big|_{x=1}^{x=B} = \frac{\alpha}{1-\alpha}(B^{-\alpha+1} - 1^{-\alpha+1}).$$

Kako je $\alpha - 1 > 0$ imamo

$$\lim_{B\to\infty} B^{-\alpha+1} = \lim_{B\to\infty} \frac{1}{B^{\alpha-1}} = 0$$

pa je

$$EX = \frac{\alpha}{\alpha - 1}.$$

Ako je $\alpha \leq 1$ (a prema definiciji Paretove razdiobe je $\alpha > 0$), onda je

$$EX = \infty.$$

Kako to znamo? Uzmimo $\alpha = 1$. Tada je

$$EX = \int_1^{\infty} \frac{1}{x} dx = \ln(x)\Big|_{x=1}^{x=\infty} = \infty.$$

Za $\alpha < 1$ i $x > 1$ je $x^{\alpha} < x$ pa je

$$\frac{1}{x^{\alpha}} > \frac{1}{x},$$

a onda zbog monotonosti integrala slijedi

$$\int_1^{\infty} \frac{1}{x^{\alpha}} dx \geq \int_1^{\infty} \frac{1}{x} dx = \infty.$$

Dakle, za $\alpha \leq 1$ je

$$EX = \infty.$$

Zaključujemo

$$EX = \begin{cases} \frac{\alpha}{\alpha-1}, & \alpha > 1 \\ \infty, & \alpha \leq 1. \end{cases}$$

Ovo je primjer slučajnih varijabli (za $\alpha \leq 1$) čije očekivanje ne postoji (jednako je ∞). Kako je očekivanje od X neograničeno (∞) varijanca slučajne varijable X nije definirana za $\alpha \leq 1$ (sjetite se člana $-(EX)^2$ u definiciji varijance). Na vrlo sličan način kao u prethodnom računu vidimo da je $EX^2 = \infty$, za $\alpha \in (1, 2]$, dok za $\alpha > 2$ imamo

$$EX^2 = \int_1^\infty x^2 \frac{\alpha}{x^{\alpha+1}} dx = \alpha \int_1^\infty \frac{1}{x^{\alpha-1}} dx = \alpha \frac{x^{-\alpha+2}}{-\alpha+2}\Big|_{x=1}^{x=\infty} = \frac{\alpha}{\alpha-2}.$$

Stoga je za $\alpha > 2$

$$\operatorname{Var}(X) = \frac{\alpha}{\alpha-2} - \frac{\alpha^2}{(\alpha-1)^2} = \frac{\alpha(\alpha-1)^2 - \alpha^2(\alpha-2)}{(\alpha-1)^2(\alpha-1)} = \frac{\alpha}{(\alpha-1)^2(\alpha-1)}.$$

6.1.3 Očekivanje, indikatori i vjerojatnost

U odjeljku 5.2.3.2 smo definirali indikatorsku slučajnu varijablu. Sjetimo se, za slučajni događaj A se indikator I_A tog događaja (skupa) definira kao funkcija $I_A : \Omega \to \{0, 1\}$ takva da je

$$I_A(\omega) = \begin{cases} 1, & \omega \in A \\ 0, & \text{inače.} \end{cases} \tag{6.16}$$

Vidjeli smo da I_A možemo interpretirati kao Bernoullijevu slučajnu varijablu pri čemu se uspjeh može definirati kao "dogodio se slučajni događaj A", a neuspjeh kao "nije se dogodio slučajni događaj A". U skladu s tom interpretacijom je parametar p takve Bernoullijeve slučajne varijable zapravo jednak $p = P(I_A = 1) = P(A)$.

Iako su jednostavni, indikatori skupova su vrlo korisni i često korišteni u vjerojatnosti. U sljedećoj propoziciji su navedena neka svojstva indikatora.

Propozicija 6.1.14. *Neka su A i B slučajni događaji. Tada vrijede sljedeća svojstva*

i) $I_{A^c} = 1 - I_A$

ii) $I_{A \cap B} = I_A I_B$

iii) $I_{A \cup B} = I_A + I_B - I_A I_B$

iv) A i B su nezavisni događaji ako i samo ako su I_A i I_B nezavisne slučajne varijable

v) $A_1, A_2, \ldots, A_n$, $n \in \mathbb{N}$, *su nezavisni ako i samo ako su* $I_{A_1}, I_{A_2}, \ldots, I_{A_n}$ *nezavisne slučajne varijable.*

Dokaz ove propozicije smo ostavili za vježbu u Zadatku 6.5.6 čije je rješenje dano na kraju poglavlja.

U prošlom odjeljku nismo izračunali očekivanje i varijancu binomne slučajne varijable jer se oba računa provode vrlo jednostavno korištenjem indikatora. Naime, binomna slučajna varijabla $X \sim B(n, p)$ se može zapisati kao zbroj n nezavisnih Bernoullijevih slučajnih varijabli $B_1, \ldots, B_n$ s parametrom p. Kako je očekivanje Bernoullijeve slučajne varijable jednako p zbog linearnosti očekivanja slijedi

$$E(X) = E(B_1 + B_2 + \ldots + B_n) = EB_1 + EB_2 + \ldots + EB_n = np,$$

kao što smo i bili naveli. Slično, kako je varijanca Bernoullijeve slučajne varijable jednaka $p(1-p)$ te kako su su $B_1, \ldots, B_n$ nezavisne, korištenjem svojstva varijance (6.15) slijedi

$$\text{Var}\,(X) = \text{Var}\,(B_1 + B_2 + \ldots + B_n) = \text{Var}\; B_1 + \text{Var}\; B_2 + \ldots + \text{Var}\; B_n = np(1-p).$$

Indikatori nam omogućavaju da uspostavimo vrlo općenitu poveznicu između vjerojatnosti i matematičkog očekivanja. Neka je A neki slučajan događaj takav da je $P(A) = p \in [0,1]$. Uočite općenitost slučajnog događaja A. Pogledajmo sada indikator skupa A, u oznaci I_A. Prema definiciji indikatora je $P(I_A = 1) = p$. Indikator I_A možemo smatrati Bernoullijevom slučajnom varijablom s parametrom p. Kao što smo već vidjeli, tada je $EI_A = p$. Ako malo razmislimo, vidimo da zapravo vrijedi

$$EI_A = P(A). \tag{6.17}$$

To znači da vjerojatnost svakog slučajnog događaja možemo predstaviti kao očekivanje (indikatorske) slučajne varijable. Ovo može biti pomalo iznenađujuć rezultat jer je vjerojatnost "osnovniji" objekt, ali uz malo općenitiju definciju integrala (Legesgeov integral) vjerojatnosti možemo predstaviti kao integrale određenih funkcija. Nama takva razina općenitosti neće trebati, ali konceptualno je korisno uočiti vezu između vjerojatnosti i očekivanja predstavljenu u relaciji (6.17).

Ideja da se slučajne varijable mogu prikazati kao zbroj indikatora, poput prikaza binomne kao zbroja nezavisnih Bernoullijevih, često olakšava izračune, pogotovo izračune očekivanja i to zbog linearnosti očekivanja. U nastavku je dan primjer problema uparivanja (eng. *matching problem*).

Primjer 6.1.15. Neka su na n listića (karata) napisani brojevi od 1 do n, $n \in \mathbb{N}$. Promiješajmo listiće i slažimo ih na stol jedan po jedan. Kažemo da je listić uparen ako je broj koji je na njemu zapisan jednak poziciji listića na kojoj je taj broj (dakle, jednak je rednom broju listića prilikom slaganja karata na stol). Neka slučajna varijabla M broji broj uparivanja koji se postiže prilikom slučajnog rasporeda listića po stolu. Pitamo se koje je očekivanje slučajne varijable M.
Problem možemo riješiti tako da s A_i označimo događaj u kojem je i-ti listić uparen, $i = 1, 2, \ldots, n$. Sada definiramo indikator $I_i = I_{A_i}$. Prema definiciji indikatora je $I_i = 1$ ako je lsitić s bojem i uparen, a 0 inače. Poanta je da se M može predstaviti kao zbroj tih indikatora, odnosno

$$M = I_1 + I_2 + \ldots + I_n.$$

Sada za listić na kojem je napisan broj i, $i = 1, 2, \ldots, n$, uočimo da se on može prilikom redanja karata na stol staviti na jedno od n mjesta pa je $P(I_i = 1) = P(A_i) = 1/n$.[5] No, to je sve što nam treba za izračun očekivanja slučajne varijable M zbog linearnosti očekivanja. Imamo

$$\begin{aligned} EM &= E(I_1 + I_2 + \ldots + I_n) = EI_1 + EI_2 + \ldots + EI_n \\ &= P(I_1 = 1) + \ldots + P(I_n = 1) = n\frac{1}{n} = 1. \end{aligned}$$

Zaključujemo da je očekivani broj uparenih listića jednak 1 (ne ovisi o n). Inače, ovaj problem se često formulira kroz pitanje "koja je vjerojatnost da će prilikom slučajnog redanja označenih listića biti barem jedno uparivanje?". Takav problem se može riješiti formulom uključivanja-isključivanja (nećemo u to ulaziti na ovom mjestu), a proizlazi da se tražena vjerojatnost približava $1 - 1/e$ kada $n \to \infty$. □

[5] Ako ćemo prebrajati sve mogućnosti uočimo da je ukupan broj razmještaja n listića na n mjesta jednak $n!$, dok je broj razmještaja n listića na n mjesta na način da je i-ti listić na i-tom mjestu jednak $(n-1)!$. Dakle, tražena vjerojatnost je jednaka $(n-1)!/n! = 1/n$.

Sljedeći primjer pokazuje primjenu iste tehnike u računarstvu (primjer je preuzet iz [12], poglavlje 2.2).

Primjer 6.1.16 (Quicksort)**.** Pogledajmo primjer algoritma za sortiranje quicksort. Riječ je o rekurzivnom algoritmu koji sortira niz od n brojeva. Ukoliko je $n = 2$ algoritam uspoređuje dvije vrijednosti i sortira ih (mijenja im mjesto ili ih ostavlja kakve su bile ako su u rastućem poretku).

Za $n > 2$ algoritam izabere jedan član zadanog niza brojeva i onda ispred njega "pomakne" sve brojeve manje od njega, a iza njega sve brojeve veće od njega. U sljedećem koraku na isti način sortira brojeve koje se nalaze ispred prvog odabranog broja, a zatim one iza njega (dakle, algoritam je rekurzivan). Da bi bilo jasnije što radimo uzmimo primjer. Neka je zadano 10 brojeva

$$8, 15, 4, 6, 12, 7, 13, 20, 14, 11.$$

Recimo da je prvo odabran broj 11. Prema algoritmu prolazimo kroz preostale brojeve i one koji su manji ostavimo ispred broja 11 (vizualno ih stavljamo u uglate zagrade), a one koje su veći stavimo iza broja 11 (opet u uglatim zagradama). Dobivamo

$$[8, 4, 6, 7]\ 11\ [12, 15, 13, 20, 14].$$

Sada pogledamo lijevu uglatu zagradu (manje brojeve od 11). Odaberimo sada broj 7 i na brojeve u prvoj uglatoj zagradi primjenimo isti postupak.

$$[4, 6], 7\ \{8\}\ 11\ [12, 15, 13, 20, 14].$$

sada je ostala samo jedna uglata zagrada s lijeve strane i to s dva člana pa dobivamo

$$4, 6, 7, 8, 11\ [12, 15, 13, 20, 14].$$

Sada se vratimo na desnu uglatu zagradu od prvobitno odabranog broja 11. Odaberimo u njoj broj 14 i opet ponovimo postupak. Dobijemo

$$4, 6, 7, 8, 11\ [12, 13]\ 14\ [15, 20].$$

I lijeva i desna strana su dvočlane pa se "razriješe" u jednom koraku. Dobivamo sortirani niz

$$4, 6, 7, 8, 11, 12, 13, 14, 15, 20.$$

Brzina izvršavanja algoritma ovisi o broju usporedbi članova niza. Ukoliko se u svakom koraku biraju najveći (ili najmanji) brojevi u uglatim zagradama imat ćemo $n(n-1)/2$ usporedbi. To je gornja ograda ukupnih usporedbi. Iako je to korisna procjena, još je zanimljivije procjeniti neki prosječni, odnosno očekivani broj usporedbi. U tu svrhu nam mogu pomoći slučajne varijable i njihovo očekivanje.

Da bi procjenili očekivani broj usporedbi prilikom izvršavanja quicksort algoritma pretpostavit ćemo da je u svakom koraku unutar uglate zagrade odabran bilo koji od brojeva na slučajan način, odnosno jednako vjerojatno. (Ta je pretpostavka ekvivalentna tome da je inicijalni poredak brojeva slučajan, a da je u svakoj uglatoj zagradi odabran prvi (ili zadnji) broj.) Neka slučajna varijabla X broji usporedbe koje se obave prilikom izvršavanja algortima. Želimo izračunati EX.

Slučajnu varijablu X ćemo prikazati kao zbroj jednostavnijih slučajnih varijabli. U tu svrhu označimo brojeve koje trebamo sortirati: neka je s 1 (ili a_1) označen najmanji broj, s 2 sljedeći najmanji broj (ili a_2) i tako dalje sve do najvećeg broja koji označimo s n. Tada za i, j takve da je $1 \leq i < j \leq n$ definirajmo jednostavnu slučajnu varijablu $I(i, j)$ čija je vrijednost jednaka 1 ako su i i j direktno uspoređeni tokom izvršavanja

algoritma, a 0 inače. Kada zbrojimo sve te slučajne varijable $I(i,j)$ za $i<j$ dobivamo broj usporedbi prilikom izvršavanja algoritma. Drugim riječima

$$X=\sum_{j=2}^{n}\sum_{i=1}^{j-1}I(i,j).$$

Zbog linearnosti očekivanja je

$$EX=\sum_{j=2}^{n}\sum_{i=1}^{j-1}E(I(i,j))=\sum_{j=2}^{n}\sum_{i=1}^{j-1}P(i \text{ i } j \text{ su uspoređeni prilikom izvršavanja algoritma}).$$

Da bi izračunali gornju vjerojatnost uočimo da su vrijednosti $i,(i+1),\ldots,(j-1),j$ inicijalno sve u istoj uglatoj zagradi (istom dijelu podataka kojem će se prilikom izvršavanja algoritma rekurzivno pristupiti). Vrijednosti $i,(i+1),\ldots,(j-1),j$ će ostati u istoj uglatoj zagradi sve dok jedna od tih vrijednosti ne bude izabrana za usporedbu. Tada imamo sljedeće mogućnosti:

1. bit će izabrana jedna od vrijednosti $(i+1),\ldots,(j-1)$ pa će i biti razvrstan u lijevu uglatu zagradu od te vrijednosti, a j u desnu. U tom slučaju i i j neće biti uspoređeni.
2. bit će odabran i ili j pa će oni biti direktno uspoređeni.

Kolika je onda vjerojatnost od "i i j nisu uspoređeni prilikom izvršavanja algoritma"? Prema uvjetima koje smo definirali bilo koja od vrijednosti $i,(i+1),\ldots,(j-1),j$ može biti izabrana s jednakom vjerojatnosti pa je ukupan broj odabira jednak $j-i+1$, a samo u dva slučaja (kada je odabran i ili j) će i i j biti uspoređeni. Prema naivnoj definiciji vjerojatnosti je

$$P(i \text{ i } j \text{ su uspoređeni prilikom izvršavanja algoritma})=\frac{2}{j-i+1}.$$

Sada računamo

$$\begin{aligned}
EX&=\sum_{j=2}^{n}\sum_{i=1}^{j-1}\frac{2}{j-i+1} && \text{(uvedimo supstituciju } k=j-i+1)\\
&=2\sum_{j=2}^{n}\sum_{k=1}^{j}\frac{1}{k} && \text{(zamjenimo poredak suma)}\\
&=2\sum_{k=2}^{n}\sum_{j=k}^{n}\frac{1}{k}\\
&=2\sum_{k=2}^{n}\frac{n-k+1}{k}\\
&=2(n+1)\sum_{k=2}^{n}\frac{1}{k}-2\sum_{k=2}^{n}1\\
&=2(n+1)\sum_{k=2}^{n}\frac{1}{k}-2(n-1).
\end{aligned}$$

Linearni član možemo zanemariti (značajno je manji od prvog člana), a za izračun prvog člana gornjeg zbroja iskoristimo asimptotsku ocjenu[6]

$$\sum_{k=2}^{n}\frac{1}{k}\sim\ln(n).$$

[6]Oznaku $g(n)\sim f(n)$ u kontekstu asimptotske ocjene koristimo kada vrijedi $\lim_{n\to\infty}f(n)/g(n)=1$, gdje su f i g neke funkcije koje ovise o n.

Stoga se očekivani broj usporedbi prilikom izvršavanja quicksort algoritma asimptotski ponaša kao

$$EX \sim 2n\ln(n).$$

Uočimo, ako uzmemo $n = 10.000$, onda je gornja ograda za mogući broj usporedbi u quicksort algoritmu jednaka 49.995.000, dok je procjena očekivanih usporedbi jednaka 92.103. □

Napomena 6.1.17 (Očekivanje kao integral repne vjerojatnosti)**.** Ponekad se za izračun očekivanja koristi drugačija forma od uobičajene, odnosno one s kojom smo započeli ovo poglavlje. Naime, za nenegativnu slučajnu varijablu X vrijedi

$$EX = \int_0^\infty P(X > x)dx. \tag{6.18}$$

Ova formula vrijedi općenito, a za nenegativne diskretne slučajne varijable se reducira na[7]

$$EX = \sum_{n=0}^{\infty} P(X > n). \tag{6.19}$$

Dokaz relacije (6.18) je instruktivan u kontekstu indikatora. Naime, slučajna varijabla X se može predstaviti kao

$$X = \int_0^X dx = \int_0^\infty I_{\{X>x\}}dx, \tag{6.20}$$

gdje je $I_{\{X>x\}}$ indikator slučajnog događaja $\{X > x\}$. Nema sumnje da reprezentacija slučajne varijable X iz (6.20) izgleda čudno, ali uočimo da smo iz te reprezentacije izostavili argument slučajne varijable (funkcije) X. Naime, u (6.20) zapravo piše

$$X(\omega) = \int_0^{X(\omega)} dx = \int_0^\infty I_{\{X(\omega)>x\}}dx, \quad \omega \in \Omega. \tag{6.21}$$

Dakle, za sve $\omega \in \Omega$ vrijedi gornja jednakost, a $X(\omega)$ je samo broj. Tako, na primjer, za X slučajnu varijablu koja je konstantna i jednaka 3 ($X \equiv 3$) zapravo imamo jednakost

$$3 = \int_0^3 dx = \int_0^\infty I_{\{3>x\}}dx,$$

a tu je jednakost intuitivno bitno lakše prihvatiti.
Ako prihvatimo valjanost relacije (6.20), koja je istinita, onda možemo djelovati očekivanjem na obje strane te jednakost. Kako je očekivanje zapravo integral, ono i integral $\int_0^\infty$ mogu zamijeniti mjesta (kao kod dvostrukog integrala nenegativnih funkcija) pa prema relaciji (6.17) dobivamo

$$EX = \int_0^\infty E(I_{\{X>x\}})dx = \int_0^\infty P(X > x)dx,$$

što smo i željeli pokazati. Inače, vrijedi i općenitija formula za slučajnu varijablu X koja ima konačno očekivanje. Tada je

$$EX = \int_0^\infty P(X > x)dx - \int_{-\infty}^0 P(X < x)dx.$$

Relacija (6.18) nam govori da se očekivanje može prikazati kao integral funkcije repne vjerojatnosti. Sjetimo se, u Definiciji 5.4.4 smo vjerojatnost $P(X > x)$ nazvali repnom

[7] U skladu s Napomenom 6.1.4. Sume su zaista posebni slučajevi općenitih integrala.

vjerojatnošću. Ovdje gledamo funkciju $x \mapsto P(X > x)$ koja je zapravo jednaka $\bar{F}_X(x) = 1 - F_X(x)$, gdje je F_X funkcija distribucije slučajne varijable X.
Prirodna prva reakcija na novu formulu za izračun očekivanja je - čemu još jedna formula? Suprotno raširenom mišljenju studenata, cilj razvoja matematike nije zakomplicirati neku situaciju, nego olakšati izračune kad god je to moguće. Konkretno, formula dana u (6.18) olakšava izračun očekivanja kada je repna funkcija distribucije $\bar{F}_X$ jednostavnijeg oblika od funkcije distribucije, odnosno funkcije gustoće.
Tipičan primjer upotrebe formule (6.18), odnosno diskretne verzije (6.19), je izračun očekivanja geometrijske slučajne varijable. Naime, ako je G geometrijska slučajna varijabla s parametrom p, onda je (pogledajte odjeljak 5.2.3.4, odnosno Zadatak 5.7.8) $P(G > n) = (1-p)^n$, $n \in \mathbb{N}$. Primjenom (6.19) te korištenjem formule za zbroj geometrijskog reda lagano izračunamo

$$E(G) = \sum_{n=0}^{\infty} P(G > n) = \sum_{n=0}^{\infty} (1-p)^n = \frac{1}{1-(1-p)} = \frac{1}{p}.$$

Jedan složeniji primjer uključuje tako zvanu desno cenzuriranu eksponecijalnu slučajnu varijablu. Neka je X eksponencijalna slučajna varijabla s parametrom λ i $c \geq 0$ broj. Definiramo novu slučajnu varijablu $Y = \min\{X, c\}$. Ovakve situacije se sureću u nekim ispitivanjima (recimo kliničkim) u kojima je c trajanje ispitivanja, a X vrijeme života (trajanja) jedinke ili objekta koji ispitujemo. Tada je funkcija distribucije F_Y slučajne varijable Y jednaka 0 za $x < 0$, jednaka 1 za $x \geq c$, dok je

$$F_Y(x) = 1 - e^{-\lambda x}, \ x \in [0, c).$$

Kako je $P(Y > x) = \bar{F}_Y(x) = 1 - F_Y(x)$ jednostavno izračunamo

$$EY = \int_0^{\infty} P(Y > x)dx = \int_0^c e^{-\lambda x} = \frac{1 - e^{-\lambda x}}{\lambda}.$$

Više o ovom primjeru, kao i nekim drugim primjenama formule (6.18) može se naći u [8]. □

6.1.4 Viši momenti i još neka obilježja slučajnih varijabli

U vjerojatnosti se uobičajeno, za slučajnu varijablu X, brojevi EX i EX^2 zovu prvi i drugi moment slučajne varijable X. Oni su poseban slučaj općenite situacije koju opisujemo u sljedećoj definiciji.

Definicija 6.1.18. Neka je X slučajna varijabla i $r > 0$ realan broj. $E(X^r)$ zovemo **r-ti moment** od X, dok $E(|X|^r)$ zovemo **r-ti apsolutni moment** od X.
Ako je očekivanje slučajne varijable X konačno, onda se $E[(X - EX)^r]$ zove **r-ti centralni moment** od X, dok se $E(|X - EX|^r)$ zove **r-ti apsolutni centralni moment** od X.

U skladu s prethodnom definicijom je očekivanje slučajne varijable X prvi moment od X, dok je varijanca drugi centralni moment od X.
Osnovno pitanje vezano uz momente slučajne varijable je kada oni (neki od njih) postoje. To, naravno, ovisi o rezdiobi slučajne varijable X, ali općenito vrijedi: ako je konačan r-ti moment $E(X^r)$, onda su konačni i svi momenti $E(X^s)$, $0 \leq s < r$, pri čemu je po konvenciji $E(X^0) = 1$. Ta se činjenica lagano dokaže, s time da r-ti moment konačan ako je $E|X|^r < \infty$. Naime, jer vrijedi jednostavna nejednakost[8]

$$|X|^s \leq \max\{1, |X|^r\} \leq 1 + |X|^r$$

[8] Ako niste sigurni zašto se pojavljuje maksimum u gornjoj nejednakost uočite da se potencije različito ponašaju na intervalima $(0,1)$ i $(1,\infty)$. Naime, na $(0,1)$ veće potencije imaju manje vrijednosti, dok na $(1,\infty)$ veće potencije imaju veće vrijednosti (rastu brže). Razmislite.

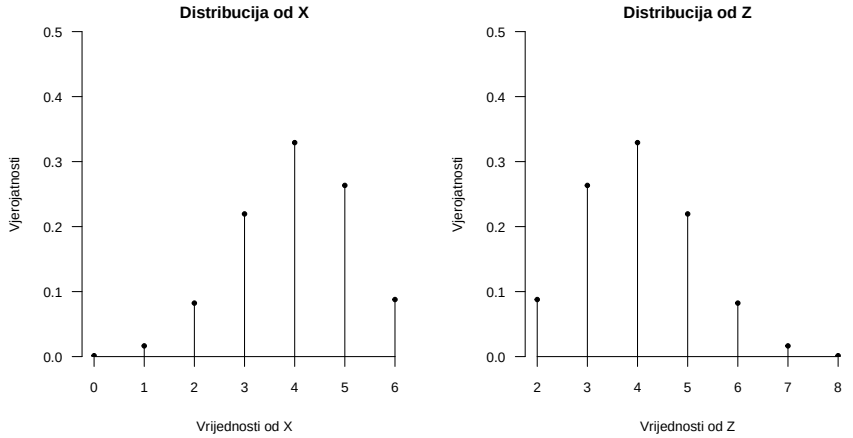
zbog monotonosti matematičkog očekivanja (relacija (6.5) u Teoremu 6.1.5) slijedi da je

$$E|X|^s \leq 1 + E|X|^r. \tag{6.22}$$

To konkretno znači da je konačno očekivanje slučajne varijable X za koju je $EX^2 < \infty$. Posebno, ako postoji varijanca slučajne varijable X (konačna je), onda postoji i očekivanje slučajne varijable X.

Značaj viših momenata[9] slučajnih varijabli proizlazi iz činjenice da oni pružaju dodatne informacije o razdiobama slučajnih varijabli. Pod nekim uvjetima momenti slučajne varijable mogu u potpunosti odrediti razdiobu slučajne varijable,[10] ali već i neki od pojedinačnih viših momenata pružaju koristan uvid u karakteristike razdioba slučajnih varijabli. Potreba za računanjem viših momenata slučajnih varijabli proizlazi iz činjenice da očekivanje i varijanca općenito nisu dovoljni za potpun opis razdioba slučajnih varijabli, što zorno predstavljamo u sljedećem primjeru.

Primjer 6.1.19. Neka je $X \sim B(6, 2/3)$ binomna slučajna varijabla s parametrima $n = 6$ i $p = 2/3$ te $Z = Y + 2$, gdje je $Y \sim B(6, 1/3)$ binomna slučajna varijabla s parametrima $n = 6$ i $p = 1/3$. Na donjim slikama su prikazane razdiobe slučajnih varijabli X i Z.



Iako je jasno da se razdiobe slučajnih varijabli X i Z značajno razlikuju njihovo očekivanje i varijanca su jednaki. Prema izračunima koje smo proveli za binomne slučajne varijable, a zbog linearnosti očekivanja imamo

$$EX = 6 \cdot \frac{2}{3} = 4 \quad \text{i} \quad EZ = E(2 + Y) = 2 + EY = 2 + 6 \cdot \frac{1}{3} = 4.$$

Slično, zbog svojstva i) iz Propozicije 6.1.13 imamo

$$\operatorname{Var}(X) = 6 \cdot \frac{2}{3} \cdot \frac{1}{3} = \frac{4}{3} \quad \text{i} \quad \operatorname{Var}(Z) = \operatorname{Var}(Y) = 6 \cdot \frac{1}{3} \cdot \frac{2}{3} = \frac{4}{3}.$$

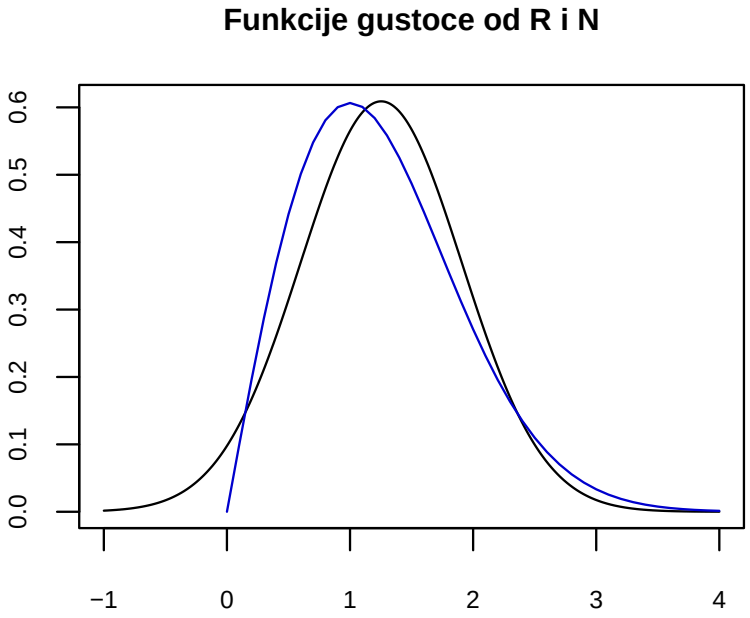
Sličnu pojavu možemo uočiti i kod neprekidnih slučajnih varijabli. Recimo, neka je R Rayleghova slučajna varijabla s parametrom $\sigma = 1$. S tom smo se slučajnom varijablom, odnosno razdiobom, upoznali u potpoglavlju 5.5. Njena je funkcija gustoće

$$f(x) = \begin{cases} xe^{-x^2/2}, & x \geq 0 \\ 0, & \text{inače,} \end{cases}$$

[9] Uobičajeno se misli na momente više od drugoga.

[10] Da bi to razjasnili trebali bi definirati pojam karakteristične funkcije slučajne varijable što ne radimo na ovom mjestu. Radi reference navodimo da se o ovoj temi govori u Teoremu 13.8. i Propoziciji 13.6. u [10].

dok su joj očekivanje i varijanca $ER = \sqrt{\pi/2}$ i $\mathrm{Var}\,(R) = (4-\pi)/2$. Neka je $\mu = \sqrt{\pi/2}$ i $\sigma^2 = (4-\pi)/2$ te neka je $N \sim (\mu, \sigma^2)$ normalna slučajna varijabla s parametrima μ i σ^2. Prema karakteristikama normalne slučajne varijable znamo da R i N imaju isto očekivanje i varijancu. Ipak, njihove razdiobe su dosta različite, što jasno pokazuje donja slika na kojoj su prikazane funkcije gustoće slučajnih varijabli R (plavom bojom) i N (crnom bojom).



Funkcija gustoće normalne slučajne varijable je simetrična oko svog očekivanja, koje je jednako $\sqrt{\pi/2}$, dok je funkcija gustoće slučajne varijble R "rastegnuta" na desnu stranu (u odnosu na simetričnu razdiobu) te je jednaka nuli za $x < 0$. □

Rastegnutost, odnosno ukošenost razdiobe ili funkcije gustoće slučajne varijable je svojstvo koje se uobičajeno mjeri standardiziranim trećim momentom. Imamo sljedeću definiciju.

Definicija 6.1.20. Neka je X slučajna varijabla s očekivanjem μ i varijancom σ^2. Njena **ukošenost** (eng. *skewness*) se definira kao

$$Skew(X) = E\Big(\frac{X-\mu}{\sigma}\Big)^3. \tag{6.23}$$

Prije nego što kratko iskomentiramo pojam ukošenosti uočimo da je u gornjoj definiciji provedena standardizacija slučajne varijable X. S tim postupkom smo se već susreli proučavajući normalanu slučajnu varijablu u prethodnom poglavlju (relacija (5.27)), ali on se može provesti i u vrlo općenitom slučaju. Imamo sljedeću propoziciju.

Propozicija 6.1.21. *Neka je X slučajna varijabla s konačnim očekivanjem μ i varijancom $\sigma^2 > 0$. Tada slučajna varijabla*

$$Y = \frac{X-\mu}{\sigma}$$

ima očekivanje nula i varijancu jedan. Slučajna varijabla Y je standardizirana slučajna varijabla dobivena iz slučajne varijable X.

Dokaz. Dokaz ove propozicije je vrlo jednostavan i koristi osnovna svojstva očekivanja i varijance s kojima smo se već susreli. Zbog linearnosti očekivanja imamo

$$EY = E\Big(\frac{X-\mu}{\sigma}\Big) = \frac{1}{\sigma}E(X-\mu) = \frac{1}{\sigma}(EX - E(\mu)) = \frac{1}{\sigma}(\mu-\mu) = 0.$$

Zbog svojstava varijance $i)$ i $ii)$ iz Propozicije 6.1.13 slijedi

$$\mathrm{Var}\,(Y) = \mathrm{Var}\,\left(\frac{X-\mu}{\sigma}\right) = \frac{1}{\sigma^2}\,\mathrm{Var}\,(X-\mu) = \frac{1}{\sigma^2}\,\mathrm{Var}\,(X) = \frac{1}{\sigma^2}\sigma^2 = 1.$$

□

Imajući na umu što implicira postupak standardizacije slučajne varijable jasno nam je da definicija ukošenosti slučajne varijable (skewnessa) najprije zahtjeva standardizaciju slučajne varijable, a zatim računa njen treći moment. Zašto treći moment? Ukošenost slučajne varijable je svojstvo odstupanja od simetrije. Naime, za simetrične slučajne varijable, odnosno one za koje $X-\mu$ i $\mu-X$ imaju jednaku razdiobu, je ukošenost jednaka nuli. Kanonski primjer simterične slučajne varijable je normalna slučajna varijabla.[11] Nakon standardizacije ona postaje jedinična normalna slučajna varijabla $Z \sim N(0,1)$. Njen treći moment se računa kao

$$\int_{-\infty}^{\infty} x^3 f_Z(x)dx.$$

Funkcija gustoće jedinične (standardizirane) slučajne varijable Z je simetrična funkcija oko nule pa je podintegralna funkcija u gornjem integralu neparna. Stoga je gornji integral jednak nuli. Uočimo da će svi neparni momenti slučajne varijable Z, kao i drugih standardiziranih simetričnih slučajnih varijabli, biti jednaki nuli.

Ukoliko slučajna varijabla nema simetričnu gustoću ili razdiobu, treći moment njene standardizirane verzije općenito neće biti jednak nuli pa na njega, treći moment standardizirane verzije, možemo gledati kao na mjeru nesimetričnosti, odnosno ukošenosti slučajne varijable. Ukoliko je ukošenost slučajne varijable pozitivna, onda se kaže da je slučajna varijabla (njena razdioba) **desno ukošena**. Ukoliko je ukošenost slučajne varijable negativna, onda se kaže da je slučajna varijabla (njena razdioba) **lijevo ukošena**. U ovoj terminologiji desno i lijevo sugerira stranu na kojoj je rep, u smislu veće repne vjerojatnosti, veći (istaknutiji). U Primjeru 6.1.19 su slučajne varijable R i Z desno ukošene, dok je slučajna varijabla X lijevo ukošena. Treba istaknuti da ukošenost, odnosno standardizirani treći moment slučajne varijable, nije jedina mjera ukošenosti, ali se često koristi jer se relativno lagano računa.

U gornjoj raspravi, kao i prije u skripti, susreli smo se s pojmom repa razdiobe. Pod tim pojmom se podrazumijevaju, za neprekidne slučajne varijable, oni dijelovi funkcije gustoće koji se nalaze dalje od nekog "centra mase" funkcije gustoće. Kod normalne razdiobe su to područja i lijevo i desno od očekivanja (parametra μ) koja su udaljenija od centra razdiobe. Nemamo neku jasnu definiciju mjesta na kojem prestaje centralni dio neke razdiobe, a gdje počinje njen rep, ali pod repnim ponašanjem neke razdiobe ili slučajne varijable X s tom razdiobom se smatra onaj dio funkcije gustoće kod kojega površina ispod funkcije gustoće postaje mala (manja od $0,1$, recimo). Naravno, površina ispod funkcije gustoće je vjerojatnost pa tako dolazimo do repnih vjerojatnosti oblika $P(X > x)$ ili $P(X < -x)$, gdje je x neki realan broj. Do sada uvedeni momenti ne mjere veličinu repa neke razdiobe, ali četvrti standardizirani moment ima tu svrhu. Prije nego što ga definiramo pogledajmo jedan primjer.

Primjer 6.1.22. Uzmimo slučajnu varijablu L čija je funkcija gustoće

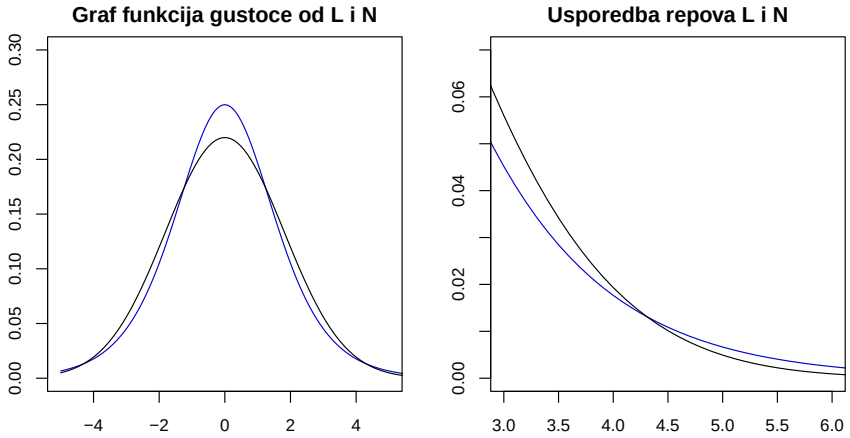
$$f_L(x) = \frac{e^x}{(1+e^x)^2},\ x \in \mathbb{R}.$$

[11] To su i diskretna i neprekidna uniformna razdioba, odnosno odgovarajuće slučajne varijable.

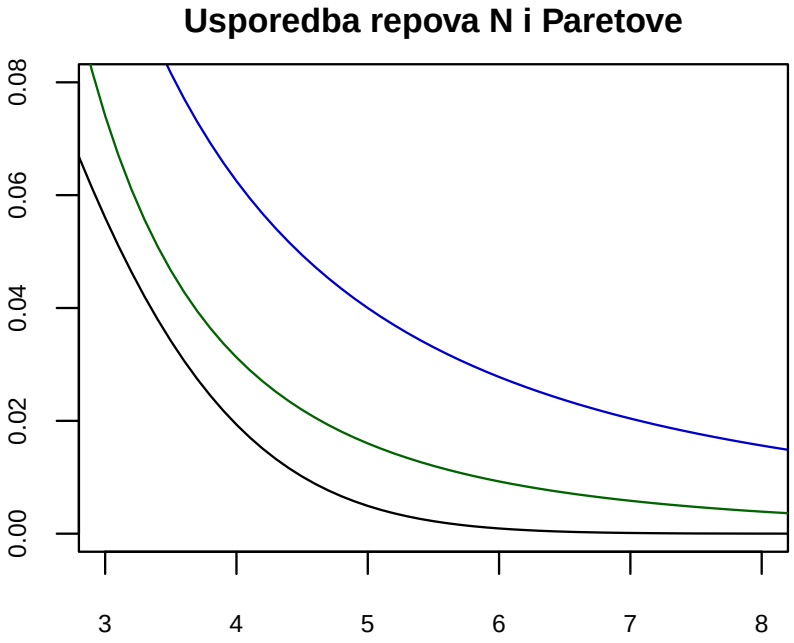
Slučajna varijabla L se zove (jedinična) **logistička** slučajna varijabla. Njeno je očekivanje nula, a varijanca $\pi^2/3$. Iako to nije odmah očito, ipak vrijedi da je funkcija gustoće f_L simetrična. To vidimo tako da malo transformiramo funkciju f_L:

$$f_L(x) = \frac{e^x}{(1+e^x)^2} = \frac{1}{e^{-x}(1+e^x)^2} = \frac{1}{(e^{-x/2})^2(1+e^x)^2} = \frac{1}{(e^{-x/2}+e^{x/2})^2} = f_L(-x).$$

Logistička slučajna varijabla se može predstaviti kao kompozicija nekih drugih slučajnih varijabli. Na primjer, ako je $Y \sim Exp(1)$ jedinična eksponencijalna slučajna varijabla, onda je $\ln(e^Y - 1)$ logistička slučajna varijabla.
Neka je N normalna slučajna varijabla $N \sim N(0, \pi^2/3)$. Na donjem grafu su prikazane funkcije gustoće slučajnih varijabli L (plavom bojom) i N (crnom bojom) te njihovi desni repovi.



Slučajne varijable L i N imaju isto očekivanje, varijancu i ukošenost koja je jednaka nuli jer su funkcije gustoće obje slučajne varijable simetrične. Njihove razdiobe se razlikuju u središtu razdiobe i u repovima. Doduše, ta razlika nije prevelika te postoje druge razdiobe koje imaju dosta veću razliku u repovima od normalne razdiobe. Za usporedbu prikazujemo samo repno ponašanje (desnog repa) slučajne varijable N i Paretovih slučajnih varijabli (uveli smo ih u odjeljku 5.4.1.4) s parametrima $\alpha = 1$ (plavom bojom) i $\alpha = 2$ (zelenom bojom).



Vidimo da je u ovom slučaju razlika u repovima izraženija. Uočimo da se Paretova razioba od normalne razdiobe ne razlikuje smo u repnom ponašanju jer joj je i ukošenost značajno različita (pozitivna), a vidjeli smo da očekivanje i varijanca Paretove razidobe ne moraju niti postojati za neke vrijednosti parametra α. □

U prošlom primjeru smo ilustrirali razlike koje se javljaju u repnom ponašanju (izgledu) nekoliko razdioba. Razdiobe koje imaju veće, kaže se i deblje, repove nazivaju se razdiobama s **teškim repovima** (eng. *heavy-tail distribution*). Bez želje da na ovom mjestu ulazimo u detalje možemo reći da slučajna varijabla X ima težak (desni) rep ako postoji $\alpha > 0$ takav da se repna vjerojatnost asimptotski ponaša kao $x^{-\alpha}$, odnosno da vrijedi

$$P(X > x) \sim x^{-\alpha}, \quad x \to \infty. \tag{6.24}$$

Oznaku $\sim$ koristimo da bi iskazali asimptotsku ekvivalenciju dviju funkcija. Tako ćemo za funkcije f i g pisati $f(x) \sim g(x)$, za $x \to \infty$, ako vrijedi

$$\lim_{x\to\infty} \frac{f(x)}{g(x)} = 1.$$

Paretove slučajne varijable su kanonski primjer slučajnih varijabli s razdiobom koja ima teške repove.

Jedna od mjera repnog ponašanja slučajne varijable, odnosno njene razdiobe, je standardizirani četvrti moment slučajne varijable koji se naziva kurtosis.[12] Imamo sljedeću definiciju.

Definicija 6.1.23. Neka je X slučajna varijabla s očekivanjem μ i varijancom σ^2. Njen **kurtosis** (eng. *kurtosis*) se definira kao

$$Kurt(X) = E\Big(\frac{X-\mu}{\sigma}\Big)^4 - 3. \tag{6.25}$$

Često se definicija kortosisa iskazuje bez oduzimanja broja 3. On se u definiciji pojavljuje kako bi normalne razdiobe imale kurtosis jednak nuli pa one mogu poslužiti kao usporedna vrijednost za ostale razdiobe. Ako pogledamo samo četvrti standardizirani moment $E[((X-\mu)/\sigma)^4]$ i razmišljamo u terminima vrijednosti slučajne varijable X možemo uočiti da će doprinos vrijednosti od X koje su od μ udaljene za manje od 1 (a to je standardna devijacija od $(X-\mu)/\sigma$) u izračunu četvrtog standardiziranog momenta biti vrlo mali jer uzimanje četvrte potencije brojeva manjih od jedan smanjuje vrijednosti prema nuli. S te strane gledano možemo razumijeti da kurtosis u velikoj mjeri ovisi o ponašanju slučajne varijable u repovima. Treba istaknuti da je to samo jedna od mjera, čak i ne najvažnija, kojima se proučavaju repovi raznih distribucija.

Primjer 6.1.24 (Povrati na tržištima kapitala)**.** Pregledavajući materijal koji je iznesen u ovom odjeljku mogao bi se steći dojam da su uvedeni pojmovi ukošenosti, kurtosisa i teških repova apstraktni i teško primjenjivi u praksi. To je daleko od istine jer su oni primjenjivi u raznim područjima poput meteorologije, hidrologije, geofizike, ali i vrlo pragmatičnom područja kao što su financije, odnosno upravljanje financijskom imovinom (eng. *asset management*).
Na financijskim tržištima su dostupne cijene razne imovine poput dionica, obveznica, raznih roba ili nekih agregiranih financijskih instrumenata poput dioničkih indeksa (primjerice, američki S&P 500, europski Eurostoxx 600 ili hrvatski CROBEX). Cijene imovine se promatraju kroz vrijeme i na taj način formiraju niz cijena $S_1, S_2, \ldots, S_n$, $n \in \mathbb{N}$.[13]

[12] Nemamo prijevod na hrvatski. Mogući prijevod bi bio zakrivljenost, ali time se ne uključuje dovoljno činjenica da je zapravo riječ o mjeri težine (debljine) repova neke razdiobe.

[13] Tako dobivamo vremenski niz podataka. Još jedna velika tema u vjerojatnosti i statistici.

Vremenom se shvatilo da se o samim cijenama financijske imovine može dosta reći, ali da je produktivnije gledati povrate koje ostvaruju pojedine imovine jer oni pokazuju veću stabilnost u statističkom smislu. Povrate na određenu imvovinu definiramo kao

$$R_i = \frac{S_i - S_{i-1}}{S_{i-1}},\ i = 2, 3, \ldots, n.$$

Veliko pitanje u financijama je pitanje razdiobe povrata na financijskim tržištima. O tome se zna i puno i malo. Nema jednoznačnog odgovora o karakteristikama (razdiobi) povrata na financijskim tržištima, ali su uočene neke pravilnosti koje se često sažimaju u formi tako zvanih stiliziranih činjenica o povratima na imovinu (eng. *stylized facts on asset returns*). U nastavku navodimo neka ot tih opažanja.
Zanimljiva karakteristika povrata na financijskim tržištima je da njihovo ponašanje nije isto u kraćim vremenskim razdobljima (danima, satima ili minutama) u odnosu na duža razdoblja poput godina. Što je veća mjerna jedinica vremena koju promatramo to su podaci po razdiobi bliskiji normlanoj razdiobi. Nadalje, podaci o povratima imaju uglavnom negativnu ukošenost (skewness) što je posljedica činjenice da su pozitivni povrati češći od negativnih. S druge strane povrati na financijskim tržištima imaju teške repove - kurtosis im je veći od normalno distribuiranih slučajnih varijabli. To je posebno relevantno jer se veliki negativni povrati pojavljuju s učestalošću koja je značajno veća od one koja bi slijedila iz normalne razdiobe. Dakle, povrati na financijskim tržištima pružaju primjer podataka kojima je lijevi rep težak.
Ima još nekih karakteristika povrata koji su vrlo relevantni za upravljanje financijskom imovinom poput koreliranosti uzastopnih povrata koja postaje vrlo izražena u financijskim krizama kada se veliki negativni povrati grupiraju (klasteriraju). Literatura o ovoj temi je zaista velika i teško je čak i preporučiti jedan izvor za dalje informiranje/proučavanje, ali poznat i vrlo citiran pregled je dan u članku [4]. □

Završit ćemo ovaj odjeljak s dvije definicije pojmova s kojima smo praktički započeli poglavlje o opisnim statistikama.

Definicija 6.1.25 (Medijan)**.** Neka je X slučajna varijabla. Realni broj c je **medijan** slučajne varijable X ako je $P(X \leq c) \geq 1/2$ i $P(X \geq c) \geq 1/2$.

Definicija 6.1.26 (Mod)**.** Neka je X diskretna slučajna varijabla. Realni broj c je **mod** slučajne varijable X ako je $P(X = c) \geq (X = xc)$, za sve $x \in \mathbb{R}$.
Neka je X neprekidna slučajna varijabla. Realni broj c je **mod** slučajne varijable X ako je $f(c) \geq f(x)$, za sve $x \in \mathbb{R}$. S f smo označili funkciju gustoće slučajne varijable X.

Kao i kod brojeva, možemo se zapitati koji broj najbolje aproksimira[14] slučajnu varijablu X (pogledajte Napomenu 2.3.4). Odgovor ovisi o tome da li gledamo očekivano srednjekvadratno odstupanje od slučajne vriajble ili očekivano odstupanje po apsolutnoj vrijednosti. Sljedeća propozicija govori o tome. Zainteresirani čitatelj može pogledati dokaz Teorema 6.1.4. u [3].

Propozicija 6.1.27. *Neka je X slučajna varijabla s očekivanjem μ i medijanom m. Tada*

1) Minimalna vrijednost od $E(X - c)^2$ se postiže za $c = \mu$

2) Minimalna vrijednost od $E(|X - c|)$ se postiže za $c = m$.

Ako malo pažljivije pogledamo sadržaj ovog poglavlja vidimo da smo praktički sve kvantitativne mjere podataka koje smo uveli u poglavlju o opisnoj statistici preveli na jezik slučajnih varijabli i očekivanja. Još nam je preostalo da prevedmo i korelaciju na isti jezik što ćemo učiniti u sljedećem odjeljku.

[14] U većini situacija je malo pretenciozno reći opisuje.

6.1.5 Kovarijanca i korelacija slučajnih varijabli

Do sada uvedeni pojmovi u ovom poglavlju (očekivanje, varijanca, viši momenti, medijan) pružaju osnovne informacije o karakteristikama pojedinačne slučajne varijable. Nemojmo zaboraviti, najpotpunija informacija o nekoj slučajnoj varijabli je dana njenom razdiobom, ali cijela razdioba slučajne varijable nije uvijek dostupna u praksi, dok se uvedene kvantitativne karakteristike slučajnih varijabli mogu procijeniti iz određenog skupa podataka. Time ćemo se pozabaviti u sljedećem poglavlju.

Ukoliko želimo sažeto, ali ipak pojednostavljeno, prikazati međuodnos dvije slučajne varijable potrebno je definirati pojam kovarijance što činimo u sljedećoj definiciji. Opet vrijedi ista napomena: najpotpunija informacija o odnosu dvije slučajne varijable je dana njihovom zajedničkom razdiobom, ali ona nije uvijek dostupna ili se ne može lagano odrediti. Sa pojmom zajedničke razdiobe slučajnih varijabli smo se susreli u kratkoj raspravi izloženoj nakon Teorema 5.2.14 te u tablici (5.14) u diskretnom slučaju, a u Primjeru 5.4.18 u neprekidnom slučaju.

Definicija 6.1.28. Neka su X i Y slučajne varijable s konačnim drugim momentima, odnosno neka je $EX^2 < \infty$ i $EY^2 < \infty$. **Kovarijanca** slučajnih varijabli X i Y, u oznaci $\mathrm{Cov}(X, Y)$, definira se kao

$$\mathrm{Cov}(X, Y) = E[(X - EX)(Y - EY)]. \tag{6.26}$$

Slično kao i u slučaju varijance (vidi relaciju (6.14)) i kovarijanca ima drugu formu koja se vrlo često koristi. Naime, vrijedi relacija

$$\mathrm{Cov}(X, Y) = E(XY) - EXEY \tag{6.27}$$

koja se jednostavno pokaže pa dokaz te relacije ostavljamo za vježbu u Zadatku 6.5.8.
Iz same definicije kovarijance vidimo da je ona simetrična funkcija svojih argumenata, odnosno vrijedi

$$\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X). \tag{6.28}$$

Iz relacije (6.27) direktno slijedi da je

$$\mathrm{Cov}(X, X) = \mathrm{Var}\,(X) \tag{6.29}$$

te tako zvano svojstvo homogenosti prema kojem je za realni broj a

$$\mathrm{Cov}(aX, Y) = a\,\mathrm{Cov}(X, Y). \tag{6.30}$$

Jasno, zbog simetrije kovarijance vrijedi i $\mathrm{Cov}(X, aY) = a\,\mathrm{Cov}(X, Y)$. U sljedećoj propoziciji navodimo još neka svojstva kovarijance.

Propozicija 6.1.29. *Neka su X, Y, Z slučajne varijable s konačnim drugim momentom. Tada vrijedi*

i) $\mathrm{Cov}(X, C) = 0$, *za konstantnu slučajnu varijablu* $C \equiv c$, $c \in \mathbb{R}$,

ii) ako su X i Y nezavisne slučajne varijable, onda je $\mathrm{Cov}(X, Y) = 0$,

iii) $\mathrm{Cov}(X + Y, Z) = \mathrm{Cov}(X, Z) + \mathrm{Cov}(Y, Z)$.

Dokaz. Dokaz ove propozicije je vrlo jednostavan.
Svojstvo *i*) slijedi iz (6.26) jer je $EC = c$.
Svojstvo *ii*) slijedi iz (6.27) jer za nezavisne slučajne varijable vrijedi $(XY) = EXEY$, prema (6.6).

Valjanost svojstva *iii*) provjerimo direktnim računom. Zbog linearnosti očekivanja, prema (6.27), imamo

$$\begin{aligned}\mathrm{Cov}(X+Y,Z) &= E[(X+Y)Z] - E(X+Y)EZ \\ &= E(XZ) + E(YZ) - EXEZ - EYEZ \\ &= E(XZ) - EXEZ + E(YZ) - EYEZ = \mathrm{Cov}(X,Z) + \mathrm{Cov}(Y,Z).\end{aligned}$$

□

Uočimo da zbog simetričnosti kovarijance iz svojstva *iii*) odmah zaključujemo da je $\mathrm{Cov}(X, Y+Z) = \mathrm{Cov}(X,Y) + \mathrm{Cov}(X,Z)$. Ukoliko još uzmemo u obzir i svojstvo (6.30), onda za slučajne varijable X, Y, Z i V te brojeve $a, b, c, d \in \mathbb{R}$ dobivamo

$$\mathrm{Cov}(aX+bY, cZ+dV) = ac\,\mathrm{Cov}(X,Z) + ad\,\mathrm{Cov}(X,V) + bc\,\mathrm{Cov}(Y,Z) + bd\,\mathrm{Cov}(Y,V). \tag{6.31}$$

Zanimljiv poseban slučaj dobivamo kada je $Y \equiv 1$ i $V \equiv 1$. Zbog svojstva *i*) iz Propozicije 6.1.29 se gornja jednakost reducira na

$$\mathrm{Cov}(aX+b, cZ+d) = ac\,\mathrm{Cov}(X,Z). \tag{6.32}$$

Dakle, linearna transformacija slučajnih varijabli X i Y ne mijenja kovarijancu slučajnih varijabli.

Pogledajmo jedan jednostavan primjer da vidimo kako se primjenjuju navedena svojstva.

Primjer 6.1.30. Neka je $X \sim N(0,1)$ jedinična normalna slučajna varijabla koja je nezavisna sa jediničnom eksponencijalnom slučajnom varijablom $V \sim Exp(1)$. Neka je $Z = 2X - 1$. Izračunajmo $\mathrm{Cov}(X, Z+V)$.
Prema svojstvu *iii*) iz prethodne propozicije, a zbog simetričnosti kovarijance imamo

$$\mathrm{Cov}(X, Z+V) = \mathrm{Cov}(X,Z) + \mathrm{Cov}(X,V).$$

Kako su X i V nezavisni $\mathrm{Cov}(X,V) = 0$, prema svojstvu *ii*) iz propozicije. Uočite da za ovaj zaključak nije bilo važno iz koje su razdiobe X i V, već samo njihov međuodnos (nezavisnost). Nadalje, prema definiciji slučajne varijable Z i svojstva *i*) u prethodnoj propoziciji imamo

$$\mathrm{Cov}(X,Z) = \mathrm{Cov}(X, 2X-1) = \mathrm{Cov}(X,2X) + \mathrm{Cov}(X,-1) = \mathrm{Cov}(X,2X).$$

Napokon, zbog homogenosti kovarijance (6.30) te zbog svojstva (6.29) dobivamo

$$\mathrm{Cov}(X, Z+V) = \mathrm{Cov}(X,2X) = 2\,\mathrm{Cov}(X,2X) = 2\,\mathrm{Var}\,(X) = 2.$$

□

Korištenjem matematičke indukcije iz svojstva *iii*) u prošloj propoziciji, odnosno svojstva (6.31) dobivamo sljedeći rezultat.

Propozicija 6.1.31. *Neka su $X_1, X_2, \ldots, X_n$ i $Y_1, Y_2, \ldots, Y_m$, $n, m \in \mathbb{N}$, slučajne varijable s konačnim drugim momentima. Tada vrijedi*

$$\mathrm{Cov}\left(\sum_{i=1}^{n} X_i, \sum_{j=1}^{m} Y_j\right) = \sum_{i=1}^{n}\sum_{j=1}^{m} \mathrm{Cov}(X_i, Y_j). \tag{6.33}$$

Jednostavna, ali važna i često korištena posljedica prethodnog rezultata dana je u nastavku.

Korolar 6.1.32. *Neka su $X_1, X_2, \ldots, X_n$, $n \in \mathbb{N}$, slučajne varijable s konačnim drugim momentima. Tada vrijedi*

$$\operatorname{Var}\Big(\sum_{i=1}^{n} X_i\Big) = \sum_{i=1}^{n} \operatorname{Var}(X_i) + \sum_{\substack{i=1 \\ i\neq j}}^{n}\sum_{i=1}^{n} \operatorname{Cov}(X_i, X_j). \tag{6.34}$$

Za $n = 2$ te $X = X_1$ i $Y = X_2$ se prethodna formula svede na

$$\operatorname{Var}(X+Y) = \operatorname{Var}(X) + \operatorname{Var}(Y) + 2\operatorname{Cov}(X,Y). \tag{6.35}$$

Dokaz. Prema relaciji (6.29) imamo

$$\begin{aligned}
\operatorname{Var}\Big(\sum_{i=1}^{n} X_i\Big) &= \operatorname{Cov}\Big(\sum_{i=1}^{n} X_i, \sum_{j=1}^{n} X_j\Big) && \text{(prema Propoziciji 6.1.31)} \\
&= \sum_{i=1}^{n}\sum_{j=1}^{n} \operatorname{Cov}(X_i, X_j) \\
&= \sum_{i=1}^{n} \operatorname{Cov}(X_i, X_i) + \sum_{\substack{i=1 \\ i\neq j}}^{n}\sum_{i=1}^{n} \operatorname{Cov}(X_i, X_j) && \text{(zbog (6.29))} \\
&= \sum_{i=1}^{n} \operatorname{Var}(X_i) + \sum_{\substack{i=1 \\ i\neq j}}^{n}\sum_{i=1}^{n} \operatorname{Cov}(X_i, X_j).
\end{aligned}$$

□

Uočimo, ako su sve slučajne varijable $X_1, X_2, \ldots, X_n$ nezavisne, onda je, prema svojstvu *ii*) iz Propozicije 6.1.29, $\operatorname{Cov}(X_i, X_j) = 0$, za $i \neq j$ pa se formula (6.34) svede na (6.15). Dakle, formula (6.15) je samo poseban slučaj općenitije formule (6.34).

Kovarijanca pruža dobar osnovni sažetak međuovisnosti slučajnih varijabli. Uočimo da su jednice u kojima se izražava kovarijanca jednake onima u kojima su slučajne varijable čiju međuovisnost pokušavamo odrediti. Stoga se često događa da se neke izačunate kovarijance mogu dosta razlikovati, iako su same ovisnostikoje se mjere slične , odnosno bliske. Stoga se nameće potreba da se kovarijance standardiziraju, odnosno prikažu u istom mjerilu. Kvantitativna veličina koja to omogućava je korelacija. Imamo sljedeću definiciju.

Definicija 6.1.33. Neka su X i Y slučajne varijable s konačnim drugim momentom te za njih vrijedi $\operatorname{Var}(X) > 0$ i $\operatorname{Var}(Y) > 0$. **Korelacija** slučajnih varijabli X i Y, u oznaci $\operatorname{Corr}(X,Y)$ ili $\rho(X,Y)$, definira se kao

$$\rho(X,Y) = \operatorname{Corr}(X,Y) = \frac{\operatorname{Cov}(X,Y)}{\sqrt{\operatorname{Var}(X)\operatorname{Var}(Y)}}. \tag{6.36}$$

Ukoliko je $\operatorname{Corr}(X,Y) = 0$ kažemo da su X i Y **nekorelirane** slučajne varijable. Ukoliko je $\operatorname{Corr}(X,Y) > 0$ slučajne varijable X i Y su **pozitivno korelirane**, a ako je $\operatorname{Corr}(X,Y) < 0$, onda su X i Y **negativno korelirane**.

Za korelaciju slučajnih varijabli vrijedi

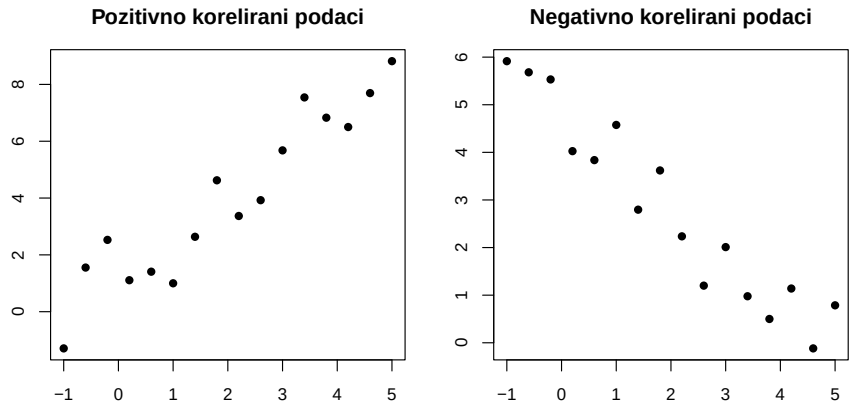
$$-1 \leq \operatorname{Corr}(X,Y) \leq 1 \tag{6.37}$$

pa se korelacija s pravom može smatrati standardiziranom mjerom međuovisnosti dvije slučajne varijable. Ukoliko je korelacija od X i Y po apsolutnoj vrijednosti bliska 1, kažemo da su slučajne varijable X i Y visoko korelirane (pozitivno ili negativno). Iz osnovnih svojstava kovarijance i varijance slijedi da, za $a, b \in \mathbb{R}$, $a \neq 0$, vrijedi

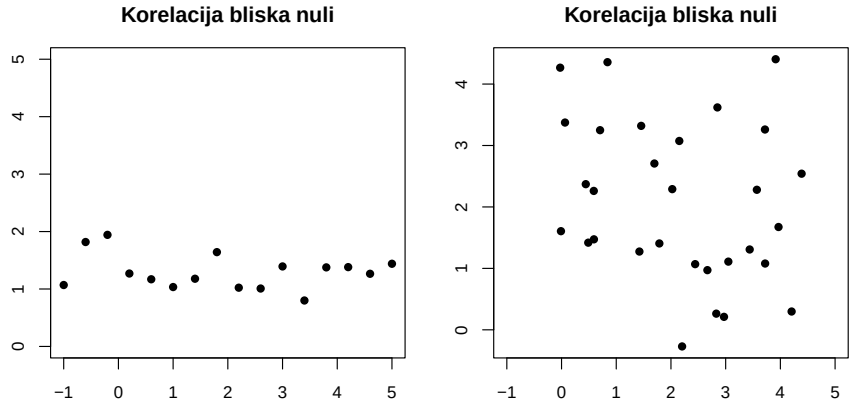
$\mathrm{Corr}(aX + b, Y) = \mathrm{Corr}(X, Y)$, za $a > 0$ i

$\mathrm{Corr}(aX + b, Y) = -\mathrm{Corr}(X, Y)$, za $a < 0$.

Korelacija između određenih podataka, za koje pretpostavimo da su realizacije nekih slučajnih varijabli, se često može približno odrediti (njen predznak) iz grafičkog prikaza podataka. Tako na sljedećoj slici ilustriramo podatke koji su pozitivno i negativno korelirani.



Na sljedećoj slici ilustriramo podatke čija je korelacija bliska nuli. Uočimo da je karakter podataka različit. Na lijevoj slici su prikazane realizacije nekih slučajnih varijabli čija je korelacija bliska nuli, ali su slučajne varijable "dosta zavisne", dok je na desnoj slici ilustriran prikaz realizacija dvije nezavisne slučajne varijable.



Prije nego što pokažemo neke primjere napomenimo da je jasno da za nezavisne slučajne varijable X i Y vrijedi $\mathrm{Corr}(X, Y) = 0$ (zbog ii) u Propoziciji 6.1.29). Obrat općenito ne vrijedi: ako je korelacija dvije slučajne varijable jednaka nuli, one ne moraju biti nezavisne. Takav je slučaj ilustiran na prethodnoj lijevoj slici.

Primjer 6.1.34. Na slučajan način i nezavisno bacimo dvije simetrične kockice. Neka je slučajna varijabla X jednaka nuli ukoliko je na prvoj kockici pao broj 1 ili 2, neka je jednaka 1 ako je na prvoj kockici pao broj 3 ili 4 te neka je jednaka 2 ako je na prvoj kockici pao broj 5 ili 6. Slično, neka je slučajna varijabla Y jednaka nuli ukoliko je na drugo kockici pao broj 1 ili 2, neka je jednaka 1 ako je na drugo kockici pao broj 3 ili 4 te neka je jednaka 2 ako je na drugoj kockici pao broj 5 ili 6. Definirajmo još tri slučajne varijable Z, V i W tako da je $Z = X + Y$, $V = \min\{X, Y\}$ i $W = \max\{X, Y\}$.

Odredimo razdiobe upravo definiranih diskretnih slučajnih varijabli. Iako bi mogli raditi na općenitom vjerojatnosnom prostoru, ili na uobičajenom $\{(i,j) \mid i,j = 1,2,3,4,5,6\}$ definirat ćemo jednostavniji diskretan vjerojatnosni prostor primjeren za definiciju slučajnih varijabli X i Y. Označimo s a elementarni događaj "na kockici je pao broj 1 ili 2", s b elementarni događaj "na kockici je pao broj 3 ili 4" te s c elementarni događaj "na kockici je pao broj 5 ili 6". Za simetričnu kockicu je $P(a) = P(b) = P(c) = 1/3$. Sada opisani slučajni eksperiment bacanja dvije kockice možemo opisati diskretnim vjerojatnosnim prostorom

$$\Omega = \{(a,a),(a,b),(a,c),(b,a),(b,b),(b,c),(c,a),(c,b),(c,c)\}$$

pri čemu su svi navedeni elementarni događaji jednako vjerojatni.[15] U skladu s definicijom slučajnih varijabli X i Y je $X(a) = 0$, $X(b) = 1$ i $X(c) = 2$, a također $Y(a) = 0$, $Y(b) = 1$ i $Y(c) = 2$. Zbog simetričnosti kockica je jasno da je razdioba od X i Y

$$X, Y \sim \begin{pmatrix} 0 & 1 & 2 \\ 1/3 & 1/3 & 1/3 \end{pmatrix}$$

Vidimo da je riječ o diskretnim uniformnim slučajnim varijablama. Očekivanje i varijancu im lagano izračunamo:

$$EX = EY = 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} + 2 \cdot \frac{1}{3} = 1,$$

$$EX^2 = EY^2 = 0^2 \cdot \frac{1}{3} + 1^2 \cdot \frac{1}{3} + 2^2 \cdot \frac{1}{3} = \frac{5}{3},$$

$$\operatorname{Var}(X) = \operatorname{Var}(Y) = EX^2 - (EX)^2 = \frac{5}{3} - 1 = \frac{2}{3}.$$

Da bi izračunali razdiobu slučajne varijable Z uočimo njaprije da ona poprima vrijednosti 0,1,2, 3 ili 4. nakon toga trebamo izračunati $P(Z = 0)$, $P(Z = 1)$, $P(Z = 2)$, $P(Z = 3)$ i $P(Z = 4)$. Da bi izračunali te vjerojatnosti uočimo najprije da je

$$\{Z = 0\} = \{\omega \in \Omega \mid Z(\omega) = 0\} = \{(a,a)\},$$

$$\{Z = 1\} = \{\omega \in \Omega \mid Z(\omega) = 1\} = \{(a,b),(b,a)\},$$

$$\{Z = 2\} = \{\omega \in \Omega \mid Z(\omega) = 2\} = \{(b,b),(a,c),(c,a)\},$$

$$\{Z = 3\} = \{\omega \in \Omega \mid Z(\omega) = 3\} = \{(b,c),(c,b)\},$$

$$\{Z = 4\} = \{\omega \in \Omega \mid Z(\omega) = 4\} = \{(c,c)\}.$$

Kako je vjerojatnost na Ω uniformna zaključujemo da je razdioba od Z

$$Z \sim \begin{pmatrix} 0 & 1 & 2 & 3 & 4 \\ 1/9 & 2/9 & 3/9 & 2/9 & 1/9 \end{pmatrix}.$$

Na sličan način odredimo razdiobe slučajnih varijabli V i W. One mogu poprimiti vrijednosti 0,1 ili 2, a vrijedi da je

$$\{V = 0\} = \{\omega \in \Omega \mid V(\omega) = 0\} = \{(a,a),(a,b),(b,a),(a,c),(c,a)\},$$

$$\{V = 1\} = \{\omega \in \Omega \mid V(\omega) = 0\} = \{(b,b),(b,c),(c,b)\},$$

$$\{V = 2\} = \{\omega \in \Omega \mid V(\omega) = 0\} = \{(c,c)\},$$

[15] Ovo smo mogli napraviti zato što slučajne varijable X i Y ne razlikuju slučajeve u kojima na kockici padne broj 1 ili 2 pa su ti ishodi bacanja nerazlučivi, odnosno elementarni.

$$\{W=0\}=\{\omega\in\Omega\mid W(\omega)=0\}=\{(a,a)\},$$
$$\{W=1\}=\{\omega\in\Omega\mid W(\omega)=1\}=\{(a,b),(b,a),(b,b)\},$$
$$\{W=2\}=\{\omega\in\Omega\mid W(\omega)=2\}=\{(a,c),(c,a),(b,c),(c,b),(c,c)\}.$$

Stoga su njihove razdiobe

$$V\sim\begin{pmatrix}0&1&2\\5/9&3/9&1/9\end{pmatrix}\quad W\sim\begin{pmatrix}0&1&2\\1/9&3/9&5/9\end{pmatrix}.$$

Izračunajmo očekivanje i varijancu slučajne varijable Z

$$EZ=0\cdot\frac{1}{9}+1\cdot\frac{2}{9}+2\cdot\frac{3}{9}+3\cdot\frac{2}{9}+4\cdot\frac{1}{9}=2,$$
$$EZ=0^2\cdot\frac{1}{9}+1^2\cdot\frac{2}{9}+2^2\cdot\frac{3}{9}+3^2\cdot\frac{2}{9}+4^2\cdot\frac{1}{9}=5,3333,$$
$$\operatorname{Var}(Z)=EZ^2-(EZ)^2=5,333-4=1,3333.$$

Na sličan način dobijemo

$$EV=0,55556,\quad EW=1,44444\ \text{ i}$$
$$\operatorname{Var}(V)=0,46914,\quad \operatorname{Var}(W)=0,46914.$$

Izračunajmo sada neke od kovarijanci/korelacija. Prije svega, jer su X i Y nezavisne slučaje varijable vrijdi da je

$$\operatorname{Cov}(X,y)=\operatorname{Corr}(X,Y)=0.$$

Da bi izračunali $\operatorname{Cov}(X,Z)$ trebamo izračunati $E(XZ)$. No, to je lagano jer je

$$E(XZ)=E(X(X+Y))=E(X^2+XY)=EX^2+EXEY=\frac{5}{3}+1=\frac{8}{3}.$$

Prema (6.27) i (6.36) dobivamo

$$\operatorname{Cov}(XZ)=E(XZ)-EXEZ=\frac{8}{3}-1\cdot 2=\frac{2}{3}\ \text{ i}$$
$$\operatorname{Corr}(XZ)=\frac{\operatorname{Cov}(XZ)}{\sqrt{\operatorname{Var}(X)\operatorname{Var}(Z)}}=\frac{2/3}{\sqrt{2/3\cdot 1,333}}=0,7071.$$

Vidimo da je korelacija dosta visoka pa to indicira visoku povezanost slučajnih varijabli X i Z. No, to nam je jasno jer veliki zbrojevi nastaju od velikih pribrojnika i obratno. Izračunajmo korelaciju između X i V. U tu svrhu trebamo izračunati $E(XV)$. U ovom slučaju X i V nisu nezavisne slučajne varijable[16] pa to očekivanje ne možemo jednostavno izračunati. S obzirom da je XV slučajna varijabla, a promatrana situacija je jednostavna, kao i vjerojatnosni prostor na kojem sve gledamo, u ovom slučaju možemo odrediti razdiobu slučajne varijable XV i onda izračunati njeno očekivanje. Uočimo da su vrijednosti koje može poprimiti varijabla XV 0,1, 2 i 4. Dodatno, uočimo da je slučajna varijabla X na Ω definirana kao $X(x,y)=x$, za $x,y\in\{a,b,c\}$. Stoga je

$$\{XV=0\}=\{\omega\in\Omega\mid XV(\omega)=0\}=\{(a,a),(a,b),(b,a),(a,c),(c,a)\},$$

[16] To je dosta jasno iz prirode slučajnog eksperimenta koji gledamo i definicija slučajnih varijabli X i W. Formalno, to možemo pokazati korištenjem karakterizacije nezavisnosti danoj u (5.13). Konkretno, $P(X=0,V=0)=P(\{(a,a),(a,b),(a,c)\})=3/9$, dok je $P(X=0)=1/3$ i $P(V=0)=5/9$. Stoga je $P(X=0,V=0)\neq P(X=0)P(V=0)$.

$$\{XV = 1\} = \{\omega \in \Omega \mid XV(\omega) = 1\} = \{(b,b),(b,c)\},$$
$$\{XV = 2\} = \{\omega \in \Omega \mid XV(\omega) = 2\} = \{(c,b)\},$$
$$\{XV = 4\} = \{\omega \in \Omega \mid XV(\omega) = 4\} = \{(c,c)\}.$$

Kako je na Ω vjerojatnost uniformna zaključujemo da je

$$XV \sim \begin{pmatrix} 0 & 1 & 2 & 4 \\ 5/9 & 2/9 & 1/9 & 1/) \end{pmatrix} \tag{6.38}$$

pa je

$$E(XV) = 0 \cdot \frac{5}{9} + 1 \cdot \frac{2}{9} + 2 \cdot \frac{1}{9} + 4 \cdot \frac{1}{9} = 0,88888.$$

Sada lagano izračunamo kovarijancu i korelaciju slučajnih varijabli X i V. Dobivamo

$$\mathrm{Cov}(XV) = E(XV) - EXEV = 0,88888 - 1 \cdot 0,55555 = 0,33333 \text{ i}$$

$$\mathrm{Corr}(XV) = \frac{\mathrm{Cov}(XV)}{\sqrt{\mathrm{Var}\,(X)\,\mathrm{Var}\,(V)}} = \frac{0,33333}{\sqrt{2/3 \cdot 0,46914}} = 0,596.$$

Na sličan način možemo izračunati i korelacije između X i W, zatim V i W, kao i Z i V. Probajte to napraviti za vježbu. Korelacija između V i W ispadne negativna i iznosi $-0,53$. □

Napomena 6.1.35 (Zajednička razdioba diskretnih slučajnih varijabli)**.** Iako je razdioba slučajne varijable XV dana u (6.38) ispravno izračunata uobičajenije je zapisati zajedničku razdiobu slučajnih varijabli X i V u formi tablice koju smo općenito zapisali u (5.14). Za slučajne varijable X i V iz prethodnog primjera zajednička razdioba se može općenito zapisati kao

$y\backslash x$	0	1	2	$P(V=y)$
0	$P(X=0,V=0)$	$P(X=1,V=0)$	$P(X=2,V=0)$	$\sum$
1	$P(X=0,V=1)$	$P(X=1,V=1)$	$P(X=2,V=1)$	$\sum$
2	$P(X=0,V=2)$	$P(X=1,V=2)$	$P(X=2,V=2)$	$\sum$
$P(X=x)$	$\sum$	$\sum$	$\sum$	1

Uočimo da se zbrajanjem po recima dobivaju vjerojatnosti $P(V=0)$, $P(V=1)$ i $P(V=2)$, a zbrajanjem po stupcima se dobivaju vjerojatnosti $P(X=0)$, $P(X=1)$ i $P(X=2)$. Zbroj svih vjerojatnosti u centralnom dijelu tablice je jednak 1.
Vjerojatnosti iz prethodne tablice izračunamo na sličan način na koji smo računali razdiobu slučajne varijable XV u prethodnom primjeru. Prije svega uočimo da je

$$P(X=0,V=1) = P(X=0,V=2) = P(X=1,V=2) = 0$$

jer minimum dva broja ne može biti veći od jednog od brojeva. Nadalje,

$$P(X=0,V=0) = P(\{(a,a),(a,b),(a,c)\}) = 1/3.$$

Slično,

$$P(X=1,V=0) = P(\{(b,a)\}) = 1/9 = P(\{(c,a)\}) = P(X=2,V=0),$$
$$P(X=1,V=1) = P(\{(b,b),(b,c)\}) = 2/9 \text{ i}$$
$$P(X=2,V=1) = P(\{(c,b)\}) = 1/9 = P(\{(c,c)\}) = P(X=2,V=2).$$

Dakle, zajednička razdioba od X i V je dana s

$y\backslash x$	0	1	2	$P(V=y)$
0	1/3	1/9	1/9	5/9
1	0	2/9	1/9	3/9
2	0	0	1/9	1/9
$P(X=x)$	1/3	1/3	1/3	1

(6.39)

Kada imamo zajedničku razdiobu dvije slučajne varijable, onda možemo izračunati ne samo očekivanje njihovog produkta, nego i očekivanje praktički proizvoljne funkcije te dvije slučajne varijable. Naime, vrijedi sljedeći teorem koji je analogon svojstava (6.7) i (6.8) u slučaju dvodimenzionalnog vektora. Vrijedi i općenitiji rezultat koji uključuje n-dimenzionalne vektore, ali ga ovdje ne navodimo.

Teorem 6.1.36. *Neka je $g : \mathbb{R}^2 \to \mathbb{R}$ neka funkcija. Neka su X i Y diskretne slučajne varijable čija je zajednička razdioba dana u (5.14). Tada je*

$$E(g(X,Y)) = \sum_{i=1}^{\infty}\sum_{i=1}^{\infty} g(a_i,b_i)P(X=a_i,Y=b_j), \tag{6.40}$$

Ako su X i Y neprekidne slučajne varijable sa zajedničkom funkcijom gustoće $f_{X,Y}$, onda je

$$E(g(X,Y)) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(x,y)f_{X,Y}(x,y)dxdy. \tag{6.41}$$

U primjeni prethodnog teorema treba paziti da sve naznačene sume i integrali postoje, ali ne želimo ući u tu problematiku na ovom mjestu. U svakom slučaju, primjenom Teorema 6.1.36, odnosno relacije (6.40), na funkciju $g(x,y) = x \cdot y$ i slučajne vektore X i V dobivamo

$$E(XV) = 0\cdot\frac{1}{3} + 0\cdot\frac{1}{9} + 0\cdot\frac{1}{9} + 0\cdot 0 + 1\cdot\frac{2}{9} + 2\cdot\frac{1}{9} + 0\cdot 0 + 2\cdot 0 + 4\cdot\frac{1}{3} = \frac{8}{9} = 0,8888.$$

Naravno, dobili smo isti rezultat kao u prethodnom primjeru. □

Na kraju ovog odjeljka pogledajmo jedan jednostavan primjer u kojem je zajednička razdioba dvije slučajne varijable već zadana.

Primjer 6.1.37. Neka su X i Y dvije diskretne slučajne varijable čija je zajednička razdioba dana s

$y\backslash x$	0	1	2	$P(Y=y)$
-1	1/6	1/6	1/6	1/2
1	0	1/2	0	1/2
$P(X=x)$	1/6	2/3	1/6	1

(6.42)

Iz zajedničke razdiobe slučajnih varijabli X i Y lagano dobijemo razdiobe slučajnih varijabli Xi Y

$$X \sim \begin{pmatrix} 0 & 1 & 2 \\ 1/6 & 2/3 & 1/6 \end{pmatrix} \quad Y \sim \begin{pmatrix} -1 & 1 \\ 1/2 & 1/2 \end{pmatrix},$$

a onda jednostavno izračunamo njihovo očekivanje

$$EX = 0\cdot\frac{1}{6} + 1\cdot\frac{2}{3} + 2\cdot\frac{1}{6} = 1 \quad \text{i} \quad EY = -1\cdot\frac{1}{2} + 1\cdot\frac{1}{2} = 0.$$

Izračunajmo korelaciju slučajnih varijabli X i Y. U tu svrhu trebamo izračunati $E(XY)$. Korištenjem relacije (6.40) dobivamo

$$E(XY) = 0\cdot\frac{1}{6} - 1\cdot\frac{1}{6} - 2\cdot\frac{1}{6} + 0\cdot 0 + 1\cdot\frac{1}{2} + 2\cdot 0 = 0.$$

Zbog toga je

$$\mathrm{Cov}(X,Y) = E(XY) - EXEY = 0 - 1 \cdot 0 = 0$$

pa je i

$$\mathrm{Corr}(X,Y).$$

Dakle, X i Y su nekorelirane slučajne varijable. Da li su nezavisne? Nisu, jer je

$$P(X=0, Y=1) = 0 \neq \frac{1}{6} \cdot \frac{1}{2} = P(X=0)P(Y=1).$$

Dakle, X i Y su nekorelirane slučajne varijable koje su zavisne. □

6.2 Granični teoremi

Pod graničnim teoremima u vjerojatnosti se smatraju **zakoni velikih brojeva** i **centralni granični teoremi**. U ovom potpoglavlju ćemo se upoznati s osnovnim verzijama tih teorema. Granični teoremi su teorijski fascinantne tvrdnje o konvergenciji slučajnih varijabli, ali njihova važnost ne staje na teorijskoj razini vjerojatnosti. Oni su poveznica vjerojatnosti sa statistikom i u velikoj su mjeri omogućili moderan razvoj statistike te njenu primjenu u brojnim područjima života.

Granični teoremi nam govore kako se ponašaju, na primjer, prosjeci (aritmetičke sredine) niza slučajnih varijabli. Da bi ih formulirali trebamo imati na raspolaganju niz ili nizove slučajnih varijabli. U ovom potpoglavlju pretpostavljamo da imamo niz slučajnih varijabli

$$X_1, X_2, \ldots, X_n \ldots$$

pri čemu su sve te slučajne varijable nezavisne i jednako distribuirane (iz iste su razdiobe). za takav niz slučajnih varijabli se kaže da je **nezavisan i jednako distribuiran**. Skraćenica je n.j.d. (eng. IID ili i.i.d. od *independent and identically distributed*).

6.2.1 Nejednakosti

Nakon nekog vremena provedenog u računanju raznih vjerojatnosti suočit ćemo se s problemima u kojima nije moguće (ili je teško) točno odrediti određenu vjerojatnost. U takvim situacijama je korisno imati nekakvu procjenu vjerojatnosti ili barem intervala u kojem se nalazi tražena vjerojatnost. Postoje razne nejednakosti u vjerojatnosti koje nam omogućavaju ograničavanje određenih vjerojatnosti vezanih uz slučajne varijable ili očekivanja slučajnih varijabli.

Da steknemo dojam o kakvim se nejednakostima radi i kako se do nekih od njih dolazi uzmimo neprekidnu slučajnu varijablu X s funkcijom gustoće f_X. Pretpostavimo da je X nenegativna te neka je $a > 0$ neki broj. Tada je

$$\begin{aligned} EX &= \int_0^\infty x f_X(x)dx = \int_0^a x f_X(x)dx + \int_a^\infty x f_X(x)dx \\ &\geq \int_a^\infty x f_X(x)dx \qquad (\text{na } (a,\infty) \text{ je } x \geq a) \\ &\geq \int_a^\infty a f_X(x)dx \\ &= a\int_a^\infty f_X(x)dx = aP(X \geq a). \end{aligned}$$

Dakle, vrijedi nejednakost

$$P(X \geq a) \leq \frac{EX}{a}. \tag{6.43}$$

Kada pogledamo gornju jednakost nije odmah jasno koja je korist od takve nejednakosti. Naime, ako je a velik, a očekivanje od X konačno onda će s desne strane biti vrlo mali broj. To je u redu jer želimo odrediti gornju ogradu na vjerojatnost s lijeve strane, ali s lijeve strane se u tom slučaju nalazi vjerojatnost da je X veća od nekog velikg broja, a intuitivno bismo i sami mogli smatrati da je to tako. Naravno, disperzija slučajne varijable X može biti velika pa ni ova ocjena nije beskorisna.

S druge strane, ako je a mali broj (blizak nuli), onda nam je zanimljivo pronaći gornju ogradu na takvu vjerojatnost. No, u tom slučaju je $1/a$ velik broj pa s desne strane nejednakosti imamo velik broj pomnožen s očkekivanjem od X što može biti vrlo velik broj. Uočite da nam u tom slučaju ništa ne znači dobivena gornja ograda jer mi već znamo da je vjerojatnost manja ili jednaka od 1.

Poanta je da za vrijednost a treba uzeti vrijednosti koje odgovaraju situaciji u kojoj želimo procjeniti traženu vjerojatnost. Općenito govoreći, ako je očekivanje od X konačno i uzmemo $a = EX$, onda nam gornja nejednakost kaže da je $P(X > EX) \leq 1$, što nije korisna procjena. Ali, već za $a = 2EX$ dobivamo nejednakost

$$P(X > 2EX) \leq \frac{EX}{2EX} = \frac{1}{2}$$

što je već zanimljivija gornja ograda za vjerojatnost s lijeve strane. Naime, dobivena nejednakost nam kaže da je vjerojatnost da će slučajna varijabla biti veća od svog dvostrukog očekivanja manja ili jednaka od $1/2$. Slično, za $a = 3EX$ dobivamo da je

$$P(X > 3EX) \leq \frac{EX}{3EX} = \frac{1}{3},$$

odnosno vjerojatnost da će slučajna varijabla biti veća od svog trostrukog očekivanja je manja ili jednaka od $1/3$.

Nejednakost (6.43) je osnova verzija općenitije Markovljeve nejednakosti koju dajemo u sljedećem teoremu (vidi Propoziciju 10.8 i Korolar 10.3 u [10])

Teorem 6.2.1 (Markovljeva nejednakost)**.** *Neka je X općenita sličajna varijabla, $r > 0$ broj te neka je $E|X|^r < \infty$. Tada vrijedi nejednakost*

$$P(|X| \geq a) \leq \frac{E|X|^r}{a^r}. \tag{6.44}$$

Za ovu nejednakost vrijede napomene koje smo dali ranije. U osnovi je glavni problem Markovljeve nejednakost to što ona pri ocjeni vjerojatnosti uzima u obzir samo očekivanje slučajne varijable (ili neki viši apsolutni moment). No, uz malu specijalizaciju te nejednakosti dobivamo jednu od najpoznatijih nejednakosti u vjerojatnosti - Čebiševljevu nejednakost koju iskazujemo u sljedećem teoremu.[17]

Teorem 6.2.2 (Čebiševljeva nejednakost)**.** *Neka je X općenita sličajna varijabla s konačnim očekivanjem i varijancom te neka je $a > 0$ broj. Tada vrijedi*

$$P(|X - EX| \geq a) \leq \frac{\mathrm{Var}\,(X)}{a^2}. \tag{6.45}$$

Čebiševljeva nejednakost slijedi direktno iz Markovljeve nejednakosti primijenjene na centriranu slučajnu varijablu $X - EX$. Naime, prema Markovljevoj nejednakosti je

$$P(|X - EX| \geq a) = P((X - EX)^2 \geq a^2) \leq \frac{E(X - EX)^2}{a^2} = \frac{\mathrm{Var}\,(X)}{a^2}.$$

[17] Čebišev i Markov su ruski matematičari iz 19. i početka 20. stoljeća.

Kao što vidimo, Čebiševljeva nejednakost nam daje ocjenu vjerojatnosti odstupanja slučajne varijable od njenog očekivanja. Ona pokazuje, kao što je i jasno ako malo razmislimo, da vrijednosti slučajne varijable s velikom vjerojatnošću, koja ovisi o varijanci, ne mogu proizvoljno odstupati od očekivanja slučajne varijable. Često se koristi i sljedeća verzija Čebiševljeve nejednakosti: umjesto a uzmemo $a\sigma$ u gornjoj nejednakosti, gdje je $\sigma = \sqrt{\mathrm{Var}\,(X)}$

$$P(|X - EX| \geq a\sigma) \leq \frac{1}{a^2}. \tag{6.46}$$

Ova nejednakost još eksplicitnije pokazuje vjerojatnost odstupanja slučajne varijable od njenog očekivanja u terminima varijance, odnosno standardne devijacije. Ukoliko za a uzmemo prirodni broj k (sjetite se vjerojatnosti suprotnog događaja) iz gornje nejednakosti dobivamo

$$P(|X - \mu| < k\sigma) = 1 - P(|X - \mu| \geq k\sigma) \geq 1 - \frac{1}{k^2}. \tag{6.47}$$

Za vrijednosti od $k = 2, 3, 4$ redom dobivamo da su vjerojatnosti odstupanja X-a od EX-a za manje od $k\sigma$ veće ili jednake od $3/4$, $8/9$, $15/16$.

Iako je Čebiševljeva nejednakost vrlo korisna, jer nam daje ocjenu vjerojatnosti odstupanja slučajne varijable od svog očekivanja, treba imati na umu da je ta ocjena prilično gruba. Sljedeći primjer to pokazuje.

Primjer 6.2.3. Uzmimo jediničnu normalnu slučajnu varijablu $Z \sim N(0, 1)$. Znamo da je $EZ = 0$, a $Var(Z) = 1$. U statistici se često gledaju vjerojatnosti poput

$$P(|X - EX| > 2\sigma) \quad \text{ili} \quad P(|X - EX| > 3\sigma),$$

za $X \sim N(\mu, \sigma)$. Te se vjerojatnosti pojednostavljuju[18] za $Z \sim N(0, 1)$ pa postaju

$$P(|Z| > 2) \quad \text{ili} \quad P(|Z| > 3).$$

Prema Čebiševljevoj nejednakosti imamo ocjene

$$P(|Z| > 2) \leq \frac{1}{4} = 0,25$$

i

$$P(|Z| > 3) \leq \frac{1}{9} \approx 0,111.$$

S druge strane, mi znamo izračunati vjerojatnosti s lijeve strane pomoću funkcije distribucije Φ jedinične normalne slučajne varijable. Iskoristimo simetričnost funkcije gustoće jedinične normalne slučajne varijable φ oko nule te skupovnu jednakost $\{|Z| > 2\} = \{Z < -2\} \cup \{Z > 2\}$ da dobijemo

$$P(|Z| > 2) = \Phi(-2) + (1 - \Phi(2)) = 2\Phi(-2))$$

i

$$P(|Z| > 3) = 2\Phi(-3).$$

Kako je $\Phi(-2) \approx 0,02275$ i $\Phi(-3) \approx 0,00135$, približno točne vrijednosti traženih vjerojatnosti su

$$P(|Z| > 2) \approx 0,0455$$

i

$$P(|Z| > 3) \approx 0,00271.$$

[18] Sjetite se da se svaka normalno distribuirana slučajna varijabla može lagano transformirati u jediničnu normalnu transformacijom $(X - \mu)/\sigma$.

Vidimo da su te vrijednosti dosta manje od onih dobivenih pomoću Čebiševljeve nejednakosti. Naravno, Čebiševljeva nejednakost daje samo gornju ogradu vjerojatnosti, ne i procjenu same vjerojatnosti. Uočite da je

$$P(|Z| \leq 1) \approx 0,68$$

$$P(|Z| \leq 2) \approx 0,95$$

i

$$P(|Z| \leq 3) \approx 0,997.$$

Ove su vjerojatnosti vrlo važne u statistici. One nam govore da je vjerojatnost da će se normalna slučajna varijabla nalaziti unutar jedne standardne devijecije oko svog očekivanja približno jednaka $0,68$, unutar dvije standardne devijacije oko svog očekivanja približno jednaka $0,95$, a unutar tri standardne devijacije oko svog očekivanja približno jednaka $0,997$. □

Primjer 6.2.4. Pretpostavimo da keramičar može u jednom danu postaviti u prosjeku 40 keramičkih pločica. Naravno, količina ovisi o prostoru, veličini pločica, raspoloženju keramičara i slično. Pretpostavimo da je varijanca broja postavljenih pločica jednaka 20 pločica. Što možemo reći o vjerojatnostima
a) da će keramičar u jednom danu postaviti više od 60 pločica
b) da će se u jednom danu broj pločica koje će postaviti keramičar razlikovati od prosjeka za više od 10 pločica.

Neka je X slučajna varijabla koja mjeri broj pločica koje keramičar postavi u jednom danu. Prema uvjetima zadatka je $EX = 40$ i $Var(X) = 20$. Ukoliko nemamo podatke o distribuciji slučajne varijable X nemamo puno načina za ocijeniti vjerojatnost odstupanja slučajne varijable od njenog očekivanja ili vjerojatnost da će slučajna varijabla biti veća od neke vrijednosti. Alati koji su nam dostupni su iskazani u nekoj od vjerojatnosnih nejednakosti poput Markovljeve ili Čebiševljeva nejednakost.[19]
a) Želimo naći ocjenu za $P(X > 60)$. Za to možemo upotrijebiti Markovljevu nejednakost (6.43). Njenom primjenom dobivamo

$$P(X > 60) \leq \frac{EX}{60} = \frac{40}{60} = \frac{2}{3}.$$

Ovo je dosta loša gornja ograda za vjerojatnost s lijeve strane. Iako vjerojatnosti nisu potpuno usporedive, primjenom Čebiševljeve nejednakosti (6.45) s $a = 20$ dobijemo ocjenu

$$P(|X - 40| \geq 20) \leq \frac{\mathrm{Var}\,(X)}{20^2} = \frac{20}{20^2} = \frac{1}{20}.$$

b) Direktnom primjenom Čebiševljeve nejednakosti dobivamo da je

$$P(|X - 40| \geq 10) \leq \frac{20}{10^2} = \frac{1}{5}.$$

Dakle, gornja ograda vjerojatnost $P(|X-40| \geq 10)$ je $1/4$. Uočimo da nam vjerojatnosne nejednakosti ne daju procjenu (aproksimaciju) tražene vjerojatnosti, nego samo njenu (gornju) granicu. Često je i to korisno. □

Osim nejednakosti kojima možemo naći ograde za vjerojatnosti koje se odnose na neke slučajne varijable, postoji cijeli niz nejednakosti koje se odnose na očekivanja slučajnih varijabli. Jedna od najpoznatijih, ne samo u vjerojatnosti, je Cauchy-Schwarzova nejednakost. Ona je iskazana u sljedećem teoremu.

[19] Postoje i neke strože nejednakosti poput Chernoffove.

Teorem 6.2.5 (Cauchy-Schwarz). *Neka su X i Y slučajne varijable s konačnim drugim momentima. Tada vrijedi*

$$|E(XY)| \leq \sqrt{EX^2 EY^2}. \tag{6.48}$$

Ranije smo u ovom poglavlju vidjeli da očekivanje produkta XY nije lagano izračunati ako ne znamo zajedničku razdiobu slučajnih varijabli X i Y. Cauchy-Schwarzova nejednakost nam daje gornju ogradu za apsolutnu vrijednost očekivanja produkta slučajnih varijabli X i Y što je često vrijedna informacija.

Ukoliko Cauchy-Schwarzovu nejednakost primjenimo na slučajne varijable $X - EX$ i $Y - EY$ dobijemo nejednakost

$$|\operatorname{Cov}(X,Y)| \leq \sqrt{\operatorname{Var}(X)\operatorname{Var}(Y)}.$$

Iz te nejednakosti direktno slijedi $|\operatorname{Corr}(X,Y)| \leq 1$, što smo već vidjeli u relaciji (6.37). Uočimo još da za $Y \equiv 1$ slijedi da je $EY^2 = 1$ pa se Cauchy-Schwarzova nejednakost svede na $|EX| \leq \sqrt{EX^2}$. Kvadriranjem te nejednakosti dobivamo

$$(EX)^2 \leq EX^2.$$

Ta nejednakost pokazuje da je varijanca uvije nenegativan broj, ali i da iz konačnosti drugog momenta slučajne varijable slijedi konačnost očekivanja. S time smo se u općenitijem slučaju već susreli u (6.22).

Za kraj ovog kratkog pregleda osnovnih nejednakosti u vjerojatnosti napomenimo da postoje i neke druge dosta općenite nejednakosti ovog tipa, poput Jensenove nejednakosti. Ona kaže da za konveksnu funkciju $g : \mathbb{R} \to \mathbb{R}$ vrijedi

$$g(EX) \leq E(g(X)).$$

Funkcija g je konveksna ako za $x, y \in \mathbb{R}$ i $0 \leq q \leq 1$ vrijedi $g(tx + (1-t)y) \leq tg(x) + (1-t)g(y)$. Primjer konveksne funkcije je $g(x) = x^2$.

6.2.2 Zakoni velikih brojeva

Neka je $X_1, X_2, \ldots$ niz nezavisnih i jednako distribuiranih slučajnih varijabli (n.j.d.) s (konačnim) očekivanjem μ i konačnom varijancom σ^2. Neka je $n \in \mathbb{N}$. Definiramo slučajne varijable (za svaki n)

$$\bar{X}_n = \frac{X_1 + X_2 + \ldots + X_n}{n}.$$

Zbog linearnosti očekivanja je

$$E(\bar{X}_n) = \frac{1}{n}(EX_1 + E_X - 2 + \ldots + EX_n) = \frac{1}{n} n\mu = \mu. \tag{6.49}$$

Kako su slučajne varijable $X_1, X_2, \ldots, X_n$ nezavisne prema (6.15) zaključujemo

$$\operatorname{Var}(\bar{X}_n) = \frac{1}{n^2}(\operatorname{Var}(X_1) + \operatorname{Var}(X_2) + \ldots + \operatorname{Var}(X_n)) = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}. \tag{6.50}$$

Jasno, jer su $X_1, X_2, \ldots, X_n$ jednako distribuirane vrijedi $\operatorname{Var}(X_1) = \ldots = \operatorname{Var}(X_n)$. Uočimo, kako je varijanca slučajnih varijabli X_i konačna, za $n \to \infty$ slijedi $\operatorname{Var}(\bar{X}_n) \to 0$.

Iskoristimo sada Čebiševljevu nejednakost za sljedeću ocjenu

$$P(|\bar{X}_n - \mu| > \epsilon) = P(|\bar{X}_n - E(\bar{X}_n)| > \epsilon) \leq \frac{1}{\epsilon^2} \operatorname{Var}(\bar{X}_n) = \frac{\sigma^2}{n\epsilon^2}, \tag{6.51}$$

gdje je $\epsilon > 0$ proizvoljan pozitivan broj. Ako u (6.51) uzmemo limes, za $n \to \infty$ dobivamo

$$\lim_{n\to\infty} P(|\bar{X}_n - \mu| > \epsilon) = 0.$$

Time smo dokazali sljedeći teorem koji se naziva **slabi zakon velikih brojeva**.

Teorem 6.2.6 (Slabi zakon velikih brojeva)**.** *Neka je $X_1, X_2, \ldots$ niz nezavisnih i jednako distribuiranih slučajnih varijabli (n.j.d.) s očekivanjem μ i konačnom varijancom σ^2.*[20] *Tada vrijedi*

$$\lim_{n\to\infty} P(|\bar{X}_n - \mu| > \epsilon) = 0. \tag{6.52}$$

Napomena 6.2.7 (Konvergencija po vjerojatnosti)**.** Za općeniti niz slučajnih varijabli $X_1, X_2, \ldots$ kažemo da **konvergira po vjerojatnosti** prema slučajnoj varijabli X ako za svako $\epsilon > 0$ vrijedi

$$\lim_{n\to\infty} P(|X_n - X| > \epsilon) = 0. \tag{6.53}$$

Za označavanje takvog tipa konvergencije se koriste oznake

$$X_n \xrightarrow{P} X \quad \text{ili} \quad (P)\lim_{n\to\infty} X_n = X.$$

Za konvergenciju po vjerojatnosti vrijede neka dobra svojstva poput: neka su $(X_i)_{i\in\mathbb{N}}$ i $(Y_i)_{i\in\mathbb{N}}$ dva niza slučajnih varijabli, $a, b \in \mathbb{R}$, te neka $X_n \xrightarrow{P} X$ i $Y_n \xrightarrow{P} Y$. Onda vrijedi

$$aX_n + bY_n \xrightarrow{P} aX + bY \quad \text{i} \quad X_nY_n \xrightarrow{P} XY.$$

□

Slabi zakon velikih brojeva govori o tome da aritmetička sredina n.j.d. niza slučajnih varijabli $(X_i)_{i\in\mathbb{N}}$ konvergira po vjerojatnosti prema očekivanju slučajnih varijabli X_i. Uz iste pretpostavke može se dokazati i jači rezultat prema kojem postoji događaj E takav da je $P(E) = 0$, a za $\omega \in E^c$ vrijedi

$$\lim_{n\to\infty} \bar{X}_n(\omega) = \mu.$$

Jasno, $P(E^c) = 1$. Taj rezultat je iskazan u sljedećem teoremu koji nazivamo jakim zakonom velikih brojeva.

Teorem 6.2.8 (Jaki zakon velikih brojeva)**.** *Neka je $X_1, X_2, \ldots$ niz nezavisnih i jednako distribuiranih slučajnih varijabli s očekivanjem μ i konačnom varijancom σ^2.*[21] *Tada vrijedi*

$$P(\lim_{n\to\infty} \bar{X}_n = \mu) = 1. \tag{6.54}$$

Napomena 6.2.9 (Konvergencija gotovo sigurno)**.** Konvergenicija u Teoremu 6.2.8 se naziva **konvergencija gotovo sigurno**. S pojmom gotovo sigurno smo se susreli u Napomeni 5.4.1. On nam govori da neko svojstvo vrijedi za sve elemente nekog vjerojatnosnog prostora, osim za eventualno neke čije je vjerojatnost jednaka nuli. Od svih konvergencija u vjerojatnosti taj je tip konvergencije najbliži uobičajenom (onom iz realne analize). Za općeniti niz slučajnih varijabli $X_1, X_2, \ldots$ kažemo da **konvergira gotovo sigurno** prema slučajnoj varijabli X ako

$$P(\{\omega \in \Omega \mid \lim_{n\to\infty} X_n(\omega) = X(\omega)\}) = 1 \tag{6.55}$$

Za označavanje takvog tipa konvergencije se koriste oznake

$$X_n \xrightarrow{g.s.} X \quad \text{ili} \quad (g.s.)\lim_{n\to\infty} X_n = X.$$

[20] Može se pokazati da je za valjanost slabog zakona velikih brojeva za n.j.d. niz slučajnih varijabli dovoljno da je očekivanje EX_1 konačno. Pogledajte Teorem u [6], str 243.

[21] Može se pokazati da je za valjanost jakog zakona velikih brojeva za n.j.d. niz slučajnih varijabli nužno i dovoljno da je očekivanje EX_1 konačno. Pogledajte Teorem 12.15 u [10].

Za konvergenciju gotovo sigurno vrijede neka dobra svojstva kao i za konvergenciju po vjerojatnosti. neka su $(X_i)_{i\in\mathbb{N}}$ i $(Y_i)_{i\in\mathbb{N}}$ dva niza slučajnih varijabli, $a, b \in \mathbb{R}$, te neka $X_n \xrightarrow{g.s.} X$ i $Y_n \xrightarrow{g.s.} Y$. Onda vrijedi

$$aX_n + bY_n \xrightarrow{g.s.} aX + bY \quad \text{i} \quad X_nY_n \xrightarrow{g.s.} XY.$$

Ako su još slučajne varijable Y_n, $n \in \mathbb{N}$, i Y različite od nula (gotovo sigurno), onda i

$$\frac{X_n}{Y_n} \xrightarrow{g.s.} \frac{X}{Y}.$$

Važno je napomenuti da je konvegencija gotovo sigurno jača od konvergencije po vjerojatnosti, odnosno ako $X_n \xrightarrow{g.s.} X$, onda i $X_n \xrightarrow{P} X$.

Jedna od posljedica konvergencije (bilo gotovo sigurno bilo po vjerojatnosti) je da iz zakona velikih brojeva slijedi da ako imamo nizove n.j.d. slučajnih varijabli (X_n) i (Y_n) s očekivanjima μ_X i μ_Y i konačnim varijancama, onda

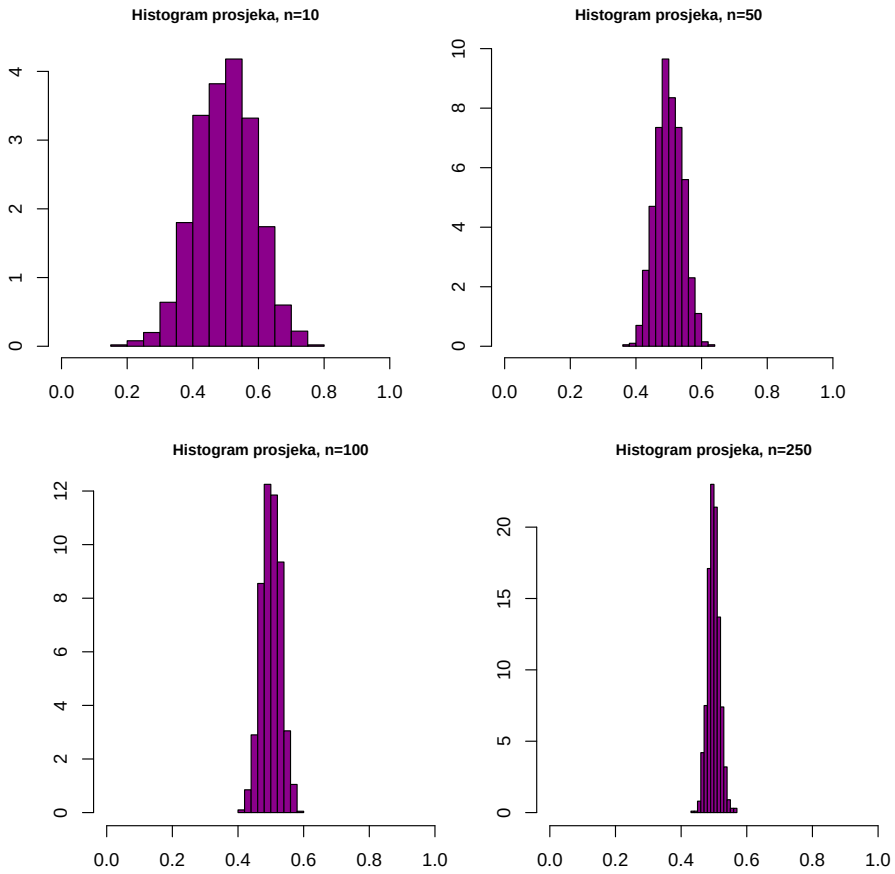
$$\bar{X}_n\bar{Y}_n \to \mu_X\mu_Y$$

i po vjerojatnosti i gotovo sigurno. □

Koju god verziju da gledamo zakon velikih brojeva nam govori da prosjeci nezavisnih i jednako distribuiranih slučajnih varijabli konvergiraju prema očekivanju tih slučajnih varijabli (proizvoljno su blizu μ kada n raste u beskonačnost). To znači da se očekivanje slučajne varijable može po volji točno aproksimirati prosjekom (aritmetičkom sredinom) slučajnih varijabli koje su nezavisne i jednako distribuirane kao polazna slučajna varijabla. Dobro je uočiti da nam zakoni velikih brojeva ne govore ništa o brzini konvergencije prosjeka prema očekivanju (koliko velik mora biti n da bi prosjeci bli udaljeni od očekivanja za manje od nekog $\epsilon > 0$). Takvi rezultati, odnosno ocjene, se mogu dobiti primjenom zakona ponovljenog logaritma, ali to je tema van dosega ove skripte.

Pogledajmo na primjeru o čemu govori zakon velikih brojeva. Na donjim slikama su prikazani histogrami prosjeka uniformno distribuiranih brojeva (to su nezavisne realizacije $U(0,1)$ slučajnih varijabli). Na prvom grafu je uzet prosjek 10 brojeva te je 1000 puta ponovljen proces da vidimo disperziju izračunatih prosjeka. Na ostalim grafovima je ponovljen proces s time da se povećava broj brojeva kojima računamo prosjek - pogledajte naslove grafova. Vidimo da se s rastom n prosjeci sve više grupiraju oko vrijednosti $1/2$, što je očekivanje jedinične uniformne distribucije.

```
> par(mfrow = c(1, 2), mar=c(3,2,3,2))
> set.seed(42)
> for (i in 1:1000){
+ x.values = runif(10)
+ y.values[i] = mean(x.values)
+ }
> hist(y.values, main="Histogram prosjeka, n=10", probability=TRUE,
+     xlim=c(0, 1), ylab="Relativna frekvencija", cex.main=0.8,
+     cex.lab=0.8,col="darkmagenta")
> for (i in 1:1000){
+ x.values = runif(50)
+ y.values[i] = mean(x.values)
+ }
> hist(y.values, main="Histogram prosjeka, n=50", probability=TRUE,
+     xlim=c(0, 1), ylab="Relativna frekvencija", cex.main=0.8,
+     cex.lab=0.8,col="darkmagenta")
```



Zakon velikih brojeva ima i neke druge posljedice. Na primjer, recimo da želimo izračunati vjerojatnost da će neka slučajna varijabla (s konačnim očekivanjem i varijancom) biti u nekom skupu oblika $(a, b]$, $a < b$ (može biti i općenitiji skup, ali ovo je dovoljno za prikaz koncepta). Drugim riječima, ako je zadana slučajna varijabla X zanima nas vjerojatnost

$$p = P(X \in (a, b]).$$

Načelno govoreći bi tu vjerojatnost procjenili na sljedeći način: uzeli bi niz nezavisnih slučajnih varijabli $X_1, X_2, \ldots, X_n$ koje su jednako distribuirane kao X (to su nezavisne realizacije slučajnog pokusa koji opisuje X) i onda bi brojali koliko se puta pojavljuje događaj $\{X_i \in (a, b]\}$ te bi podijelili taj broj s ukupnim brojem ponavljanja slučajnog pokusa n. Intuitivno bi taj broj trebao biti blizu vjerojatnosti p. Formalno, definirajmo niz indikatora

$$Y_i = \begin{cases} 1, & X_i \in (a, b] \\ 0, & X_i \notin (a, b]. \end{cases}$$

Svaki taj indikator je slučajna varijabla i funkcija je nezavisnih slučajnih varijabli X_i. Stoga su Y_i, $i = 1, 2, \ldots, n$ nezavisne slučajne varijable (pogledajte svojstvo v) u Propoziciji 6.1.14). Njihovo je očekivanje tražena vjerojatnost p (sjetite se očekivanja Bernoullijeve slučajne varijable). Prema zakonu velikih brojeva znamo da

$$\bar{Y}_n = \frac{Y_1 + Y_2 + \ldots + Y_n}{n}$$

konvergiraju prema očekivanju od $\bar{Y}_n$, a ono je jednako p. Dakle

$$\bar{Y}_n \to E(Y_1) = p. \tag{6.56}$$

Zakon velikih brojeva se može primijeniti za procjenu funkcije gustoće neprekidne slučajne varijable, izračuna površine ispod integrala, kao i za konvergencija empirijskih funkcija distribucije. S nekim od tih primjena ćemo se upoznati malo kasnije.

Primjer 6.2.10 (Još malo o konvergenciji u zakonu velikih brojeva)**.** Povijesno gledano se (slabi) zakon velikih brojeva prvi puta formulira za nezavisne Bernoullijeve slučajne varijable (za detaljniji prikaz zainteresirani čitatelj može pogledati poglavlje 9 u [13]). Sam Bernoulli je formulirao prvu verziju teorema i to proučavajući ponašanje ishoda bacanja simetričnog novčića. On primjećuje da ako bacamo novčić n puta te glava padne m puta, onda s povećanjem broja bacanja vjerojatnost događaja $\{|\frac{m}{n} - \frac{1}{2}| < \epsilon\}$ teži k jedan, za proizvoljan $\epsilon > 0$. Važno je uočiti vjerojatnosni karakter te tvrdnje. Naime, tvrdi se da određene vjerojatnosti, koje ovise o n konvergiraju prema jedan. Suvremenim rječnikom govoreći, ishode bacanja simetričnog novčića možemo modelirati nizom nezavisnih Bernoullijevih slučajnih varijabli B_i,[22] $i \in \mathbb{N}$, pa se tvrdnja o konvergenciji vjerojatnosti prema jedan može formulirati kao

$$P\Big(\Big|\frac{1}{n}\sum_{i=1} B_i - \frac{1}{2}\Big| < \epsilon\Big) \to 1,\ n \to \infty. \tag{6.57}$$

Ono što se ne tvrdi u gornjem teoremu je da brojevi m/n konvergiraju prema $1/2$. U čemu je razlika? Ako gledamo beskonačan niz bacanja simetričnog novčića (jasno, to ne možemo realizirati u praksi), onda je jedan od mogućih ishoda bacanja onaj u kojem padnu sve glave. Na taj način dobivamo beskonačan niz jedinica $1111\ldots$, a jasno je da aritmetička sredina tog niza (za prvih n članova niza) nije $1/2$, nego 1. Ono što tvrdi slabi zakon velikih brojeva je da se s povećanjem broja bacanja n smanjuje broj nizova bacanja za koje ne vrijedi da im je prosjek (zbroj nezavisnih Bernoullijevih slučajnih varijabli) jednak $1/2$. Malo preciznije rečeno, takvi nizovi bacanja novčića postaju zanemarivi, odnosno vjerojatnost njihova pojavljivanja teži k nuli. Naravno, prema formuli za vjerojatnost suprotnog događaja je (6.57) exvivalentno s

$$p_n = P\Big(\Big|\frac{1}{n}\sum_{i=1}^{n} B_i - \frac{1}{2}\Big| \geq \epsilon\Big) \to 0,\ n \to \infty$$

što smo i tvrdili u Teoremu 6.2.6. Dakle, slabi zakon velikih brojeva tvrdi da repne vjerojatosti p_n teže nuli kada n raste. Koja je razlika u odnosu na jaki zakon velikih brojeva? U jakom zakonu je iskazana konvergencija gotovo sigurno. U Napomeni 6.55 je dana definicija konvergencije gotovo sigurno, ali je korisno uočiti da je ta definicija za prosjeke ekvivalentna tvrdnji (vidi Propoziciju 10.16 u [10])

$$\lim_{n\to\infty} P\left(\bigcup_{k=n}^{\infty}\left\{\Big|\frac{1}{k}\sum_{i=1}^{k} B_i - \frac{1}{2}\Big| \geq \epsilon\right\}\right) = 0. \tag{6.58}$$

Kako je očito

$$\left\{\Big|\frac{1}{n}\sum_{i=1}^{n} B_i - \frac{1}{2}\Big| > \epsilon\right\} \subset \bigcup_{k=n}^{\infty}\left\{\Big|\frac{1}{k}\sum_{i=1}^{k} B_i - \frac{1}{2}\Big| \geq \epsilon\right\}$$

jasno je da iz konvergencije gotovo sigurno slijedi konvergencija po vjerojatnosti, odnosno konvergencija repnih vjerojatnosti p_n prema nuli u slučaju koji ovdje promatramo. Jaki zakon velikih brojeva govori da postoji skup vjerojatnosti jedan na kojem $\frac{1}{n}\sum_{i=1}^{n} B_i$ konvergira prema $1/2$, a ta konvergencija eventualno ne vrijedi van tog skupa čija je vjerojatnost jednaka 0. Jaki zakon velikih brojeva možemo zapisati i kao

$$P\Big(\lim_{n\to\infty}\Big(\frac{1}{n}\sum_{i=1}^{n} B_i - \frac{1}{2}\Big) = 0\Big) = 1$$

□

[22] Vrijednost 1 označava "pala je glava", a 0 "palo je pismo".

6.2.3 Centralni granični teorem

Neka je opet $X_1, X_2, \ldots$ niz nezavisnih i jednako distribuiranih slučajnih varijabli s konačnim očekivanjem μ i konačnom varijancom σ^2. U prošlom poglavlju smo vidjeli da prosjeci $\bar{X}_n$ konvergiraju prema μ, očekivanju slučajnih varijabli X_i, s vjerojatnošću 1. Kada pogledamo gornje grafove sa simulacijama vidimo da je to istina, ali se može naslutiti da bi se možda mogla odrediti i granična distribucija prosjeka $\bar{X}_n$. Naime, čini se da histogrami prosjeka izgledaju poput normalne razdiobe. Vidjet ćemo da je to zaista istina, s time da ne gledamo same prosjeke nego ih prije centriramo i normaliziramo.

Preciznije, oduzmimo od slučajne varijable $\bar{X}_n$ njeno očekivanje μ i podijelimo je s njenom standardnom devijacijom $\sigma/\sqrt{n}$. Tako definiramo novi niz slučajnih varijabli

$$Z_n = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma}.$$

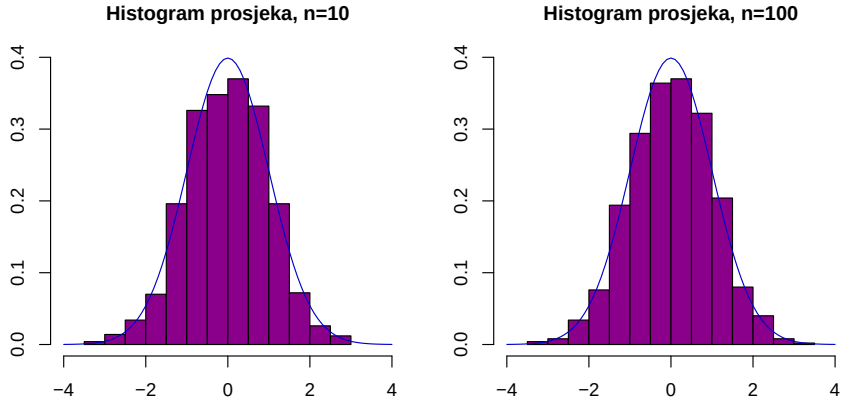
Pogledajmo što se događa kada primijenimo ovaj postupak na prije prikazane prosjeke slučajno generiranih brojeva. Neka je $U_1, U_2, \ldots \sim U(0,1)$ niz nezavisnih i jednako distribuiranih uniformnih slučajnih varijabli na $(0,1)$. Za $n \in \mathbb{N}$ definirajmo

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} U_i.$$

Jer je $EU_1 = 1/2$, a $\mathrm{Var}\,(U_1) = 1/12$, prema (6.49) i (6.50) zaključujemo da je

$$E(\bar{X}_n) = \frac{1}{2} \quad \text{i} \quad \mathrm{Var}\,(\bar{X}_n) = \frac{1}{12n}.$$

Prema gornjoj definiciji je $Z_n = \sqrt{12n}(\bar{X}_n - 1/2)$. Provedimo sada simulacije poput onih iz prošlog odjeljka: generiramo uzorak duljine n iz jedinične uniformne razdiobe, izračunamo vrijednost od Z, ponovimo taj postupak 1.000 puta i nacrtamo histogram. Za vrijednosti $n = 10$ i $n = 100$ dobivamo



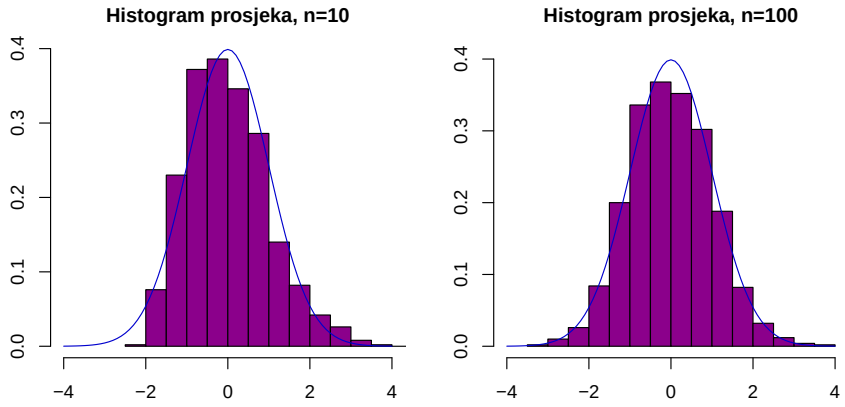
Uzmimo još jednu razdiobu i ponovimo postupak. Neka su $X_1, X_2, \ldots \sim Exp(3)$ niz nezavisnih i jednako distribuiranih eksponencijalnih slučajnih varijabli s parametrom $\lambda = 3$. Za $n \in \mathbb{N}$ definirajmo

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} U_i.$$

Jer je $EX_1 = 1/3$, a $\mathrm{Var}\,(X_1) = 1/0$, prema (6.49) i (6.50) zaključujemo da je

$$Z = \sqrt{9n}(\bar{X}_n - 1/3).$$

Provedimo opet simulacije kao za uniformno distribuirane podatke za $n = 10$ i $n = 100$. Dobivamo histograme



Na sve prethodne histograme smo dodali teorijske vrijednosti jedinične normalne razdiobe radi usporedbe sa simuliranim podacima. Vidimo da su centralizirane i normalizirane vrijednosti bliske jediničnoj normalnoj razdiobi. Razlog za takvo ponašanje je općeniti rezultat, **centralni granični teorem** (CGT), koji iskazujemo u sljedećem teoremu.

Teorem 6.2.11 (Centralni granični teorem). *Neka je $X_1, X_2, \ldots$ niz nezavisnih i jednako distribuiranih slučajnih varijabli (n.j.d.) s očekivanjem μ i konačnom varijancom σ^2. Pretpostavimo da je $\sigma_1 > 0$. Tada za slučajne varijable*

$$Z_n = \frac{\bar{X}_n - E\bar{X}_n}{\sqrt{Var(\bar{X}_n)}} = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma} \tag{6.59}$$

vrijedi

$$\lim_{n\to\infty} F_{Z_n}(x) \to \Phi(x), \ x \in \mathbb{R}. \tag{6.60}$$

Vidimo da nam centralni granični teorem govori da niz funkcija distribucija slučajnih varijabli Z_n, $n \in \mathbb{N}$, konvergira prema funkciji distribucije Φ jedinične normalne slučajne varijable $Z \sim N(0,1)$. Takav tip konvergencije nazivamo **konvergenicijom po distribuciji**. Riječ je o konvergenciji funkcija pa tu konvergenciju formalno možemo zapisati kao: Za $x \in \mathbb{R}$, za sve $\epsilon > 0$ postoji $n_0 \in \mathbb{N}$ takav da za $n \geq n_0$ vrijedi

$$\left| F_{Z_n}(x) - \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{x} e^{-t^2/2} dt \right| < \epsilon.$$

Dakle, razdioba od Z_n postaje sve bliskija jediničnoj normalnoj razdiobi kada n raste. Sjetimo se, $F_{Z_n}(x) = P(Z_n \leq x)$ pa centralni granični teorem zapravo daje procjenu

$$P\left(\sqrt{n}\frac{\bar{X}_n - \mu}{\sigma} \leq x\right) \approx P(Z \leq x) = \Phi(x), \ x \in \mathbb{R}. \tag{6.61}$$

Uočimo da konvergencija u Teoremu 6.2.11 vrijedi za prosjeke slučajnih varijabli iz proizvoljne razdiobe, pod uvjetom da imaju konačno očekivanje i varijancu te da su X_i nezavisne slučajne varijable (pogledajte Teorem 14.3 u [10]). Riječ je o vrlo općenitom teoremu. Iako ima ograničenja za njegovu primjenu, on je vrlo primjenjiv za mnoge slučajne pojave poput raznih fizičkih obilježja (visina, težina, raspon krila, duljina stabljike i tako dalje) mnogih populacija. S te strane gledano gotovo da je riječ o prirodnom zakonu koji govori da je prosječna razdioba obilježja nezavisnih jedinki približno normalna. Radi potpunosti treba istaknuti da postoje i neke druge granične razdiobe koje se javljaju u asimptotskim rezultatima poput centralnog graničnog teorema (na primjer, neke ekstremne razdiobe poput Gumbelove s kojom smo se susreli u prethodnom poglavlju). Pogledajmo jedan primjer primjene centralnog graničnog teorema.

Primjer 6.2.12. Pretpostavimo da neka osiguravajuća kuća ima osiguranih 16.000 automobila. Gledamo ukupne godišnje zahtjeve za naknadom štete od strane osiguranika. Pretpostavimo da se pojedinačni zahtjev za naknadom štete od strane pojedinog osiguranika može opisati slučajnom varijablom s očekivanjem od 312 eura i varijancom od 550 eura. Pitamo se koja je vjerojatnost da će ukupni godišnji zahtjevi osiguranika za naknadom štete biti veći od 5 miliona eura.
Ako s T označimo slučajnu varijablu koja označava ukupni godišnji zahtjev osiguranika za naknadom štete, a s X_i, $i = 1, 2, \ldots, 16.000$ zahtjev za štetom pojedinog osiguranika, onda je $T = X_1 + \ldots + X_{16.000}$. Razumno je pretpostaviti da su X_i nezavisni.[23] Kako želimo primijeniti centralni granični teorem možemo krenuti tako da podijelimo T (kao zbroj nezavisnih slučajnih varijabli) s 16.000 da dobijemo $\bar{X}_{16000}$ u prijašnjim oznakama. Tada je

$$P(T > 5.000.000) = P(T/16000 > 5000000/16000) = P(T/16000 > 312, 5).$$

Kako su nam zadani očekivanje i varijanca od X_i oduzmimo s obje strane očekivanje 312, pomnožimo izraz pod znakom vjerojatnosti u gornjem redu s $\sqrt{16000}$ te ga podijelimo s korijenom varijance $\sqrt{550}$. Korištenjem centralnog graničnog teorema, odnosno relacije (6.61), dobijemo aproksimaciju

$$\begin{aligned} P(T > 5.000.000) &= P\Big(\sqrt{16000}\frac{T/16000 - 312}{\sqrt{550}} > \sqrt{16000}\frac{312,5 - 312}{\sqrt{550}}\Big) \\ &\approx P(Z > 2,6968) = 0,0035, \end{aligned}$$

gdje je $Z \sim N(0, 1)$. Uočite da je

$$P(Z > 2,6968) = 1 - P(Z \leq 2,6968) = 1 - \Phi(2,6968), \tag{6.62}$$

a vrijednosti funkcije distribucije Φ jedinične normalne slučajne variajble su tabelirane pa ih možemo očitati iz tabilica. Alternativno u R-u izračunamo

```
> 1-pnorm(2.6968)

[1] 0.003500465
```

Uz malo drugačiji zapis gornji izračun možemo provesti i tako da gledamo samo slučajnu varijablu T (neuprosječenu) te da Z_n iz centralnog graničnog teorema zapišemo kao

$$Z_n = \frac{X_1 + \ldots + X_n - n\mu}{\sqrt{n}\sigma}.$$

Iz uvjeta zadatka dobivamo $n\mu = 16000 \cdot 312 = 4.992.000$, dok je $\sqrt{n}\sigma = \sqrt{16000 * 550} = 2.966,48$. Iz centralnog graničnog teorema slijedi aproksimacija

$$P(T > 5.000.000) = P\Big(\frac{T - 4992000}{2966,48} > \frac{5000000 - 4992000}{2966,48}\Big) \approx P(Z > 2,6968) = 0,0035.$$

Ovaj primjer pokazuje jednostavnu upotrebu centralnog graničnog teorema za izračun (aproksimaciju) vjerojatnosti zbroja nezavisnih slučajnih varijabli. Primjer ukazuje na put kojim se mogu procjenjivati štete koje osiguravatelj može isplatiti, a to je osnova za kapitalne rezerve koje osiguravatelj mora imati kako bi imao održivo poslovanje. □

[23] Da se radi o osiguranju od potresa to ne bi bila prirodna pretpostavka za pojedinačne osiguranike.

Općenitost centralnog graničnog teorema podrazumjeva da se on može primijeniti u mnogim situacijama. Primjerice, malom transformacijom očekivanja i varijance vidimo da nam centralni granični teorem govori da distribuciju od $\bar{X}_n$ možemo aproksimirati s $N(\mu, \sigma^2/n)$. Naime, prema (6.59) imamo

$$\bar{X}_n = \frac{\sigma}{\sqrt{n}} Z_n + \mu. \tag{6.63}$$

Jer je $Z_n \approx N(0,1)$ i jer normalna slučajna varijabla ostaje normalna nakon linearne transformacije (pogledajte relaciju (5.26)) za rastuće n-ove dobivamo aproksimaciju

$$\bar{X}_n \approx N(\mu, \sigma^2/n). \tag{6.64}$$

Već smo od prije znali da su očekivanje i varijanca od $\bar{X}_n$ jednaki μ i σ^2/n, ali nam prethodni rezultat govori da je $\bar{X}_n$ približno normalno distibuiran s tim očekivanjem i varijancom. Razmišljajući dalje u tom smjeru uočimo da je $X_1 + \ldots + X_n = n\bar{X}_n$ pa za velike vrijednosti n imamo aproksimaciju

$$\sum_{i=1}^{n} X_i \approx N(n\mu, n\sigma^2) \tag{6.65}$$

jer za slučajnu varijablu $Y \sim N(\mu, \sigma^2/n)$ vrijedi da je $nY \sim N(n\mu, n\sigma^2)$, opet prema relaciji (5.26). Jedan od najpoznatijih slučajeva zbroja nezavisnih slučajnih varijabli je zbroj nezavisnih Bernoullijevih slučajnih varijabli čija je razdioba binomna.

Na taj način dolazimo do jednog od posebnih slučajeva centralnog graničnog teorema koji se zove **Moivre-Laplaceov centralni granični teorem**, a on je povijesno gledano bio prvi teorem tog tipa. On kaže da za binomne slučajne varijable $X_n \sim B(n,p)$, $n \in \mathbb{N}$, $p \in (0,1)$, te realne brojeve a i b, $a < b$ vrijedi

$$\lim_{n\to\infty} P\Big(a \le \frac{X_n - np}{\sqrt{np(1-p)}} \le b\Big) = \Phi(b) - \Phi(a) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-x^2/2} dx. \tag{6.66}$$

Kao što vidimo, Moivre-Laplaceov teorem nam daje teorijsku osnovu za procjenu vrjerojatnosti vezanih uz binomne slučajne varijable. Sjetite se, za $X_n \sim B(n,p)$ je $EX_n = np$, a $Var(X_n) = np(1-p)$. Obje smo te veličine jednostavno izračunali iz činjenice da se binomna slučajna varijabla može izraziti kao zbroj nezavisnih Bernoullijevih. Uočimo da je

$$P\Big(a \le X_n \le b\Big) = P\Big(\frac{a - np}{\sqrt{np(1-p)}} \le \frac{X_n - np}{\sqrt{np(1-p)}} \le \frac{b - np}{\sqrt{np(1-p)}}\Big) \tag{6.67}$$

pa nam Moivre-Laplaceov centralni granični teorem zapravo kaže da je za velike n

$$P\Big(a \le X_n \le b\Big) \approx \Phi\Big(\frac{b - np}{\sqrt{np(1-p)}}\Big) - \Phi\Big(\frac{a - np}{\sqrt{np(1-p)}}\Big). \tag{6.68}$$

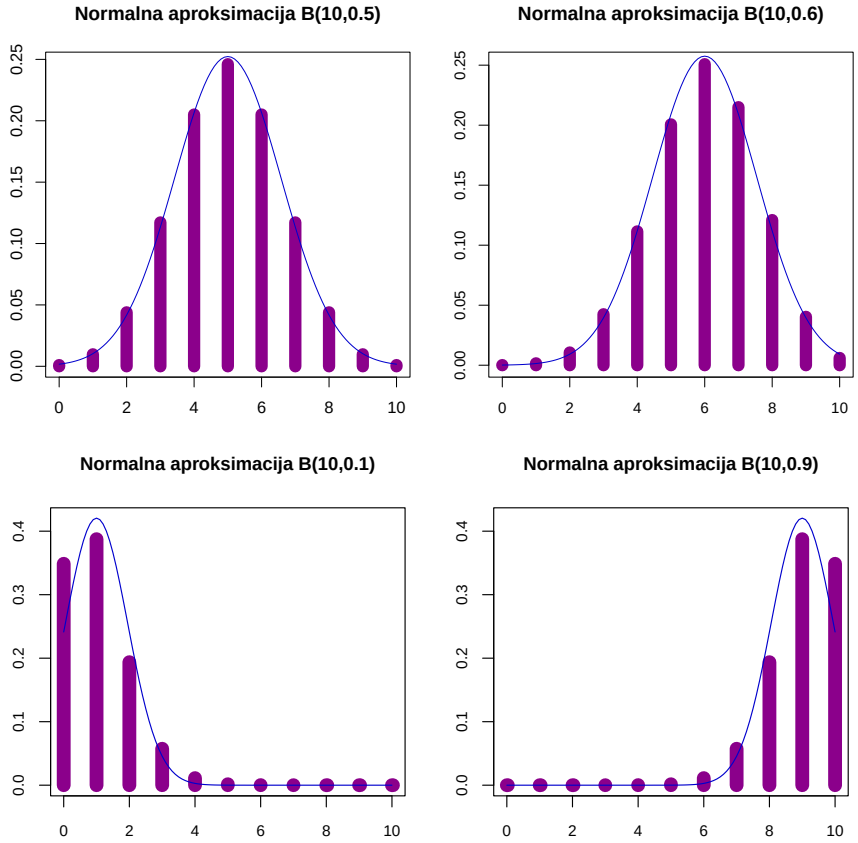
Pogledajmo primjer.

Primjer 6.2.13. Izračunajmo vjerojatnost da će među 1000 novorođene djece biti barem 490 muške ako je za svako novorođenče jednako vjerojatno da bude muško ili žensko.
Ukoliko "uspjehom" proglasimo rođenje muškog djeteta onda situaciju zadanu u primjeru opisujemo slučajnom varijablom $X \sim B(1000, 1/2)$. Kako je $EX = 1000 \cdot 1/2 = 500$ i $\mathrm{Var}\,(X) = 1000 \cdot 1/2 \cdot 1/2 = 250$ prema Moivre-Laplaceovom centralnom graničnom teoremu imamo aproksimaciju

$$\begin{aligned} P(490 \le X \le 1000) &= P((490-500)/\sqrt{250} < (X-500)/\sqrt{250} < (1000-500)/\sqrt{250}) \\ &\approx \Phi\Big(500/\sqrt{250}\Big) - \Phi\Big(-10/\sqrt{250}\Big) = 0,7454. \end{aligned}$$

□

Može se pokazati da je pogreška u aproksimativnoj formuli (6.68) manja kada je p blizu $1/2$. Drugim riječima, aproksimacija koja slijedi iz Moivre-Laplaceovog teorema je bolja kada je p blizu $1/2$. To ilustriramo na sljedećim slikama gdje uzimamo $X_n \sim B(10, p_i)$, $i = 1, 2, 3, 4$, gdje su p_i redom $0,5$, $0,6$, $0,1$ i $0,9$. Ljubičastim stupićima su prikazane teorijske vjerojatnosti odgovarajuće binomne slučajne varijable, a plavom linijom normalna aproksimacija.



Zanimljivo je, a pomalo i neočekivano, da se vrijednosti binomne slučajne varijable za male vrijednosti p mogu bolje aproksimirati Poissonovom slučajnom varijablom, nego normalnom. Naime, za $X_n \sim B(n, p_n)$ takve da je $\lim_{n\to\infty} p_n = 0$ i $\lim_{n\to\infty} np_n = \lambda$, $0 < \lambda < \infty$, $q_n = 1 - p_n$, vrijedi (vidi Teorem 5.4. u [10])

$$\lim_{n\to\infty} P(X_n = k) = \lim_{n\to\infty} \binom{n}{k} p_n^k q_n^{n-k} = \frac{\lambda}{k!} e^{-\lambda}, \ k = 0, 1, 2, \ldots \tag{6.69}$$

Taj se rezultat ponekad naziva Poissonov zakon malih brojeva.

I normalna aproksimacija se može primijeniti na procjenu vrijednosti pojedinačnih vjerojatnosti $P(X_n = k)$, $k = 0, 1, \ldots, n$, binomne slučajne varijable $X_n \sim B(n, p)$. Kako je normalna slučajna varijabla neprekidna vjerojatnost postizanja bilo koje pojedinačne točke je jednaka nuli pa je potrebna prilagodba aproksimacijske formule (6.65).[24] U praksi se često koristi korekcija po neprekidnosti prema kojoj je za velike n

$$P(X_n = k) = P(k-1/2 < X < k+1/2) \approx \Phi\Big(\frac{k + 1/2 - np}{\sqrt{np(1-p)}}\Big) - \Phi\Big(\frac{k - 1/2 - np}{\sqrt{np(1-p)}}\Big). \tag{6.70}$$

Pogledajmo jedan primjer u kojem računamo vjerojatnosti vezane uz binomnu slučajnu varijablu koristeći se Poisonovm i binomnom aproksimacijom. Radi preglednosti smo uzeli mali n za $X_n \sim B(n, p)$.

[24] Binomna slučajna varijable je zbroj n nezavisnih Bernoullijevih slučajnih varijabli kojima je očekivanje jednako p, a varijanca $p(1-p)$ pa relacija (6.65) govori o tome da je $X_n \approx N(np, np(1-p))$.

Primjer 6.2.14 (Aproksimacija binomne slučajne varijable)**.** Uzmimo $n = 10$ i pogledajmo slučajnu varijablu $B \sim B(10, 1/10)$. Na razini interpretacije slučajna varijable B modelira nezavisno ponavljanje nekog slučajnog eksperimenta u kojem se uspjeh postiže s vjerojatnošću $1/10$. Pod uspjehom se mogu smatrati razni događaji poput ulova ribe teže od 3 kilograma, pogađanja centra mete u pikadu, odabir neispravnog proizvoda u nekoj seriji proizvoda, i tako dalje. Slučajna varijable B je zbroj 10 nezavisnih Bernoullijevih slučajnih varijabli s parametrom $p = 1/10$.
Kako je $n = 10$ prilično mali, isto kao i vjerojatnost uspjeha, Poissonova aproksimacija binomne slučajne varijable bi trebala biti dobra. Izračunajmo vjerojatnost da će B biti jednak 1 ili 4. Prema (6.69) je $\lambda = np = 1$ pa je

```
> 1/factorial(1)*exp(-1)

[1] 0.3678794

> dbinom(1,10,1/10)

[1] 0.3874205

> 1/factorial(4)*exp(-1)

[1] 0.01532831

> dbinom(4,10,1/10)

[1] 0.01116026
```

Dakle, dobivamo aproksimacije

$$0,3874205 = P(B = 1) \approx \frac{1}{1!}e^{-\lambda} = 0,3678794 \quad \text{i}$$

$$0,01116026 = P(B = 4) \approx \frac{1}{4!}e^{-\lambda} = 0,01532831.$$

Pogledajmo kakva je aproksimacija normalnom razdiobom, kada uzmemo u obzir korekciju po neprekidnosti danu u relaciji (6.70). Kako je

$$P(B = 1) \approx \Phi\Big(\frac{1 + 1/2 - 1}{\sqrt{0,9}}\Big) - \Phi\Big(\frac{1 - 1/2 - 1}{\sqrt{0,9}}\Big) = \Phi(0,5270463) - \Phi(-0,5270463)$$

i

$$P(B = 4) \approx \Phi\Big(\frac{4 + 1/2 - 1}{\sqrt{0,9}}\Big) - \Phi\Big(\frac{4 - 1/2 - 1}{\sqrt{0,9}}\Big) = \Phi(3,689324) - \Phi(2.635231)$$

pomoću R-a izračunamo

```
> pnorm(0.5270463)-pnorm(-0.5270463)

[1] 0.4018386

> pnorm(3.689324)-pnorm(2.635231)

[1] 0.004091577
```

Dakle, normalnom aproksimacijom dobivamo

$$P(B=1) \approx 0,4018386 \quad \text{i} \quad P(B=4) \approx 0,004091577$$

što su nešto lošije aproksimacije od onih dobivenih Poissonovom aproksimacijom.
Uzimo sada $B \sim B(10,6/10)$ i izračunajmo normalnu aproksimaciju, uz korekciju po neprekidnosti, za $P(B=5)$. Prema (6.70) imamo

$$P(B=5) \approx \Phi\Big(\frac{5+1/2-6}{\sqrt{2,4}}\Big) - \Phi\Big(\frac{5-1/2-6}{\sqrt{2,4}}\Big) = \Phi(-0,3227486) - \Phi(-0.9682458)$$

pa opet korištenjem R-a izračunamo

```
> pnorm(-0.3227486)-pnorm(-0.9682458)

[1] 0.206982

> dbinom(5,10,0.6)

[1] 0.2006581
```

Kako je vjerojatnost uspjeha bliža 1/2 čak i za prilično mali n dobivamo dosta dobru aproksimaciju

$$0,2006581 = P(B=5) \approx 0.206982 = \Phi(-0,3227486) - \Phi(-0.9682458).$$

Korekcija po neprekidnosti pomaže i prilikom korištenja formule (6.68). Aproksimirajmo vjerojatnost $P(B \le 5) = P(-\infty < B \le 5)$. Teorijski točna vrijednost od $P(B \le 5)$ je

```
> pbinom(5,10,0.6)

[1] 0.3668967
```

Aproksimacija iz (6.68) daje

$$P(B \le 5) \approx \Phi\Big(\frac{5-6}{\sqrt{2,4}}\Big) = \Phi(-0.6454972).$$

pa korištenjem R-a dobivamo

```
> pnorm(-0.6454972)

[1] 0.2593025
```

što nam daje aproksimaciju

$$0,3668967 = P(B \le 5) \approx \Phi(-0,6454972) = 0,2593025.$$

Jer je B diskretna slučajna varijabla mogli bi argumentirati da je $P(B \le 5) = P(B < 6)$ što nas vodi do aproksimacije

$$P(B < 6) \approx \Phi\Big(\frac{6-6}{\sqrt{2,4}}\Big) = \Phi(0) = 0,5$$

koja opet nije dobra. No, korištenjem korekcije po neprekidnosti dobivamo

$$P(B \le 5+1/2) \approx \Phi\Big(\frac{5+1/2-6}{\sqrt{2,4}}\Big) = \Phi(-0,3227486) = 0,3734428$$

što nam daje aproksimaciju vjerojatnosti $P(B \le 5)$ koja je bliska stvarnoj vrijednosti $0,3668967$. □

Primjer 6.2.15 (Koliki mora biti n?)**.** U ovom poglavlju smo se susreli s više graničnih teorema koji nam govore na koji način možemo aproksimirati (CGT) ili ograničiti (Čebiševljeva nejednakost) neke vjerojatnosti. Jedno od prirodnih pitanja koja si možemo postaviti je: "koliki mora biti n da bi dobili određenu procjenu vjerojatnosti"? Općeniti odgovor na to pitanje nas vodi na ocjene grešaka aproksimacije u graničnim teoremima, ali neke procjene veličine n-a koji je potreban da bi se postigla određena vjerojatnost mogu se izvesti iz formula koje smo prezentirali.

Pretpostavimo situaciju u kojoj neka politička stranka želi provjeriti svoju popularnost među biračima. U tu svrhu intervjuira n, $n \in \mathbb{N}$, građana pri čemu svaki od ispitanih građana može dati odgovor da će glasati za tu stranku (to je uspjeh) ili da neće glasati za tu stranku (to je neuspjeh). U skladu s time, odgovore građana možemo modelirati Bernoullijevim slučajnim varijablama $B_1, B_2, \ldots, B_n$. Ukoliko su građani odabrani slučajno razumno je pretpostaviti da su slučajne varijable $B_1, B_2, \ldots, B_n$ nezavisne.[25] Ispitani građani čine uzorak od cijele populacije i stranku zapravo zanima vjerojatnost da će populacija birača glasati za tu stranku. Stoga su B_i jednako distribuirane jer čine uzorak cijele populacije, a cijela populacija će s nekom vjerojatnosti p glasati za tu stranku. Dakle, $B_1, B_2, \ldots, B_n$ su nezavisne i jednako distribuirane Bernoullijeve slučajne varijable s parametrom p.

Iz dobivenih odogovora stranka procjenjuje vjerojatnost da će opća populacija građana glasati za tu stranku i to tako da za procjenu te vjerojatnosti p koristi prosjek slučajnih varijabli $B_1, B_2, \ldots, B_n$ koje modeliraju odgovore ispitanih građana. Dakle, gledamo slučajnu varijablu

$$\bar{X}_n = \frac{B_1 + B_2 + \ldots + B_n}{n}.$$

Prema zakonima velikih brojeva znamo da $\bar{X}_n \to p$, kada n raste pa se čini da će takva procjena biti dobra. Ipak, u stranci žele znati koliko je pouzdana dobivena procjena vjerojatnosti, odnosno koliko je zapravo ispitanika potrebno da bi dobili pouzdanu procjenu. Malo preciznije, u stranci žele znati koliki mora biti n da bi s 90%-tnom pouzdanošću mogli tvrditi da se procijenjena vrijednost $\bar{X}_n$ neće razlikovati od stvarne vrijednosti p za više od $0,05$.

Prva ideja za procjenu tražene pouzdanosti nam može biti primjena Čebiševljeve nejednakosti (6.45) s vrijednosti $a = 0,05$. Zbog linearnosti očekivanja i činjenice da su B_i, $i = 1, 2, \ldots, n$, jednako distribuirani vrijedi $E\bar{X}_n = p$, pa primjenom Čebiševljeve nejednakosti dobivamo

$$P(|\bar{X}_n - p| \geq 0,05) \leq \frac{\operatorname{Var}(\bar{X}_n)}{0,05^2}.$$

Kako su $B_1, B_2, \ldots, B_n$ nezavisne i jednako distribuirane te zbog svojstva varijance $ii)$ iz Propozicije 6.1.13 vrijedi

$$\operatorname{Var}(\bar{X}_n) = \frac{1}{n^2}(\operatorname{Var}(B_1) + \ldots + \operatorname{Var}(B_1)) = \frac{1}{n^2} n \operatorname{Var}(B_1) = \frac{1}{n}\operatorname{Var}(B_1).$$

Znamo da je $\operatorname{Var}(B_1) = p(1-p)$ pa gornja nejednakost postaje

$$P(|\bar{X}_n - p| \geq 0,05) \leq \frac{p(1-p)}{n0,05^2}.$$

Za $p \in [0,1]$ vrijedi nejednakost $p(1-p) \leq 1/4$[26] pa konačno dobivamo nejednakost

$$P(|\bar{X}_n - p| \geq 0,05) \leq \frac{1}{4n0,05^2}. \tag{6.71}$$

[25] Osim na nezavisnost prilikom odabira građna koji će se intervjuirati treba paziti i na reprezentativnost. Naime, poželjno je da odabrani građani dobro reprezentiraju opću populaciju da se ne dogodi da je među, na primjer, 100 odabranih građana 50 ribara ili 50 doktora matematike.

[26] Definirajte funkciju $f(p) = p - p^2$. Njena derivacija je $1 - 2p$ pa izjednačavanjem derivacije s nulom slijedi da se u $p = 1/2$ postiže ekstrem. Jer je $f''(p) < 0$ riječ je o maksimumu. Jasno, $f(1/2) = 1/4$.

Stranka želi da je

$$P(|\bar{X}_n - p| < 0,05) \geq 0,9.$$

Prema formuli za vjerojatnost suprotnog događaja iz (6.71) dobivamo

$$P(|\bar{X}_n - p| < 0,05) = 1 - P(|\bar{X}_n - p| \geq 0,05) \geq 1 - \frac{1}{4n0,05^2}.$$

Sada želimo da je

$$1 - \frac{1}{4n0,05^2} \geq 0,9, \quad \text{odnosno} \quad \frac{1}{4n0,05^2} \leq 0,1.$$

Rješavanjem te nejednakosti dobivamo

$$n \geq 1000.$$

Drugi način na koji bi mogli procjeniti traženi n je korištenjem centralnog graničnog teorema. U tu svrhu možemo koristiti općenitu procjenu danu u relaciji (6.61) pri čemu je $E\bar{X}_n = p$ i $\mathrm{Var}\,(\bar{X}_n) = p(1-p)/n$. Najprije uočimo da je

$$P(|\bar{X}_n - p| < 0,05) = 1 - P(\bar{X}_n - p \geq 0,05) - P(\bar{X}_n - p \leq -0,05). \tag{6.72}$$

Želimo aproksimirati vjerojatnosti s desne strane gornje jednakosti. Sjetimo se da centralni granični teorem govori da se funkcija distribucije slučajne varijable

$$Z_n = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma} = \sqrt{n}\frac{\bar{X}_n - p}{\sqrt{p(1-p))}}$$

asimptotski približava funkciji distribucije jedinične normalne slučajne varijable Z. Prema (6.61) imamo

$$\begin{aligned} P(\bar{X}_n - p \leq -0,05) &= P\Big(\sqrt{n}\frac{\bar{X}_n - p}{\sqrt{p(1-p)}} \leq \sqrt{n}\frac{-0,05}{\sqrt{p(1-p)}}\Big) \\ &= P\Big(Z_n \leq -\sqrt{n}\frac{0,05}{\sqrt{p(1-p))}}\Big) \\ &\approx P\Big(Z \leq -\sqrt{n}\frac{0,05}{\sqrt{p(1-p))}}\Big) = \Phi\Big(-\sqrt{n}\frac{0,05}{\sqrt{p(1-p)}}\Big). \end{aligned}$$

Zbog simetričnosti slučajne varijable Z dobijemo i

$$\begin{aligned} P(\bar{X}_n - p \geq 0,05) &= P\Big(\sqrt{n}\frac{\bar{X}_n - p}{\sqrt{p(1-p)}} \geq \sqrt{n}\frac{0,05}{\sqrt{p(1-p)}}\Big) \\ &= P\Big(Z_n \geq \sqrt{n}\frac{0,05}{\sqrt{p(1-p)}}\Big) \\ &\approx P\Big(Z \geq \sqrt{n}\frac{0,05}{\sqrt{p(1-p)}}\Big) = P\Big(Z \leq -\sqrt{n}\frac{0,05}{\sqrt{p(1-p)}}\Big). \end{aligned}$$

Stoga u (6.72) dobivamo

$$P(|\bar{X}_n - p| < 0,05) = 1 - 2\Phi\Big(-\sqrt{n}\frac{0,05}{\sqrt{p(1-p)}}\Big)$$

i želimo da ta vjerojatnost bude veća ili jednaka od $0,9$, odnosno da vrijedi

$$\Phi\Big(-\sqrt{n}\frac{0,05}{\sqrt{p(1-p)}}\Big) \leq 0,05.$$

Sada smo problem sveli na traženje najvećeg broja x za koji je $\Phi(x) \leq 0,05$. Iz tablica, odnosno korištenjem R-a (funkcija `qnorm()`) dobijemo

```
> qnorm(0.05)

[1] -1.644854
```

pa mora vrijediti

$$-\sqrt{n}\frac{0,05}{\sqrt{p(1-p)}} \leq -1,644854,$$

odnosno

$$\sqrt{n}\frac{0,05}{\sqrt{p(1-p)}} \geq 1,644854.$$

Opet iskoristimo nejednakost $p(1-p) \leq 1/4$ za $p \in [0,1]$ da dobijemo

$$\sqrt{n}\frac{0,05}{\sqrt{p(1-p)}} \geq \sqrt{n}\frac{0,05}{2}.$$

Želimo da dobiveni izraz s desne strane bude veći ili jednak $1,644854$, a to će biti ispunjeno za

$$n \geq 66.$$

Vidimo da procjenom iz centralnog graničnog teorema dobivamo dosta manji traženi broj ispitanika. To ne treba čuditi jer smo već napomenuli da je Čebiševljeva nejednakost dosta gruba nejednakost. □

6.3 Primjeri u R-u

Zakoni velikih brojeva, kao i centralni granični teorem, imaju mnoge posljedice i primjene. Jedna od primjena jakog zakona velikih brojeva je izračun vrijednosti određenog integrala omeđenih (ograničenih) funkcija.

Uzmimo realnu funkciju f koja je na nekom segmentu $[a,b]$ ograničena, što znači da postoji realni broj d takav da je

$$f(x) \leq d,\ x \in [a,b].$$

Želimo izračunati, odnosno procijeniti, vrijednost određenog integrala

$$\int_a^b f(x)dx.$$

Iako se ne prvu čini da vjerojatnost nema veze s određivanjem vrijednosti integrala jer u tom postupku nema ničeg slučajnog, ideja je da uvedemo randomizaciju u cijeli postupak i onda iskoristimo neke od rezultata koje smo upoznali. S obzirom da je funkcija f ograničena na segmentu $[a,b]$ cijeli graf funkcije[27] f se nalazi u pravokutniku $Q = [a,b] \times [c,d]$. Radi jednostavnosti pretpostavimo da je funkcija f nenegativna na segmentu $[a,b]$ pa možemo uzeti $c = 0$. Dodatno definirajmo skup $A = \{(x,y) \mid x \in [a,b], 0 \leq y \leq f(x)\} \subset Q$. Površina skupa A je jednaka površini ispod grafa funkcije f na segmentu $[a,b]$, a to je upravo jednako vrijednosti određenog integrala $\int_a^b f(x)dx$.

Definirajmo, na nekom vjerojatnosnom prostoru, niz nezavisnih slučajnih vektora $(U_1,V_1),(U_2,V_2),\ldots,(U_n,V_n)$, pri čemu su nezavisne i slučajne varijable U_i i V_i te je $U_i \sim U(a,b)$ i $V_i \sim U(0,d)$, $i = 1,2,\ldots,n$. Vidimo da je U_i niz nezavisnih slučajnih varijabli s neprekidnom uniformnom razdiobom na (a,b), dok je V_i niz nezavisnih slučajnih varijabli s neprekidnom uniformnom razdiobom na $(0,d)$. Realizacije niza slučajnih varijabli U_i i

[27] Graf funkcije je skup $\{(x,y) \mid y = f(x)\}$ koji je podskup ravnine.

V_i možemo dobiti generiranjem (pseudo)slučajnih brojava sa zadanim razdiobama. Kao što ćemo vidjeti postupak koji ćemo izložiti nije previše osjetljiv na odabir gornje granice d, sve dok je cijeli graf funkcije f sadržan u pravokutniku Q.

Definirajmo sada niz indikatora $I_1, I_2, \ldots, I_n$ tako da je za $i = 1, 2, \ldots, n$

$$I_i(\omega) = \begin{cases} 1, & (U_1(\omega), V_1(\omega)) \in A \\ 0, & \text{inače} \end{cases} \tag{6.73}$$

Tako definirani indikatori su nezavisni i jednako distribuirani s konačnim očekivanjem i varijancom.[28] Stoga je na njima primjenjiv jaki zakon velikih brojeva što znači da za sve $\omega \in E$, $P(E) = 1$, vrijedi

$$\frac{1}{n}\sum_{i=1}^{n} I_i \to E(I_1),\ n \to \infty.$$

Uočimo da se I_i mogu interpretirati kao nezavisne Bernoullijeve slučajne varijable pri čemu je vjerojatnost uspjeha u svakom od ponavljanja (generiranja para realizacija slučajnog vektora (U_i, V_i)) jednaka vjerojatnosti da će se (U_i, V_i) nalaziti u skupu A, pri čemu se prema definiciji od U_i i V_i one nalaze u pravokutniku Q. Dakle, vjerojatnost uspjeha tih Bernoullijevih slučajnih varijabli je jednaka

$$\frac{\int_a^b f(x)dx}{d(b-a)}.$$

Sjetimo se formule (6.17) pa zaključimo da prema jakom zakonu velikih brojeva za gotovo sve $\omega \in \Omega$ i velike $n \in \mathbb{N}$ vrijedi aproksimacija

$$\frac{1}{n}\sum_{i=1}^{n} I_i \approx E(I_1) = P(I_1 = 1) = \frac{\int_a^b f(x)dx}{d(b-a)}.$$

Dakle, brojeći "uspjehe" u nizu indikatora I_i možemo dobiti aproksimaciju omjera integrala $\int_a^b f(x)dx$ i površine pravokutnika Q, odnosno

$$\int_a^b f(x)dx \approx d(b-a) \cdot \frac{1}{n}\sum_{i=1}^{n} I_i.$$

Ovakav postupak aproksimacije vrijednosti određenog itegrala naziva se Monte Carlo integracija. Pogledajmo kako provodimo taj postupak na primjeru neke konkretne funkcije. Uzmimo funkciju

$$f(x) = 0,1x^3 - 0,5x^2 - 0,25x + 4,\ x \in \mathbb{R}$$

iz potpoglavlja 5.3 te aproksimirajmo vrijednost određenog integrala

$$\int_1^6 f(x)dx.$$

Vrijednost tog integrala je približno jednaka $12,16667$.

Prema prije opisanom postupku, trebamo generirati nizove uniformno distribuiranih slučajnih brojeva u_i i v_i pri čemu su u_i realizacije slučajne varijable $U(1,6)$, a v_i će biti realizacije slučajne varijable $U(0,8)$ (uzeli smo 8 kao gornju granicu funkcije f na $[1,6]$). Izdvajanjem onih parova (u_i, v_i) za koje je $v_i \leq f(u_i)$ dobit ćemo aproksimaciju integrala $\int_1^6 f(x)dx$. To smo napravili u niže predstavljenom R kodu s $n = 1.000$ ponavljanja.

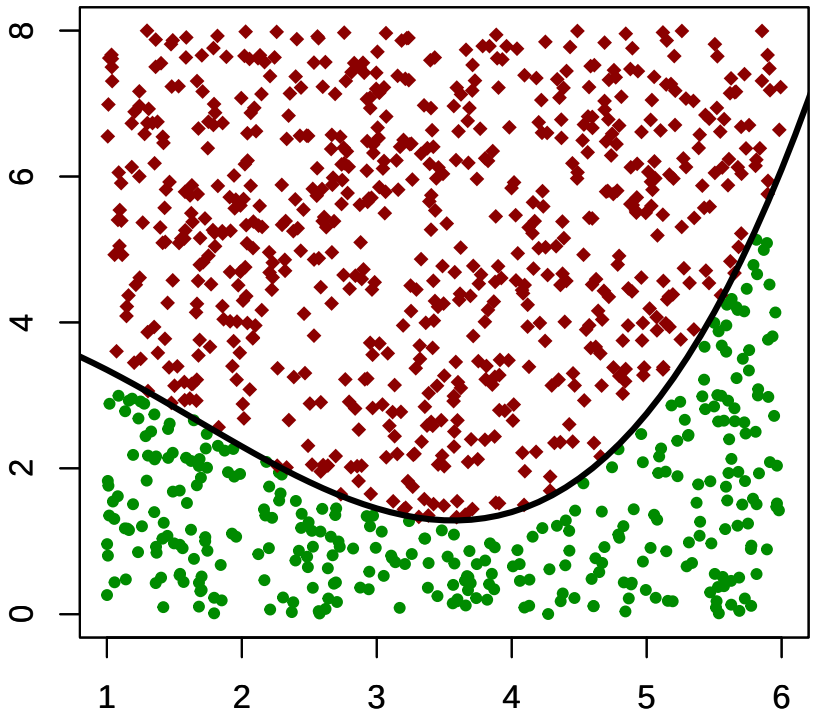
[28] To je trivijalno jer je $|I_i| \leq 1$, $i = 1, 2, \ldots, n$.

```
> fx<-function(x) { 0.1*x^3 - 0.5*x^2 - 0.25*x + 4}
> set.seed(42); n<-1000
> a<-1; b<-6;c<-0;d<-8
> Pov<-(b-a)*(d-c)
> u<-runif(n,a,b); v<-runif(n,c,d)
> vekt<-matrix(c(u,v),nrow=2, ncol=n, byrow=TRUE)
> ispod<-length(vekt[,fx(u)>v])/2
> vjerojatnost<-ispod/n*Pov
> vjerojatnost

[1] 13.12
```

Prikažimo geometrijski rezultate simulacije iz prethodnog koda. Zelenom bojom (kružićima) smo prikazali parove (u_i, v_i) koji se nalaze su skupu $A = \{(x, y) \mid x \in [1, 6], 0 \leq y \leq f(x)\} \subset 8((6-1)$, a crvenom bojom (kvadratima) preostale parove (u_i, v_i). Crnom bojom smo prikazali graf funkcije f.

```
> par( mar=c(2,2,2,2))
> plot(vekt[,fx(u)>v][1,],vekt[,fx(u)>v][2,], xlim=c(1,6), ylim=c(0,8),
+      pch=20,col="green4", xlab="", ylab="")
> par(new=TRUE)
> plot(vekt[,fx(u)<v][1,],vekt[,fx(u)<v][2,], xlim=c(1,6), ylim=c(0,8),
+      pch=18,col="red4", xlab="", ylab="")
> x.axes<- seq(-1,7, 0.1)
> lines(x.axes, fx(x.axes),lwd=3 , xlim=c(1,6), ylim=c(0,8))
```



Dobivena procjena integrala $\int_1^6 f(x)dx$ od $13,12$ nije naročita, ali i 1000 ponavljanja simulacije nije prevelik broj. Za $n = 1.000.000$ dobivamo bolju procjenu

```
[1] 12.17804
```

Probajte sami izračunati (procijeniti) vrijednosti nekih drugih određenih integrala.

6.4 Sažetak poglavlja

Neka je X diskretna slučajna varijabla s razdiobom

$$X \sim \begin{pmatrix} a_1 & a_2 & \dots & a_n & \dots \\ p_1 & p_2 & \dots & p_n & \dots \end{pmatrix}.$$

Matematičko očekivanje slučajne varijable X se definira kao

$$EX = E(X) := \sum_{i=1}^{\infty} a_i p_i = \sum_{i=1}^{\infty} a_i P(X = a_i).$$

Neka je X neprekidna slučajna varijabla čija je funkcija gustoće $f_X(x)$, $x \in \mathbb{R}$. **Matematičko očekivanje slučajne varijable** X se definira kao

$$EX = \int_{-\infty}^{\infty} x f_X(x) dx.$$

Osnovna svojstva matematičkog očekivanja: Neka su X i Y slučajne varijable te $a, b \in \mathbb{R}$. Tada je

$$E(aX + bY) = aEX + bEY. \qquad \text{(linearnost)}$$

Ako je $X \leq Y$ s vjerojatnošću 1, onda je

$$EX \leq EY. \qquad \text{(monotonost)}$$

Ako su X i Y **nezavisne** slučajne varijable, onda je

$$E(XY) = EX \cdot EY.$$

Neka je $g : \mathbb{R} \to \mathbb{R}$ neka funkcija. Ako je X diskretna slučajna varijabla s razdiobom

$$X \sim \begin{pmatrix} a_1 & a_2 & \dots & a_n & \dots \\ p_1 & p_2 & \dots & p_n & \dots \end{pmatrix}.$$

onda je

$$E(g(X)) = \sum_{i=1}^{\infty} g(a_i) p_i = \sum_{i=1}^{\infty} g(a_i) P(X = a_i),$$

a ako je X neprekidna slučajna varijabla s funkcijom gustoće f_X, onda je

$$E(g(X)) = \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

Ako su $X_1, X_2, \dots, X_n$, $n \in \mathbb{N}$, slučajne varijable, onda se linearnost očekivanja proširuje do

$$E(X_1 + X_2 + \dots + X_n) = EX_1 + EX_2 + \dots + EX_n.$$

Varijanca slučajne varijable X, u oznaci $\mathrm{Var}\,(X)$, definira se kao

$$\mathrm{Var}\,(X) = E[(X - EX)^2].$$

Standardna devijacija slučajne varijable X je drugi korijen varijance od X, odnosno

$$SD(X) = \sqrt{E[(X - EX)^2]}.$$

Alternativna formula za varijancu

$$\mathrm{Var}\,(X) = EX^2 - (EX)^2.$$

Osnovna svojstva varijance Neka su X i Y slučajne varijable te a, b realni brojevi. Tada vrijedi

$$\operatorname{Var}(X+b) = \operatorname{Var}(X)$$
$$\operatorname{Var}(aX) = a^2 \operatorname{Var}(X)$$

Ako su X i Y nezavisne, onda je $\operatorname{Var}(X+Y) = \operatorname{Var}(X) + \operatorname{Var}(Y)$. To općenito ne vrijedi za slučajne varijable koju nisu nezavisne.
Ako su $X_1, X_2, \ldots, X_n$ nezavisne slučajne varijable onda je

$$\operatorname{Var}(X_1 + X_2 + \ldots + X_n) = \operatorname{Var}(X_1) + \operatorname{Var}(X_2) + \ldots + \operatorname{Var}(X_n).$$

* * * * *

Očekivanje i varijanca nekih diskretnih slučajnih varijabli

1) **Bernoullijeva** slučajna varijabla X s parametrom p
$EX = p$, $\operatorname{Var}(X) = p(1-p) = pq$.

2) **Diskretna uniformna** slučajna varijabla X na $\{1, 2 \ldots, n\}$, $n \in \mathbb{N}$
$P(X = i) = 1/n$, $i = 1, 2, \ldots, n$, $EX = \frac{n+1}{2}$, $\operatorname{Var}(X) = \frac{n^2-1}{12}$.

3) **Binomna** slučajna varijabla B s parametrima n i p
$EB = np$, $\operatorname{Var}(B) = np(1-p) = npq$.

4) **Geometrijska** slučajna varijabla G s parametrom p
$E(G) = \frac{1}{p}$, $\operatorname{Var}(G) = \frac{1-p}{p^2}$.

5) **Hipergeometrijska** slučajna varijabla X s parametrima p, c i n
$E(X) = n\frac{p}{p+c}$, $\operatorname{Var}(X) = \frac{npc(p+c-n)}{(p+c)^2(p+c-1)}$.

6) **Poissonova** slučajna varijabla X s parametrom λ
$EX = \lambda$, $\operatorname{Var}(X) = \lambda$.

Očekivanje i varijanca nekih neprekidnih slučajnih varijabli

1) **Uniformna** slučajna varijabla U na (a, b)

$$EU = \frac{a+b}{2}, \quad \operatorname{Var}(U) = \frac{(b-a)^2}{12}.$$

Posebno je za $U \sim U(0,1)$

$$EU = \frac{1}{2} \quad \operatorname{Var}(U) = \frac{1}{12}.$$

2) **Eksponencijalna** slučajna varijabla X s parametrom λ

$$EX = \frac{1}{\lambda}, \quad \operatorname{Var}(X) = \frac{1}{\lambda^2}.$$

3) **Normalna** slučajna varijabla X s parametrima μ i σ^2

$$EX = \mu, \quad \operatorname{Var}(X) = \sigma^2.$$

4) **Paretova** slučajna varijabla X s parametrom α

$$EX = \begin{cases} \frac{\alpha}{\alpha-1}, & \alpha > 1 \\ \infty, & \alpha \leq 1. \end{cases}$$

Za $\alpha > 2$

$$\operatorname{Var}(X) = \frac{\alpha}{(\alpha-1)^2(\alpha-1)}.$$

* * * * *

Neka je X slučajna varijabla i $r > 0$ realan broj.
$E(X^r)$ zovemo r-**ti moment** od X dok $E(|X|^r)$ zovemo r-**ti apsolutni moment** od X.
Ako je očekivanje slučajne varijable X konačno, onda se $E[(X - EX)^r]$ zove r-**ti centralni moment** od X, dok se $E(|X - EX|^r)$ zove r-**ti apsolutni centralni moment** od X.
Očekivanje slučajne varijable X prvi moment od X, dok je varijanca drugi centralni moment od X.
Neka je X slučajna varijabla s konačnim očekivanjem μ i varijancom $\sigma^2 > 0$. Tada slučajna varijabla

$$Y = \frac{X - \mu}{\sigma}$$

ima očekivanje nula i varijancu jedan.
Neka je X slučajna varijabla s očekivanjem μ i varijancom σ^2. Njena **ukošenost** (eng. *skewness*) se definira kao

$$Skew(X) = E\Big(\frac{X - \mu}{\sigma}\Big)^3.$$

Neka je X slučajna varijabla s očekivanjem μ i varijancom σ^2. Njen **kurtosis** (eng. *kurtosis*) se definira kao

$$Kurt(X) = E\Big(\frac{X - \mu}{\sigma}\Big)^4 - 3.$$

Neka je X slučajna varijabla. Realni broj c je **medijan** slučajne varijable X ako je $P(X \leq c) \geq 1/2$ i $P(X \geq c) \geq 1/2$.
Neka je X diskretna slučajna varijabla. Realni broj c je **mod** slučajne varijable X ako je $P(X = c) \geq (X = xc)$, za sve $x \in \mathbb{R}$.
Neka je X neprekidna slučajna varijabla. Realni broj c je **mod** slučajne varijable X ako je $f(c) \geq f(x)$, za sve $x \in \mathbb{R}$. S f smo označili funkciju gustoće slučajne varijable X.

* * * * *

Neka su X i Y slučajne varijable s konačnim drugim momentima, odnosno neka je $EX^2 < \infty$ i $EY^2 < \infty$. **Kovarijanca** slučajnih varijabli X i Y, u oznaci $\mathrm{Cov}(X, Y)$, definira se kao

$$\mathrm{Cov}(X, Y) = E[(X - EX)(Y - EY)].$$

Slično kao i u slučaju varijance i kovarijanca ima drugu formu koja se vrlo često koristi

$$\mathrm{Cov}(X, Y) = E(XY) - EXEY$$

Kovarijanca je simetrična funkcija svojih argumenata

$$\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X).$$

Dodatno vrijedi

$$\mathrm{Cov}(X, X) = \mathrm{Var}\,(X)$$

i tako zvano svojstvo homogenosti prema kojem je za realni broj a

$$\mathrm{Cov}(aX, Y) = a\,\mathrm{Cov}(X, Y).$$

Neka su X, Y, Z slučajne varijable s konačnim drugim momentom. Tada vrijedi
$\mathrm{Cov}(X, C) = 0$, za konstantnu slučajnu varijablu $C \equiv c$, $c \in \mathbb{R}$,

ako su X i Y nezavisne slučajne varijable, onda je $\mathrm{Cov}(X,Y)=0$,

za slučajne varijable X,Y,Z i V te brojeve $a,b,c,d\in\mathbb{R}$ vrijedi

$$\mathrm{Cov}(aX+bY,cZ+dV)=ac\,\mathrm{Cov}(X,Z)+ad\,\mathrm{Cov}(X,V)+bc\,\mathrm{Cov}(Y,Z)+bd\,\mathrm{Cov}(Y,V).$$

Neka su X i Y slučajne varijable s konačnim drugim momentom te za njih vrijedi $\mathrm{Var}\,(X)>0$ i $\mathrm{Var}\,(Y)>0$. **Korelacija** slučajnih varijabli X i Y, u oznaci $\mathrm{Corr}(X,Y)$ ili $\rho(X,Y)$, definira se kao

$$\rho(X,Y)=\mathrm{Corr}(X,Y)=\frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}\,(X)\,\mathrm{Var}\,(Y)}}.$$

Ukoliko je $\mathrm{Corr}(X,Y)=0$ kažemo da su X i Y **nekorelirane** slučajne varijable. Ukoliko je $\mathrm{Corr}(X,Y)>0$ slučajne varijable X i Y su **pozitivno korelirane**, a ako je $\mathrm{Corr}(X,Y)<0$, onda su X i Y **negativno korelirane**.

Za korelaciju slučajnih varijabli vrijedi

$$-1\le\mathrm{Corr}(X,Y)\le 1$$

* * * * *

Neka je X općenita slučajna varijabla, $r>0$ broj te neka je $E|X|^r<\infty$. Tada vrijedi Markovljeva nejednakost

$$P(|X|\ge a)\le\frac{E|X|^r}{a^r}.$$

Neka je X općenita sličajna varijabla s konačnim očekivanjem i varijancom te neka je $a>0$ broj. Tada vrijedi Čebiševljeva nejednakost

$$P(|X-EX|\ge a)\le\frac{\mathrm{Var}\,(X)}{a^2}.$$

Neka su X i Y slučajne varijable s konačnim drugim momentima. Tada vrijedi Cauchy-Schwarzova nejednakost

$$|E(XY)|\le\sqrt{EX^2EY^2}.$$

Jensenova nejednakostkaže da za konveksnu funkciju $g:\mathbb{R}\to\mathbb{R}$ vrijedi

$$g(EX)\le E(g(X)).$$

Funkcija g je konveksna ako za $x,y\in\mathbb{R}$ i $0\le q\le 1$ vrijedi $g(tx+(1-t)y)\le tg(x)+(1-t)g(y)$. Primjer konveksne funkcije je $g(x)=x^2$.

* * * * *

(Slabi zakon velikih brojeva) Neka je $X_1,X_2,\ldots$ niz nezavisnih i jednako distribuiranih slučajnih varijabli (n.j.d.) s očekivanjem μ i konačnom varijancom σ^2. Tada vrijedi

$$\lim_{n\to\infty}P(|\bar{X}_n-\mu|>\epsilon)=0.$$

(Jaki zakon velikih brojeva) Neka je $X_1,X_2,\ldots$ niz nezavisnih i jednako distribuiranih slučajnih varijabli s očekivanjem μ i konačnom varijancom σ^2. Tada vrijedi

$$P(\lim_{n\to\infty}\bar{X}_n=\mu)=1.$$

(Centralni granični teorem) Neka je $X_1, X_2, \ldots$ niz nezavisnih i jednako distribuiranih slučajnih varijabli (n.j.d.) s očekivanjem μ i konačnom varijancom σ^2. Pretpostavimo da je $\sigma_1 > 0$. Tada za slučajne varijable

$$Z_n = \frac{\bar{X}_n - E\bar{X}_n}{\sqrt{Var(\bar{X}_n)}} = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma}$$

vrijedi

$$\lim_{n\to\infty} F_{Z_n}(x) \to \Phi(x),\ x \in \mathbb{R}.$$

Centralni granični teorem daje procjenu

$$P\Big(\sqrt{n}\frac{\bar{X}_n - \mu}{\sigma} \leq x\Big) \approx P(Z \leq x) = \Phi(x),\ x \in \mathbb{R}.$$

Poseban slučaj centralnog graničnog teorema je **Moivre-Laplaceov centralni granični teorem**. On kaže da za binomne slučajne varijable $X_n \sim B(n,p)$, $n \in \mathbb{N}$, $p \in (0,1)$, te realne brojeve a i b, $a < b$ vrijedi

$$\lim_{n\to\infty} P\Big(a \leq \frac{X_n - np}{\sqrt{np(1-p)}} \leq b\Big) = \Phi(b) - \Phi(a) = \frac{1}{\sqrt{2\pi}}\int_a^b e^{-x^2/2}dx.$$

Moivre-Laplaceov CGT omogućava aproksimaciju binomne slučajne varijable

$$P\Big(a \leq X_n \leq b\Big) \approx \Phi\Big(\frac{b - np}{\sqrt{np(1-p)}}\Big) - \Phi\Big(\frac{a - np}{\sqrt{np(1-p)}}\Big).$$

6.5 Zadaci

Zadatak 6.5.1. *Iz definicije matematičkog očekivanja je jasno da za slučajne varijable X i Y s istom razdiobom vrijedi da je $EX = EY$. Da li vrijedi obrat, odnosno da li iz relacije $EX = EY$ slijedi da X i Y imaju stu razdiobu? Obrazložite.*

Zadatak 6.5.2. *Diskretna slučajna varijabla X zadana je svojom razdiobom*

$$X \sim \begin{pmatrix} 1 & 3 & 5 & 7 \\ 0,2 & 0,3 & 0,3 & 0,2 \end{pmatrix}.$$

Izračunajte EX, $E(2X-4)$ i $E(X^2)$.

Zadatak 6.5.3. *Neka su X i Y nezvisne diskretne slučajne varijable koje su zadane svojim razdiobama*

$$X \sim \begin{pmatrix} -1 & 0 & 1 & 2 \\ 0,2 & 0,15 & 0,4 & 0,25 \end{pmatrix} \quad Y \sim \begin{pmatrix} 0 & 2 & 4 \\ 0,3 & 0,2 & 0,5 \end{pmatrix}.$$

Izračunajte EX, $E|X|$, EY, $\mathrm{Var}\,(X)$, $\mathrm{Var}\,(Y)$, $E(X+Y)$ i $E(2XY-2)$.

Zadatak 6.5.4. *Pogledajmo situaciju u kojoj želite organizirati igru ruleta (za opis igre ruletom pogledajte Zadatak 5.7.9). Zainteresirani ste za procjenu svog (mogućeg) dobitka kao organizatora ruleta i želite analizirati situaciju u kojoj se posjetitelji (igrači) klade na crveno ili crno polje s time da isključujete mogućnost stavljanja uloga na zeleno polje (nulu). Pretpostavili ste da se ljudi podjednako klade na crvena i crna polja te da će u svakoj vrtnji ruleta biti uplaćeno po 10 eura na crvena polja i crna polja (ne analizirate za sada situaciju postavljanja uloga na pojedinačne brojeve). Da biste bili "fer" odlučujete da ćete 20 eura koje prikupite u svakoj vrtnji raspodjeliti natrag igračima i to tako da*

ćete svim igračima koji su se kladili na crno polje isplatiti 20 eura (proporcionalno ulogu svakog igrača) ako kuglica ostane na crnom polju dok u tom slučaju igrači koji su se kladili na crvenu boju neće dobiti ništa, i analogno napravite ako se kuglica zaustavi na crvenom polju. Koji je vaš očekivani dobitak u svakoj vrtnji ruleta (ako ga ima)? Koje je vaš očekivani dobitak nakon 100 dana ako se u jednom danu odigra po 30 igra ruleta prema gore navedenom uvjetima? Pretpostavljamo da je ishod svake pojedinačne igre ruleta nezavisan od ostalih igara.

Zadatak 6.5.5. *Neka je X neprekidna slučajna varijabla kojoj je funkcija gustoće*

$$f_X(x) = \begin{cases} \frac{3}{16}x^2, & x \in (-2,2) \\ 0, & \text{inače.} \end{cases}$$

Izračunajte EX, $\mathrm{Var}(X)$ i EX^5.

Zadatak 6.5.6. *Dokažite Popoziciju 6.1.14.*

Zadatak 6.5.7. *Neka je X slučajna varijabla za koju je $EX = 2$ i $\mathrm{Var}(X) = 3$. Izračunajte očekivanje i varijancu slučajne varijable $Y = 4 - 2X$.*

Zadatak 6.5.8. *Pretpostavimo da imamo pravilni tetraedar kojemu su stranice označene brojevima od 1 do 4. Kada bacimo takav tetraedar kazat ćemo da je na njemu pao onaj broj koji je okrenut prema površini plohe na koju smo ga bacili. Pogledajmo sada slučajni eksperiment u kojem bacamo dva takva tetraedra (slučajno i nezavisno). Neka je slučajna varijabla T jednaka zboju brojeva koji su pali na ta dva tetraedra. Odredite razdiobu slučajne varijable T te joj odredite očekivanje i varijancu.*

Zadatak 6.5.9. *Koristeći Definiciju 6.1.28 dokažite relaciju (6.27), odnosno dokažite da vrijedi*

$$\mathrm{Cov}(X,Y) = E(XY) - EXEY.$$

(Uputa: izvršite sva množenja pod znakom očekivanja u relaciji (6.26) te uzmite očekivanje svih dobivenih članova. Nemojte smetnuti s uma da su EX i EY samo brojevi.)

Zadatak 6.5.10. *Zadana je diskretna slučajna varijabla X svojom razdiobom*

$$X \sim \begin{pmatrix} -1 & 0 & 1 & 5 \\ 5/12 & 1/6 & 1/6 & 1/4 \end{pmatrix}.$$

Ocijenite vjerojatnost $P(|X-1| \geq 3)$.

Zadatak 6.5.11. *Uzmimo slučajni eksperiment nezavisnog bacanja dvije simetrične igraće kockice. Neka je Z slučajna varijabla koja je jednaka zbroju koji je pao na obje kockice. Izračunajte ili ocijenite vjerojatnost $P(Z \leq 6)$.*

Zadatak 6.5.12. *Proizvođač aluminijskih folija pakira svoj proizvod u pakiranja od 50 metara. Uzorkovanjem velikog broja proizvedenih 50-metarskih folija proizvođač je utvrdio da je očekivana duljina pakiranih folija 50,06 metara, a standardna devijacija duljine folija je 0,15 metara. U skorije vrijeme će proizvodni pogon proizvođača posjetiti komisija za kontrolu kvalitete i uzorkovati (na slučajan način) 30 pakiranja folija od 50 metara. Proizvođača zanima vjerojatnost da će prosječna duljina folija iz tog uzorka biti manja od 50 metara. Procjenite tu vjerojatnost korištenjem centralnog graničnog teorema.*

Zadatak 6.5.13 (Primjer 6.3c iz [11])**.** *Na nekom fakultetu su zaključili da je optimalan broja studenata na predavanju jednak 150. Iz iskustava iz prethodnih godina se procjenjuje da samo 30% od upisanih studenata dolazi na predavanja. S obzirom na to, fakultet upisuje 450 studenata. Procijenite vjerojatnost da će više od 150 studenata biti na predavanju.*

Zadatak 6.5.14. *Pretpostavimo da organizirate druženje za 30 ljudi i želite napraviti dovoljno sendviča za cjelovečernje druženje. S obzirom da slušate kolegij iz vjerojatnosti i statistike pitate se da li možete procijeniti koliko sendviča trebate napraviti da ih bude dovoljno s vjerojatnošću* $0,95$*. Iz prošlih druženja znate da osmina ljudi ne pojede niti jedan sendvič, polovica ljudi pojede jedan sendvič, a ostali pojedu po dva sendviča. Koliko sendviča trebate napraviti?*

6.5.1 Rješenja zadataka

Rješenje 68 (Zadatak 6.5.1)**.** Ne vrijedi. To dokazujemo protuprimjerom. Uzmimo slučajne varijable X i Y s razdiobama

$$X \sim \begin{pmatrix} -2 & -1 & 0 & 1 & 2 \\ 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \end{pmatrix} \quad Y \sim \begin{pmatrix} -5 & 5 \\ 1/2 & 1/2 \end{pmatrix}.$$

Vrijedi da je $EX = EY = 0$ (provjerite to za vježbu) iako X i Y imaju različite razdiobe. Jasno je da imamo velik broj primjera koji nam mogu poslužiti kao protuprimjer za tvrdnju zadatka. na primjer, ako su N_1 i N_2 normalne slučajne varijable takve da je $N_1 \sim N(0,1)$ i $N_2 \sim N(0,4)$, onda su očekivanja obje te slučajne varijable jednaka nuli, dok su im varijance, pa onda i funkcije gustoće, različite.

Rješenje 69 (Zadatak 6.5.2)**.** Prema definiciji očekivanja za diskretne slučajne varijable 6.1.1 imamo

$$EX = 1 \cdot 0,2 + 3 \cdot 0,3 + 5 \cdot 0,3 + 7 \cdot 0,2 = 4.$$

Zbog linearnosti matematičkog očekivanja je

$$E(2X - 4) = 2EX - 4 = 2 \cdot 4 - 4 = 4.$$

Prema (6.7) je

$$EX^2 = 1^2 \cdot 0,2 + 3^2 \cdot 0,3 + 5^2 \cdot 0,3 + 7^2 \cdot 0,2 = 20,2.$$

Rješenje 70 (Zadatak 6.5.3)**.** Prema definiciji očekivanja za diskretne slučajne varijable 6.1.1 imamo

$$EX = -1 \cdot 0,2 + 0 \cdot 0,15 + 1 \cdot 0,4 + 2 \cdot 0,25 = 0,7 \quad \text{i}$$
$$EY = 0 \cdot 0,3 + 2 \cdot 0,2 + 4 \cdot 0,5 = 2,4.$$

Prema (6.7) je

$$E|X| = |-1| \cdot 0,2 + |0| \cdot 0,15 + |1| \cdot 0,4 + |2| \cdot 0,25 = 1,1,$$
$$EX^2 = (-1)^2 \cdot 0,2 + 0^2 \cdot 0,15 + 1^2 \cdot 0,4 + 2^2 \cdot 0,25 = 1,6 \quad \text{i}$$
$$EY^2 = 0^2 \cdot 0,3 + 2^2 \cdot 0,2 + 4^2 \cdot 0,5 = 8,8.$$

Stoga je, prema (6.14)

$$\operatorname{Var}(X) = EX^2 - (EX)^2 = 1,6 - 0,7^2 = 1,11 \quad \text{i}$$
$$\operatorname{Var}(Y) = EY^2 - (EY)^2 = 8,8 - (2,4)^2 = 3,04.$$

Zbog linearnosti očekivanja je

$$E(X + Y) = EX + EY = 0,7 + 2,4 = 3,1.$$

Kako su X i Y nezavisne, prema (6.6)

$$E(XY) = EX \cdot EY = 0,7 \cdot 2,4 = 1,68,$$

a opet zbog linearnosti očekivanja imamo

$$E(2XY - 2) = 2E(XY) - 2 = 2 \cdot 1,68 - 2 = 1,36.$$

Rješenje 71 (Zadatak 6.5.4)**.** Prema uvjetima zadatka u svakoj od igara prikupite 20 eura. Ako se kuglica zaustavi na crnom polju isplaćujete 20 eura i isto toliko ako se kuglica zaustavi na crvenom polju. Ako se kuglica zaustavi na zelenom polju ne plaćate ništa igračima. Označimo s X_1 slučajnu varijablu koja je jednaka isplaćenom iznosu u prvoj igri (jednoj igri) ruleta. Kako je vjerojatnost da će se kuglica zaustaviti na crvenom polju jednaka $18/37$, vjerojatnost da će se kuglica zaustaviti na crnom polju jednaka $18/37$ te vjerojatnost da će se kuglica zustaviti na zelenom polju jednaka $1/37$ zaključujemo da je razdioba slučajne varijable X_1 dana s

$$X_1 \sim \begin{pmatrix} 0 & 20 \\ 1/37 & 36/37 \end{pmatrix}$$

Prema uvjetima zadatka je Vaš dobitak D_1 u jednoj igri jednak

$$D_1 = 20 - X_1.$$

Vidimo da je D_1 slučajna varijabla (dobivena iz X_1) pa joj možemo izračunati očekivanje. Dobivamo

$$ED_1 = 20 - EX_1 = 20 - (0 \cdot \frac{1}{37} + 20 \cdot \frac{36}{37}) = 20 - 19,45946 = 0,54054.$$

Dakle, Vaš očekivani dobitak u jednoj igri iznosi $0,54054$ eura. Izračunajmo i varijancu slučajne varijable D_1, a u tu svrhu najprije izračunajmo varijancu slučajne varijable X_1. Jer je

$$EX_1^2 = 0^2 \cdot \frac{1}{37} + 20^2 \cdot \frac{36}{37} = 389,1892$$

Dobivamo

$$\mathrm{Var}\,(X_1) = EX_1^2 - (EX_1)^2 = 389,1892 - (19,45946)^2 = 389,1892 - 378,6706 = 10,5186.$$

Sada, prema svojstvima *i*) i *ii*) iz Propozicije 6.1.13, izračunamo varijancu Vašeg očekivanog dobitka u jednoj igri

$$\mathrm{Var}\,(D_1) = \mathrm{Var}\,(20 - X_1) = \mathrm{Var}\,(X_1) = 10,5186.$$

Nadamo se da je ovakav rezultat i intuitivno jasan: jedina varijabilnost u Vašoj dobiti u pojedinoj igri proizlazi iz varijabilnosti slučajne varijable X_1, odnosno iz ishoda vrtnje ruleta.
Ako će u 100 dana biti odigrano po 30 igri ruletom dnevno jasno je da će ukupno biti odigrano 3.000 igri. Označimo Vašu dobit u prvoj igri s D_1, u drugoj s D_2 i tako dalje do dobiti u tritisućitoj igri s $D_{3.000}$. Neka je D_u Vaš ukupni dobitak nakon 100 dana na igri ruleta. Uočite da on može biti i nula (ako se u 3.000 vrtnji ruleta kuglica niti jednom nije zaustavila na zelenom polju). Jasno, $D_u = D_1 + D_2 + \ldots + D_{3.000}$ i sve slučajne varijable D_i, $i = 1, 2, \ldots, 3000$ imaju jednaku razdiobu kao D_1. Prema linearnost očekivanja je Vaš očekivani dobitak nakon 100 dana jednak

$$ED_u = ED_1 + ED_2 + \ldots ED_{3.000} = 3000 \cdot ED_1 = 1.621,62 \text{ eura.}$$

Izračun varijance ukupnog dobitka D_u je olakšan činjenicom da su vrtnje ruletom nezavisne pa su nezavisne i slučajne varijable $D_1, D_2, \ldots, D_{3.000}$. Prema (6.15) imamo

$$\mathrm{Var}\,(D_u) = 3.000 \cdot \mathrm{Var}\,(D_1) = 3.000 \cdot \mathrm{Var}\,(D_1) = 31.555,8.$$

Vidimo da je varijanca očekivanog dobitka prilično velika pa bi mogli razmišljati da je Vaš ukupni očekivani dobitak pozitivan, ali da pri tome previše riskirate. Ipak, velika

varijanca je u ovom slučaju malo zavaravajuće. Naime, ukupni očekivani dobitak ne može biti negativan jer će Vam u najgorem slučaju (niti u jednoj vrtnji ruleta se kuglica nije zaustavila na zelenoj boji) ostati nula eura. Nadalje, u praksi ćete odstupanje stvarne zarade od očekivane zarade mjeriti standardnom devijacijom, a ona je jednaka $\sqrt{31.555,8} = 177,64$ eura.
Možemo još malo detaljnije razmisliti o negativnim scenarijima za "business case" posla s ruletom.[29] Možemo se zapitati kolika je uopće vjerojatnost da se u niti u jednoj vrtnji ruleta kuglica neće zaustaviti na zelenom polju. Ako jednu vrtnju ruleta smatramo jednim slučajnim eksperimentom, onda je, zbog nezavisnosti izvođenja, jasno da u zadatku gledamo nezavisno izvođenje slučajnog eksperimenta u kojem je uspjeh "kuglica se zaustavila na zelenom polju", a neuspjeh "kuglica se zaustavila na crvenom ili crnom polju". U skladu s time možemo definirati slučajne događaje $A_i =$ "u i-toj vrtnji ruleta se kuglica zaustavila na zelenom polju", $i = 1, 2, \ldots, 3.000$. Događaji A_i su nezavisni i $P(A_i) = 1/37$. Događaj $A =$ "u niti jednoj vrtnji se kuglica nije zaustavila na zelenom polju" je zapravo jednak

$$A = A_1^c \cap A_2^c \cap \ldots \cap A_{3000}^c = \bigcap_{i=1}^{3000} A_i^c.$$

Prema Propoziciji 4.3.5 (uz korištenje matematičke indukcije) slijedi da su i slučajni događaji A_i^c nezavisni pa je

$$P(A) = P(A_1^c)P(A_2^c)\ldots P(A_{3000}^c) = (P(A_i^c))^{3000} = (1 - P(A_i))^{3000} = \left(\frac{36}{37}\right)^{3000} \approx 2 \cdot 10^{-36}.$$

Dakle, taj je slučajni događaj, iako moguć, vrlo malo vjerojatan.
Uočimo za kraj sljedeće: ako je uspjeh u i-toj vrtnji ruleta događaj da se kuglica zaustavila na zelenom polju, onda cijeli taj niz vrtnji ruleta možemo modelirati nizom (nezavisnih) Bernoullijevih slučajnih varijabli s vjerojatnosti uspjeha $p = 1/37$. Tada je očekivana vrijednost pojedinačne Bernoullijeve slučajne varijable jednaka $p = 1/37$, dok je očekivana vrijednost zbroja njih 3.000 jednaka $3000 \cdot 1/37 = 81,081$. Ako se sjetimo uvjeta zadatka, odnosno činjenice da se cijela naša zarada zasniva na slučajevima u kojima se kuglica zustavi na zelenom polju te da u tim slučajevima uprihodujemo 20 eura, onda je jasno da je naša očekivana zarada jednaka $20 \cdot 81,081 = 1.162,62$ eura, što samo povrđuje prijašnji izračun.

Rješenje 72 (Zadatak 6.5.5)**.** Prema (6.3) je

$$EX = \frac{3}{16}\int_{-2}^{2} x^3 dx = \frac{3}{16}\frac{x^4}{4}\Big|_{x=-2}^{x=2} = \frac{3}{16}\left(\frac{2^4}{4} - \frac{(-2)^4}{4}\right) = 0.$$

Uočite da smo i bez računa mogli znati da će očekivanje biti jednako nuli. Naime, podintegralna funkcija x^3 je neparna pa je traženo očekivanje zapravo integral neparne funkcije na području integracije koje je simetrično oko nule, a takav integral je jednak nuli. Istim argumentom slijedi da je $EX^5 = 0$.
Kako je $EX = 0$ slijedi da je $\mathrm{Var}\,(X) = EX^2$. Dakle,

$$\mathrm{Var}\,(X) = EX^2 = \frac{3}{16}\int_{-2}^{2} x^4 dx = \frac{3}{16}\frac{x^5}{5}\Big|_{x=-2}^{x=2} = \frac{3}{16}\left(\frac{2^5}{5} - \frac{(-2)^5}{5}\right) = \frac{3}{16}\cdot\frac{64}{5} = \frac{12}{5}.$$

Rješenje 73 (Zadatak 6.5.6)**.** Prva tri svojstva vrijede na skupovnoj razini što se lagano provjeri. Valjanost svojstva *iii*) možemo provjeriti i algebarski

$$I_{A\cup B} = i) = 1 - I_{A^c\cap B^c} = ii) = 1 - I_{A^c}I_{B^c} = i) = 1 - (1 - I_A)(1 - I_B) = I_A + I_B - I_A I_B.$$

[29] Ovo je zaista samo ilustrativan primjer analize rizika nekog poslovnog poduhvata. Autor na nikoji način ne potiče, a čak i ne podupire, bavljenjem igrama na sreću, odnosno klađenjem.

U gornjem raspisu smo iskoristili de Morganovu formulu za komplement unije. Podsjećamo, imamo dvije takve formule

$$(A \cup B)^c = A^c \cap B^c \quad \text{i} \quad (A \cap B)^c = A^c \cup B^c$$

koje vrijede za općenite skupove A i B.

Dokaz svojstva *iv*) se zasniva na Teoremu 5.2.14. Pretpostavimo[30] da su A i B nezavisni slučajni događaji. Tada je $P(A \cap B) = P(A)P(B)$. Uočimo da su jedine vrijednosti indikatora I_A i I_B brojevi 0 i 1. Stoga se uvjet (5.13) svodi na provjeru 4 jednakosti.
Ukoliko su, prema oznakama u Teoremu 5.2.14, $a_1 = 0$ i $b_1 = 0$, onda je prema definiciji indikatora

$$P(I_A = 0) = P(\{\omega \in \Omega \mid I_A(\omega) = 0\}) = P(\{\omega \in A^c\}) = P(A^c)$$

i slično $P(I_B = 0) = P(B^c)$. S druge strane je

$$P(I_A = 0, I_B = 0) = P(\{\omega \in \Omega \mid I_A(\omega) = 0\} \cap \{\omega \in \Omega \mid I_B(\omega) = 0\}) = P(A^c \cap B^c).$$

Sada se pitamo da li vrijedi

$$P(A^c \cap B^c) = P(I_A = 0, I_B = 0) = P(I_A =)P(I_B = 0) = P(A^c)P(B^c)$$

pri čemu smo upravo pokazali da vrijede dvije vanjske jednakosti. Srednja jednakost vrijedi zbog Propozicije 4.3.5 u kojoj smo ustvrdili da nezavisnost događaja A i B implicira nezavisnost događaja A i B^c, zatim A^c i B te A^c i B^c.

Dosta je jasno da na vrlo sličan način možemo provjeriti valjanost uvjeta (5.13) za $a_2 = 1$ i $b_1 = 0$, zatim $a_1 = 0$ i $b_2 = 1$ i napokon $a_2 = 1$ i $b_2 = 1$. Obratna implikacija (ako su I_A i I_B nezavisne slučajne varijable, onda su A i B nezavisni slučajni događaji) se lagano dokaže jer iz jednakosti

$$P(I_A = 1, I_B = 1) = P(I_A = 1)P(I_B = 1)$$

direktno slijedi da je $P(A \cap B) = P(A)P(B)$.

Svojstvo *v*) se dokaže iz svojstva *iv*) korištenjem matematičke indukcije.

Rješenje 74 (Zadatak 6.5.7)**.** Zbog linearnosti očekivanja je

$$EY = 4 - 2EX = 4 - 2 \cdot 2 = 0.$$

Prema svojstvima *i*) i *ii*) iz Propozicije 6.1.13 je

$$\operatorname{Var}(Y) = \operatorname{Var}(4 - 2X) = \operatorname{Var}(-2X) = 4 \operatorname{Var}(X) = 4 \cdot 3 = 12.$$

Rješenje 75 (Zadatak 6.5.8)**.** Prije svega uočimo da možemo definirati dosta jasan skup elementarnih događaja koji opisuje ovaj eksperiment. Naime, ako stavimo $\Omega = \{(i, j) \mid i, j = 1, 2, 3, 4\}$, jasno je da ćemo opisati sve moguće ishode bacanja dva pravilna tatraedra. Jer je riječ o pravilnim tetraedrima jasno je da je prirodno definirati vjerojatnost na Ω kao $P(\{\omega\}) = 1/16$, gdje je $\omega \in \Omega$ (jasno, za svaki $\omega \in \Omega$ postoje neki $i, j \in \{1, 2, 3, 4\}$ takvi da je $\omega = (i, j)$). Za ovaj zadatak nije prevažno, ali se možemo podsjetiti da nezavisne eksperimente možemo modelirati Kartezijevim produktom

[30] Matematičke tvrdnje koje uključuju formulaciju ako i samo ako uključuju zapravo dvije implikacije. U ovom slučaju se zapravo tvrdi: ako su A i B nezavisni događaji, onda su I_A i I_B nezavisne slučajne varijable, ali i obratno: ako su I_A i I_B nezavisne slučajne varijable, onda su događaji A i B nezavisni.

skupova, a vjerojatnost na tom produktu definiramo kao produkt vjerojatnosti na komponentama. U ovom slučaju možemo definirati $\Omega_1 = \{1,2,3,4\}$ i vjerojatnost P_1 na Ω_1 sa $P_1(\{i\}) = 1/4$, za $i = 1,2,3,4$. Tada je $\Omega = \Omega_1 \times \Omega_1$, a $P = P_1 \times P_1$, što znači da je $P(\{(i,j)\}) = P_1(\{i\}) \cdot P_1(\{j\})$, gdje su $i,j \in \{1,2,3,4\}$.

Najprije trebamo odrediti koje sve vrijednosti može poprimiti slučajna varijabla T. Kako je ona zbroj brojeva koji su pali na tetraedrima jasno je da su njene moguće vrijednosti $2,3,4,5,6,7$ ili 8. Jasno, T je diskretna slučajna varijabla pa ima svoju razdiobu. Nju određujemo tako da odredimo vjerojatnosti $P(T = k)$, za $k \in \{2,3,4,5,6,7,8\}$. Istaknuli smo više puta, ali ponovimo još jednom: $P(T = k)$ je pokrata za vjerojatnost skupa $\{\omega \in \Omega \mid T(\omega) = k\}$.

U svakom slučaju, lagano izračunamo vjerojatnosti $P(T = k)$ jer su to samo vjerojatnosti podskupova od Ω koji se sastoje od uređenih parova (i,j) za koje je $i + j = k$. Konkretno, za $k = 4$ je $\{T = 4\} = \{(1,3),(2,2),(3,1)\}$ pa je $P(T = 4) = 3/16$, prema naivnoj definiciji vjerojatnosti. U svakom slučaju, dobijemo

$$T \sim \begin{pmatrix} 2 & 3 & 4 & 5 & 6 & 7 & 8 \\ 1/16 & 2/16 & 3/16 & 4/16 & 3/16 & 2/16 & 1/16 \end{pmatrix}.$$

Da je zaista riječ o razdiobi provjerimo tako da se uvjerimo da je zbroj brojeva u donjem redu gornje tablice jednak 1. Očekivanje slučajne varijable T je jednako

$$ET = 2 \cdot \frac{1}{16} + 3 \cdot \frac{2}{16} + 4 \cdot \frac{3}{16} + 5 \cdot \frac{4}{16} + 6 \cdot \frac{3}{16} + 7 \cdot \frac{2}{16} + 8 \cdot \frac{1}{16} = \frac{80}{16} = 5.$$

Kako je

$$ET^2 = 2^2 \cdot \frac{1}{16} + 3^2 \cdot \frac{2}{16} + 4^2 \cdot \frac{3}{16} + 5^2 \cdot \frac{4}{16} + 6^2 \cdot \frac{3}{16} + 7^2 \cdot \frac{2}{16} + 8^2 \cdot \frac{1}{16} = 27,5$$

Dobivamo

$$\operatorname{Var}(T) = ET^2 - (ET)^2 = 27,5 - 5^2 = 2,5.$$

Za dodatnu vježbu možete izračunati očekivanje i varijancu slučajnih varijabli $T - 5$ ili $2T$.

Rješenje 76 (Zadatak 6.5.9)**.** Radi grafički jasnije argumentacije označimo $\mu_X = EX$ i $\mu_Y = EY$. Prema definiciji kovarijance i zbog linearnosti očekivanja imamo

$$\begin{aligned} \operatorname{Cov}(X,Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E(XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y) \\ &= E(XY) - \mu_X EY - \mu_Y EX + \mu_X \mu_Y E(1) \\ &= E(XY) - \mu_X \mu_Y - \mu_Y \mu_X + \mu_X \mu_Y = E(XY) - EXEY. \end{aligned}$$

Rješenje 77 (Zadatak 6.5.10)**.** Ovo je vrlo jednostavan zadatak kojem je svrha izvježbati izračune vezane uz slučajne varijable. S obzirom da se u zadatku traži ocjena vjerojatnosti $P(|X - 1| \geq 3)$ prirodno se nameće iskoristiti Čebiševljevu nejednakost. U tu svrhu izračunajmo očekivanje i varijancu slučajne varijable X. Imamo

$$EX = -1 \cdot \frac{5}{12} + 0 \cdot \frac{1}{6} + 1 \cdot \frac{1}{6} + 5 \cdot \frac{1}{4} = \frac{-5 + 2 + 15}{12} = 1,$$

$$EX^2 = (-1)^2 \cdot \frac{5}{12} + 0^2 \cdot \frac{1}{6} + 1^2 \cdot \frac{1}{6} + 5^2 \cdot \frac{1}{4} = \frac{5 + 2 + 75}{12} = \frac{82}{12} = \frac{20,5}{3} \quad \text{i}$$

$$\operatorname{Var}(X) = EX^2 - (EX)^2 = \frac{20,5}{3} - 1 = \frac{17,5}{3}.$$

Kako je $EX = 1$, prema Čebiševljevoj nejednakosti imamo ocjenu

$$P(|X-1| \geq 3) \leq \frac{\operatorname{Var}(X)}{3^2} = \frac{17.5}{27} = 0,648.$$

S druge strane, kada imamo cijelu razdiobu slučajne varijable, a ne samo očekivanje i varijancu poput siutacije u Primjeru 6.2.4, u principu možemo egzaktno izračunati traženu vjerojatnost. Naime, prvo vidimo da je razdioba slučajne varijable $X-1$ dana s (pogledajte Primjer 5.2.18)

$$X - 1 \sim \begin{pmatrix} -2 & -1 & 0 & 4 \\ 5/12 & 1/6 & 1/6 & 1/4 \end{pmatrix}$$

pa je razdioba od $|X-1|$

$$|X-1| \sim \begin{pmatrix} 0 & 1 & 2 & 4 \\ 1/6 & 1/6 & 5/12 & 1/4 \end{pmatrix}.$$

Zbog toga je $P(|X-1| \geq 3) = P(|X-1| = 4) = 1/4$.

Rješenje 78 (Zadatak 6.5.11)**.** S obzirom da znamo razdiobu slučajne varijable Z (pogledajte Primjer 6.1.9) lagano izračunamo

$$\begin{aligned} P(Z \leq 6) &= P(Z=2) + P(Z=3) + P(Z=4) + P(Z=5) + P(Z=6) \\ &= \frac{1}{36} + \frac{2}{36} + \frac{3}{36} + \frac{4}{36} + \frac{5}{36} = \frac{15}{36} \approx 0,41666. \end{aligned}$$

Radi vježbe ocijenimo vjerojatnost $P(Z < 6)$ Čebiševljevom nejednakosti. U tu svrhu izračunajmo očekivanje i varijancu slučajne varijable Z. S obzirom da znamo razdiobu slučajne varijable Z očekivanje i varijancu možemo izračunati prema definicijskim formulama (6.1) i (6.12). No, kao što smo već uočili u Primjeru 6.1.9, te izračune je lakše napraviti korištenjem činjenice da je Z zbroj dvije nezavisne i jednako distribuirane slučajne varijable X i Y koje su jednake brojevima koji su pali na prvoj, odnosno drugoj kockici. Tako smo jednostavno izračunali da je

$$EZ = EX + EY = 3,5 + 3,5 = 7.$$

Kako je za uniformnu slučajnu varijablu varijanca jednaka $(n^2-1)/12$, a zbog nezavisnosti slučajnih varijabli X i Y, zaključujemo da je

$$\operatorname{Var}(Z) = \operatorname{Var}(X) + \operatorname{Var}(Y) = \frac{6^2-1}{12} + \frac{6^2-1}{12} = \frac{70}{12} \approx 5,83333.$$

Primijenimo sada Čebiševljevu nejednakost. Uočimo da je ne možemo direktno primijeniti, ali malim promjenama zapisa dobivamo

$$P(Z \leq 6) = P(Z-7 \leq -1) \leq P(|Z-7| \geq 1) = P(|Z-EZ| \geq 1).$$

Na zadnju vjerojatnost u gornjem nizu jendakosti možemo direktno primijeniti Čebiševljevu nejednakost pa dobivamo ocjenu

$$P(Z \leq 6) \leq \frac{\operatorname{Var}(Z)}{1} = \frac{5,83333}{1} = 5,83333.$$

Naravno, uvijek je $P(Z \leq 6) \leq 1$ pa nam Čebiševljeva nejednakost u ovom slučaju nije dala nikakvu novu informaciju. Stvar je u tome da je varijanca slučajne varijable Z dosta velika, a mi smo tražili procjenu vjerojatnosti malog odstupanja od očekivanja $P(|Z-EZ| \geq 1)$.

Rješenje 79 (Zadatak 6.5.12)**.** Prema uvjetima zadatka uzima se 30 uzoraka folija. Neka su $X_1, X_2, \ldots, X_{30}$ izmjerene duljine folija. Na njih možemo gledati kao na slučajne varijable čije je očekivanje $50,06$, a standardna devijacija $0,12$. Kako se uzorak uzima na slučajan način slučajne varijable $X_1, X_2, \ldots, X_{30}$ možemo smatrati nezavisnima. Stoga je primjenjiv centralni granični teorem na prosjek tih slučajnih varijabli

$$\bar{X}_{30} = \frac{X_1 + X_2 + \ldots + X_{30}}{30}.$$

Zanima nas procjena vjerojatnosti $P(\bar{X}_{30} < 50)$. Da bi ju procjenili koristimo formulu (6.61). Prema njoj je

$$\begin{aligned} P(\bar{X}_{30} < 50) &= P\Big(\sqrt{30}\frac{\bar{X}_{30} - 50,06}{0,12} \leq \sqrt{30}\frac{50 - 50,06}{0,12}\Big) \\ &\approx P\Big(Z \leq \sqrt{30}\frac{50 - 50,06}{0,12}\Big) = \Phi\Big(-2,738613\Big), \end{aligned}$$

gdje je $Z \sim N(0,1)$ jedinična normalna slučajna varijabla, a Φ njena funkcija ditribucije. Iskoristimo R da izračunamo $\Phi(-2.738613)$

```
> pnorm(-2.738613)

[1] 0.003084948
```

Dakle, tražena vjerojatnost je manja od $0,005$.

Rješenje 80 (Zadatak 6.5.13)**.** Označimo s X slučajnu varijablu koja označava broj studenata koji dolaze na predavanje. Pretpostavimo da svaki student neovisno od drugim studentima dolazi ili ne dolazi na predavanje (to i ne mora biti u potpunosti zadovoljeno, ali pragmatično gledano uz tu pretpostavku možemo procijeniti traženu vjerojatnost). Stoga dolaske studenata na predavanja možemo modelirati Bernoullijevim slučajnim varijablama s vjerojatnostima uspjeha $p = 0,3$. Uz tu pretpostavku je zapravo X binomna slučajna varijabla s parametrima $n = 450$ i $p = 0,3$. Korištenjem Moivre-Laplaceovog centralnog graničnog teorema ćemo procijeniti vjerojatnost da je

$$P(X > 150.5)$$

pri čemu koristimo korekciju za neprekidnost (nije naročita greška ako ne koristite korekciju za neprekidnost nego računate $P(X > 150)$). Po uzoru na formule (6.67) i (6.68) računamo

$$P(X > 150.5) = P\Big(\frac{X - 450 \cdot 0,3}{\sqrt{450 \cdot 0,3 \cdot 0,7}} > \frac{150,5 - 450 \cdot 0,3}{\sqrt{450 \cdot 0,3 \cdot 0,7}}\Big) \approx P(Z > 1,59),$$

gdje je Z standardna normalna slučajna varijabla za koju je $P(Z > 1,59) = 1 - \Phi(1,59)$. Iskoristimo R da dobijemo

```
> pnorm(1.59)

[1] 0.9440826
```

pa je

$$P(X > 150.5) \approx 1 - \Phi(1,59) = 1 - 0,9440826 \approx 0,06.$$

Dakle, vjerojatnost da će više od 150 studenta doći na predavanje je približno jednaka $0,06$.

Rješenje 81 (Zadatak 6.5.14)**.** Neka je X ukupan broj sendviča koji će svi ljudi pojesti, a X_i, $i = 1, 2, \ldots, 30$ broj sendviča koji će pojesti osoba i. Jasno,

$$X = X_1 + X_2 + \ldots + X_{30}.$$

Pretpostavimo da svaka osoba pojede određeni broj sendviča nezavisno od drugih osoba. Uz takve pretpostavke se čni da bi mogli primijeniti centralni granični teorem, s time da ne znamo očekivanje i varijancu slučajnih varijabli X_i. Ipak, iz uvjeta zadatka možemo pretpostaviti da je

$$X_1 \sim \begin{pmatrix} 0 & 1 & 2 \\ 1/8 & 1/2 & 3/8 \end{pmatrix}.$$

Sada lagano izračunamo

$$EX = 0 \cdot \frac{1}{8} + 1\frac{1}{2} + 2\frac{3}{8} = \frac{10}{8} = 1,25,$$

$$EX^2 = 0^2 \cdot \frac{1}{8} + 1^2\frac{1}{2} + 2^2\frac{3}{8} = \frac{16}{8} = 2 \quad \text{i}$$

$$\operatorname{Var}(X) = EX^2 - (EX)^2 = 2 - (1,25)^2 = 0,4375.$$

Iz tog računa slijedi da je

$$EX = 30EX_1 = 30 \cdot 1,25 = 37.5$$

a zbog nezavisnosti i

$$\operatorname{Var}(X) = 30 \operatorname{Var}(X_1) = 30 \cdot 0,4375 = 13,125.$$

Sada se pitamo koliko mora biti broj x tako da vrijedi

$$P(X \leq x) \geq 0,95.$$

Malo modificiramo slučajnu varijablu Z_{30} iz (6.59) da dobijemo

$$Z_{30} = \frac{X_1 + X - 2 + \ldots + X_{30} - 30EX_1}{\sqrt{30 \cdot \operatorname{Var}(X_1)}} = \frac{X_1 + X - 2 + \ldots + X_{30} - 37,5}{\sqrt{13,125}}$$

pa onda iz centralnog graničnog teorema, odnosno relacije (6.60) slijedi

$$P(X \leq x) = P\Big(\frac{X - 37,5}{\sqrt{13,125}} \leq \frac{x - 37,5}{\sqrt{13,125}}\Big) = P\Big(Z_{30} \leq \frac{x - 37,5}{\sqrt{13,125}}\Big) \approx \Phi\Big(\frac{x - 37,5}{\sqrt{13,125}}\Big).$$

Sada se pitamo koliki treba biti x da je izraz s gornje strane gornjih jednakost veći ili jednak od 0.95. U R-u izračunamo broj z takav da je $\Phi(z) = 0,95$ i to korištenjem funkcije `qnorm()`

```
> qnorm(0.95)

[1] 1.644854
```

Dakle,

$$\frac{x - 37,5}{\sqrt{13,125}} \approx \Phi^{-1}(0,95) = 1,64485.$$

Iz toga slijedi da je $x \approx 43,459$. Dakle, ako napravimo 44 sendviča ćemo s 95%-tnom vjerojatnosti zadovoljiti potražnju za sendvičima na druženju koje organiziramo.

Rješenje 82 (Zadatak ??)**.**

Poglavlje 7

Osnove statističkog zaključivanja

Statistika se, kao znanost, bavi proučavanjem podataka. Poveznica svijeta vjerojatnosti i slučajnih događaja s podacima su slučajne varijable. Na podatke možemo gledati kao na realizacije slučajnih varijabli. Statističko zaključivanje je proces kojim iz podataka želimo nešto zaključiti o pravilnostima u ponašanju podataka. U jeziku vjerojatnosti zapravo želimo odrediti razdiobu iz koje dolaze podaci. Kako podatke modeliramo slučajnim varijablama pitanje koje si postavljamo u statističkom zaključivanju je da li iz nekog niza vrijednosti slučajnih varijabli $X_1, X_2, \ldots, X_n$, $n \in \mathbb{N}$, možemo odrediti razdiobu tih slučajnih varijabli ili barem neke značajke razdiobe poput očekivanja i varijance. Takva razmatranja nam pomažu da bolje shvatimo i opišemo slučajnu pojavu koju proučavamo, a u konačnici da i donekle predvidimo ponašanje te slučajne pojave.

7.1 Procjenitelji

Kao što smo istaknuli, statistika se bavi proučavanjem podataka. Statističkom terminologijom govoreći podatke dobivamo mjerenjima nekih značajki dijela jedinki koje čine ukupnu **populaciju**. Mjerenja koja generiraju podatke mogu biti jednostavna (visina, težina, duljina, brojnost i slično), ali i vrlo agregirana (primjerice podaci o bruto domaćem proizvodu koji nastaje u interakciji mnoštva ekonomskih aktera). Razni podaci prirodno sadrže određenu razinu slučajnosti (neizvjesnosti), bilo da ona (slučajnost) nastaje zbog varijabilnosti nekih značajki u populaciji, zbog grešaka mjerenja tih varijabilnosti, ili neizvjesnoti u ishodima nekog događaja. Načelno govoreći, na slučajnost smo se referirali uvodeći pojam slučajnog eksperimenta što nam je bila motivacija za proučavanje vjerojatnosih prostora. Uvođenjem aksiomatike teorije vjerojatnosti (poglavlje o vjerojatnosti) postavili smo temelje za razvoj teorije vjerojatnosti čije smo dijelove izložili u prethodnim poglavljima.

Može se argumentirati da je formalizam vjerojatnosnih prostora teorijski konstrukt pa se postavlja pitanje kako povezati apstraktne pojmove teorije vjerojatnosti sa podacima. Statistička analiza podataka pokušava pronaći **statističke modele** koji bi dobro opisivali podatke koje pruočavamo. Poveznica vjerojatnosti sa statistikom su slučajne varijable. Koristeći se konceptualnim okvirom slučajnih varijabli povezujemo proučavanje slučajnih eksperimenata sa statističkim modelima. Slučajne varijable pridružuju brojeve slučajnim događajima vezanima uz općenitu slučajnu pojavu koju proučavaju. Statistika želi pronaći statistički model kojim će opisati tako dobivene vrijednosti (podatke).

Malo formalnije, ako s X označimo slučajnu varijablu kojom želimo opisati neke značajke slučajne pojave ili populacije koju proučavamo, a s $\mathcal{M}_\theta$ statistički model koji opisuje podatke koje dobivamo mjerenjima tih značajki, onda konceptualnu vezu vjerojatnosnih

prostora i slučajnih modela možemo prikazati kao

$$(\Omega, \mathcal{F}, P) \xrightarrow{X} \mathcal{M}_\theta.$$

Naravno, vjerojatnost P je ta koja strukturi slučajnih događaja pridružuje mjeru neizvjesnosti (vjerojatnosti kao brojevi pridruženi nekim slučajnim događajima). Ta se mjera neizvjesnosti treba prenijeti i na statističke modele jer oni po prirodi modeliranja slučajnih pojava ne mogu deterministički (mehanicistički) opisati stvarnost.

7.1.1 Uzorak

Ako slučajne varijable daju informacije o nekim slučajnim pojavama postavlja se pitanje kako pomoću slučajnih varijabli možemo doći do određenog statističkog modela kojim ćemo opisati promatranu slučajnu pojavu. Sjetimo se, slučajne varijable mogu mjeriti neke kvantitativne karakteristike određenih jedinki, ali i ishode nekog slučajnog eksperimenta poput bacanja novčića. Ako populaciju čine sve jedinke neke vrste (živa bića ili predmeti) ili svi slučajni eksperimenti koji se mogu izvesti pod nekim uvjetima, onda je osnova ideja da promatramo dio jedinki ili određeni broj slučajnih eksperimenata kako bi izdvojili **uzorak iz promatrane populacije**. Populacijom možemo nazvati i niz slučajnih eksperimenata. Cilj statističkog zaključivanja je proučavanjem karakteristika uzorka pružiti odgovore o karakteristikama cijele populacije.

Uzorak se može prikupljati na različite načine i odnositi na različite pojave. U nastavku ćemo promatrati uzorke koji se dobivaju slučajnim odabirom jedinki iz populacije ili nezavisnim ponavljanjem nekog slučajnog eksperimenta. U skladu s time imamo sljedeću definiciju.

Definicija 7.1.1 (Uzorak)**.** Niz **nezavisnih** slučajnih varijabli $X_1, X_2, \ldots, X_n$, $n \in \mathbb{N}$, koje imaju **istu razdiobu** nazivamo **slučajnim uzorkom** ili samo **uzorkom**. Za niz slučajnih varijabli $X_1, X_2, \ldots, X_n$ kažemo da je **nezavisan i jednako distribuiran** i često koristimo skraćenicu n.j.d. kako bi opisali takav niz slučajnih varijabli.

Uzorak često označavamo kao $X^n = (X_1, X_2, \ldots, X_n)$, odnosno na uzorak možemo gledati kao na slučajni vektor. Reći ćemo da se uzorak **bira na slučajan način** ako svaki element iz populacije čije karakteristike želimo proučiti ima jednaku vjerojatnost da bude izabran u uzorak i neovisno od drugih članova u uzorku. Uz takvu interpretaciju su varijable $X_1, X_2, \ldots, X_n$ nezavisne i imaju jednaku razdiobu pa su u skladu s prethodnom definicijom.

Definiravši pojam uzorka možemo preciznije reći što podrazumijevamo pod pojmom statističkog modela $\mathcal{M}_\theta$ kojim želimo opisati neke podatke. Naime, statistički modeli $\mathcal{M}_\theta$ obuhvaćaju općeniti skup razdioba, odnosno distribucija. Na razini statistike načelno se razlikuju **parametarski** i **neparametarski** statistički modeli. Parametarski statistički modeli pretpostavljaju da se razdiobe iz $\mathcal{M}_\theta$ mogu opisati konačnim skupom parametara $\theta \in \Theta$, pri čemu se Θ naziva prostorom parametara.[1] Kod neparametarskih modela se ne pretpostavlja da postoji konačan skup parametara koji opisuje $\mathcal{M}_\theta$, odnosno se pretpostavlja da su parametri iz nekog beskonačno dimenzionalnog skupa. U slučaju neparametarskih modela se želi procijeniti razdioba bez pretpostavke o pripadnosti te razdiobe nekoj grupi razdioba. U nastavku ćemo uglavnom gledati parametarske modele, iako ćemo se susresti i s neparametarskim modelima, odnosno metodama (određivanje empirijske funkcije distribucije).

[1] Opet nova grčka slova. Problem je u matematici, a vidimo i u statistici, da su "obična" slova rezervirana za brojeve, skupove, funkcije i slično pa nam za objekte koje želimo izdvojiti posebnim označavanjem trebaju dodatne oznake. Uobičajeni prvi odabir su slova iz grčkog alfabeta. θ je jedno od takvih slova. Čitamo ga kao "teta". Θ je samo veliko θ.

Ukoliko je $X_1, X_2, \ldots, X_n$ uzorak, onda je cilj parametarskog statističkog modeliranja određivanje zajedničke razdiobe $f((x_1, x_2, \ldots, x_n) \mid \theta)$, $\theta \in \Theta$, $x^n = (x_1, x_2, \ldots, x_n) \in \mathbb{R}^n$. Funkcije f su u principu funkcije gustoće koje određuju neku razdiobu, a θ predstavlja konačan skup parametara koji određuje tu razdiobu.[2] Dakle, iz uzorka $X_1, X_2, \ldots, X_n$ želimo odrediti razdiobe zadane s $f((x_1, x_2, \ldots, x_n) \mid \theta)$. Na razini statističkih modela to možemo shematski predstaviti kao

$$(X_1, X_2, \ldots, X_n) \to \mathcal{M}_\theta = \{f((x_1, x_2, \ldots, x_n) \mid \theta), \theta \in \Theta\}.$$

Neki od primjera parametarskih modela su

- $X_1, X_2, \ldots, X_n$ su iz Bernoullijeve razdiobe s parametrom p. Tada je $\theta = p$ parametar koji određuje razdiobu uzorka, a $\Theta = [0, 1]$,
- $X_1, X_2, \ldots, X_n$ su iz eksponencijalne razdiobe s parametrom λ. Tada je $\theta = \lambda$ parametar koji određuje razdiobu uzorka, a $\Theta = (0, \infty)$,
- $X_1, X_2, \ldots, X_n$ su iz normalne razdiobe s parametrima μ i σ^2. Tada se skup parametara θ sastoji od dva parametra μ i σ^2, a $\Theta = \mathbb{R} \times [0, \infty]$.

Ukoliko prihvatimo da je neki parametarski statistički model pogodan za modeliranje podataka koji su nam na raspolaganju, onda je cilj statističkog zaključivanja procjena tih paramatara. Drugo je pitanje prikladnosti odabranog modela, ali to se također može naknadno provjeriti s time da na ovomk mjestu ne ulazimo u tu problematiku.

U prijašnjim razmatranjima je jedna stvar ostala nerazjašnjena. Naime, rekli smo da se statistika bavi podacima (brojevima, ali i kvalitativnim podacima). S druge strane smo rekli da značajke neke slučajne pojave modeliramo slučajnim varijablama, odnosno uzorkom $X^n = (X_1, X_2, \ldots, X_n)$. Gdje su onda tu podaci? I što znači onaj $x^n = (x_1, x_2, \ldots, x_n)$ u $f((x_1, x_2, \ldots, x_n) \mid \theta)$?
Radi se o tome da u statistici gledamo **realizacije** slučajnih varijabli $X_1, X_2, \ldots, X_n$, odnosno uzorka X^n. Realizacije slučajnih varijabli su konkretne vrijednosti (brojevi) koje slučajne varijable postižu. Te realizacije nazivamo **opaženim uzorkom**. U terminima definicije slučajnih varijabli i vjerojatnosnih prostora na realizacije možemo gledati kao na vrijednosti $X^n(\omega) = (X_1(\omega) \ldots, X_1(\omega)) = (x_1, \ldots x_n) \in \mathbb{R}^n$, za $\omega \in \Omega$. Izračuni i procjene koje se obavljaju u statistici se obavljaju na brojevima koji su realizacije slučajnih varijabli, odnosno uzorka. Dakle, polazište u analizi podataka je opaženi uzorak koji modeliramo (slučajnim) uzorkom. Pomoću opaženog uzorka, odnosno konkretnih brojeva, želimo procijeniti parametre razdiobe kojoj pripadaju slučajne varijable čije smo realizacije opazili. Vektor $x^n = (x_1, x_2, \ldots, x_n)$ u $f((x_1, x_2, \ldots, x_n) \mid \theta)$ označava argumente funkcije f kojoj je domena $\mathbb{R}^n$, a kodomena $\mathbb{R}$ (pogledajte odjeljak 5.4.2). Prije nego što se malo detaljnije pozabavimo procjenom parametara, dajemo jednu napomenu.

Napomena 7.1.2. Kako znamo da su realizacije slučajnih varijabli "dobri reprezentanti" uzorka koji promatramo? Odgovor na to pitanje nije jednostavan i detaljniju raspravu ne možemo dati u okviru ove skripte. Načelno možemo reći da zakoni velikih brojeva garantiraju da, recimo, relativne frekvencije nekih slučajnih događaja konvergiraju prema vjerojatnostima tih slučajnih događaja (pogledajte relaciju (6.56)). No, kao što znamo (Napomena 6.2.10) zakoni velikih brojeva ne impliciraju potpunu (brojevnu) konvergenciju relativnih frekvencija, nego konvergenciju u vjerojatnosnom smislu. Stoga

[2] U osnovi f mogu biti i funkcije distribucije F jer i one jednoznačno određuju neku razdiobu, ali je uobičajeno gledati funkcije gustoće radi kasnije važne metode najveće vjerodostojnosti za određivanje parametara nekog statističkog modela. Funkcije gustoće za diskretne slučajne varijable možemo definirati kao funkcije razdiobe p koje su definirane u slučaju diskretnih slučajnih varijabli pa integrali kojima računamo vjerojatnosti ili očekivanje postaju zbrojevi (sume).

je zahtjev potreban za statističko modeliranje da je realizacija $(x_1, \dots x_n)$ zaista "reprezentativna" realizacija uzorka $X^n = (X_1, \dots, X_n)$. U osnovi nas takva razmatranja vode na frekventističku interpretaciju vjerojatnosti (Napomena 4.4.3), ali nećemo dublje ulaziti u tu problematiku. Zainteresirani čitatelj može pogledati poglavlja 6 i 11 u [15] ili poglavlje 10 u [13].
Uočimo još jednu činjenicu. Valjanost rezultata u statistici često argumentiramo nekim graničnim rezultatima poput zakona velikih brojeva ili centralnog graničnog teorema. Stoga pretpostavljamo da nam je na raspolaganju uzorak beskonačne duljine, a konkretno statističko zaključivanje provodimo upotrebom konačnog uzorka. Jasno, sve su populacije konačne, ali nam apstrahizacija u vidu dostupnosti beskonačnog niza opservacija (uzorka) potrebna kako bismo iskoristili vjerojatnosni aparat koji nam je na raspolaganju.
Materijal koji izlažemo u nastavku je vrlo standardan i ne ovisi o napomenama koje smo ovdje dali. Ipak, htjeli smo dati malo širi pogled na problem statističkog modeliranja kako bi se bolje razumjela njegova ograničenja. □

7.1.2 Statistike i procjenitelji

Neka je sada $X^n = (X_1, X_2, \dots, X_n)$, $n \in \mathbb{N}$ uzorak iz neke razdiobe koja je određena s $f((x_1, x_2, \dots, x_n) \mid \theta)$, gdje je θ neki konačan skup parametara. Sjetimo se, to znači da su slučajne varijable $X_1, X_2, \dots, X_n$ nezavisne i sve imaju istu razdiobu. Ta je razdioba određena s funkcijom gustoće f pri čemu na općenitoj razini ne razlikujemo diskretne i neprekidne slučajne varijable. Osnovni pojam koji ćemo koristiti u nastavku je pojam statistike čiju definiciju dajemo u sljedećoj definiciji.

Definicija 7.1.3 (Statistika)**.** Neka je $X^n = (X_1, X_2, \dots, X_n)$, $n \in \mathbb{N}$, slučajni uzorak. Funkcija slučajnog uzorka koja ne sadrži nepoznate parametre se naziva **statistikom**.

Uočimo da iz definicije proizlazi da su i same statistike slučajne varijable kao funkcije niza slučajnih varijabli. Neke od najpoznatijih statistika, koje smo već upoznali, su **uzoračka sredina** (eng. *sample mean*)

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i \tag{7.1}$$

i **uzoračka varijanca** (eng. *sample variance*)

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \bar{X}_n)^2. \tag{7.2}$$

Primjer funkcije slučajnog uzorka koja nije statistika je

$$\frac{1}{n-1} \sum_{i=1}^{n} (X_i - \mu)^2.$$

gdje je $\mu = EX$, jer sadrži nepoznato očekivanje μ slučajne varijable X.

U prošlom poglavlju smo već vidjeli u (6.49) i (6.50) da za uzoračku sredinu $\bar{X}_n$ vrijedi

$$E\bar{X}_n = \mu \quad \text{i} \quad Var(\bar{X}_n) = \frac{\sigma^2}{n}.$$

U poglavlju o opisnoj statistici smo vidjeli da za brojeve vrijedi relacija (2.5) (pogledajte Napomenu 2.3.3) pa na razini vrijednosti slučajnih varijabli vrijedi[3]

$$(n-1)S_n^2(\omega) = \sum_{i=1}^{n} X_i^2(\omega) - (\bar{X}_n(\omega))^2,\ \omega \in \Omega.$$

Na obje strane te jednakost djelujmo očekivanjem i iskoristimo linearnost očekivanja i jednaku razdiobu slučajnih varijabli X_i da dobijemo

$$(n-1)E(S_n^2) = E(\sum_{i=1}^{n} X_i^2) - nE(\bar{X}_n^2) = nE(X_1^2) - nE(\bar{X}_n^2). \tag{7.3}$$

Iz alternativne relacije za izračun vrijednosti varijance (6.14) slijedi

$$E(X^2) = \operatorname{Var}(X) + (EX)^2.$$

Uvrstimo te izraze u (7.3) i iskoristimo formule za izračun očekivanja i varijance uzoračke sredine da dobijemo

$$\begin{aligned}(n-1)E(S_n^2) &= n\operatorname{Var}(X_1) + n(EX_1)^2 - n\operatorname{Var}(\bar{X}_n^2) - n(E(\bar{X}_n^2))^2 \\ &= n\sigma^2 + n\mu^2 - n\frac{\sigma^2}{n} - n\mu^2 \\ &= (n-1)\sigma^2.\end{aligned}$$

Dakle, za uzoračku varijancu vrijedi

$$E[S_n^2] = \sigma^2. \tag{7.4}$$

Uzoračka sredina i varijanca su svakako među najvažnijim statistikama, a dodatni značaj im daje činjenica da se one često koriste za procjenu paramatara nekog statističkom modela. Naime, **metoda momenata** se zasniva na svojstvima uzoračkog očekivanja i varijance.

Da bi to vidjeli uzmimo općenitu situaciju koju smo ranije predstavili. Neka slučajna varijabla X opisuje neku slučajnu pojavu koju opisujemo. Uzmimo uzorak $X^n = (X_1, X_2, \ldots, X_n)$, $n \in \mathbb{N}$, koji je dobiven slučajnim odabirom iz populacije čija je razdioba opisana slučajnom varijablom X, odnosno njenom funkcijom gustoće $f(x \mid \theta)$, gdje θ označava nepoznati skup parametara koje želimo procjeniti. Neka $x^n = (x_1, x_2, \ldots, x_n)$ označava opaženi uzorak. Sjetimo se, to su realizacije slučajnog uzorka X^n, odnosno n nezavisnih realizacija slučajne varijable X.

Ako je θ jedan nepoznati parametar, onda se očekivanje cijele populacije, kaže se **populacijsko očekivanje**, može izračunati kao

$$\mu(\theta) = EX = \int_{-\infty}^{\infty} x f(x \mid \theta) dx, \tag{7.5}$$

ako je X neprekidna slučajna varijabla, odnosno kao

$$\mu(\theta) = EX = \sum_{x} x f(x \mid \theta) dx = \sum_{i=1}^{\infty} a_i p_X(a_i \mid \theta) \tag{7.6}$$

ako je X diskretna slučajna varijabla čija je razdioba

$$X \sim \begin{pmatrix} a_1 & a_2 & \ldots & a_n & \ldots \\ p_1 & p_2 & \ldots & p_n & \ldots \end{pmatrix},$$

[3] Zapravo to vrijedi za gotovo sigurno sve ω, a ne sve ω, ali smo naznačili ovisnost o ω da ukažemo na činjenicu da ovdje govorimo o funkcijskim vrijednostima. Dakle, brojevima.

pri čemu je $p_X(\cdot \mid \theta)$ razdioba od X za koju vrijedi $p_X(a_i \mid \theta) = P(X = a_i) = p_i$, $i = 1, 2, \ldots$ Dodatno izračunajmo vrijednost uzoračke sredine za realizacije $(x_1, x_2, \ldots, x_n)$ kao

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^{n} x_i \in \mathbb{R}.$$

Procjena parametra θ metodom momenata je rješenje jednadžbe

$$\mu(\theta) = \bar{x}_n. \tag{7.7}$$

Dobivena procjena se uobičajeno označava s $\hat{\theta}(\bar{x}_n)$, dok je **procjenitelj** za θ statistika $\hat{\theta}(\bar{X}_n)$. Uočimo razliku: $\hat{\theta}(\bar{x}_n)$ je broj, dok je $\hat{\theta}(\bar{X}_n)$ statistika, odnosno slučajna varijabla. Ako je iz konteksta jasno da li se radi o procjeni ili procjenitelju pišemo samo $\hat{\theta}$. Metoda momenata se zasniva na činjenici da su očekivanja uzoračke sredine, a onda i uzoračke varijance (promatrane kao statistike, odnosno slučajne varijable), jednake očekivanju, odnosno varijanci slučajnih varijabli koje čine uzorak. Pogledajmo primjere.

Primjer 7.1.4 (Procjena parametra λ eksponencijalne slučajne varijable)**.** Pretpostavimo da se neko svojstvo populacije može opisati eksponencijalnom slučajnom varijablom X s parametrom λ. U tom slučaju znamo da je $EX = 1/\lambda$.
Neka je sada $X^n = (X_1, X_2, \ldots, X_n)$ slučajni uzorak iz eksponencijalne razdiobe s parametrom λ. To znači da su slučajne varijable X_i nezavisne te im je svima razdioba $Exp(\lambda)$. Parametar koji želimo procjeniti je $\theta = \lambda$. U skladu s prethodnim razmatranjem, želimo riješiti jednadžbu u kojoj izjednačavamo populacijsko očekivanje EX i uzoračku sredinu $\bar{X}_n$ (uočite da sada tražimo procjenitelj, a ne procjenu). Tako dobijemo jednadžbu

$$EX = \frac{1}{\lambda} = \bar{X}_n.$$

Rješenje te jednadžbe je jednostavno pa dobijemo procjenitelj parametra λ

$$\hat{\lambda}(X^n) = \frac{1}{\bar{X}_n} = \frac{1}{\frac{1}{n}\sum_{i=1}^{n} X_i}.$$

Naravno, ako je $(x_1, x_2, \ldots, x_n)$ realizacija uzorka X^n, dakle, opaženi uzorak, onda je procjena parametra λ

$$\hat{\lambda}(x^n) = \frac{1}{\frac{1}{n}\sum_{i=1}^{n} x_i}.$$

□

Primjer 7.1.5 (Procjena parametra p Bernoullijeve slučajne varijable s parametrom p)**.** Neka se sada populacija može opisati Bernoullijevom slučajnom varijablom X s parametrom p. U tom slučaju je $EX = p$. Znamo da je X je diskretna slučajna varijabla koja poprima vrijednosti 1 ili 0 s vjerojatnostima p i $q = 1 - p$.
Uzmimo $X^n = (X_1, X_2, \ldots, X_n)$ slučajni uzorak iz Bernoullijeve razdiobe s parametrom p. Kao i prije, slučajne varijable X_i nezavisne te su sve Bernoullijeve slučajne varijable s parametrom p. Parametar koji želimo procjeniti je $\theta = p$. Opet želimo riješiti jednadžbu u kojoj izjednačavamo populacijsko očekivanje EX i uzoračku sredinu $\bar{X}_n$. Tako dobijemo jednadžbu

$$EX = p = \bar{X}_n.$$

Rješenje te jednadžbe je trivijalno pa dobijemo procjenitelj parametra p

$$\hat{p}(X^n) = \bar{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i.$$

Ako je $(x_1, x_2, \ldots, x_n)$ opaženi uzorak, onda je procjena parametra p

$$\hat{p}(x^n) = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Primjetimo da je zbog interpretacije binomne slučajne varijable kao zbroja nezavisnih Bernoullijevih slučajnih varijabli ovakva procjena primijenjiva i za binimnu slučajnu varijablu. □

Prvo sljedeće pitanje koji se možemo postaviti, a vezano uz procjenu parametara metodom momenata, je "što napraviti ako se θ sastoji od više elemenata"? Nećemo ulaziti u općeniti postupak, iako se on može naslutiti, ali pokažimo što napraviti kada je $\theta = (\theta_1, \theta_2)$, odnosno kada je θ dvodimenzionalan. U tom slučaju izjednačavamo prva dva populacijska momenta (EX i EX^2) s pripadnim uzoračkim momentima, pri čemu se nekada umjesto EX^2 gleda $\mathrm{Var}\,(X)$. Na taj način dobivamo sustav dvije jednadžbe s dvije nepoznanice

$$\mu(\theta_1, \theta_2) = \bar{x}_n \quad \text{i}$$
$$\sigma^2(\theta_1, \theta_2) = \mathrm{Var}\,(X) = s_n^2,$$

pri čemu je $\sigma^2(\theta_1, \theta_2)$ populacijska varijanca, a s_n^2 opažena uzoračka varijanca. Naravno, umjesto opaženog uzorka možemo raditi s uzorkom pa, kao i prije, umjesto procjene dobivamo procjenitelj. Pogledajmo vrlo jednostavan, a važan primjer.

Primjer 7.1.6 (Procjena parametara μ i σ^2 normalne slučajne varijable $N(\mu, \sigma^2)$)**.** Neka je sada $X \sim N(\mu, \sigma^2)$. U tom slučaju je $\theta = (\mu_1, \sigma^2)$.
Kako je $EX = \mu$, a $\mathrm{Var}\,(X) = \sigma^2$ jednostavno slijedi da je

$$\hat{\mu} = \bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i \qquad \hat{\sigma}^2 = S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2.$$

Dakle, parametre normalne razdiobe procjenjujemo procjeniteljima (statistikama) $\bar{X}_n$ i S_n^2. □

Općenita metoda za procjenu parametara je metoda najveće vjerodostjojnosti (eng. *maximal likelihood*). Ona je analitički nešto zahtjevnija (uključuje u općenitom slučaju parcijalne derivacije) pa je ovdje ne predstavljamo. Zainteresirani čitatelj može pogledati poglavlje 9 u [15].

Također, postoje još neka razmatranja vezana uz procjenitelje (zainteresirani čitatelj može za jednostavan i lako razumljiv pregled pogledati raspravu iza Primjera 5.2. u [1]). Jedno od svojstava procjenitelja je njegova nepristranost. Kaže se da je procjenitelj $\hat{\theta}(X^n)$ **nepristran** ako za njega vrijedi

$$E(\hat{\theta}(X^n)) = \theta. \tag{7.8}$$

Opet su dva najpoznatija primjera nepristranih procjenitelja uzoračka sredina i uzoračka varijanca, a razlog za faktor $1/(n-1)$, umjesto grafički logičnijeg $1/n$ je upravo želja da se dobije nepristrani procjenitelj varijance.

Iako je nepristranost procjenitelja dobro svojstvo još je važnije da procjenitelj ima malu **srednjekvadratnu grešku**, skraćeno MSE (eng. *mean square error*). Srednjekvadratna greška procjenitelja $\hat{\theta}(X^n)$ za parametar θ definira se kao

$$MSE(\hat{\theta}(X^n)) = E(\hat{\theta}(X^n) - \theta)^2. \tag{7.9}$$

Ukoliko je $\hat{\theta}(X^n)$ nepristrani procjenitelj za θ, onda je $MSE(\hat{\theta}) = Var(\hat{\theta})$. U suprotnome možemo definirati **pristranost** (eng. *bias*) kao

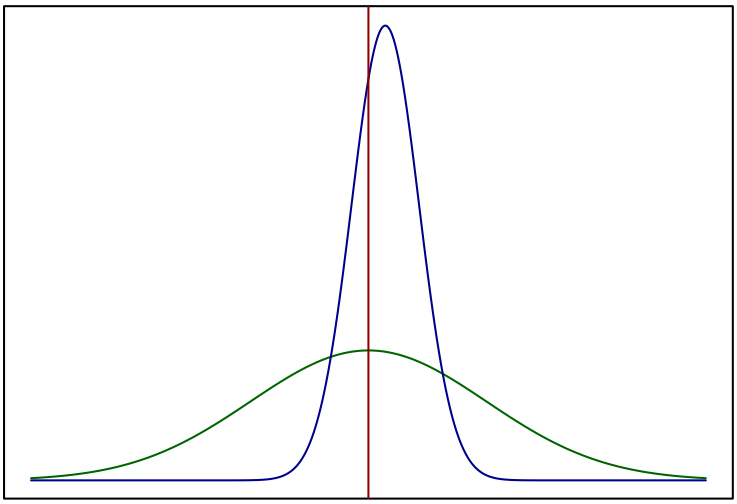
$$b(\hat{\theta}) := E(\hat{\theta}(X^n)) - \theta, \tag{7.10}$$

a onda je

$$MSE(\hat{\theta}(X^n)) = Var(\hat{\theta}) + b(\hat{\theta})^2. \tag{7.11}$$

Dakle, kod kvalitete procjenitelja može biti važna nepristranost, ali isto tako može prevagnuti i manja varijanca u korist nekog procjenitelja. To je ilustrirano na donjoj slici na kojoj su prikazane distribucije dva procjenitelja - jedan je s velikom varijancom, ali je nepristran (zelena linija), a drugi je s malom varijancom, ali je pristran (plava linija). Ukupna srednjekvadratna greška je manja za pristrani procjenitelj (ovo je samo ilustrativni primjer). Procjenjuje se parametar μ koji je prikazan okomitom crvenom linijom.

Usporedba distribucije dva procjenitelja



Kaže se da je procjenitelj **konzistentan** ukoliko $MSE(\hat{\theta}(X^n)) \to 0$, za $n \to \infty$. To zapravo znači, prema (7.11), da s porastom veličine uzorka n i pristranost (bias) i varijanca procjenitelja teže prema nuli. Na ovom mjestu nećemo dublje ulaziti u analizu pojma konzistentnosti procjenitelja.

7.1.3 Svojstva $\bar{X}_n$ i S_n^2 za uzorke iz normalne razdiobe

Pretpostavimo da je $X_1, X_2, \dots X_n$, $n \in \mathbb{N}$, uzorak iz normalne razdiobe $N(\mu, \sigma^2)$. Tada su $\bar{X}_n$ i S_n^2 nezavisne slučajne varijable (Teorem 11.10. u [10]). Može se pokazati da su $\bar{X}_n$ i S_n^2 nezavisni samo za uzorke iz normalne slučajne varijable.

Dodatno, znamo da je $\bar{X}_n \sim N(\mu, \sigma^2/n)$ (sjetimo se da je zbroj nezavisnih jednako distribuiranih normalnih slučajnih varijabli opet iz normalne razdiobe). U prošlom poglavlju smo vidjeli da za uzorak iz neke razdiobe s konačnom varijancom niz slučajnih varijabli

$$Z_n = \frac{\bar{X}_n - E\bar{X}_n}{\sqrt{Var(\bar{X}_n)}} = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma}$$

konvergira po distribuciji prema jediničnoj normalnoj slučajnoj varijabli $Z \sim N(0,1)$ za $n \to \infty$ (Teorem 6.2.11). Uočimo da su za uzorak $X_1, X_2, \dots X_n$ iz normalne razdiobe

$N(\mu, \sigma^2)$ već same slučajne varijable Z_n, $n \in \mathbb{N}$, iz jedinične normalne razdiobe, odnosno

$$Z_n = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma} \sim N(0,1).$$

Donekle slična relacija vrijedi i za uzoračku varijancu (Teorem 11.11. iz [10])

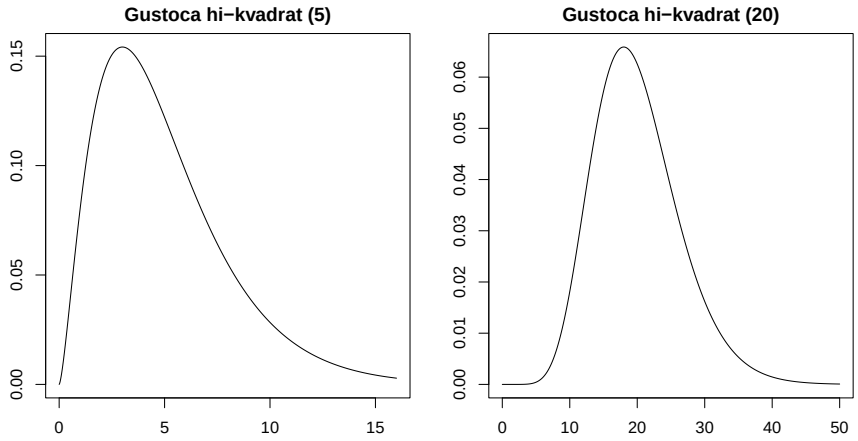
$$\frac{(n-1)S_n^2}{\sigma^2} \sim \chi^2(n-1) \tag{7.12}$$

gdje je χ^2_{n-1} oznaka za razdiobu hi-kvadrat s $n-1$ stupnjeva slobode. Njena funkcija distribucije je relativno kompliciran (uključuje Γ-funkciju koja je poopćenje faktorijela). S druge strane, ako su $Z_1, Z_2, \ldots, Z_n \sim N(0,1)$ nezavisne slučajne varijable, $n \in \mathbb{N}$, onda je G,

$$G = Z_1^2 + Z_2^2 + \ldots + Z_n^2,$$

slučajna varijabla čija je distribucija hi-kvadrat s n stupnjeva slobode, u oznaci $G \sim \chi^2_n$.

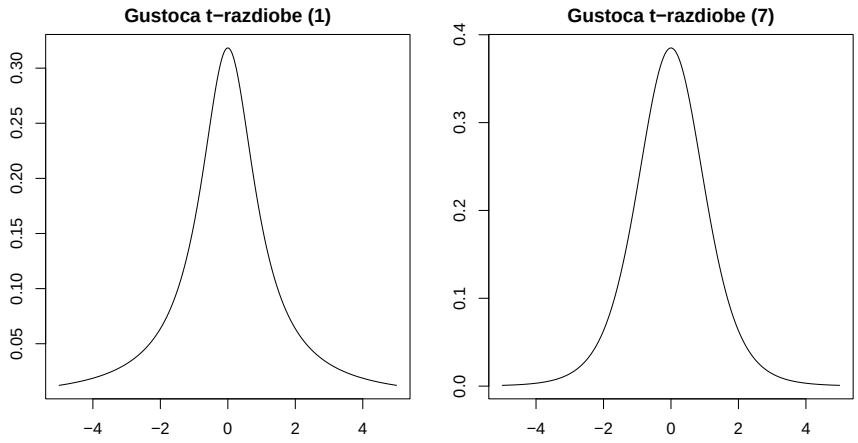
Ukoliko imamo dvije nezavisne slučajne varijable G_1 i G_2 takve da je $G_1 \sim \chi^2_n$ i $G_2 \sim \chi^2_m$, $n, m \in \mathbb{N}$, onda je $G_1 + G_2 \sim \chi^2_{n+m}$. Za $G \sim \chi^2_n$ vrijedi $EG = n$ i $Var(G) = 2n$. Vidimo da s rastom n očekivanje hi-kvadrat slučajne varijable brzo raste, kao i varijanca. Uočimo, kao zbroj pozitivnih slučajnih varijabli, slučajna varijabla G nema negativnih vrijednosti. Na donjim grafovima su iscrtane gustoće slučajnih varijabli s distribucijama $\chi^2(5)$ i $\chi^2(20)$. Za izračun vrijednosti gustoća koristimo R-ovu funkciju `dchisq()`.



Uz razdiobu χ^2 je usko vezana još jedna razdioba koja je važna u statistici: t-razdioba (ili t-distribucija ili Studentova t-distribucija). Ukoliko su Z i G_n nezavisne slučajne varijable takve da je $Z \sim N(0,1)$ i $G_n \sim \chi^2_n$ definiramo novu slučajnu varijablu T_n kao

$$T_n = \frac{Z}{\sqrt{G_n/n}}. \tag{7.13}$$

Tada slučajna varijabla T_n ima t-razdiobu s n stupnjeva slobode. Za razliku od razdiobe χ^2, t-distribucija je simetrična (poput normalne razdiobe). Dapače, za velike n će T_n biti približno distribuirana poput $Z \sim N(0,1)$. Ipak, repovi t-distribucije (vjerojatnosti $P(T_n > x)$ ili $P(T_n < -x)$, za neke pozitivne vrijednosti x) su nešto veći od repova normalne distribucije. U vjerojatnosti se kaže da t-razdioba ima teže repove (eng. *heavy tails*) od normalne razdiobe. Te razlike nisu lagano vidljive golim okom (s grafa). Ipak, za ilustraciju, na donjim grafovima dajemo primjere t-razdiobe



Radi potpunosti navodimo da je $E(T_n) = 0$, za $n > 1$ i $Var(T_n) = n/(n-2)$, za $n > 2$.

Značaj t-razdiobe u statistici zasniva se na njenom korištenju o zaključivanju o parametru μ slučajne varijable X (odnosno cijele populacije). Kao što smo već rekli, ukoliko promatramo standardiziranu verziju uzoračke sredine

$$Z_n = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma}$$

onda je $Z_n \sim N(0,1)$ za uzorke iz normalne distribucije, odnosno konvergira prema jediničnoj normalnoj varijabli prema centralnom granuičnom teoremu. Ukoliko vrijednost od σ nije poznata, što je čest slučaj, onda se gleda studentizirana verzija slučajne varijable Z, odnosno gleda se

$$T_n = \sqrt{n}\frac{\bar{X}_n - \mu}{S_n}, \tag{7.14}$$

gdje je $S_n = \sqrt{S_n^2}$ uzoračka standardna devijacija. Ukoliko je uzorak $X_1, X_2, \ldots X_n$ iz normalne distribucije $N(\mu, \sigma^2)$, onda je $T_n \sim t(n-1)$ (Teorem 11.14. u [10]). Uočimo da to znači da razdioba od T_n ne ovisi o vrijednostima parametara μ i σ (uz pretpostavku $0 < \sigma < \infty$).

Ukoliko uzorak nije iz normalne razdiobe to općenito ne vrijedi, ali iz centralnog graničnog teorema[4] slijedi da niz slučajnih varijabli T_n definiranih u (7.14) konvergira po distribuciji prema jediničnoj normalnoj razdiobi, odnosno

$$\lim_{n\to\infty} F_{T_n}(x) = \Phi(x) = \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{x} e^{-t^2/2}dt, \ x \in \mathbb{R}.$$

Gornja razmatranja, vezana uz χ^2 i t-razdiobu, ne radimo radi uvođenja novih razdioba, nego zato što one imaju ulogu u statistici, konkretno u testiranju statističkih hipoteza. Ugrubo, radi se o tome da se odrede neki kvantili vezani uz te razdiobe te ih se iskoristi za određeno zaključivanje.

7.1.4 Empirijske funkcije distribucije

Jedan od važijih rezultata u statistici govori o tome da se funkcije distribucije mogu aproksimirati empirijskim funkcijama distribucije zasnovanima na uzorku iz dane razdiobe. Preciznije, neka je $X_1, X_2, \ldots X_n$ uzorak iz razdiobe čija je funkcija distribucije F (dakle, $X_1, X_2, \ldots X_n$ su nezavisne slučajne varijable pri čemu sve imaju istu funkciju distribucije F). Tada definiramo **empirijsku funkciju distribucije** F_n kao

$$F_n(x) = \frac{1}{n}\sum_{i=1}^{n} I_{\{X_i \le x\}} = \frac{\text{broj } X_i\text{-jeva koji su} \le x}{n}, \quad x \in \mathbb{R}. \tag{7.15}$$

[4] Treba iskoristiti i slabi zakon velikih brojeva da se pokaže da S_n^2 konvergira po vjerojatnosti prema σ^2, a onda zapravo iz teorema Slutskog slijedi taj rezultat.

Uočite da je empirijska funkcije distribucije zapravo slučajna varijabla jer je funkcija slučajnih varijabli $X_1, \ldots, X_n$, odnosno indikatora tih slučajnih varijabli. Podsjetimo se

$$I_{\{X_i \leq x\}} \sim \begin{pmatrix} 0 & 1 \\ 1 - F(x) & F(x) \end{pmatrix}.$$

Jer su $X_1, \ldots, X_n$ nezavisne odmah slijedi (zbroj nezavisnih Bernoullijevih je binomna slučajna varijable) da je $nF_n(x) \sim B(n, F(x))$, za $x \in \mathbb{R}$, a onda zbog zakona velikih brojeva slijedi da je za sve $\epsilon > 0$

$$\lim_{n\to\infty} P(|F_n(x) - F(x)| > \epsilon) = 0,$$

odnosno $\lim_{n\to\infty} F_n(x) = F(x)$ gotovo sigurno. U svakom slučaju, za realne brojeve x je vrijednost empirijske funkcije F_n vrlo bliska vrijednosti funkcije distribucije $F(x)$, odnosno

$$F_n(x) \approx F(x).$$

Kako je empirijska funkcija distribucije slučajna varijabla, ona ima svoje očekivanje. Zbog linearnosti očekivanja lagano se vidi da je

$$E(F_n(x)) = F(x).$$

Zbog nezavisnosti $X_1, \ldots, X_n$, a onda i $I_{\{X_1 \leq x\}}, \ldots, I_{\{X_n \leq x\}}$, dobijemo

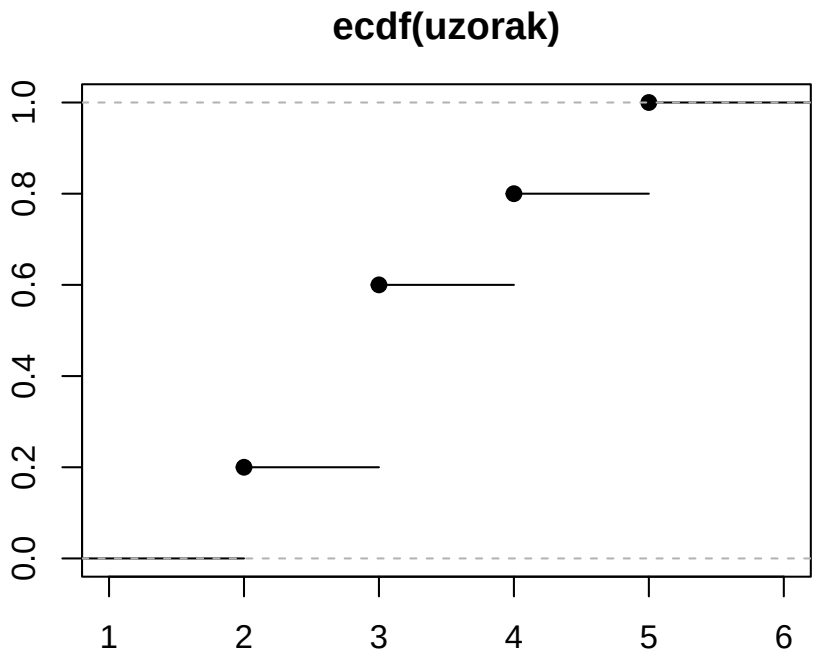
$$Var(F_n(x)) = F(x)(1 - F(x))/n.$$

Aproksimacija funkcije distribucije empirijskom funkcijom distribucije spada među neparametarske statističke metode jer ne pretpostavljamo da polazna razdioba, odnosno uzorak iz te razdiobe, ima konačan skup paramatara koji je određuje. Pogledajmo primjer konstrukcije empirijskih funkcija distribucije.

Primjer 7.1.7. Pretpostavimo da imamo neku slučajnu pojavu (recimo da ju modeliramo slučajnom varijablom X) i da nam je dan uzorak duljine 5. To znači da su nam dane vrijednosti, odnosno realizacije nezavisnih slučajnih varijabli X_1, X_2, X_3, X_4 i X_5 pri čemu su sve distribuirane kao i slučajna varijabla X. U naravi su realizacije tih slučajnih varijabli brojevi. Pretpostavimo da su dobiveni brojevi $3, 2, 5, 4, 3$. Izračunajmo empirijsku funkciju distribucije, na osnovu danog uzorka, u točki π.
Za početak sortirajmo realizacije uzorka koji smo dobili: $2, 3, 3, 4, 5$. Empirijska funkcije distribucije u točki π se računa kao

$$\frac{1}{5}(I_{\{2\leq\pi\}} + I_{\{3\leq\pi\}} + I_{\{3\leq\pi\}} + I_{\{4\leq\pi\}} + I_{\{5\leq\pi\}}) = \frac{1}{5}(1 + 1 + 1 + 0 + 0) = \frac{3}{5}.$$

Ovo je jednostavan primjer s malim uzorkom, ali iz prijašnjih razmatranja znamo da je dobivena vrijednost $F_5(\pi) = 3/5$ približno jednaka stvarnoj (uzoračkoj) distribuciji, odnosno funkciji distribucije u točki π: $F(\pi) = F_X(\pi)$. Sjetimo se da je funkcija distribucije vrlo korisna jer omogućava izračun praktički svih vjerojatnosti vezanih uz slučajnu varijablu (koja opisuje neku slučajnu pojavu). Naravno, kao što smo izračunali funkciju distribucije u točki π možemo je izračunati i za druge realne brojeve x. Na donjoj slici prikazujemo dobivenu empirijsku funkciju distribucije za zadani uzorak.



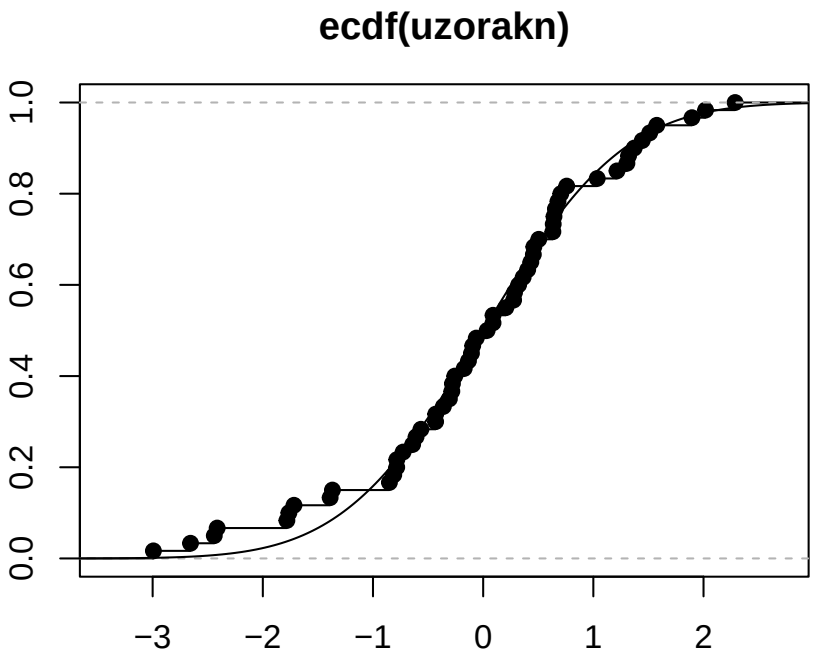
Pretpostavimo sada da imamo malo drugačiju situaciju: dobili smo uzorak od 60 brojeva

```
> options(width=75)
> set.seed(42)
> uzorakn<-rnorm(60)
> uzorakn

 [1]  1.37095845 -0.56469817  0.36312841  0.63286260  0.40426832
 [6] -0.10612452  1.51152200 -0.09465904  2.01842371 -0.06271410
[11]  1.30486965  2.28664539 -1.38886070 -0.27878877 -0.13332134
[16]  0.63595040 -0.28425292 -2.65645542 -2.44046693  1.32011335
[21] -0.30663859 -1.78130843 -0.17191736  1.21467470  1.89519346
[26] -0.43046913 -0.25726938 -1.76316309  0.46009735 -0.63999488
[31]  0.45545012  0.70483734  1.03510352 -0.60892638  0.50495512
[36] -1.71700868 -0.78445901 -0.85090759 -2.41420765  0.03612261
[41]  0.20599860 -0.36105730  0.75816324 -0.72670483 -1.36828104
[46]  0.43281803 -0.81139318  1.44410126 -0.43144620  0.65564788
[51]  0.32192527 -0.78383894  1.57572752  0.64289931  0.08976065
[56]  0.27655075  0.67928882  0.08983289 -2.99309008  0.28488295
```

Taj smo uzorak generirali iz jedinične normalne razdiobe $N(0,1)$. Pretpostavimo da to ne znamo, ali imamo razloga za vjerovati da je uzorak dobiven iz normalne razdiobe. Želimo usporediti empirijsku funkciju distribucije koju računamo iz uzorka (u R-u) i funkcije distribucije normalno distribuirane slučajne varijable. Dobivamo

```
> par( mar=c(2,2,3,2))
> plot(ecdf(uzorakn), xlab="")
> x.values = seq(-4,4, length = 1000)
> y.values = pnorm(x.values, 0,1)
> lines(x.values, y.values)
```



Vidimo da empirijska funkcija distribucije dobro aproksimira funkciju distribucije jedninične normalne razdiobe. Čak i ako pretpostavimo (ispravno) da je uzorak koji smo dobili iz normalne razdiobe postavlja se pitanje koje je očekivanje i varijanca tog uzorka. Kao što smo vidjeli, očekivanje možemo procijeniti uzoračkom sredinom, a varijancu uzoračkom varijancom. Ima još dosta pitanja koja se vežu uz procjenu parametara ili izgled distribucije, a na neka se može odgovoriti u okviru testiranja hipoteza. □

7.2 Testiranje statističkih hipoteza

Testiranje statističkih hipoteza je veliko područje koje uključuje i parametarske i neparametarske modele. Mi ćemo pogledati neke osnovne primjere parametarskih statističkih testova.

Statistička hipoteza je u osnovi neka tvrdnja (pretpostavka) o parametrima θ distribucije neke populacije. Testiranje statističkih hipoteza podrazumijeva formuliranje procedure koja će nam omogućiti da utvrdimo da li je neka pretpostavka o parametrima distribucije podataka konzistentna s uzorkom podataka ili nije. Ukoliko se utvrdi da je hipoteza koju smo postavili konzistentna s podacima (uzorkom), onda se kaže da se hipoteza prihvaća, a u suprotnom se odbacuje.

Formalno, pretpostavimo da je X neka slučajna varijabla i θ neki parametar[5] njene distribucije $f(x \mid \theta)$, pri čemu se vrijednosti parametra θ nalaze u prostoru parametara Θ. U ovisnosti o vrijednosti parametra θ se prostor parametara Θ može podijeliti na dva disjunktna skupa Θ_0 i Θ_1 čija je unija Θ. Ono što želimo testirati statističkim testovima je da li vrijedi hipoteza

$$H_0 : \theta \in \Theta_0 \tag{7.16}$$

u odnosu na

$$H_1 : \theta \in \Theta_1 \tag{7.17}$$

Hipoteza H_0 se zove **nul hipoteza**, a H_1 textbfalternativna hipoteza ili aterantivne hipoteze.

[5]Može biti i više parametara, ali ovdje gledamo samo jednostavne hipoteze koje se odnose na jedan parametar.

Odluka o prihvaćanju, odnosno odbacivanju, nul hipoteze (u korist alternativne hipoteze) zasnovana ja na uzorku $X_1, \ldots, X_n$ iz distribucije $f(\cdot \mid \theta)$, odnosno na vrijednostima neke statistike T danog uzorka. Da bi se donijela željena odluka potrebno je naći skup C u kojem će se nalaziti vrijednosti statistike T da bi se odbacila hipoteza H_0. Ukoliko se vrijednosti statistike nalaze van skupa C onda se hipoteza H_0 ne odbacuje (smatra se važećom). Statistika T se zove **testna statistika**, a područje C **kritično područje**. Vrlo često će kritično područje biti oblika

$$C = \{x \mid T(x) > c\}.$$

Broj c se zove **kritična vrijednost** testa. Da bi se testirala hipoteza H_0 potrebno je naći odgovarajuću testnu statistiku te odrediti kritičnu vrijednost testa. Ukoliko se hipoteza koju ispitujemo odnosi na očekivanje neke populacije (dakle, $\theta = \mu$), prirodno ćemo probati iskoristiti neku statistiku koja će sadržavati uzoračku sredinu $\bar{X}_n$.

Prilikom provođenja postupka testiranja hipoteza možemo doći do ispravnog odgovora (prihvatiti hipotezu H_0 kada je ona istinita ili prihvatiti alternativnu hipotezu H_1 kada je ona istinita) ili napraviti dva tipa pogreške: odbaciti hipotezu H_0 kada je ona istinita, što se naziva **pogreškom prve vrste** ili prihvatiti hipotezu H_0 kada je istinita hipoteza H_1, što se naziva **pogreškom druge vrste**. Shematski možemo prikazati mogućnosti prihvaćanja ili odbacivanja hipoteza kao u Tablici 7.1. Uočite da odluke koje su navedene u recima tablice donosimo na osnovi dostupnih podataka.

	H_0 istinita	H_1 istinita
H_0 odbačena	Greška I vrste	Ispravna odluka
H_0 prihvaćena	Ispravna odluka	Greška II vrste

Tablica 7.1: Mogućnosti prilikom testiranja hipoteza

Važno je uočiti sljedeće: statistika, pa i statistički testovi su zasnovani na vjerojatnosti. Stoga je primjereno zaključivati u terminima vjerojatnosti. Očito je poželjno da se pogreške prve i druge vrste ograniče nekim malim brojem, odnosno da je njihova vjerojatnost mala. To je načelno lagano napraviti jer je za test koji uvijek prihvaća hipotezu H_0 (nikada je ne odbacuje) $\alpha = 0$. Bilo bi idealno kada bi mogli imati test s proizvoljno malim greškama i prve i druge vrste, ali to nije moguće. Stoga je prilikom testiranja hipoteza uobičajeno odabrati broj $\alpha \in (0, 1)$, koji će tipično biti neki mali broj poput $0,05$ ili $0,01$ (odnosno 5% ili 1%), i onda tražiti test kojemu će pogreška prve vrste biti manja ili jednaka od α. Taj broj α se naziva **razina značajnosti testa**. Vjerojatnost prihvaćanja nul hipoteze ukoliko ona nije istinita (pogreška druge vrste) se obično označava s β. Malo formalnije zapisano je vjerojatnost pogreške prve vrste

$$\alpha = P_\theta(\text{odbacujemo} H_0), \quad \text{a} \quad \theta \in \Theta_0, \tag{7.18}$$

dok je vjerojatnost pogreške druge vrste

$$\beta = P_\theta(\text{odbacujemo} H_1), \quad \text{a} \quad \theta \in \Theta_1. \tag{7.19}$$

S P_θ smo označili vjerojatnost koja proizlazi iz činjenice da je θ iz Θ_0 ili Θ_1, a određena je s $f(x \mid \theta)$.

Postupak testiranja statističkih hipoteza sažeto možemo prikazati kao

1) Odredimo nul hipotezu H_0 i alternativnu hipotezu H_1,

2) Odredimo željenu razinu značajnosti testa $\alpha \in (0, 1)$ (tipično mali broj poput $0,05$),

3) Odaberemo testnu statistiku T,

4) Odredimo kritično područje testa C_α za koje vrijedi $P_\theta(T \in C_\alpha) \leq \alpha$, $\theta \in \Theta_0$,

5) Izračunamo vrijednost statistike T za podatke koji su nam dostupni (opaženi uzorak) da dobijemo broj t

6) Ukoliko je $t \in C_\alpha$ odbacujemo H_0

7) Ukoliko $t \notin C_\alpha$ ne odbacujemo H_0

8) U terminima kritičnog područja je $\alpha = P_\theta(T \in C_\alpha)$, za $\theta \in \Theta_0$ i $\beta = P_\theta(T \notin C_\alpha)$, za $\theta \in \Theta_1$.

Napomenimo da se prilikom formuliranja hipoteza koje ćemo testirati u prinicipu u okviru alternativne hipoteze formulira hipoteza čiju valjanost želimo utvrditi podacima koji su nam dostupni. Ako podaci ne potvrđuju nul hipotezu prihvatit ćemo alternativnu hipotezu, a u suprotnom nećemo moći odbaciti nul hipotezu. Nul hipoteza ostaje valjana dok (i ako) podaci o slučajnom eksperimentu koji promatramo ne opovrgnu njenu istinitost. Pogledajmo kako izgleda postupak testiranja hipoteza na jednom primjeru.

7.2.1 Očekivanje uzorka iz normalne distribucije s poznatom varijancom

Pretpostavimo da imamo uzorak $X_1, X_2, \ldots X_n$ iz normalne razdiobe pri čemu je poznata varijanca uzorka σ^2 i nepoznato očekivanje μ. U skladu s prijašnjim oznakama je $\theta = \mu$ u ovom slučaju.

Pretpostavimo da želimo testirati hipotezu da je $\mu = \mu_0$, gdje je μ_0 neki konkretan broj (na primjer 5). Želimo provjeriti da li nam podaci (koji su dani uzrokom $X_1, X_2, \ldots X_n$) potvrđuju tu pretpostavku. U skladu s prije uvednom terminologijom nam je nul hipoteza

$$H_0 : \mu = \mu_0,$$

dok kao alternativnu hipotezu (skup alternativnih hipoteza) u ovom slučaju uzimamo

$$H_1 : \mu \neq \mu_0.$$

Uzmimo $\alpha = 0,05$ kao razinu značajnosti testa.

Sljedeći korak u testiranju hipoteza je odabir testne statistike (dakle, funkciju uzorka) kojom ćemo testirati valjanost nul hipoteze. U ovom slučaju je dosta jasno da je dobro početi sa uzoračkom sredinom $\bar{X}_n$ jer znamo da je ona dosta blizu očekivanja μ.[6] Ukoliko se pretpostavi da vrijedi nul hipoteza, to zapravo znači da je uzoračka sredina $\bar{X}_n$ blizu broja μ_0 jer je pod pretpostavkom da vrijedi nul hipoteza $\mu = \mu_0$.

Kao što smo vidjeli, primarni cilj prilikom testiranja hipoteza je ne odbaciti nul hipotezu ukoliko je ona istinita. Alat kojim to postižemo je statistika, u ovom slučaju uzoračka sredina, te ne želimo da je vjerojatnost da je uzoračka statistika "previše" udaljena od μ_0, ukoliko vrijedi nul hipoteza. Konkretno, želimo da vrijedi

$$P_{\mu_0}(|\bar{X}_n - \mu_0| > c) = \alpha. \tag{7.20}$$

Vrijednost c je kritična vrijednost (za statistiku $\bar{X}_n$ u ovom slučaju). U gornjoj jednakost istaknuli činjenicu da gledamo vjerojatnost P_{μ_0} koja vrijedi ako je istinita nul hipoteza, odnosno dako je nepoznati parametar $\mu = \mu_0$.

[6] I u smislu očekivanja i u smislu konvergencije po zakonu velikih brojeva.

Uočimo još jednu činjenicu: ukoliko je neki $c' > c$, onda je $\{\omega : |\bar{X}_n - \mu_0| > c'\} \subset \{\omega : |\bar{X}_n - \mu_0| > c\}$ pa je

$$P_{H_0}(|\bar{X}_n - \mu_0| > c') \leq P_{H_0}(|\bar{X}_n - \mu_0| > c) = \alpha.$$

Stoga je vjerojatnost odbacivanja nul hipoteze ukoliko je ona istinita (dakle, greška tipa I) manja ili jednaka od razine značajnosti α za sve $c' > c$. Kao što smo rekli, takvo područje (vrijednosti c') je kritično područje. U tom području je vjerojatnost odbacivanja nul hipoteze uz pretpostavku njene istinitosti manja od α.

Sjetimo se da ukoliko definiramo slučajnu varijablu Z (koja ovisi o danom uzorku)

$$Z = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma},$$

možemo zaključiti da je $Z \sim N(0,1)$ jer smo pretpostavili da je cijeli uzorak iz normalne razdiobe $N(\mu, \sigma^2)$. Stoga se jednakost u (7.20) može zapisati u ekvivalentnom obliku

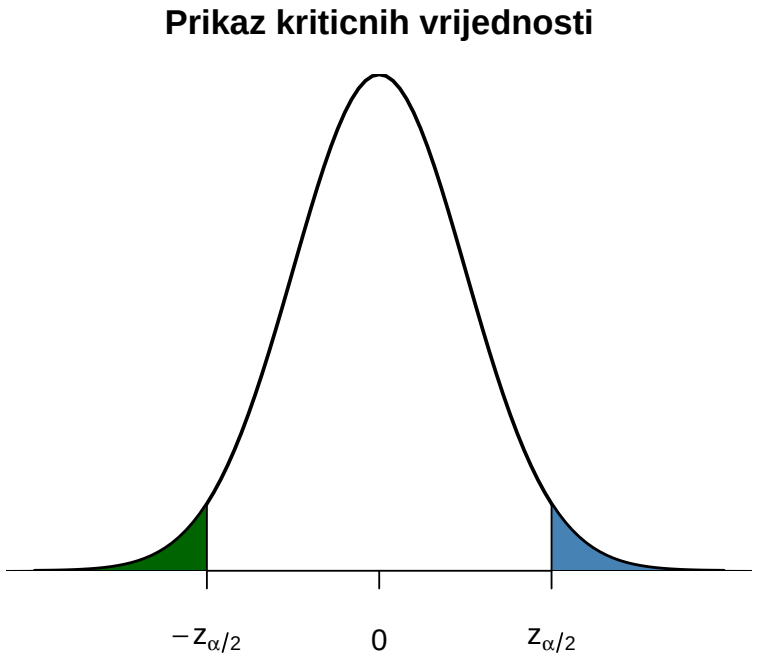
$$P\Big(|Z| > \frac{c\sqrt{n}}{\sigma}\Big) = \alpha. \tag{7.21}$$

Kako je funkcija gustoće od Z simetrična, relacija (7.21) se može zapisati kao

$$2P\Big(Z > \frac{c\sqrt{n}}{\sigma}\Big) = \alpha. \tag{7.22}$$

Sada smo u situaciji u kojoj se zapravo pitamo koja je to kritična vrijednost $z_{\alpha/2}$ (uobičajena oznaka u statistici) takva da je $P(Z > z_{\alpha/2}) = 1 - \Phi(z_{\alpha/2}) = \alpha/2$. Grafički to možemo prikazati kao

```
> par( mar=c(3,2,3,2))
> curve(dnorm(x),
+       xlim = c(-4, 4), main = 'Prikaz kritičnih vrijednosti',
+       yaxs = 'i', xlab = 'z', ylab = '', lwd = 2, axes = 'F')
> axis(1,  at = c(-2, 0, 2), padj = 0.75,
+      labels = c( expression(-z[alpha/2]),
+                  0,
+                  quote(z[alpha/2])))
> polygon(x = c(-6, seq(-6, -2, 0.01), -2),
+         y = c(0, dnorm(seq(-6, -2, 0.01)),0),
+         col = 'darkgreen')
> polygon(x = c(2, seq(2, 6, 0.01), 6),
+         y = c(0, dnorm(seq(2, 6, 0.01)), 0),
+         col = 'steelblue')
```



Nadamo se da je jasno da je na gornjem grafu plavom bojom prikazana površina ispod funkcije gustoće standardne normalne razdiobe za realne brojeve $x > z_{\alpha/2}$, a to je upravo $1 - \Phi(z_{\alpha/2})$. Zelenom bojom je prikazana površina ispod funkcije gustoće standardne normalne distribucije za realne brojeve $x < -z_{\alpha/2}$, a to je $\Phi(-z_{\alpha/2})$. Ako je problem postavljen kako smo ga opisali, onda zapravo želimo da je zbroj te dvije površine jednak α. Ujedno su ta dva područja (zeleno i plavo) kritična područja za test koji promatramo. Ukoliko će vrijednosti od Z (koja ovisi o uzorku preko $\bar{X}_n$) biti u tom području odbacit ćemo nul hipotezu, a u suprotnom slučaju to nećemo napraviti.

Kako znamo izračunati $z_{\alpha/2}$ (bilo iz tablica ili u R-u ili na neki drugi način) dobijemo da je originalno tražena kritična vrijednost c jednaka

$$c = \frac{\sigma z_{\alpha/2}}{\sqrt{n}}.$$

Uz zadanu razinu značajnosti α na taj način smo dobili test koji odbacuje nul hipotezu ukoliko je $|\bar{X}_n - \mu_0| > \sigma z_{\alpha/2}/\sqrt{n}$, a prihvaća je u suprotnom slučaju. Drugačije napisano, nul hipoteza H_0 se odbacuje ako je

$$\frac{\sqrt{n}}{\sigma}|\bar{X}_n - \mu_0| > z_{\alpha/2},$$

a prihvaća se ako je

$$\frac{\sqrt{n}}{\sigma}|\bar{X}_n - \mu_0| \leq z_{\alpha/2}.$$

Pogledajmo jedan numerički primjer koji zapravo pokazuje da je ovdje riječ o jednostavnom testu.

Primjer 7.2.1. Pretpostavimo da imamo 5 mjerenja neke pojave za koju iz iskustva znamo da možemo modelirati normalnom razdiobom sa varijancom 4. Pretpostavimo da je uzoračka sredina (dakle, aritmetička sredina 5 podatka) jednaka $9,5$. Testirat ćemo hipotezu $H_0 : \mu = 8$ (očekivanje je jednako $\mu_0 = 8$), u odnosu na alternativnu hipotezu $H_1 : \mu \neq 8$). Uzmimo razinu značajnosti testa $\alpha = 0,05$.

Uz gore definiranu statistiku Z, a prema prijašnjim razmatranjima, možemo uočiti da nam treba vrijednost $z_{0,025}$ (to je ona vrijednost za koju je $1-\Phi(z_{0,025}) = 0,025$). Dobivamo $z_{0,025} = 1,96$. Taj broj možemo izračunati u R-u korištenjem funkcije `qnorm()`.

```
> 1-qnorm(0.025)

[1] 2.959964
```

Izračunamo izraz $\sqrt{n}/\sigma|\bar{X}_n - \mu_0|$:

$$\frac{\sqrt{n}}{\sigma}|\bar{X}_n - \mu_0| = \frac{\sqrt{5}}{2}|9,5 - 8| = 1,68.$$

Kako je $1,68 \leq z_{0,025} = 1,96$ prihvaćamo nul hipotezu $H_0 : \mu = 8$. □

Napomena 7.2.2 (p-vrijednost)**.** Često okolnosti vezane uz pojavu koju opisujemo nekim statističkim modelom određuju željenu razinu značajnosti α. Kod nekih pojava jednostavno želimo imati visoku razinu sigurnosti da nećemo odbaciti istinitu nul hipotezu. S druge strane, možemo započeti izračune kao da provodimo test, ali bez da unaprijed odredimo razinu značajnosti. U tom slučaju jednostavno izračunamo vrijednost testne statistike, a zatim i vjerojatnost da će testna statistika biti veća od te vrijednosti. Ta se vjerojatnost zove **p-vrijednost**.

Ukoliko se vratimo na prethodni primjer pretpostavimo da je uzoračka sredina jednaka $\bar{X}_n = 8,5$. Tada prvo izračunamo

$$\frac{\sqrt{n}}{\sigma}|\bar{X}_n - \mu_0| = \frac{\sqrt{5}}{4}|8,5 - 8| = 0,559,$$

a onda i vjerojatnost $P(|Z| > 0,599)$. Iskoristimo činjenicu da je $Z \sim N(0,1)$ da dobijemo

$$P(|Z| > 0,599) = 2P(Z > 0,599) = 2 \cdot 0,288 = 0,576.$$

Dakle, p-vrijednost za $\bar{X}_n = 8,5$ iznosi $0,576$. Za sve razine značajnosti $\alpha < 0,576$ će nul hipoteza biti prihvaćena, a to znači praktički uvijek. S druge strane, za $\bar{X}_n = 11,5$ dobivamo da je p-vrijednost ovog testa jednaka 0.00005, što je vrlo mala vrijednost pa će praktički za sve razine značajnosti nul hipoteza biti odbačena. Poanta je da nam p-vrijednost daje informaciju koju možemo interpretirati tako da ustvrdimo da sa smanjenjem p-vrijednosti rastu dokazi (zasnovani na podacima) protiv nul hipoteze. □

Gornja razmatranja i izračuni u velikoj mjeri opisuju test očekivanja uzorka iz normalne razdiobe s poznatom varijancom. Ipak, nismo posebno komentirali vjerojatnost prihvaćanja nul hipoteze ako ona nije istinita, odnosno grešku druge vrste. Vjerojatnost prihvaćanja H_0 ako je istinita H_1 smo označili s β. Često se vrijednost $1 - \beta$ zove **funkcija snage testa** i u pravilu će ovisiti o parametrima razdiobe koju promatramo (govorimo o parametarskim testovima).[7] Za test je dobro svojstvo da se β približava broju jedan za što veći skup parametara.

U slučaju konkretnog testa koji opisujemo želimo izračunati vjerojatnost prihvaćanja nul hipoteze kada je očekivanje μ različito od μ_0. Ta će vjerojatnost ovisiti o μ pa je označimo s $\beta(\mu)$. Imamo

$$\beta(\mu) = P_\mu\Big(\Big|\sqrt{n}\frac{\bar{X}_n - \mu_0}{\sigma}\Big| \leq z_{\alpha/2}\Big) = P_\mu\Big(-z_{\alpha/2} \leq \sqrt{n}\frac{\bar{X}_n - \mu_0}{\sigma} \leq z_{\alpha/2}\Big).$$

Ovu vjerojatnost možemo izračunati tako da uočimo da je

$$Z = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma} \sim N(0,1).$$

[7] Na engleskom se često koristi terminologija *size of the test* za grešku prve vrste i *power of the test* za grešku druge vrste.

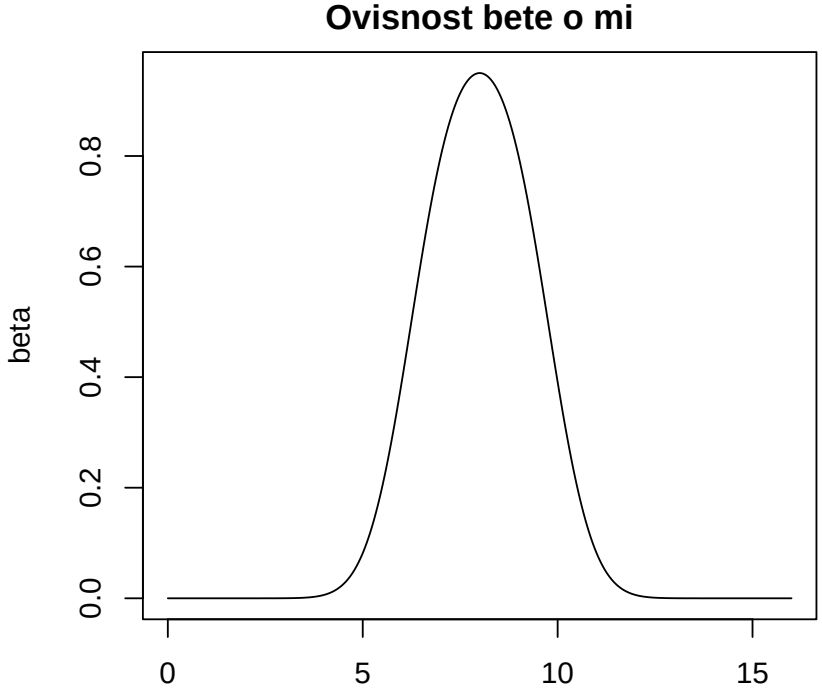
Uočite da sada Z ovisi o μ, a ne μ_0, jer radimo pod pretpostavkom istinitosti alternativne hipoteze H_1. Tada imamo

$$\begin{aligned}
\beta(\mu) &= P_\mu\Big(-z_{\alpha/2} \leq \sqrt{n}\frac{\bar{X}_n - \mu_0}{\sigma} \leq z_{\alpha/2}\Big) \\
&= P_\mu\Big(-z_{\alpha/2} - \sqrt{n}\frac{\mu}{\sigma} \leq \sqrt{n}\frac{\bar{X}_n - \mu_0 - \mu}{\sigma} \leq z_{\alpha/2} - \sqrt{n}\frac{\mu}{\sigma}\Big) \\
&= P_\mu\Big(-z_{\alpha/2} - \sqrt{n}\frac{\mu}{\sigma} \leq Z - \sqrt{n}\frac{\mu_0}{\sigma} \leq z_{\alpha/2} - \sqrt{n}\frac{\mu}{\sigma}\Big) \\
&= P\Big(\sqrt{n}\frac{\mu_0 - \mu}{\sigma} - z_{\alpha/2} \leq Z \leq \sqrt{n}\frac{\mu_0 - \mu}{\sigma} + z_{\alpha/2}\Big) \\
&= \Phi\Big(\sqrt{n}\frac{\mu_0 - \mu}{\sigma} + z_{\alpha/2}\Big) - \Phi\Big(\sqrt{n}\frac{\mu_0 - \mu}{\sigma} - z_{\alpha/2}\Big) \qquad (7.23)
\end{aligned}$$

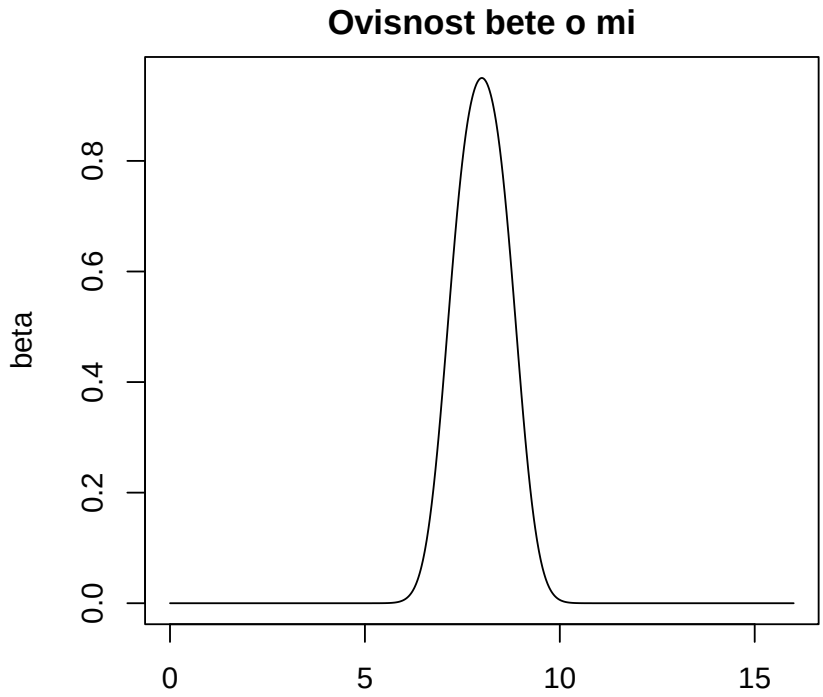
Kada pogledamo gornju jednakost možemo uočiti da je za μ vrlo bliske μ_0 i male n $\beta(\mu)$ zapravo vrlo blizu $\Phi(z_{\alpha/2}) - \Phi(-z_{\alpha/2})$ što je otprilike jednako $1 - \alpha$, a to je blizu vrijednosti 1. Stoga snaga testa u tom slučaju neće biti velika. Općenito će $\beta(\mu)$ ovisiti o ponašanju $\sqrt{n}(\mu_0 - \mu)/\sigma$.

Pretpostavimo, kao u gornjem primjeru, da je $\mu_0 = 8$, da je $n = 5$, $\sigma^2 = 4$, a $\alpha = 0,05$. Onda ćemo dobiti ovisnost $\beta(\mu)$ o μ kao na donjoj slici. Na x osi su nanesene vrijednosti od μ, dok je na y osi vijednost $\beta(\mu)$. Naravno, kada se μ udaljava od $\mu_0 = 8$ vrijednost od β pada prema nuli (snaga testa raste).

```
> par(mar=c(2,4,2,2))
> betami<-function(mi)
+   {pnorm(sqrt(5)*(8-mi)/2+1.96)- pnorm(sqrt(5)*(8-mi)/2-1.96)}
> x.values = seq(0,16, length = 1000)
> y.values = betami(x.values)
> plot(x.values, y.values, type="l", lty=1, xlab="mi", ylab="beta",
+      main="Ovisnost bete o mi")
```



U pravilu snaga testa rase kada i n raste. Na donjoj slici smo ponovili gornji graf, ali sada s $n = 20$.



Na ovom mjestu nećemo ulaziti u detalje, ali možemo uočiti da se izraz za β poput gornjega može iskoristiti za određivanje veličine uzorka n da bi se osigurale neke karakteristike snage testa. Također treba biti svjetan da u mnogim situacijama nije lagano odrediti eksplicitnu formulu za β, odnosno za snagu testa, poput ove koju smu odredili u ovom slučaju.

Zadnja tema koju ćemo obraditi u ovom primjeru (zapravo uvodu) je tako zvani **jednostrani test**. Radi se o tome da smo uz istu nul hipotezu $H_0 : \mu = \mu_0$ mogli staviti drugačiju alternativnu hipotezu poput

$$H_1 : \mu > \mu_0.$$

U tom slučaju želimo formulirati test koji će odbacivati nul hipotezu ako je $\bar{X}_n$ (procjena od μ) značajno veći od μ_0. Kao i kod prijašnje verzije testa (koji je **dvostrani**) želimo naći kritičnu vrijednost c za koju će vjerojatnost odbacivanja nul hipoteze ako je ona istinita biti najviše jednaka α. Stoga tražimo c za koji će biti

$$P_{H_0}(\bar{X}_n - \mu_0 > c) = \alpha. \tag{7.24}$$

Iskoristit ćemo činjenicu da je

$$Z = \sqrt{n}\frac{\bar{X}_n - \mu_0}{\sigma}$$

iz $N(0,1)$ distribucije ako vrijedi H_0. Kao i prije zaključujemo da je (7.24) za $Z \sim N(0,1)$ ekvivalentno s

$$P\Big(Z > \frac{c\sqrt{n}}{\sigma}\Big) = \alpha. \tag{7.25}$$

S obzirom da znamo za koji je z_α (iz tablica, R-a,..)

$$P(Z > z_\alpha) = \alpha$$

možemo izračunati

$$c = \frac{\sigma z_\alpha}{\sqrt{n}}.$$

Na taj način dobivamo test koji prihvaća nul hipotezu H_0 ukoliko je

$$\frac{\sqrt{n}}{\sigma}(\bar{X}_n - \mu_0) \leq z_\alpha,$$

a odbacuje ju ako je

$$\frac{\sqrt{n}}{\sigma}(\bar{X}_n - \mu_0) > z_\alpha.$$

Već iz ove formulacije testa bi se čitatelj mogao zapitati ne bi li ovako izgledao i test koji bi testirao jednostranu nul hipotezu $H_0' : \mu \leq \mu_0$ u odnosu na alternativnu hipotezu $H_1 : \mu > \mu_0$ i bio bi u pravu. U oba slučaja test izgleda isto.

Intuitivno gledano se radi o tome da ako pokažemo da je vrijednost testne statistike ekstremna (veća od z_α) u odnosu na hipotezu (pretpostavku) $\mu = \mu_0$, onda je to pogotovo istina ako je prihvaćena hipoteza $H_0 : \mu \leq \mu_0$.

Formalno, da bi se to pokazalo treba se uvjeriti da vjerojatnost odbacivanja nul hipoteze H_0' nikada nije veća od α kada je H_0' istinita. U terminima $\beta(\mu)$ to znači da želimo pokazati da je $1 - \beta(\mu) \leq \alpha$ za $\mu \leq \mu_0$, odnosno

$$\beta(\mu) \geq 1 - \alpha, \quad \text{za } \mu \leq \mu_0. \tag{7.26}$$

Izračun $\beta(\mu)$ za jednostrani test je sličan onome za dvostrani. Naime, imamo

$$\begin{aligned}
\beta(\mu) &= P_\mu\Big(\bar{X}_n \leq \mu_0 + z_\alpha \frac{\sigma}{\sqrt{n}}\Big) \\
&= P_\mu\Big(\frac{\sqrt{n}(\bar{X}_n - \mu_0)}{\sigma} \leq \frac{\sqrt{n}(\mu_0 - \mu)}{\sigma} + z_\alpha\Big) \\
&= P\Big(Z \leq \frac{\sqrt{n}(\mu_0 - \mu)}{\sigma} + z_\alpha\Big)
\end{aligned}$$

gdje je $Z \sim N(0,1)$. No, u zadnjoj jednakost prepoznajemo funkciju distribucije standardne normalne slučajne varijable pa je

$$\beta(\mu) = \Phi\Big(\frac{\sqrt{n}(\mu_0 - \mu)}{\sigma} + z_\alpha\Big)$$

Za $\mu = \mu_0$ je $\beta(\mu_0) = \Phi(z_\alpha) = 1 - \alpha$ (tako je odabran z_α). Za $\mu \leq \mu_0$ dobivamo $\beta(\mu) \geq \beta(\mu_0) = 1 - \alpha$, a to smo u (7.26) i željeli pokazati.

Prikažimo pregledno kako izgledaju kritična područja u odnosu na različite kombinacije alternativnih hipoteza. Ako je $H_0 : \mu = \mu_0$, gdje je μ_0 neki konkretan broj, onda hipoteze mogu biti

1) $H_0 : \mu = \mu_0$, $H_1 : \mu > \mu_0$

2) $H_0 : \mu = \mu_0$, $H_1 : \mu \neq \mu_0$

3) $H_0 : \mu = \mu_0$, $H_1 : \mu < \mu_0$

dok su odgovarajuća kritična područja (uz iste oznake kao i do sada)

1) $C_\alpha = [z_\alpha, \infty)$

2) $C_\alpha = \mathbb{R} \setminus (-z_\alpha, z_\alpha)$

3) $C_\alpha = (-\infty, -z_\alpha)$.

Pogledajmo jedan numerički primjer jednostranog testa.

Primjer 7.2.3. Pretpostavimo da je prosječna količina masti u nekom prehrambenom proizvodu na tržištu $1,6$ grama na 100 grama proizvoda. Neki proizvođač tvrdi da njegov proizvod ima manju količinu masti u proizvodu u odnosu na prosjek. Da bi se testirala ta tvrdnja uzeto je 20 proizvoda tog proizvođača i utvrđeno je da je prosječna količina masti u tim proizvodima iznosila $1,5$ grama na 100 grama proizvoda. Kakav zaključak možemo izvesti ako znamo da je standardna devijacija količine masti u tom proizvodu jednaka $0,8$?

Da bi testirali tvrdnju proizvođača u osnovi želimo formulirati test koji će provjeriti da li su podaci koji su dobiveni testiranjem 20 proizvoda u kontradikciji s tvrdnjom proizvođača, odnosno da li podaci potkrijepljuju suprotnu tvdnju od proizvođačeve. Stoga formuliramo hipoteze testa kao

$$H_0 : \mu \geq 1,6 \text{ i } H_1 : \mu < 1,6$$

te definiramo razinu značajnosti testa $\alpha = 0,5$. Uz dane podatke je vrijednost testne statistike

$$\sqrt{n}(\bar{X}_n - \mu_0)/\sigma = \sqrt{20}(1,5 - 1,6)/0,8 = -0,559.$$

Kako je $-z_{0,05} = -1,65$ proizlazi da je vrijednost statistike $-0,559$ veća ili jednaka od $-1,65$ pa prihvaćamo nul hipotezu $H_0 : \mu \geq 1,6$. Dakle, podaci koje je predočio proizvođač nisu dovoljni da bi se odbacila takva nul-hipoteza.
Prema prijašnjim napomenama bi jednak zaključak donijeli da je $H_0 : \mu = 1,6$, a $H_1 : \mu < 1,6$, a uz te hipoteze smo u slučaju 3) prema prije navedenim slučajevima alternativne hipoteze. □

7.2.2 t-test

U prošlom odjeljku smo pokazali kako testirati očekivanje uzorka iz normalne razdiobe s poznatom varijancom. Realističnija je situacija u kojoj ne znamo varijancu. U takvoj situaciji se može upotrebiti t-test.

Pretpostavimo da opet imamo uzorak $X_1, X_2, \ldots X_n$ iz normalne razdiobe. Pretpostavimo da nam nisu unaprijed poznati ni očekivanje mu ni varijanca σ^2 uzorka. Pretpostavimo da opet želimo ispitati nul hipotezu $H_0 : \mu = \mu_0$, gdje je μ_0 neki broj, u odnosu na alternativnu hipotezu $H_1 : \mu \neq \mu_0$.

Kao i u slučaju poznate varijance čini se razumnim krenuti od statistike $\bar{X}_n$ te formirati test koji će odbaciti nul hipotezu ukoliko je $\bar{X}_n$ "dovoljno daleko" od μ_0. U slučaju poznate varijance smo formirali testnu statistiku $\sqrt{n}(\bar{X}_n - \mu_0)/\sigma$ i onda smo provjerom vrijednosti te statistike u odnosu na kvantile normalne razdiobe (odnosno vrijednosti z_α takvih da je $\Phi(z_\alpha) = \alpha$) odlučivali da li ćemo prihvatiti ili odbaciti nul hipotezu. Pri tome smo se oslonili na "teorijske" rezultate kojima smo zaključili nešto o ponašanju, odnosno razdiobi, testne statistike. U ovom slučaju ne možemo iskoristiti istu testnu statistiku jer ne znamo σ.

Nadamo se da je dosta očita ideja da se standardna devijacija σ zamijeni uzoračkom standardnom devijacijom, odnosno sa

$$S_n = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2}.$$

U tom smislu definirajmo testnu statistiku

$$T = \sqrt{n}\frac{(\bar{X}_n - \mu_0)}{S_n}.$$

Kao što smo vidjeli u odjeljku 7.1.3, kada je $\mu = \mu_0$ (dakle, kada vrijedi nul hipoteza) T ima t-distribuciju s $n-1$ stupnjeva slobode, a za nju se opet mogu naći kritične vrijednosti bilo putem tablica, bilo putem nekog programa poput R-a. Dakle, želimo naći 100 $\alpha/2$ percentil $t_{n-1,\alpha/2}$ distribucije $t(n-1)$ (koja je simetrična) za koji je

$$P_{\mu_0}\Big(\Big|\sqrt{n}\frac{(\bar{X}_n - \mu_0)}{S_n}\Big| > t_{n-1,\alpha/2}\Big) = \alpha,$$

odnosno

$$P_{\mu_0}\big(\{T < -t_{n-1,\alpha/2}\} \cup \{T > t_{n-1,\alpha/2}\}\big) = \alpha,$$

a što je ekvivalentno s

$$P_{\mu_0}\Big(-t_{n-1,\alpha/2} \leq \sqrt{n}\frac{(\bar{X}_n - \mu_0)}{S_n} \leq t_{n-1,\alpha/2}\Big) = 1-\alpha.$$

Prema tome, nul hipoteza H_0 se odbacuje ako je

$$\frac{\sqrt{n}}{S_n}|\bar{X}_n - \mu_0| > t_{n-1,\alpha/2},$$

a prihvaća se ako je

$$\frac{\sqrt{n}}{S_n}|\bar{X}_n - \mu_0| \leq t_{n-1,\alpha/2}.$$

Ponovimo, u ovom slučaju su $t_{n-1,\alpha/2}$ kritične vrijednosti t-distribucije s $n-1$ stupnjeva slobode, a ne više $N(0,1)$ distribucije. Pogledajmo jedan primjer upotrebe t-testa.

Primjer 7.2.4. Pretpostavimo da se u nekoj tvornici proizvodi neki proizvod koji prema tehničkoj specifikaciji ima promjer 1 cm. Radi kontrole kvalitete je slučajno odabrano 20 završenih proizvoda i izmjeren im je dijametar. Dobivena su sljedeća mjerenja

$$1,108 \quad 1,009 \quad 1,042 \quad 1,053 \quad 0,969 \quad 1,002 \quad 0,9688 \quad 1,019 \quad 1,062 \quad 1,032$$

$$1,072 \quad 0,977 \quad 1,062 \quad 1,044 \quad 1,069 \quad 1,029 \quad 0,979 \quad 1,096 \quad 1,079 \quad 0,999$$

Želimo provjeriti da li dobiveni rezultati podržavaju željenu tehničku specifikaciju proizvoda. Stoga nam je nul hipoteza $H_0 : \mu = 1$, a alternativna hipoteza je $H_1 : \mu \neq 1$. U ovom slučaju nam unaprijed nisu poznati niti očekivanje niti varijanca pa ih trebamo procijeniti iz podataka. Kako se nul hipoteza odnosi na očekivanje primijenit ćemo t-test.

Izračunamo uzoračku sredinu i dobijemo $\bar{X}_n = 1,03354$. Nije odmah jasno da li je to statistički značajno različito od 1, a utvrđivanje takvih zaključaka je upravo svrha statističkih testova, jer to ovisi o izmjerenoj (uzoračkoj) varijanci, odnosno standardnoj devijaciji. Standardna devijacija iznosi $0,04229$. Pretpostavimo da je dobiveni uzorak iz normalne distribucije. Formiramo testnu statistiku T i izračunamo

$$T = \sqrt{n}\frac{(\bar{X}_n - \mu_0)}{S_n} = \sqrt{20}\frac{(1,03-1)}{0,0372} = 3,54683.$$

Uzmimo razinu značajnosti testa $\alpha = 0,05$. Iz tablica očitamo $t_{19,0,025} = 2,093$. Alternativno, upotrijebimo R-ovu funkciju `qt()` i to kao `qt(0.9750, df=19)`. Kako je $T > t_{19,0,025}$ odbacujemo nul hipotezu. Slično bi se postupilo u slučaju ispitivanja jednostranih hipoteza (s time da gledamo $t_{19,0,05}$).

S druge strane, vidjeli smo u prošlom primjeru da se na osnovi izračunate vrijednosti testne statistike može izračunati i p-vrijednost testa. U ovom slučaju je to vjerojatnost $P(|T| \geq 3,54683)$. Kako je t-distribucija simetrična, p-vrijednost je jednaka $2P(T \geq 3,54683)$. Tu vjerojatnost izračunamo iz tablica ili u R-u pomoću `1-pt(3.54683, df=19)`. U svakom slučaju dobijemo da je p-vrijednost jednaka 0.00215. To je vrlo mala vrijednost koja samo potvrđuje da je razumno odbaciti nul hipotezu. Podsjetimo, p-vrijednost nam govori u kojoj su mjeri podaci suglasni s nul hipotezom. U ovom slučaju podaci govore u korist alternativne hipoteze. □

Zadatak 7.2.5. *Pretpostavite da su podaci iz prethodnog primjera došli s dvije proizvodne trake: prvih 10 podataka (proizvoda) je došlo s jedne proizvodne trake, a drugih 10 podataka za proizvode s druge proizvodne trake. Provedite t-test na svaku od te dvije grupe podataka s istom nul hipotezom i alternativnom hipotezom te razinom značajnosti $\alpha = 0,05$. Da li vrijedi isti zaključak u oba slučaja? (Rj: Uzoračka sredina prvih 10 podataka je $1,02648$, a uzoračka standardma devijacija je $0,04278$. Uzoračka sredina drugih 10 podataka je $1,0406$, a uzoračka standardna devijacija je $0,04283$. Vrijednost testne statistike za prvih 9 podataka je $1,957$, a vrijednost testne statistike za drugih 9 podataka je $2,9975$. Kritična vrijednost je $t_{9,0.025} = 2,262$. Dakle, za uzorak s prve proizvodne linije ne možemo odbaciti nul hipotezu. Provjerite sve izračune za vježbu.)*

Izračune koje smo prikazali treba razumijeti jer se upoznajemo sa statističkim testovima. Ipak, u primjeni je dovoljno koristiti neki statistički paket/jezik koji omogućava brzu i efikasnu obradu podataka. Naravno, R je rađen upravo s tom namjerom pa su u njemu implementirani mnogi testovi, među kojima i t-test. Konkretno, ukoliko uzmemo podatke iz prošlog primjera, napišimo sljedeći kod koji nam daje rezultate t-testa.

```
> diam<-c(1.108, 1.009,1.042, 1.053, 0.969, 1.002, 0.9688,
+         1.019, 1.062, 1.032,1.072, 0.977, 1.062, 1.044,
+         1.069, 1.029,0.979, 1.096,1.079, 0.999)
> ttest<-t.test(diam, mu=1,alternative=c("two.sided"),conf.level=0.95 )
> ttest

        One Sample t-test

data:  diam
t = 3.5468, df = 19, p-value = 0.002154
alternative hypothesis: true mean is not equal to 1
95 percent confidence interval:
 1.013748 1.053332
sample estimates:
mean of x
  1.03354
```

Razumijemo skoro sve brojeve koje dobivamo funkcijom `t.test`, osim `95 percent confidence interval`. To je u biti interval unutar kojega bi se prava vrijednost očekivanja (prema danim podacima) trebala nalaziti 95% vremena. Formalno je to interval za koji je vjerojatnost da će μ biti u tom intervalu jednaka $0,95$. U ovoj izjavi se krije mala suptilnost jer μ nije slučajna varijable, nego broj pa je dakle slučajan sam interval pouzdanosti, odnosno njegove granice.

Kao i inače kod R-a funkcija `ttest` ima više vrijednosti što možemo vidjeti korištenjem funkcije `names()`

```
> names(ttest)

 [1] "statistic"   "parameter"   "p.value"     "conf.int"    "estimate"
 [6] "null.value"  "stderr"      "alternative" "method"      "data.name"
```

Navednim vrijednostima pristupamo kao i inače u R-u. Na primjer, vrijednost statistike dobijemo

```
> ttest$statistic

       t
3.546811
```

Napomenimo da funkcija `ttest` može usporediti i očekivanja dva uzorka, odnosno ispitati da li su jednaka. Na primjer, ukoliko prvih 10 mjerenja iz prošlog primjera smatramo jednim uzorkom, a drugih 10 drugim uzorkom dobijemo sljedeće:

```
> diam1<-c(1.108,1.009,1.042,1.053,0.969,1.002,0.9688,1.019,1.062,1.032)
> diam2<-c(1.072,0.977,1.062,1.044,1.069,1.029,0.979,1.096,1.079,0.999)
> t.test(diam1, diam2, alternative = c("two.sided"),conf.level = 0.95 )

        Welch Two Sample t-test

data:  diam1 and diam2
t = -0.73757, df = 18, p-value = 0.4703
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -0.05433981  0.02609981
sample estimates:
mean of x mean of y
  1.02648   1.04060
```

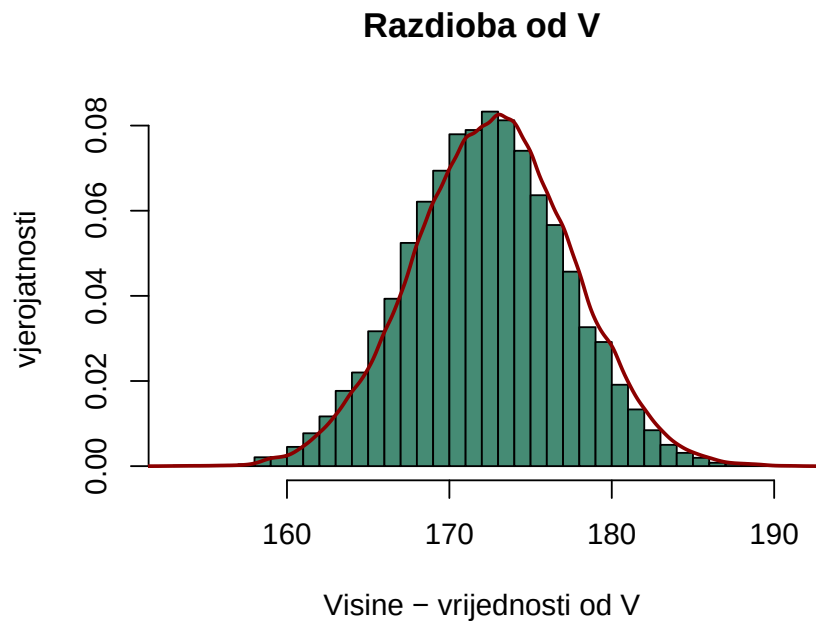
U ovom slučaju se nul hipoteza prema kojoj su očekivanja tih uzoraka jednaka ne može odbaciti.

Vidimo da je t-test dosta fleksibilan s time da se pretpostavka da je slučajni uzorak $X_1, X_2, \dots X_n$ iz normalne razdiobe čini dosta ograničavajućom. Iako velik dio podataka dolazi iz normalne razdiobe, nije realno očekivati da je to jedini mogući slučaj. No, vidjeli smo na prošlom predavanju (zaključak je slijedio iz centralnog graničnog teorema) da statistika T konvergira prema $N(0,1)$ kada uzorak nije iz normalne razdiobe. To nam pruža mogućnost da na sličan način testiramo hipoteze vezane uz očekivanje čak i kada imamo uzorke iz općenite (nepoznate) razdiobe. Treba voditi računa da je u tom slučaju potrebno imati veći broj podataka jer je centralni granični teorem rezultat asimptotskog karaktera (imamo konvergenciju funkcija distribucije). Nećemo ovdje ulaziti u detalje, a pragmatično gledano to ne možemo testirati na ispitu.

Inače, postoje i testovi normalnost, odnosno testovi koji testiraju da li su neki podaci iz normalne razdiobe. Primjeri takvih testova su Kolmogorov–Smirnovljev test ili Shapiro–Wilkov test. Prije upotrebe testa bi se trebalo upoznati sa samim testom, ali želimo ilustrirati ukratko kako bi izgledala provjera normalnosti podataka. Uzet ćemo Primjer 5.2.8, koji sadrži podatke o visini i težini 25.000 osoba.

```
'data.frame':        25000 obs. of  2 variables:
 $ Broj  : num  1 2 3 4 5 6 7 8 9 10 ...
 $ Visina: num  167 182 176 173 172 174 177 178 172 170 ...
```

U Primjeru 5.2.8 smo nacrtali histogram podataka i oni su izgledali "dosta normalno". Na histogram smo dodali i graf koji dobijemo funkcijom `density()`.



Provjerimo Shapiro–Wilkovim testom da li su podaci normalni. Napomena, nul hipoteza je da su podaci normalni pa velike p-vrijednosti indiciraju normalnost podataka. Također, osnovna R-ova funkcija može obraditi najviše 5.000 podataka pa smo za ilustraciju odabrali prvih 1.000 podataka

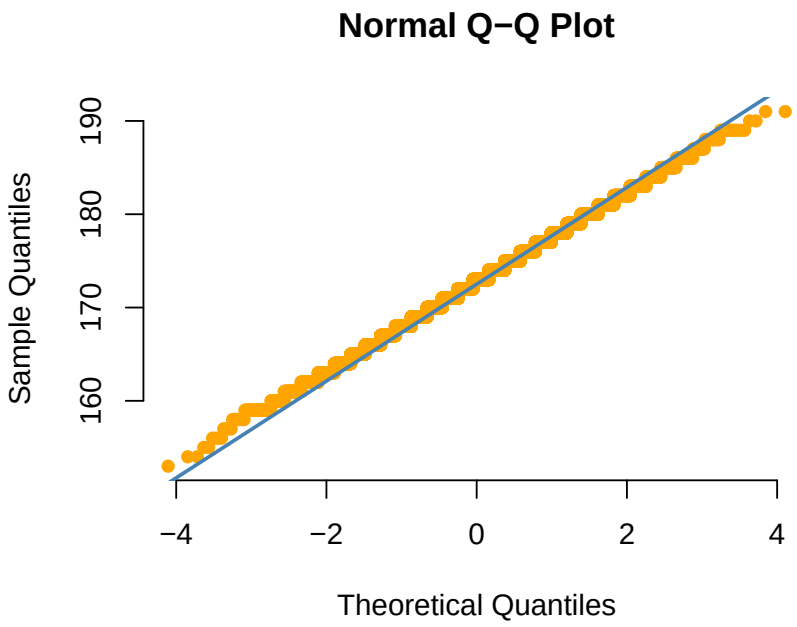
```
> shapiro.test(visina$Visina[1:1000])

        Shapiro-Wilk normality test

data:  visina$Visina[1:1000]
W = 0.99437, p-value = 0.0008447
```

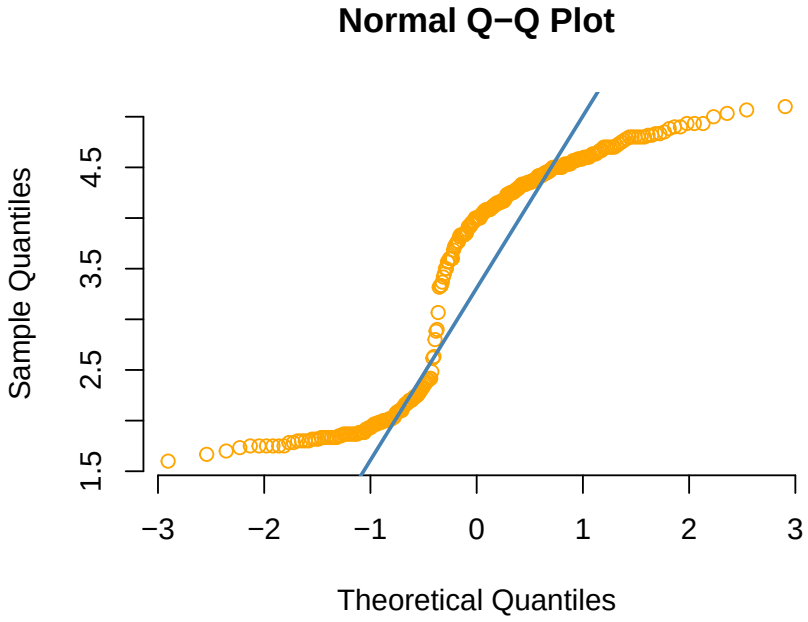
Dobivamo p-vrijednost koja nije velika pa ona indicira moguću ne-normalnost podataka. Često se upotrebljava i tzv. q-q plot koji uspoređuje kvantile podataka s kojima radimo u odnosu na normalne kvantile korištenjem funkcije `qnorm()`. Dobivamo sljedeći graf pri čemu koristimo sve podatke.

```
> qqnorm(visina$Visina, col="orange", pch = 16, frame = FALSE)
> qqline(visina$Visina, col = "steelblue", lwd = 2)
```



Narančastom bojom su označeni kvantili podataka, a plavom bojom su dodani terijski kvantili. Vidimo da su podaci prilično usklađeni s normalnima, s time da su u lijevom repu mogući problemi. Primjer značajno različitih podatak od normalnih možemo dobiti korištenjem podataka o trajanju erupcija iz paketa podataka `faithful` (pogledajte Primjer 2.7.3).

```
> qqnorm(faithful$eruptions, col="orange", pch = 1, frame = FALSE)
> qqline(faithful$eruptions, col = "steelblue", lwd = 2)
```



7.3 Upareni podaci - korelacija i regresija

Do sada smo uglavnom promatrali jedan uzorak iz neke populacije (iz neke razdiobe, vjerojatnosno gledano). U mnogim situacijama i primjenama potrebno je utvrditi moguću vezu (odnos) među nekim pojavama, odnosno varijablama. Jedan od načina za usporedbu dvije varijable (dva uzorka) je mjerenje snage njihove povezanosti što možemo mjeriti, između ostaloga, korelacijom. S druge strane je moguće pokušati procjeniti prirodu povezanosti dvije varijable što radimo **regresijskom analizom**. Regresija ima raznih, a mi ćemo se ukratko uvesti u područje **linearnom regresijom**.

Pretpostavimo da su dane slučajne varijable X i Y. Ukoliko na njih gledamo kao na vektor govorimo o bivarijatnom (dvodimenzionalnom) vektoru (X, Y). Pretpostavimo da su realizacije tog bivarijatnog vektora brojevi

$$(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n).$$

U analizi združenih podataka se učestalo koriste sljedeće statistike

$$S_{XX} = \sum_{i=1}^{n} (X_i - \bar{X}_n)^2 = \sum_{i=1}^{n} X_i^2 - n\bar{X}_n^2,$$

$$S_{YY} = \sum_{i=1}^{n} (Y_i - \bar{Y}_n)^2 = \sum_{i=1}^{n} Y_i^2 - n\bar{Y}_n^2$$

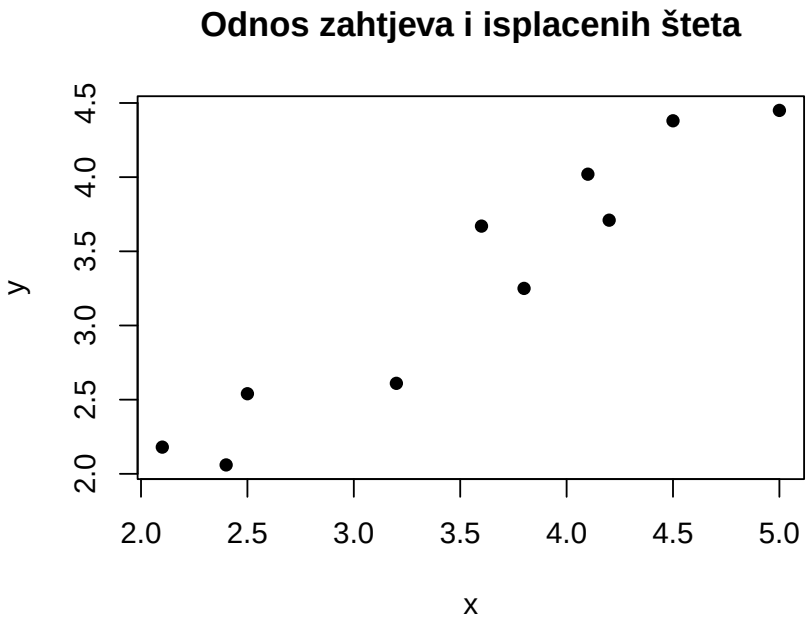
i

$$S_{XY} = \sum_{i=1}^{n} (X_i - \bar{X}_n)(Y_i - \bar{Y}_n) = \sum_{i=1}^{n} X_i Y_i - n\bar{X}_n\bar{Y}_n.$$

Pogledajmo jedan primjer. Dobili smo podatke od neke osiguravajuće kuće. Podaci sadržavaju iznose zahtjeva za naknadu šteta (x_i) i iznose koje je osiguravajuće društvo zaista platilo:

x_i	2,10	2,40	2,50	3,20	3,60	3,80	4,10	4,20	4,50	5,00
y_i	2,18	2,06	2,54	2,61	3,67	3,25	4,02	3,71	4,38	4,45.

Prije bilo kakve numeričke analize nije loše grafički prikazati podatke. To možemo napraviti već prije uvedenim dijagramom raspršenja (scatter-plot).



Izračunajmo vrijednosti statistika S_{XX}, S_{XY} i S_{YY}, s time da izračunate vrijednosti (realizacije) označavamo s S_{xx}, S_{xy} i S_{yy}. Dobivamo

```
> sxx<-sum((x-mean(x))^2)
> syy<-sum((y-mean(y))^2)
> sxy<-sum((x-mean(x))*(y-mean(y)))
> sxx

[1] 8.444

> sxy

[1] 7.4502

> syy

[1] 7.15881
```

Sada možemo definirati novu statistiku, **uzorački koeficijent korelacije** (Pearsonov koeficijent korelacije) kao

$$R := \frac{S_{XY}}{\sqrt{S_{XX}S_{YY}}} \tag{7.27}$$

čije su realizacije

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} = \frac{1}{n-1}\sum_{i=1}^{n}\frac{x_i - \bar{x}_n}{s_x}\cdot\frac{y_i - \bar{y}_n}{s_y}, \tag{7.28}$$

gdje su s_x i s_y standardne devijacije podataka (realizacija od X i Y). Često se uzorački koeficijent korelacije označava s ρ. U slučaju podataka koje imamo u ovom primjeru dobivamo

```
> r<-cor(x,y)
> r

[1] 0.958238
```

Kako je uvijek $-1 \leq r \leq 1$ dobivena vrijednost $r = 0,958$ je prilično visoka što ukazuje na značajnu povezanost podataka o zahtjevima za štetu i isplaćenim štetama. Ta je povezanost pozitivna, a kaže se da su podaci visoko pozitivno korelirani. Da smo dobili vrijednost $r = -0,958$ rekli bi da su podaci značajno negativno korelirani.

U kontekstu statističkih testova, relativno lagano možemo konstruirati test nul hipoteze $H_0 : r = 0$ jer pod tom nul hipotezom vrijedi da je

$$\sqrt{n-2}\frac{R}{\sqrt{1-R^2}} \sim t(n-2).$$

Pretpostavka za taj rezultat je da su X i Y normalno distribuirane. Postoji općenitiji asimptotski rezultat koji nam omogućava testiranje nulhipoteza oblika $H_0 : r = r_0$, gdje je r_0 zadani broj takav da je $|r_0| < 1$. Naravno, to nije i jedini tip testa vezan uz korelaciju jer se mogu formirati i permutacijski testovi za korelaciju, ali ne stignemo o tome više reći na ovom mjestu. U svakom slučaju, opis svojstava dva niza brojeva (pojava) korelacijom daje indikaciju snage njihove povezanosti. Krakter povezanosti je tema kojom se bavi regresija.

U regresijskoj analizi se pretpostavlja da je jedna varijabla neazvisna (obično X u ovim oznakama), a druga zavisna (dakle Y). U principu ćemo na početku analize

imati dvodimenzionalni niz brojeva $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$ koje u ovom kontekstu smatramo realizacijom slučajnog uzorka

$$(x_1, Y_1), (x_2, Y_2), \ldots, (x_n, Y_n).$$

U slučaju linearne regresije pretpostavljamo da vrijedi

$$Y_i = \alpha + \beta x_i + \epsilon_i, \ i = 1, 2, \ldots, n, \tag{7.29}$$

gdje su $\alpha, \beta \in \mathbb{R}$, a ϵ_i, $i = 1, 2, \ldots, n$ su slučajne varijable koje se nazivaju **slučajnim pogreškama** (šumovima). Dodatno se pretpostavlja

(1) $E(\epsilon_i) = 0$, $i = 1, 2, \ldots, n$ (ϵ_i su centrirane)

(2) $\mathrm{Var}\,(\epsilon_i) = \sigma^2$, $i = 1, 2, \ldots, n$ (ϵ_i imaju istu varijancu)

(3) $\mathrm{Cov}(\epsilon_i, \epsilon_j) = 0$, za $i \neq j$, $i, j \in \{1, 2, \ldots, n\}$ (ϵ_i su nekorelirane).

Podsjetimo se, za slučajne varijable X i Y je $\mathrm{Cov}(X, Y) = r(X, Y)\sqrt{Var(X)}\sqrt{Var(Y)}$, gdje je $r(X, Y)$ korelacija između X i Y.

Mala napomena: gornja formulacija prema kojoj gledamo realizacije slučajnog uzorka $(x_1, Y_1), (x_2, Y_2), \ldots, (x_n, Y_n)$ može izgledati malo čudno. Stvar je u tome da se linearna povezanost od X i Y može zapisati kao

$$E(Y \mid X = x) = \alpha + \beta x,$$

gdje je $E(Y \mid X = x)$ uvjetno očekivanje od Y uz uvjet $X = x$, $x \in \mathbb{R}$. Ne možemo na jednostavan način objasniti kakav je to objekt za općenite slučajne varijable pa zato koristimo gornju formulaciju. Poanta je da u danom uzorku $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$ na x_i, $i = 1, 2, \ldots, n$ možemo gledati kao na determinističke (neslučajne) vrijednosti, a na y_i kao na realizacije slučajne varijable Y, odnosno uzorka $(Y_1, \ldots, Y_n)$. Uočimo da se u relaciji (7.29) i s lijeve i s desne strane jednakosti nalaze slučajne varijable, Y_i i ϵ_i.

Nakon što smo postavili linearni model ovisnosti Y o x-evima, želimo naći procjenitelje $\hat{\alpha}$ i $\hat{\beta}$ od α i β. Oni se standardno procjenjuju metodom najmanjih kvadrata, odnosno dobivaju se minimizacijom funkcije

$$\sum_{i=1}^{n} (y_i - (\alpha + \beta x_i))^2$$

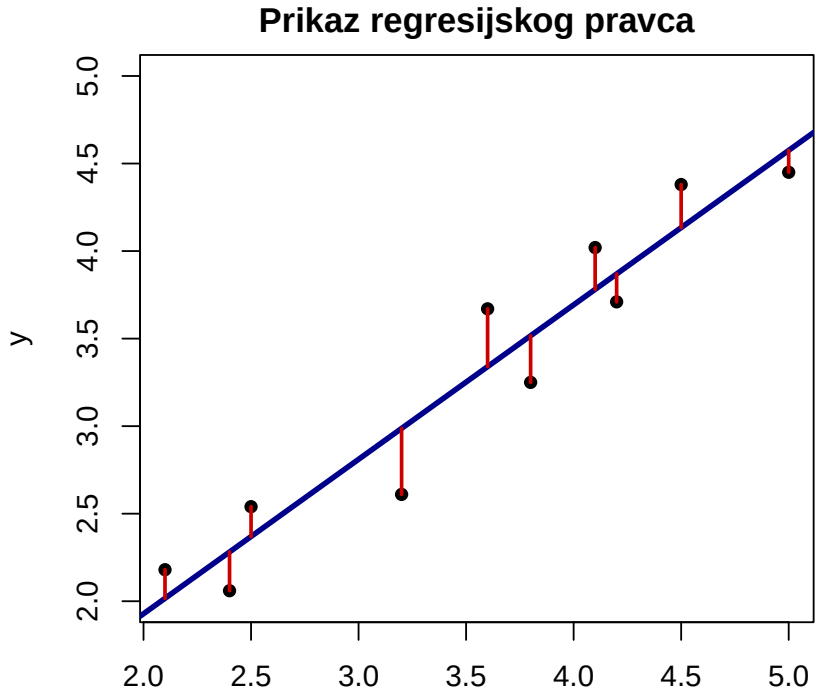
po α i β. Minimum te funkcije se postiže za

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\alpha} = \bar{y}_n - \hat{\beta}\bar{x}_n.$$

Na taj način dobivamo pravac koji najbolje (u smislu ostvarivanja minimuma prije navedene funkcije) aproksimira niz podataka (točaka u ravnini) $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$. Taj pravac se naziva regresijskim pravcem, a zadan je jednadžbom

$$y = \hat{\alpha} + \hat{\beta}x, \ x \in \mathbb{R}. \tag{7.30}$$

Na donjem grafu prikazujemo regresijski pravac za primjer podataka o isplaćenim štetama (plavom bojom). Crvenom bojom su označene dužine od točaka (x_i, y_i) do $(x_i, \hat{\alpha} + \hat{\beta}x_i)$. Kvadrati duljina tih dužina su upravo sumandi funkcije $\sum_{i=1}^{n}(y_i - (\alpha + \beta x_i))^2$ koju smo minimizirali po α i β. Geometrijski gledano, regresijski pravac je onaj pravac za koji je zbroj kvadrata duljina crvenih dužina najmanji.



Vidjeli smo kako izračunati brojeve $\hat{\alpha}$ i $\hat{\beta}$ iz niza podataka $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$. No, ne treba smetnuti s uma da su $\hat{\alpha}$ i $\hat{\beta}$ procjenitelji od α i β koje smo dobili metodom najmanjih kvadrata. Prema tome, možemo definirati statistike

$$\hat{\beta} = \frac{S_{xY}}{S_{xx}}$$

i

$$\hat{\alpha} = \bar{Y}_n - \hat{\beta}\bar{x}_n.$$

Oba su procjenjitelja nepristrana jer je

$$E(\hat{\alpha}) = \alpha \quad \text{i} \quad E(\hat{\beta}) = \beta.$$

Za varijance tih procjenitelja imamo

$$Var(\hat{\alpha}) = \sigma^2 \cdot \left(\frac{1}{n} + \frac{\bar{x_n}}{S_{xx}}\right)$$

i

$$Var(\hat{\beta}) = \sigma^2 \frac{1}{S_{xx}}.$$

Pomoću ta dva procjenitelja možemo dobiti i procjenitelj za Y (a od toga smo i krenuli u regresijsku analizu). Naime, sa $\hat{Y}_i = \hat{\alpha} + \hat{\beta}x_i$ označimo procjenitelj za slučajnu varijablu Y_i, $i = 1, 2, \ldots, n$. Realizacije tog procjenitelja možemo označiti s $\hat{y}_i$. To su, za vrijednosti x_i, opet zapravo točke s regresijskog pravca. Pomoću procjenitelja (statistike) $\hat{Y}_i$ možemo naći nepristrani procjenitelj $\hat{\sigma}^2$ varijance slučajnih grešaka ϵ_i (pogledajte definiciju od ϵ_i, $i = 1, 2, \ldots, n$). Imamo

$$\hat{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2.$$

Na taj smo način zapravo izračunali sve važnije statističke veličine vezane uz linearni regresijski model. Regresije se mogu poopćavati i na više varijabli (u linarnom modelu), ali i na nelinearne modele. Analiza takvih modeal nadilazi opseg tema koje obrađujemo

na ovim predavanjima. Ideja za studentski zadatak može biti da se obradi (s gotovim formulama) kvadratni regresijski model i primijeni na podatke.

Ukoliko sada primijenimo procjenitelje koje smo predstavili na numerički primjer koji smo započeli dobijemo, u R-u (a može se izračunati i "na ruke")

```
> fit.podaci

Call:
lm(formula = y ~ x)

Coefficients:
(Intercept)            x
     0.1636       0.8823
```

što čitamo kao procjene

$$\hat{\alpha} = 0,1636$$

i

$$\hat{\beta} = 0,8823.$$

Dakle, procjenjeni regresijski pravac zadan je jednadžbom

$$\hat{y} = 0,1636 + 0,8823x.$$

Grafički smo taj pravac prikazali na gornjem grafu. Pogledajmo primjer jednog zadatka vezanog uz uparene podatke.

Zadatak 7.3.1. *Zadani su sljedeći podaci:*

$$(100, 45), (110, 52), (120, 50), (130, 60), (140, 62), (150, 68).$$

Izračunajte:

a) korelaciju među podacima s time da prvi niz podataka čine prve komponente gornjeg niza vektora (brojevi koje se nalaze na prvom mjestu u uređenim parovima oblika (x_i, y_i), $i = 1, 2, 3, 4, 5, 6$), a drugi niz podataka čine druge komponente gornjeg niza vektora.

b) jednadžbu regresijskog pravca za dani niz podataka.

Prema uvjetima zadatka zadani su nam sljedeći podaci (prema oznakama koje smo uveli)

$$x... \ (100, 110, 120, 130, 140, 150)$$

$$y... \ (45, 52, 50, 60, 62, 68).$$

Čini mi se da je najlakše izračunati tražene veličine iz zadatka tako da se izračunaju $\bar{x}_6$ i $\bar{y}_6$ te S_{xx}, S_{yy} i S_{xy}. U svakom slučaju dobivamo sljedeća rješenja

```
> xz<-c(100,110,120,130,140,150)
> yz<-c(45,52,50,60,62,68)
> cor(xz,yz)

[1] 0.9646452

> xypodaci<-lm(yz ~ xz)
> xypodaci
```

```
Call:
lm(formula = yz ~ xz)

Coefficients:
(Intercept)           xz
     0.8095       0.4429
```

Dakle, dobivamo da je korelacija jednaka $0,9647$, a jednadžba regresijskog pravca je $\hat{y} = 0,8095 + 0,4429x$. Radi potpunosti navodimo i izračune za S_{xx}, S_{yy} i S_{xy}

```
> sxx<-sum((xz-mean(xz))^2)
> syy<-sum((yz-mean(yz))^2)
> sxy<-sum((xz-mean(xz))*(yz-mean(yz)))
> sxx

[1] 1750

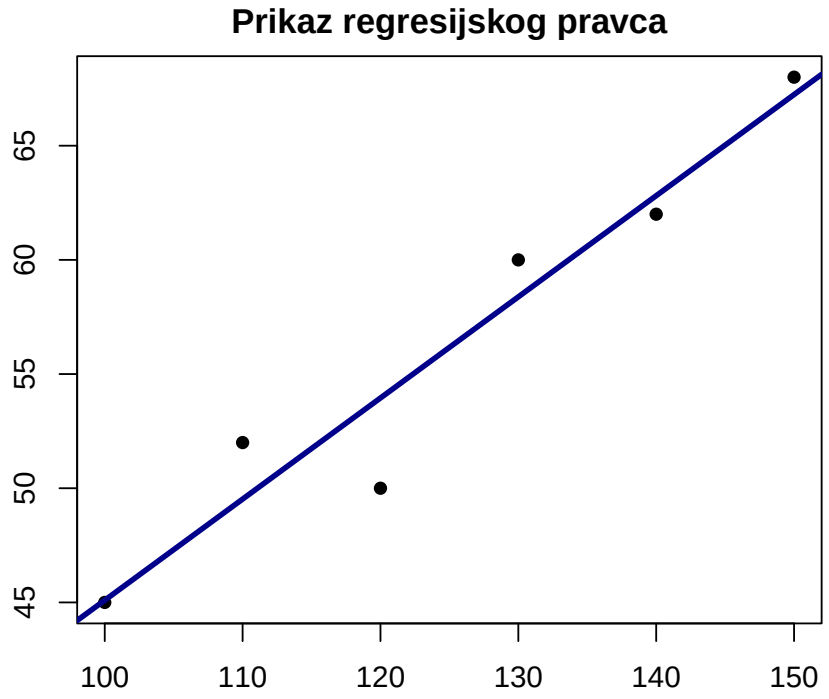
> sxy

[1] 775

> syy

[1] 368.8333
```

Na ovom mjestu si možemo priuštiti i luksuz da nacrtamo regresijski pravac.



7.4 Sažetak poglavlja

Uzorak - niz nezavisnih i jednako distribuiranih slučajnih varijabli $X_1, X_2, \ldots, X_n$.
Opaženi uzorak - realizacija uzorka (to su podaci, brojevi).
Statistika - funkcija slučajnog uzorka koja ne sadrži nepoznate parametre.

Uzoračka sredina

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$$

Uzoračka varijanca

$$S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2.$$

$$E\bar{X}_n = \mu \text{ i } Var(\bar{X}_n) = \frac{\sigma^2}{n}.$$

$$E(S_n^2) = \sigma^2.$$

Procjenitelj parametra θ neke razdiobe je statistika uzorka kojom procjenjujemo taj parametar.
Procjenitelj $\hat{\theta}(X^n)$ je **nepristran** ako za njega vrijedi

$$E(\hat{\theta}(X^n)) = \theta.$$

Srednjekvadratna greška procjenitelja $\hat{\theta}(X^n)$ za parametar θ

$$MSE(\hat{\theta}(X^n)) = E(\hat{\theta}(X^n) - \theta)^2.$$

Ukoliko je $\hat{\theta}(X^n)$ nepristrani procjenitelj za θ, onda je $MSE(\hat{\theta}) = Var(\hat{\theta})$.
Općenito definiramo **pristranost** kao

$$b(\hat{\theta}) = E(\hat{\theta}(X^n)) - \theta,$$

Vrijedi

$$MSE(\hat{\theta}(X^n)) = Var(\hat{\theta}) + b(\hat{\theta})^2.$$

* * * * *

Za $Z_1, Z_2, \ldots, Z_n \sim N(0,1)$ nezavisne slučajne varijable, $n \in \mathbb{N}$, je

$$G = Z_1^2 + Z_2^2 + \ldots + Z_n^2,$$

slučajna varijabla čija je distribucija hi-kvadrat s n stupnjeva slobode, u oznaci $G \sim \chi_n^2$.
Za Z i G_n nezavisne slučajne varijable takve da je $Z \sim N(0,1)$ i $G_n \sim \chi_n^2$ definiramo novu slučajnu varijablu T_n

$$T_n = \frac{Z}{\sqrt{G_n/n}}.$$

Tada slučajna varijabla T_n ima t-razdiobu s n stupnjeva slobode. Za razliku od razdiobe χ^2, t-distribucija je simetrična (poput normalne razdiobe). Za velike n će T_n biti približno distribuirana poput $Z \sim N(0,1)$. Ipak, repovi t-distribucije (vjerojatnosti $P(T_n > x)$ ili $P(T_n < -x)$, za neke pozitivne vrijednosti x) su nešto veći od repova normalne distribucije.

Empirijska funkcija distribucije za uzorak $X_1, X_2, \ldots, X_n$ definira se kao

$$F_n(x) = \frac{1}{n}\sum_{i=1}^{n} I_{\{X_i \le x\}} = \frac{\text{broj } X_i\text{-jeva koji su} \le x}{n}, \quad x \in \mathbb{R}.$$

* * * * *

Postupak testiranja statističkih hipoteza sažeto možemo prikazati kao

1) Odredimo nul hipotezu H_0 i alternativnu hipotezu H_1,

2) Odredimo željenu razinu značajnosti testa $\alpha \in (0,1)$ (tipično mali broj poput $0,05$),

3) Odaberemo testnu statistiku T,

4) Odredimo kritično područje testa C_α za koje vrijedi $P_\theta(T \in C_\alpha) \leq \alpha$, $\theta \in \Theta_0$,

5) Izračunamo vrijednost statistike T za podatke koji su nam dostupni (opaženi uzorak) da dobijemo broj t

6) Ukoliko je $t \in C_\alpha$ odbacujemo H_0

7) Ukoliko $t \notin C_\alpha$ ne odbacujemo H_0

Ukoliko je uzorak $X_1, X_2, \ldots, X_n$ iz normalne razdiobe s poznatom varijancom σ^2 testna statistika je

$$T = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma}.$$

Kritične vrijednosti z_α određuju se iz funkcije distribucije Φ jedinične normalne razdiobe. Ako je $H_0 : \mu = \mu_0$, onda alternativne hipoteze mogu biti

1) $H_0 : \mu = \mu_0$, $H_1 : \mu > \mu_0$ (jednostrani test)

2) $H_0 : \mu = \mu_0$, $H_1 : \mu \neq \mu_0$ (dvostrani test)

3) $H_0 : \mu = \mu_0$, $H_1 : \mu < \mu_0$ (jednostrani test)

dok su odgovarajuća kritična područja

1) $C_\alpha = [z_\alpha, \infty)$

2) $C_\alpha = \mathbb{R} \setminus (-z_\alpha, z_\alpha)$

3) $C_\alpha = (-\infty, -z_\alpha)$.

Ukoliko je uzorak $X_1, X_2, \ldots, X_n$ iz normalne razdiobe s nepoznatom varijancom testna statistika je

$$T = \sqrt{n}\frac{\bar{X}_n - \mu}{S_n}.$$

Kritične vrijednosti $t_{n-1,\alpha}$ određuju se iz funkcije distribucije t-razdiobe s $n-1$ stupnjem slobode. Ovaj se test naziva t-test i primjenjiv je i za uzorke koji nisu iz normalne razdiobe zbog činjenice da t-razdioba konvergira prema jediničnoj normalnoj za velike n.

Definiramo statistiku **uzoračkI koeficijent korelacije** kao

$$R := \frac{S_{XY}}{\sqrt{S_{XX}S_{YY}}}$$

čije su realizacije

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} = \frac{1}{n-1}\sum_{i=1}^{n}\frac{x_i - \bar{x}_n}{s_x} \cdot \frac{y_i - \bar{y}_n}{s_y},$$

gdje su s_x i s_y standardne devijacije podataka (realizacija od X i Y).

* * * * *

Neka je $(X_1, Y_1), (X_2, Y_2), \ldots, (X_n, Y_n)$, $n \in \mathbb{N}$, dvodimenzionalni uzorak čije su realizacije brojevi

$$(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n).$$

U analizi združenih podataka se učestalo koriste sljedeće statistike

$$S_{XX} = \sum_{i=1}^{n} (X_i - \bar{X}_n)^2 = \sum_{i=1}^{n} X_i^2 - n\bar{X}_n^2,$$

$$S_{YY} = \sum_{i=1}^{n} (Y_i - \bar{Y}_n)^2 = \sum_{i=1}^{n} Y_i^2 - n\bar{Y}_n^2$$

i

$$S_{XY} = \sum_{i=1}^{n} (X_i - \bar{X}_n)(Y_i - \bar{Y}_n) = \sum_{i=1}^{n} X_i Y_i - n\bar{X}_n\bar{Y}_n.$$

Za modeliranje podataka linearnom povezanošću, odnosno u slučaju linearne regresije pretpostavljamo da vrijedi

$$Y_i = \alpha + \beta x_i + \epsilon_i, \ i = 1, 2, \ldots, n,$$

gdje su $\alpha, \beta \in \mathbb{R}$, a ϵ_i, $i = 1, 2, \ldots, n$ su slučajne varijable koje se nazivaju **slučajnim pogreškama** (šumovima).

Procjene parametara $\hat{\beta}$ i $\hat{\alpha}$ metodom najmanjih kvadrata

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\alpha} = \bar{y}_n - \hat{\beta}\bar{x}_n.$$

Pravac

$$y = \hat{\alpha} + \hat{\beta}x, \ x \in \mathbb{R}.$$

se naziva **pravcem regresije**.

7.5 Zadaci

Zadatak 7.5.1. *Neki proizvođač čeličnih cijevi proizvodi cijevi čija je deklarirana gustoća* $7.8\ g/cm^3$. *U cilju ispitivanja kvalitete proizvedenih cijevi proizvođač je na slučajan način odabrao 10 cijevi i izmjerio njhovu gustoću. Dobio je redom vrijednosti* $7.6, 7.5, 7.8, 7.9, 7.4, 7.85, 7.65, 7.7, 7.9, 7.7$. *Iz prijašnjih mjerenja proizvođač zna da gustoća cijevi koje proizvodi ima standardnu devijaciju od* $0.2\ g/cm^3$. *Da li proizvođač može tvrditi da cijevi koje proizvodi imaju deklariranu gustoću od* $7.8\ g/cm^3$. *Neka je razina značajnosti testa kojim to želi provjeriti jednaka* 0.05. *Možete iskoristiti* $\Phi(1.96) = 0.025$.

Zadatak 7.5.2. *Neki proizvođač čokoladnih krema s lješnjacima proizvodi kreme s smanjenim udjelom ugljikohidrata. Proizvođač tvrdi da udio ugljikohidrata u 100 grama kreme ne prelazi 25 grama. Na slučajan način je odabran uzorak od 10 pakiranja s tom kremom i mjerena je količina ugljikohidrata u 100 grama kreme. Dobiveni su podaci:* $24,92,\ 24,98,\ 25,11,\ 24,95,\ 24,99,\ 25,03,\ 24,94,\ 25,10,\ 25,14,\ 24,98$. *Da li podaci o količini ugljikohidrata u 100 grama kreme potkrepljuju tvrdnju proizvođača da udio ugljikohidrata u 100 grama kreme ne prelazi 25g? Pretpostavite da je dobiveni uzorak iz normalne razdiobe. Želite odrediti valjanost tvrdnje proizvođača da njegove kreme ne sadrže više od 25 grama ugljikohidrata (u 100 grama kreme) uz razinu značajnosti od* 5%. *Možete iskoristiti da je* $t_{9,0,05} = 1,833$.

Zadatak 7.5.3. *Neki proizvođač baterija je proizveo baterije koje su dizajnirane tako da traju 40 sati. Da bi provjerio tu tvrdnju proizvođač je odabrao slučajni uzorak od 15 baterija. Pretpostavimo da je da je tako dobiveni uzorak iz normalne distribucije. Na osnovi dobivenih podatka (uzorka) izračunato je da je prosječno trajanje baterija iz uzorka bilo* $44,9$ *sati, a također je izračunato da je standardna devijacija uzorka jednaka* $8,9$ *sati. Proizođač želi provjeriti, testirati hipotezu, da je očekivani vijek traja baterija (dakla svih baterija, odnosno cijele populacije) veći od 40 sati uz razinu značajnosti testa od* $0,05$*. Da li proizvođač može na osnovu izmjerenih podatka donijeti takav zaključak. Iskoristite da je* $t_{14,0,05} = 1,761$.

Zadatak 7.5.4. *Neka je T slučajna varijabla koja broji velike svjetske potrese u godini dana (intenziteta većeg od 5 po Mercallijevoj ljestvici). Podaci prikupljeni u 10 godina (od 2002. do 2011.) pokazuju sljedeći broj velikih potresa:*

$$1341, 1358, 1672, 1844, 1865, 2270, 1948, 2057, 2383, 2481.$$

Na te podatke možemo gledati kao na nezavisne realizacije slučajne varijable T. Pretpostavimo da je slučajna varijabla T normalno distribuirana. Da li navedeni podaci podržavaju hipotezu prema kojoj je očekivani broj velikih potresa u godini jednak 1.675 *uz razinu značajnost $\alpha = 0,05$? Uzmite u obzir da je $t_{9,\ 0,025} = 2,265$.*

Zadatak 7.5.5. *Zadana su dva niza podataka: $x = (-2, -1, 0, 1, 2)$ i $y = (4, 3, 3, 1, -1)$ koji su realizacije nekih slučajnih varijabli. Želimo ispitati odnos y (zavisna varijabla) i x (nezavisna varijabla). Nađite jednadžbu regresijskog pravca na osnovu danih podatka.*

Zadatak 7.5.6. *Neki proizvođač automobila mjerio je odnos snage motora automobila i njegove potrošnje te je dobio sljedeće parove podataka:* $(80,\ 5,6)$, $(90,\ 5,8)$, $(100,\ 6,2)$, $(110,\ 6,6)$, $(120,\ 6,8)$ *(prva komponenta svakog uređenog para predstavlja snagu motora, a druga komponenta predstavlja prosječnu potrošnju na 100 kilometara u litrama). Želimo ispitati odnos potrošnje (zavisna varijabla) i snage motora (nezavisna varijabla). Nađite jednadžbu regresijskog pravca na osnovu danih podatka.*

Zadatak 7.5.7. *Neki proizvođač automobila mjerio je odnos težine auta i potrošnje te je dobio sljedeće parove podataka:* $(12,\ 5,6)$, $(13,\ 5,8)$, $(14,\ 6,2)$, $(15,\ 6,6)$, $(16,\ 6,8)$ *(prva komponenta svakog uređenog para predstavlja težinu auta u stotinama kilograma, a druga komponenta predstavlja prosječnu potrošnju na 100 kilometara u litrama). Želimo ispitati odnos potrošnje (zavisna varijabla) i težine auta (nezavisna varijabla). Nađite jednadžbu regresijskog pravca na osnovu danih podatka.*

Zadatak 7.5.8. *Pretpostavimo da se 5 studenata priprema za neki ispit. Naravno, nisu svi posvetili jednako vrijeme pripremi (učenju) za ispit pa su i rezultati na ispitu bili različiti. Konkretno, u sljedećim parovima podataka su prikazani broj sati učenja i broj bodova (postotak) osvojenih na ispitu:* $(4, 40)$, $(8, 60)$, $(12, 75)$, $(16, 80)$, $(20, 90)$. *Želimo ispitati odnos broja sati učenja (nezavisna varijabla) i osvojenih bodova na ispitu (zavisna varijabla). Nađite jednadžbu regresijskog pravca na osnovu danih podatka.*

7.5.1 Rješenja zadataka

Rješenje 83 (Zadatak 7.5.1)**.** Označit ćemo s X slučajnu varijablu koja je jednaka gustoći proizvedenih cijevi (cijele populacije). U zadatku nam je već zadano da je $\sqrt{Var(X)} = \sigma = 0,2$. Izračunamo uzoračku sredinu za uzorak izmjerenih gustoća cijevi. Dobijemo da je $\bar{X}_{10} = 7,7$.

Za nul hipotezu odaberemo $H_0 : \mu = 7,8$, dok je alternativna hipoteza $H_1 : \mu \neq 7.8$ (dvostrana alternativna hipoteza). Zadana je razina značajnosti željenog testa $\alpha = 0.05$.

Vidjeli smo na predavanjima (predavanje 11) da je statistika

$$Z = \sqrt{n}\frac{\bar{X}_n - \mu}{\sigma},$$

normalno distribuirana ($N(0,1)$). Izračunamo vrijednost statistike na osnovi danog uzorka:

$$\sqrt{n}\frac{\bar{X}_n - \mu}{\sigma} = \sqrt{10}\frac{7.7 - 7.8}{0,2} = -1,58.$$

Kod dvoostranog testa smo na predavanjima ustanovili da se nul hipoteza H_0 odbacuje ako je

$$\frac{\sqrt{n}}{\sigma}|\bar{X}_n - \mu_0| > z_{\alpha/2},$$

a u suprotnome se prihvaća. U ovom slučaju to znači da ispitujemo da li je

$$|-1,58| > 1,96.$$

Kako to nije istina prihvaćamo nul hipotezu, odnosno zaključujemo da podaci iz uzorka potvrđuju deklaraciju gustoće proizvođača.

Rješenje 84 (Zadatak 7.5.2)**.** Ovdje imamo uzorak iz normalne razdiobe s nepoznatim očekivanjem i varijancom, odnosno standardnom devijacijom, pa je primjereno upotrijebiti t-test (to bi bilo primjereno i da uzorak nije iz normalne razdiobe, s time da bi se u prakci ipak zahtjevalo da je uzorak nešto veći). Definirajmo nul hipotezu u skladu s tvrdnjom proizvođača

$$H_0 : \mu \leq 25,$$

gdje je μ nepoznato očekivanje količine ugljikohidrata u 100 grama kreme. Uočite, a to smo komentirali u skripti, da je nul hipoteza mogla biti i $H_0 : \mu = 25$, ali je alternativna hipoteza jednostrana, to jest

$$H_1 : \mu > 25.$$

Razina značajnosti testa je $\alpha = 0,05$ dok je testna statistika

$$T = \sqrt{n}\frac{(\bar{X}_n - \mu_0)}{S_n},$$

gdje su $\bar{X}_n$ i S_n procjenitelji za očekivanje i standardnu devijaciju uzorka:

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i,$$

$$S_n = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2}.$$

U našem slučaju je $n = 10$, $\bar{X}_n = 25.014$ i $S_n = 0.07749$. Dakle, vrijednost testne statistike je

$$T = 0,5713.$$

Kako je vrijednost statistike manja od kritične vrijednosti testa $1,833$ zaključujemo da dobiveni podaci potkrepljuju tvrdnju proizvođača.

Rješenje 85 (Zadatak 7.5.3). Neka je X slučajna varijabla koja mjeri vijek trajanja baterije. Odabran je uzorak od 15 baterija i izračunata je uzoračka sredina i uzoračka standardna devijacija jer je već zadano $\bar{X}_{15} = 44,9$ i $S_{15} = 8,9$. U zadatku je navedeno da možemo pretpostaviti da je uzorak iz normalne distribucije pa je primjereno upotrijebiti t-test. Za nul hipotezu ćemo odabrati $H_0 : \mu = 40$, dok je alternativna hipoteza $H_1 : \mu > 40$, pri čemu je μ nepoznato očekivanje vijeka trajanja baterija cijele populacije (dakle, svih baterija koje se proizvode).

Dakle, imamo jednostrani t-test u kojem želimo provjeriti da li podaci potvrđuju hipotezu da je $\mu = 40$ ili su u suglasju s alternativnom hipotezom. Stoga ćemo kao kritično područje (područje za koje provjeravamo da li se u njemu nalazi izračunata vrijednost statistike) uzeti jednostrani interval brojeva većih od $t_{14,0,05} = 1,761$. Testna statistika je

$$T = \sqrt{n}\frac{(\bar{X}_n - \mu_0)}{S_n}.$$

Prema uvjetima zadatka je

$$T = \sqrt{15}\frac{(44,9 - 40)}{8,9} \approx 2,13.$$

Kako je vrijednost testne statistike veća od $t_{14,0,55} = 1,761$ odbacujemo nul hipotezu da je $\mu = 40$, odnosno dani uzorak podržava hipotezu da je očekivani vijek trajanja baterija veći od 40 sati.

Rješenje 86 (Zadatak 7.5.4). Prema pretpostavkama zadatka, imamo uzorak iz normalne razdiobe kojoj nisu poznati niti očekivanje niti varijanca. S obzirom da trebamo procijeniti i očekivanje i varijancu uzorka primjereno je koristiti t-test. Znamo da je u tom slučaju testna statistika

$$T = \sqrt{n}\frac{(\bar{X}_n - \mu_0)}{S_n}.$$

Za nul hipotezu uzmimo $H_0 : \mu_0 = 1.675$, a za alternativnu $H_1 : \mu_0 \neq 1.675$. Hipoteza H_0 se odbacuje ukoliko je apsolutna vrijednost testne statistike veća od $t_{9,\ 0,025} = 2,265$. Prema zadanim podacima računamo

$$\bar{X}_n = 1921,9,$$

$$S_n = 393,347$$

pa je vrijednost testne statistike jednaka

$$T = \sqrt{9}\frac{(1921,9 - 1675)}{393,347} = 1,88307.$$

Kako je vrijednost testne statistike manja od $t_{9,\ 0,025} = 2,265$ ne možemo odbaciti nul hipotezu. Dakle, podaci nisu u suprotnosti s pretpostavljenom nul hipotezom.

Rješenje 87 (Zadatak 7.5.5). U ovom zadatku trebamo iskoristiti formule iz potpoglavlja 7.3, s time da se traži regresijski pravac za niz uparenih podataka u kojima su realizacije nezavisne varijable $x_1 = -2$, $x_2 = -1$, $x_3 = 0$, $x_4 = 1$ i $x_5 = 2$, a realizacije zavisne varijable su $y_1 = 4$, $y_2 = 3$, $y_3 = 3$, $y_4 = 1$ i $y_5 = -1$. Najprije izračunamo aritmetičke sredine tih brojeva

$$\bar{x}_5 = \frac{x_1 + x_2 + x_3 + x_4 + x_5}{5} = 0$$

i

$$\bar{y}_5 = \frac{y_1 + y_2 + y_3 + y_4 + y_5}{5} = 2.$$

Regresijski pravac računamo po formuli

$$y = \hat{\alpha} + \hat{\beta}x,$$

gdje su

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\alpha} = \bar{y}_n - \hat{\beta}\bar{x}_n$$

i

$$S_{xx} = \sum_{i=1}^{n}(x_i - \bar{x}_n)^2, \quad S_{xy} = \sum_{i=1}^{n}(x_i - \bar{x}_n)(y_i - \bar{y}_n).$$

Izračunajmo gore navedene izraze. Imamo redom

$$S_{xx} = \sum_{i=1}^{5}(x_i - 0)^2 = (-2-0)^2 + (-1-0)^2 + (0-0)^2 + (1-0)^2 + (2-0)^2 = 10,$$

$$\begin{aligned} S_{xy} = \sum_{i=1}^{5}(x_i - 0)(y_i - 2) &= (-2-0)(4-2) + (-1-0)(3-2) + (0-0)(3-2) \\ &\quad + (1-0)(1-2) + (2-0)(-1-2) \\ &= -2\cdot 2 - 1\cdot 1 + 1\cdot(-1) + 2\cdot(-3) = -12, \end{aligned}$$

$$\hat{\beta} = \frac{-12}{10} = -1,2$$

i

$$\hat{\alpha} = 2 - 1,2\cdot 0 = 2.$$

Dakle, jednadžba regresijskog pravca je

$$y = 2 - 1,2x.$$

Rješenje 88 (Zadatak 7.5.6)**.** U ovom zadatku trebamo iskoristiti formule iz potpoglavlja 7.3, s time da se traži regresijski pravac za niz uparenih pdataka u kojima su realizacije nezavisne varijable $x_1 = 80$, $x_2 = 90$, $x_3 = 100$, $x_4 = 110$ i $x_5 = 120$, a realizacije zavisne varijable su $y_1 = 5,6$, $y_2 = 5,8$, $y_3 = 6,2$, $y_4 = 6,6$ i $y_5 = 6,8$. Za račun će nam trebati aritmetičke sredine tih brojeva

$$\bar{x}_5 = \frac{x_1 + x_2 + x_3 + x_4 + x_5}{5} = 100$$

i

$$\bar{y}_5 = \frac{y_1 + y_2 + y_3 + y_4 + y_5}{5} = 6.2.$$

U (7.30) smo vidjeli da se regresijski pravac računa kao

$$y = \hat{\alpha} + \hat{\beta}x,$$

gdje su

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\alpha} = \bar{y}_n - \hat{\beta}\bar{x}_n$$

i

$$S_{xx} = \sum_{i=1}^{n}(x_i - \bar{x}_n)^2, \quad S_{xy} = \sum_{i=1}^{n}(x_i - \bar{x}_n)(y_i - \bar{y}_n).$$

Sada trebamo izračunati gore navedene izraze. Imamo redom

$$S_{xx} = \sum_{i=1}^{5}(x_i - 100)^2 = (80-100)^2 + (90-100)^2 + (100-100)^2 + (110-100)^2 + (120-100)^2 = 1000,$$

$$\begin{aligned} S_{xy} = \sum_{i=1}^{5}(x_i - 60)(y_i - 6,2) &= (80-100)(5,6-6,2) + (90-100)(5,8-6,2) \\ &\quad + (100-100)(6,2-6,2) \\ &\quad + (110-100)(6,6-6,2) + (120-1000)(6,8-6,2) \\ &= -20\cdot(-0,6) - 10\cdot(0,4) + 10\cdot 0,4 + 20\cdot 0,6 = 32, \end{aligned}$$

$$\hat{\beta} = \frac{32}{1000} = 0,032$$

i

$$\hat{\alpha} = 6,2 - 0,032\cdot 100 = 3,00.$$

Dakle, jednadžba regresijskog pravca je

$$y = 3 + 0,032x.$$

Rješenje 89 (Zadatak 7.5.7). U ovom zadatku trebamo iskoristiti formule iz potpoglavlja 7.3, s time da se traži regresijski pravac za niz uparenih pdataka u kojima su realizacije nezavisne varijable $x_1 = 12$, $x_2 = 13$, $x_3 = 14$, $x_4 = 15$ i $x_5 = 16$, a realizacije zavisne varijable su $y_1 = 5,6$, $y_2 = 5,8$, $y_3 = 6,2$, $y_4 = 6,6$ i $y_5 = 6,8$. Za račun će nam trebati aritmetičke sredine tih brojeva

$$\bar{x}_5 = \frac{x_1 + x_2 + x_3 + x_4 + x_5}{5} = 14$$

i

$$\bar{y}_5 = \frac{y_1 + y_2 + y_3 + y_4 + y_5}{5} = 6.2.$$

U (7.30) smo vidjeli da se regresijski pravac računa kao

$$y = \hat{\alpha} + \hat{\beta}x,$$

gdje su

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\alpha} = \bar{y}_n - \hat{\beta}\bar{x}_n$$

i

$$S_{xx} = \sum_{i=1}^{n}(x_i - \bar{x}_n)^2, \quad S_{xy} = \sum_{i=1}^{n}(x_i - \bar{x}_n)(y_i - \bar{y}_n).$$

Sada trebamo izračunati gore navedene izraze. Imamo redom

$$S_{xx} = \sum_{i=1}^{5}(x_i - 14)^2 = (12-14)^2 + (13-14)^2 + (14-14)^2 + (15-14)^2 + (16-14)^2 = 10,$$

$$S_{xy} = \sum_{i=1}^{5}(x_i - 14)(y_i - 6,2) = (12-14)(5,6-6,2) + (13-14)(5,8-6,2) + (14-14)(6,2-6,2) + (15-14)(6,6-6,2) + (16-14)(6,8-6,2) = -2\cdot(-0,6) - 1\cdot(0,4) + 1\cdot 0,4 + 2\cdot 0,6 = 3.2,$$

$$\hat{\beta} = \frac{3,2}{10} = 0,32$$

i

$$\hat{\alpha} = 6,2 - 0,32 \cdot 14 = 1,72.$$

Dakle, jednadžba regresijskog pravca je

$$y = 1,72 + 0,32x.$$

Rješenje 90 (Zadatak 7.5.8). Nađimo pomoću R-a traženi pravac regresije (najbolju procjenu danih parova podataka u smislu minimizacije srednjekvadratne greške).

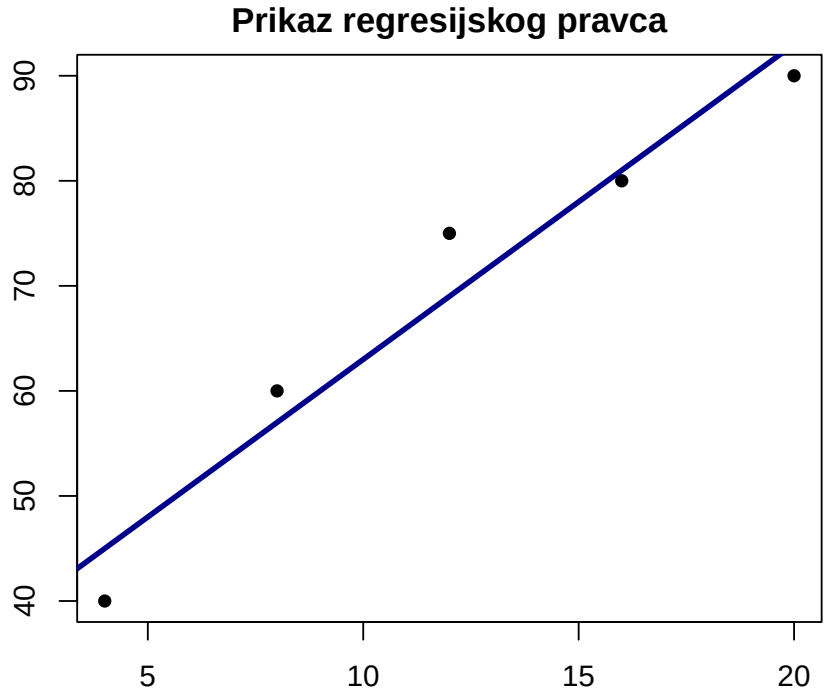
```
> xz<-c(4,8,12,16,20)
> yz<-c(40,60,75,80,90)
> cor(xz,yz)

[1] 0.9733285

> xypodaci<-lm(yz ~ xz)
> xypodaci

Call:
lm(formula = yz ~ xz)

Coefficients:
(Intercept)           xz
         33            3
```



U zadatku se od nas traži da nađemo koeficijente $\hat{\alpha}$ i $\hat{\beta}$ regresijskog pravca

$$y = \hat{\alpha} + \hat{\beta}x.$$

Rekli smo da je

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\alpha} = \bar{y}_n - \hat{\beta}\bar{x}_n,$$

gdje je

$$S_{xx} = \sum_{i=1}^{n}(x_i - \bar{x}_n)^2 = \sum_{i=1}^{n} x_i^2 - n\bar{x}_n^2 \quad \text{i}$$

$$S_{xy} = \sum_{i=1}^{n}(x_i - \bar{x}_n)(y_i - \bar{y}_n) = \sum_{i=1}^{n} x_i y_i - n\bar{x}_n\bar{y}_n.$$

Dakle, najprije trebamo izračunati $\bar{x}_n$ i $\bar{y}_n$, gdje je $n = 5$. Dobijemo

$$\bar{x}_5 = \frac{4 + 8 + 12 + 16 + 20}{5} = 12,$$

$$\bar{y}_5 = \frac{40 + 60 + 75 + 80 + 90}{5} = 69.$$

U prošlim zadacima smo koristili izraze za S_{xx} i S_{xy} koji su navedeni odmah iza prve jednakosti, ali možemo koristiti i

$$S_{xx} = \sum_{i=1}^{n} x_i^2 - n\bar{x}_n^2 \quad \text{i}$$

$$S_{xy} = \sum_{i=1}^{n} x_i y_i - n\bar{x}_n\bar{y}_n.$$

Sada je

$$\sum_{i=1}^{5} x_i^2 = 4^2 + 8^2 + 12^2 + 16^2 + 20^2 = 880$$

pa je

$$S_{xx} = 880 - 5 \cdot 12^2 = 160.$$

Slično,

$$\sum_{i=1}^{5} x_i y_i = 4 \cdot 40 + 8 \cdot 60 + 12 \cdot 75 + 16 \cdot 80 + 20 \cdot 90 = 4620$$

pa je

$$S_{xy} = 4620 - 5 \cdot 12 \cdot 69 = 480.$$

Stoga je

$$\hat{\beta} = \frac{S_{xy}}{S_{xx}} = \frac{480}{160} = 3$$

i

$$\hat{\alpha} = \bar{y}_5 - \hat{\beta}\bar{x}_5 = 69 - 3 \cdot 12 = 33.$$

Dakle, jednadžba regresijskog pravca je

$$y = 3x + 33.$$

Uočite da nam izračun regresijskog pravca omogućava da procijenimo potrebno vrijeme učenja za dobivanje nekog prosjeka (naravno, ako su podaci koje smo dobili u zadatku reprezentativni za cijelu populaciju promatranih studenata). Tako, na primjer, za dobivanje $y = 70$ bodova na ispitu treba učiti

$$x = \frac{70 - 33}{3} = 12,33 \text{ sata}.$$

Literatura

[1] Bojan Basrak, *Statistika, s primjerima u R-u*, PMF, Sveučilište u Zagrebu (skripta); dostupna na https://web.math.pmf.unizg.hr/~bbasrak/?Courses_%2F_Nastava

[2] Mirta Benšić, Nenad Šuvak, *Uvod u vjerojatnost i statistiku*, Sveučilište J.J. Strossmayera, Odjel za matematiku, Osijek, 2014.

[3] Joseph K. Blitzstein, Jessica Hwang, *Introduction to Probability*, Second Edition, CRC Press, Taylor & Francis Group, Boca Raton, 2019.

[4] Rama Cont, *Empirical properties of asset returns: stylized facts and statistical issues*, Quantitative Finance, 1:2, 223-236, 2001.

[5] Neven Elezović, *Vjerojatnost i statistika, Diskretna vjerojatnost*, Element, Zagreb, 2015.

[6] William Feller, *An Introduction to Probability Theory and Its Applications, Volume I*, Third Edition (Revised Printing), John Wiley & Sons, 1970.

[7] Prakash Gorroochurn, *Classic Problems of Probability*, First Edition, John Wiley & Sons, 2012.

[8] Ambrose Lo, *Demystifying the Integrated Tail Probability Expectation Formula*, The American Statistician, 73:4, 367-374, 2019.

[9] Svetozar Kurepa, *Matematička analiza 1: Diferenciranje i integriranje*, Tehnička knjiga, Zagreb, 1984.

[10] Nikola Sarapa, *Teorija vjerojatnosti*, Školska knjiga, Zagreb, 1992.

[11] Sheldon M. Ross, *Introduction to Probability and Statistics for Engineers and Scientists*, Fifth Edition, Academic Press (Elsevier), 2014.

[12] Sheldon M. Ross, *Probability Models for Computer Science*, Harcourt/Academic Press, 2002.

[13] Aris Spanos, *Probability Theory and Statistical Inference, Empirical Modeling with Observational Data*, Second Edition, Cambridge University Press, 2019.

[14] Darko Veljan, *Kombinatorna i diskretna matematika*, Algoritam, Zagreb, 2001.

[15] Larry Wasserman, *All of Statistics, A Concise Course in Statistical Inference*, Springer New York, NY, 2003.

Kazalo

Aritmetička sredina, 28, 295

Bayesova formula, 166
Binomna formula, 116
Binomni koeficijent, 109, 116

Cauchy-Schwarzova nejednakost, 332
Centralni granični teorem, 339

Distribucija diskretne sl. var., 203
Događaj, 142

Elementarni događaji, 96, 142
Empirijska funkcija distribucije, 373

Formula potpune vjerojatnosti, 167
Frekvencija podataka, 23
    relativna, 23
Funkcija
    poopćeni inverz, 261
Funkcija distribucije, 207, 224
    empirijska, 373
    repna, 314
Funkcija gustoće, 212, 239

Gotovo sigurno, 241

Hipoteza
    alternativna, 376
    nul, 376
Histogram, 39

i.i.d., 329
Indikator skupa, 214, 253, 309
Integral, 230
    linearnost, 231
    monotonost, 231
    neodređeni, 231
    Određeni, 230
Interkvartilni raspon, 33, 37

Jaki zakon velikih brojeva, 334
Jensenova nejednakost, 333

Koeficijent
    korelacije, 46
    varijacije, 33
Kombinacije
    bez ponavljanja, 109
    s ponavljanjem, 110
Kombinatorni dokaz, 117
Konvergencija
    gotovo sigurno, 334
    po distribuciji, 339
    po vjerojatnosti, 334
Korelacija, 46
    slučajnih varijabli, 323
Kovarijanca
    slučajnih varijabli, 321
Kritična vrijednost, 377
Kritično područje, 377
Kurtosis razdiobe, 319
Kvantil, 37
Kvartil, 37

Linearna funkcija, 88
Linearna regresija, 391
Lista
    ispis elemenata, 58
Logistička slučajna varijabla, 318

Markovljeva nejednakost, 330
Matematičko očekivanje
    v. Očekivanje, 294
Medijan, 29
    slučajne varijable, 320
Metoda momenata, 368
Mod, 29
    slučajne varijable, 320
Moivre-Laplaceov CGT, 341
Monotonost vjerojatnosti, 142
Multiskup, 74, 111

Nejednakost
    Cauchy-Schwarzova, 332
    Jensenova, 333
    Markovljeva, 330
    Čebiševljeva, 330
Nekorelirane slučajne varijable, 323, 353
Nezavisne slučajne varijable, 222

Nezavisnost
događaja, 150

Odabiri bez ponavljanja
nije važan poredak, 109
važan je poredak, 106
Odabiri s ponavljanjem
nije važan poredak, 110, 115
važan je poredak, 105, 112
Opaženi uzorak, 366
Oznaka za umnožak $\prod$, 104
Oznaka za zbroj $\sum$, 103
Očekivanje
diskretne sl.var, 294
neprekidne sl.var, 295
populacijsko, 368

Particija skupa, 149, 202
Pascalov trokut, 116, 124
Percentil, 36
Permutacija, 107, 109
riječi, 113
s ponavljanjem, 113
Podaci
diskretni, 22
kvalitativni, 24
kvantitativni, 27
neprekidni, 22
Populacija, 22, 364
Potpun sustav događaja, 166
Praslika, 195
Procjena parametra, 369
Procjenitelj, 369
nepristrani, 370
srednjekvadratna greška, 370
Prostor elementarnih događaja, 73, 96, 140
produktni, 154

R funkcija
apply(), 172
R Funkcije
qnorm(), 346
R funkcije
aggregate(), 56, 61
append(), 11
as.numeric(), 31
barplot(), 26
boxplot(), 43
by(), 54
c(), 9
choose, 124
class(), 14
cor(), 48
count(), 26
cumsum(), 27
data.frame(), 17
dbinom(), 217
dchisq(), 372
dexp(), 251
dgeom(), 218
dgumbel(), 258
dim(), 15
dnorm(), 246
dpois(), 220
factorial(), 124
getwd(), 18
gsub(), 58
head(), 59
hist(), 40
integrate(), 232
intersect(), 12
korisnički definirane funkcije, 31
length(), 7
matrix(), 14
mean(), 30
median(), 30
mode(), 7
order(), 59
pairs(), 49
paste0(), 57
pbinom(), 217
pbirthday(), 126
pexp(), 251
pgeom(), 218
plot(), 48, 65
pnorm(), 245
ppois(), 220
print(), 6
qnorm(), 247
range(), 38
rbinom(), 217
read_html(), 57
read.xlsx(), 18
rep(), 10
replicate(), 125, 172
rgeom(), 218
rnorm(), 249
rpois(), 220
rug(), 60, 66
runif(), 254
sample(), 125, 172, 177
sd(), 33
segments(), 197

seq(), 10
set.seed(), 125, 172
setdiff(), 12
setwd(), 18
str(), 17
summary(), 38, 51
table(), 25
tail(), 59
typeof(), 14
var(), 32
which(), 12
write.xlsx(), 21
Raspon podataka, 32
Razdioba, 194, 203
Binomna, 215
diskretna uniformna, 213
eksponencijalna, 251
geometrijska, 218
Gumbelova, 257
hipergeometrijska, 219
Jedinična normalna, 244
kurtosis, 319
normalna, 243
Paretova, 258
Poissonova, 220
teški repovi, 319
ukošenost, 316
uniformna, 253
zajednička, 222, 321, 327
Razina značajnosti testa, 377
Razred, 41
Realizacije sl. var., 366
Relativna frekvencija podataka, 23
Repna vjerojatnost, 314

Sigma algebra, 141
Simetrična kockica, 100
Simetrični novčić, 100
Simulacija, 128
Skewness
v. ukošenost, 316
Skup
De Morganova pravila, 81, 359
disjunktni skupovi, 81
element skupa, 74
jednakost skupova, 76
Kartezijev produkt, 93
komplement skupa, 81
neprebrojivi skup, 90
partitivni skup, 86
podskup, 76
pravi podskup, 76
prazan, 76
prebrojivi skup, 90
presjek, 80
razlika skupova, 81
simetrična razlika, 85
unija, 78
Skupovna inkluzija, 77
Slabi zakon velikih brojeva, 333
Slučajna varijabla, 194
Bernoullijeva, 214, 309
Binomna, 214
diskretna, 202
diskretna uniformna, 213
distribucija, 203
eksponencijalna, 251
geometrijska, 218
hipergeometrijska, 219
jedinična normalna, 244
neprekidna, 239
nezavisne sl. var., 222
normalna, 243
Paretova, 258
Poissonova, 220
razdioba, 203
uniformna, 253
zavisne sl. var., 223
Slučajni događaj, 96, 142
suprotni (komplement), 141
Slučajni eksperiment, 73, 140
Slučajni vektor, 224
Središnja vrijednost
v. Medijan, 29
Srednja vrijednost
v. Aritmetička sredina, 28
Standardizacija
normalne sl. var., 244
općenite sl. var., 316
Standardna devijacija
slučajne varijable, 302
standardna devijacija podataka, 33
Statistika, 367
testna, 377
uređajna, 37
Statistički model, 364
Statistički modeli
neparametarski, 365
parametarski, 365

t-test, 385
Tablica (relativnih) frekvencija, 23
Testiranje statističkih hipoteza, 376
Testna Statistika, 377

Teški repovi, 319
Tidyverse, 56
    magritt, 57
    rvest, 57

Ukošenost razdiobe, 316
Uvjetna vjerojatnost, 159
    Bayesova formula, 166
    formula potpune vjerojatnosti, 167
Uzorak, 22
    slučajan, 365
    uzoračka sredina, 367
    uzoračka varijanca, 367

Varijable
    diskretne, 22
    neprekidne, 22
Varijacije
    bez ponavljanja, 107
    s ponavljanjem, 106
Varijanca
    slučajne varijable, 302
    varijanca podataka, 32
Viši momenti sl.var., 314
Vjerojatnosni prostor, 142
    diskretan, 144
    produktni, 154
Vjerojatnost, 142
    σ-aditivnost, 142
    σ-poluaditivnost, 142
    disjunktne unije, 119
    konačna aditivnost, 141, 142
    naivna definicija, 100, 118
    produktna, 154
    repna, 246
    suprotnog događaja, 100, 119, 141
    uniformna, 146
    uvjetna, 159

Zajednička razdioba sl. var., 222, 321, 327

Čebiševljeva nejednakost, 330